머신러닝 프로그래밍
Machine Learning Programming

Lecture 6 : k-Nearest Neighbor

충북대학교
CHUNGBUK NATIONAL UNIVERSITY
충북대학교
산업인공지능연구센터

k-Nearest Neighbor

■ 모델 기반 학습

- 훈련 데이터로부터 모델 f의 파라미터(가중치)를 최적화하여 최적의 함수 f^* 생성
- 한 번 모델 생성을 완료하면 테스트 데이터에 대해서는 단순하게 함수 f^* 의 연산으로 예측값 도출
- 선형회귀, 로지스틱회귀, 퍼셉트론, 다층 퍼셉트론 등이 모델 기반 학습 방법

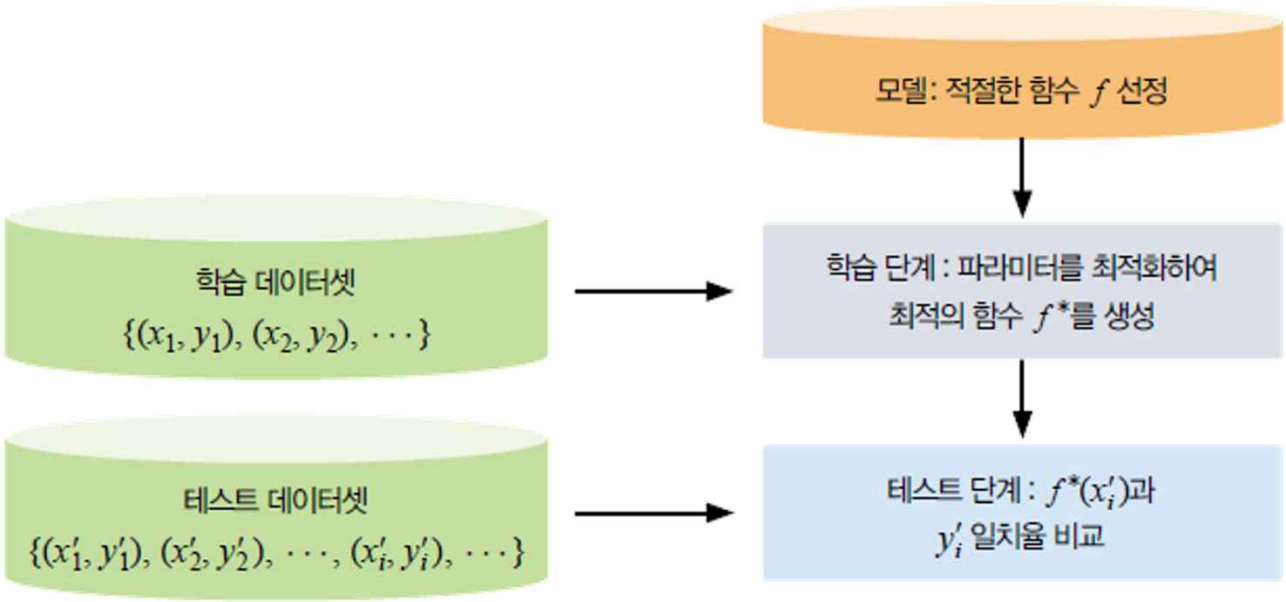

그림1. 모델 기반 학습 예

k-Nearest Neighbor

■ 사례 기반 학습

- 별도의 모델을 생성하지 않는 방식
- 테스트 데이터가 입력될 때마다 학습 데이터를 기반으로 예측값 연산
- k-최근접 이웃이 대표적인 사례 기반 학습 방법임

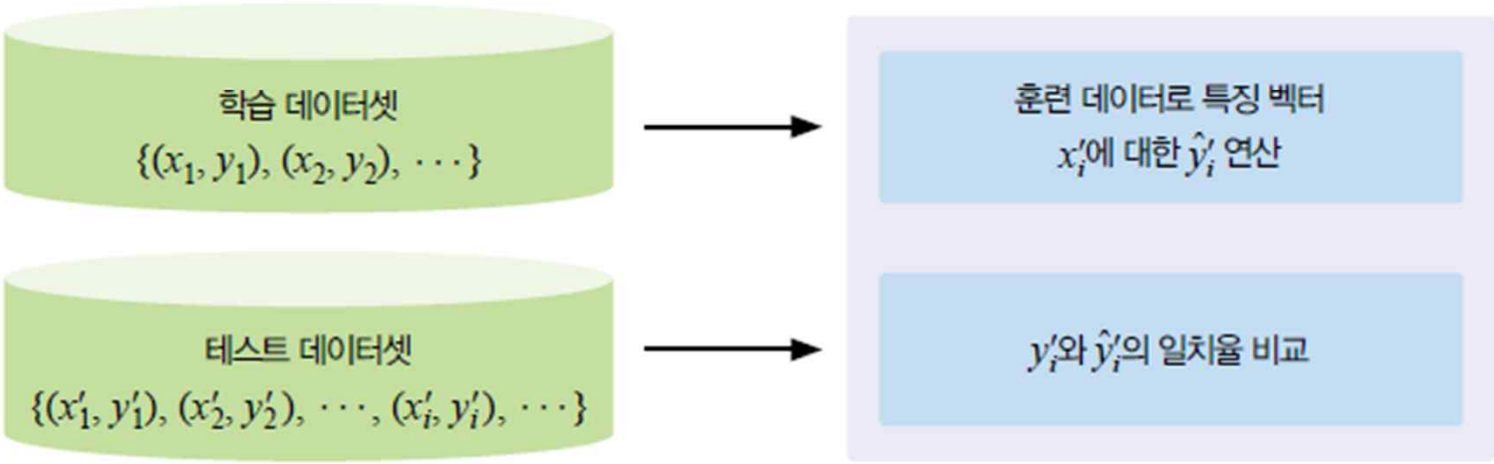

그림2. 사례 기반 학습 예

k-Nearest Neighbor

- **k 최근접 이웃(k-Nearest Neighbor)**
  - 지도학습 방법의 하나로, 새로운 데이터를 기존 데이터와 비교하여 분류하는 알고리즘

▪ **1-최근접 이웃(k=1)**

- 새로운 데이터에 대해서 기존 데이터와 가장 유사한 데이터는?
  → 해당 데이터와 동일하게 분류
- k는 근접해 있는 데이터 중 몇 개를 확인할 것인지를 의미한다.

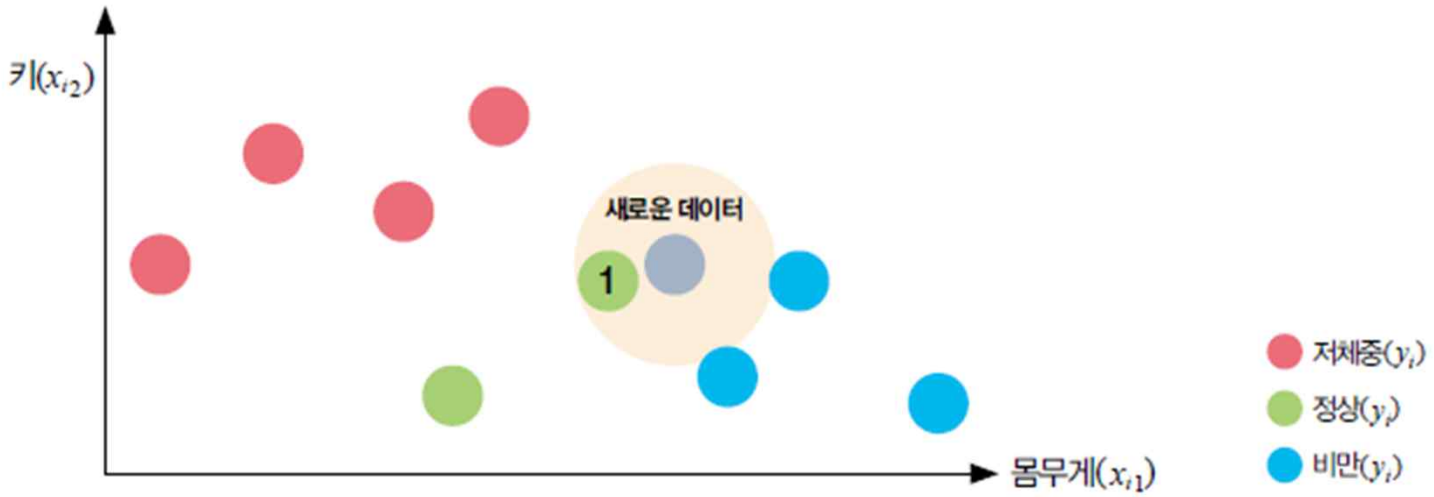

그림3. k-최근접 이웃 예(k=1)

k-Nearest Neighbor

- k의 값에 따라 새로운 데이터가 어떤 이산형 실제값을 가질지 예측해보자.

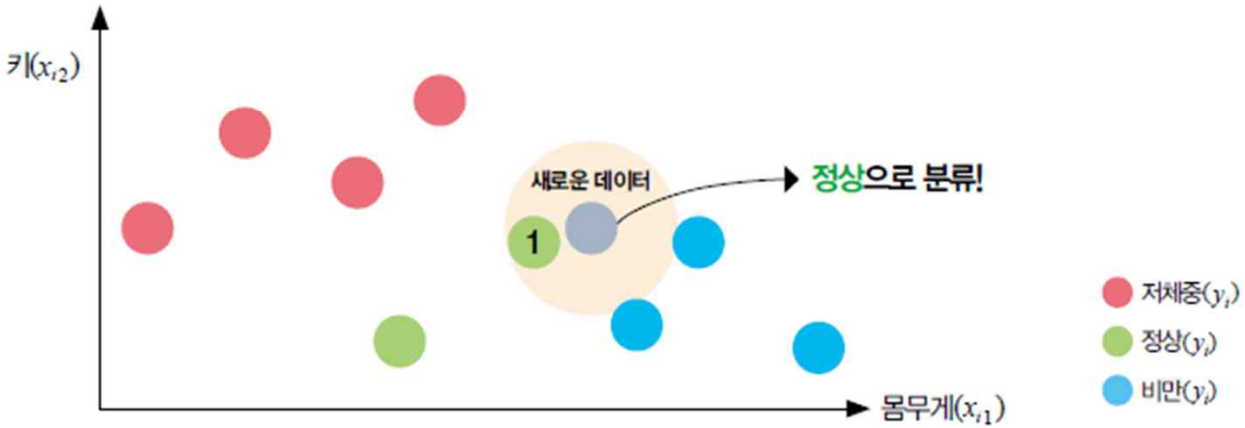

그림4. k-최근접 이웃 예(k=1)

k-Nearest Neighbor

- **3 최근접 이웃(k=3)**
  - k=3일 때 새로운 데이터는 어떻게 새로운 이산형 실제값을 결정해줄까?
  - 주변 데이터의 이산형 실제값에 따라 다수결로 새로운 이산형 실제값을 결정한다.

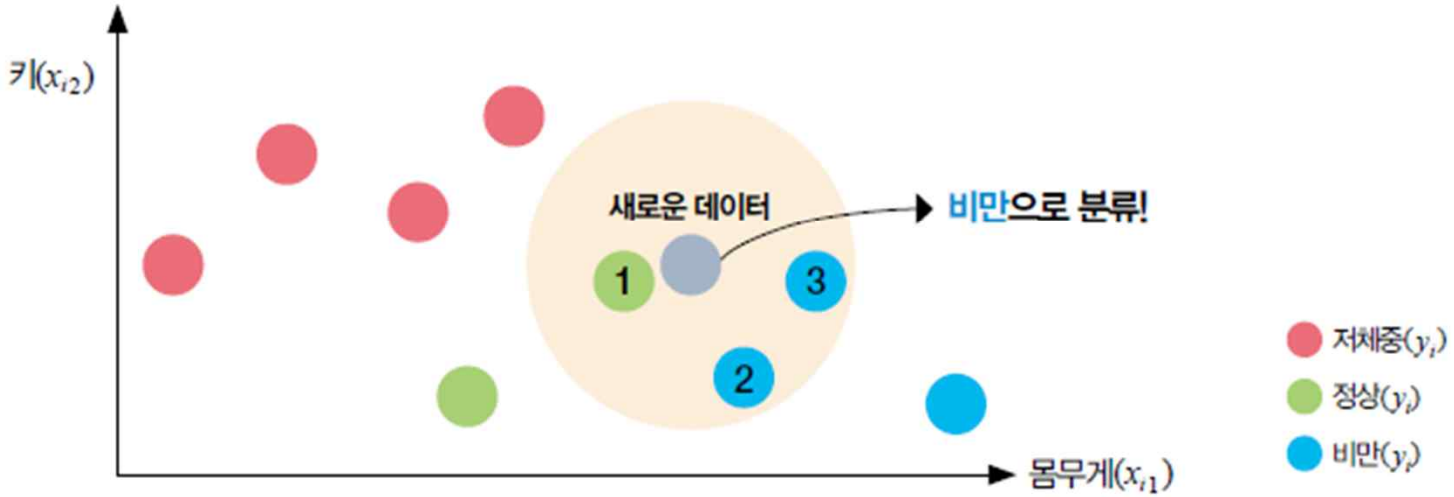

그림5. k-최근접 이웃 예(k=3)

k-Nearest Neighbor

거리 측도

- 테이블 데이터에서는 근접한 데이터를 어떻게 계산할까? → 거리측도
- 새로운 데이터가 발생한 이후에 실제값 예측 수행됨 → 사례 기반 학습의 특징

– 아래 표의 데이터로 유클리드 거리와 맨해튼 거리에 대해 알아보자.

표 1. 키-몸무게 등급에 따른 비만 여부

	몸무게(x_{i1})	키(x_{i2})	비만 여부(y_i)
생도 1	1	0	0
생도 2	2	1	0
생도 3	3	3	0
생도 4	5	2	1
생도 5	5	4	1
생도 6	6	5	1
생도 7	9	2	1
신입 생도	3	4	?

k-Nearest Neighbor

■ 유클리드 거리

- 가장 많이 사용하는 거리측도 → 고등수학 과정의 직선 거리, 점과 점 사이의 거리
- 대응되는 관측치의 특징벡터 간 차이 제곱 합의 제곱근

$$\text{Euclidean Distance}(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{\sum_{j=1}^{p} (x_{1j} - x_{2j})^2}$$

- p : 데이터(특징 벡터)를 구성하는 성분의 수

$$\text{Euclidean Distance}(\mathbf{x}_3, \mathbf{x}_7) = \sqrt{(3-9)^2 + (3-2)^2} = \sqrt{37} \approx 6.08$$

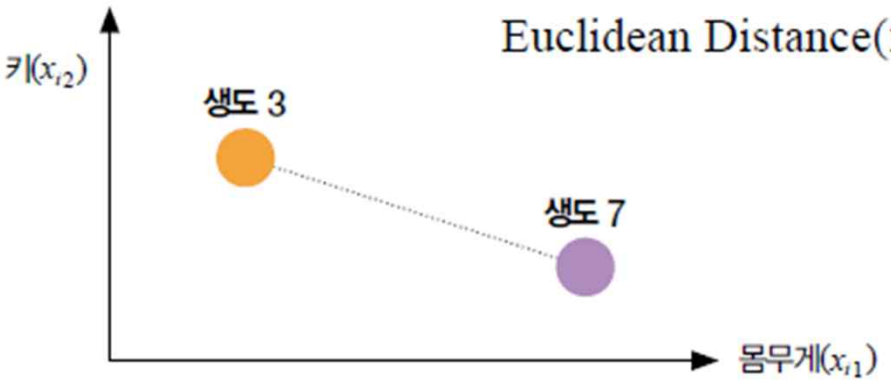

그림6. 유클리드 거리 예

k-Nearest Neighbor

■ 맨해튼 거리

– 일상생활에서는 잘 사용하지 않으나, 머신러닝 혹은 프로그래밍에서 종종 사용

– 실제 뉴욕의 맨해튼과 같은 구획에서 이동할 때는 맨해튼 거리처럼 이동해야함

$$\text{Manhattan Distance}(\mathbf{x}_1, \mathbf{x}_2) = \sum_{j=1}^{p} \left| x_{1j} - x_{2j} \right|$$

- p : 데이터(특징 벡터)를 구성하는 성분의 수

$$\text{Manhattan Distacne}(\mathbf{x}_3, \mathbf{x}_7) = |3 - 9| + |3 - 2| = 7$$

k-Nearest Neighbor

그림7. 맨해튼 지도

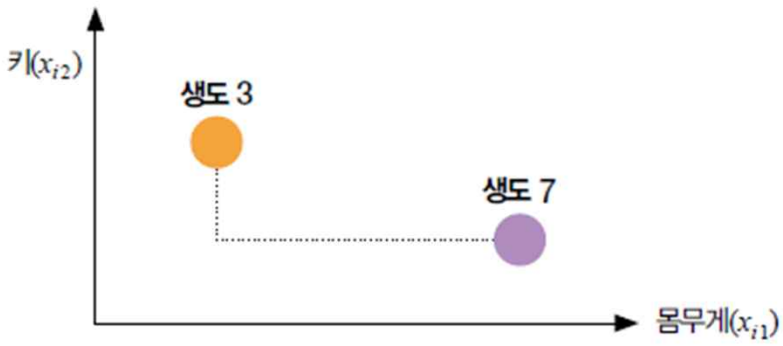

그림8. 맨해튼 거리 예

k-최근접 이웃을 통한 분류

- **k-최근접 이웃 동작 단계**
  - 목적: 새로운 데이터의 예측값을 결정하기 위한 3단계 과정
  - **1단계: 거리 계산**
    - 모든 학습 데이터와 새로운 데이터 사이의 거리 계산, 유클리드 거리(기본값) 사용
  - **2단계: 가까운 데이터 탐색**
    - k 값에 따라 가까운 데이터 탐색(예시: k=3)

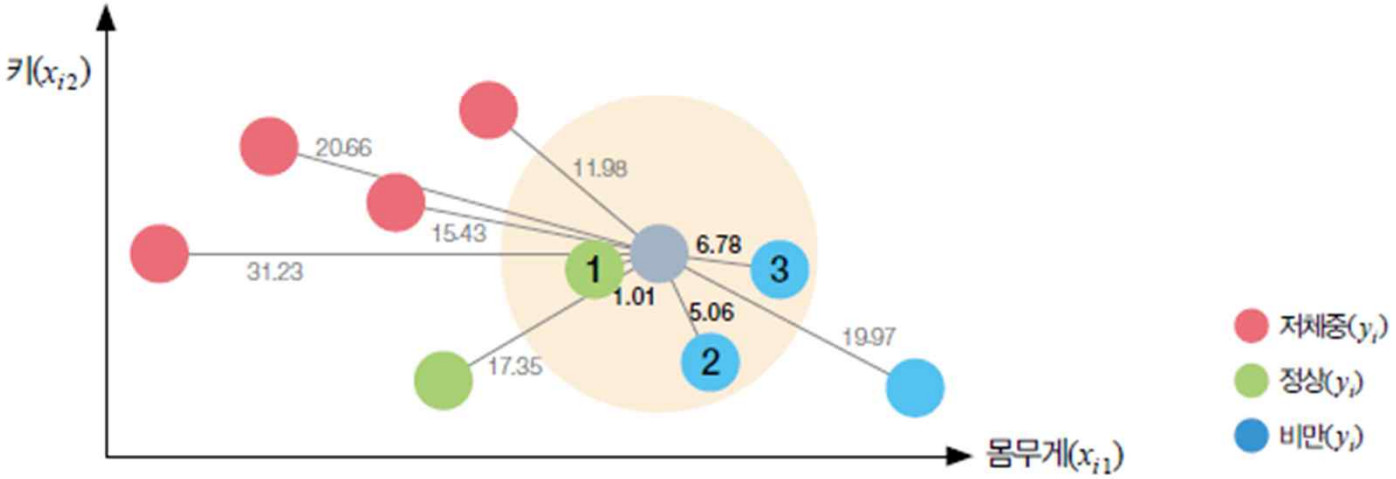

그림9. k-최근접 이웃을 통한 분류 예(k=3): 1,2 단계

k-최근접 이웃을 통한 분류

- **3단계: 예측값 결정**
  - k개의 데이터에서 가장 많이 등장한 이산형 실제값으로 예측

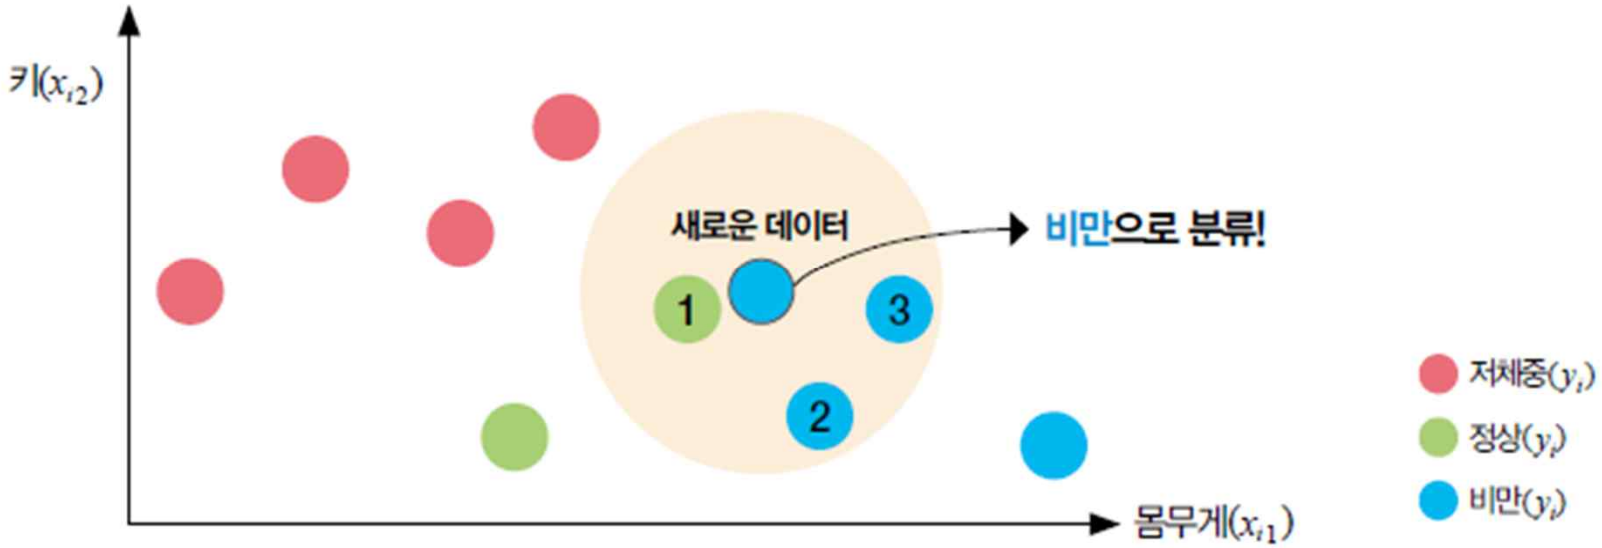

그림10. k-최근접 이웃을 통한 분류 예(k=3): 3 단계

k-최근접 이웃을 통한 분류

- **k-최근접 이웃 예제(분류)**
  - 생도의 유전자 정보와 코로나 확진 여부가 주어졌다.
  - 신입 생도의 코로나 확진 여부를 k-최근접 이웃 문제를 통해 예측해보자. (k=1, k=3)

표2. 유전자 정보에 따른 코로나 확진 여부 데이터(분류)

	유전자 1	유전자 2	유전자 3	유전자 4	확진 여부(y_i)
생도 A	2.54	4.33	3.99	2.57	정상
생도 B	3.12	3.87	3.84	3.04	정상
생도 C	2.76	4.17	5.63	3.28	정상
생도 D	3.87	3.56	4.25	3.65	확진
생도 E	3.55	3.91	2.68	4.22	확진
생도 F	4.12	2.86	3.30	3.71	확진
신입 생도	3.24	3.68	3.82	3.77	?

k-최근접 이웃을 통한 분류

- 가장 가까운 3개의 데이터의 이산형 실제값을 통해 신입생도의 확진 여부를 결정한다. (k=3)

표4. 유전자 정보에 따른 코로나 확진 여부 데이터(k=3)

	유전자 1	유전자 2	유전자 3	유전자 4	확진 여부	새 관측치와의 거리
생도 A	2.54	4.33	3.99	2.57	정상	1.54
생도 B	3.12	3.87	3.84	3.04	정상	0.76
생도 C	2.76	4.17	5.63	3.28	정상	2.00
생도 D	3.87	3.56	4.25	3.65	확진	0.78
생도 E	3.55	3.91	2.68	4.22	확진	1.28
생도 F	4.12	2.86	3.30	3.71	확진	1.31
신입 생도	3.24	3.68	3.82	3.77	확진	

k-최근접 이웃을 통한 회귀

- **k-최근접 이웃 알고리즘 (회귀 문제)**
  - y의 값이 이산형 데이터가 아닌 연속형 데이터일 경우에는 회귀를 수행
  - 알고리즘의 동작은 동일하나, k 개 데이터의 값의 평균을 회귀값으로 반환
  - 거리에 비례하여 가중치를 주는 방법도 존재

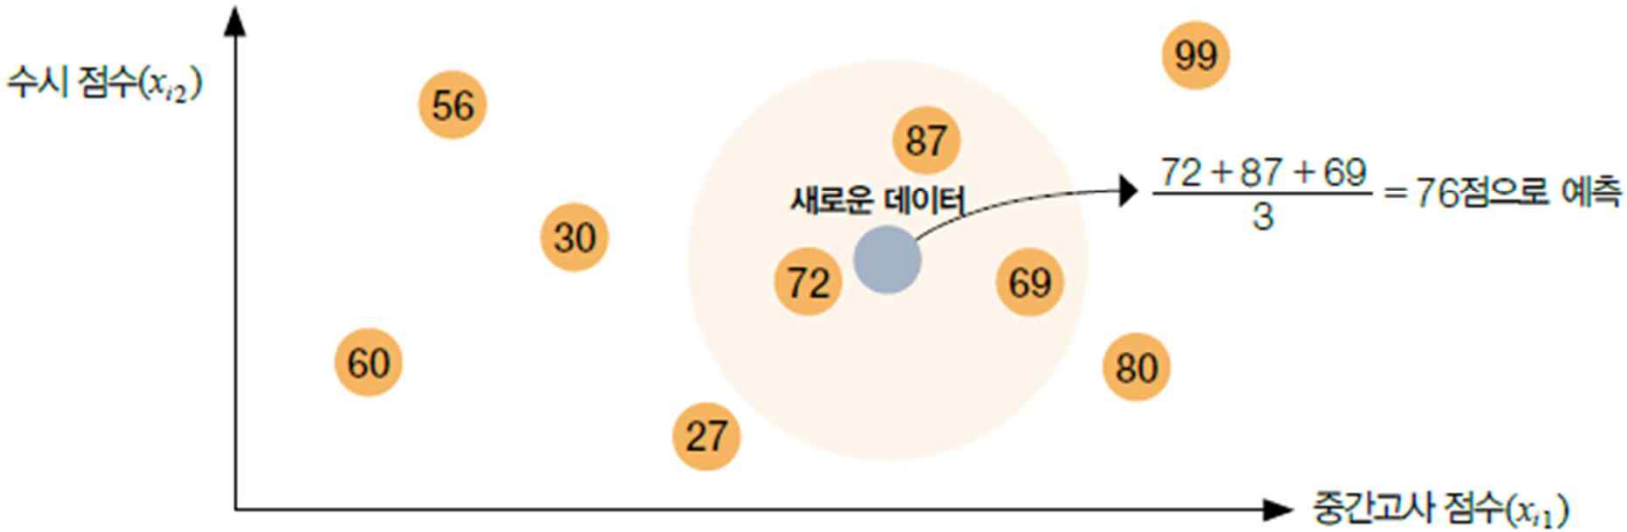

그림 11. k-최근접 이웃을 통한 회귀 예(k=3)

k-최근접 이웃을 통한 회귀

- **k-최근접 이웃 예제 (회귀)**
  - 생도의 과목별 최종 점수와 인공지능 입문 최종 점수 정보가 주어졌다.
  - 신입 생도의 인공지능 최종 점수를 k-최근접 이웃을 통해 예측해보자. (k=1, k=3)

표5. 타과목 점수에 따른 인공지능 입문 점수 데이터 (회귀)

	미적분학	기초물리학	프로그래밍	통계의 이해	군사영어	인공지능 입문
생도 A	7.5	7.5	7.0	9.5	8.5	5.0
생도 B	7.5	7.0	7.5	8.0	8.0	6.0
생도 C	8.0	7.0	8.0	8.0	8.5	8.5
생도 D	8.5	8.0	9.5	7.5	6.0	7.0
생도 E	10.0	9.5	9.0	7.5	7.5	10.0
생도 F	9.0	9.0	8.0	8.0	8.0	9.0
신입 생도	9.0	8.5	8.0	7.0	8.0	?

k-최근접 이웃을 통한 회귀

표6. 타과목 점수에 따른 인공지능 입문 점수 데이터

	미적분학	기초물리학	프로그래밍	통계의 이해	군사영어	인공지능 입문	새 관측치와의 거리
생도 A	7.5	7.5	7.0	9.5	8.5	5.0	3.28
생도 B	7.5	7.0	7.5	8.0	8.0	6.0	2.40
생도 C	8.0	7.0	8.0	8.0	8.5	8.5	2.12
생도 D	8.5	8.0	9.5	7.5	6.0	7.0	2.65
생도 E	10.0	9.5	9.0	7.5	7.5	10.0	1.87
생도 F	9.0	9.0	8.0	8.0	8.0	9.0	1.12
신입 생도	9.0	8.5	8.0	7.0	8.0	?	

- **k-최근접 이웃의 장점**

  – 이상치에 대한 강건성 / 데이터의 분산 고려 / 많은 학습 데이터에 효과적

- **k-최근접 이웃의 한계점**

  – k 값 설정의 어려움 / 적절한 거리 측도 선택 / 계산 비용

k-최근접 이웃의 하이퍼파라미터

- **하이퍼파라미터**
  - 학습을 통해 탐색되지 않는 사용자 직접 결정 파라미터
  - 적절한 값 설정이 모델 성능에 큰 영향을 미침

- **k 값의 역할**
  - k는 가장 가까운 데이터의 개수로, 모델의 성능에 중요한 영향을 미침

- **k 값 설정의 문제**
  - 작은 k 값: 데이터의 지역적 특성을 과도하게 반영, 과대 적합 유발
  - 큰 k 값: 다른 범주의 개체 포함, 잘못 분류 위험, 과소 적합 유발

- **적절한 k 값 찾기**
  - k 값을 변경하며 성능을 평가, 가장 좋은 성능을 보일 때의 k를 선택

k-최근접 이웃의 하이퍼파라미터

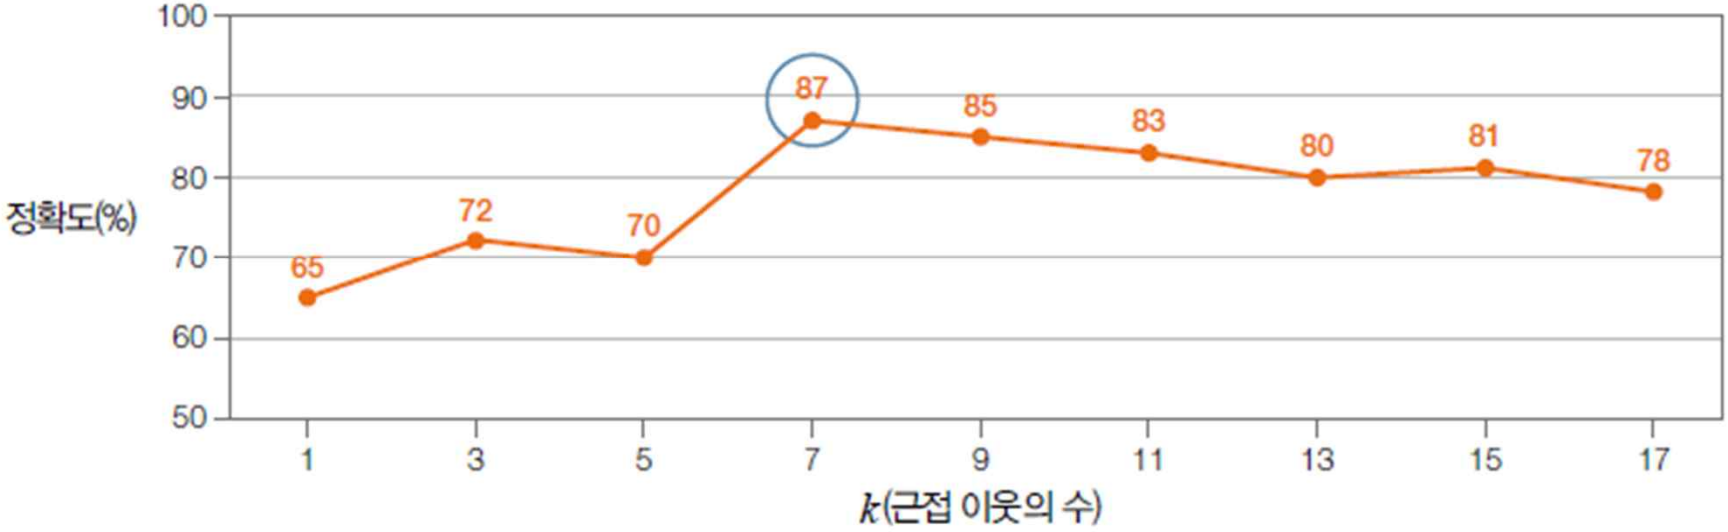

그림 12. k값에 따른 분류 결과 예시

Summary

회귀(REGRESSION) VS 분류(CLASSIFICATION)

회귀 (Regression)

연속적인 수치 값을 예측하는 문제

- 내일의 기온 예측
- 주택 가격 예측
- 광고비에 따른 매출액

분류 (Classification)

데이터를 정해진 범주(Category)로 나누는 문제

- 스팸 메일 여부 (Yes/No)
- 생도의 체중 상태 (저체중/정상/비만)
- 이미지 객체 인식

선형 회귀의 핵심 개념

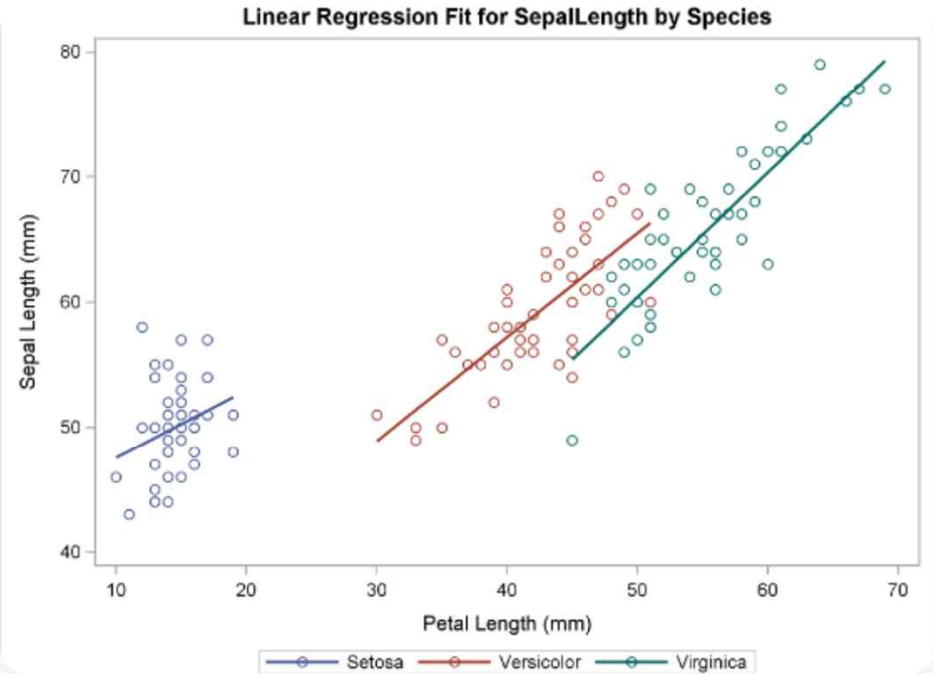

선형적 관계의 모델링

독립 변수(X)와 종속 변수(Y) 사이의 관계를 직선 형태로 모델링합니다. 입력값이 변함에 따라 출력값이 일정한 비율로 변하는 성질을 이용합니다.

"최적의 회귀선(Best Fit Line)을 찾는 것"

Summary

선형 회귀의 수식 이해

$$y = w_1 x + w_0$$

- **w1 (Weight/Slope):** 기울기 - X가 1단위 증가할 때 Y가 변화하는 양
- **w0 (Bias/Intercept):** 절편 - 모든 입력값이 0일 때의 기본값
- **목표:** 실제 값과 예측 값의 차이(오차)를 최소화하는 w들을 찾는 것

오차 측정: MSE (평균 제곱 오차)

회귀 모델의 성능을 평가하고 학습하기 위해서는 오차를 숫자로 나타내는 '비용 함수'가 필요합니다.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

왜 제곱을 할까?

- 음수 오차를 양수로 만들기 위해
- 오차가 클수록 더 큰 벌점을 주기 위해
- 수학적으로 미분이 가능하여 최적화에 유리

분류를 위한 곡선

시그모이드 함수의 마법

선형 회귀는 결과값이 무한대로 뻗어 나갑니다. 하지만 분류는 0과 1 사이의 '확률'이 필요합니다.

로지스틱 회귀는 선형 결과를 시그모이드 함수에 통과시켜 모든 값을 0~1 사이로 압축합니다.

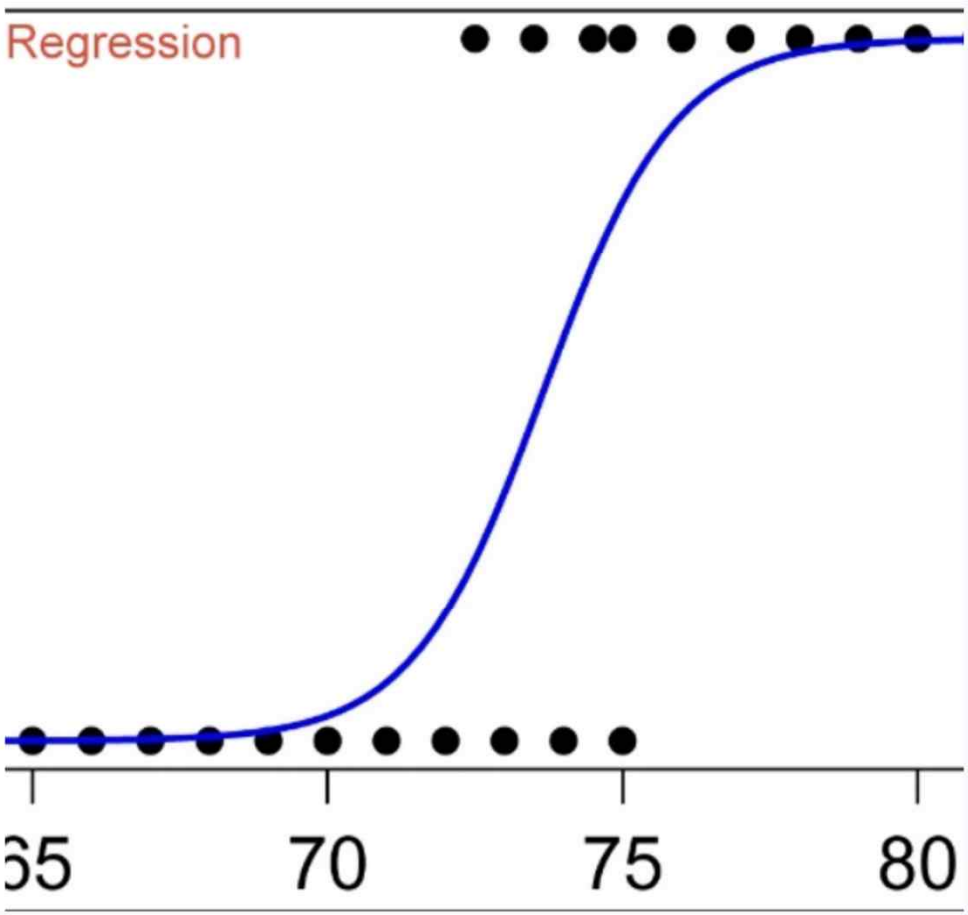

이 슬라이드 꾸미기

Summary

시그모이드(SIGMOID) 함수

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

출력값이 0.5보다 크면 1(True), 작으면 0(False)으로 분류하는 임계값(Threshold)을 기본으로 사용합니다.

- **S자형 곡선:** 어떤 값이든 0과 1 사이로 매핑
- **확률적 해석:** 결과가 0.8이라면 "1일 확률이 80%"임을 의미
- **이진 분류:** 합격/불합격, 투표/미투표 등 예측에 탁월

비교: 선형 VS 로지스틱

특징	선형 회귀 (Linear)	로지스틱 회귀 (Logistic)
목적	연속적인 수치 예측	범주(Category) 분류
결과 범위	무한대	0 ~ 1 사이 (확률)
활용 함수	직선 함수 (y = ax + b)	시그모이드 함수
결과 형태	최적의 직선	S자형 곡선

K-최근접 이웃(K-NN)의 원리

"유유상종" (Birds of a feather flock together)

새로운 데이터가 주어졌을 때, 가장 가까운 이웃 k개를 보고 그들의 다수결로 자신의 레이블을 결정합니다.

- **게으른 학습(Lazy Learning):** 훈련 데이터 자체를 모델로 사용
- **거리 기반:** 이웃과의 거리가 분류의 핵심

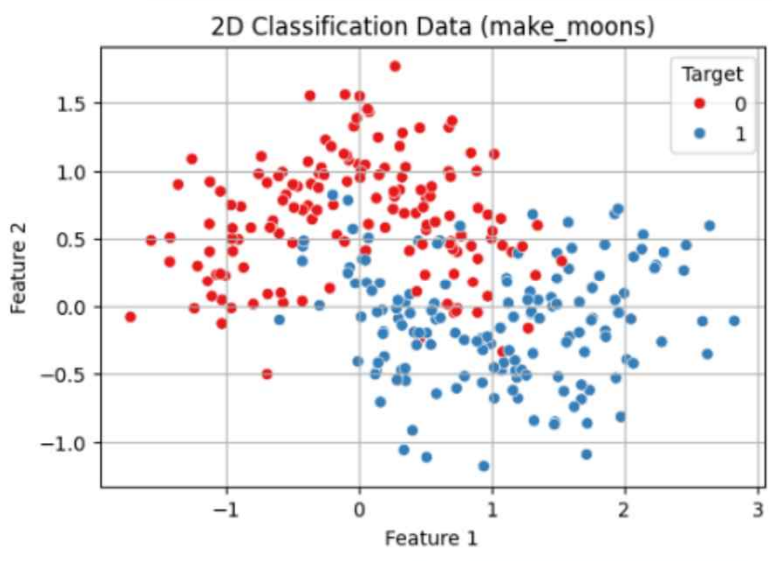

거리 측정 방식: 유클리드 VS 맨해튼

유클리드 거리

두 점 사이의 가장 짧은 직선 거리

$$\sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

맨해튼 거리

격자 도로를 따라가는 직각 거리

$$|x_2 - x_1| + |y_2 - y_1|$$

데이터의 성격(이상치 유무, 차원의 수)에 따라 적절한 거리를 선택합니다.

Summary

k가 너무 작으면 (k=1)

모델이 너무 예민해져서 데이터의 '노이즈'까지 학습합니다.

과적합 (Overfitting) 위험

k가 너무 크면 (k=N)

경계가 너무 뭉툭해져서 데이터의 개별 특성을 무시합니다.

과소적합 (Underfitting) 위험

보통 홀수를 사용하며, 실험을 통해 최적의 k를 찾아야 합니다.

Summary

모델은 어떻게 평가할까?

회귀 모델 지표

- **MSE:** 오차의 제곱 합
- **R-Squared:** 모델의 설명력

분류 모델 지표

- **Accuracy:** 정확도
- **F1-Score:** 정밀도와 재현율의 조화

오차 행렬 (CONFUSION MATRIX)

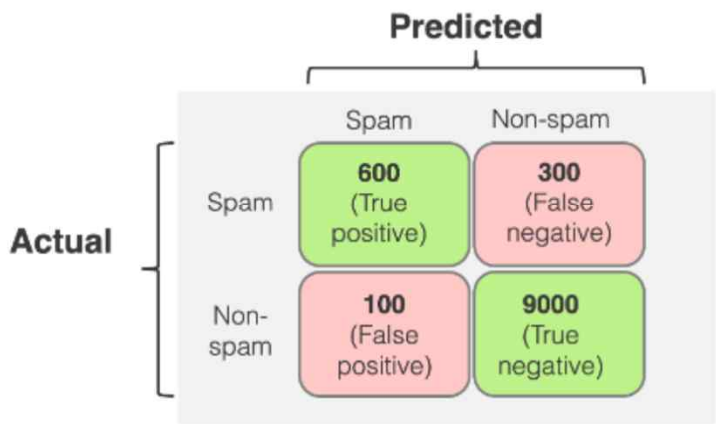

단순한 정확도만으로는 위험합니다 (예: 99%가 정상인 데이터).

- **TP:** 양성을 양성으로 예측 (성공)
- **TN:** 음성을 음성으로 예측 (성공)
- **FP:** 음성을 양성으로 잘못 예측 (오탐)
- **FN:** 양성을 음성으로 잘못 예측 (미탐)

Summary

핵심 요약

- 선형 회귀는 수치를 예측하며 최적의 직선을 찾는 과정이다.
- 로지스틱 회귀는 시그모이드 함수를 통해 0과 1 사이의 확률로 분류한다.
- k-NN은 가장 가까운 이웃 k개의 다수결로 결과를 결정하는 거리 기반 모델이다.
- k-NN과 같은 거리 기반 모델은 반드시 피처 스케일링을 거쳐야 한다.
- 모델의 목적에 따라 MSE(회귀) 또는 Accuracy(분류) 지표를 선택해 평가한다.

실습_데이터셋 설명

분류(Classification)용 Iris 데이터셋

- **데이터 개요 및 구성** 총 150개의 샘플로 구성된 균형 데이터셋 (3개 품종별 각 50개 샘플). 1936년 Fisher에 의해 소개된 머신러닝의 표준 벤치마크.
- **입력 변수 (Features)** 꽃받침 길이(Sepal Length), 꽃받침 너비(Sepal Width), 꽃잎 길이(Petal Length), 꽃잎 너비(Petal Width) 등 4가지 수치형 특징.
- **예측 목표 (Target Class)** Setosa, Versicolor, Virginica 등 붓꽃의 3가지 세부 품종 분류.
- **분석 시사점** 특징 간 상관관계가 높고 클래스 경계가 뚜렷

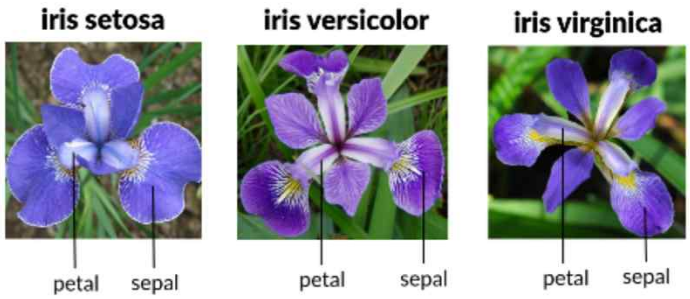

[그림 1] 꽃받침과 꽃잎의 신체적 특징 구조

실습_데이터셋 설명

시계열 회귀용 ETTh1 데이터셋

데이터 개요 및 구성

중국 내 전력 변압기에서 2년간(2016-2018) 수집된 산업용 시계열 데이터. 1시간 단위 샘플링, 총 17,420개 타임스텝.

입력 변수 (Multivariate Features)

고/중/저부하 상황에서의 유효 전력(HUFL, MUFL, LUFL) 및 무효 전력(HULL, MULL, LULL) 등 6개 다변량 변수.

예측 목표 (Target Variable)

변압기 오일 온도(OT, Oil Temperature). 미래 시점의 온도 수치를 연속형 값으로 예측하는 것이 핵심 과제.

분석 시사점

뚜렷한 계절성(Seasonality)과 복잡한 비선형 패턴을 포함하고 있어 ARIMA-Transformer 하이브리드 모델의 성능 검증에 용이.

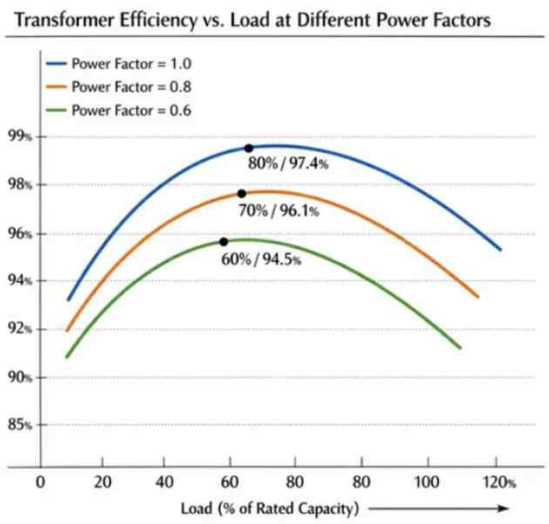

[그림 2] ETTh1 데이터셋의 시계열 변동 및 주기성 패턴

실습_시계열 데이터란?

정의 및 핵심 가설

일정 시간 간격으로 배치된 데이터의 수열을 의미합니다. 가장 중요한 특징은 **시간적 순서 (Temporal Order)**가 데이터의 의미를 결정한다는 점입니다.

- **연속성:** 과거의 상태가 미래에 영향을 줌
- **자기상관성:** 인접한 데이터 간의 높은 상관관계
- **가변성:** 시간에 따른 통계적 특성 변화

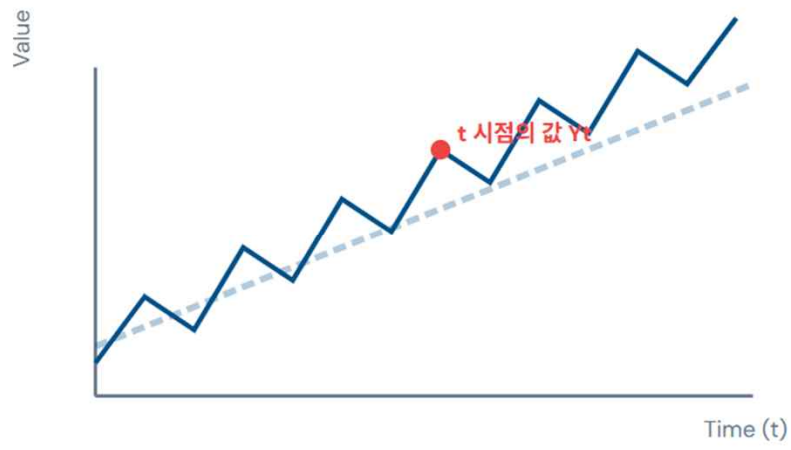

실습_시계열 데이터란?

시계열의 4대 구성 요소

추세 (Trend)
장기적으로 증가하거나 감소하는 전반적인 방향성

계절성 (Seasonality)
일/주/월 단위로 반복되는 일정한 패턴

순환성 (Cyclicity)
정해진 주기 없이 나타나는 변동 (경제 주기 등)

노이즈 (Irregular)
예측 불가능한 우연적 변동 및 오차

정상성(Stationarity)의 개념

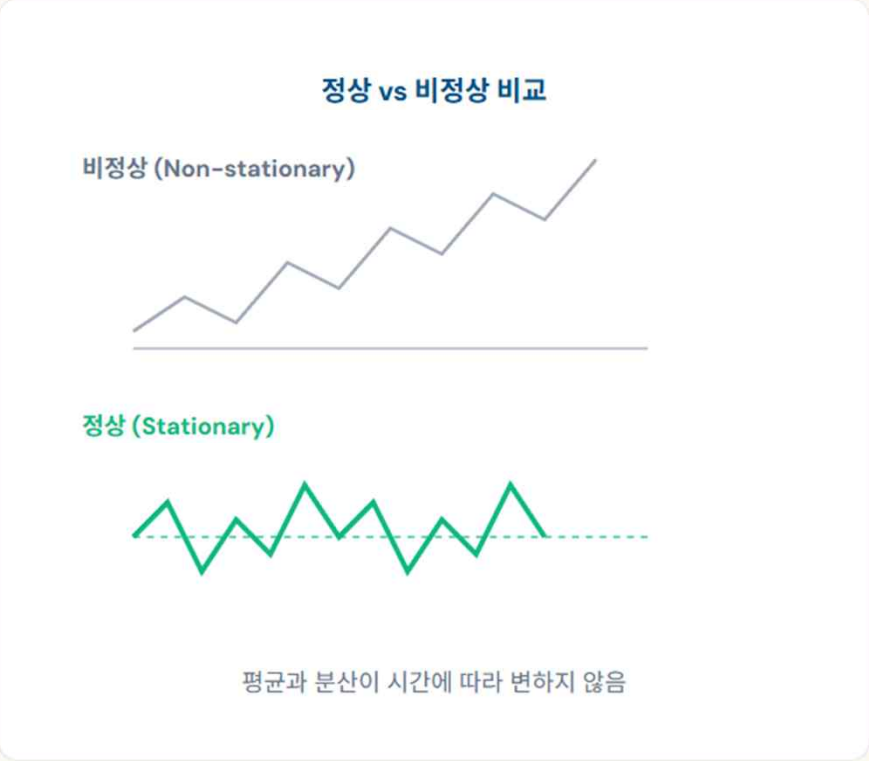

분석을 위한 필수 전제

대부분의 통계적 모델은 데이터가 정상성을 가진다고 가정합니다. 비정상 데이터는 모델링 전 처리가 필요합니다.

비정상 시계열 처리 기법:

- **차분(Differencing):** $y_t' = y_t - y_{t-1}$ (추세 제거)
- **로그 변환:** 분산이 시간에 따라 변할 때 사용

실습_시계열 데이터란?

산업별 시계열 활용 사례

에너지 (Energy)

전력 부하 예측(Load),

금융 (Finance)

주가 및 환율 예측,

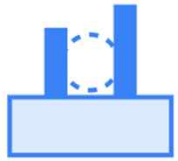

제조 (Mfg)

장비 고장 예지(RUL),

실습_KNN

```python
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import classification_report, confusion_matrix, accuracy_score

# 1. 데이터 로드 및 전처리 (이전과 동일)
file_path = r"D:\My_project\datasets\iris.csv"
df = pd.read_csv(file_path)
X = df.drop(columns=['variety'])
y = df['variety']

X_train, X_test, y_train, y_test = train_test_split( *arrays: X, y, test_size=0.2, random_state=42)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# 2. 모델 학습 및 예측
knn = KNeighborsClassifier(n_neighbors=3)
knn.fit(X_train_scaled, y_train)
y_pred = knn.predict(X_test_scaled)

# --- 📋 결과 표 출력 파트 ---

print("\n" + "="*50)
print(f"🥇 최종 모델 정확도: {accuracy_score(y_test, y_pred) * 100:.2f}%")
print("="*50 + "\n")

# 표 1: 분류 리포트 (Precision, Recall, F1-score)
report_dict = classification_report(y_test, y_pred, output_dict=True)
report_df = pd.DataFrame(report_dict).transpose()

print("[표 1: 품종별 상세 분류 성능 지표]")
print(report_df.round(3)) # 소수점 3자리까지 출력
print("-" * 50 + "\n")

# 표 2: 혼동 행렬 (Confusion Matrix)
cm = confusion_matrix(y_test, y_pred)
labels = knn.classes_
cm_df = pd.DataFrame(cm, index=[f"실제_{l}" for l in labels],
                         columns=[f"예측_{l}" for l in labels])

print("[표 2: 혼동 행렬 (Confusion Matrix Table)]")
print(cm_df)
print("="*50)
```

중간 프로젝트

Time series data를 활용해서 데이터 전처리 – 지도학습 – 성능평가를 진행.

- 데이터 전처리, 비교 모델, 성능평가 해석을 중점으로 설명

- PPT 구성을 자유롭게 하되 배운 이론을 중심으로 10분 이내 발표