

📌 제1장. 머신러닝 기초 및 개발 환경

1. 머신러닝 패러다임 구조

- **전통적 프로그래밍:** 데이터 X + 규칙(f) $\rightarrow$ 컴퓨터가 해답(y) 출력. 사람이 모든 예외 규칙을 정의해야 하므로 한계 봉착.
- **머신러닝:** 데이터 X + 해답(Label, y) $\rightarrow$ 컴퓨터가 규칙($f(x)$)을 스스로 최적화(학습).
- **학습 유형별 수학적 정의**
 - **지도 학습:** $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ 기반, 조건부 확률 $P(y|\mathbf{x})$ 또는 매핑 함수 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 근사. (회귀: $\mathcal{Y} \in \mathbb{R}$, 분류: $\mathcal{Y} \in \{1, \dots, C\}$)
 - **비지도 학습:** 레이블 없는 $\mathcal{D} = \{\mathbf{x}_i\}_{i=1}^N$ 기반, 주변 확률 분포 $P(\mathbf{x})$ 또는 잠재 구조(Latent Structure) 파악. (PCA, K-Means, DBSCAN, 이상탐지)
 - **강화 학습:** MDP 환경 내에서 누적 기대 보상 $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$ 을 최대화하는 최적 정책 $\pi^*(a|s)$ 를 시행착오로 학습.

2. 환경 구축 핵심 콘솔 명령어

- 가상환경 생성: `conda create -n <env_name> python=3.9 -y`
- 가상환경 활성화/비활성: `conda activate <env_name>` / `conda deactivate`
- 빌드 환경 백업 및 복원 이식: `pip freeze > requirements.txt` $\rightarrow$ `pip install -r requirements.txt`

📌 제2장. 데이터 전처리 및 데이터 유출 방지

1. 데이터 자료형 분류

- **수치형 (Numerical):** 연속형(온도, 압력 등 연속된 실수) 및 이산형(고장 횟수 등 셀 수 있는 정수).
- **범주형 (Categorical):** 명목형(순서 없음, 원-핫 인코딩 필수) 및 순서형(대소 존재, 정수 매핑 레이블 인코딩).

2. 피쳐 스케일링 (Feature Scaling) 수학적 모델

- **필요성:** 특성 간 단위 격차로 인한 경사하강법 등고선 왜곡 및 거리 기반 알고리즘(KNN, SVM)의 편향 차단.
- **표준화 (StandardScaler):** 평균 $\mu = 0$, 표준편차 $\sigma = 1$ 변환. 이상치에 강건함.

$$x'_i = \frac{x_i - \mu}{\sigma}, \quad \mu = \frac{1}{N} \sum x_i, \quad \sigma = \sqrt{\frac{1}{N} \sum (x_i - \mu)^2}$$

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

3. 데이터 분할 및 데이터 유출(Data Leakage) 차단

- **3분할 구조 (6:2:2):** 학습(가중치 최적화) / 검증(하이퍼파라미터 튜닝 및 조기종료) / 평가(최종 일반화 오차 측정).
- **유출 방지 규칙:** `fit_transform()` 은 학습(Train) 세트에만 적용. 검증 및 평가 세트에는 학습 세트의 μ, σ 를 계승하는 `transform()` 만 가동함.

4. 탐색적 데이터 분석 (EDA) 지표 판정 기준

- **박스 플롯 이상치 기준:** $IQR = Q_3 - Q_1$ 산정 후, $Q_1 - 1.5 \times IQR$ 미만이거나 $Q_3 + 1.5 \times IQR$ 초과 시 아웃라이어로 확정.
- **피어슨 상관계수 (r):** 다중공선성 차단을 위해 상관 매트릭스 플로팅 필수.

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2 \sum (y - \bar{y})^2}}$$

📌 제3장. 선형 회귀의 선형대수학적 증명

1. 선형 회귀 행렬 표기

- 가설 함수: $\hat{y} = w_0 + w_1x_1 + \dots + w_Dx_D = \mathbf{w}^T \mathbf{x}$ (편향 w_0 처리를 위해 더미 피쳐 $x_0 = 1$ 추가).

2. 비용함수 MSE (Mean Squared Error) 성격

$$J(\mathbf{w}) = \frac{1}{2m} \sum_{i=1}^m \left(\mathbf{w}^T \mathbf{x}^{(i)} - y^{(i)} \right)^2 = \frac{1}{2m} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

- 전 구간에서 헤시안(Hessian) 행렬이 양수이므로 로컬 미니마 없이 오직 하나의 전역 최저점만 가지는 Convex 함수임.

3. 최소자승법 (OLS) 정규 방정식 수학적 유도 (★서술형 필수)

1. 비용함수 행렬 전개:

$$J(\mathbf{w}) = \frac{1}{2}(\mathbf{X}\mathbf{w} - \mathbf{y})^T(\mathbf{X}\mathbf{w} - \mathbf{y}) = \frac{1}{2}(\mathbf{w}^T\mathbf{X}^T\mathbf{X}\mathbf{w} - 2\mathbf{w}^T\mathbf{X}^T\mathbf{y} + \mathbf{y}^T\mathbf{y})$$

2. 가중치 벡터 $\mathbf{w}$ 에 대한 그라디언트 편미분 전개:

$$\frac{\partial J}{\partial \mathbf{w}} = \mathbf{X}^T\mathbf{X}\mathbf{w} - \mathbf{X}^T\mathbf{y}$$

3. 최적화 조건 ($\frac{\partial J}{\partial \mathbf{w}} = 0$) 설정 후 정규 방정식 최종 도출:

$$\mathbf{X}^T\mathbf{X}\mathbf{w} = \mathbf{X}^T\mathbf{y} \implies \mathbf{w}^* = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

- 특성: 행렬 복잡도가 $O(D^3)$ 이므로 변수 개수 D 가 대용량일 시 연산 불가. 다중공선성 존재 시 역행렬 정의 불능(Singular Matrix) 문제 발생.

📌 제4장. 로지스틱 회귀와 분류 성능 평가

1. 로지스틱 회귀 수식 유도 4단계 (★서술형 필수)

- Step 1(선형 경계 선언): $z = \mathbf{w}^T\mathbf{x}$ ($z \in [-\infty, +\infty]$)
- Step 2 (오즈비 정의): 확률 P 대 불확률 $1 - P$ 의 비율로 실수 영역 $[0, +\infty]$ 확장.

$$\text{Odds} = \frac{P}{1 - P}$$

- Step 3 (로짓 변환): 자연로그를 적용하여 전 실수가 가능한 공간 매핑 완료.

$$\ln\left(\frac{P}{1 - P}\right) = \mathbf{w}^T\mathbf{x} = z$$

- Step 4 (역함수 정리를 통한 시그모이드 도출):

$$\frac{P}{1 - P} = e^z \implies P = e^z(1 - P) \implies P(1 + e^z) = e^z \implies P = \frac{1}{1 + e^{-z}} = \sigma(z)$$

2. 비용함수: 교차 엔트로피 (Cross-Entropy Loss)

- 모순 차단: 시그모이드 변환식 대입 시 MSE 함수는 Non-convex가 되어 수렴 실패함.
- 교차 엔트로피 수식:

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right]$$

3. 분류 평가지표 공식 연산

$$\text{Accuracy (정확도)} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision (정밀도)} = \frac{TP}{TP + FP} \quad [\text{FP 제어: 스팸 메일 필터링 용도}]$$

$$\text{Recall (재현율)} = \frac{TP}{TP + FN} \quad [\text{FN 방어 치명적: 반도체 불량, 암 진단 용도}]$$

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad [\text{클래스 불균형 데이터용 조화평균}]$$

- ROC-AUC: 임계값 변화에 따른 $\text{FPR}(\frac{FP}{FP+TN})$ 대 $\text{TPR}(\text{Recall})$ 의 곡선 면적. 완벽 예측 시 1.0 도출.

📌 제5장. 규제 선형 모델 및 SVM·KNN 가치 증명

1. 가중치 규제 모델 비교

- Ridge (L_2 규제): 가중치 제곱합 추가. 가중치를 완만히 축소시키나 0으로 만들지는 않음. 다중공선성 해소 전용.

$$J(\mathbf{w})_{\text{Ridge}} = \text{MSE} + \frac{\alpha}{2} \sum_{j=1}^D w_j^2$$

- Lasso (L_1 규제): 가중치 절대값 합 추가. 무관한 특성의 가중치를 정확히 0으로 변환하여 자동 특성 선택 효과 유도.

$$J(\mathbf{w})_{\text{Lasso}} = \text{MSE} + \alpha \sum_{j=1}^D |w_j|$$

2. SVM (서포트 벡터 머신) 최적화 공식

- 기하학적 마진: $\text{Margin} = \frac{2}{\|\mathbf{w}\|_2} \implies \|\mathbf{w}\|_2^2$ 최소화 문제로 유도됨.

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \quad \text{subject to } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

- C 가 클수록 오차 불허용 초평면 정교화(과적합), 작을수록 두터운 마진 오차 방관(과소적합).
- **커널 트릭**: 고차원 변환 없이 저차원에서 내적 수치 직접 계산. 가우시안 RBF 커널 수식 암기 필수:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (\gamma \text{ 클수록 과적합 유도})$$

📌 제6장. 결정트리 불순도 및 랜덤 포레스트 OOB 증명

1. 불순도 지표 연산 공식

- Entropy (ID3): $H(D) = -\sum p_i \log_2 p_i$, Gini Impurity (CART): $\text{Gini}(D) = 1 - \sum p_i^2$
- **정보 획득량**: 부모 노드 불순도와 자식 노드 불순도 가중합의 차이인 $\text{Gain}(D, A)$ 를 극대화하는 축 선택 분기.

2. 랜덤 포레스트 OOB(Out-of-Bag) 수학적 확률 증명 (★종합시험 필수)

- 크기 N 의 원본에서 1회 복원 추출 시 특정 행이 미선택될 확률: $1 - \frac{1}{N}$
- N 번 연속 추출 연산 완료 시 해당 샘플이 최종 누락(OOB) 상태로 남을 극한 확률 구조식:

$$P_{\text{OOB}} = \lim_{N \rightarrow \infty} \left(1 - \frac{1}{N}\right)^N = e^{-1} \approx 0.368 \text{ (36.8\%)}$$

- **결론**: 개별 나무 모델링 시 약 36.8%의 데이터가 학습에서 자동 제외되므로, 별도 교차 검증(K-fold) 없이 OOB 자체 모의고사 점수(`oob_score_`)로 성능 검증 완결 가능.

📌 제7장. 차원 축소 및 주성분 분석 (PCA) 선형대수학 유도

1. PCA 주성분 도출 4단계 (★최우순 순위 증명)

- Step 1 (평균 중심화): 원점 동기화를 위해 전체 변수 축 중심 이동. $\mathbf{X}_{center} = \mathbf{X} - \boldsymbol{\mu}$
- Step 2 (공분산 행렬 산출): 변수 간 분산 정보 취합. $\boldsymbol{\Sigma} = \frac{1}{m} \mathbf{X}_{center}^T \mathbf{X}_{center}$
- Step 3 (고유값 분해): 직교축 연산을 위한 특성치 분해 적용. $\boldsymbol{\Sigma} \mathbf{v} = \lambda \mathbf{v}$
 - $\mathbf{v}$: 주성분의 방향 벡터(Eigenvector), λ : 해당 축의 분산 크기 정보량(Eigenvalue).
- Step 4 (차원 결정): 누적 설명 분산 비율($\text{EVR}_j = \lambda_j / \sum \lambda_c$) 산정 후 엘보우 포인트 축 추출.

📌 제8장. 비계층적 군집화 정밀 비교 대조 매트릭스

핵심 평가 속성 지표	K-Means 군집화 (거리 중심)	DBSCAN 군집화 (밀도 중심)
사전 군집 수 (K) 지정	무조건 필수 지정	완벽히 불필요 (밀도 자동 추적 확장)
결정 경계면 기하 형태	구형 / 볼록(Convex) 공간만 한정 우수	도넛, 동심원 등 임의의 비선형 형태 완전 분류
이상치 및 노이즈 강건성	극도로 취약 (Centroid가 크게 왜곡됨)	극도로 강력 (밀도 미달점 노이즈(-1) 자동 배제)
시간 복잡도 계산 연산	준수함 ($O(I \cdot K \cdot N \cdot D)$)	공간 전수 질의 수반으로 지연 가능 ($O(N^2)$)

📌 제9장. 비지도 이상 탐지 (Anomaly Detection) 핵심 아키텍처

1. 시점 차이 정의

- **탐지 (Detection):** 과거/현재 계측 데이터 도메인 분포 이탈점을 실시간 감지 (Anomaly Score 산출).
- **예측 (Prediction):** 시계열 추이를 종합 해석해 미래 고장 시점을 사전에 도출 (예지 보전, RUL 판단).

2. 딥러닝 3대 패러다임 메커니즘

1. **시퀀스 복원 (LSTM-AE / VAE):** 정상 데이터 시퀀스로만 정보 압축 분기 훈련. 이상 유입 시 압축 복원 궤적이 깨져 복원 오차(Reconstruction Error, $\|\mathbf{x} - \hat{\mathbf{x}}\|^2$)가 폭증하는 원리로 불량 판정.
2. **어텐션 연관 (Anomaly Transformer):** 트랜스포머 셀프 어텐션을 가동해 시점 간 장기 의존성 추적. 연관 관계가 사방으로 비주기적 비산되는 '연관성 불일치(Association Discrepancy)' 변동 폭으로 맥락적 이상(Contextual Anomaly) 적발.
3. **그래프 관계망 (MTAD-GAT / GDN):** 다변량 다채널 센서들을 각각의 그래프 노드로 맵핑. 센서 단독값은 지극히 정상 범위일지라도 기기 역학 상 유지되어야 할 센서 간 상호 동기 구조가 붕괴 시 즉시 이상 감지.

📌 제10장. Scikit-Learn 필수 구현 코드 템플릿

1. 데이터 분할, 스케일링, Lasso 규제 회귀

```
import numpy as np, pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import Lasso

df = pd.read_csv("sensor_raw.csv")
X, y = df.drop(columns=['target']), df['target']
X_tmp, X_test, y_tmp, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
X_train, X_val, y_val, y_val_t = train_test_split(X_tmp, y_tmp, test_size=0.25, random_state=42)
```

```

scaler = StandardScaler()
X_train_s = scaler.fit_transform(X_train)
X_test_s = scaler.transform(X_test)

lasso = Lasso(alpha=0.1).fit(X_train_s, y_train)
print(f"사멸 피쳐 수: {np.sum(lasso.coef_ == 0)}")

```

2. 로지스틱 다중 분류 및 종합 평가지표 리포트 출력

```

from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix, roc_auc_score

log_reg = LogisticRegression(C=1.0, penalty='l2', solver='lbfgs', random_state=42)
y_pred = log_reg.predict(X_test_s)
y_prob = log_reg.predict_proba(X_test_s)[:, 1]

print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred, digits=4))
print(f"ROC-AUC 점수: {roc_auc_score(y_test, y_prob):.4f}")

```

3. 랜덤 포레스트 앙상블 빌드 및 OOB 점수 검증

```

from sklearn.ensemble import RandomForestClassifier

```