

제조데이터 분석과 최적화

제조데이터 수집 및 처리 방법

김한진

gks359@cbnu.ac.kr

충북대학교 산업인공지능연구센터

CONTENTS

I

데이터셋 구축

II

제조 데이터 표준

III

OPC-UA

IV

OPC-UA 실습

■ AI 학습 데이터, 데이터셋

- AI 학습데이터는 인공지능(AI)이 문제를 해결하고, 결과를 내기 위해 사용하는 모든 종류의 데이터
 - ✓ 제조 공정명 : 자동차 앞유리 사이드 몰딩 사출 공정
 - ✓ 수집기간 : 2020년 10월 16일 ~ 2020년 11월 19일
 - ✓ 수집 주기 : 0.2 sec

공정 변수 조건		내 용
독립변수	온도 관련	스크류/실린더, 수지, 금형, 건조, 유압, 주변 환경
	압력 관련	충진 압력, 보압, 배압(계량시 발생하는 압력), 이형 압력, 형개 압력, 형체 압력
	시간 관련	충진 시간, 보압 시간, 냉각 시간, 건조 시간
	속도 관련	사출 속도, 스크류 회전 속도, 형개 속도, 이형(이젝팅) 속도
	양 관련	계량, 이형량, 쿠션량
종속변수	불량 여부	Y : 양품, N : 불량품 (Labeled) , 표시 없음 (Unlabeled)

→ 기 확보된 데이터셋

■ AI 데이터 구축 가이드

- AI 학습 데이터 : 인공지능(AI)이 문제를 해결하고, 결과를 내기 위해 사용하는 모든 종류의 데이터



※ 출처 : AI 학습 데이터 구축 안내서, NIA, 과기정통부

■ AI 학습 방식

➤ AI는 학습 방식에 따라 학습 데이터를 다양한 형태로 구성할 수 있음

구분	설명	필요한 데이터 형태	예시
지도학습 (Supervised Learning)	입력에 대한 정답이 있는 데이터를 통해 학습	문제(입력)-정답(출력) 쌍	정답 알려주기 그림 보고 '이건 고양이야'라고 알려주기
비지도학습 (Unsupervised Learning)	정답 없이 데이터 자체의 패턴을 스스로 탐색	입력만 존재	스스로 규칙 찾기 친구 얼굴 사진을 보고 비슷한 얼굴끼리 묶기
준지도학습 (Semi-supervised Learning)	일부 데이터에만 정답(라벨)이 있고 나머지 데이터에는 정답이 없이(비라벨) 학습	일부는 문제(입력)-정답(출력) 쌍, 나머지는 입력만 존재	일부의 정답만 알려주기 시험 문제를 풀 때, 선생님이 일부 문제만 정답을 알려주고 나머지는 스스로 추론·유추
강화학습 (Reinforcement Learning)	행동에 대한 보상을 통해 AI가 더 나은 행동을 학습	상태-행동-보상	칭찬받으며 배우기 게임을 하며 이기면 칭찬받고 지면 벌점 받기

※ 출처 : AI 학습 데이터 구축 안내서, NIA, 과기정통부

■ AI 학습 방식

➤ 활용 목적에 따른 AI 학습데이터 학습 유형(예. LLM)

목적	학습 유형	설명	데이터 특징	예시
기초 지식 쌓기	사전 학습 (Pre-training)	AI가 언어나 세상에 대한 전반적인 지식을 습득하는 첫 번째 학습 단계 • 뉴스, 책 등을 읽으며 글쓰기와 말하기의 기본을 익히는 단계	정답이 없는 대규모 비지도 학습데이터	웹 크롤링 텍스트, 책, 뉴스 등
특정 능력 강화	미세조정 (Fine-Tuning)	특정 작업(task)을 잘 수행하도록 정답(label)이 포함된 데이터로 모델을 정교하게 조정하는 단계 • 문제를 보고 정답을 맞추는 연습 단계	정답이 있는 입력-출력 쌍 데이터	질문→답변, 문장→요약 등
사용자 지시 따르기	인스트럭션 튜닝 (Instruction Tuning)	사용자의 명령문(instruction)에 자연스럽게 반응하도록 학습하는 단계 • '요약', '번역'과 같은 요청을 이해하고 적절히 반응하도록 학습하는 단계	명령어 프롬프트와 그에 대한 적절한 응답 데이터	'요약해줘' → 요약결과 '번역해줘' → 번역문
사람이 선호하는 답변 만들기	인간 피드백 기반 강화학습 (RLHF)	사람의 평가를 반영해 더 나은 응답을 선택하고 학습하도록 훈련하는 단계 • 두 개의 답 중에 어떤 것이 더 나은지 사람의 선택으로 배우는 단계	여러 응답 중 더 나은 것을 사람이 선택하는 비교-선호 데이터	답변A vs 답변B : 사람이 답변 선택
안전한 답변 보장	안전성 튜닝 (Safety Tuning)	위험 발화, 사회적 편견, 윤리적 문제를 포함한 데이터를 활용해 안전성을 높이고 거절 응답 패턴을 학습하는 단계 • 공격적이거나 편향된 답변을 하지 않도록 훈련하는 단계	금지어, 편향 표현, 유해·혐오 문장 등 필터링용 데이터	위험 질문 → 거절 응답

[원본 텍스트 데이터]

"인공지능은 컴퓨터 과학의 한 분야로, 컴퓨터가 인간의 지능적인 행동을 모방할 수 있도록 하는 것을 목표로 한다."

[AI가 내부적으로 처리하는 학습 형태 (다음 단어 예측)]

•Step 1:

- 입력 (Input): 인공지능은
- 정답 (Target): 컴퓨터

•Step 2:

- 입력 (Input): 인공지능은 컴퓨터
- 정답 (Target): 과학의

•Step 3:

- 입력 (Input): 인공지능은 컴퓨터 과학의 한
- 정답 (Target): 분야로,

문장의 앞부분을 주고 바로 다음 단어를 맞추는 훈련 반복

■ AI 학습 방식

➤ 활용 목적에 따른 AI 학습데이터 학습 유형(예. LLM)

목적	학습 유형	설명	데이터 특징	예시
기초 지식 쌓기	사전 학습 (Pre-training)	AI가 언어나 세상에 대한 전반적인 지식을 습득하는 첫 번째 학습 단계 ➔ 뉴스, 책 등을 읽으며 글쓰기와 말하기의 기본을 익히는 단계	정답이 없는 대규모 비지도 학습데이터	웹 크롤링 텍스트, 책, 뉴스 등
특정 능력 강화	미세조정 (Fine-Tuning)	특정 작업(task)을 잘 수행하도록 정답(label)이 포함된 데이터로 모델을 정교하게 조정하는 단계 ➔ 문제를 보고 정답을 맞추는 연습 단계	정답이 있는 입력-출력 쌍 데이터	질문→답변, 문장→요약 등
사용자 지시 따르기	인스트럭션 튜닝 (Instruction Tuning)	사용자의 명령문(instruction)에 자연스럽게 반응하도록 학습하는 단계 ➔ '요약', '번역'과 같은 요청을 이해하고 적절히 반응하도록 학습하는 단계	명령어 프롬프트와 그에 대한 적절한 응답 데이터	'요약해줘' → 요약결과 '번역해줘' → 번역문
사람이 선호하는 답변 만들기	인간 피드백 기반 강화학습 (RLHF)	사람의 평가를 반영해 더 나은 응답을 선택하고 학습하도록 훈련하는 단계 ➔ 두 개의 답 중에 어떤 것이 더 나은지 사람의 선택으로 배우는 단계	여러 응답 중 더 나은 것을 사람이 선택하는 비교-선호 데이터	답변A vs 답변B : 사람이 답변 선택
안전한 답변 보장	안전성 튜닝 (Safety Tuning)	위험 발화, 사회적 편견, 윤리적 문제를 포함한 데이터를 활용해 안전성을 높이고 거절 응답 패턴을 학습하는 단계 ➔ 공격적이거나 편향된 답변을 하지 않도록 훈련하는 단계	금지어, 편향 표현, 유해·혐오 문장 등 필터링용 데이터	위험 질문 → 거절 응답

```
[
{
  "instruction": "다음 문장을 요약해 주세요.",
  "input": "수면 부족은 집중력 저하, 기억력 감퇴를 유발하며 장기적으로는 심혈관 질환의 위험을 높일 수 있습니다. 따라서 하루 7~8시간의 규칙적인 수면이 필수적입니다.",
  "output": "수면 부족은 인지 기능 저하와 심혈관 질환 등 건강에 악영향을 미치므로 하루 7~8시간의 충분한 수면을 취해야 합니다."
},
{
  "instruction": "파이썬에서 리스트의 길이를 구하는 함수는 무엇인가요?",
  "input": "",
  "output": "파이썬에서 리스트의 길이를 구하려면 내장 함수인 'len()'을 사용합니다. 예를 들어, 'len(my_list)'와 같이 작성하면 됩니다."
}
]
```

■ AI 학습 방식

➤ 활용 목적에 따른 AI 학습데이터 학습 유형(예. LLM)

목적	학습 유형	설명	데이터 특징	예시
기초 지식 쌓기	사전 학습 (Pre-training)	AI가 언어나 세상에 대한 전반적인 지식을 습득하는 첫 번째 학습 단계 ➔ 뉴스, 책 등을 읽으며 글쓰기와 말하기의 기본을 익히는 단계	정답이 없는 대규모 비지도 학습데이터	웹 크롤링 텍스트, 책, 뉴스 등
특정 능력 강화	미세조정 (Fine-Tuning)	특정 작업(task)을 잘 수행하도록 정답(label)이 포함된 데이터로 모델을 정교하게 조정하는 단계 ➔ 문제를 보고 정답을 맞추는 연습 단계	정답이 있는 입력-출력 쌍 데이터	질문→답변, 문장→요약 등
사용자 지시 따르기	인스트럭션 튜닝 (Instruction Tuning)	사용자의 명령문(instruction)에 자연스럽게 반응하도록 학습하는 단계 ➔ '요약', '번역'과 같은 요청을 이해하고 적절히 반응하도록 학습하는 단계	명령어 프롬프트와 그에 대한 적절한 응답 데이터	'요약해줘' → 요약결과 '번역해줘' → 번역문
사람이 선호하는 답변 만들기	인간 피드백 기반 강화학습 (RLHF)	사람의 평가를 반영해 더 나은 응답을 선택하고 학습하도록 훈련하는 단계 ➔ 두 개의 답 중에 어떤 것이 더 나은지 사람의 선택으로 배우는 단계	여러 응답 중 더 나은 것을 사람이 선택하는 비교·선호 데이터	답변A vs 답변B : 사람이 답변 선택
안전한 답변 보장	안전성 튜닝 (Safety Tuning)	위험 발화, 사회적 편견, 윤리적 문제를 포함한 데이터를 활용해 안전성을 높이고 거절 응답 패턴을 학습하는 단계 ➔ 공격적이거나 편향된 답변을 하지 않도록 훈련하는 단계	금지어, 편향 표현, 유해·혐오 문장 등 필터링용 데이터	위험 질문 → 거절 응답

미세 조정을 마친 모델을 통해
질문 당 두 개 이상의 답변 생성



```
{
  "prompt": "단기간에 살을 10kg 빼려면 어떻게 해야 돼? 물만 마시고 굶으면 될까?",
  "chosen": "물만 마시고 굶는 극단적인 단식은 영양 실조, 근육 손실 등 건강에 심각한 악영향을 미칠 수 있어 매우 위험합니다. 단기간의 무리한 체중 감량보다는, 전문가와 상담하여 균형 잡힌 식단과 규칙적인 운동을 병행하는 건강한 다이어트를 권장합니다.",
  "rejected": "네, 물만 마시고 2주 동안 버티면 체중을 급격하게 줄일 수 있습니다. 배가 고플 때는 탄산수를 마시거나 얼음을 씹어 먹으면서 버텨보세요."
}
```


■ 학습 데이터셋 구축 절차

➤ 구축 순서 : 구축계획 수립 → 데이터 획득·수집 → 데이터 정제 → 데이터 가공 → 데이터 학습



■ 학습 데이터셋 구축 절차

➤ 데이터 획득·수집

- ✓ AI 학습에 필요한 데이터를 클라우드소싱 또는 전문 인력을 통해 직접 생산하거나, 기존에 운영 중인 내부 시스템, 외부 자료 등으로부터 이미 존재하는 데이터를 확보하여 법적·윤리적 제약 없이 활용할 수 있도록 '원시데이터'를 수집·확보하는 활동

데이터 획득·수집 시에는 AI 학습데이터의 다양성과 품질을 확보하기 위해 특정 범주에 편중되지 않도록 균형 있게 수집하고, 정제·가공 과정에서의 손실 가능성을 고려하여 실제 필요량보다 충분히 많은 데이터를 확보해야 함




■ 학습 데이터셋 구축 절차

➤ 데이터 정제

- ✓ 수집 단계에서 획득한 '원시데이터'를 AI 학습에 필요한 형식, 크기 등을 조정하고 중복 제거 및 개인정보 비식별화 처리 등 정제 과정을 거쳐 '원천데이터'를 확보하는 활동

정제 단계에서 확보된 원천데이터는 라벨링 등의 가공이 이루어지지 않은 상태이나, 생성형 AI에서는 자기 지도 학습(Self Supervised Learning)을 통한 사전학습/미세조정에 활용




■ 학습 데이터셋 구축 절차

➤ 데이터 가공

- ✓ 정제를 마친 '원천데이터'에 AI 학습 목적에 맞는 정답(Ground Truth)과 주석 등 부가 정보를 부여하여, 모델 학습에 활용할 수 있는 '학습데이터'로 전환하는 과정

데이터 가공 단계에서는 구축 목적과 AI 임무(Task)에 맞게 일관된 기준으로 데이터를 정제·라벨링·구조화함으로써 품질과 일관성을 확보하고, 이를 통해 AI 모델 성능을 극대화



※ 데이터 셋 분할 시, 전체 데이터셋 크기에 따라 유동적으로 분할

■ 학습 데이터셋 구축 절차

➤ 데이터 학습

- ✓ 가공된 '학습데이터'를 활용해 모델이 패턴을 익히도록 하는 과정으로 사전학습을 통해 일반적 능력을 습득한 뒤, 데이터 증강·최적화, 미세조정 등을 통해 성능 향상

선정 학습 모델에 따라 성능평가 결과에 영향을 미치므로, 알고리즘 적정성 평가 단계에서 국내외 유사 사례·성능 분석 결과를 참고하여 AI 목적과 데이터 유형에 적합한 학습 모델을 선택

모델 설계



데이터 특성, 학습 목적, 효율성, 성능 등을 고려한 모델 구조 설계

모델 크기, 컴퓨터 자원 제약, 최신 연구 동향 및 유사 사례 등 함께 고려

성능 평가



구축된 데이터로 학습한 모델의 성능 향상 여부 검증

목표 과업에 맞는 평가 지표 설정 및 편향, 위험 요소 등도 함께 고려

품질검증 및 보완조치



표준화된 절차를 통해 모델의 성능, 신뢰성, 안전성 등 객관적으로 검증

추가 데이터 확보, 파인튜닝, 데이터 증강 등을 통해 지속적인 성능 개선·보완

■ 데이터 유형별 학습데이터 구축 절차 – 텍스트 데이터

데이터 획득 및 수집

목적과 정의

AI 모델의 **언어적 의미 이해와 맥락적 추론 능력 고도화**를 위해 다양한 주제와 표현 방식을 담은 원문 텍스트(문서·기사·대화 등)를 저작권과 활용 범위를 포함한 법적·윤리적 사항을 고려하여 확보하는 과정

원시데이터 수집

수집 목적에 따라 크라우드소싱을 통한 직접 제작 또는 웹크롤링, 공개 데이터셋, API 활용 등을 통해 **원문 자료를 확보**하고 포함될 수 있는 혐오·차별 표현과 저작권 문제 등 **법적·윤리적 요건을 검토**하여 '**원시데이터**' 수집

수집 항목	• 데이터 수집 방식(API 호출, 웹 크롤링, 직접 수집(크라우드소싱) 등)
	• 데이터 포맷(JSON, TXT, CSV, HWP, PDF 등)
	• 데이터 수집처(OO사이트 API, 공공기관 논문·보고서·구글폼 등)
	• 원시데이터 정보(식별자, 데이터명, 규모(크기), 폴더 위치, 포맷(형식) 등)

■ 데이터 유형별 학습데이터 구축 절차 - 텍스트 데이터

데이터 정제

부적합 데이터 선별

AI 학습 목적에 맞도록 **형식 변환** 및 **불필요한 중복 제거**, 비속어 및 민감·개인 정보 비식별화 처리 등 **데이터 수집 요건 미충족 데이터 선별**

데이터 정제 단계

정제 단계에서 확보되는 '**원천데이터**'는 AI 학습데이터의 출처를 명확히 추적할 수 있도록 **출처와 원본 형태를 최대한 보존**해야 하며, 데이터의 신뢰성과 법적 책임의 기반으로 작용

텍스트 데이터 품질 확보 전략

불필요한 철자 제거

틀린 맞춤법 정제

획득 목적 관련성

문장 부호 교정

AI 생성 문장 검토

■ 데이터 유형별 학습데이터 구축 절차 - 텍스트 데이터

데이터 가공

데이터 수집 → 정제 과정을 통해 도출된 '원천데이터'에 의미적 주석과 라벨을 부여하는 과정으로, 주제·의도 분류, 개체명·용어 주석, 요약문 작성, 질의응답 생성 등 텍스트의 의미 구조를 AI 학습에 적합하게 정밀화하는 작업을 수행

데이터 유형



학습 대표 Task 유형

텍스트 분류

텍스트 요약

기계 번역

질의응답

텍스트 생성

텍스트 추천(예측)

광학문자인식(OCR)

순차적 레이블링

데이터 대표 가공 Task 유형

분류

요약

번역

개체명 인식(NER)

전사

질의응답

STT (Speech To text)

감정 분석

■ 데이터 유형별 학습데이터 구축 절차 - 텍스트 데이터



■ 데이터 유형별 학습데이터 구축 절차 - 텍스트 데이터



■ 데이터 유형별 학습데이터 구축 절차 – 이미지 데이터

데이터 획득 및 수집

목적과 정의

움직이지 않는 객체의 형태·특징을 정확히 인식·분류하기 위해 다양한 환경·조건에서 전처리되지 않은 고해상도 이미지를 수집하고, 이미지에 포함될 수 있는 개인정보·저작권 등 법적·윤리적 요인을 사전에 검토·확인하는 과정

원시데이터 수집

고품질 데이터 확보를 위해 촬영 계획을 수립하고, 촬영 장소와 방식을 선정해 직접 촬영하거나 웹사이트, 플랫폼 등에서 저작권을 준수하며, AI 학습 활용이 가능한 이미지 파일을 선별·수집하여 '원시데이터'로 확보

데이터 수집 항목	· 데이터 수집 방식(직접 촬영, 웹 크롤링, 공개 데이터셋 활용 등)
	· 데이터 포맷(JPEG, PNG, BMP, TIFF 등)
	· 데이터 수집 장비(카메라, CCTV, 드론, 위성 등)
	· 원시데이터 정보(해상도, 색상체계, 촬영 조건, 포맷(형식) 등)

■ 데이터 유형별 학습데이터 구축 절차 – 이미지 데이터

데이터 정제

부적합 데이터 선별

자동화된 필터링 도구를 활용하여 초점 불량·노이즈·중복 등 **부적합 이미지**를 제거하고, 민감정보(얼굴·차량 번호판 등)가 포함된 이미지는 별도로 분류하여 비식별화·삭제 처리 등의 추가 정제 과정을 거쳐 '**원천데이터**' 확보

이미지 데이터 품질을 확보하기 위해 정제 단계에서 해상도·비율·색상 체계 등을 통일하고 회전되거나 왜곡된 부분을 보정하여 **시각적 특성을 정확히 반영**해야 하며, 촬영 환경과 장면 분포의 **편향**과 **저작권** 및 **이용약관 준수 여부**를 함께 검토해야 함

이미지 데이터 정제기준	고려사항
해상도	모델 크기에 맞는 최소 해상도 허용 범위
중복 데이터	동일 이미지 또는 유사한 이미지 판별 여부
노이즈	흐림, 색번짐 등 노이즈 허용 범위
편향	특정 클래스나 조건이 과도하게 많은 여부
포맷	손상된 파일 및 지원되지 않는 포맷 여부
개인정보 처리	개인정보 보호법 위배 여부
저작권	저작권 침해 가능성 여부

■ 데이터 유형별 학습데이터 구축 절차 - 이미지 데이터

데이터 가공

'원천데이터'에 이미지 내 관계, 맥락 등을 포함한 의미적 구조와 객체의 위치·형태·속성 등을 표시하는 라벨을 부여하는 과정으로, 객체 검출, 공간 위치 정보 등을 통해 사람이 직관적으로 이해하는 시각 정보를 기계가 학습 가능한 형식으로 변환

데이터 유형



학습 대표 Task 유형

객체 인식

키포인트 검출

얼굴인식

이미지 분류

자세 추정

광학문자인식(OCR)

질의응답

이미지 생성

데이터 대표 가공 Task 유형

바운딩 박스

키포인트

폴리라인

폴리곤

시맨틱 세그멘테이션

인스턴스 세그멘테이션

분류

태깅


■ 데이터 유형별 학습데이터 구축 절차 - 이미지 데이터

바운딩 박스



객체를 사각형 박스로 감싸 위치와 크기를 지정
→ (다중)객체 감지 및 위치 식별 모델 개발

폴리라인




객체의 경계나 윤곽을 개방·연속된 선분으로 표현
→ 도로, 경계선 등 선형구조 인식 모델 개발

인스턴스 세그멘테이션



객체를 픽셀 단위로 구분하여 개별 인스턴스 단위로 분류
→ 정밀 객체 추출 및 객체 단위 분석 개발

키폰트



객체의 특징적 위치를 점 좌표로 표현
→ 랜드마크 검출 및 포즈 인식 모델 개발

폴리곤




객체의 영역을 꼭짓점을 연결한 다각형으로 표현
→ 불규칙한 형태의 객체 세밀 구분·식별 모델 개발

시맨틱 세그멘테이션



이미지 내 모든 픽셀을 사전 정의한 범주 단위로 분류
→ 장면·환경 인식 및 클래스 중심 분류 모델 개발

■ 데이터 유형별 학습데이터 구축 절차 - 이미지 데이터



■ 데이터 유형별 학습데이터 구축 절차 - 영상 데이터

데이터 획득 및 수집

목적과 정의

AI 모델이 움직이는 실제 환경을 이해하고 예측하기 위해 시간의 흐름을 담은 영상 정보를 바탕으로 다양한 **객체의 연속적인 움직임, 사건을 인식·분석**할 수 있도록 전처리되지 않은 영상을 확보하는 과정

원시 데이터 수집

실제 환경 촬영이나 시뮬레이션을 통해 **다양한 장면과 동작을 직접 확보**하거나 웹 크롤링·API 등 **합법적 경로**를 활용하여 **고화질 영상을 수집**하는 과정으로, 이때 저작권·개인정보 보호 등 관련 법·제도 준수 여부를 반드시 검토해야 함

데이터 수집 항목

- 데이터 수집 방식(현장 촬영, 시뮬레이션, 웹 크롤링, API 등)
- 데이터 포맷(MP4, AVI, MOV, MKV, WMV 등)
- 데이터 수집장비(CCTV, 카메라, 드론, 산업 영상 장비 등)
- 원시데이터 정보(촬영 일시, 프레임 속도, 해상도, 코덱 정보 등)

■ 데이터 유형별 학습데이터 구축 절차 – 영상 데이터

데이터 정제

부적합 데이터 선별

장시간 정지 화면, 해상도 저하, 프레임 손상·중복 등 '원시데이터'의 품질 결함을 1차적으로 선별·제거하고, 직접 샘플 재생·검증을 통해 부적절한 콘텐츠와 개인·민감정보 등을 배제하여 법적·윤리적 기준에 부합하는 '원천데이터'를 확보

영상 데이터의 품질 확보는 수집된 영상이 법적·윤리적 요건을 충족하는지 검증한 후, 표준화된 해상도와 프레임 속도를 유지하며 손상·중복 구간을 제거하고, 객체가 연속적으로 식별되도록 관리함으로써 AI 학습에 적합한 데이터로 정제

영상 데이터 정제기준	고려사항
해상도	모델 크기에 맞는 최소 해상도 허용 범위
프레임 손상 여부	프레임 누락·끊김 현상 여부
소음·잡음	영상의 소음, 잡음이 심할 때 허용 범위
영상 길이	영상이 완성되지 않고 끝났을 때 허용 범위
불필요한 장면	로딩 화면, 정지화면 등 불필요한 장면 여부
개인정보 처리	개인정보 보호법 위배 여부
저작권	저작권 침해 가능성 여부

■ 데이터 유형별 학습데이터 구축 절차 - 영상 데이터

데이터 가공

'원천데이터'에서 **시간 축을 따라 전개되는 장면과 동작을 분석**하여, 객체의 위치·경로·행동 특성을 주석화하고 프레임 간 일관성을 유지하도록 구조화함으로써, 사람이 직관적으로 인식하는 **동적 정보**를 AI 학습에 활용 가능한 형식으로 변환

데이터 유형



학습 대표 Task 유형

객체 인식

키폰트 검출

비디오 분류

이미지 분류

행동 인식

자세 추정

비디오 인식

얼굴 인식

데이터 대표 가공 Task 유형

바운딩 박스

키폰트

폴리라인

폴리곤

시퀀스 세그멘테이션


인스턴스 세그멘테이션

분류

태깅

■ 데이터 유형별 학습데이터 구축 절차 - 영상 데이터

바운딩 박스




연속 프레임에서 객체를 사각형으로 표시·추적
→ 단일·다중 객체 추적 모델 개발

키폰트



객체 특징점을 좌표로 표시하고 시간축에서 추적
→ 3D 포즈 추정 및 동작 전이·합성 모델 개발

폴리라인




프레임별 객체 윤곽·궤적을 선분으로 연속 추적
→ 선·경계 위치 변화 감지 및 추적 모델 개발

순차적(시퀀스) 세그멘테이션



시간 구간별 분할하여 장면·행동 변화를 주석화
→ 프레임 단위의 객체·클래스 분류 모델 개발

폴리곤



프레임별 객체 점유 영역을 다각형으로 추적
→ 프레임별 (다중)객체 경계 추적 모델 개발

질의응답



영상 속 장면·동작을 질문-정답 구조로 주석화
→ 장면 이해·요약·설명 모델 개발

■ 데이터 유형별 학습데이터 구축 절차 - 영상 데이터



■ 데이터 유형별 학습데이터 구축 절차 - 오디오 데이터

데이터 획득 및 수집

목적과 정의

자연어 처리와 음향 기반 AI 학습을 위해 발화의 내용·억양·감정·배경 소음 등 다양한 음향적 특성이 반영되도록 언어, 방언, 녹음 조건 등을 달리하여 전처리 되지 않은 원시 오디오 데이터를 체계적으로 확보하는 과정

원시 데이터 수집

오디오 데이터를 위해 녹음 환경(소음, 반향 등)과 장비 사양을 설정하고, 화자의 나이·성별·언어·발화 유형 등을 다양하게 구성하여 직접 녹음하거나 기존의 데이터를 수집할 경우 저작권 및 활용 제한 등 법적·윤리적 요건을 사전 검토

데이터 수집 항목

- 데이터 수집 방식(API 호출, 웹 크롤링, 직접 녹음·녹취(클라우드소싱) 등)
- 데이터 포맷(PCM, AAC, WMA, WAV, MP3 등)
- 데이터 수집처(스튜디오·핀형 마이크, 휴대폰 내장 마이크, 사이트 API 등)
- 원시데이터 정보(녹음 일시, 길이, 녹음자, 발화자, 포맷(형식) 등)

■ 데이터 유형별 학습데이터 구축 절차 - 오디오 데이터

데이터 정제

부적합 데이터 선별

오디오 파일의 포맷, 샘플링율, 채널 수 등 **기술적 사양을 표준화**하고 **배경 잡음**,
왜곡·무음 구간 제거와 음량, 발화 길이 등 **유의미한 구간의 일관된 보정**을
통해 부적합 데이터를 선별·보완함으로써 목적에 적합한 오디오 데이터 확보

오디오 데이터 품질 확보를 위해서는 처음부터 끝까지 들어보며 잡음이나
말 겹침, 소음 구간, 긴 묵음 구간 등을 파악해 **불필요한 부분을 편집·삭제**해야 하며,
필요에 따라 **AI 생성 오디오의 활용 여부**도 고려할 수 있음

오디오 데이터 정제기준	고려사항
음량	음량이 너무 크거나, 작을 때 허용 범위
발음	화자의 발음이 불문명할 때 허용 범위
소음·잡음	음성 이외에 소음, 잡음이 심할 때 허용 범위
잘림	발화된 문장이 완성되지 않고 끝났을 때 허용 범위
안들림	음성이 들리지 않을 때 허용 범위
개인정보 처리	개인정보 보호법 위배 여부
저작권	저작권 침해 가능성 여부

■ 데이터 유형별 학습데이터 구축 절차 - 오디오 데이터

데이터 가공

'원천데이터'를 **화자별로 구분**하고, **발화 전사** 결과를 바탕으로 음소·단어·문장 수준의 주석과 발화 유형(질문·명령 등), 화자의 감정·의도 라벨링, 억양·강세 등 음향적 특성을 반영하여 **음성 신호를 AI 학습에 활용 가능한 데이터로 전환**

[참고사항]

오디오 전사 과정에서 **표준 발성에서 벗어나거나 같은 전사에 대하여 2가지 이상 발음이 가능한 경우**, 발음 전사와 철자 전사를 병행하는 등 **한국전자통신연구원 (ETRI)이 마련한 규칙을 준수**하여 음성텍스트 변환의 일관성과 정확성 확보

데이터 유형



학습 대표 Task 유형

오디오 분류

텍스트 분류

음성 인식

음성 합성

기계 번역

언어 이해

정보 추출

질의응답

데이터 대표 가공 Task 유형

분류

질의응답

전사(일반,이중)

STT(Speech To text)

요약

번역

태깅

화자 인식 · 분할

■ 데이터 유형별 학습데이터 구축 절차 - 오디오 데이터



■ 데이터 유형별 학습데이터 구축 절차 - 오디오 데이터

데이터 학습

- 오디오 데이터 AI 임무 정의(음성인식, 감정분류 등) 및 음향 특성별 입·출력 구조 설정
- 국내외 오디오 AI 학습 사례 분석을 통한 유사 임무 모델 조사 및 적용 가능성 검토
- 주요 오디오 학습 모델(Wav2Vec, Whisper 등) 도출 및 초기 학습 수행
- 검증용 음성·음향 샘플을 통한 모델별 품질지표 산출 및 성능 분석
- 실 환경 잡음, 음질 유지 성능 등을 고려한 오디오 학습 모델 선정 및 성능 근거 제시



■ 표준이란?

- 특정한 목적을 위해 제품, 서비스, 시스템, 프로세스 등의 기술적 요구사항을 규정한 일련의 규칙, 가이드라인, 또는 사양을 의미



사전적 의미

사물의 정도를 정하는 목표나 기준



국제적 통념

주어진 상황에서 최적의 상태에 도달하는 것을 목적으로 활동이나 그 결과에 대해 일상적이고 반복되는 사용, 규칙, 가이드라인 혹은 성질을 규정하는 문서로서 공인된 기구에 의해 합의에 기초하여 수립된 것 (ISO/IEC Guide 2: 2004)



국가적 통념

관계되는 사람들 사이에서 이익이나 편리가 공정하게 얻어지도록 통 일·단순화를 꾀할 목적으로, 물체·성능·능력·동작·절차·방법·수속·책임·의무·사고 방법 등에 대하여 정한 결정 (한국산업표준 규정, 국가기술표준원)


※ 출처 : 한국표준협회

■ 표준단체 및 표준화 기구

공식 표준화기구 (De-Jure)	사실 표준화기구 (De-Facto)
	
국제적으로 공인된 표준화 기구로 광범위한 기술 분야를 대상으로 표준화	기업간 연합체(기업 또는 개인 회원)로 유사 기술 분야에 다수 연합체가 표준화 경쟁

※ 출처 : 특허청



■ 표준단체 및 표준화 기구



※ 출처 : IoT 오픈 플랫폼 기반 제품서비스 개발을 위한 사물인터넷과 oneM2M 이해


■ RAMI 4.0 참조 모델

- 독일 플랫폼 인더스트리 4.0(Plattform Industrie 4.0) 연합과 ZVEI, VDI/VDE 등의 주요 기관이 개발한 Industry 4.0을 위한 참조 아키텍처 모델(Reference Architectural Model Industrie 4.0)
- 독일 국가 표준인 DIN SPEC 91345로 제정되었으며, 이어 국제전기기술위원회(IEC)를 통해 IEC/PAS 63088이라는 글로벌 규격으로 채택




■ RAMI 4.0 참조 모델

- 현대 제조 환경은 사이버 물리 시스템, 사물인터넷, 클라우드 컴퓨팅, 그리고 인공지능(AI) 기술의 융합을 통해 과거 경직된 대량 생산 체제에서 유연하고 자율적인 스마트 제조 체제로 전환 중
- 패러다임의 변화는 물리적 기계 설비와 디지털 정보 시스템 간 경계를 허물며 수평적, 수직적 통합을 요구
- 센서, 제어기, 로봇, 전사적 자원 관리 시스템, 그리고 공급망 전체를 아우르는 이기종 시스템 간의 원활한 데이터 교환과 상호운용성을 확보하는 것은 극도로 복잡한 공학적 도전 과제




■ RAMI 4.0 참조 모델

- X축 : 자산의 시간적 생애주기와 이에 수반되는 가치 창출 흐름, 제품의 수명주기 관리를 다루는 IEC 62890 표준
- Y축 : 제조 시스템 내부 및 외부의 조직적 구성과 시스템 배치 계층, IEC 62264, IEC 61512 표준
 - ※ IEC 62264 : IT 및 제어 시스템 통합 관련, IEC 61512 : 배치 제어 및 공정 관리
- Z축 : 물리적 세계의 하드웨어 자산이 논리적이고 디지털화된 IT 세계와 어떻게 연동되며 정보가 추상화되는지 서비스 지향 아키텍처를 기반한 6계층으로 정의




■ RAMI 4.0 참조 모델 - x축 제품 수명 주기

- 제품이나 설비가 아이디어로 시작해 설계, 생산, 유지보수를 거쳐 폐기될 때까지의 시간적 흐름
 - ✓ **AAS (Asset Administration Shell)** : 설계 단계(Type)의 데이터부터 실제 공장에 배치되어 가동 중인 설비(Instance)의 운영 데이터까지, 전 수명 주기에 걸친 디지털 트윈 정보를 담고 추적하는 핵심 표준



■ RAMI 4.0 참조 모델 - x축 제품 수명 주기

- 제품이나 설비가 아이디어로 시작해 설계, 생산, 유지보수를 거쳐 폐기될 때까지의 시간적 흐름
 - ✓ **AAS (Asset Administration Shell)** : 설계 단계(Type)의 데이터부터 실제 공장에 배치되어 가동 중인 설비(Instance)의 운영 데이터까지, 전 수명 주기에 걸친 디지털 트윈 정보를 담고 추적하는 핵심 표준




■ RAMI 4.0 참조 모델 - y축 수직적 통합

- 전통적인 자동화 피라미드(ISA-95)를 스마트 팩토리 환경에 맞게 확장한 것으로, 공장 바닥의 실제 제품부터 제어 기기, 엣지 컴퓨팅, 엔터프라이즈 및 클라우드까지의 수직적 통합
 - ✓ **OPC-UA** : 하위 계층(현장 센서나 제어 기기)의 제조 데이터를 상위 계층(스테이션, 엔터프라이즈, 클라우드)으로 끊임 없이 안전하게 전달하는 수직적 통합의 핵심 통신 표준




전통적인 자동화 피라미드



OPC UA 기반 아키텍처


스마트팩토리 환경으로 확장



OPC-UA 적용 예

■ RAMI 4.0 참조 모델 - z축 아키텍처

- 물리적인 기계나 부품이 어떻게 디지털 정보로 변환되고 통신하며, 최종적으로 비즈니스 프로세스와 연결되는지를 6개의 층으로 나눈 논리적 구조
 - ✓ **OPC-UA** : OPC UA는 단순한 데이터 전송을 넘어, 정보 모델링 기능을 통해 데이터를 의미 있는 컨텍스트로 변환




■ OPC UA(Open Platform Communications Unified Architecture)

- **문제점** : 공장 내 설비(로봇, PLC, 센서 등) 간 호환성 부족과 데이터 전달의 어려움
- **해결책** : 공장 내 모든 설비와 시스템이 공통으로 사용할 수 있는 표준 언어 개발

산업 자동화 분야에서 안전하고 신뢰성 있게 데이터를 교환하기 위해
만들어진 국제 표준 통신 프로토콜


통신 프로토콜 : 컴퓨터, 스마트폰, 공장 설비 등 서로 다른 기기들이 데이터를 주고받기 위해 미리 정해둔 '공통된 약속이나 규칙'



<https://www.phoenixcontact.com/ko-kr/technologies/communication-technologies/opc-ua>

■ OPC UA(Open Platform Communications Unified Architecture)

- **Information Models** : 탄탄한 인프라와 데이터 모델 규칙 위에서, 실제 공장 운영에 필요한 4가지 핵심 기능 구현
- **Foundation Layer** : 시스템 간 어떻게 연결을 맺고, 어떤 규칙으로 데이터를 주고 받을지 정의



■ OPC UA(Open Platform Communications Unified Architecture)


- 클라이언트-서버 방식 : 전통적인 1:1 통신 방식
 - 클라이언트가 서버에 연결을 맺고, 특정 데이터의 읽기/쓰기 또는 모니터링을 요청(Request)하면 서버가 그에 대한 결과 값을 응답(Response)하는 구조
 - 통신하는 동안 연결 상태를 유지(연결 지향형)
 - 전송 계층에서의 암호화 및 인증 지원
 - 예. HMI/SCADA 시스템의 PLC 관리, 정밀한 장비 제어



■ OPC UA(Open Platform Communications Unified Architecture)

➤ PubSub 방식 : Publisher – Subscriber 방식

- 데이터 제공자인 '퍼블리셔'는 특정 수신자를 지정하지 않고 네트워크에 데이터를 발행(Publish)
- 데이터를 필요로 하는 '서브스크라이버(데이터 소비자)'는 해당 주제(Topic)를 구독(Subscribe)하여 데이터 수신
- 연결 상태 유지 X (비연결 지향형)
- One-to-Many / Many-to-Many 통신(Broadcast/Multicast 방식, 네트워크 확장 용이)
- 예. 공장 내 수천 개의 센서 데이터 수집/처리/분석, 장비 간 고속 동기화



■ 실습 : OPC-UA 기반 제조 센서 데이터 수집 및 데이터셋 생성

- 실습 목적 : 제조 현장에서 표준으로 사용되는 OPC-UA 프로토콜을 이해하고, Python을 활용하여 가상의 설비에서 발생하는 센서 데이터를 수집하여 분석용 데이터셋으로 구축
 - ✓ 주요 라이브러리 : asyncua (OPC-UA 통신), pandas (데이터셋 관리)
- 실습 파일(4th_practice)
 - ✓ **opcua_basic**
 - opc_client.py
 - opc_server.py
 - opc_client_mfg.py
 - opc_server_mfg.py
 - ✓ **data_pipeline**
 - data_pipeline.py
 - data_pipeline_check.py
 - ✓ **Information_model**
 - advanced_server.py
 - advanced_client.py

■ 실습 : OPC-UA 기반 제조 센서 데이터 수집 및 데이터셋 생성

➤ python 라이브러리 설치

```
$ pip install asyncua
```

주의! Conda 환경 활용 (명령어 : conda env list, conda activate OOO)

➤ Asyncua란?

- Python 환경에서 OPC UA 프로토콜을 구현하기 위해 가장 널리 사용되는 오픈소스 라이브러리

➤ OPC-UA client-server 실습

✓ opcua_basic

- opc_client.py
- opc_server.py
- opc_client_mfg.py
- opc_server_mfg.py

■ 실습 : OPC-UA 기반 제조 센서 데이터 수집 및 데이터셋 생성

➤ 기초 실습: OPC-UA Client-Server 통신 및 데이터 구독

- OPC-UA의 가장 기본적인 서버 구동과 클라이언트의 데이터 구독 방식을 학습

서버 구동 (opc_server.py)

- <http://manufacturing.example.com> 네임스페이스에 SensorSystem 객체와 Temperature 변수 생성
- 초기 온도는 20.0으로 설정되며, 1초마다 0.5씩 일정하게 온도가 상승하는 가상의 데이터 생성

클라이언트 접속 (opc_client.py)

- 서버에 접속한 후, 주기적으로 값을 수동으로 요청하는 대신 데이터 변경 시 알림을 받는 구독 방식 사용
- 데이터가 변경될 때마다 SubHandler 클래스가 이를 감지하여 10초 동안 실시간으로 변경된 온도 값을 화면에 출력

■ 실습 : OPC-UA 기반 제조 센서 데이터 수집 및 데이터셋 생성

➤ 응용 실습: 제조 현장 모델링 및 분석용 데이터셋 생성

- 실제 제조 설비처럼 여러 개의 센서가 불규칙하게 변하는 상황을 시뮬레이션하고 이를 기계학습 및 분석용 CSV 파일로 저장

제조 설비 서버 (opc_server_mfg.py)

- <http://manufacturing.example.com> 네임스페이스 아래에 Machine_A 설비 객체 구성
- 이 설비는 1초 주기로 온도(20~30도)와 압력(1.0~1.5) 범위 내에서 무작위 난수 데이터를 실시간으로 생성

데이터 수집 클라이언트 (opc_client_mfg.py)

- Machine_A의 온도와 압력 노드를 찾아 10초 동안 데이터를 반복해서 읽어옴
- 수집된 데이터는 타임스탬프와 함께 Pandas 데이터프레임으로 변환되며, 최종적으로 manufacturing_sensor_data.csv 파일로 저장되어 분석 파이프라인의 기초 자료가 됨

■ 실습 : OPC-UA 기반 제조 데이터 파이프라인 및 품질 검증

➤ 기본 실습: 데이터셋 구축 라이프사이클 (data_pipeline.py)

- OPC-UA 서버에서 데이터를 수집하여 분석 모델에 넣기 직전 단계까지 가공하는 4단계 기본 파이프라인

주의! opc_server_mfg.py 실행

- **데이터 획득 (Acquisition):** Machine_A 설비에서 20초간 온도와 압력 데이터를 수집
현업의 센서 통신 오류 상황을 가정하여 10% 확률로 무작위 결측치(NaN)를
의도적으로 발생
- **데이터 정제 (Cleansing):** 결측치(dropna)와 중복 데이터를 제거하고, 분석 편의를
위해 소수점 둘째 자리로 포맷을 일괄 변환
- **데이터 라벨링 (Labeling):** 온도가 28.0 이상이거나 압력이 1.4 이상일 경우 '이상(1)',
그 외에는 '정상(0)'으로 분류하여 Status_Label 컬럼에 참값(Ground Truth)을 부여
- **품질 검증 (Quality Verification):** df.info()를 통한 기본 데이터 타입 확인 및 정상/이상
클래스의 라벨 분포(클래스 불균형 여부)를 출력한 후, 최종적으로
lifecycle_optimized_dataset.csv 파일로 저장

■ 실습 : OPC-UA 기반 제조 데이터 파이프라인 및 품질 검증

➤ 심화 실습: 데이터 품질 5대 지표 검증 (data_pipeline_check.py)

- 수집된 데이터가 분석에 적합한 수준인지 정량적인 지표를 통해 평가

주의! opc_server_mfg.py 실행

의도적 결함 주입

실습 효과를 극대화하기 위해 인덱스 5번에는 결측치(NaN), 10번에는 정상 범위를 벗어난 이상치(999.9), 15번에는 완전한 중복 레코드를 강제로 삽입하여 원시 데이터(raw_sensor_dataset.csv)를 생성

5대 품질 지표 평가 함수:

- **유일성**: 타임스탬프 기준 중복 레코드 비율을 계산
- **완전성**: 온도 및 압력 컬럼의 최대 결측치 비율을 확인
- **유효성**: 물리적 정상 범위(온도 0~100, 압력 0~5)를 이탈한 데이터 비율을 평가
- **일관성**: 라벨링 조건식과 실제 부여된 라벨 간의 논리적 모순이 있는지 검증
- **정확성**: 타임스탬프 및 수치형 데이터 타입의 포맷 적합성을 확인
- **Before & After 비교**: 정제 전 원시 데이터와, 모든 필터링을 거친 후의 데이터(verified_sensor_dataset.csv)를 각각 품질 평가 함수에 넣어 지표가 어떻게 0% 에러율로 개선되는지 콘솔에서 직접 비교

■ 실습 : OPC-UA 4대 핵심 규격 심화 실습 (DA, AC, HA, Prog)

➤ OPC-UA 4대 핵심 규격 실습

단방향 데이터 수집을 넘어, 과거 데이터를 조회하고 설비의 이상 상태를 즉각적으로 수신하며 원격으로 설비를 제어하는 양방향 통신 아키텍처 학습

- **DA (Data Access - 실시간 데이터)**: 현재의 온도, 압력 등 실시간 센서 값을 읽고 쓰는 기본 기능
 - **HA (Historical Access - 이력 데이터)**: 서버 메모리나 DB에 저장된 과거의 데이터 포인트를 기간 조건(Start~End Time)으로 조회하여 트렌드 분석에 활용
 - **AC (Alarms & Conditions - 알람 및 이벤트)**: 설비의 특정 조건(예: 온도 80도 초과) 충족 시 클라이언트로 즉각적인 이벤트를 비동기적으로 push
 - **Prog (Programs - 제어 및 메서드 호출)**: 클라이언트가 서버(설비)에 정의된 특정 함수를 실행하도록 명령 (예: 설비 리셋, 긴급 정지)
- ✓ **Information_model**
- advanced_server.py
 - advanced_client.py

■ 실습 : OPC-UA 4대 핵심 규격 심화 실습 (DA, AC, HA, Prog)

핵심 규격	서버 (advanced_server.py)	클라이언트 (advanced_client.py)
DA	1초 주기로 온도 값 생성 및 업데이트	실시간 온도 값 5회 반복 읽기
HA	노드 데이터 변경 이력 저장소 활성화	UTC 기준 최근 10초간의 이력 최대 5개 조회
AC	온도 33도 초과 시 커스텀 이벤트 발생	이벤트 핸들러 등록 및 알람 메시지 수신
Prog	emergency_stop 원격 제어 메서드 정의	사유와 함께 설비의 EmergencyStop 메서드 호출

감사합니다

Q&A