

어프런티스 프로젝트

Apprentice Project



충북대학교
CHUNGBUK NATIONAL UNIVERSITY



충북대학교
산업인공지능연구센터

어프런티스 프로젝트

Apprentice Project

Lecture : Feature Scaling



충북대학교
CHUNGBUK NATIONAL UNIVERSITY



충북대학교
산업인공지능연구센터

Feature Scaling?

Feature Scaling의 개념과 필요성

- 핵심 개념 : 서로 다른 물리적 단위(Unit)와 측정 범위를 동일한 척도로 맞추는 표준화 과정
- 특정 변수의 절대적 수치 크기가 거리 계산이나 가중치 업데이트를 독점(Domination)하는 현상을 방지

Before Scaling (스케일링 전)

• 물리적 단위 차이로 가로축이 거리를 압도




⚠ 문제점: RPM 차이(수백 단위)에 묻혀 미세 온도 변화(10°C)가 무시됨



Feature Scaling
(규격화 변환)

After Scaling (스케일링 후)

• 모든 변수가 공정한 가중치 공간에 정렬



✓ 해결: 거리 및 경사하강법 계산 시 두 피처가 동등한 영향력 행사

Feature Scaling?

Feature Scaling : 서로 다른 변수의 값에 대한 범위를 일정한 수준으로 맞추는 작업


차량 모델 (Car Model)	사용 연수 [Years, 년]	누적 주행거리 [Mileage, km]	차량 상태 등급 (Grade)
차량 A	1 년	15,000 km	A 등급(신차급)
차량 B (진단 대상)	12 년	20,000 km	? (예측)
차량 C	3 년	130,000 km	C 등급 (노후/정비)
차량 D	4 년	150,000 km	C 등급 (노후/정비)

사람의 상식적·직관적 판단 : 차량 B는 주행거리는 20,000km로 매우 짧지만, 출고된 지 무려 12년이나 지난 노후 차량이므로 직관적으로 'C 등급(노후/정비필요)'으로 판정


Feature Scaling?

❖ Feature Scaling 장점

- 인공신경망의 경사하강법 알고리즘의 수렴 속도를 빠르게 함
 - ✓ 스케일링을 하지 않는 경우 알고리즘이 목표로 하는 지점까지 찾아가는데 오래 걸림
 - ✓ 스케일링을 하게 되면 목표 지점까지 좀 더 빠르게 도달 가능




Scaling하지 않은 경사하강법



Scaling을 사용한 경사하강법

Feature Scaling?

경사하강법(Gradient Descent)의 기본 원리



$$w_{t+1} = w_t - \eta \nabla J(w_t)$$

$$w_{t+1} = w_t - \eta \frac{\partial J(w)}{\partial w}$$

<- 단일변수(스칼라) 형태로 편미분을 풀어서 표기

어느 방향으로 내려갈 것인가?

현재 위치에서 손실 함수를 미분한
기울기(Gradient, ∇J)의 반대 부호(-) 방향으로
이동합니다. (기울기가 양수면 좌측으로, 음수면
우측으로 이동)

한 번에 얼마나 크게 움직일 것인가?

기울기 크기에 곱해주는 보폭 조절 비율을
학습률(Learning Rate, η).

몇 번이나 갱신할 것인가?

기울기가 0에 근접하여 오차가 더 이상 줄어들지
않을 때까지 데이터셋을 충분한 횟수(Epochs &
Iterations) 동안 반복 통과시킵니다.

짙은 안개 속에서 발밑의 경사(기울기)를 확인하며, 설정한 보폭(학습률)으로 가장 깊은 골짜기(최소 오차)를 향해 한 걸음씩 조심스럽게 내려가는 과정

Feature Scaling?

경사하강법(Gradient Descent)에 중고차를 대입해본다면?

$$w_{t+1} = w_t - \eta \nabla J(w_t)$$

1. 모델과 변수 설정

- x_1 : 누적 주행거리 = 20,000 km
- x_2 : 사용 연수 = 12 년
- w_1 : 주행거리에 곱해지는 가중치
- w_2 : 연식에 곱해지는 가중치

2. 경사하강법 수식에 실제 대입

- 주행거리 가중치 갱신 식:

$$w_{1,t+1} = w_{1,t} - \eta \cdot (\text{예측 오차}) \cdot 20,000$$

- 연식 가중치 갱신 식:

$$w_{2,t+1} = w_{2,t} - \eta \cdot (\text{예측 오차}) \cdot 12$$

- 스케일링 미적용(if, 예측 오차 = 1)
 - 일반적인 학습률 ($\eta = 0.001$)을 썼을 때
 - w_1 갱신량: $0.001 \times 1 \times 20,000 = 20$
→ 발산(Overshooting). 일반적인 가중치(0.1 ~ 1.0)
 - w_2 갱신량: $0.001 \times 1 \times 12 = \mathbf{0.012}$
→ 보폭이 너무 작아 정지.
 - 학습률을 대폭 낮췄을 때 ($\eta = 0.000001$)
 - w_1 갱신량: $0.000001 \times 1 \times 20,000 = \mathbf{0.2}$
 - w_2 갱신량: $0.000001 \times 1 \times 12 = \mathbf{0.00012}$
 - → 수백만 번의 Epoch를 돌아도 가중치 w_2 가 사실상 업데이트되지 않음.

Feature Scaling?

경사하강법(Gradient Descent)에 중고차를 대입해본다면?

$$w_{t+1} = w_t - \eta \frac{\partial J(w)}{\partial w}$$

1. 모델과 변수 설정

- x_1 : 누적 주행거리 = 20,000 km
- x_2 : 사용 연수 = 12 년
- w_1 : 주행거리에 곱해지는 가중치
- w_2 : 연식에 곱해지는 가중치

2. 경사하강법 수식에 실제 대입

- 주행거리 가중치 갱신 식:

$$w_{1,t+1} = w_{1,t} - \eta \cdot (\text{예측 오차}) \cdot 20,000$$

- 연식 가중치 갱신 식:

$$w_{2,t+1} = w_{2,t} - \eta \cdot (\text{예측 오차}) \cdot 12$$

● 스케일링(Min-Max) 적용

중고차 전체 데이터의 최대치는

- 주행거리 최대값: 150,000 km(차량 D)

- 연식 최대값: 12 년(차량 B)

① 주행거리 스케일링 계산

$$\frac{20,000 \text{ km}}{150,000 \text{ km}} = \frac{2}{15} \approx 0.133 \quad (\text{약 } 13\%)$$

② 사용 연수(연식) 스케일링 계산

$$\frac{12 \text{ 년}}{12 \text{ 년}} = 1.0 \quad (100\%)$$

Feature Scaling?

비교 항목	스케일링 미적용 (Raw Data)	스케일링 적용 (Min-Max)
입력 피처값 (x_1, x_2)	주행거리 20,000, 연식 12	주행거리 0.133(13%), 연식 1.0(100%)
기울기(보폭) 비율	$w_1:w_2 \approx 1,667:1$ (주행거리 압도)	$w_1:w_2 \approx 0.133:1.0$ (연식 주도)
학습률(η) 딜레마	양자택일 불가(어느 쪽에 맞춰도 반 대편 파탄)	표준 학습률($\eta = 0.01 \sim 0.1$) 하나로 동시 해결
$\eta = 0.001$ 적용 시	w_1 은 +20으로 발산, w_2 는 미미	$w_1 = 0.00013, w_2 = 0.001$ 로 동시 안정 수렴
$\eta = 0.000001$ 적용 시	w_1 은 안정되나, w_2 가 0.00012로 정 지	— (극단적으로 작은 학습률을 쓸 필 요가 없음)
모델이 판단한 핵심 요 인	상대적으로 짧은 주행거리(20,000) 에만 집착	"12년이나 된 노후 차량"이라는 본 질을 핵심으로 인식

Feature Scaling?

스케일링 기법	수학적 변환 공식	핵심 동작 메커니즘	변환 범위	이상치 영향 및 권장
Min-Max Scaling MinMaxScaler	$X_{\text{new}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$	최솟값을 0, 최댓값을 1로 고정하여 데이터의 상대적 분포 형태를 [0, 1] 구간으로 선형 압축	[0, 1] (음수 시 [-1, 1])	이상치에 극도로 취약 - 이미지 픽셀 정규화 (0~255) - KNN, K-Means 등 거리 기반 모델
Standardization StandardScaler	$Z = \frac{X - \mu}{\sigma}$	데이터의 평균(μ)을 0, 표준편차(σ)를 1로 맞추어 표준정규분포 형태로 중심화 및 재정렬	제한 없음 (통상 [-3, 3])	보통 (상대적 안정) - 경사하강법 기반 신경망 (MLP, DL) - 선형/로지스틱 회귀, SVM, PCA
Robust Scaling RobustScaler	$X_{\text{new}} = \frac{X - Q_2}{Q_3 - Q_1}$	이상치에 취약한 평균 대신 중앙값 (Median)과 사분위범위(IQR)를 기준으로 스케일 조정	제한 없음 (IQR 기준 정렬)	이상치에 매우 강건 - 노이즈·스파이크가 잦은 센서 로그 - 제조 공정 계측/금융 이상거래 데이터
MaxAbs Scaling MaxAbsScaler	$X_{\text{new}} = \frac{X}{ X _{\max}}$	절댓값 최댓값으로 나누어 원점(0)을 이동시키지 않고 [-1, 1] 범위로 스케일 조정	[-1, 1] (0의 위치 불변)	최댓값 이상치에 취약 0의 희소성(Sparsity) 보존 필수 데이터 - 텍스트 BoW / TF-IDF, 추천 시스템 행렬

Feature Scaling?

Normalization (정규화) : Min-Max Scaling

최솟값을 0, 최댓값을 1로 설정하여 모든 데이터를 [0, 1] 구간으로 선형 압축하는 기법

BEFORE SCALING (RAW DATA)			공식 (Formula)	AFTER MIN-MAX SCALING [0.0 ~ 1.0]		
차량 모델	사용 연수 [년]	누적 주행거리 [km]		차량 모델	연식 [Scaled]	주행거리 [Scaled]
차량 A	1 년	15,000 km	$X_{new} = \frac{X - X_{min}}{X_{max} - X_{min}}$ ■ 연식 기준값 Min=1년, Max=12년 (Δ=11) ■ 주행거리 기준값 Min=1.5만, Max=15만 (Δ=13.5만) 선형 정규화 변환 →	차량 A	0.00	0.00
차량 B	12 년	20,000 km		차량 B	1.00	0.04
차량 C	3 년	130,000 km		차량 C	0.18	0.85
차량 D	4 년	150,000 km		차량 D	0.27	1.00

- 변환 결과 해석 : 단위가 사라지고 공정한 상대적 영향력이 복원됨
- 차량 B의 연식이 1.00(최대 노후)으로 정확히 부각되고, 주행거리는 0.04(신차급)로 압축되어 알고리즘이 마침내 상식과 일치하는 학습을 수행.


Feature Scaling?

Standardization (표준화) : Z-Score Scaling

임의의 평균(μ)과 분산(σ^2)을 가진 데이터를 평균 0, 표준편차 1인 표준정규분포(Standard Normal Distribution)로 변환

기존 데이터 (Original Distribution)

$$X \sim N(\mu, \sigma^2)$$



피쳐마다 평균(μ)과 퍼진 폭(σ)이 완전히 다른 상태

Z-SCORE TRANSFORMATION


$$Z = \frac{X - \mu}{\sigma}$$

- 1 평균 차감 ($X - \mu$)
데이터 중심을 원점(0)으로 평행 이동
- 2 편차 정규화 ($\div \sigma$)
데이터 폭(분산)을 1.0 단위로 균일화

Z-Score 표준화 변환 →

표준화된 데이터 (Standardized)

$$Z \sim N(0, 1)$$



모든 피쳐가 원점(0) 중심으로 동일한 단위 폭($\sigma=1$)을 공유

핵심 메커니즘 : Zero-Centering (원점 중심 정렬)과 Unit-Variance (단위 분산 정렬)
달린 구간 $[0, 1]$ 로 가두는 Min-Max와 달리, 상·하한 경계선 없이 이상치의 영향을 유연하게 흡수하며 경사하강법 및 신경망 역전파에 가장 최적화된 대칭적 손실 곡면을 형성

Feature Scaling?

제조 및 시계열 특화 스케일링 기법 비교

스케일링 기법	변환 공식 및 구조	시계열/제조 특화 메커니즘	이상치 대응력	제조 도메인 활용
RevIN Reversible Instance Norm	$X_{\text{norm}}^{(t)} = \frac{X^{(t)} - \mu_t}{\sigma_t}$	Lookback Window 단위 Zero-Centering을 통해 계절·가동 조건 변화로 인한 분포 변화 (Distribution Drift) 원천 차단	비정상성 대응 최우수 입력 단위 동적 정규화로 장기 추세 왜곡 제거	- 최신 딥러닝 (PatchTST, iTransformer) - 공정 설비 전력 부하·온도 장기 예측
Robust Scaling Median & IQR Scaler	$X_{\text{new}} = \frac{X - \text{Median}}{Q_3 - Q_1}$	평균 대신 중앙값과 사분위수 (IQR)를 사용하여 모터 기동 시 발생하는 급격한 과도 응답이나 통신 결측 스파이크 방어	노이즈 저항력 최우수 극단값에 오염되지 않고 정상 50% 신호 보존	- CNC 스피들 진동 가속도 계측 - 모터 피크 전류 이상 진단 (Anomaly)
채널별 표준화 Channel StandardScaler	$Z_d = \frac{X_d - \mu_d}{\sigma_d}$	압력(bar), RPM, 전류(A), 온도 (°C) 등 이종(Heterogeneous) 센서의 단위를 동일한 Unit-Variance로 정렬하여 가중치 편향 방지	경사하강법 안정화 대칭적 손실 곡면으로 빠른 수렴 보장	- 다변량 공정 모니터링 융합 모델 - 회전기기 베어링 결함 다중 분류
잔차 정규화 Residual / Differencing	$Z_e = \frac{X_t - \hat{T}_t}{\sigma_e}$	설비 마모로 인한 저주파 드리프트 추세를 통계/차분 모델로 분리하고, 정상성(Stationary)을 확보한 고주파 잔차 신호만 모델에 전달	추세·주기성 분리 우수 비정상 시계열을 정상성 잔차로 전환	- ARIMA + 딥러닝 하이브리드 모델 - 공구 마모도 추정 및 잔여 수명(RUL) 예측

순간 노이즈에는 RobustScaler를, 추세가 변하는 딥러닝 시계열 예측에는 윈도우 단위 정규화 및 역변환을 지원하는 RevIN을 사용

Feature Scaling?

Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift

Sergey Ioffe

Christian Szegedy

Google, 1600 Amphitheatre Pkwy, Mountain View, CA 94043

SIOFFE@GOOGLE.COM

SZEGEDY@GOOGLE.COM

<https://proceedings.mlr.press/v37/ioffe15.pdf>

- **발표 학회:** ICML 2015
- **핵심 질문:** "심층 신경망(Deep Neural Networks)이 깊어질수록 왜 학습 속도가 현저히 느려지고, 왜 극도로 작은 학습률과 정밀한 가중치 초기화에만 의존해야 하는가?"
- **핵심 해법:** 입력층에만 적용하던 피쳐 스케일링을 신경망 내부의 모든 은닉층(Hidden Layers) 활성화 직전에 미니배치 단위로 적용하는 미분 가능한 연산 블록(Batch Normalization Transform) 설계.

Layer Normalization

Jimmy Lei Ba
University of Toronto
jimmy@psi.toronto.edu

Jamie Ryan Kiros
University of Toronto
rkiros@cs.toronto.edu

Geoffrey E. Hinton
University of Toronto
and Google Inc.
hinton@cs.toronto.edu

<https://arxiv.org/pdf/1607.06450>

- **발표 학회:** arXiv 2016 (NeurIPS 2016 Deep Learning Symposium 발표)
- **핵심 질문:** "배치 정규화(BN)는 왜 순환 신경망(RNN)이나 가변 길이 시계열/문장 데이터, 그리고 작은 배치 크기에서 제대로 작동하지 못하며, 다른 데이터 샘플에 의존하지 않고 독립적으로 정규화할 수는 없는가?"
- **핵심 해법:** 미니배치 단위로 피처별 통계량을 구하는 대신, 각 단일 샘플 내부에서 해당 은닉층(Hidden Layer)의 모든 뉴런(피처)들에 걸쳐 평균과 분산을 직접 계산하여 배치 크기와 무관하게 동작하는 미분 가능한 연산 블록(Layer Normalization) 설계.

Instance Normalization: The Missing Ingredient for Fast Stylization

Dmitry Ulyanov
Computer Vision Group
Skoltech & Yandex
Russia
dmitry.ulyanov@skoltech.ru

Andrea Vedaldi
Visual Geometry Group
University of Oxford
United Kingdom
vedaldi@robots.ox.ac.uk

Victor Lempitsky
Computer Vision Group
Skoltech
Russia
lempitsky@skoltech.ru

- **발표 학회:** arXiv 2016 (*Instance Normalization: The Missing Ingredient for Fast Stylization*, Dmitry Ulyanov et al.)
- **핵심 질문:** "이미지 스타일 전이(Style Transfer) 및 생성 모델에서 배치 정규화(BN)를 적용하면 왜 배치 내 다른 이미지의 명암과 질감에 간섭을 받아 결과물이 왜곡되며, 개별 이미지 고유의 스타일(대비, 텍스처 등) 통계량만 독립적으로 제거할 수는 없는가?"
- **핵심 해법:** 배치 전체를 묶거나 채널 간 통계량을 섞지 않고, 각 단일 샘플(Instance)의 각 채널(Channel) 내부 공간 차원(Height $\times$ Width)에 대해서만 독립적으로 평균과 분산을 계산하여 개별 데이터의 스타일·명암 편향을 정규화하는 미분 가능한 연산 블록(Instance Normalization) 설계.

Feature Scaling?

Group Normalization

Yuxin Wu

Kaiming He

Facebook AI Research (FAIR)

{yuxinwu, kaiminghe}@fb.com

- **발표 학회:** ECCV 2018 (*Group Normalization*, Yuxin Wu, Kaiming He)
- **핵심 질문:** "객체 검출(Detection)이나 세그멘테이션(Segmentation)처럼 고해상도 비전 작업은 GPU 메모리 한계로 배치 크기를 작게(Batch Size = 1~2) 쓸 수밖에 없는데, 배치 정규화(BN)는 이 환경에서 오차가 급증하고 기존 LN이나 IN은 CNN에서 성능이 떨어지는 문제를 어떻게 해결할 것인가?"
- **핵심 해법:** 채널(Channel)들을 여러 개의 그룹(Group)으로 묶은 뒤, 각 단일 샘플 내부에서 그룹별 채널들과 공간 차원(Height × Width)에 걸쳐 평균과 분산을 계산하여 정규화함으로써, 배치 크기와 완전히 무관하게 안정적인 최적화 성능을 달성하는 미분 가능한 연산 블록(Group Normalization) 설계.

Project 1

❖ 제조 AI 머신러닝 프로젝트 수행 절차

단계	주요 내용	단계별 미션
1. 데이터셋 획득 및 문제 정의	회사 제조데이터 또는 공개데이터 활용 입력변수(X)와 출력변수(Y) 정의 분류/회귀 문제 유형 결정	프로젝트 대상 데이터와 예측 문제를 명확히 설정
2. 데이터 분할 및 비교	Train/Test 분할과 Train/Validation/Test 분할 비교 검증 데이터 유무에 따른 성능 차이 분석	검증 데이터의 유무에 따라 결과가 달라지는가?
3. 하이퍼파라미터 조정	휴리스틱(Heuristic) 또는 Grid Search 사용 예: K, max_depth, learning rate 등 조정 Validation 성능 기준으로 최적값 선택	하이퍼파라미터 조정이 필요한가?
4. 데이터 스케일링 및 이유 설명	Standardization, Min-Max, Robust Scaling 등 비교 왜 해당 방법을 선택했는지 설명 Scaler는 Train에만 fit, Validation/Test는 transform	데이터 전처리의 필요성을 이해하고 Data Leakage를 방지
5. 최종 성능 평가	분류: Accuracy, Precision, Recall, F1-score 회귀: MAE, MSE, RMSE, R ² Test 데이터로 최종 성능 평가	모델의 일반화 성능을 객관적으로 검증

※ 유의사항: 테스트 데이터는 모든 튜닝이 끝난 뒤 최종 1회만 사용