

어프런티스 프로젝트

Apprentice Project

2026-2

충북대학교 산업인공지능연구센터 채민선



충북대학교
CHUNGBUK NATIONAL UNIVERSITY



충북대학교
산업인공지능연구센터

어프런티스 프로젝트

Apprentice Project

Lecture : 학습, 검증, 테스트




충북대학교
CHUNGBUK NATIONAL UNIVERSITY



충북대학교
산업인공지능연구센터

데이터의 종류

◆ 학습·검증·테스트 데이터 분할





- 데이터는 일반적으로 학습, 검증, 테스트 데이터로 분할하여 사용한다.
- 학습 데이터는 모델 학습에 사용하고, 검증 데이터는 하이퍼파라미터 조정과 모델 선택에 사용한다.
- 테스트 데이터는 모든 튜닝이 끝난 뒤 최종 성능 평가에만 사용한다.
- 분할 비율은 고정되어 있지 않지만, 학습 데이터가 가장 큰 비중을 차지한다.
- 예: 학습:검증:테스트 = 6:2:2, 7:2:1, 8:1:1

※ 주의: 테스트 데이터는 모델 수정이나 튜닝에 사용하지 않음

데이터의 종류

❖ 학습 데이터와 테스트 데이터

- 1 **학습/테스트 분할** : 데이터 양이 충분하지 않은 경우, 별도의 검증 데이터(Validation Set)를 사용하지 않고 데이터를 학습 데이터와 테스트 데이터로 나누어 사용할 수 있음.
- 2 **학습 데이터(Training Data)** : 모델을 학습하는 데 사용되는 데이터로, 데이터의 패턴을 학습함.
특히 신경망 모델에서는 이 데이터를 사용하여 가중치를 업데이트함.
- 3 **테스트 데이터(Test Data)** : 학습이 모두 끝난 후, 최종 모델의 성능을 평가하는 데만 사용되는 데이터.



※ 주의: 테스트 데이터는 모델 수정이나 튜닝에 사용하지 않음.

데이터의 종류

◆ 학습 데이터, 검증 데이터, 테스트 데이터

- 1 | **학습 데이터:** 모델을 구축하고 패턴을 학습하는 데 사용되는 데이터
- 2 | **검증 데이터:** 테스트 이전에 모델 성능을 사전 점검하고, 최적 모델 선택 및 하이퍼파라미터 튜닝에 사용되는 데이터
- 3 | **테스트 데이터:** 학습이 완료된 최종 모델의 성능을 평가하는 데 사용되는 데이터

< Training / Validation - 모델 학습 및 검증 >

학습 데이터

	X1	X2	X3	X4	X5
샘플1					
샘플2					
샘플3					
⋮					

모델 학습



	Y
샘플1	
샘플2	
샘플3	
⋮	

학습에 도움



검증 데이터

	X1	X2	X3	X4	X5
샘플 v					
샘플 v+1					
⋮					


	Y
샘플 v	
샘플 v+1	
⋮	

< Testing - 모델 성능 평가 >

테스트 데이터

	X1	X2	X3	X4	X5
샘플 t					
샘플 t+1					
⋮					

학습 완료된 모델



	Y
샘플 t	
샘플 t+1	
⋮	



※ 주의: 테스트 데이터는 최종 성능 평가에만 사용하며, 모델 수정이나 튜닝에는 사용하지 않음.

◆ 파라미터와 하이퍼파라미터의 차이

1 파라미터

- 모델이 학습 데이터를 바탕으로 학습 과정에서 스스로 조정하는 값

- 예: 인공신경망의 가중치, 의사결정나무의 분할 기준



데이터로부터
자동 학습

2 하이퍼파라미터

- 모델 학습 전에 사용자가 직접 설정하며, 모델 구조나 학습 방식에 영향을 주는 값
- 학습 중 자동으로 바뀌지 않으며, 검증 성능을 보며 실험적으로 조정해야 함

- 예: learning rate, 은닉층 수, 배치 크기, K값



사용자가 직접
설정

구분	인공신경망	의사결정나무	KNN (K-nearest Neighbors)
파라미터	가중치	각 노드의 분할변수 및 분할점	없음 (인스턴스 기반 학습)
하이퍼 파라미터	은닉층 개수 및 노드 수, 배치 크기, learning rate, dropout rate	최대 깊이, 최소 분할 데이터 수, 비용함수 종류 (MSE, gini, entropy 등)	이웃의 수 K, 거리 측정 방법 (유클리드, 맨해튼 거리 등)


<머신러닝 모델의 파라미터와 하이퍼파라미터>

데이터의 종류

◆ 검증 데이터 사용 이유

1 학습 및 테스트 데이터만 사용 시


- 학습 완료된 모델을 테스트할 수는 있으나, 테스트 이전에 모델의 성능을 사전 점검하거나 최적의 모델을 수립할 수 없음
- 데이터의 양이 많지 않으며, 모델 과적합이 크게 중요하지 않을 경우



테스트 이전에는 모델의 성능을 점검하거나
최적의 모델을 선택하기 어려움

2 학습, 검증 및 테스트 데이터 사용 시

- 모델 학습에 검증 데이터를 이용하여 더 일반화된 성능을 갖추고 신뢰성 있는 모델 수립 가능
- 검증 데이터를 이용하여 학습 데이터에 대한 과적합 여부 확인 가능
- 모델의 학습 및 검증을 반복하며 하이퍼파라미터 튜닝 가능



핵심: 검증 데이터는 모델 선택, 과적합 확인, 하이퍼파라미터 튜닝에 도움을 줌

데이터의 종류

◆ 학습, 검증 및 테스트 데이터 특징

- 1 모델 학습 시 **학습 및 검증 데이터**만 볼 수 있고, 학습이 끝난 후 평가 시에만 **테스트 데이터**를 볼 수 있음
- 2 학습 시 **가중치 업데이트**는 오직 **학습 데이터**에 대해서만 진행되며, 검증 데이터는 학습 도중 **최적 모델 선택** 및 **하이퍼파라미터 튜닝**에 도움을 주는 방식으로 이용됨
- 3 비시계열 데이터는 분할 전 일반적으로 **데이터 섞기 (shuffle)**를 진행하여 데이터 순서에 따른 편향 방지
 - ※ 단, 시계열 예측 모델의 경우, 일반적으로 과거 데이터를 학습하여 미래 시점의 데이터를 예측하므로 **데이터 섞기 없이 시간 순서를 유지한 채 분할**
- 4 **(중요)** 데이터에 minmax, 표준화 등의 scaling을 적용할 때, 검증 및 테스트 시에는 **학습 데이터의 통계량** (최댓값, 최솟값, 평균, 표준편차 등)을 이용해야 함





검증 데이터

❖ 검증 데이터 역할


1 모델의 최적 파라미터 선택

- 모델 학습 시 training loss와 validation loss를 기록해 두었다가 학습이 끝난 후 minimum validation loss를 기록한 모델 파라미터를 최종 파라미터로 선택
- 학습 때 보지 못한 검증 데이터로 평가함으로써 학습 데이터에 대한 과적합을 방지



학습이 진행됨에 따라
train/validation loss가 모두 감소

...



- ✓ Minimum validation loss를 기록한 모델 파라미터를 최종 선택
- ✓ 이후 테스트 데이터로 최종 성능 평가


검증 loss가 가장 낮은 시점의
모델 파라미터를 선택

➡ 검증 데이터는 학습 도중 모델의 일반화 성능을 확인하고, 최적의 모델을 선택하기 위해 사용됨

검증 데이터 역할

2. 학습 조기 종료 (Early Stopping)

- 1 모델 학습 과정에서 validation 성능이 더 이상 개선되지 않으면 (N번의 epoch 동안 validation loss가 이전보다 줄어들지 않으면) 학습 조기 종료
- 2 모델이 과적합되기 전에 학습을 중단함으로써 일반화 성능 확보




<인공신경망 학습 예시>

❖ 검증 데이터 역할

3. 최적 하이퍼 파라미터 선택

- 하이퍼 파라미터: (인공신경망의 경우) 은닉층 수, 은닉층 노드 수, 배치 크기, learning rate, dropout rate 등
- 모델 학습 후 validation 성능을 기반으로 하이퍼 파라미터 조정 반복. 이때 조정은 수동으로 진행될 수도 있고, 자동 최적화 도구를 통해 진행될 수도 있음



<인공신경망 학습 예시>

❖ 검증 데이터 역할

4. K겹 교차 검증 (K-fold Cross Validation)

- 하나의 검증 데이터에 과적합될 위험을 줄이기 위해 데이터를 K개의 부분집합으로 나누고, 한 개를 검증 데이터로 사용하며 나머지 (K-1)개를 학습 데이터로 설정하여 이를 K번 반복한다.
- K개의 모델을 학습하거나 K번의 검증을 수행하고, 각 결과의 성능을 평균 내어 최종 결과로 사용한다.
- 모든 폴드의 데이터를 검증에 활용하므로 더 안정적인 하이퍼파라미터 튜닝과 일반화된 모델 구축이 가능하지만, 모델을 K번 학습해야 하므로 계산 비용이 증가한다.



<K-fold 교차 검증 예시>

의사결정 나무 예시

❖ 의사결정나무 예시

- **예시:** 은행 고객의 채무 불이행 여부 예측을 위한 의사결정나무 분류 모델
- **입력 변수 X:** 고객의 나이, 연 수입, 부채 비율, 신용 점수, 직업 등
- **출력 변수 Y:** 채무 불이행 여부 (Yes / No)

고객 데이터 예시 (총 10,000개)

10,000개의 고객 데이터를 랜덤하게 섞기 (Shuffle)

입력 변수 X							출력 변수 Y
고객 ID	나이	연 수입	부채 비율	신용 점수	...	직업	연체 여부 (Y)
고객 5001	28	3,500	0.25	680	...	회사원	No
고객 5002	45	7,200	0.40	610	...	자영업	Yes
고객 5003	34	4,800	0.18	720	...	공무원	No
고객 5004	52	6,100	0.55	580	...	자영업	Yes
고객 5005	41	5,300	0.32	640	...	회사원	No
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
고객 8241	39	4,900	0.48	620	...	교사	Yes
고객 8242	47	5,800	0.36	690	...	회사원	No
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
고객 9712	31	3,200	0.28	710	...	프리랜서	No
고객 9987	50	6,700	0.62	560	...	자영업	Yes
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮


<데이터 분할>

학습 데이터 6,000개


검증 데이터 2,000개

테스트 데이터 2,000개

1 학습/검증 데이터로 학습 및 검증



2 테스트 데이터로 모델 성능 평가




의사결정나무는 고객의 특성을 기반으로 채무 불이행 여부를 예측하는 데 사용되며, 학습/검증/테스트 데이터 분할을 통해 일반화 성능을 평가할 수 있습니다.

합성곱 신경망 모델 예시

❖ 인공 신경망 예시

- 예시: 강아지, 고양이, 토끼 이미지 분류를 위한 합성곱 신경망 (CNN) 모델
- 입력 변수 X: 레이블이 있는 이미지
- 출력 변수 Y: 3개 클래스에 대한 예측 분포 (강아지 / 고양이 / 토끼)



1 학습/검증 데이터로 학습 및 검증



2 테스트 데이터로 모델 성능 평가



분류 문제의 경우, 일반적으로 학습/검증/테스트 데이터 내 클래스 비율이 전체 데이터에 존재하는 클래스의 비율과 동일해지도록 분할하는 **층화 샘플링 (stratified sampling)**을 적용합니다.

시계열 예측 모델

TIME SERIES FORECASTING

주요 내용

01 예시

생산 공정의 여러 센서 데이터를 통해 제품의 이상 여부를 예측하는 순환 신경망 (RNN) 모델

02 입력 변수 X

여러 센서로부터 수집된 시계열 데이터

03 출력 변수 Y

제품의 이상 여부

04 시계열 데이터 분석 시 주의점

전체 데이터를 한 번에 넣지 않고 슬라이딩 윈도우(sliding window) 크기로 나누어 각 윈도우를 하나의 입력 데이터로 사용

슬라이딩 윈도우를 이용한 입력 데이터 구성 예시



시계열 데이터 분할

시계열 예측 모델



시간의 흐름 속에서
데이터의 패턴을 학습하여 미래를 예측합니다.



예시

생산 공정의 여러 센서 데이터를
통해 제품의 이상 여부를 예측하는
순환 신경망 (RNN) 모델



입력 변수 X

여러 센서로부터 수집된
시계열 데이터



출력 변수 Y

제품의 이상 여부



시계열 데이터 분석 시 주의점

비시계열 데이터와 달리 시간의 흐름을
고려해야 하므로 데이터 섞기 없이
그대로 학습/검증/테스트 데이터로 분할 진행

1 시간 순서를 유지한 데이터 분할

⌚
길이가 10,000인
전체 데이터를
섞지 않고
시간 순서를
유지하며 분할
(순차 분할)

입력 변수 X (센서 데이터)							출력 변수 Y
시간 (t)	센서 A	센서 B	센서 C	센서 D	...	센서 K	이상 여부
1	...	...	...	...	...	...	정상
2	...	...	...	...	...	...	정상
3	...	...	...	...	...	...	불량
4	...	...	...	...	...	...	정상
5	...	...	...	...	...	...	정상
...	...	...	...	...	...	...	...
6000	...	...	...	...	...	...	정상
6001	...	...	...	...	...	...	정상
...	...	...	...	...	...	...	...
8000	...	...	...	...	...	...	불량
8001	...	...	...	...	...	...	정상
...	...	...	...	...	...	...	...
10000	...	...	...	...	...	...	정상

학습 데이터
6,000개


검증 데이터
2,000개

테스트 데이터
2,000개


< 시간 순서를 유지하며 데이터 분할 >

2 모델 학습 및 성능 평가

1 학습/검증 데이터로 학습 및 검증



2 테스트 데이터로 모델 성능 평가



시간의 흐름을 고려한 올바른 데이터 분할이 신뢰할 수 있는 시계열 예측 모델의 시작입니다.