✓ 대상 데이터셋 개요 및 선정근거

변압기 데이터를 통한 오일 온도 예측

2개 변전소에 위치한 2대의 전력 변압기 데이터(부하 및 오일 온도 포함)를 통한 오일 온도 예측 입니다.

1 데이터 개요

원본	중국의 2개 변전소에 설치된 2대의 전력 변압기, 수집된 실제 산업 데이터입니다.
관측 기간	2016년 7월 1일 00:00 ~ 2018년 6월 26일 (24개월)
기록 주기	1시간 (1-hour interval) 단위로 기록
데이터 규모	약 17,420행 × 8개 변수
데이터 유형	다변량 시계열 (Multivariate Time Series)
과제 유형	오일 온도(OT)나 부하를 예측하는 지도 학습(Supervised Learning) 및 회귀(Regression) 과제

2 변수 구성

- date (관측 일시), HUFL, HULL, MUFL, MULL, LUFL, LULL (부하 관련 수치형 변수 6개), OT (오일 온도, Oil Temperature)
- HUFL (High UseFul Load): 고압 유효 전력 부하
- HULL (High UseLess Load): 고압 무효 전력 부하
- MUFL (Middle UseFul Load): 중압 유효 전력 부하
- MULL (Middle UseLess Load): 중압 무효 전력 부하
- LUFL (Low UseFul Load): 저압 유효 전력 부하
- LULL (Low UseLess Load): 저압 무효 전력 부하
- OT는 Oil Temperature(오일 온도)

3 입력 변수 (X)와 예측 변수 (Y) 정의

- **다변량 입력 ➔ 단일 변수 예측**
- **입력 변수 (X):** 과거 일정 기간 동안의 7개 변수 전체 (부하 6종 + 오일 온도)
  X = [HUFL, HULL, MUFL, MULL, LUFL, LULL, OT]
- **예측 변수 (Y, Target):** 미래 시점의 오일 온도 1개 변수
  Y = [OT]
  이유: 변압기 파손 및 과부하를 경고하는 가장 핵심적인 물리적 지표가 오일 온도(OT)이기 때문입니다.

4 예측 길이 (Prediction Length / Horizon) 정의

- ETTh2는 1시간(1-hour) 주기로 기록된 데이터입니다. 모델이 과거 데이터를 바탕으로 '얼마나 먼 미래'를 예측할 것인지 그 길이(H)를 설정.
- 단기 예측 (Short-term): 24 (하루 뒤), 48 (이틀 뒤)
- **중기 예측 (Medium-term):** 96 (4일 뒤), 168 (일주일 뒤)
- **장기 예측 (Long-term):** 288 (12일 뒤), 720 (30일 뒤)

✓ RNN/LSTM/GRU 구현 및 기본 성능 비교

ETTh2 변압기 데이터 · 과거 96시간 7개 변수로 24시간 뒤 오일 온도(OT) 예측 · 세 모델은 순환 셀만 다르고 나머지 조건은 모두 같음.

동일 실험 조건

데이터 ETTh2 1시간 간격, 7개 변수 (HUFL…LULL, OT)

문제 입력 96h × 7변수 → 24h 뒤 OT (Many-to-one)

분할 ETT 표준 12/4/4개월 시간순 — 윈도우 8,521 / 2,880 / 2,880

전처리 StandardScaler — Train 구간에만 fit

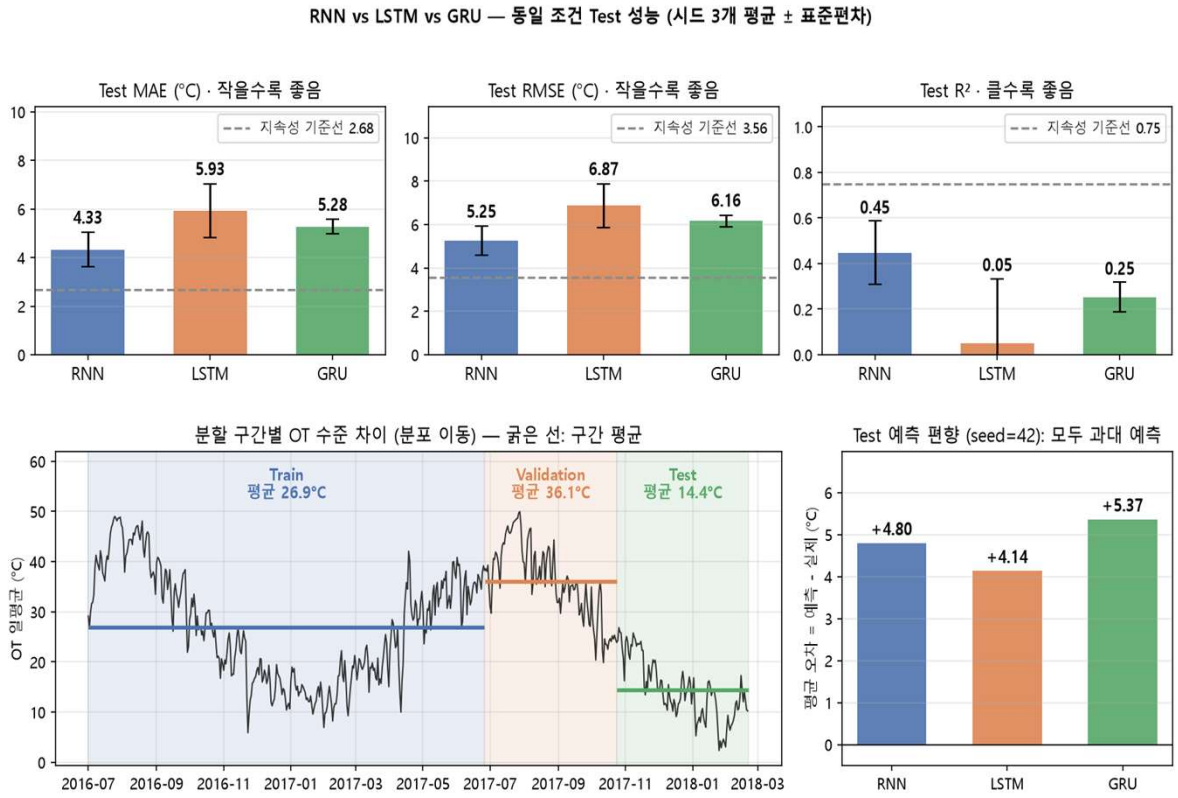
구조 순환층 2층 → 마지막 은닉상태 → Linear(1)

하이퍼 hidden 64 · layers 2 · dropout 0.1 · Adam lr 1e-3 · batch 64

학습 최대 30 epoch, Val 손실 기준 조기종료(patience 5), grad clip 1.0

Test 성능 (°C, 시드 3개 평균 ± 표준편차)

모델	MAE	RMSE	R^2	기준선 대비
RNN	4.333±0.706	5.251±0.667	0.448	−47.5%
LSTM	5.933±1.106	6.867±1.009	0.052	−92.9%
GRU	5.279±0.291	6.156±0.270	0.253	−72.9%
지속성	2.677	3.561	0.750	(기준)



핵심 결과

- 세 모델 모두 지속성 기준선(RMSE 3.56°C)보다 나쁨: RMSE RNN 5.25 〈 GRU 6.16 〈 LSTM 6.87°C
- 원인은 분포 이동 — 여름 Val(평균 36.1°C)로 고른 모델이 겨울 Test(14.4°C)를 +3.7~5.6°C 과대 예측
- Val 손실은 1~4 epoch 에서 최저 후 상승 · 파라미터 최다 LSTM 이 최하위, 시드 편차 최대(±1.01)
- 시드 편차가 겹쳐 순위는 잠정적

3. Ablation Test

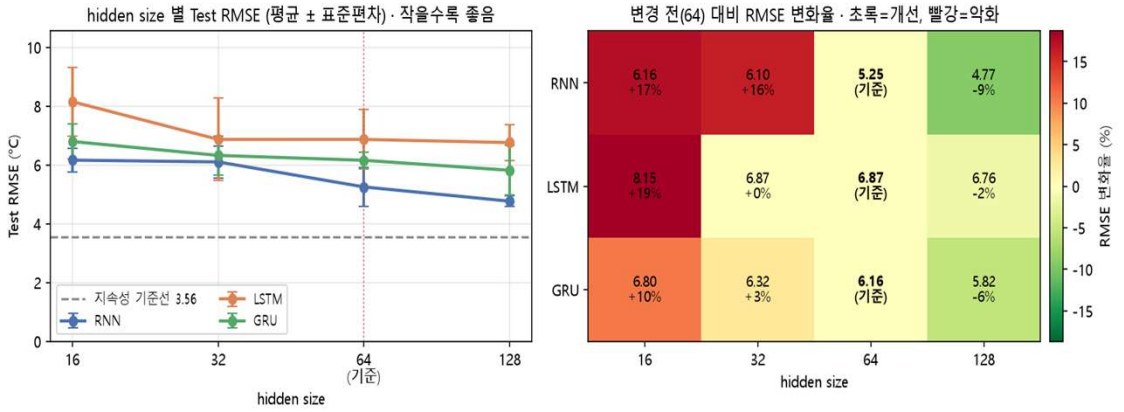
✓ hidden size 변경에 따른 RNN · LSTM · GRU 성능 변화

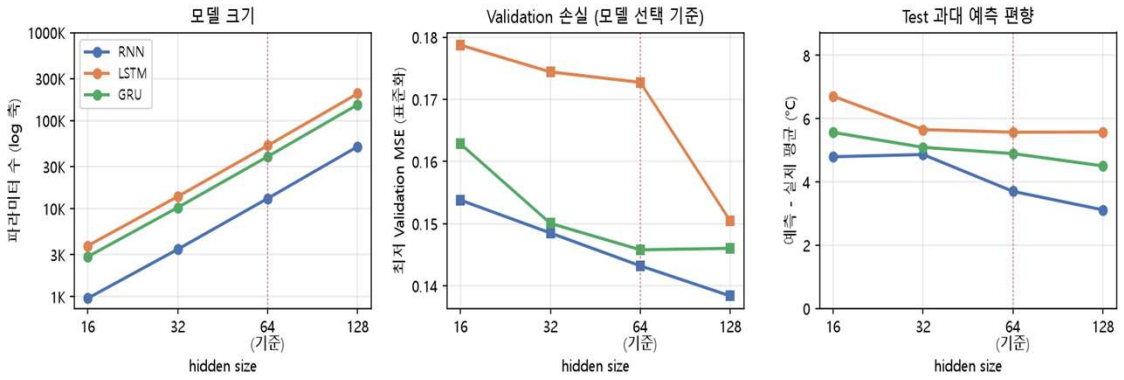
바꾼 조건은 hidden size 하나 (16 / 32 / 64 / 128, 변경 전 = 2단계 기준 64) · 나머지 조건은 2단계와 동일 · 모델 3 × 값 4 × 시드 3

Test RMSE (°C) 시드 평균 · 아래 = 변경 전 대비

모델	16	32	64 (기준)	128
RNN	6.16 +17.4%	6.10 +16.2%	5.25 기준	**4.77** −9.2%
LSTM	8.15 +18.7%	6.87 +0.0%	6.87 기준	**6.76** −1.6%
GRU	6.80 +10.4%	6.32 +2.7%	6.16 기준	**5.82** −5.5%

초록 개선 **빨강** 악화 **굵게** 모델별 최저 지속성 기준선 3.56





변경별 성능 변화 분석

64 → 16 (¼ 축소) 세 모델 모두 악화 — RNN +17% · LSTM +19% · GRU +10%. 용량 부족으로 과대 예측 편향 증가 (LSTM +5.6 → +6.7°C)

64 → 32 (½ 축소) RNN +16% · LSTM +0% · GRU +3%. RNN 만 크게 악화되고 GRU · LSTM 은 영향이 작음

64 → 128 (2배 확대) 세 모델 모두 개선 — RNN −9% · LSTM −2% · GRU −6%. 편향 감소 (RNN +3.7 → +3.1°C), Val 손실도 같은 방향으로 감소

비용 128 은 파라미터 3.9배, 학습 시간 2.1~3.6배

주의 LSTM 은 시드 간 RMSE 5.3~9.7°C — 변화량이 노이즈 수준

종합 결론 hidden size 를 키울수록 세 모델 모두 성능이 좋아졌고 128 까지 과적합 신호는 없음. 그러나 최고 성능(RNN-128, RMSE 4.77°C)도 지속성 기준선(3.56°C)에 못 미침 → 병목은 모델 용량이 아니라 분포 이동

✓ RNN · LSTM · GRU 최종 모델 Test 비교

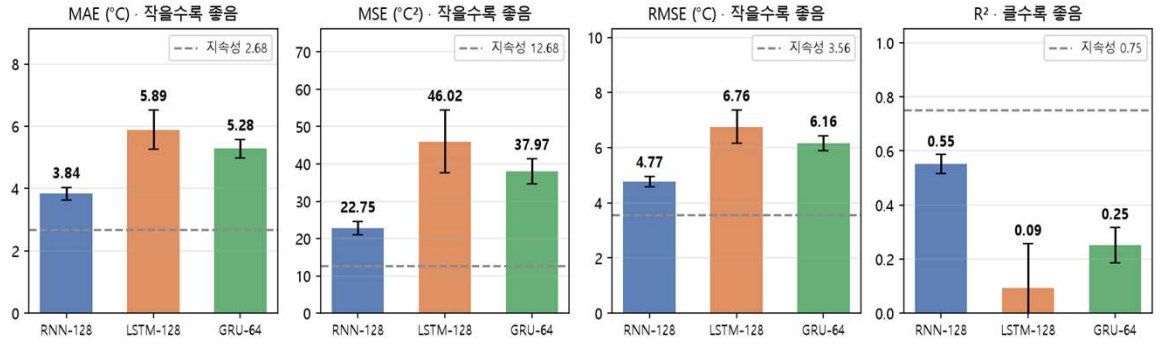
최종 설정 = 3단계 그리드에서 Validation 손실 최저(RNN-128/LSTM-128/GRU-64)·Test 는 마지막에 1회 평가·주 지표 RMSE·시드 3개 평균

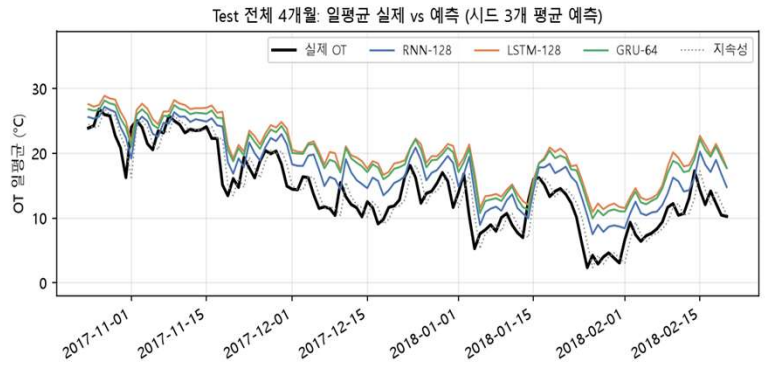
Test 성능 (°C)

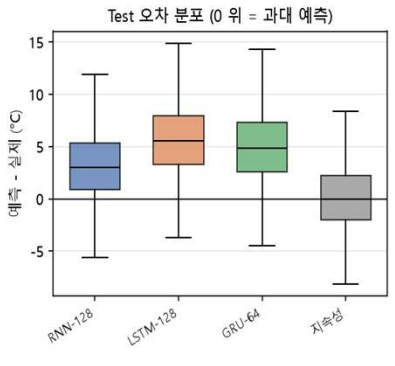
모델	MAE	MSE	RMSE	R^2	기준선 대비
RNN-128	3.84	22.8	4.77	0.55	-34%
LSTM-128	5.89	46.0	6.76	0.09	-90%
GRU-64	5.28	38.0	6.16	0.25	-73%
지속성	2.68	12.7	3.56	0.75	(기준)

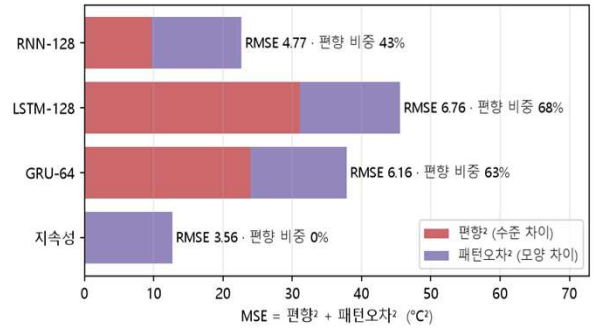
모델별 장단점

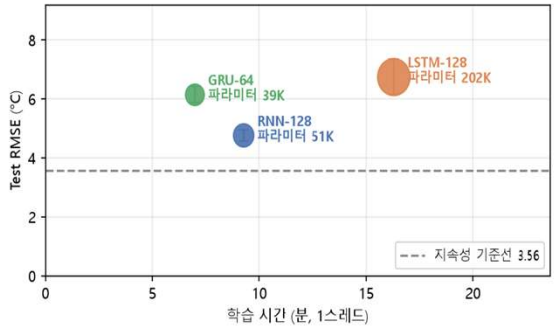
모델	장점	단점
RNN-128	RMSE 최저(4.77) · 편향(+3.1°C)과 시드 편차(±0.19) 최소	hidden 축소 시 +16~17% 악화 · 긴 의존성 학습 한계
LSTM-128	게이트로 장기 기억 · 용량 확대 시 Val 손실 개선 최대 (0.173→0.150)	RMSE 최하위(6.76) · 편향 최대 · 비용 최대(202K, 16분)
GRU-64	LSTM 대비 파라미터 1/5 로 RMSE 9% 낮음 · 학습 최단	RNN 대비 RMSE 29% 높음 · 편향 +4.9°C











결론

- RMSE 순위: RNN-128 4.77 〈 GRU-64 6.16 〈 LSTM-128 6.76°C (MAE·MSE·R^2 도 같은 순위) → 가장 단순한 RNN 이 가장 정확·안정
- 세 모델 모두 지속성 기준선(RMSE 3.56)에 미달 (-34% ~ -90%)
- 원인: 패턴오차(3.6~3.8)는 기준선 수준이나 겨울 수준을 +3.1~5.6°C 과대 예측 — 오차의 43~68% 가 편향
- 개선: 수준 편향 제거(RevIN·변화량 예측), 계절을 반영한 분할·재학습