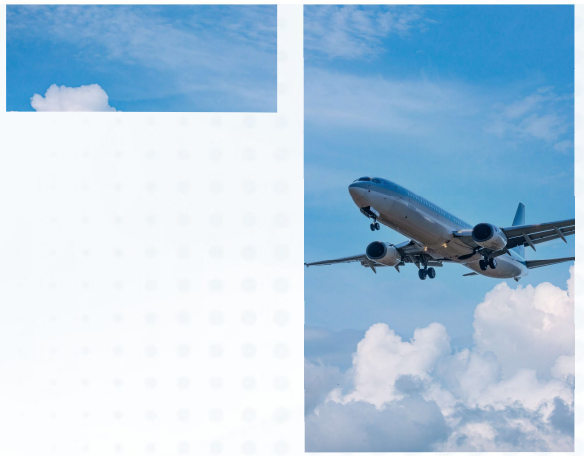
어프렌티스 프로젝트 · 프로젝트 3

SKAB 데이터셋 기반 산업 설비 이상감지

비지도 이상탐지 모델 적용 및 성능 최적화

Isolation Forest · PCA(T^2+Q) · Conv-AutoEncoder





2026254008 이은용

충북대학교 산업인공지능학과 · 2026-11-12

발표 구성

✓ 과제 수행 내용 · 학습 목표 · 발표 순서

과제 안내의 4개 구분 × 수행 내용 2개를 그대로 따라 발표합니다

구분	수행 내용	학습 목표	슬라이드
1. 데이터 분석	• 데이터셋: SKAB • 데이터 특성 분석 및 전처리	산업 시계열 데이터의 특성을 이해하고, 분석 결과를 바탕으로 이상탐지 문제 정의	3 ~ 5
2. 이상탐지 모델 설계 및 구현	• 학습 방식 선택: 비지도 (정상만 학습) • 접근 방식이 다른 모델 3종 구현·비교	데이터 특성에 적합한 모델을 선정하고, 이상탐지 모델을 설계·구현하여 성능 비교	6 ~ 8
3. 성능 개선 및 최적화	• 성능 평가지표 6종 (기준 3개 이상) • 개선 실험 4요인 설계 및 수행	다양한 실험을 통해 탐지 성능을 개선하고, 최적화 방법의 효과 검증	9 ~ 12
4. 결과 분석 및 해석	• 모델별 성능 평가 및 결과 분석 • 성능 개선 효과 및 한계 분석	객관적인 성능 비교와 결과 해석을 통해 모델의 특성 및 연구적 시사점 도출	13 ~ 16

라벨 사용 원칙 (과제 강조사항)

- ▸ **모델 학습:** 라벨 미사용
- ▸ **임계값 결정:** 라벨 미사용 (학습 구간 점수의 분위수)
- ▸ **개선 설정 선택:** dev(valve1 16개) 라벨 사용
- ▸ **성능 보고:** 선택에 쓰지 않은 holdout 18개 파일 + 지표 계산에만 라벨 사용

✓ 대상 데이터셋 개요 및 선정근거

펌프 테스트베드 센서 데이터를 통한 설비 이상감지

러시아 Skoltech 물 순환 테스트베드의 8개 센서 데이터(진동·전류·압력·온도·유량)로 설비 이상을 탐지합니다.

1 데이터 개요

원본	Skoltech(스콜텍) 펌프·밸브·배관 테스트베드에서 고장을 직접 재현하며 수집한 실험 데이터입니다.
실험 구성	**이상 실험 34회 + 정상 운전 1회** (CSV 35개)
기록 주기	**1초 (1-second interval)** 단위로 기록
데이터 규모	이상 실험 37,401행 + 정상 9,405행 (센서 8개)
데이터 유형	다변량 시계열 + 시점별 이상 레이블
과제 유형	정상 데이터로 학습하는 비지도 이상감지 과제

2 변수 구성

- datetime (관측 일시), 센서 8개 (진동 2·전류·압력·온도 2·전압·유량), anomaly · changepoint (정답 레이블 2개)
- Accelerometer1·2RMS: 펌프 진동 가속도 (RMS, 2개 축)
- Current: 구동 모터 전류
- Pressure: 배관 압력
- Temperature: 모터 본체 온도
- Thermocouple: 순환 유체 온도
- Voltage: 구동 모터 전압
- Volume Flow RateRMS: 순환 유량

3 입력 변수 (X)와 정답 레이블 (Y) 정의

- **다변량 센서 입력 ➔ 시점별 정상/이상 판정**
- **입력 변수 (X):** 슬라이딩 윈도우로 자른 8개 센서 값
  X = [Accel1·2, Current, Pressure, Temp, Thermo, Voltage, Flow]
- **정답 레이블 (Y):** 시점별 이상 여부 anomaly (0/1), 평가에만 사용
  Y = [anomaly] (보조: changepoint)
  판정: 정상 구간으로 학습한 모델의 오차가 임계값을 넘으면 이상

4 데이터셋 선정 근거

- **실제 설비 센서:** 진동·전류·압력·온도 등 현장 예지보전 센서 구성과 같음
- **정답 레이블 제공:** 시점별 이상·변화점 정답으로 F1·FAR·MAR 평가 가능
- **다양한 고장 유형:** 밸브 폐쇄·캐비테이션·누수·로터 불균형 등
- **비교 기준 존재:** 공개 리더보드(Isolation Forest, LSTM-AE 등)와 비교

✓ 데이터 특성 분석

34개 실험 모두 '정상 → 이상 1구간 → 복귀' 구조 · 운전조건이 파일마다 달라 파일별 학습이 필요

34개 · 1초
이상 포함 실험 파일
(37,401행, 결측 0)

54%
평가 구간의 이상 비율
(전체 35%)

1개
파일당 이상 구간 수
(평균 약 385초 연속)

2배+
그룹 간 유량 차이
(valve 32 vs other 75~128)

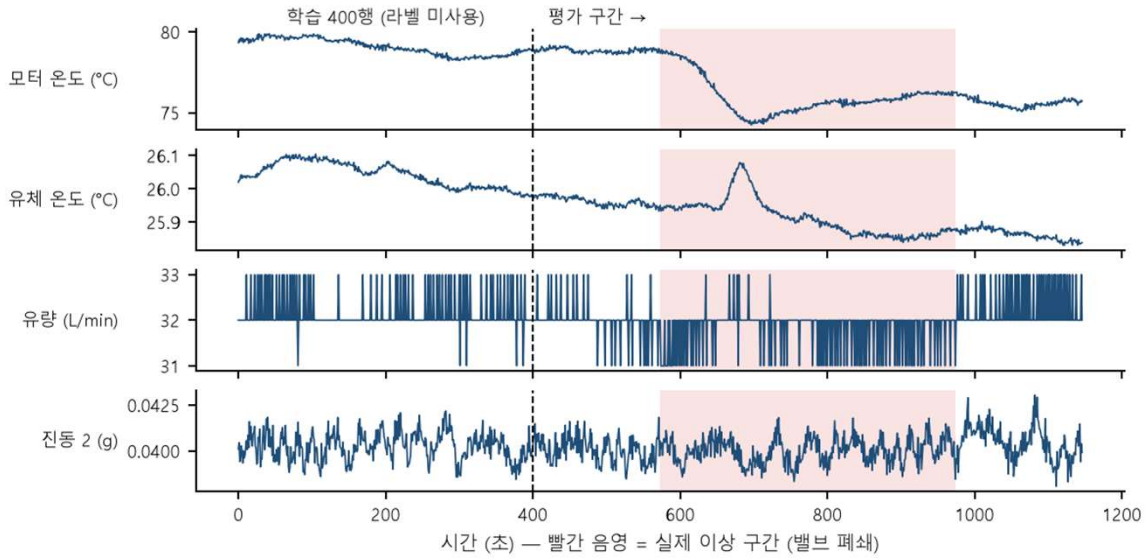
분석 결과 → 문제 정의 시사점

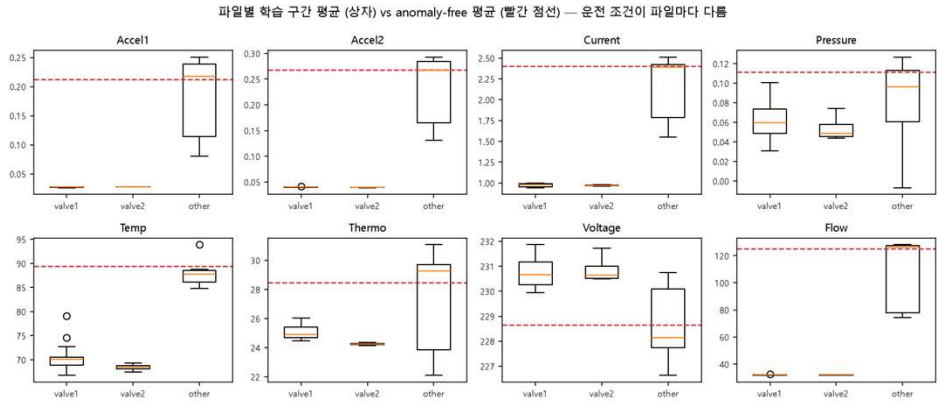
불균형 약함 평가 구간 54% 가 이상 — 강의 p.19 의 '정상 다수' 가정이 약함 → '항상 이상' 판정도 F1 0.70, F1 단독 판단 불가

집단 이상 수백 초 연속 구간 → 점 하나가 아닌 시간 패턴(윈도우·평활) 필요

운전조건 그룹마다 유량·온도 수준이 다름 → 파일별 학습·정규화

학습 구간 오염 other/2 는 104행부터 이상 → 학습 400행 중 296행이 이상





✓ 전처리 및 이상탐지 문제 정의

정상 구간만으로 '정상'을 학습하고, 벗어난 정도(점수)로 이상을 판정하는 비지도 신규성 탐지로 정의

① 시간순 분할
파일별 앞 400행 = 학습
나머지 = 평가 (셔플 없음)

→

② 라벨 분리
anomaly·changepoint
컬럼을 입력에서 제거

→

③ 표준화
StandardScaler
학습 400행에만 fit

→

④ 학습·점수화
정상 가정 구간으로 학습
→ 시점별 이상 점수

→

⑤ 임계값·판정
학습 점수의 99% 분위수
점수 〉 임계값 → 이상

이상탐지 문제 정의

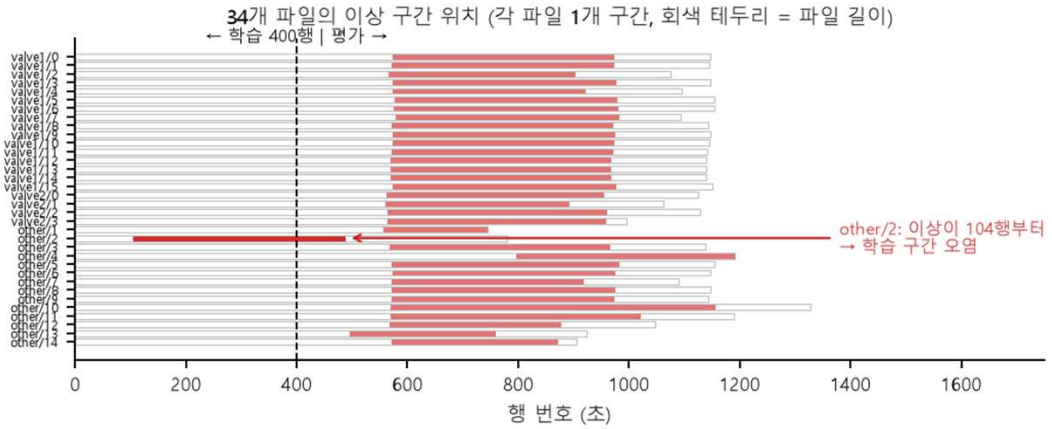
입력 X 8개 센서 (Conv-AE 는 60초 × 8센서 윈도우)

출력 시점별 이상 점수 → 임계값을 넘으면 이상(1)

정답 Y anomaly (0/1) — 평가 지표 계산에만 사용

학습 방식 비지도 — 정상(으로 가정한) 데이터만 학습 (강의 p.21-22)

선택 이유 ① 현장에는 고장 라벨이 거의 없음 ② 고장 유형이 다양하고 미지 (강의 p.16 선택 흐름: 이상 샘플이 충분치 않으면 이상탐지) ③ 운전조건이 파일마다 달라 분류기 일반화가 어려움



✓ 학습 방식 및 모델 선정

강의에서 배운 4개 알고리즘 계열 중 서로 다른 원리 3가지를 골라 같은 조건에서 비교

계열 (강의)	대표 알고리즘	이상 판단 원리	선택	선택 / 제외 사유
밀도 기반 (p.24–26)	Gaussian · GMM · LOF	정상 밀도가 낮은 곳 = 이상	—	8차원 분포 가정이 필요 · 센서 간 상관은 PCA 계열이 직접 다룸
모델 기반 (p.27)	Isolation Forest · OC-SVM · SVDD	적은 분할로 고립(얕은 깊이) = 이상	Isolation Forest	분포 가정 없음 · 빠름 · SKAB 리더보드 기준 모델
재구성 오차 (p.28)	PCA (주성분 분석)	주성분 공간 거리(T^2) · 재구성 잔차(Q)	PCA T^2+Q	센서 간 선형 상관 구조 학습 · 결정적이라 해석 쉬움
재구성 오차 (p.28)	AutoEncoder	비선형 압축 후 재구성 오차	Conv-AE	60초 윈도우로 시간 패턴 반영 · 리더보드 상위 계열
생성 모델 (p.29)	AnoGAN · GANomaly	생성 분포에서 벗어난 정도	—	파일당 학습 400행으로는 GAN 학습이 불안정

왜 비지도인가 (강의 p.15–16, p.20)

- 지도 분류는 정상·불량 경계를 배우지만 처음 보는 고장에 약함 (p.18)
- 클래스 불균형이 심하면 분류기는 대부분을 정상으로 예측 (p.20)
- 이상탐지는 정상만 학습해 미지의 이상도 '정상과 다름'으로 탐지 (p.15)

선정 원칙 — 공정한 비교

- 세 모델은 '이상 점수를 만드는 방식'만 다름
- 데이터 · 분할 · 전처리 · 임계값 규칙 · 평가지표는 모두 동일
- 하이퍼파라미터는 라벨을 보기 전에 고정 (기본 설정)
- 무작위성이 있는 IF · Conv-AE 는 시드 3개 평균

✓ 모델 설계 — 3종 구조와 이상 점수

각 모델은 '정상에서 벗어난 정도'를 점수로 만들고, 공통 규칙(학습 점수 99% 분위수)으로 판정

1 Isolation Forest

원리

무작위 분할 트리에서 빨리 고립되는(경로가 짧은) 점 = 이상

점수

평균 경로 길이 기반 이상 점수 (−score_samples)

입력

시점별 8차원 — 시간 순서 정보는 없음

설정

트리 200개 · 시드 3개

2 PCA (T^2+Q)

원리

정상 데이터의 주성분 공간으로 투영

T^2

$\Sigma\ z^2/\lambda$ — 정상 범위 밖으로 이동한 정도

Q

$\|x - \hat{x}\|^2$ — 센서 간 상관 구조가 깨진 정도

점수

$\max(T^2/T^2_{99}, Q/Q_{99})$

설정

누적 분산 90% · 결정적(시드 무관)

3 Conv-AutoEncoder

구조

Conv1d 8→32→16 (stride 2) → ConvT 16→32 → 8

입력

60초 × 8센서 윈도우

점수

윈도우 재구성 MAE → 윈도우 끝 시점

학습

Adam 1e-3 · 배치 32 · 최대 60 epoch

조기종료

학습 구간 마지막 10% 재구성 손실 (라벨 미사용) · 시드 3개

공통 판정 규칙 (라벨 미사용)

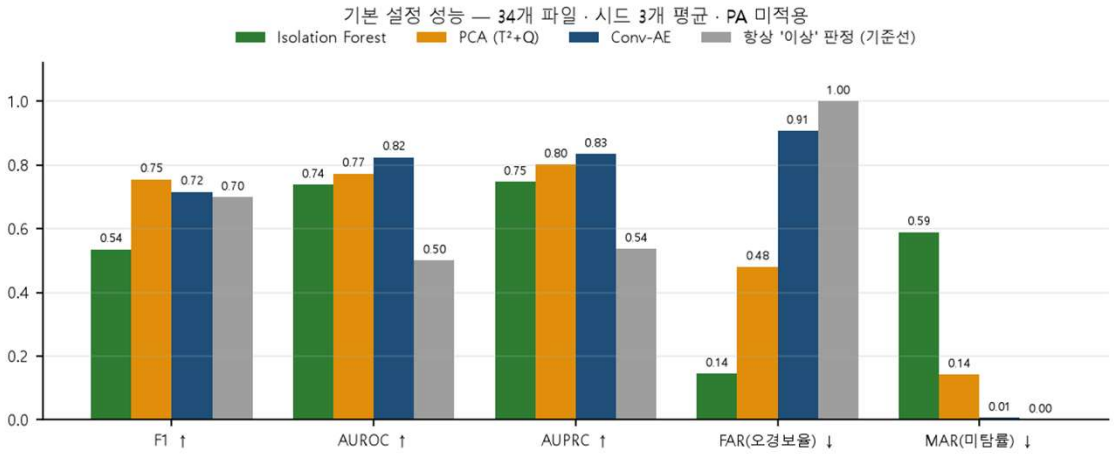
- 임계값 UCL = 학습 구간 점수의 99% 분위수 → 평가 점수 / UCL 〉 1 이면 이상
- 강의 p.14: 임계값이 정상 경계를 넓힐지(일반화: 오경보 ↓ 미탐 ↑) 좁힐지(구체화: 미탐 ↓ 오경보 ↑)를 결정 → 3장에서 실험

✓ 기본 성능 비교

기본 설정(라벨을 보기 전 고정)으로 34개 파일 평가 · 시드 3개 평균 · PA 미적용

기본 성능 (34개 파일)

모델	F1	AUROC	AUPRC	FAR / MAR
IForest	0.535	0.738	0.747	0.15 / 0.59
PCA T²+Q	**0.755**	0.773	0.801	0.48 / 0.14
Conv-AE	0.716	**0.825**	**0.834**	0.91 / 0.01
항상 이상	0.698	0.500	0.537	1.00 / 0.00



결과 해석

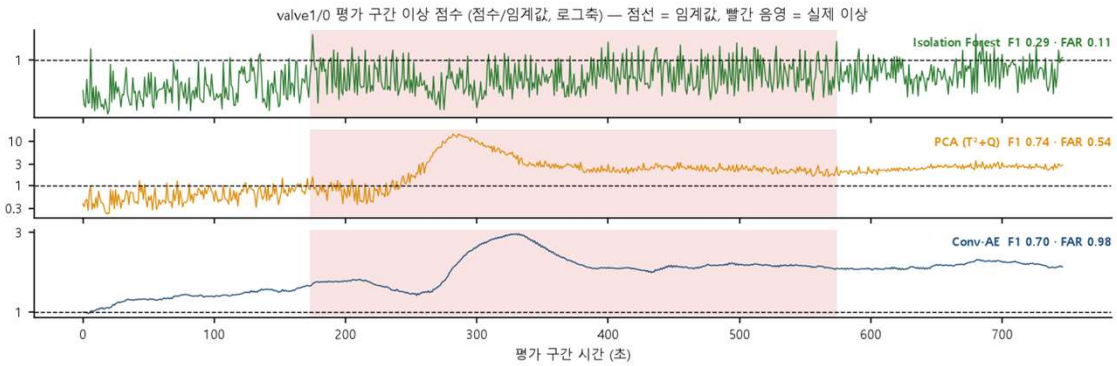
F1 PCA 0.755 〉 Conv-AE 0.716 〉 IF 0.535 — 단, '항상 이상'도 0.698이라 차이가 작음

AUROC Conv-AE 0.825 최고 — 점수 순위는 가장 좋지만 임계값이 낮아 정상의 91% 를 오경보

IF 반대로 임계값이 높아 오경보 15% 대신 이상의 59% 를 놓침

안정성 시드 간 F1 표준편차 0.006 이하 → 순위는 안정적

→ 병목 모델보다 판정 규칙(임계값) — 3장에서 개선



✓ 평가지표 선정 — 표준 평가 체계 적용

임계값 의존 지표와 독립 지표를 함께 보고, Point Adjustment 는 With / Without 을 나란히 기록

1 F1 · Precision · Recall 임계값 의존 · 주 지표

- 오경보(FP)와 미탐(FN)의 균형 — 강의 ①
- 주 지표 = 점 단위 F1 (PA 미적용), SKAB 리더보드와 같은 방식

2 FAR · MAR 임계값 의존 · 현장 지표

- FAR = 정상 중 오경보 비율, MAR = 이상 중 미탐 비율
- 운영 비용과 직결 · SKAB 리더보드 공식 지표

3 AUROC 임계값 독립 — 강의 ③

- 점수 순위의 변별력 (0.5 = 무작위)
- '모델 개선'과 '임계값 개선'을 구분하는 기준

4 AUPRC 임계값 독립 — 강의 ②

- 이상(소수 클래스) 탐지에 초점
- 기준값 = 이상 비율 0.537 (무작위 점수)

[Point Adjustment(PA) 적용 시 무결성 주의 — 강의 p.30]

- PA 는 이상 구간에서 한 점만 맞혀도 구간 전체를 정답 처리 → F1 과대평가(Overestimation)
- SKAB 는 파일마다 이상 구간 1개 · 평균 385초 → PA 의 부풀림이 특히 큼
- **본 과제: 모든 결과에 With PA / Without PA 병기, 판정은 Without PA · '항상 이상'·'무작위 경보' 기준선과 대조 (슬라이드 14)**

✓ 성능 개선 실험 설계

한 번에 한 요인만 바꾸는 4개 실험 + 조합 탐색 · 설정 선택과 효과 판정을 서로 다른 파일로 분리

실험	바꾼 요인	후보값	가설
E1 학습 데이터	학습 구간 · 데이터 출처	파일 400행(기본) · 340행 학습+60행 임계값 보정 · anomaly-free 전역 · 전역+파일별 정규화	학습에 안 쓴 구간으로 임계값을 잡으면 과적합이 줄고, 정상 데이터가 많으면 유리할 것
E2 모델 구조	용량 · 윈도우	IF 트리 50/200/500 · PCA 분산 80~99% · AE 윈도우 20/40/60/120초	구조는 점수 품질(AUROC)을 바꿀 것
E3 점수 평활	이동평균 길이	1(기본) · 5 · 15 · 30 · 60초 (과거 값만 사용)	수백 초 집단 이상에서는 평활이 잡음 경보를 줄일 것
E4 임계값	분위수 q × 배수 k	q 0.95 · 0.99 · 0.995 · 0.999 × k 1, 4/3	경계를 넓히면 오경보↓ 미탐↑ (강의 p.14)

평가 프로토콜

dev — valve1 16개 파일
설정 후보 평가에 라벨 사용

↓

설정 선택
dev F1 최대 · 조합 240~280개 후보

↓

holdout — valve2 4 + other 14
선택에 쓰지 않은 18개 파일로 1회 평가

라벨 사용 범위

- 학습 · 임계값: 사용 안 함
- 설정 선택: dev 라벨만
- 효과 보고: holdout 만

→ 선택에 쓴 데이터로 효과를 주장하지 않음

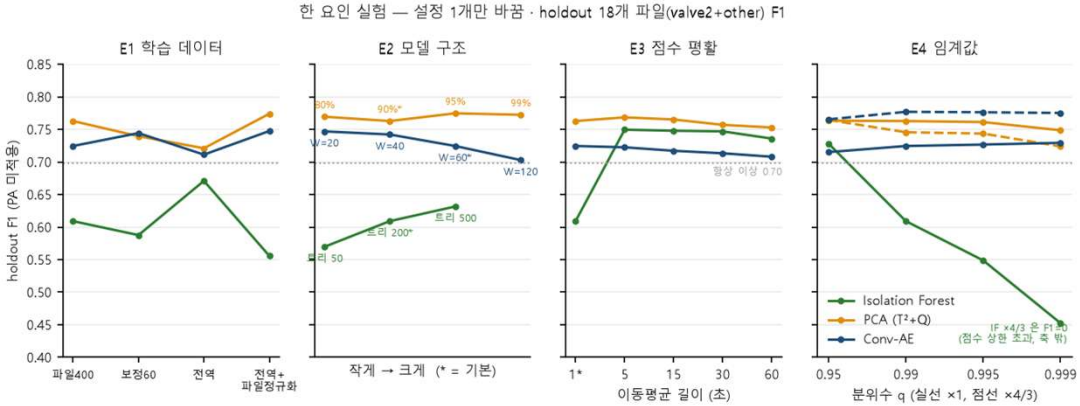
✓ 실험 결과 — 요인별 효과

holdout F1 · 각 요인에서 dev 가 가장 좋았던 값을 holdout 에 적용 (아래 = 기본 대비 변화 · 선택된 값)

holdout F1 기본: IF 0.609 · PCA 0.763 · AE 0.724

모델	학습 데이터	모델 구조	점수 평활	임계값
IForest	0.671 +0.06 · 전역†	0.632 +0.02 · 트리 500	**0.747** +0.14 · 30초	0.728 +0.12 · q0.95
PCA	**0.774** +0.01 · 정규화	0.769 +0.01 · 80%	0.768 +0.01 · 5초	0.763 ±0 · q0.95
Conv-AE	0.747 +0.02 · 정규화	0.747 +0.02 · W=20	0.724 ±0 · 기본	**0.775** +0.05 · ×4/3

초록 +0.03 이상 개선 **굵게** 모델별 최고 † 퇴화 설정 (아래 주의)



요인별 분석

점수 평활 IF 최대 개선 +0.14 · AUROC 0.75→0.78 → 점수 자체가 좋아짐

임계값 AE +0.05 (FAR 0.88→0.50) · AUROC 그대로 → 판정 규칙 개선

학습 데이터 전역 학습은 운전조건 차이로 dev 오경보 100% → 파일별 정규화를 더해야 회복

주의 † F1 만으로 고르면 IF 는 '전부 이상' 설정이 뽑힘 → FAR·AUROC 를 함께 확인

요인별 결론

- 모델 구조(E2) 영향은 ±0.02 로 작음 — 강의 p.17 처럼 성능은 모델보다 데이터 특성에 좌우
- 큰 개선은 판정 규칙(E3 평활 · E4 임계값)에서 나옴
- E4: q 를 올리면 IF 는 F1 급락(미탐↑), AE 는 ×4/3 에서 상승(오경보↓) — 기본 위치가 경계의 반대편에 있었기 때문 (강의 p.14)
- IF ×4/3 은 F1=0: IF 점수 상한(≈0.8)을 임계값이 넘어 아무것도 탐지 못함 → 임계값 배수는 점수 척도에 맞춰야 함

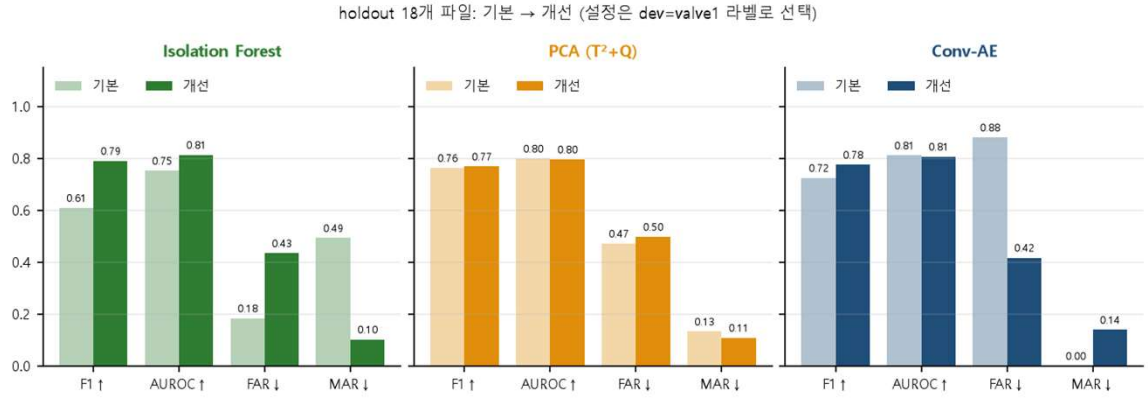
3. 성능 개선 및 최적화

✓ 최적 조합 및 개선 효과 검증

4요인 조합(IF 240 · PCA/AE 280개 후보)을 dev F1 로 선택 → holdout 18개 파일에서 1회 평가

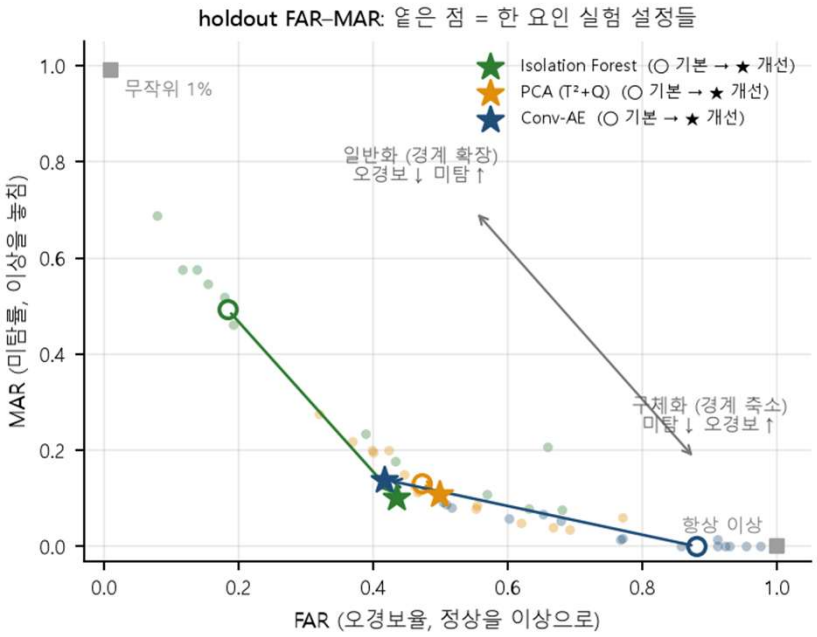
dev 에서 선택된 최종 설정

모델	학습 데이터	구조	평활	임계값	holdout F1
IForest	전역+파일 정규화	트리 200	30초	q 0.999	**0.609 → 0.790**
PCA	파일 400행	분산 80%	30초	q 0.999 ×4/3	0.763 → 0.768
Conv-AE	340+60행 보정	W=60	없음	q 0.999 ×4/3	**0.724 → 0.775**



검증

- AUROC: IF +0.06, PCA·AE 변화 없음(±0.005) → IF 는 점수 개선, PCA·AE 는 임계값 조정 효과
- 선택에 쓰지 않은 holdout 에서도 dev 와 같은 방향으로 개선 → 과적합된 선택이 아님



트레이드오프 해석 (강의 p.14)

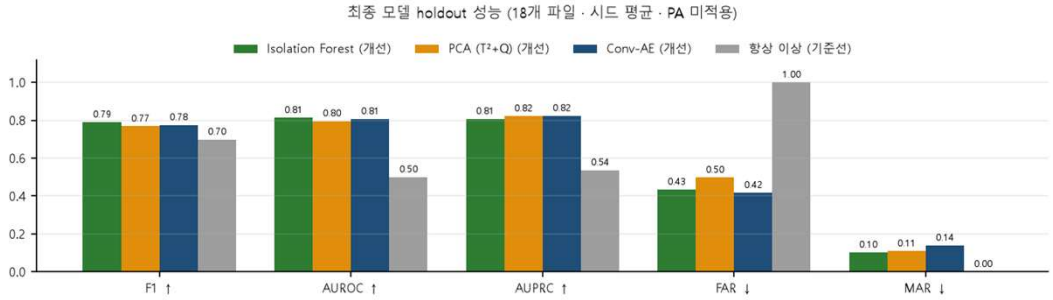
- 기본 설정은 양 극단: IF = 일반화 쪽(미탐 49%), AE = 구체화 쪽(오경보 88%)
- 최적 조합은 세 모델 모두 FAR 0.42~0.50 · MAR 0.10~0.14 의 균형점으로 수렴

✓ 모델별 성능 평가 및 결과 분석

holdout 18개 파일 · 최종 설정 · 시드 3개 평균 — 세 모델 모두 기준선보다 우수, 모델 간 차이는 작음

holdout 성능 (PA 미적용 · F1(PA) 는 참고)

모델	F1	F1(PA)	AUROC	AUPRC	FAR/MAR
IForest	**0.790**	0.836	**0.813**	0.807	0.43/0.10
PCA T²+Q	0.768	0.803	0.796	0.822	0.50/0.11
Conv-AE	0.775	0.834	0.807	**0.823**	0.42/0.14
항상 이상	0.698	0.698	0.500	0.537	1.00/0.00



모델별 특성 (장단점)

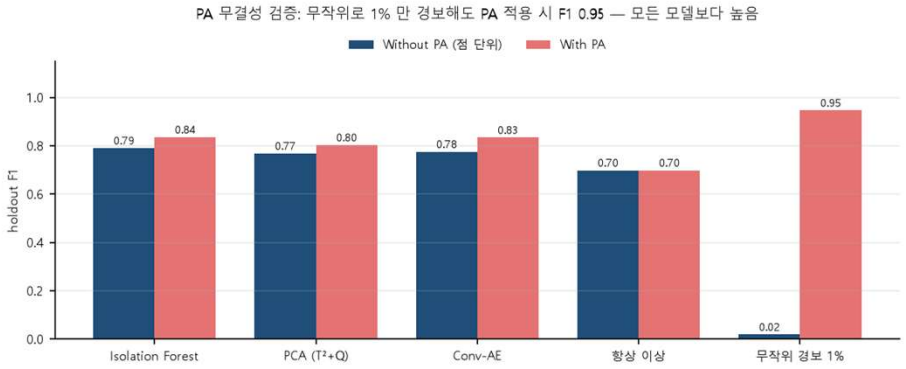
모델	장점	단점
IForest	학습 빠름 · 평활 후 F1 최고(0.79) · AUROC 0.75→0.81	점 단위 점수가 튀어 평활 없으면 이상 59% 를 놓침
PCA T²+Q	모든 실험에서 ±0.01 로 안정 · 결정적 · 해석 쉬움	개선 여지 작음 · FAR 0.50 으로 오경보 최다
Conv-AE	기본 AUROC 0.825 최고 · 시간 패턴(윈도우) 반영	임계값에 민감(기본 FAR 0.91) · 학습 비용 최대

결과 해석

- F1 0.77~0.79 · AUROC 0.80~0.81 로 근접 — 원리가 다른 세 모델이 판정 규칙 최적화 후 비슷한 수준에 도달
- 세 모델 모두 '항상 이상'(F1 0.70 · AUROC 0.50)보다 확실히 우수 → 실제로 이상을 구분함
- 강의 p.17 처럼 이상 패턴이 뚜렷한 파일은 잘 잡고, 미묘한 파일은 놓침 (슬라이드 15)
- 참고: SKAB 리더보드 Conv-AE F1 0.78 과 비슷한 수준 (평가 파일 범위가 달라 직접 비교는 참고용)

✓ 평가 무결성 검증

결과가 부풀려지지 않았는지 5가지로 점검 — PA · 자명한 기준선 · 라벨 사용 · 재현성 · 학습 구간 오염



With PA vs Without PA (holdout F1)

- **무작위 1% 경보:** Without 0.02 → With PA 0.95

  이상 구간이 길어(평균 385초) 무작위로 한 점만 맞아도 구간 전체가 정답 처리됨
- **모델:** IF 0.79→0.84 · PCA 0.77→0.80 · AE 0.78→0.83

  PA 를 쓰면 무작위가 모든 모델보다 높아져 순위가 뒤집힘
- **결론:** PA 결과는 참고로만 병기, 모든 판정은 Without PA

✓ ① PA 과대평가

무작위 1% 경보도 With PA F1 0.95 → 판정은 Without PA

✓ ② 자명한 기준선

'항상 이상' F1 0.698 · AUROC 0.50 → 세 모델 모두 두 지표에서 상회

✓ ③ 라벨 사용

학습·임계값 미사용 (코드에서 라벨 컬럼 입력 차단 assert) · 설정 선택 = dev · 보고 = holdout

✓ ④ 재현성

IF·AE 시드 3개 — F1 표준편차 0.01 이하

✓ ⑤ 학습 구간 오염

other/2 포함/제외 시 전체 F1 차이 0.005 이하 — 단, 그 파일은 세 모델 모두 탐지 실패

✓ 성능 개선 효과 및 한계 분석

강의 연계 p.23 이상탐지 알고리즘 이슈

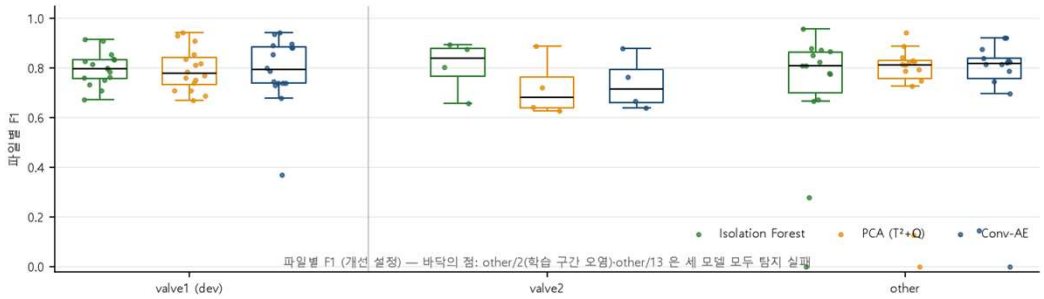
개선은 판정 규칙에서 크고 모델 구조에서는 작음 — 남은 문제는 오경보율과 일부 파일의 탐지 실패

개선 효과

IF +0.18 0.61→0.79 · 평활이 핵심 · AUROC 0.75→0.81 → 점수 자체 개선

AE +0.05 0.72→0.78 · 임계값 보정 · AUROC 그대로 → 판정 규칙 개선

PCA +0.01 0.76→0.77 · 기본이 이미 균형점 근처라 개선 여지 작음



한계

① **오경보** FAR 0.42~0.50 — 정상 시점 2개 중 1개꼴 경보, 현장 적용엔 높음

② **탐지 실패** other/2 (학습 구간 오염) · other/13 (미묘한 이상) 은 세 모델 모두 F1≈0

③ **운전조건** 정상 전용 데이터로 만든 전역 모델은 그대로 쓰면 실패 → 조건별 정규화 필요

④ **사후분석** 이상인지는 알지만 어떤 고장인지는 모름 (강의 p.23)

⑤ **지표 범위** 점 단위 지표만 사용 — 구간 지표(Affiliation F1 등)는 미적용

향후 개선 방향

- 오경보 감소: 연속 N초 이상일 때만 경보(지속 조건) · 비용 가중 임계값
- 학습 구간 오염 대응: 학습 점수가 높은 구간을 제외하고 재학습(강건 학습)
- 운전조건 적응: 조건별 정규화 · 온라인 재학습 (강의 p.6 사례)
- 원인 분석: 센서별 재구성 오차 기여도로 고장 유형 추정 (강의 p.23 사후분석)
- 평가 확장: 구간·이벤트 지표, LOF·LSTM-AE 등 다른 계열 추가

✓ 결론 및 연구적 시사점

과제의 4개 학습 목표를 모두 수행했고, 세 가지 연구적 시사점을 얻었습니다

구분	학습 목표	수행 결과
1. 데이터 분석	특성 이해 · 문제 정의	평가 구간 54% 이상 · 운전조건 차이 · 오염 파일 발견 → 비지도 신규성 탐지로 정의
2. 모델 설계	모델 선정 · 구현 · 비교	강의 3계열(모델·선형 재구성·비선형 재구성) 3종을 동일 조건 비교
3. 성능 개선	실험 · 최적화 효과 검증	지표 6종 · 4요인 실험 · dev 선택 → holdout 검증 (IF +0.18)
4. 결과 해석	특성 · 시사점 도출	PA 무결성 · 기준선 대조 · 한계 5가지와 개선 방향

한 줄 요약

정상만 학습한 3개 모델 모두 holdout F1 0.77~0.79 — 성능의 열쇠는 모델보다 판정 규칙과 정직한 평가

1 임계값이 성능을 좌우한다

같은 점수라도 판정 규칙만으로 F1 이 최대 0.18 변함 — 강의 p.14 경계 트레이드오프의 실증. 모델 구조 변경 효과(±0.02)보다 훨씬 큼

2 F1 하나로는 속는다

이상 54% 데이터에서는 '항상 이상'이 F1 0.70, PA 를 쓰면 무작위도 0.95 — 강의 p.30 의 임계값 독립 지표와 PA 병기가 필수

3 라벨 사용의 경계를 명확히

비지도라도 설정 선택에 라벨을 쓰면 별도 holdout 이 필요 · 학습 구간 오염은 곧 탐지 실패 — 정상 데이터 품질 관리가 핵심