# 어프렌티스 프로젝트

## Apprentice Project

2026-2

충북대학교 산업인공지능연구센터 채민선

충북대학교 CHUNGBUK NATIONAL UNIVERSITY

충북대학교 산업인공지능연구센터

# 어프렌티스 프로젝트

## Apprentice Project

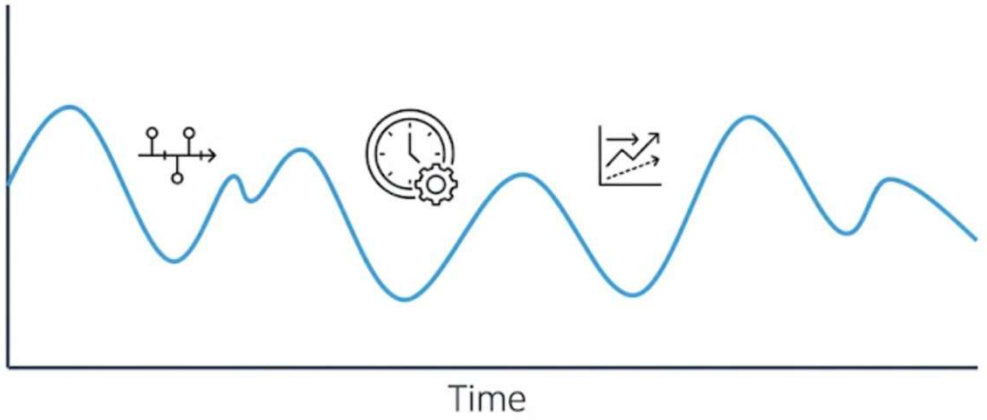
## Lecture 5 : RNN, LSTM, GRU

충북대학교 CHUNGBUK NATIONAL UNIVERSITY
충북대학교 산업인공지능연구센터

# Time Series Forecasting

❖ **시계열 데이터란?**

- 일정한 시간 간격으로 수집된 순차적 데이터 포인트의 집합



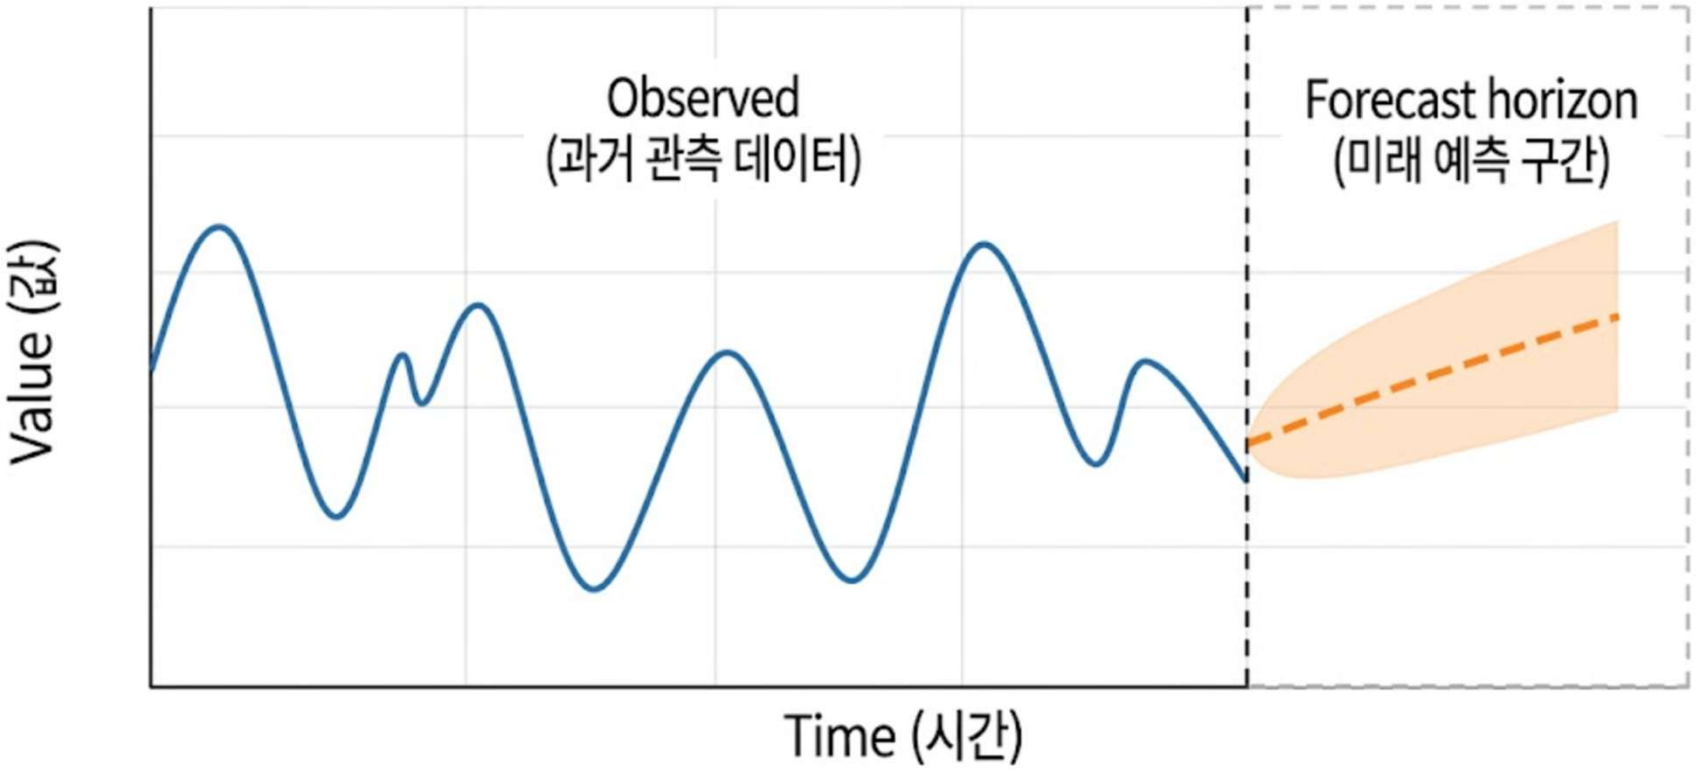

❖ **시계열 데이터의 중요한 특성은 무엇일까?**

- **시간적 순서**(Temporal order) → 데이터 포인트 간의 선후 관계가 존재
- **자기상관성**(Autocorrelation) → 현재의 값이 과거의 패턴에 의존하는 특성
- **비정상성**(Non-stationarity) → 평균, 분산, 자기상관 구조 등 통계적 특성이 시간에 따라 변하는 성질

# Time Series Forecasting

## ❖ 시계열 예측이란?

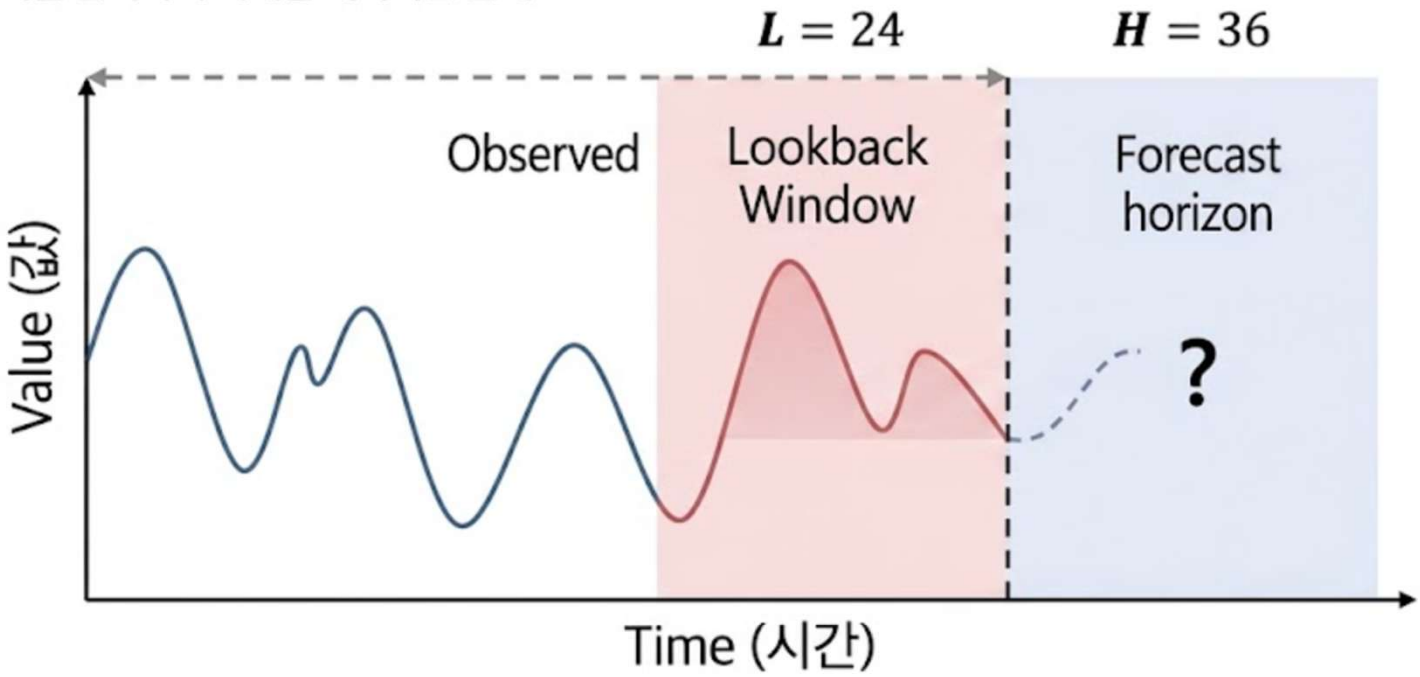
- 관측된 시계열 데이터를 분석하여 미래를 예측하는 문제



# Time Series Forecasting

❖ **시계열 예측이란?**

- 관측된 시계열 데이터를 분석하여 미래를 예측하는 문제



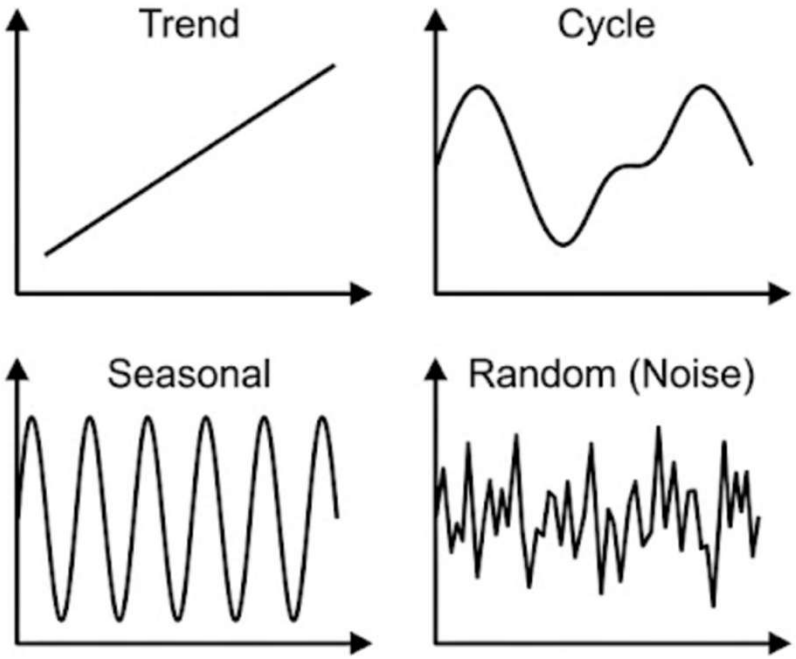

❖ $\hat{Y}_{t+1:t+H} = f_\theta(X_{t-L+1:t})$

- $L$ = lookback window
- $H$ = forecast horizon
- $t$ = 현재 시점

# 시계열데이터(Time series data)

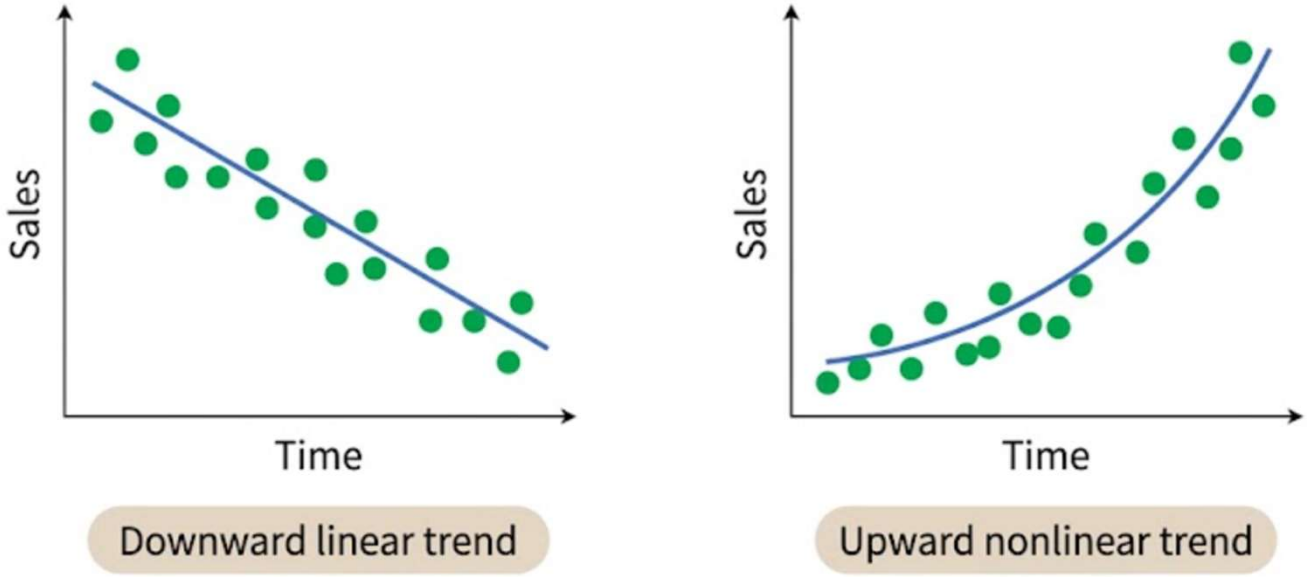
## 시계열 데이터 구성요소

- 추세변동 (Trend)
- 순환변동 (Cycle)
- 계절변동 (Seasonal variations)
- 우연변동 (Random fluctuation)



# 시계열데이터(Time series data)

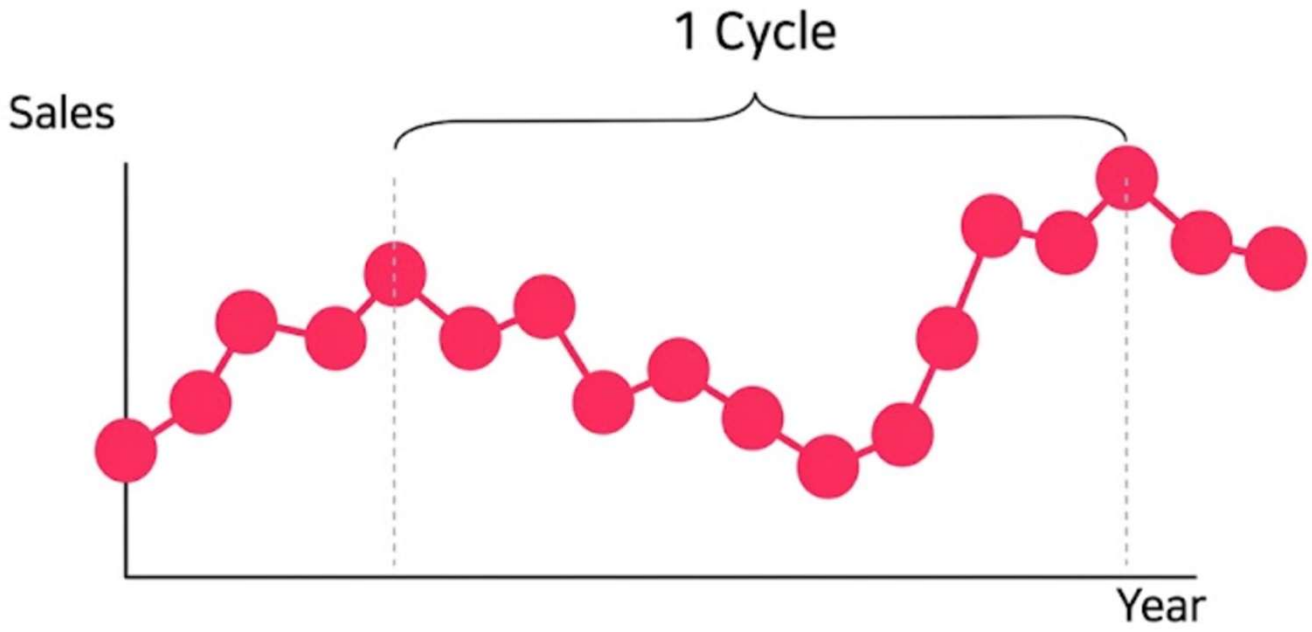
## 추세변동 (Trends)




- 시간이 경과함에 따라 관측값이 지속적으로 증가하거나 감소하는 추세를 갖는 경우의 변동. 주로 경제와 관련된 데이터에서 발생

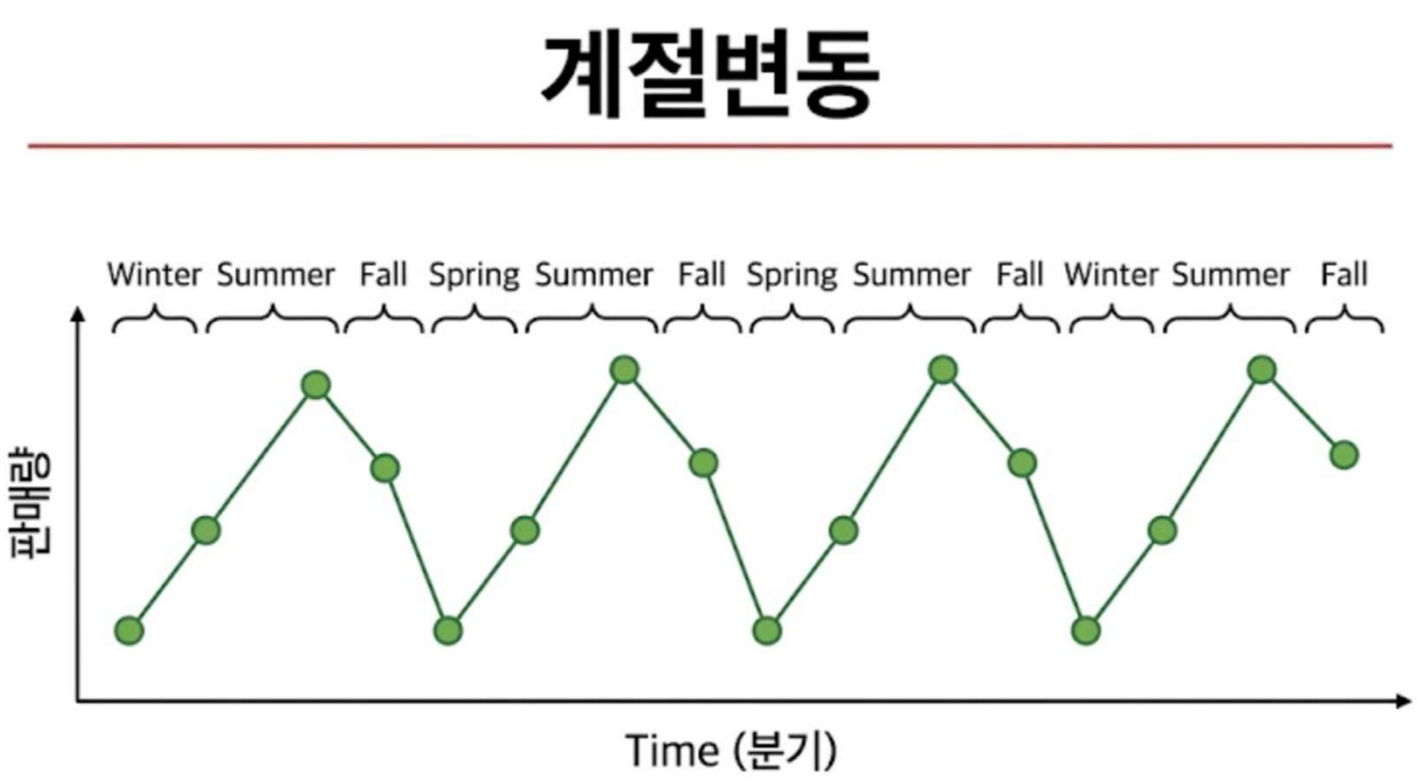
# 시계열데이터(Time series data)

## 순환, 주기변동 (Cycle)




- 주기적인 변화를 가지나 계절에 의한 것이 아니고 주기가 긴 경우의 변동

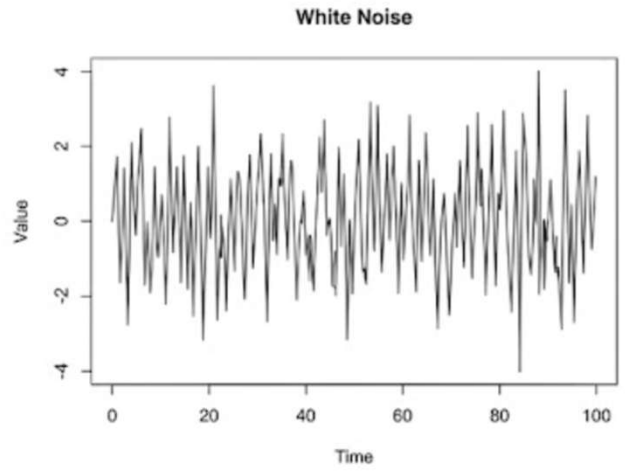
# 시계열데이터(Time series data)




- 주별, 월별, 계절별과 같이 주기적인 요인에 의한 변동

# 시계열데이터(Time series data)

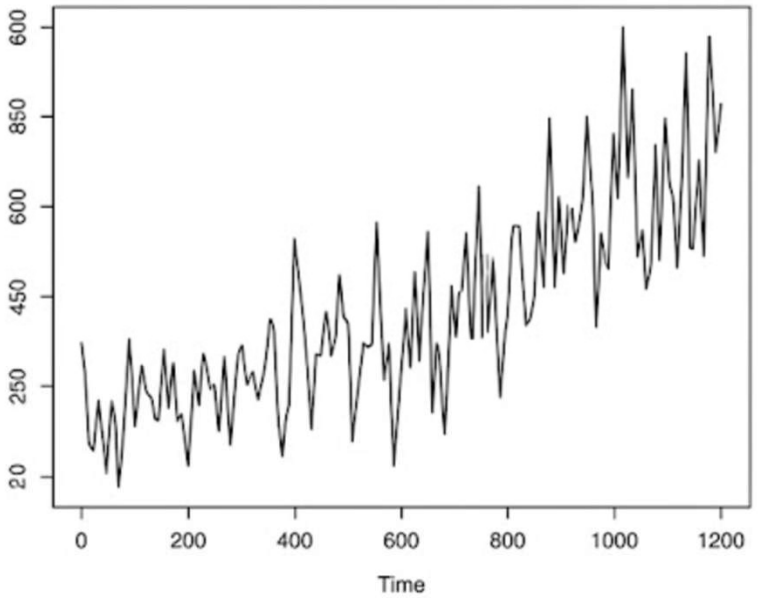
## ‘우연변동’

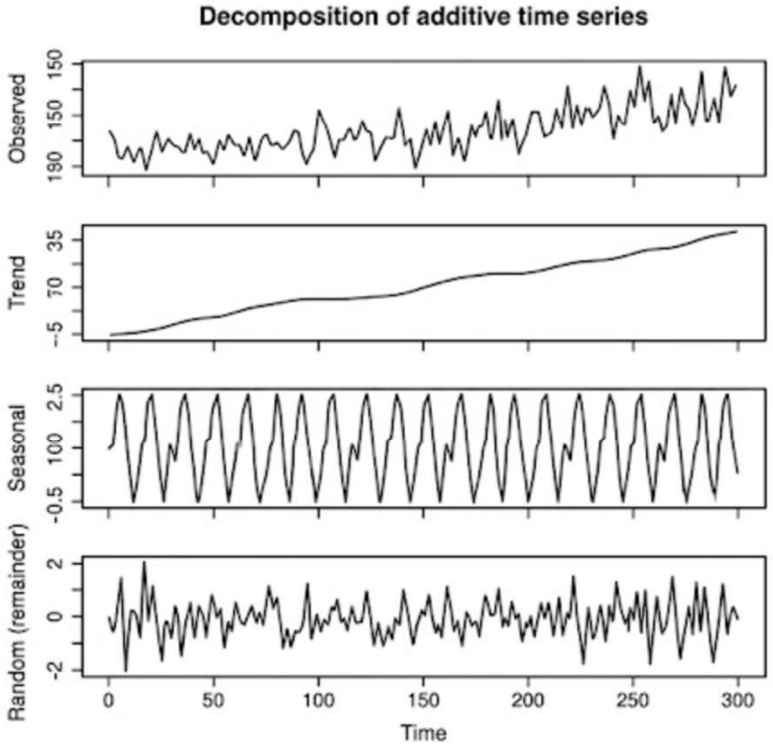



- 시간에 따른 규칙적인 움직임과는 무관하게 랜덤한 원인에 의해 나타나는 변동
- 백색잡음 (White Noise): 평균이 0이고 분산이 일정한 시계열 데이터

# 시계열데이터(Time series data)

## 시계열 데이터 구성요소



# 다변량데이터

| 차량 (Car) | 주행거리 (km) | 마력 (HP) | 배기량 (cc) | 가격 (만원) |
|---|---|---|---|---|
| Car 1 | 42,300 | 145 | 1,998 | 2,850 |
| Car 2 | 18,900 | 210 | 1,799 | 4,300 |
| Car 3 | 75,500 | 105 | 1,598 | 1,980 |
| Car 4 | 29,800 | 260 | 2,987 | 6,100 |
| Car 5 | 51,200 | 180 | 2,199 | 3,420 |

# 시계열데이터(Time series data)

- ❖ 시간의 흐름에 따라 관측되어 시간의 영향을 받게 되는 데이터
- ❖ 현재 상태가 과거의 상태에 영향을 받음

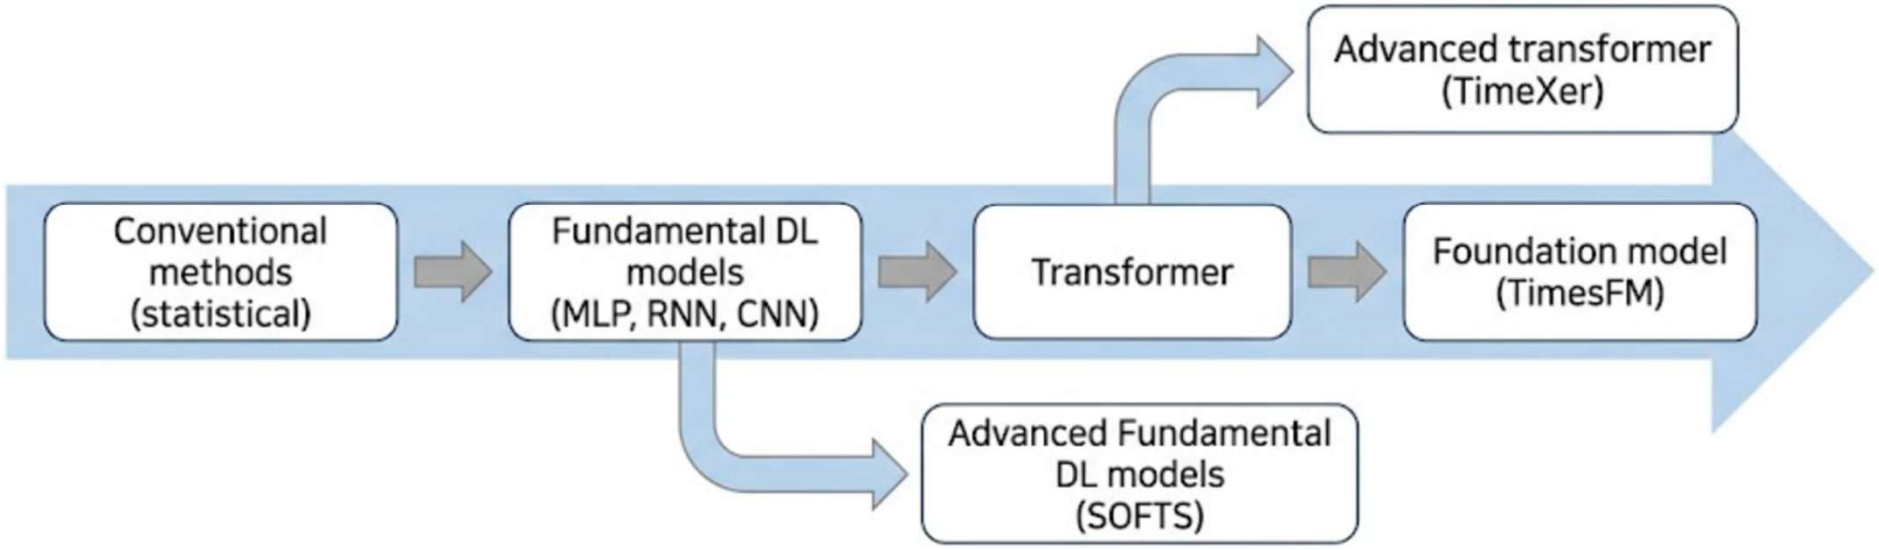
| 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|
| 12:00 | 0 | 98.9 | 3.9 | 0.19 | 021 | 정상 |
| 13:00 | 0 | 98.9 | 3.9 | 021 | 023 | 정상 |
| 14:00 | 03 | 74.5 | 6.7 | 023 | 024 | 불량 |
| 15:00 | 6.8 | 98.9 | 79 | 021 | 022 | 불량 |
| 16:00 | -09 | 78.3 | 6.6 | 021 | 023 | 정상 |
| 17:00 | -1 | 79.2 | 6.6 | 023 | 021 | 불량 |

**다변량 시계열 데이터**
**(Multivariate time series data)**

# Time Series Forecasting

## ❖ 시계열 예측 분야는 어떻게 발전해왔을까?

- 통계적 가정 기반 모델에서 데이터 기반 표현 학습으로 이동
- Transformer 도입 이후 복잡한 attention 중심에서 시계열 표현 방식과 채널 처리 전략 중심으로 논의
- CI의 안정성과 CD의 상호작용을 함께 활용하는 방향으로 발전
- 데이터셋별 학습에서 대규모 사전학습 기반 zero-shot forecasting으로 이동



# 시계열 데이터 분석 방법론 트렌드

## ❖ 전통 통계 기반 시계열 데이터 분석 방법론

- 이동평균법 (Moving average)
- 지수평활법 (Exponential smoothing)
- ARIMA (Autoregressive integrated moving average) 모델
- SARIMA (Seasonal ARIMA) 모델
- Binary variable model (해당 시점만 1, 나머지는 0으로 변환)
- Trigonometric model (sine과 cosine 함수의 조합으로 표현)
- Growth curve model
- Autoregressive integrated moving average exogenous (ARIMAX)
  (X변수를 이용하여 시계열 Y 예측)
- Prophet, ...

# 시계열 데이터 분석 방법론 트렌드

## ❖ 머신러닝 기반 시계열 데이터 분석 방법론

- Linear regression/Logistic regression models
- Support vector machine/regression
- Random forest
- Boosting
- Hidden Markov model (HMM)

## ❖ 인공지능 기반 시계열 데이터 분석 방법론

- Recurrent neural networks (RNN) (1986)
- LSTM (1997)
- GRU (2014)
- Seq2Seq (NIPS 2014)
- Seq2Seq with attention (ICLR 2015)
- Convolutional neural networks (CNN) for time series analysis (2016)
- Transformer (NIPS 2017)
- GPT-1(2018), BERT(2019), GPT-3(2020), GPT-3.5(2022), ChatGPT(2023)

# Time Series Forecasting

## ❖ Exponential Smoothing

- 최근 관측값에 더 큰 가중치를 두고, 과거로 갈수록 지수적으로 감소하는 가중치를 부여

$$s_t = \alpha x_t + (1 - \alpha) s_{t-1}$$

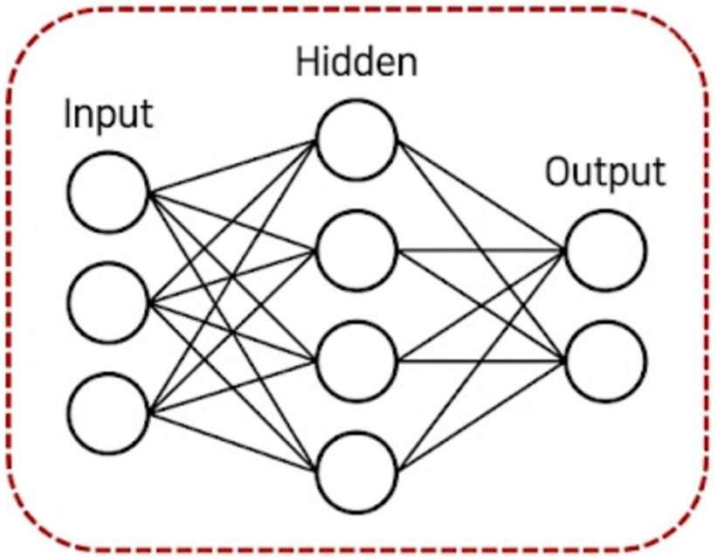
## ❖ ARIMA

- 자기상관성을 이용하면서 차분을 통해 비정상성을 완화한 뒤 예측
  - AR(AutoRegressive): 과거 값의 선형 결합
  - I(Integrated): 차분을 통해 비정상성 제거
  - MA(Moving Average): 과거 오차 항의 선형 결합

# Time Series Forecasting

## ❖ Multi-layer perceptron

- 비선형 패턴 모델링에서 강력한 성능을 보여줌




Limitation ①: weak temporal inductive bias
- 시계열의 순서성과 시간적 의존성을 반영하기 어려움

Limitation ②: fixed lookback window
- 다양한 lookback window에 유연하게 대응하기 어려움

Limitation ③: parameter/data inefficiency
- 긴 lookback이나 많은 channel을 펼쳐 넣으면 parameter 수가 증가하고, 데이터 효율성이 낮아질 수 있음

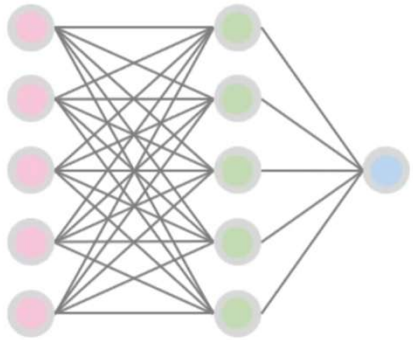
# 선형회귀모델, 로지스틱회귀모델, 뉴럴네트워크모델

❖ **선형회귀 모델**

$$f(X) = w_0 + w_1 X_1 + w_2 X_2$$

❖ **로지스틱회귀 모델**

$$f(X) = \frac{1}{1 + e^{-(w_0 + w_1 X_1 + w_2 X_2)}}$$



❖ **뉴럴네트워크 모델**

$$f(X) = \frac{1}{1 + exp\left(-\left(z_{01} + z_{11}\left(\frac{1}{1 + e^{-(w_{01} + w_{11} X_1 + w_{21} X_2)}}\right)\right) + z_{21}\left(\frac{1}{1 + e^{-(w_{02} + w_{12} X_1 + w_{22} X_2)}}\right)\right)}$$

# 뉴럴네트워크(DNN) 모델

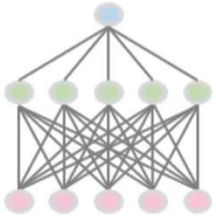
❖ 뉴럴네트워크(DNN)

| | 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|---|
| 1 | 12:00 | 0 | 98.9 | 3.9 | 0.19 | 0.21 | 정상 |

$$h_1 = f(W_{xh}x_1)$$

$$y_1 = g(W_{hy}h_1)$$

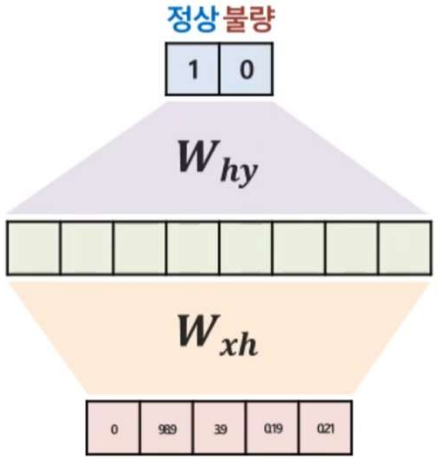
$$f(\cdot) = tanh\ ,\ g(\cdot) = softmax$$



반응 변수 $y_1$

은닉층 $h_1$

설명 변수 $x_1$




$T = 1$

$y_1$ 를 예측

더 좋은 특징 $h_1$ 를 추출

변수 $x_1$ 를 조합

# 뉴럴네트워크(DNN) 모델

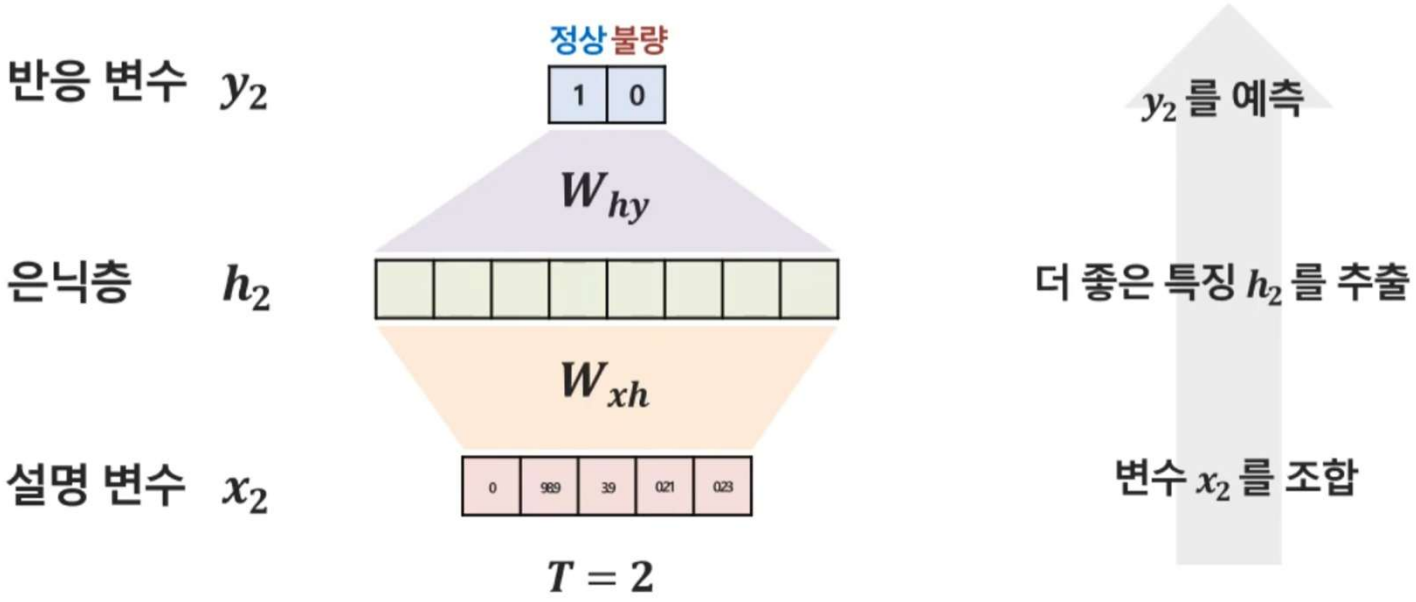
❖ 뉴럴네트워크(DNN)

| | 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|---|
| 1 | 12:00 | 0 | 98.9 | 3.9 | 0.19 | 0.21 | 정상 |
| 2 | 13:00 | 0 | 98.9 | 3.9 | 0.21 | 0.23 | 정상 |

$$h_2 = f(W_{xh}x_2)$$

$$y_2 = g(W_{hy}h_2)$$

$$f(\cdot) = tanh\ ,\ g(\cdot) = softmax$$



# 뉴럴네트워크(DNN) 모델

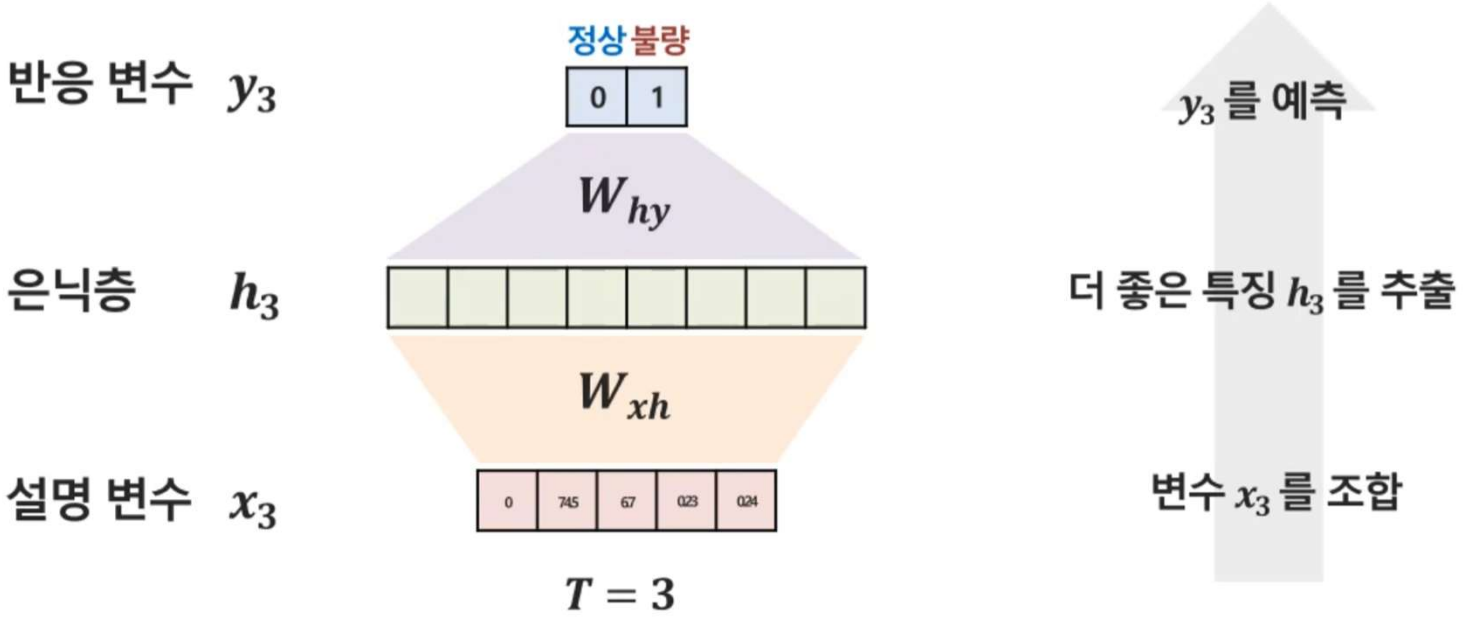
❖ 뉴럴네트워크(DNN)

| | 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|---|
| 1 | 12:00 | 0 | 98.9 | 3.9 | 0.19 | 0.21 | 정상 |
| 2 | 13:00 | 0 | 98.9 | 3.9 | 0.21 | 0.23 | 정상 |
| 3 | 14:00 | 0.3 | 74.5 | 6.7 | 0.23 | 0.24 | 불량 |

$$h_3 = f(W_{xh}x_3)$$

$$y_3 = g(W_{hy}h_3)$$

$$f(\cdot) = tanh\ ,\ g(\cdot) = softmax$$



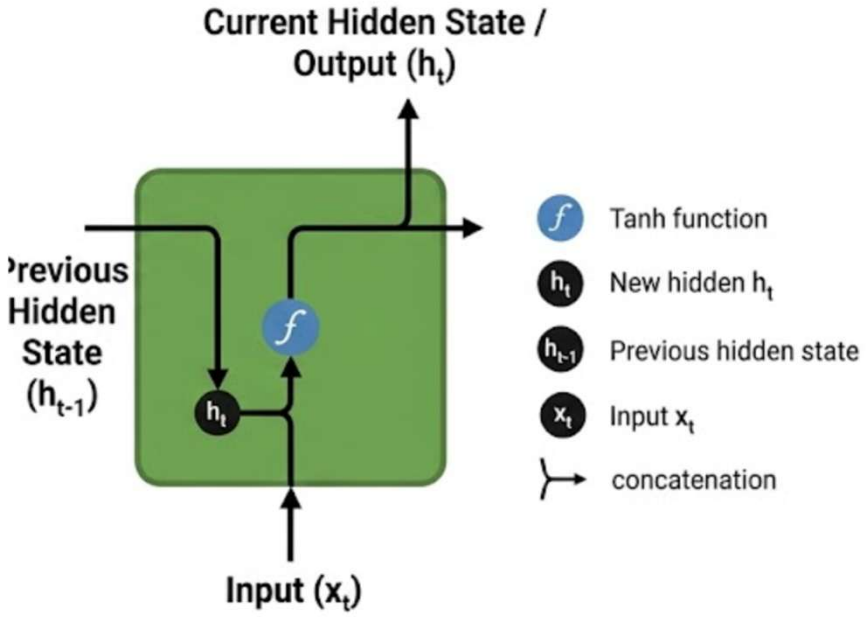
# 순환신경망 (RNN)

[RNN : Recurrent Neural Network for sequences]

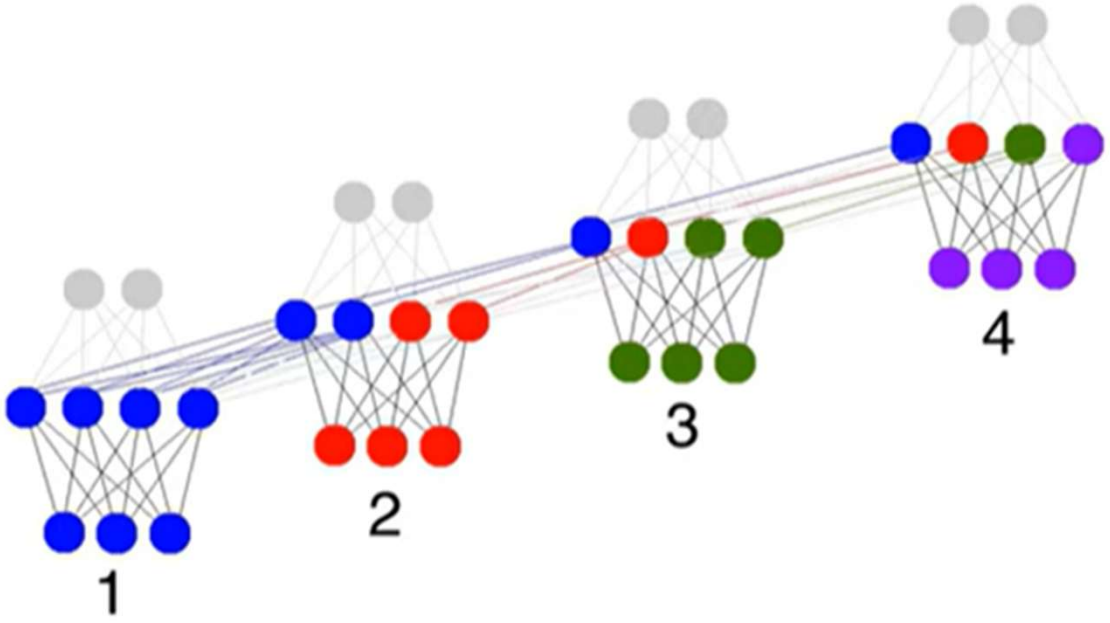
(input + prev_hidden) -> hidden -> output (O)
(input + prev_input) -> hidden -> output (X)

(input + empty_hidden) -> hidden -> output
(input + prev_hidden) -> hidden -> output
(input + prev_hidden) -> hidden -> output
(input + prev_hidden ) -> hidden -> output

(input + empty_input) -> hidden -> output
(input + prev_input) -> hidden -> output
(input + prev_input) -> hidden -> output
(input + prev_input) -> hidden -> output



# 순환신경망 (RNN) 구조




- 매 timestamp마다 (이전 정보) + (새로운 input 정보)
- 3번째 timestamp에서 녹색이 더 많은 이유 : 중요한 정보를 취사 선택하기 때문
- Hidden layer는 input과 output 사이의 barrier 역할: Output은 네트워크에 의해서 결정 (input은 어떤 것이 들어갈지를 바꿀 뿐)

Cf. timestamp 2,3,4에 아무런 input이 들어가지 않더라도 hidden layer는 매 timestamp마다 바뀜

# 순환신경망 (RNN) 필요성

## ❖ 순환신경망(RNN)

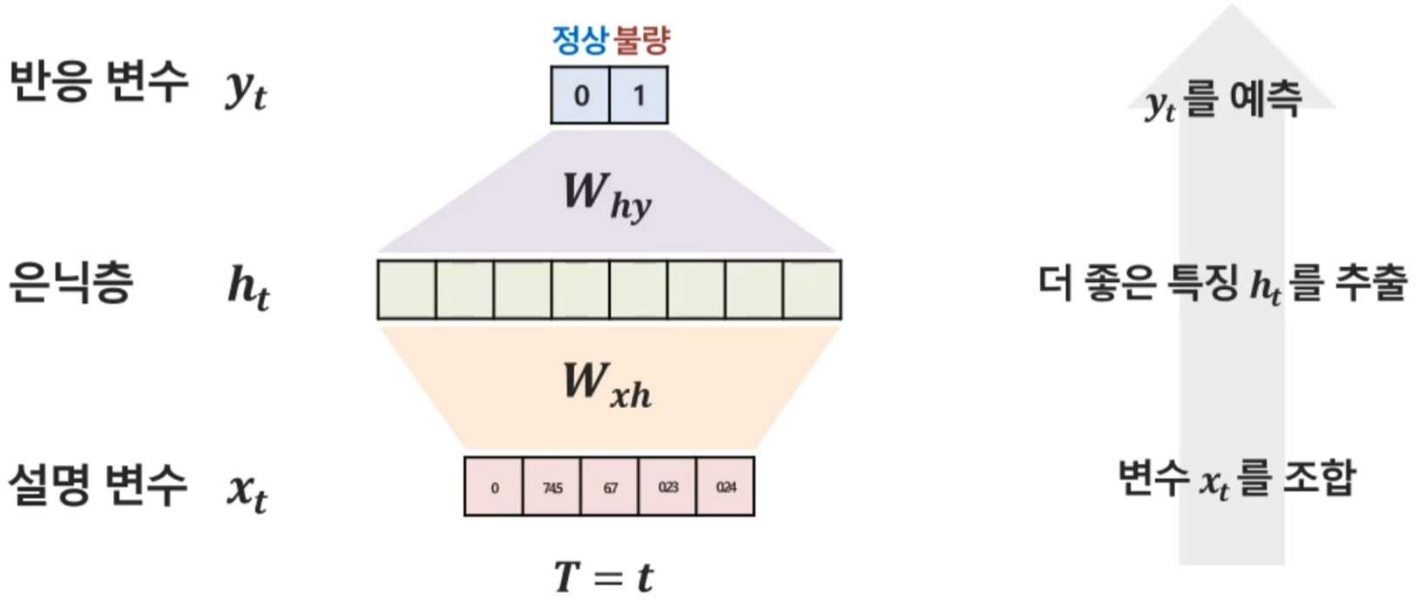
| | 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|---|
| $t-2$ | 12:00 | 0 | 98.9 | 3.9 | 0.19 | 0.21 | 정상 |
| $t-1$ | 13:00 | 0 | 98.9 | 3.9 | 0.21 | 0.23 | 정상 |
| $t$ | 14:00 | 0.3 | 74.5 | 6.7 | 0.23 | 0.24 | 불량 |

$$h_t = f(W_{xh}x_t) + \text{이전 시점 정보}$$

$$y_t = g(W_{hy}h_t)$$

$$f(\cdot) = tanh\ ,\ g(\cdot) = softmax$$

**"이전 시점 정보를 반영해서 더 나은 예측을 하자"**



# 순환신경망 구조

## ❖ 순환신경망(RNN)

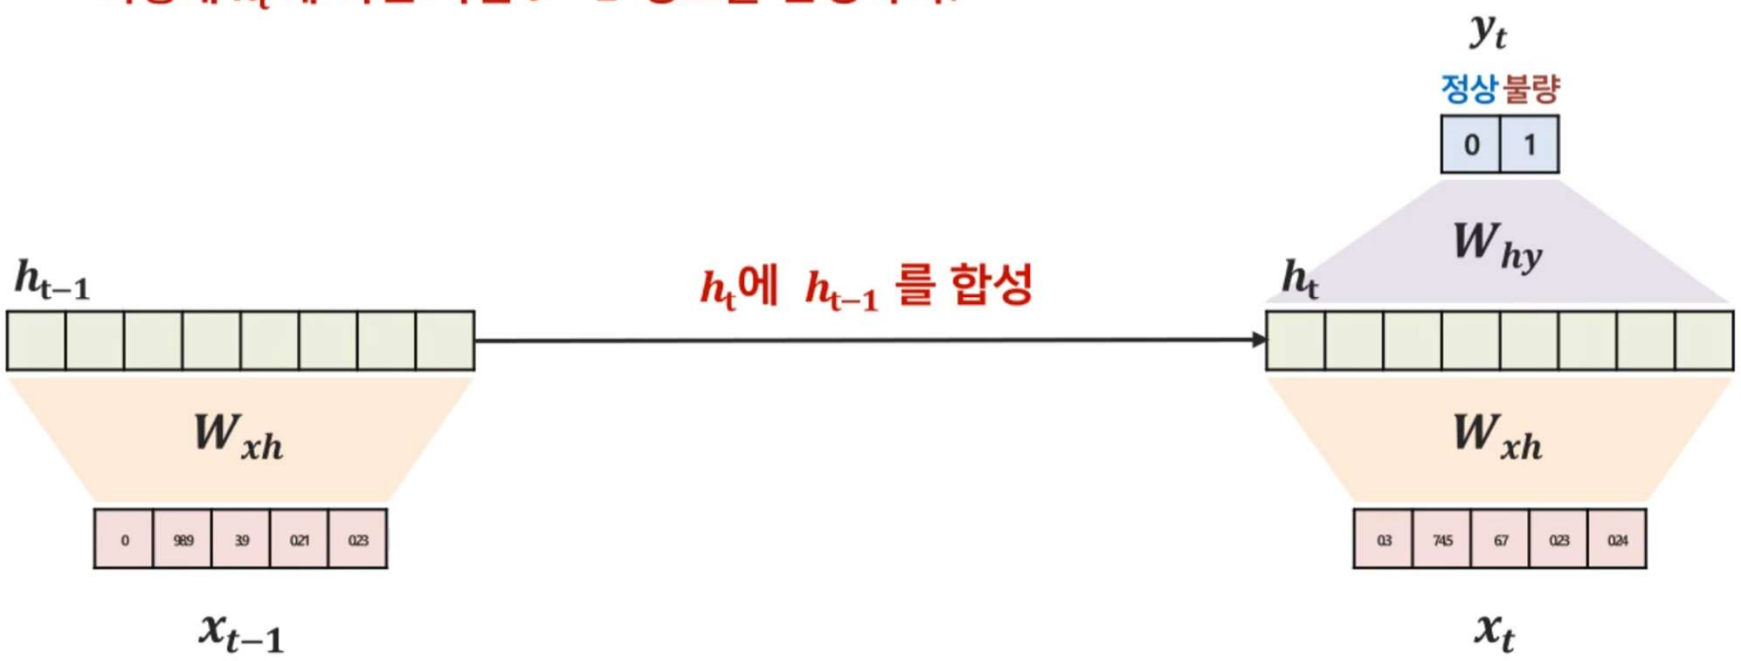
| | 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|---|
| $t-2$ | 12:00 | 0 | 98.9 | 3.9 | 0.19 | 0.21 | 정상 |
| $t-1$ | 13:00 | 0 | 98.9 | 3.9 | 0.21 | 0.23 | 정상 |
| $t$ | 14:00 | 0.3 | 74.5 | 6.7 | 0.23 | 0.24 | 불량 |

$$h_t = f(W_{xh}x_t) + t-1 \text{ 정보}$$

$$y_t = g(W_{hy}h_t)$$

$$f(\cdot) = tanh\ ,\ g(\cdot) = softmax$$

"어떻게 $h_t$에 이전 시점 $t-1$ 정보를 반영하지?"



# 순환신경망 구조

❖ 순환신경망(RNN)

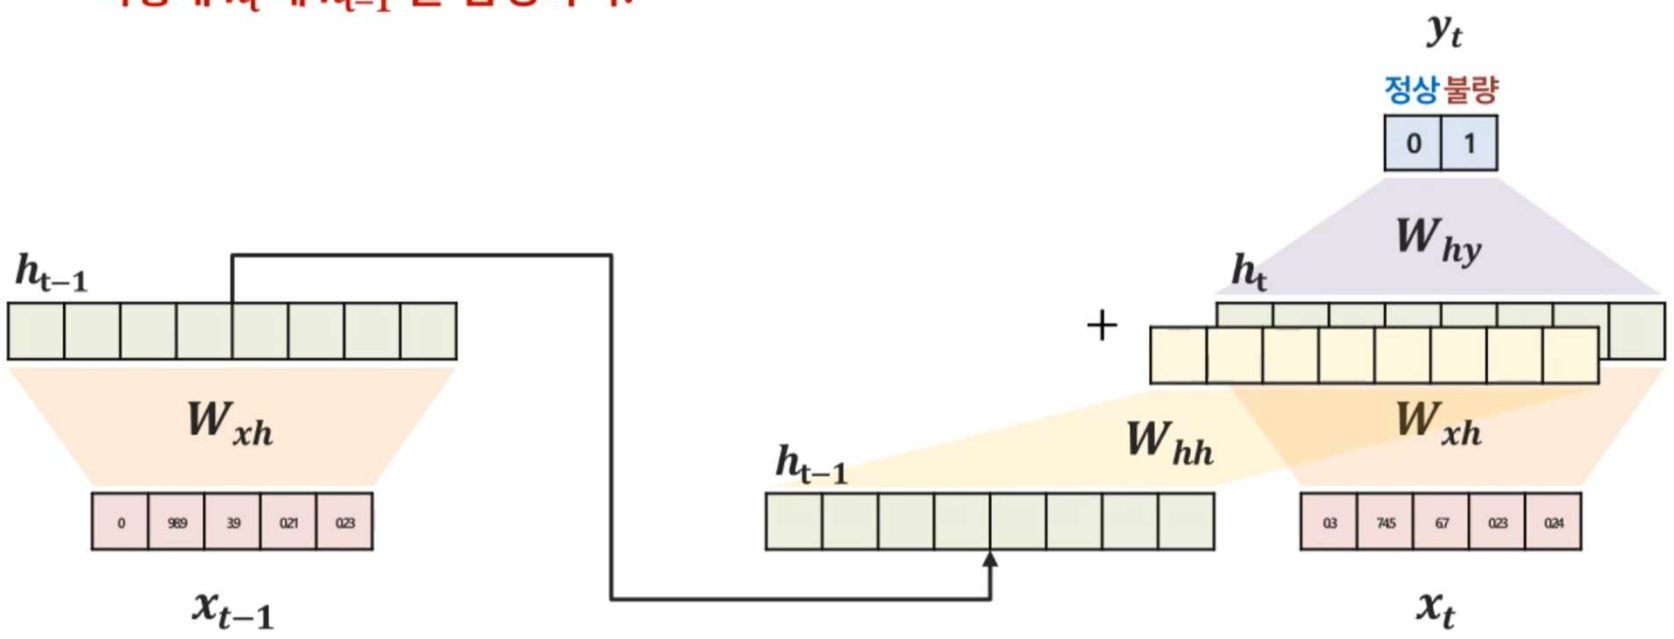
| | 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|---|
| $t-2$ | 12:00 | 0 | 98.9 | 3.9 | 0.19 | 0.21 | 정상 |
| $t-1$ | 13:00 | 0 | 98.9 | 3.9 | 0.21 | 0.23 | 정상 |
| $t$ | 14:00 | 0.3 | 74.5 | 6.7 | 0.23 | 0.24 | 불량 |

$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1})$$

$$y_t = g(W_{hy}h_t)$$

$$f(\cdot) = tanh\ ,\ g(\cdot) = softmax$$

"어떻게 $h_t$에 $h_{t-1}$ 를 합성하지?"



# 순환신경망 (RNN) 구조

❖ 순환신경망(RNN)

| | 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|---|
| $t-2$ | 12:00 | 0 | 98.9 | 3.9 | 0.19 | 0.21 | 정상 |
| $t-1$ | 13:00 | 0 | 98.9 | 3.9 | 0.21 | 0.23 | 정상 |
| $t$ | 14:00 | 0.3 | 74.5 | 6.7 | 0.23 | 0.24 | 불량 |

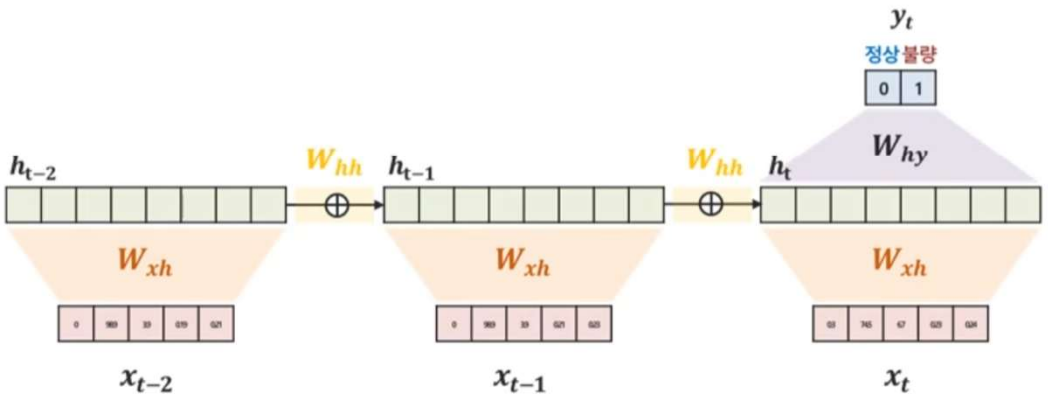
$$h_{t-1} = f(W_{xh}x_{t-1} + W_{hh}h_{t-2})$$

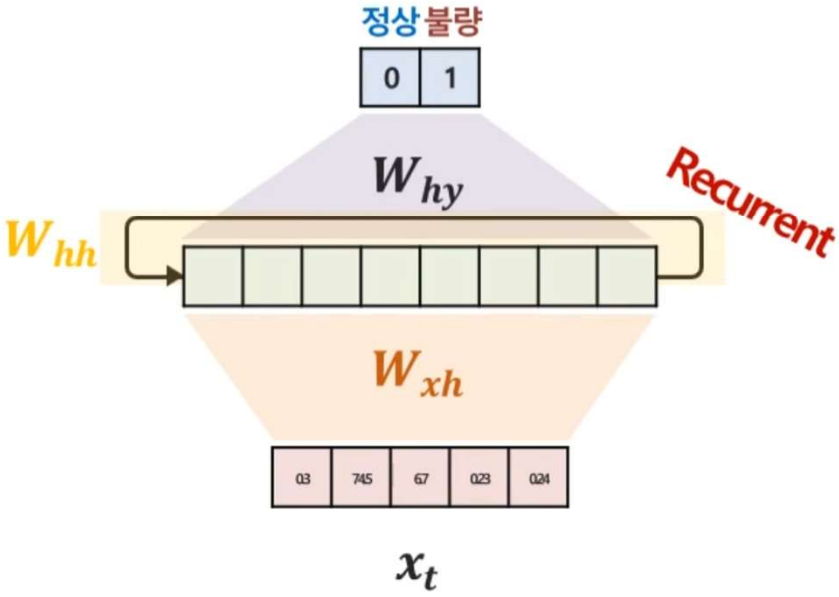
$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1})$$

$$y_t = g(W_{hy}h_t)$$

$$f(\cdot) = tanh\ ,\ g(\cdot) = softmax$$

"RNN은 이전 정보들이 순환(반복)하여 입력"

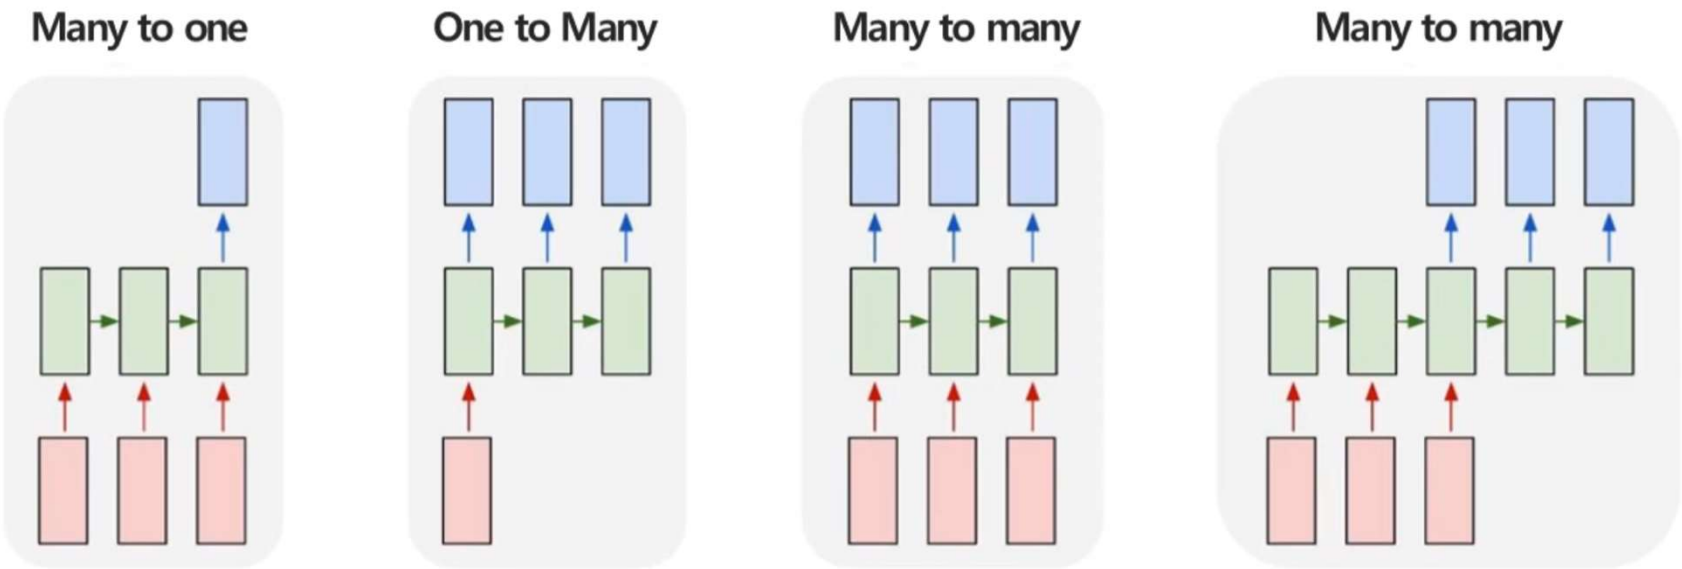


# 순환신경망 (RNN) 구조 다양성

❖ 순환 신경망 구조의 종류

- 순차적으로 입력하고, 순차적으로 예측하는 것이 가능
- 순차적인 입력의 길이, 순차적인 예측의 길이에 따라 다음과 같이 구분됨

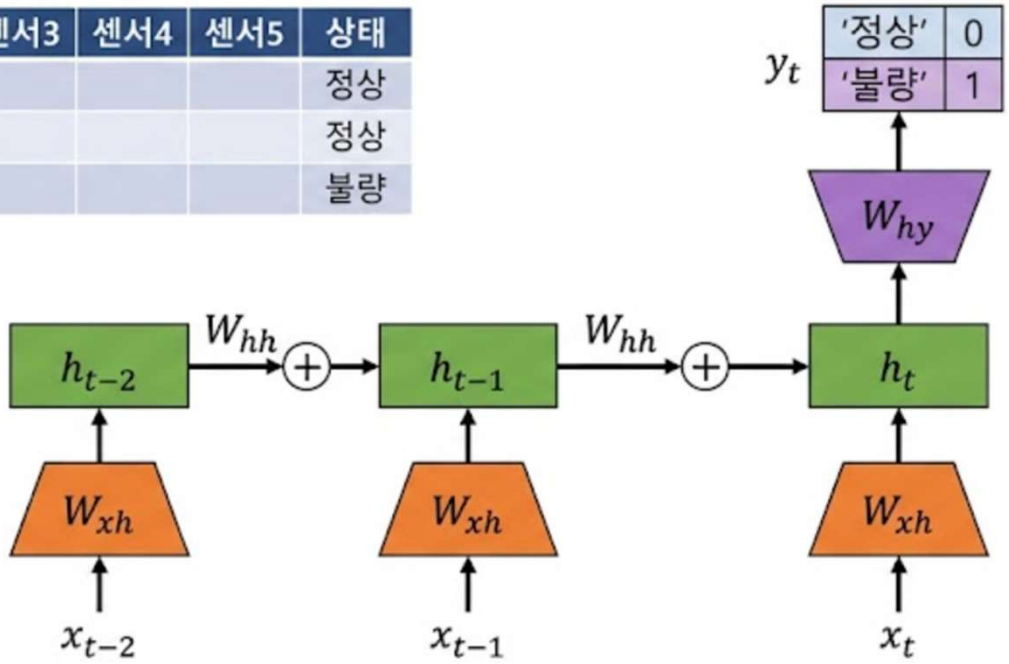


# 순환신경망 (RNN) 구조 다양성

## ❖ Many to one 구조

- 여러 시점 X로 하나의 Y를 예측하는 문제
- 예시: 여러시점에 다변량센서데이터가 주어졌을 때 특정 시점의 제품상태를 예측

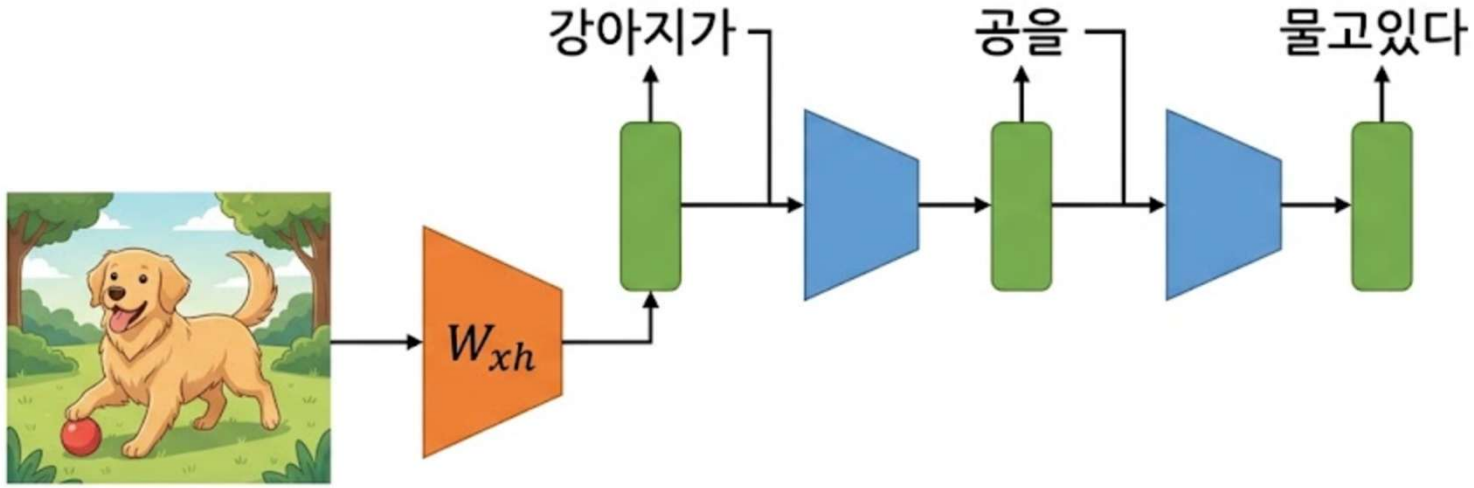
| 시간 | 센서1 | 센서2 | 센서3 | 센서4 | 센서5 | 상태 |
|---|---|---|---|---|---|---|
| t-2 | 12:00 | | | | | 정상 |
| t-1 | 13:00 | | | | | 정상 |
| t | 14:00 | | | | | 불량 |



# 순환신경망 (RNN) 구조 다양성

## ❖ One to many 구조

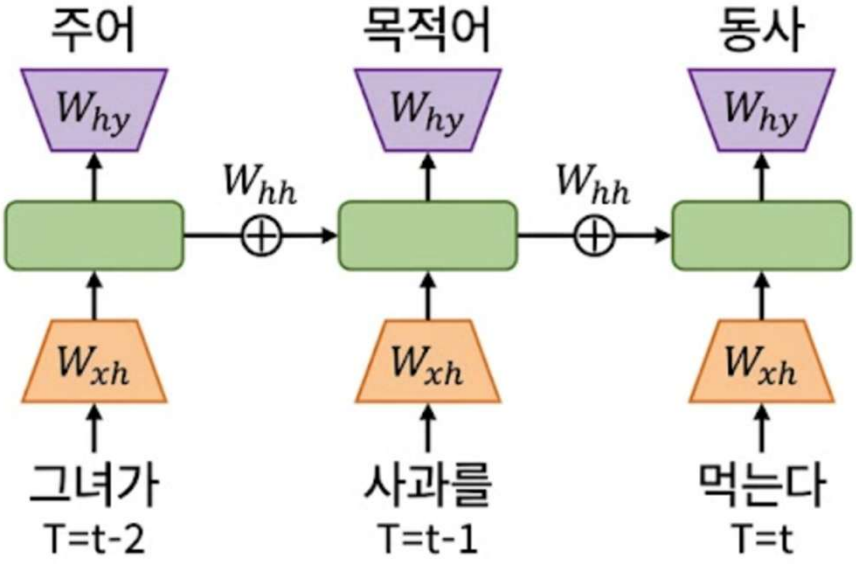
- 단일 시점 $X$로 순차적인 $Y$를 예측하는 문제
- 예시: 단일 이미지로부터 문장을 생성하는 이미지 캡셔닝(Image Captioning)



# 순환신경망 (RNN) 구조 다양성

## ❖ Many to many 구조

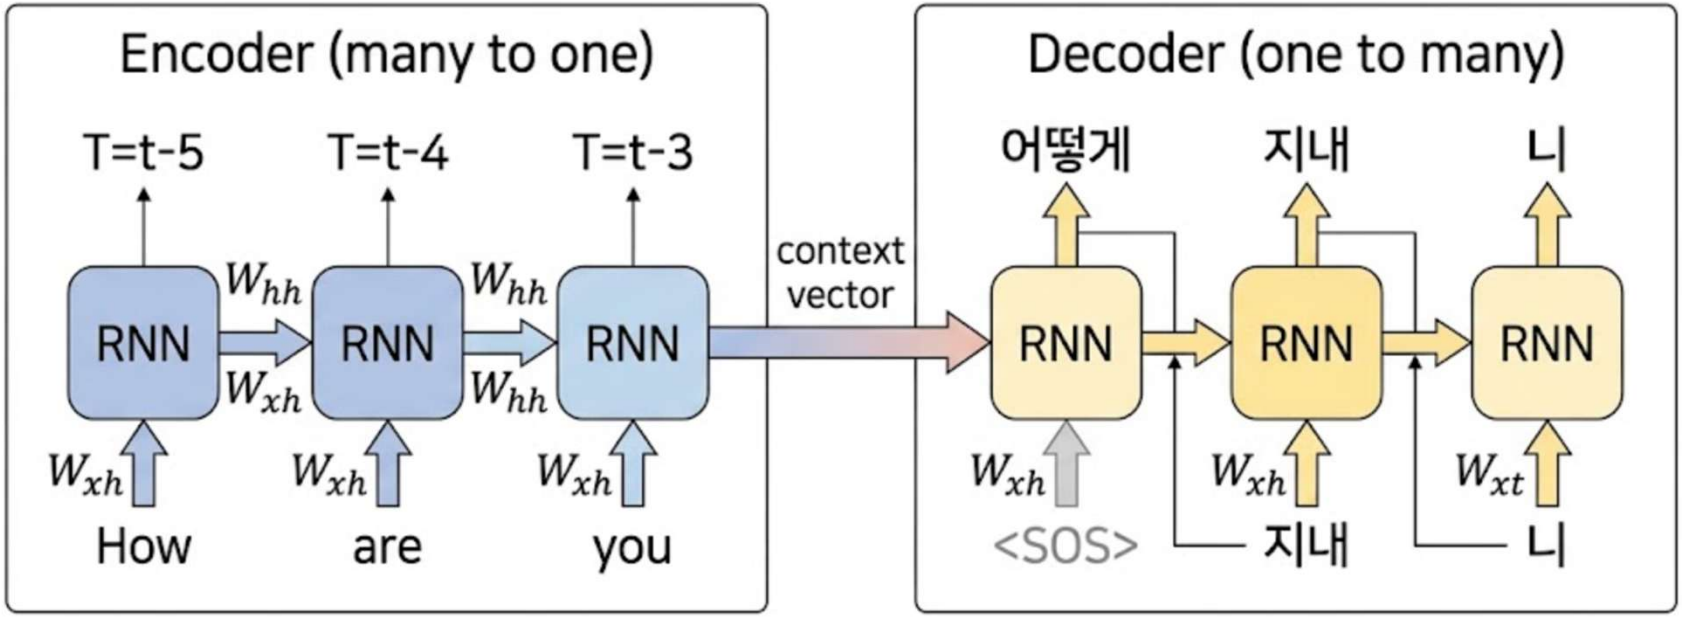
- 순차적인 X로 순차적인 Y를 예측하는 문제
- 예시: 연속된 단어가 입력될 때마다 실시간으로 각 단어의 품사를 예측 (POS Tagging)



# 순환신경망 (RNN) 구조 다양성

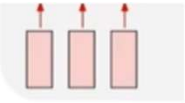
❖ Many to many 구조 (many to one + one to many)

- 순차적인 X로 순차적인 Y를 예측하는 문제
- 예시: 영어 문장이 주어졌을 때, 한글 문장으로 번역 (기계 번역)



# 순환신경망 (RNN) 구조 다양성

❖ Many to many 구조 (many to one + one to many)

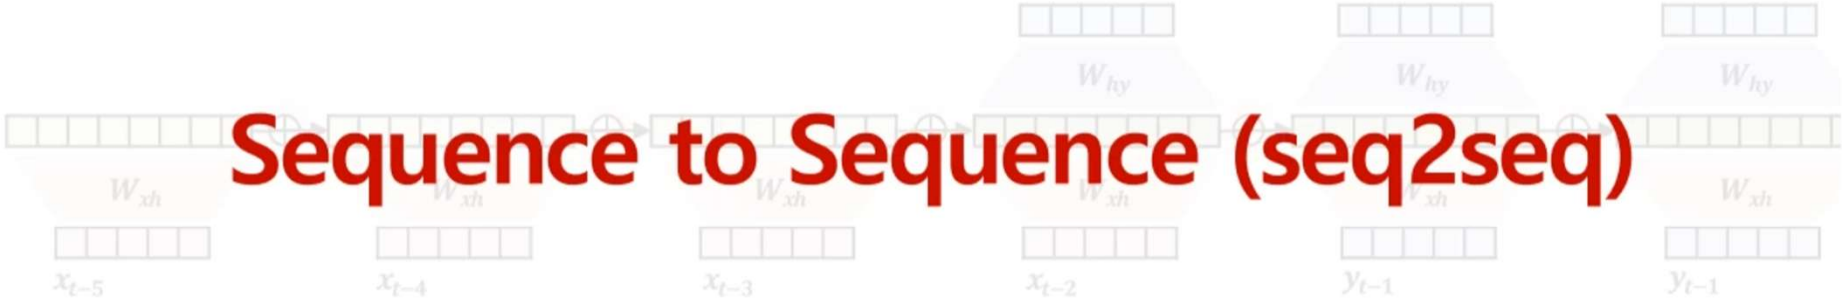


- many 순차적인 X로 many 순차적인 Y를 예측하는 문제
- 예시: 영어 문장이 주어졌을 때, 한글문장으로 번역

요약 벡터를 기반으로 출력 단어들을 예측

Decoder (Korean)

나는 너를 사랑해



**Sequence to Sequence (seq2seq)**

I Love You <EOS> 나는 너를

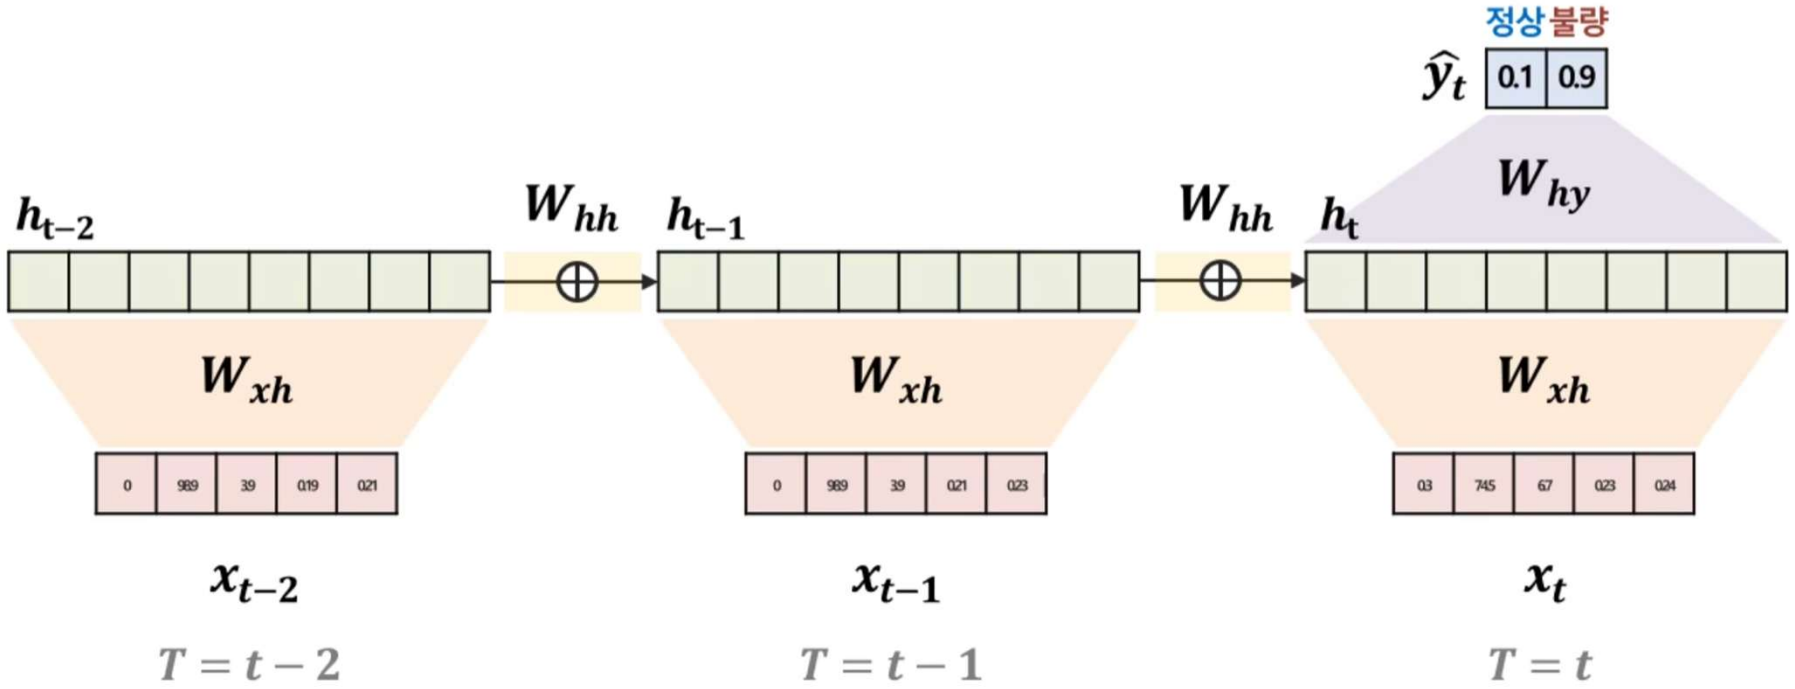
Encoder (English)

입력된 문장을 요약하여 요약벡터 생성

# 순환신경망 (RNN)

- 순환 신경망은 $t$ 시점까지의 (과거)정보를 활용하여 $y_t$ 를 예측
  - $t$ 시점 데이터 반영 → $W_{xh}$
  - $t$ 시점 이전 정보 반영 → $W_{hh}$
  - $t$ 시점의 y를 예측 → $W_{hy}$

**학습 대상(parameters): ($W_{xh}$, $W_{hh}$, $W_{hy}$)**



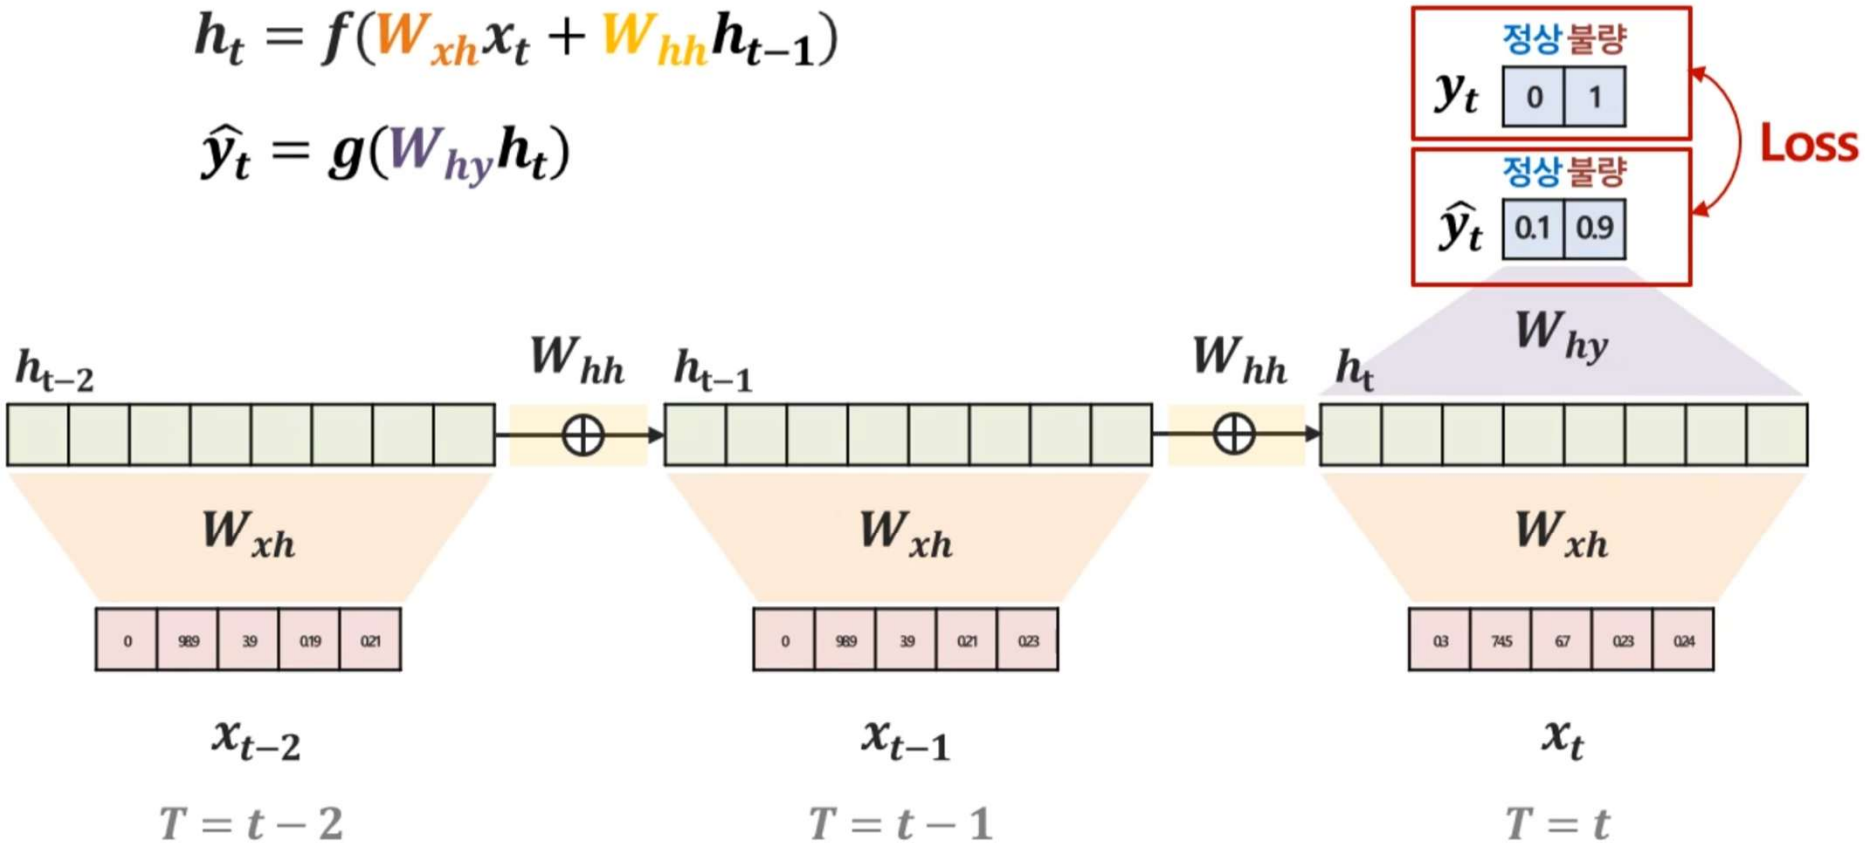
# 순환신경망 학습

❖ **학습 대상(parameters): ($W_{xh}, W_{hh}, W_{hy}$)**

- 해당 파라미터는 매 시점마다 공유하는 구조 (parameter sharing)
- 매 시점 파라미터를 구성하는 값이 같음
- 최적의 $W$: $W$를 매 시점 적용했을 때 **Loss**가 최소가 되도록

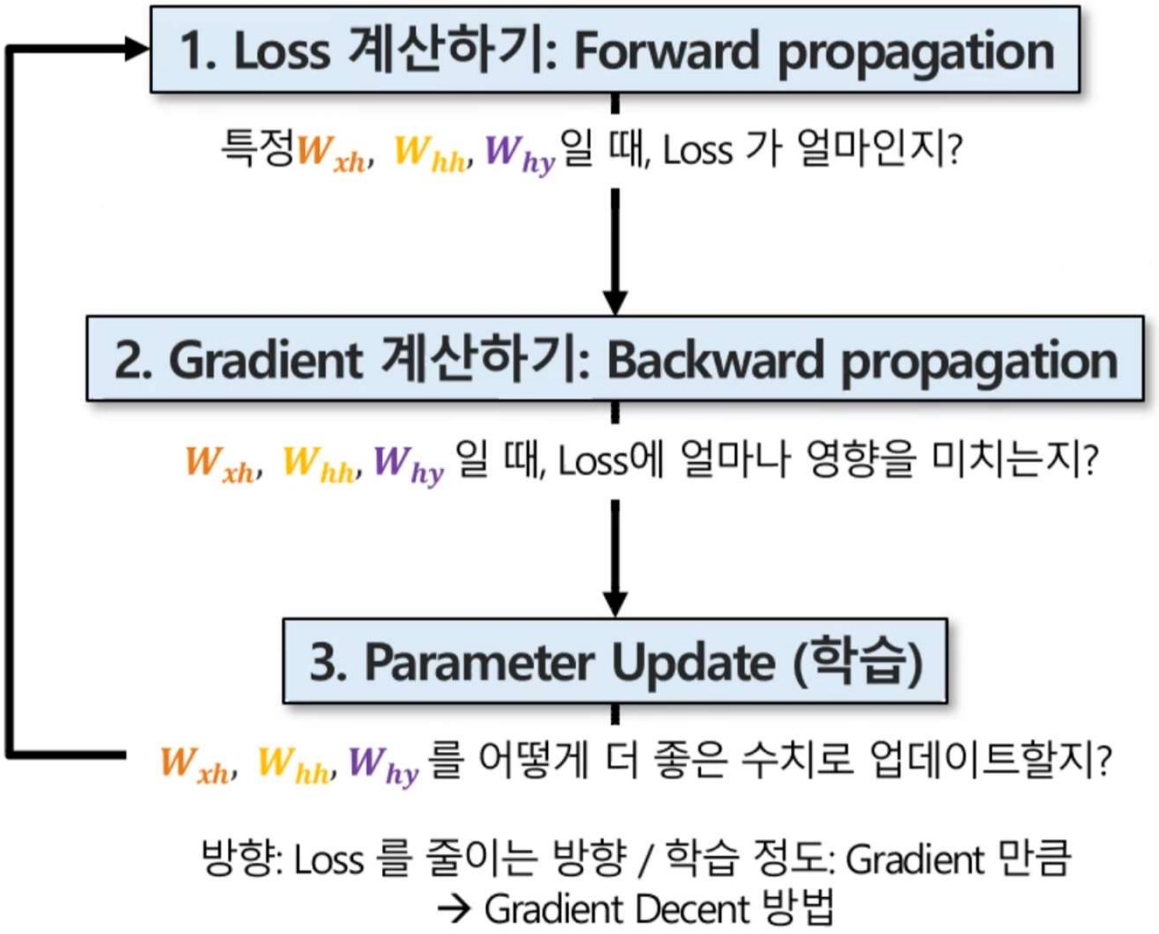
$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1})$$

$$\hat{y}_t = g(W_{hy}h_t)$$



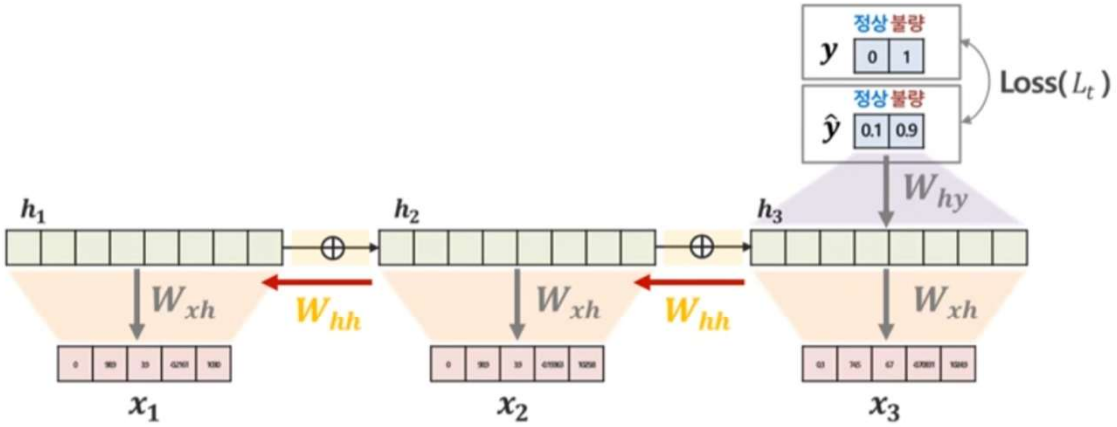
# 순환신경망 학습

❖ 학습 대상(parameters): $(W_{xh}, W_{hh}, W_{hy})$



# 순환신경망 한계점

- 장기 의존성 문제 (long-term dependency problem)
- Sequence의 길이가 길어질수록, 과거 정보 학습에 어려움이 발생
  - 원인: 기울기 소실 (vanishing gradient)
  - Gradient는 chain rule에 의해 계산되며, 이때 $h_t = tanh(W_{xh}x_t + W_{hh}h_{t-1})$



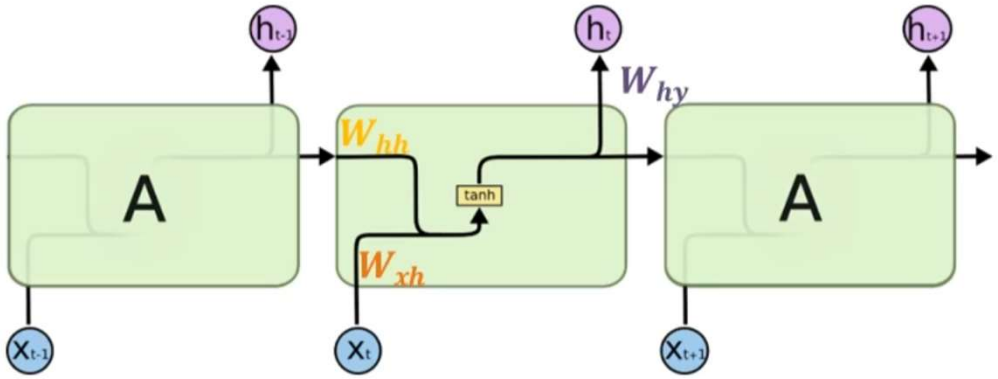

$T_3$: 시점 3 에서의 영향 $T_2$: 시점 3 으로부터 전해진 영향 고려 $T_1$: 시점 2 으로부터 전해진 영향 고려

$$\frac{\partial Loss}{\partial W_{hh}} = \boxed{\frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial \boldsymbol{h}_3} \times \frac{\partial \boldsymbol{h}_3}{\partial W_{hh}}} + \boxed{\frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial \boldsymbol{h}_3} \times \frac{\partial \boldsymbol{h}_3}{\partial \boldsymbol{h}_2} \times \frac{\partial \boldsymbol{h}_2}{\partial W_{hh}}} + \boxed{\frac{\partial Loss}{\partial \hat{y}_t} \times \frac{\partial y}{\partial \boldsymbol{h}_3} \times \frac{\partial \boldsymbol{h}_3}{\partial \boldsymbol{h}_2} \times \frac{\partial \boldsymbol{h}_2}{\partial \boldsymbol{h}_1} \times \frac{\partial \boldsymbol{h}_1}{\partial W_{hh}}}$$

# 순환신경망 개선 모델: Long Short-Term Memory (LSTM)

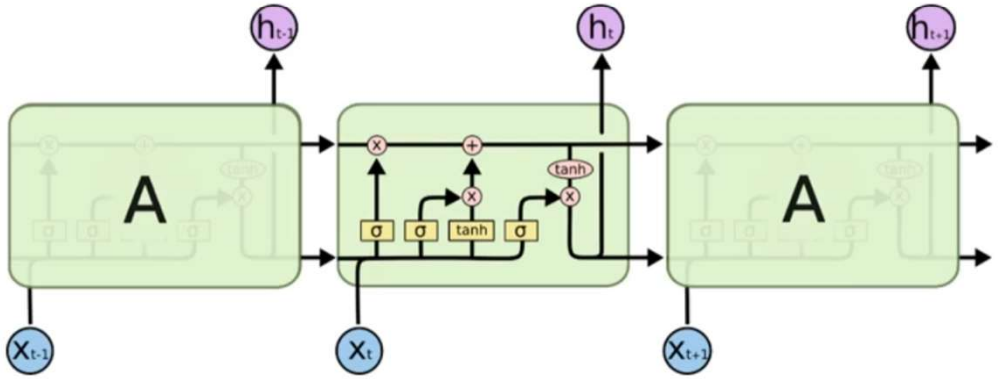
- Long Short Term Memory (LSTM)은 장기 의존성 문제를 완화한 RNN 개선 모델
- Cell state ($c_t$)구조를 제안하고, 세가지 gate를 추가한 구조
  - 세가지 gate: Forget gate ($f_t$), Input gate ($i_t$), Output gate ($o_t$)

**RNN**




$$h_{t-1} = f(W_{xh}x_{t-1} + W_{hh}h_{t-2})$$
$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1})$$
$$y_t = g(W_{hy}h_t)$$

**LSTM**

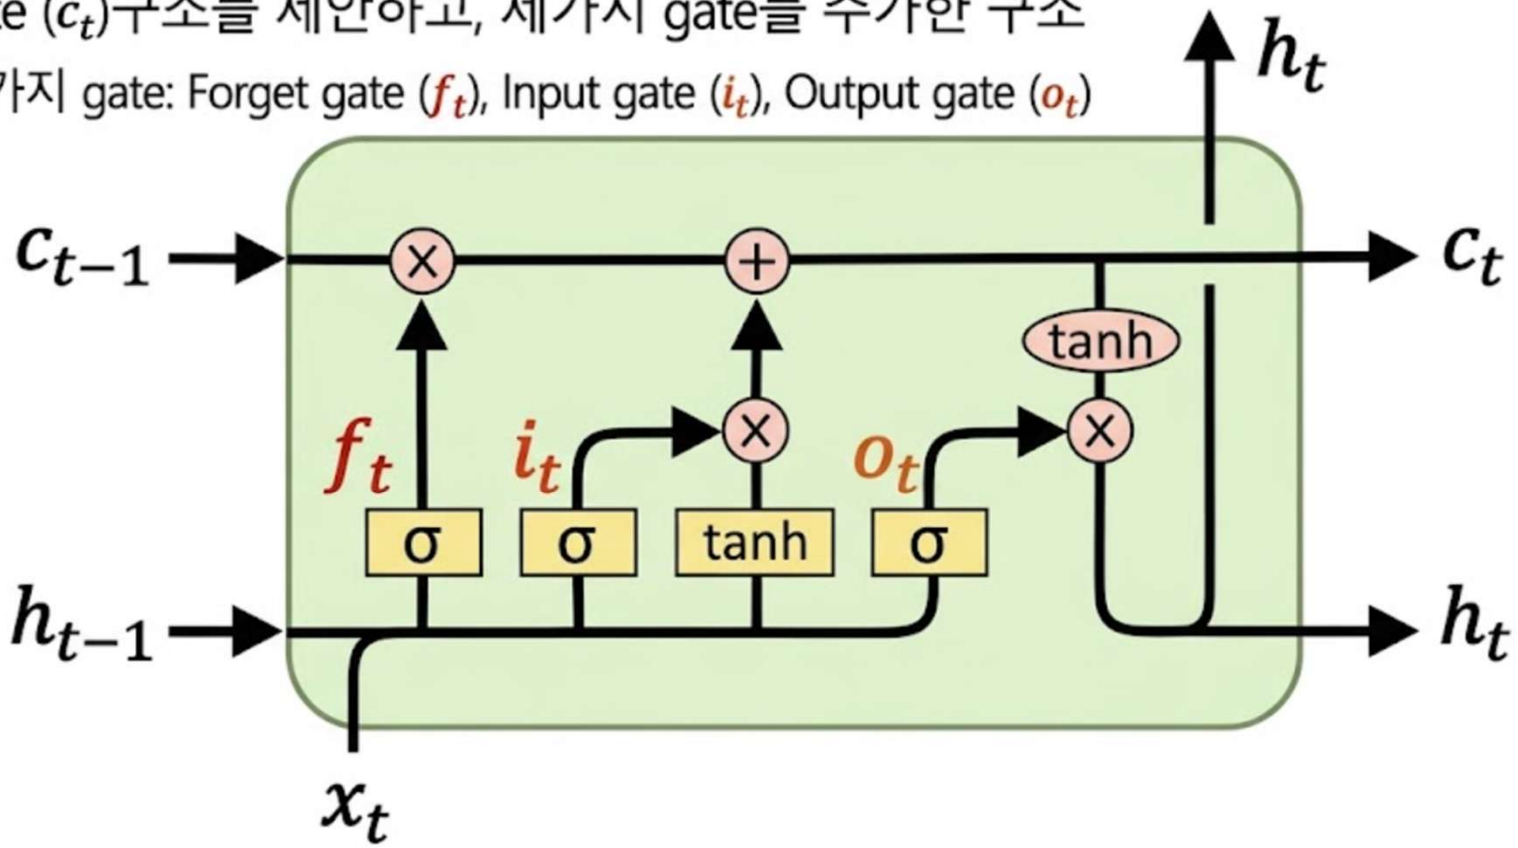



$$f_t = \sigma(W_{xh_f}x_t + W_{hh_f}h_{t-1} + b_{h_f})$$
$$i_t = \sigma(W_{xh_i}x_t + W_{hh_i}h_{t-1} + b_{h_i})$$
$$o_t = \sigma(W_{xh_o}x_t + W_{hh_o}h_{t-1} + b_{h_o})$$
$$\tilde{c}_t = tanh(W_{xh_g}x_t + W_{hh_g}h_{t-1} + b_{h_g})$$
$$c_t = f_t \otimes c_{t-1} \oplus i_t \otimes \tilde{c}_t$$
$$h_t = o_t \otimes tanh(c_t)$$

# 순환신경망 개선 모델: Long Short-Term Memory (LSTM)

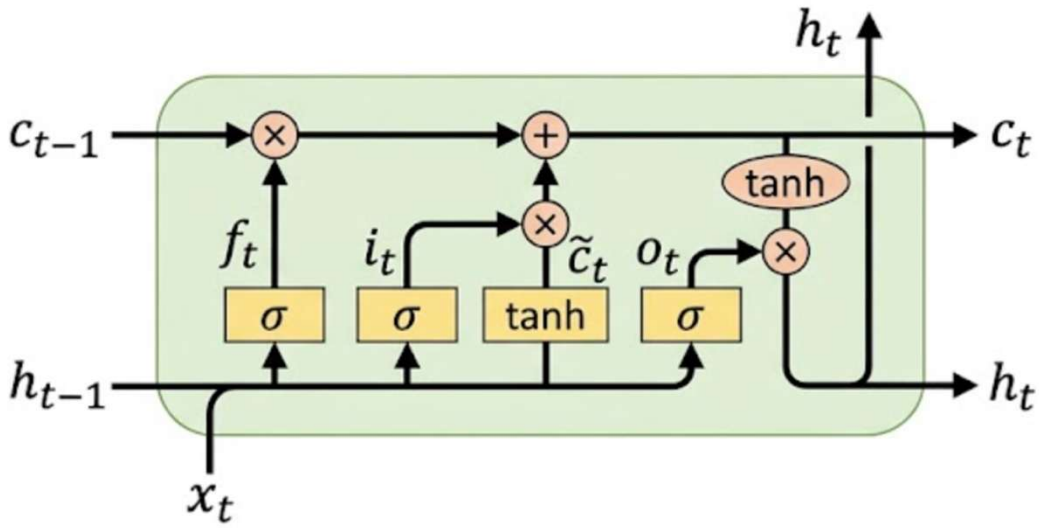
## Long Short Term Memory (LSTM) 구조

- Long Short Term Memory (LSTM)은 장기 의존성 문제를 완화한 RNN 개선 모델
- Cell state ($c_t$)구조를 제안하고, 세가지 gate를 추가한 구조
  - 세가지 gate: Forget gate ($f_t$), Input gate ($i_t$), Output gate ($o_t$)



# 순환신경망 개선 모델: Long Short-Term Memory (LSTM)

- Long Short Term Memory (LSTM)은 장기 의존성 문제를 완화한 RNN 개선 모델
- Cell state ($c_t$)구조를 제안하고, 세가지 gate를 추가한 구조
  - 세가지 gate: Forget gate ($f_t$), Input gate ($i_t$), Output gate ($o_t$)




$$f_t = \sigma(W_{xh_f} x_t + W_{hh_f} h_{t-1} + b_{h_f})$$

$$i_t = \sigma(W_{xh_i} x_t + W_{hh_i} h_{t-1} + b_{h_i})$$

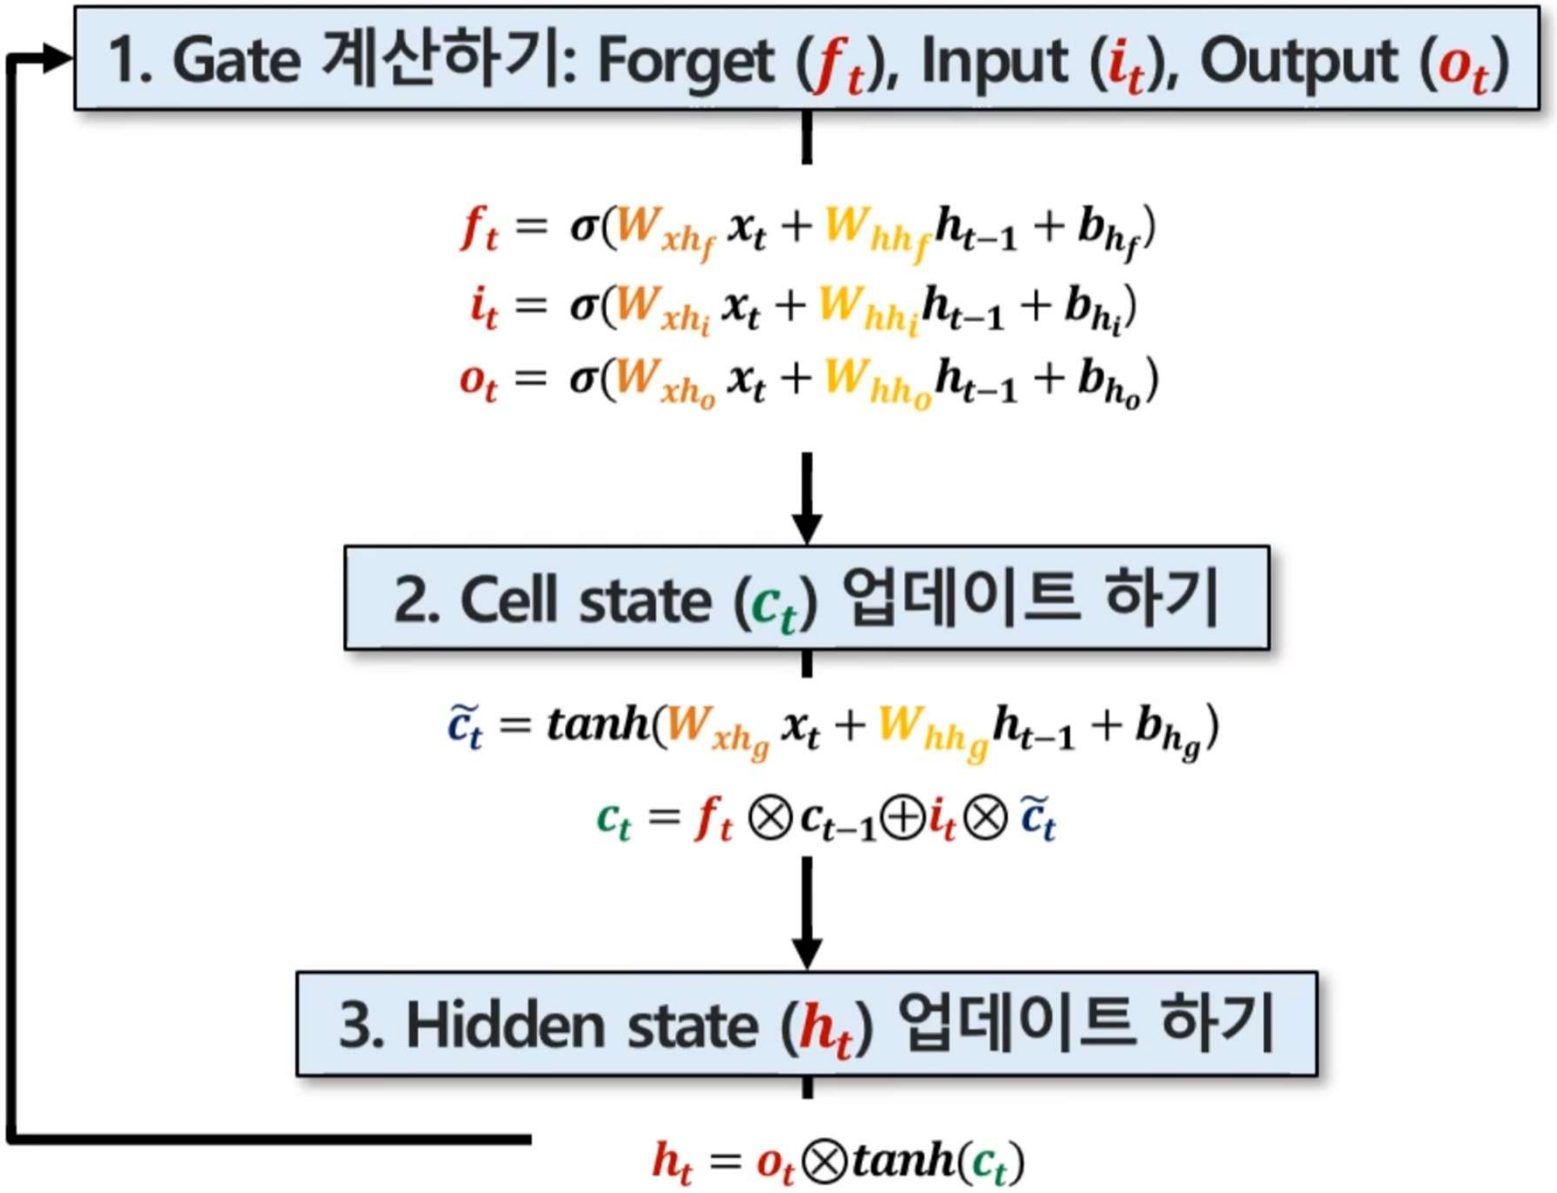
$$o_t = \sigma(W_{xh_o} x_t + W_{hh_o} h_{t-1} + b_{h_o})$$

$$\tilde{c}_t = tanh(W_{xh_g} x_t + W_{hh_g} h_{t-1} + b_{h_g})$$

$$c_t = f_t \otimes c_{t-1} \oplus i_t \otimes \tilde{c}_t$$

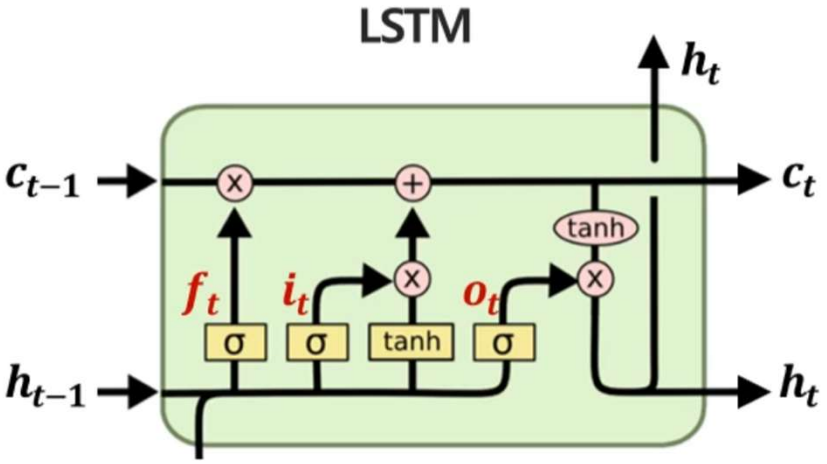
$$h_t = o_t \otimes tanh(c_t)$$

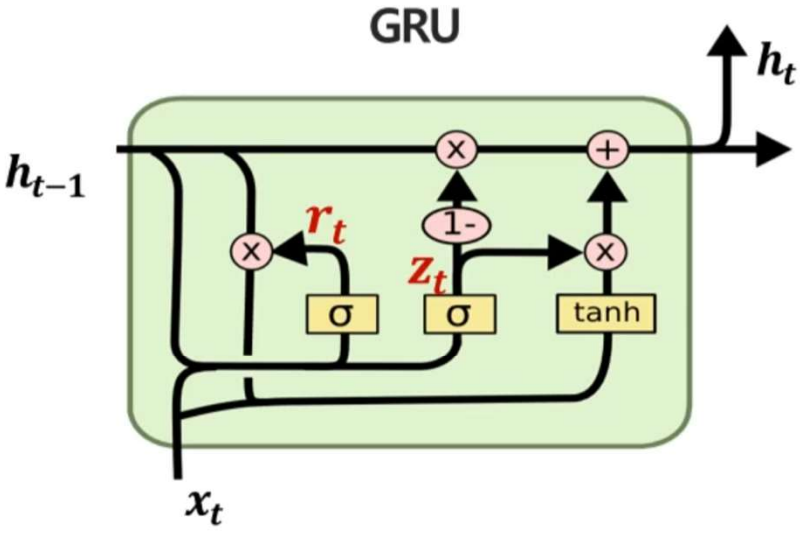
# LSTM 구조


1. Gate 계산하기: Forget ($f_t$), Input ($i_t$), Output ($o_t$)
$f_t = \sigma(W_{xh_f} x_t + W_{hh_f} h_{t-1} + b_{h_f})$
$i_t = \sigma(W_{xh_i} x_t + W_{hh_i} h_{t-1} + b_{h_i})$
$o_t = \sigma(W_{xh_o} x_t + W_{hh_o} h_{t-1} + b_{h_o})$
2. Cell state ($c_t$) 업데이트 하기
$\tilde{c}_t = tanh(W_{xh_g} x_t + W_{hh_g} h_{t-1} + b_{h_g})$
$c_t = f_t \otimes c_{t-1} \oplus i_t \otimes \tilde{c}_t$
3. Hidden state ($h_t$) 업데이트 하기
$h_t = o_t \otimes tanh(c_t)$

# LSTM 구조 개선모델:Gated Recurrent Unit(GRU)

- 일반적인 LSTM에서 cell state와 세가지 gate가 정의됨 (forget, input, output)
  - Cell state $c_t = f_t \otimes c_{t-1} \oplus i_t \otimes \tilde{c}_t$ 정의하는 과정에서 forget gate와 input gate가 활용
  - Hidden state $h_t = o_t \otimes tanh(c_t)$ 로 출력 값 정의 (output gate 활용)
- GRU는 LSTM의 구조를 간단하게 개선하여 파라미터 개수를 줄임
  - forget gate, input gate를 update gate($z_t$)로 통합, output gate를 없애고 reset gate($r_t$)정의
  - Cell state, hidden state를 hidden state로 통합




$$\tilde{c}_t = tanh(W_{xh_g} x_t + W_{hh_g} h_{t-1} + b_{h_g})$$

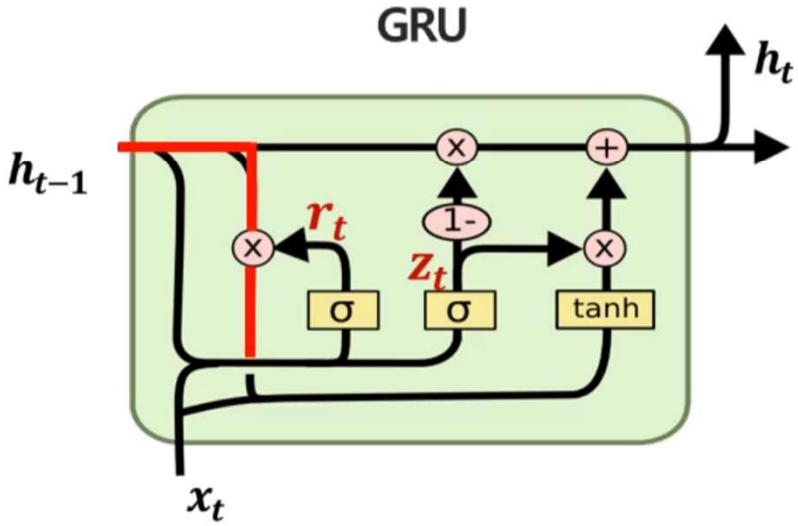
$$c_t = f_t \otimes c_{t-1} \oplus i_t \otimes \tilde{c}_t$$

$$h_t = o_t \otimes tanh(c_t)$$

# LSTM 구조 개선모델:Gated Recurrent Unit(GRU)

- Output gate를 없애고 reset gate($r_t$)정의, forget, input gate를 update gate($z_t$)로 통합
  - Reset gate $r_t = \sigma(W_{xh_r} x_t + W_{hh_r} h_{t-1} + b_{h_r})$
  - Update gate $z_t = \sigma(W_{xh_z} x_t + W_{hh_z} h_{t-1} + b_{h_z})$
  - 임시 cell state $\tilde{c}_t = tanh(W_{xh_g} x_t + W_{hh_g}(r_t \otimes h_{t-1}) + b_{h_g})$
- Cell, hidden state를 hidden state로 통합
  - 최종 cell state (=hidden state) $h_t = (1 - z_t) \otimes h_{t-1} \oplus z_t \otimes \tilde{c}_t$

Forget gate의 역할 Input gate의 역할



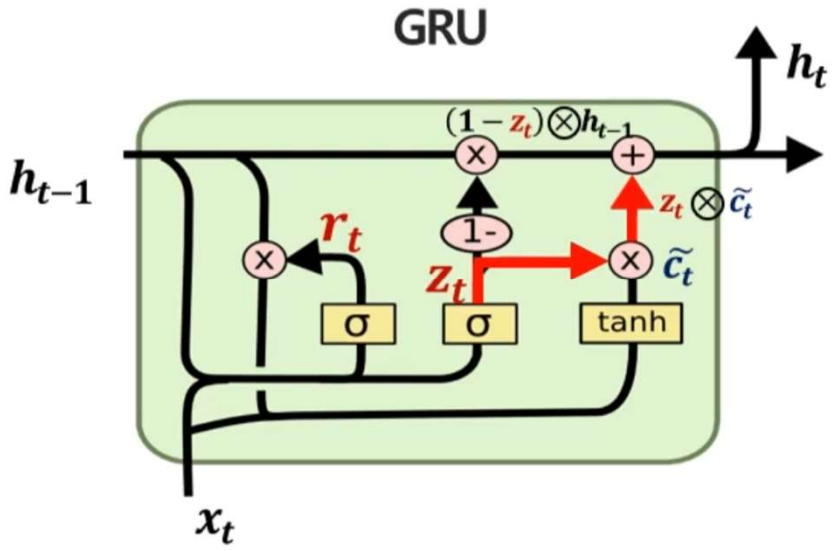

임시 cell state $\tilde{c}_t = tanh(W_{xh_g} x_t + W_{hh_g}(r_t \otimes h_{t-1}) + b_{h_g})$

최종 cell state (=hidden state) $h_t = (1 - z_t) \otimes h_{t-1} \oplus z_t \otimes \tilde{c}_t$

# LSTM 구조 개선모델:Gated Recurrent Unit(GRU)

- Output gate를 없애고 reset gate($r_t$)정의, forget, input gate를 update gate($z_t$)로 통합
  - Reset gate $r_t = \sigma(W_{xh_r} x_t + W_{hh_r} h_{t-1} + b_{h_r})$
  - Update gate $z_t = \sigma(W_{xh_z} x_t + W_{hh_z} h_{t-1} + b_{h_z})$
  - 임시 cell state $\tilde{c}_t = tanh(W_{xh_g} x_t + W_{hh_g}(r_t \otimes h_{t-1}) + b_{h_g})$
- Cell, hidden state를 hidden state로 통합
  - 최종 cell state (=hidden state) $h_t = (1 - z_t) \otimes h_{t-1} \oplus z_t \otimes \tilde{c}_t$

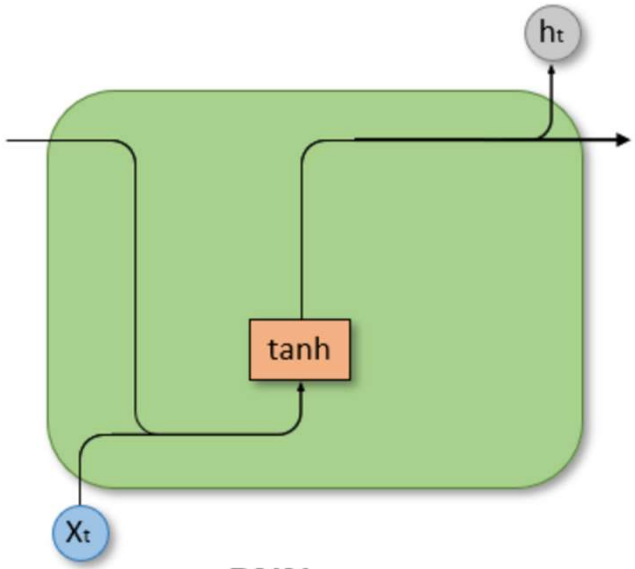
Forget gate의 역할 Input gate의 역할



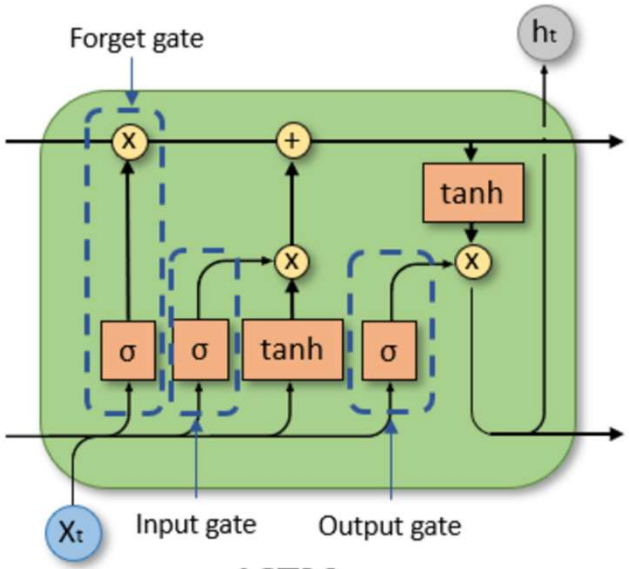

임시 cell state $\tilde{c}_t = tanh(W_{xh_g} x_t + W_{hh_g}(r_t \otimes h_{t-1}) + b_{h_g})$

최종 cell state (=hidden state) $h_t = (1 - z_t) \otimes h_{t-1} \oplus z_t \otimes \tilde{c}_t$

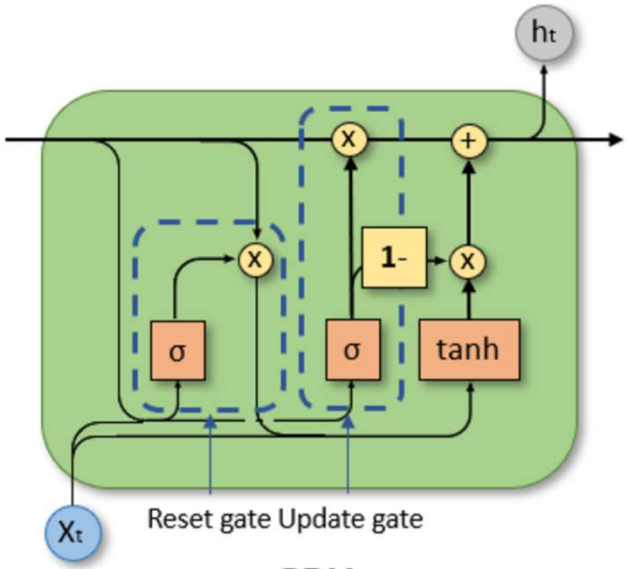
# LSTM 구조 개선모델:Gated Recurrent Unit(GRU)




RNN




LSTM




GRU

# Ablation Study

**특정 모듈을 의도적으로 제거하여, 제안 구조의 실제 성능 기여도를 인과적으로 입증하는 실험**

- 내가 제안한 모델에서 특정 기능, 모듈, 전처리 단계, 손실함수의 일부를 의도적으로 떼어냈을 때(Ablate), 모델 성능이 얼마나 망가지는가?"를 측정
- 모델의 성능 향상이 우연이 아니라, 내가 추가한 바로 그 핵심 블록 덕분이다라는 인과관계를 입증하는 것

**예를 들어 내가 LSTM 구조를 만들고 이를 주장하고자하면,**

**게이트별 제거 실험과 오차 변화 실험**

**Full Model:** f + i + o 게이트 **(오차 0.012)**
**w/o Forget:** f 게이트 제거 **(오차 0.085 ↑)**
**w/o Input:** i 게이트 제거 **(오차 0.045 ↑)**

# 프로젝트

| 단계 | 주요 내용 | 단계별 미션 |
|---|---|---|
| **1. 데이터셋 선택** | ETT 4개 중 하나를 선택<br>입력변수(X)와 예측변수(Y) 정의<br>예측 길이 및 문제 설정 | 사용할 ETT 데이터셋과<br>예측 문제를 명확히 설정 |
| **2. 모델 구현 및 비교** | RNN, LSTM, GRU 세 모델 구현<br>동일한 실험 조건에서 학습 및 예측 수행<br>기본 하이퍼파라미터 설정<br>(hidden size, layer 수, learning rate 등) | 세 모델을 동일한 조건에서 구현하고<br>기본 성능을 비교 |
| **3. Ablation Test** | 하나의 변수(입력 길이, hidden size, layer 수, dropout 등)를 선택하여 여러 값으로 변경<br>변경 전/후 결과를 통해 모델 성능에 미치는 영향 분석 | 한 가지 실험 조건을 변경하여<br>모델 성능 변화를 분석 |
| **4. 성능평가 및 결과 분석** | 평가지표(MAE, MSE, RMSE, $R^2$ 중 선택)로 성능 비교<br>Test 데이터로 최종 성능 평가<br>결과를 시각화하고 모델별 장단점 분석 | 모델의 성능을 정량적으로 비교하고<br>결과를 분석하여 결론 제시 |

https://github.com/zhouhaoyi/ETDataset