어프렌티스 프로젝트

Apprentice Project

2026-2

충북대학교 산업인공지능연구센터 채민선

충북대학교 CHUNGBUK NATIONAL UNIVERSITY
충북대학교 산업인공지능연구센터

어프렌티스 프로젝트

Apprentice Project

Lecture 8 : 2차 프로젝트 Review

충북대학교 CHUNGBUK NATIONAL UNIVERSITY

충북대학교 산업인공지능연구센터

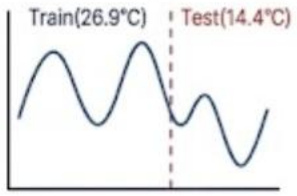
Forecasting vs Prediction

데이터셋 분석 · 입력 설계 (Dataset Analysis · Input Design)

예측 전에 데이터를 먼저 읽습니다

학습 전 데이터 편향(분포 이동)과 시계열의 물리적 특성(시차·자기상관)을 선제 규명하는 5단계 EDA 프로세스

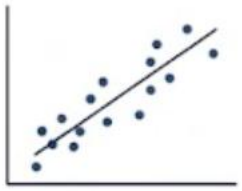
그래프로 흐름 & 분포 이동 보기



- 편향 확인 : 구간마다 데이터 수준이 달라지는지 확인

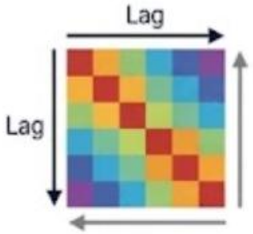
(계절성 판별 - Train(26.9°C)과 Test(겨울, 14.4°C)의 분포 차이)

같은 시점 상관 & 편향 점검



- 두 변수와의 관계 확인
- 동시점(t)에서 입력 변수와 타깃 변수의 상관 관계 점검

시차 교차상관 히트맵



- 물리적 지연(Lag) 확인 : 과거 원인 변수(t-k)가 미래 OT와 언제, 얼마나 연결되는지 확인

(불필요한 노이즈 센서 제거 및 최적의 Lookback 범위를 결정하는 근거)

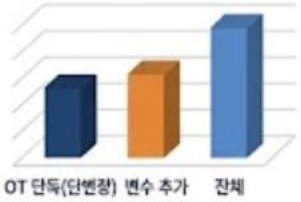
예측력 향상을 위한 다양한 방법 모색

절대값 vs 변화량 / 정규화



- 예측 타깃의 형태 : 미래 시점의 실제 온도 절대값 / 직전 온도 기준의 온도 변화량이나 관측값 기준 정규화

추가·제거 및 분할 검증



- 대조군 비교 : OT 단독 (단변량) vs 변수 추가
- 전체 변수를 같은 조건에서 비교하여 예측력 향상 검증

데이터 앤지니어링 · 모델링 기법 (Data Engineering · Modeling)

변화량 예측의 적용 대상 예시

데이터의 물리적 성질에 따른 변화량(Δy) 예측 기법의 성공(유리)과 실패(불리) 유형

물리적 관성 (Inertia)

적용 유리 (O)

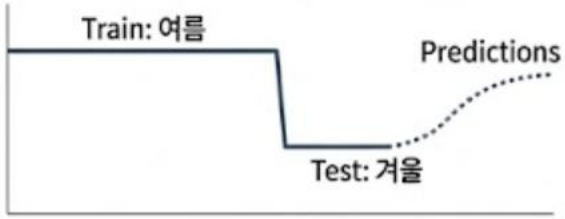
예시: 변압기·배터리·대형 반응조 온도



긴 주기의 계절성

적용 유리 (O)

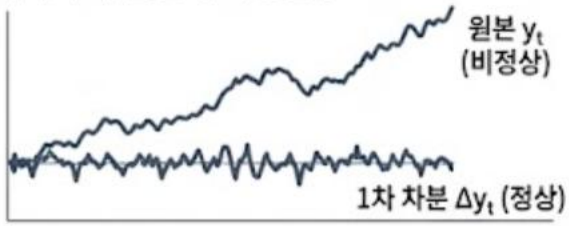
예시: 사계절 관성 데이터 (Level Shift)



통계적 비정상성 & 단위근

적용 유리 (O)

예시: 주가·환율·누적 생산량



높은 SNR & 확실한 기준점

적용 유리 (O)

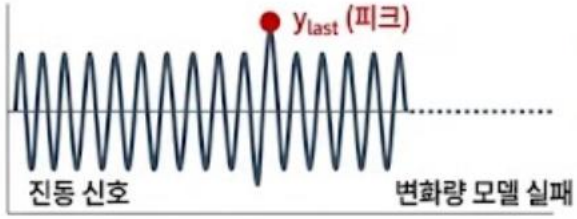
예시: 정밀 센서 데이터 (Anchor)



평균 회귀성 (Mean-Reverting)

적용 불리 (X)

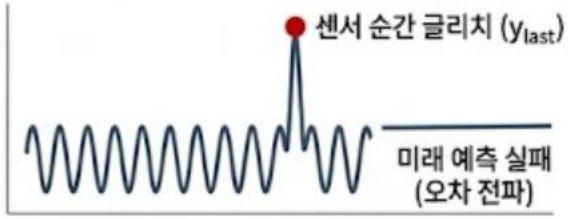
예시: 진동·가속도·음성 신호



센서 노이즈 & 순간 글리치

적용 불리 (X)

예시: 불량/이상 센서 데이터 (Glitch)



⚠ 주의: 성능 비교 시 반드시 지켜야 할 기준

만약 모델 A는 절대값을 예측하고 모델 B는 변화량을 예측했다면, 두 모델의 최종 평가는 반드시 '원래 온도 단위(℃)'로 통일해서 MSE/MAE를 계산해야 합니다.

연구 및 프레임워크 확장
(Research & Framework Expansion)

SOTA 벤치마크 모델 활용

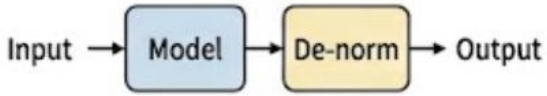
SOTA 모델용(Informer, DLinear, NLinear, iTransformer, RevIN 등)을 분석하고 구현한 우수 연구 방법론 프로세스

비정상성 극복 (RevIN)

적용 (O)

SOTA Target Reversible Instance Normalization (RevIN)

적용 효과 실시간 입력 스케일 복원 (Scale Recovery)



핵심 기법 실시간 입력 스케일 정규화 (Instance Normalization)

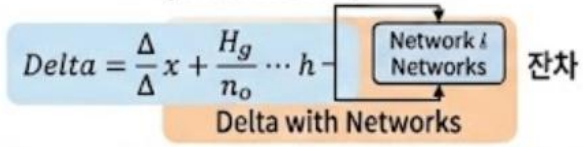
- 비정상 성질을 극복한 확장, 가치 극대화 모델
  - RevIN과의 인과관계로 안정적 정규화
  - 입력 연속성에 부과하여 변동성로 입력 극복

패턴&과적합 차단 (NLinear)

적용 (O)

SOTA Target NLinear / Residual Delta

적용 효과 변화량(Delta) 잔차화 (Relative Delta)



핵심 기법 직전값 기반 잔차 연결 (Relative Residuals)

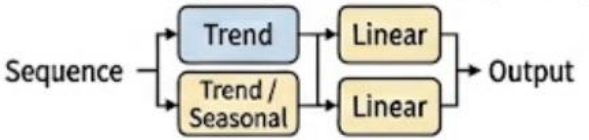
- 오버피팅 억제 효과 및 과적합 차단
  - 변화량 학습으로 무의미한 패턴 노이즈 차단
  - 점진적 학습 개선으로 우수한 지연 해소

아키텍처 최적화 (DLinear & Transformer)

적용 (O)

SOTA Target DLinear, Transformer, PatchTST

적용 효과 경량 선형화 & 분할 (Lightweight Sequence Decomposition)



핵심 기법 경량 선형망 & 어텐션 (Lightweight & Attention)

- Sequence-split 이중 예측 아키텍처 최적화
  - Trend/Seasonal 분리 (Decomposition) 활용
  - 경량 선형망 & 연산 최적화 / (Seasonal) 활용

★ [SOTA 벤치마크 아이디어 도입의 3대 가치]

1. "수학적 무결성 확보": 주먹구구식 튜닝이 아닌, 글로벌 Top 학회(NeurIPS, ICLR)에서 검증된 정규화·분해 기법으로 신뢰성 확보
2. "도메인 일반화(Generalization)": 데이터 수집 환경이 바뀌어도 오차가 튀지 않는 강건한 복원 메커니즘 수립
3. "컴퓨팅 리스크 최소화": 복잡한 신경망을 무작정 키우지 않고, 단순하면서도 강력한 MLP/선형 구조로 On-device 양산 가능성 극대화

연구의 무결성 (Research Integrity) · 모델 최적화 (Model Optimization)

어블레이션 테스트(Ablation Test) vs 하이퍼파라미터 튜닝(Hyperparameter Tuning)

모델 구성요소의 인과관계 검증과 성능 극대화를 위한 과학적 최적화

어블레이션 테스트 (Ablation Test)	구분	하이퍼파라미터 튜닝 (Hyperparameter Tuning)
[목적] 모델 구성요소의 기여도 검증	목적	[목적] 모델의 최적 설정값 탐색
[핵심 질문] 어떤 구성요소가 성능 향상에 기여하는가?	핵심 질문	[핵심 질문] 어떤 설정값에서 성능이 가장 좋은가?
[실험 방법] 특정 구성요소를 제거하거나 대체하여 성능 비교	실험 방법	[실험 방법] 하이퍼파라미터 값을 변경하며 성능 비교
[평가 기준] 구성요소 제거에 따른 성능 변화	평가 기준	[평가 기준] 설정값에 따른 검증 성능 변화
[실험 결과] 각 구성요소의 필요성과 효과 확인	실험 결과	[실험 결과] 최적 하이퍼파라미터 조합 도출
🌟 [실제 프로젝트 수행 예시] • **입력 변수(부하 센서) 제거 시험** : 다변량 7개에서 부하 센서 6종을 제거해 타깃(OT) 단독 입력과의 성능 대조 (MAE 23.5% 개선 효과 검증) • **LSTM/GRU 게이트 제거 시험** : 훈련 시 GRU/LSTM의 특정 게이트를 하나씩 제거(Ablation)하여 모델 경량화 및 필요성 확인 (3.6% 개선 입증) • **SOTA 모듈(RevIN, 잔차) 제거 및 룩백(Lookback) 조절 시험** : 정규화나 잔차(Delta) 연결의 인위적 제거 및 입력 길이 단축으로 개별	실제 수행 예시	🌟 [실제 프로젝트 수행 예시] • **네트워크 아키텍처 탐색** : Hidden Size (16, 32, 64, 128), Layer 수 (1층, 2층), 드롭아웃(Dropout) 비율 조절을 통한 과적합(Overfitting) 방지 • **최적화 및 훈련 조건 탐색** : Learning Rate (0.01, 0.005, 0.001) 및 Batch Size (32, 64, 128) 변경을 통한 수렴 안정성 및 학습 속도 확보 • **학습 제약 조건 조절** : Early Stopping Patience 설정(과적합 지점 조기 정지), Optimizer (Adam, AdamW) 선택을 통한 최적화 성능 개선

⚠️ **[실험 무결성을 위한 최우선 주의사항]**

다중 변경 금지(변수 통제): 여러 요소를 동시에 바꾸면 성능 변화를 일으킨 진짜 원인(인과관계)을 알 수 없습니다. 반드시 한 번에 단 1가지 조건만 변경(Isolating Variables)하십시오.
대조 조건의 완벽한 일치: 모델 간 공정한 비교를 위해 동일 데이터 분할(Train/Val/Test)[cite: 1.2.4, 1.2.19], 동일 시드(Seed)[cite: 1.2.21], 동일 스케일러[cite: 1.2.32]를 고정한 뒤 미세 오차(0.01 단위)의 우위를 검증해야 합니다.