어프렌티스 프로젝트

Apprentice Project

2026-2

충북대학교 산업인공지능연구센터 채민선

충북대학교 CHUNGBUK NATIONAL UNIVERSITY

충북대학교 산업인공지능연구센터

어프렌티스 프로젝트

Apprentice Project

Lecture 8,9,10 : Anomaly Detection

충북대학교 CHUNGBUK NATIONAL UNIVERSITY
충북대학교 산업인공지능연구센터

Anomaly Detection 개요

- 이상치 탐지 개요
- 밀도 기반 이상치 탐지 알고리즘
  - 2-1. 밀도 기반 이상치 탐지 알고리즘의 개념
  - 2-2. Gaussian Density Estimation
  - 2-3. Mixture of Gaussian Density Estimation
  - 2-4. Local Outlier Factor
- 모델 기반 이상치 탐지 알고리즘
  - 3-1. Isolation Forest
  - 3-2. One-Class Support Vector Machine
  - 3-3. Support Vector Data Description
- 재구축 오차 기반 이상치 탐지 알고리즘
  - 4-1. 재구축 오차의 개념
  - 4-2. Principal Component Analysis
  - 4-3. Autoencoder
- 생성적 적대 신경망 기반 이상치 탐지 알고리즘
  - 5-1. 생성적 적대 신경망의 개념
  - 5-2. AnoGAN
  - 5-3. GANomaly

Anomaly Detection

Novelty vs. Anomaly vs. Outlier

이상치 데이터란?

Anómaly

애너멀리

이상치 데이터란?

Applications: Industrial Monitoring



Anomaly Detection Suite

Detect Early, Act Smart

How it works



Build
Collect data from normal machine operations to learn/train the model

Operate / Monitor
Monitor and process real-time stream data on the fly

Predict
Predict anomaly patterns and signal when outliers occur to early

Case Study:

Predictive Maintenance for Semiconductor Processing Equipment

Goal

To detect abnormal patterns and predict remaining time-to-failure of semiconductor processing equipment in order to minimize downtime losses and unscheduled maintenance costs

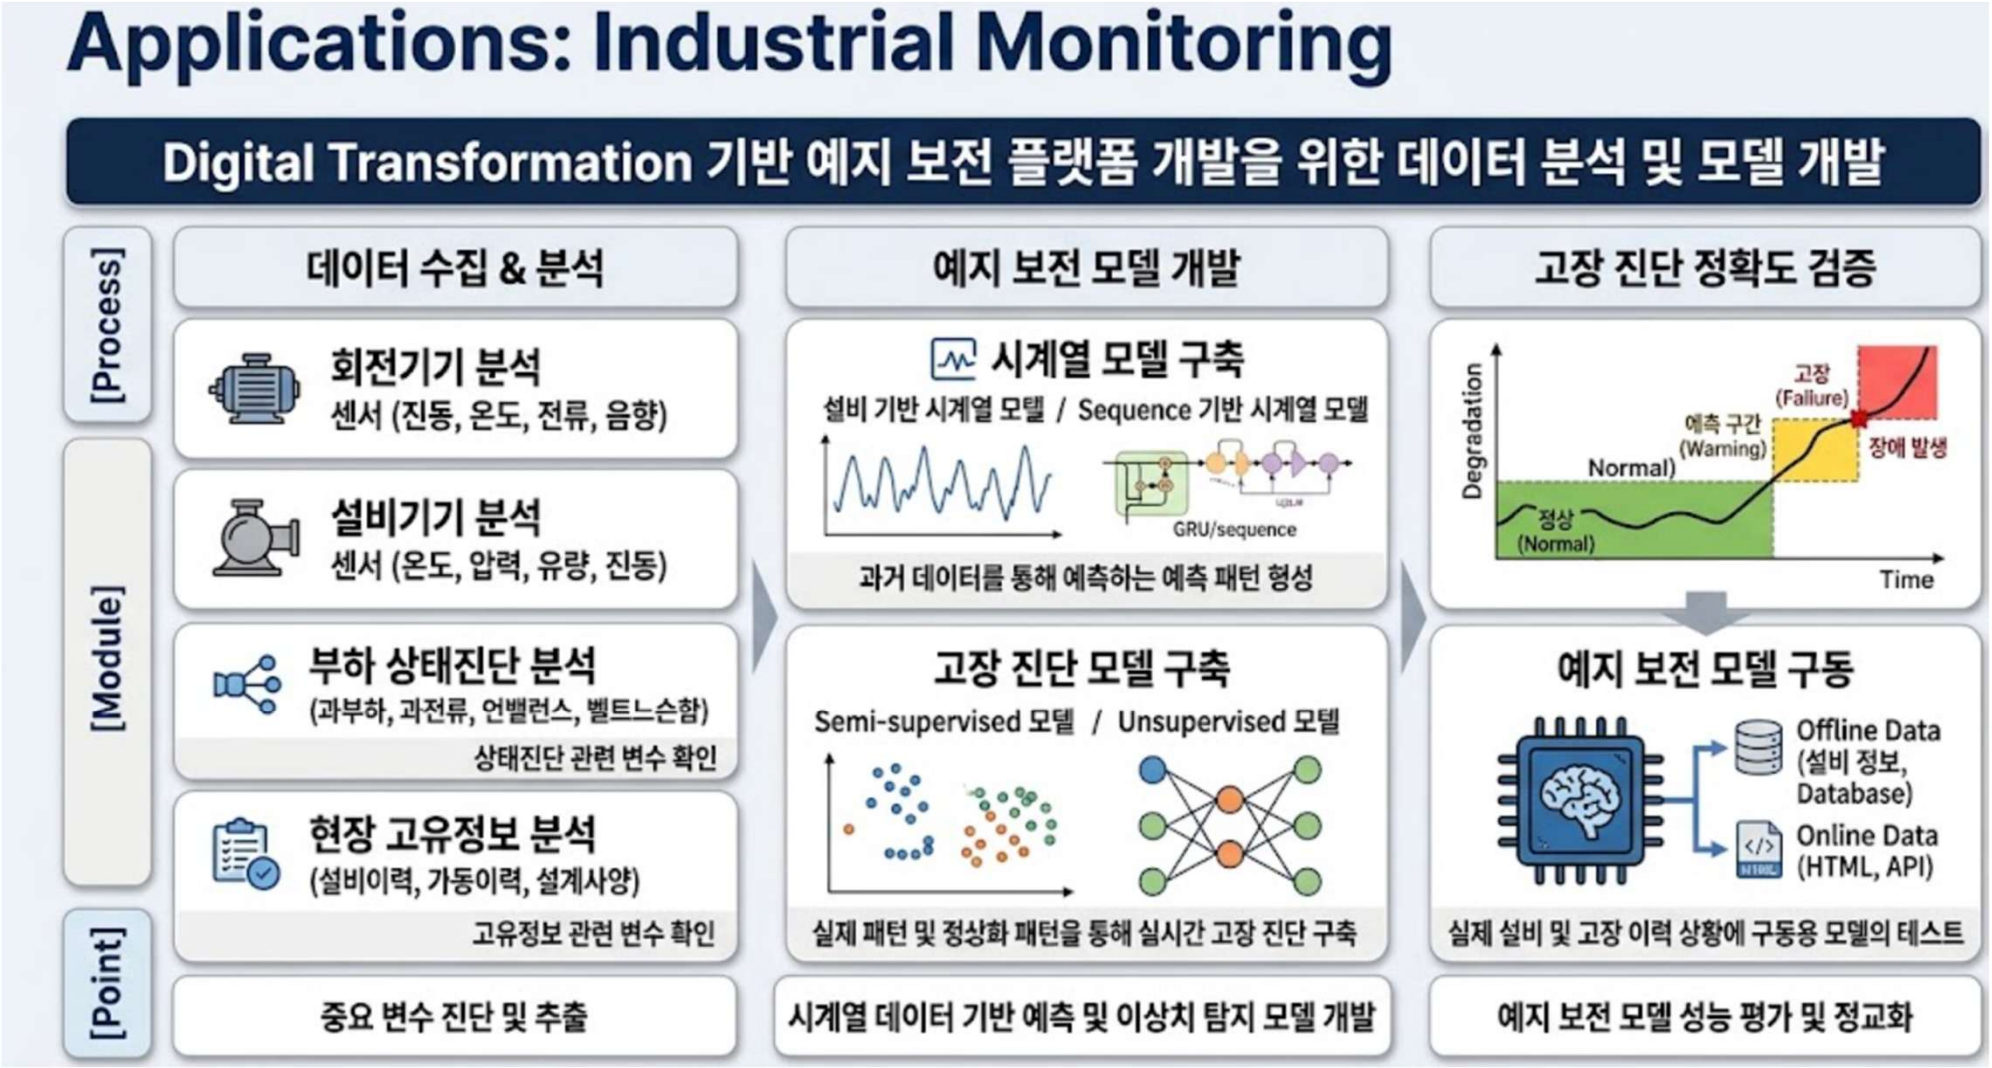
Our Approach

We formulated the problem as semi-supervised novelty detection on multivariate time-series operation data.
We developed a method to estimate time-to-failure and an online learning sysem to adapt to environment changes.

Results

Improved Time-to-failure prediction with **high accuracy** and **< 1% false alarm rate.**

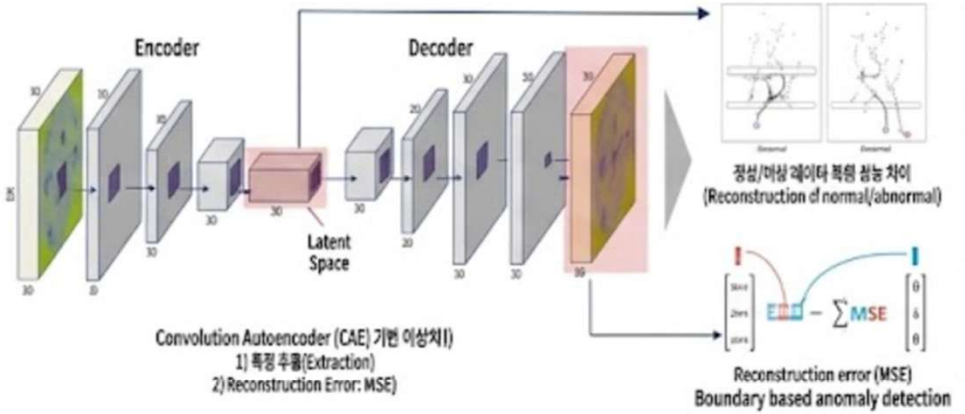
이상치 데이터란?


Applications: Industrial Monitoring
Digital Transformation 기반 예지 보전 플랫폼 개발을 위한 데이터 분석 및 모델 개발
[Process]
[Module]
[Point]
데이터 수집 & 분석
회전기기 분석
센서 (진동, 온도, 전류, 음향)
설비기기 분석
센서 (온도, 압력, 유량, 진동)
부하 상태진단 분석
(과부하, 과전류, 언밸런스, 벨트느슨함)
상태진단 관련 변수 확인
현장 고유정보 분석
(설비이력, 가동이력, 설계사양)
고유정보 관련 변수 확인
중요 변수 진단 및 추출
예지 보전 모델 개발
시계열 모델 구축
설비 기반 시계열 모델 / Sequence 기반 시계열 모델
GRU/sequence
과거 데이터를 통해 예측하는 예측 패턴 형성
고장 진단 모델 구축
Semi-supervised 모델 / Unsupervised 모델
실제 패턴 및 정상화 패턴을 통해 실시간 고장 진단 구축
시계열 데이터 기반 예측 및 이상치 탐지 모델 개발
고장 진단 정확도 검증
Degradation
고장
(Failure)
예측 구간
(Warning)
장애 발생
Normal)
정상
(Normal)
Time
예지 보전 모델 구동
Offline Data
(설비 정보,
Database)
Online Data
(HTML, API)
실제 설비 및 고장 이력 상황에 구동용 모델의 테스트
예지 보전 모델 성능 평가 및 정교화

이상치 데이터란?

Applications: Industrial Monitoring

Convolution Autoencoder (CAE) 기반 이상치 탐지



지능형 영상/AI 서버단에서
이상치 여부 탐지 및 판단

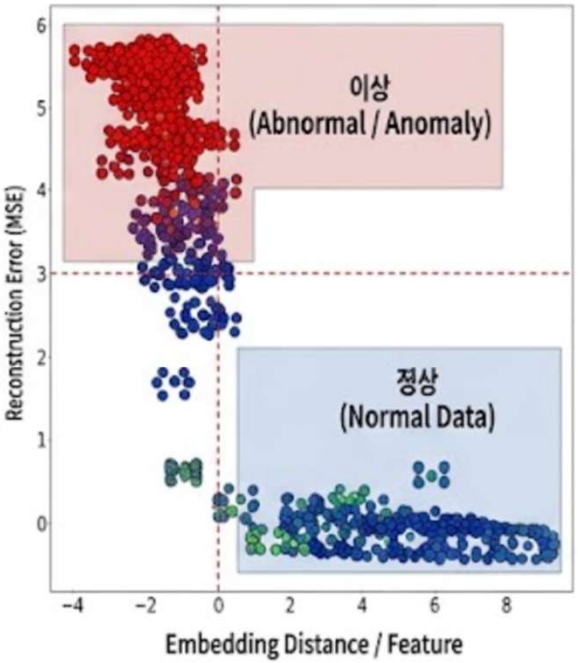
데이터/조율

수집 데이터를 기반으로 오탐율 최소화,
이상치 여부의 신속한 판별

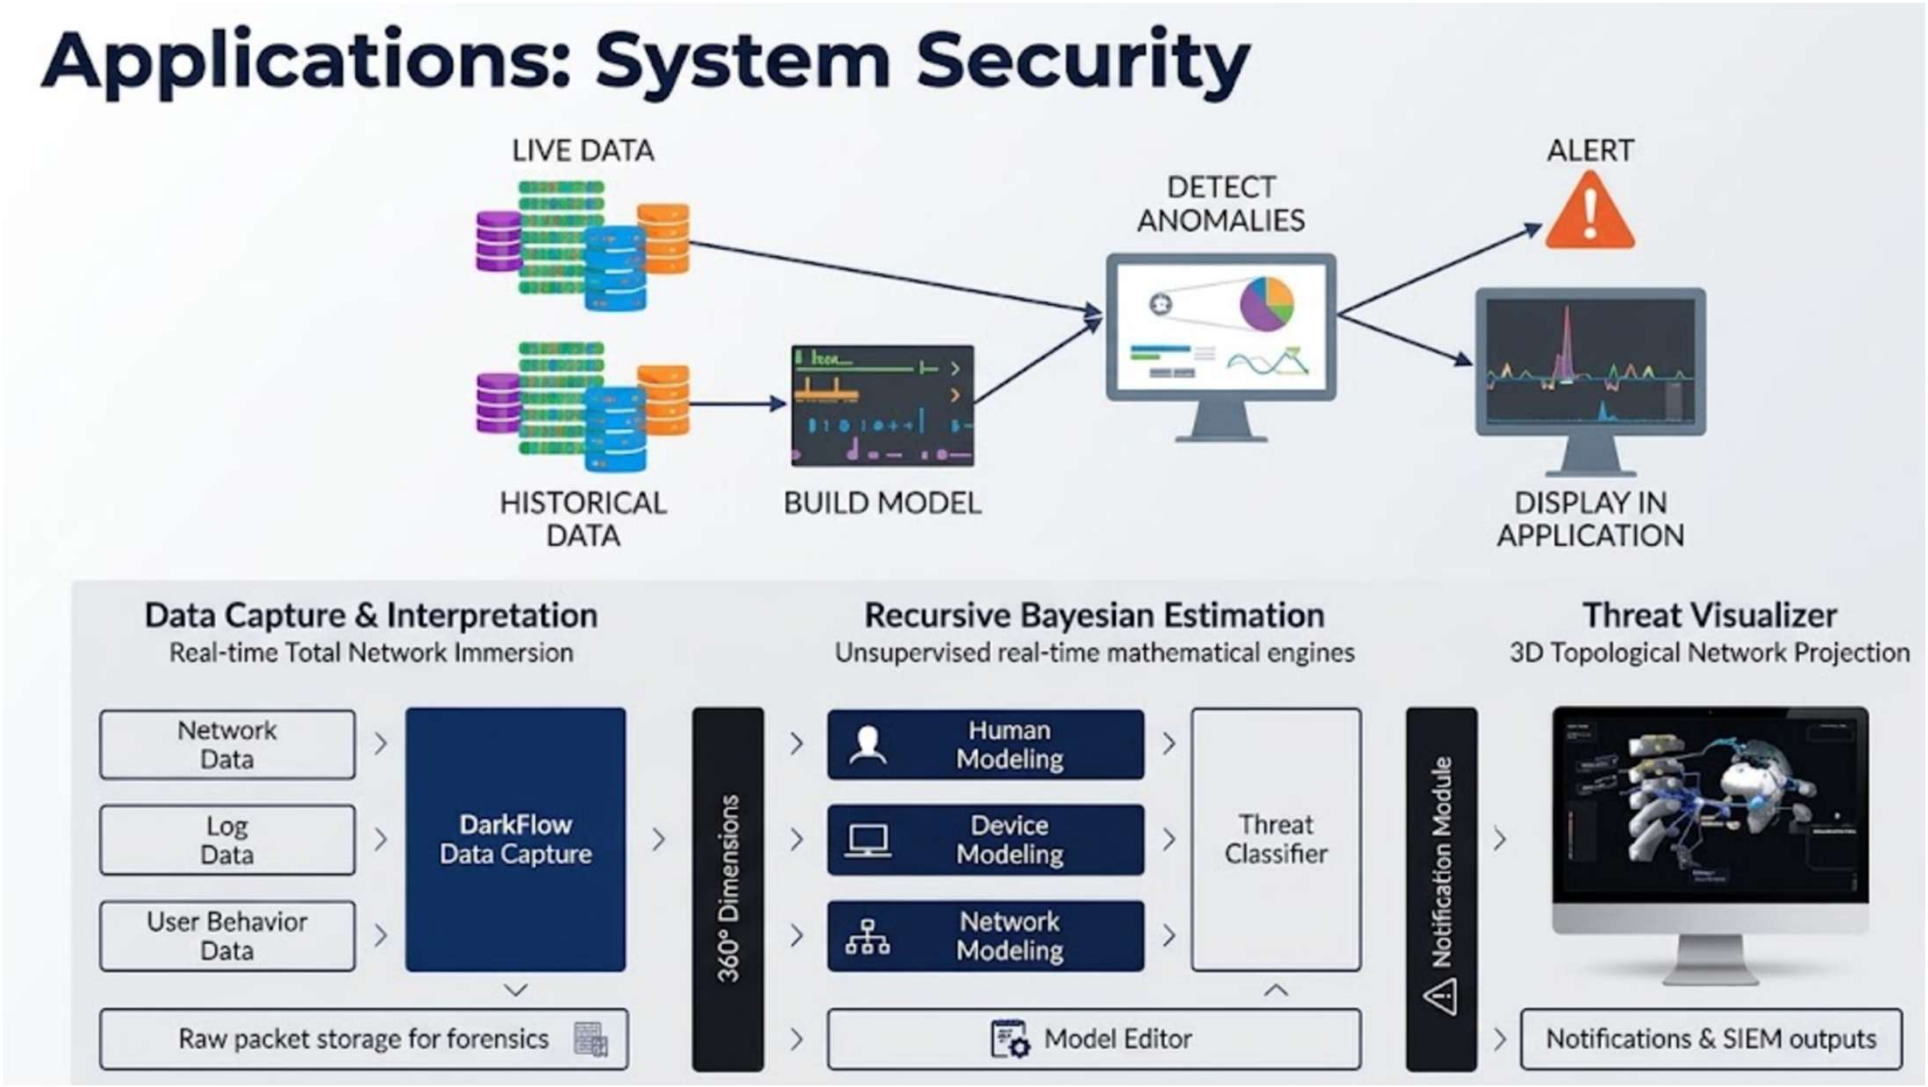
경고/대응

실시간 이상 징후 예측,
장애 및 이상치 조기 발굴
및 선제 대응

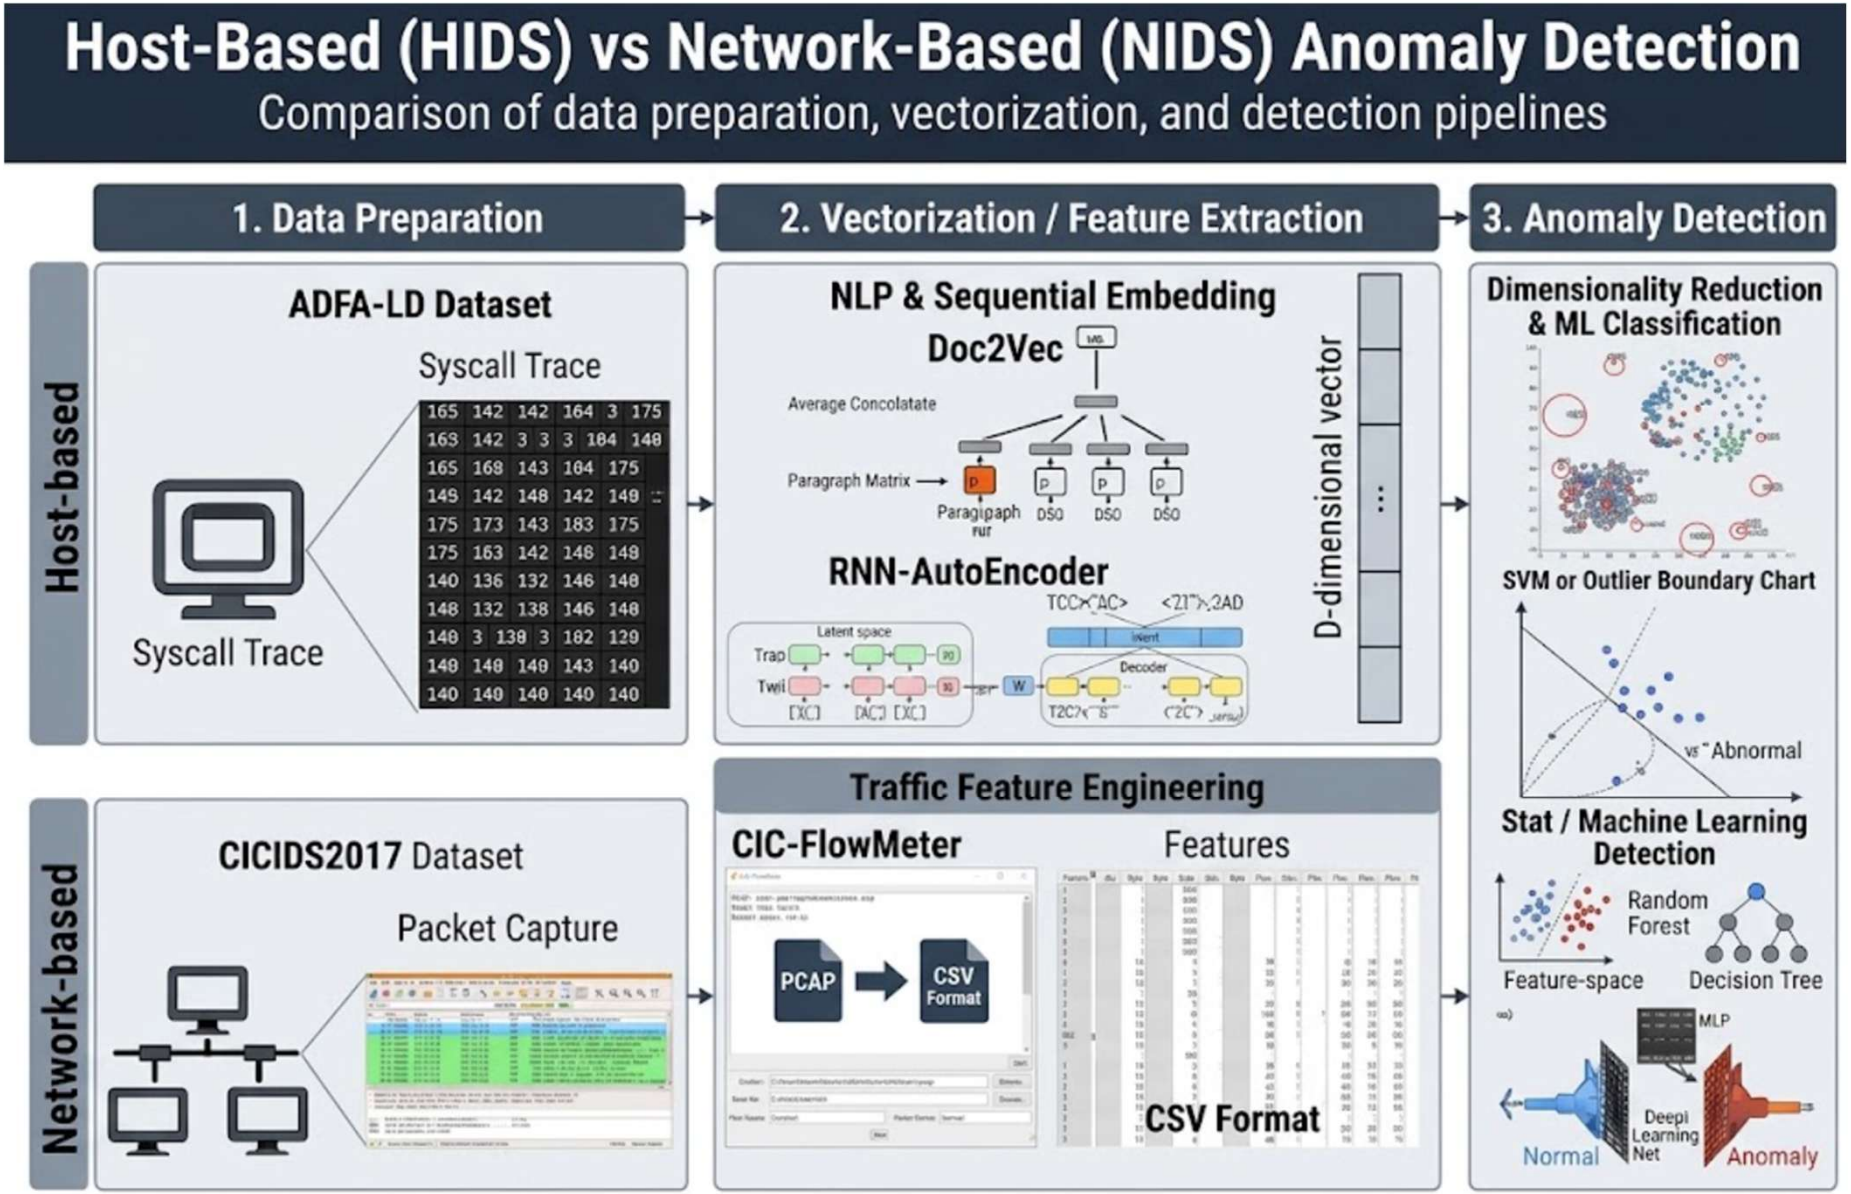
이상치 탐지 결과 시각화
(Anomaly Detection Visualization)



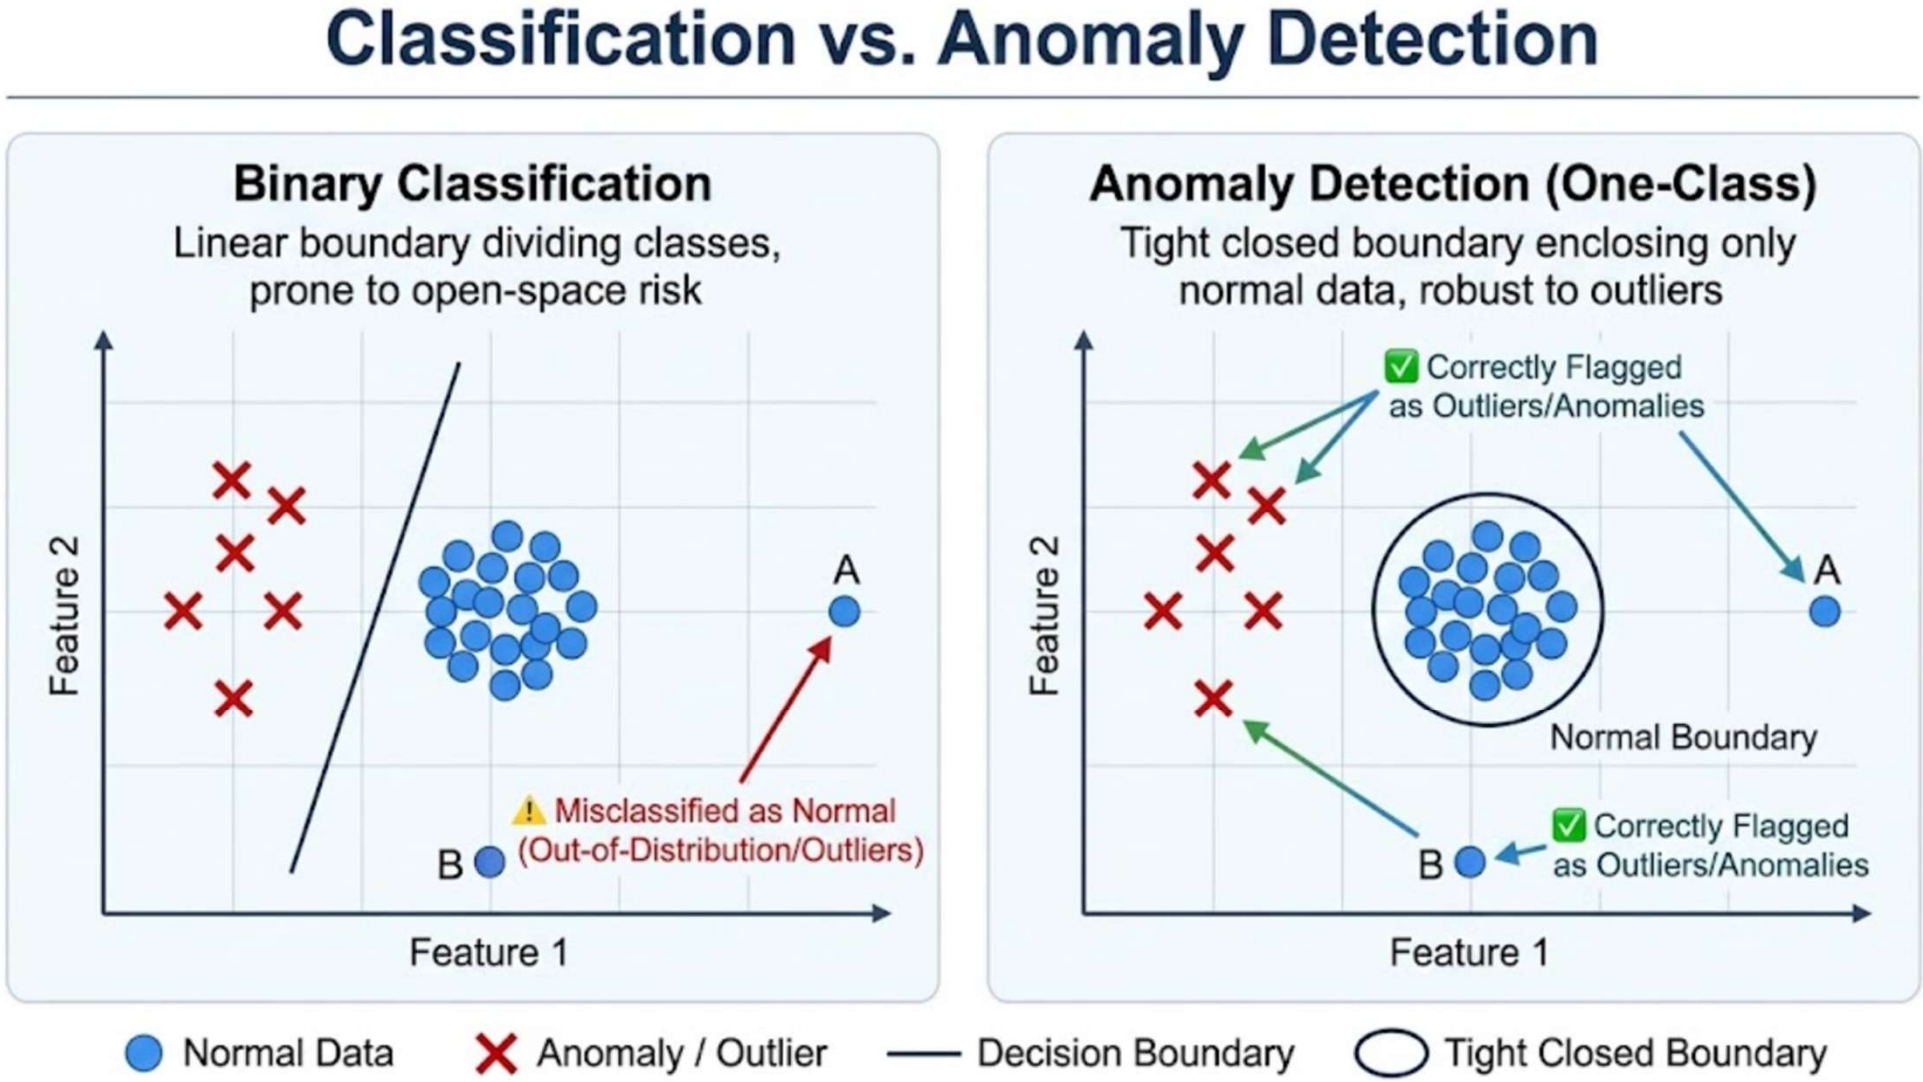
이상치 데이터란?


Applications: System Security
LIVE DATA
HISTORICAL DATA
BUILD MODEL
DETECT ANOMALIES
ALERT
DISPLAY IN APPLICATION
Data Capture & Interpretation
Real-time Total Network Immersion
Network Data
Log Data
User Behavior Data
DarkFlow Data Capture
Raw packet storage for forensics
360° Dimensions
Recursive Bayesian Estimation
Unsupervised real-time mathematical engines
Human Modeling
Device Modeling
Network Modeling
Model Editor
Threat Classifier
Notification Module
Threat Visualizer
3D Topological Network Projection
Notifications & SIEM outputs

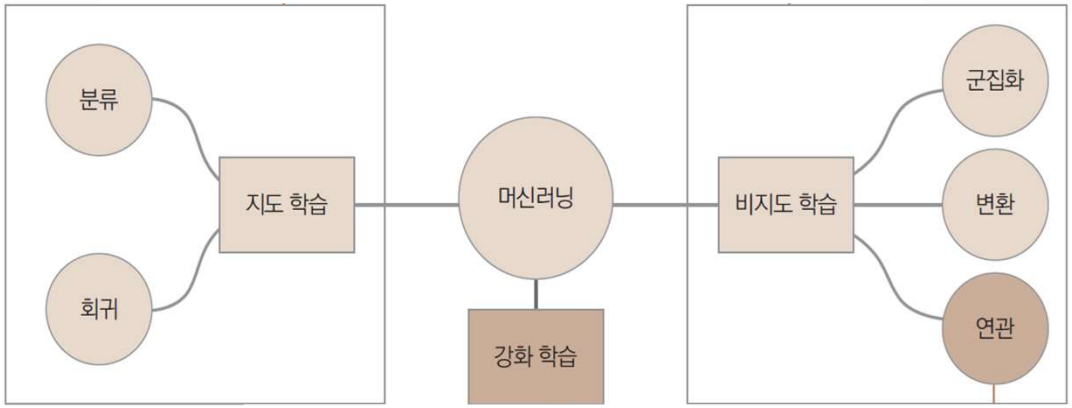
이상치 데이터란?


Host-Based (HIDS) vs Network-Based (NIDS) Anomaly Detection
Comparison of data preparation, vectorization, and detection pipelines
1. Data Preparation
2. Vectorization / Feature Extraction
3. Anomaly Detection
Host-based
ADFA-LD Dataset
Syscall Trace
Syscall Trace
NLP & Sequential Embedding
Doc2Vec
Average Concolatate
Paragraph Matrix
RNN-AutoEncoder
Latent space
Decoder
D-dimensional vector
Dimensionality Reduction & ML Classification
SVM or Outlier Boundary Chart
vs "Abnormal
Stat / Machine Learning Detection
Random Forest
Feature-space
Decision Tree
MLP
Deepl Learning Net
Normal
Anomaly
Network-based
CICIDS2017 Dataset
Packet Capture
Traffic Feature Engineering
CIC-FlowMeter
PCAP
CSV Format
Features
CSV Format

이상치 데이터란?


Classification vs. Anomaly Detection
Binary Classification
Linear boundary dividing classes, prone to open-space risk
Feature 2
Feature 1
A
B
Misclassified as Normal (Out-of-Distribution/Outliers)
Anomaly Detection (One-Class)
Tight closed boundary enclosing only normal data, robust to outliers
Correctly Flagged as Outliers/Anomalies
Normal Boundary
Correctly Flagged as Outliers/Anomalies
Normal Data
Anomaly / Outlier
Decision Boundary
Tight Closed Boundary

머신러닝 기법



- 회귀 : 연속된 값을 측정하는 문제
  (ex) 중고차 가격 예측
- **분류 : 범주형 값을 측정하는 문제**
  (ex) 마케팅 문자를 보냈을 때 구매할 것 같은 고객을 예측하는 문제는 Yes/No 두 가지 범주로 표현

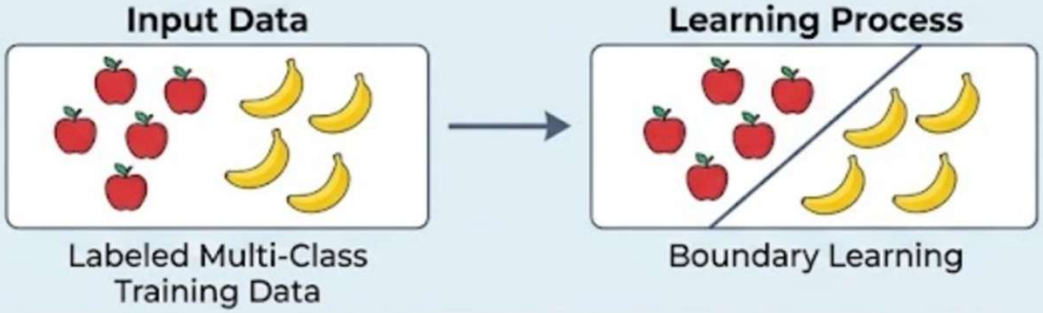
- 군집화(clustering) : 비슷한 데이터끼리 묶어주는 방법
  (ex) 소비 패턴이 유사한 카드 고객을 묶음.
- 변환(transformation) : 목적에 따라 데이터를 다른 형태로 바꿈.
  (ex) 변수 100개의 특성을 최대한 살려 변수 2개로 압축
- 연관(association) : 일명 장바구니 분석이라고도 하며, 유사한 구매 목록을 가진 고객끼리 비교하여, 서로의 장바구니에 담기지 않은 새로운 아이템을 추천을 하는 목적 등으로 사용.

이상치 데이터란?

How Models Learn: Classification vs. Anomaly Detection

'Classification (Supervised Learning)'

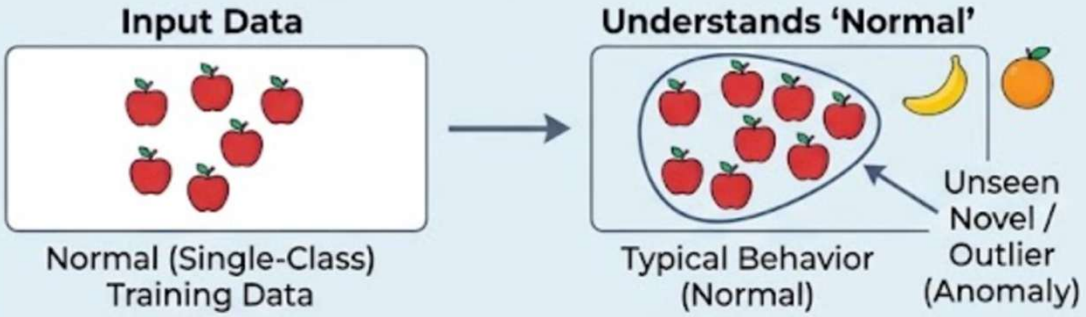
Requires labeled data from all classes to define boundaries



- Learns to distinguish between multiple known categories (Apples vs. Bananas)
- **Goal:** Classify incoming data into known categories.

Anomaly Detection / Novelty Detection

Learns ONLY from normal, typical data to understand what 'normal' is



- Learns standard patterns of a single normal class without needing to see anomalies beforehand
- **Goal:** Identify any future data that deviates from 'normal' (e.g., Bananas, etc.).

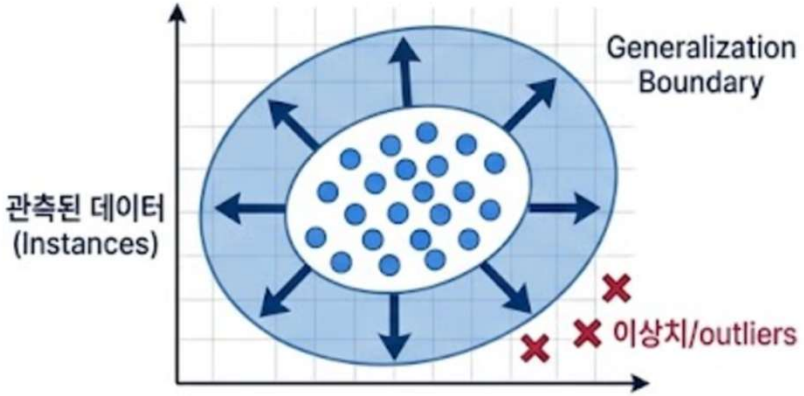
이상치 데이터란?

Generalization vs. Specialization

이상치 탐지(Anomaly Detection)에서 정상 경계 정의의 트레이드오프 (The Trade-off of Boundary Definition)

Generalization (일반화)

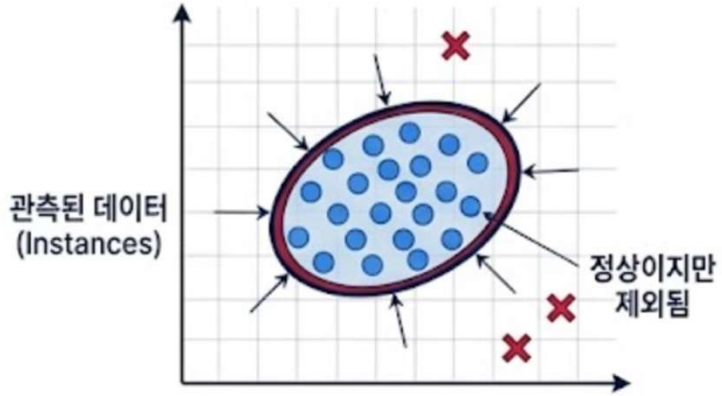
Expanding Boundaries Outward (범위를 넓혀 다양성 수용)



- 경계를 바깥쪽으로 확장 (Outward Expansion)
- 관측되지 않은 정상 범위의 다양성을 인정하여 허용 오차를 넓힘
- 장점: 오탐(False Alarm) 감소 — 웬만한 변동은 정상으로 수용
- 단점: 미탐(Missed Anomaly) 증가 — 너무 느슨해서 실제 이상치도 정상으로 통과할 위험

Specialization (구체화)

Tightening Boundaries Inward (범위를 좁혀 엄격히 제한)



- 경계를 안쪽으로 축소 (Inward Contraction)
- 훈련 데이터의 특정 패턴과 일치하는 좁은 범위만 정상으로 인정
- 장점: 미탐(Missed Anomaly) 최소화 — 조금의 비정상적 조짐도 철저히 색출
- 단점: 오탐(False Alarm) 급증 — 자연스러운 정상 변화도 이상치로 오인

'The Golden Balance' or 'Trade-off'

Too Loose (Over-generalization) ——●—— **Too Rigid** (Over-specialization)

To help students understand that finding the right threshold is key

이상치 데이터란?

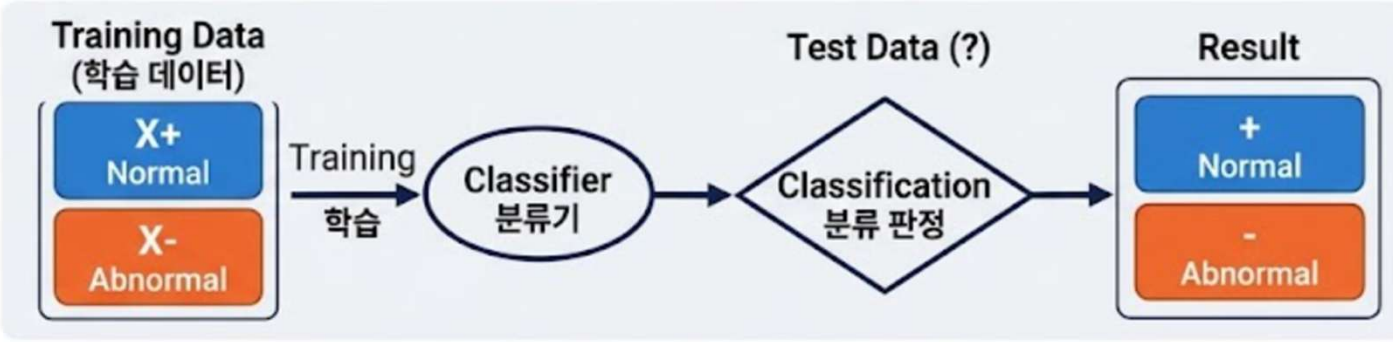
'Anomaly Detection Approach'

📌 **Assumption (전제 조건)**

There are considerably more 'normal' (정상) observations than 'abnormal' (비정상) observations in the data.

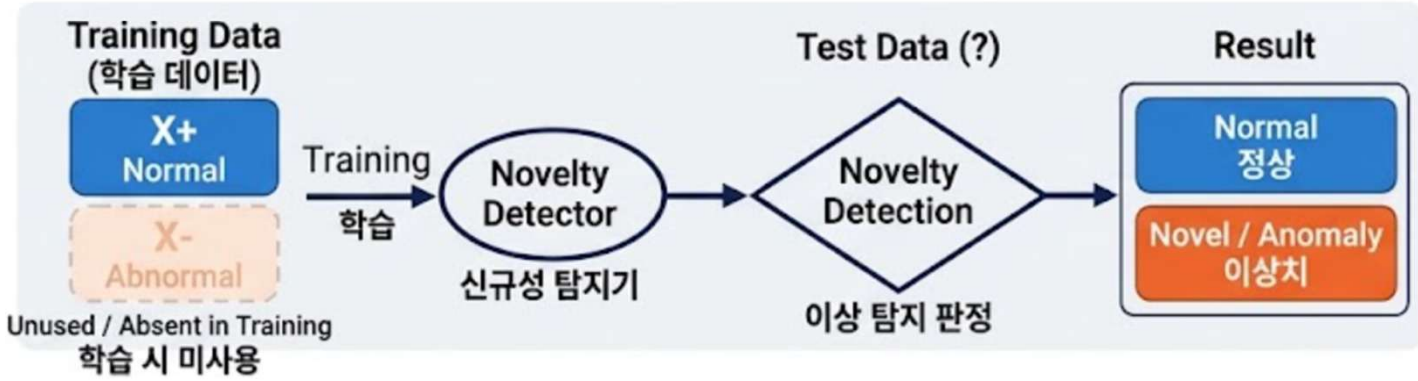
Classification
(지도학습 기반 분류)

Requires both classes (X+ and X-) to define a decision boundary.

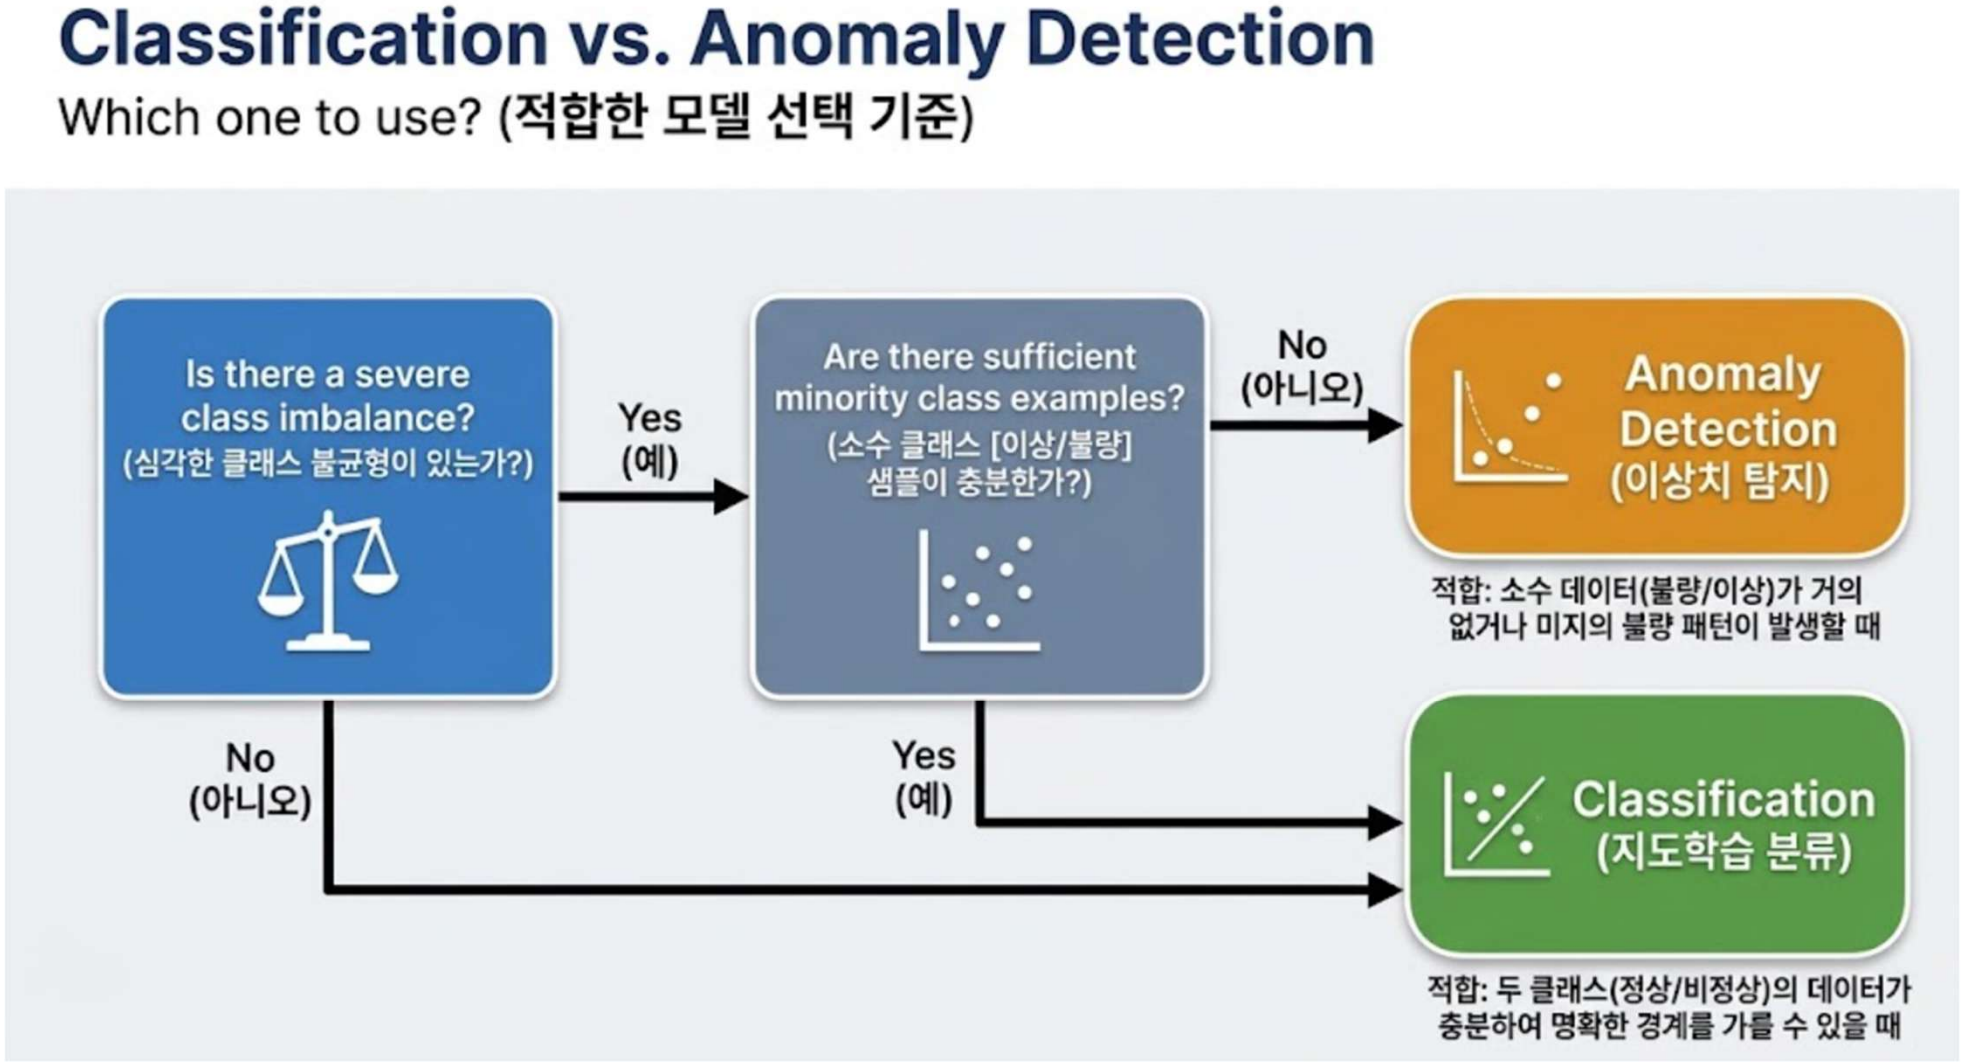


Anomaly Detection
(이상치 / 신규성 탐지)

Learns only the patterns of normal data (X+).



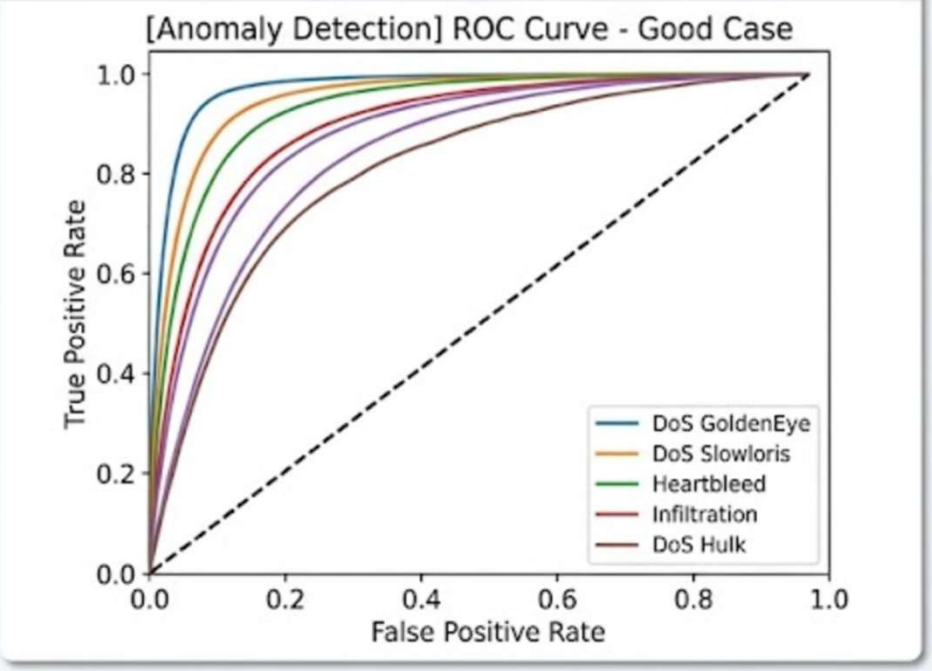
이상치 데이터란?


Classification vs. Anomaly Detection
Which one to use? (적합한 모델 선택 기준)
Is there a severe class imbalance?
(심각한 클래스 불균형이 있는가?)
Yes
(예)
Are there sufficient minority class examples?
(소수 클래스 [이상/불량] 샘플이 충분한가?)
No
(아니오)
Anomaly Detection
(이상치 탐지)
적합: 소수 데이터(불량/이상)가 거의 없거나 미지의 불량 패턴이 발생할 때
No
(아니오)
Yes
(예)
Classification
(지도학습 분류)
적합: 두 클래스(정상/비정상)의 데이터가 충분하여 명확한 경계를 가를 수 있을 때

비지도 이상탐지 성능비교

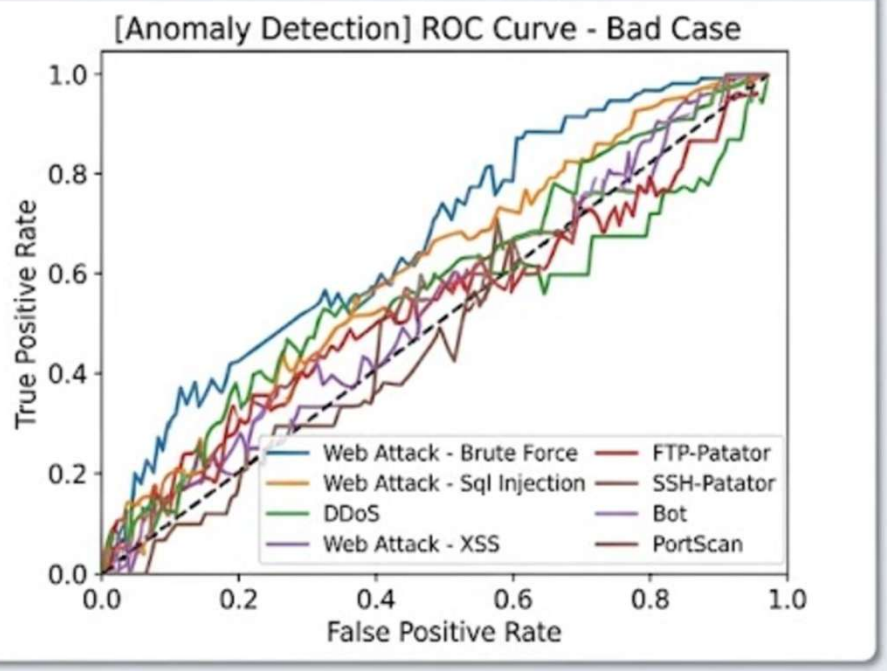
Performance comparison for network traffic anomaly detection (네트워크 트래픽 이상 탐지 성능 비교)

Good Case (우수 사례)



💡 **높은 탐지 성능 (High AUC): 대용량 트래픽 및 규칙적인 패턴을 가진 DoS 공격 등은 변칙 행동이 뚜렷하여 탐지가 매우 수월함.**

Bad Case (미흡 사례)

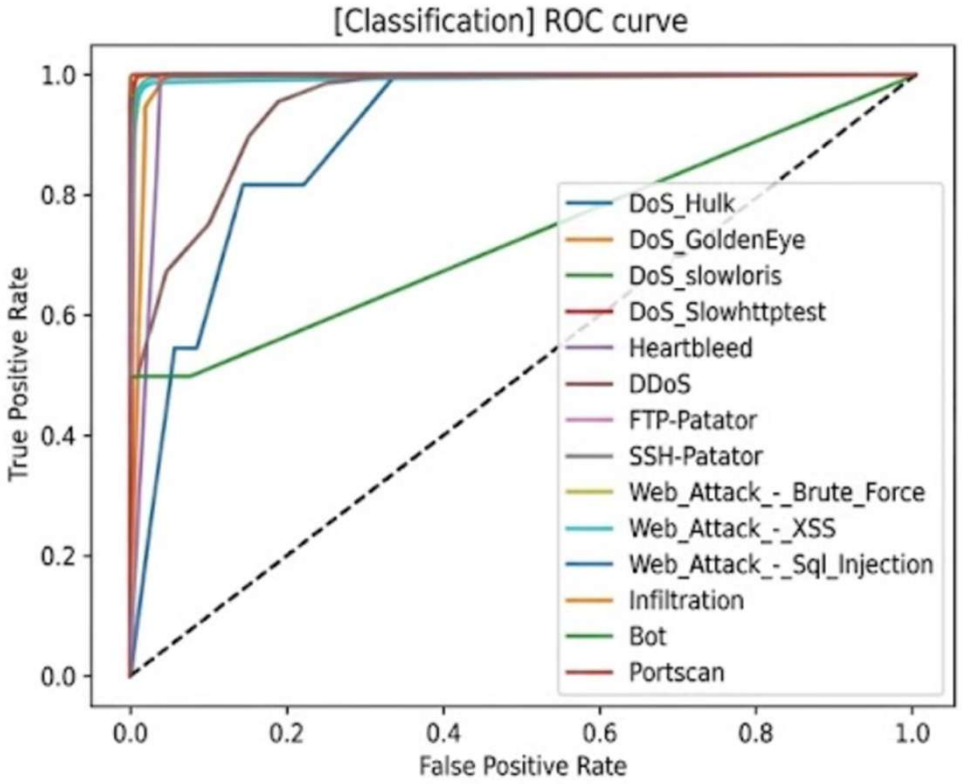


⚠️ **낮은 탐지 성능 (Low AUC): 웹 해킹, 브루트 포스 등 정상 트래픽과 패턴 구분이 어렵거나 데이터 불균형이 극심한 경우 탐지 성능이 크게 저하됨.**

지도학습 기반 이상탐지

Performance comparison for network traffic anomaly detection (네트워크 트래픽 성능 비교: 분류 기법)

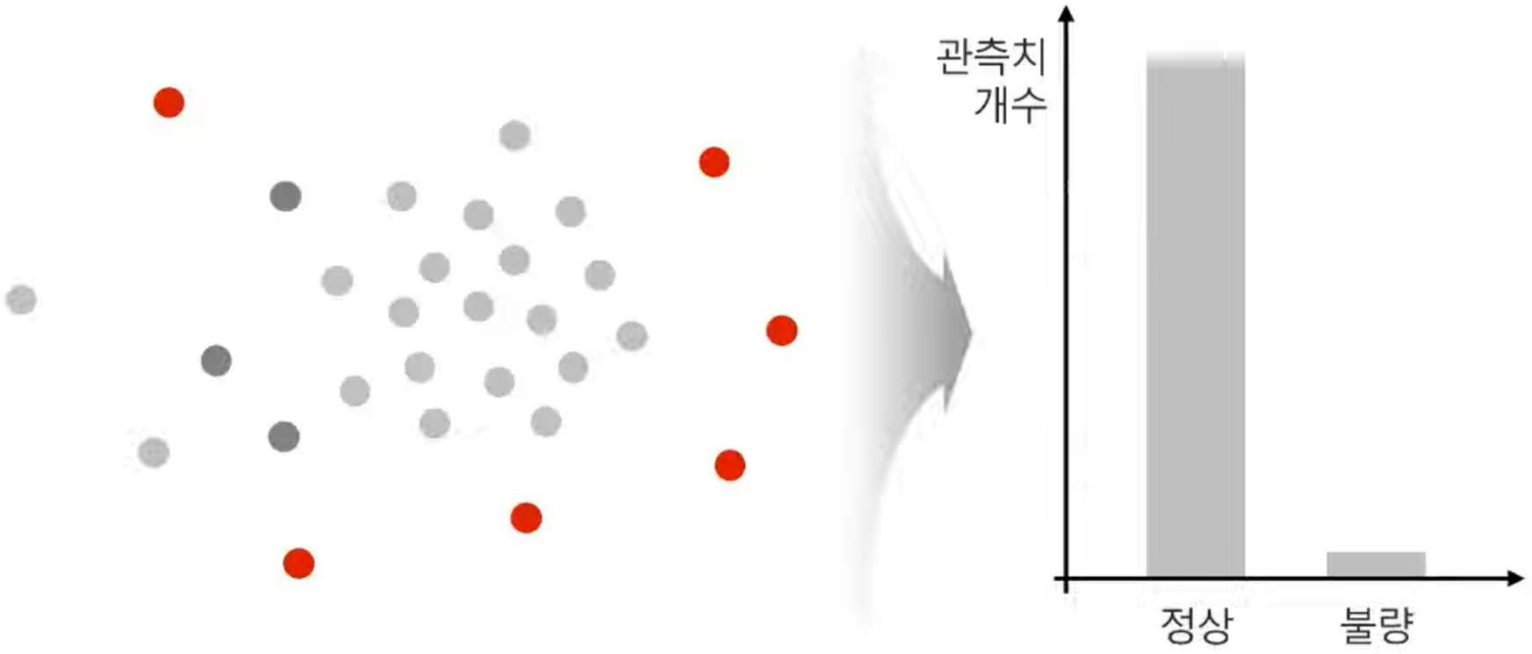
- **지도학습 기반 분류(Classification)의 성능 특징**
  - 🎯 **모든 클래스에서 압도적으로 우수한 성능 (High Performance Across All Classes)**
    - 정상과 다양한 공격 데이터를 모두 명확한 라벨(X+ & X−)로 지도학습(Supervised Learning)했기 때문에, 대부분의 공격 유형에서 ROC 곡선이 좌상단(Top-Left)에 매우 가깝게 위치함 (AUC ≈ 1.0에 근접).
- ⚖️ **Anomaly Detection과의 차이**
  - Anomaly Detection이 미흡한 성능을 보였던 웹 공격 (Web Attack), 브루트 포스, 무차별 대입(Patator) 등의 복잡한 패턴도 분류(Classification)는 사전에 패턴을 학습하여 완벽에 가깝게 탐지해 냄.
- ⚠️ **단점 (Limitations)**
  - 새로운 유형의 공격(미지의 변칙 패턴)이 발생할 경우, 학습 데이터에 없었기 때문에 탐지하지 못하고 오분류할 위험이 큼.



이상치 탐지 알고리즘

- 이상치(Anomaly) 데이터를 탐지하기 위한 알고리즘
- 활용 데이터는 일반적으로 다수의 정상 데이터와 소수의 이상치 데이터로 구성

  ⇒ (심한) 불균형



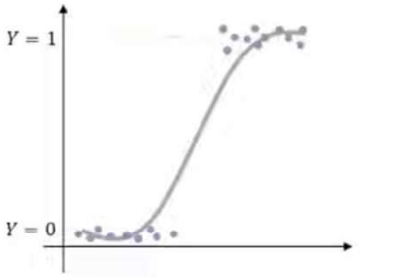
이상치 탐지 알고리즘

- 다수의 정상 데이터와 소수의 이상치 데이터를 구분하는 **지도학습 기반 분류 모델**을 적용한다면?
- 클래스 불균형이 심하기 때문에, 이상치 데이터를 올바르게 구분하기 어려움 (대부분 정상으로 예측하는 오류를 범함)

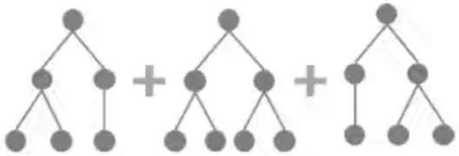
분류 모델 적용 결과

입력 데이터

X1	...	Xn
2	...	3
4	...	3
5	...	6
4.8	...	5
...	...	...
3	...	4
6	...	8



로지스틱 회귀 분석



그래디언트 부스팅

예측된 출력 변수

$\hat{Y}$
정상
정상
정상
정상
...
정상
정상

출력 변수

Y
정상
정상
불량
정상
...
정상
불량

이상치 탐지 알고리즘

❖ 다수의 정상 데이터와 소수의 이상치 데이터를 구분하기 위하여 **정상 데이터만으로 학습**하여 이상치 데이터를 탐지할 수 있는 **알고리즘**이 제안됨

입력 데이터 출력 변수

X1	...	Xn	Y
2	...	3	정상
4	...	3	정상
5	...	6	불량
4.8	...	5	정상
...	...	...	...
3	...	4	정상
6	...	8	불량

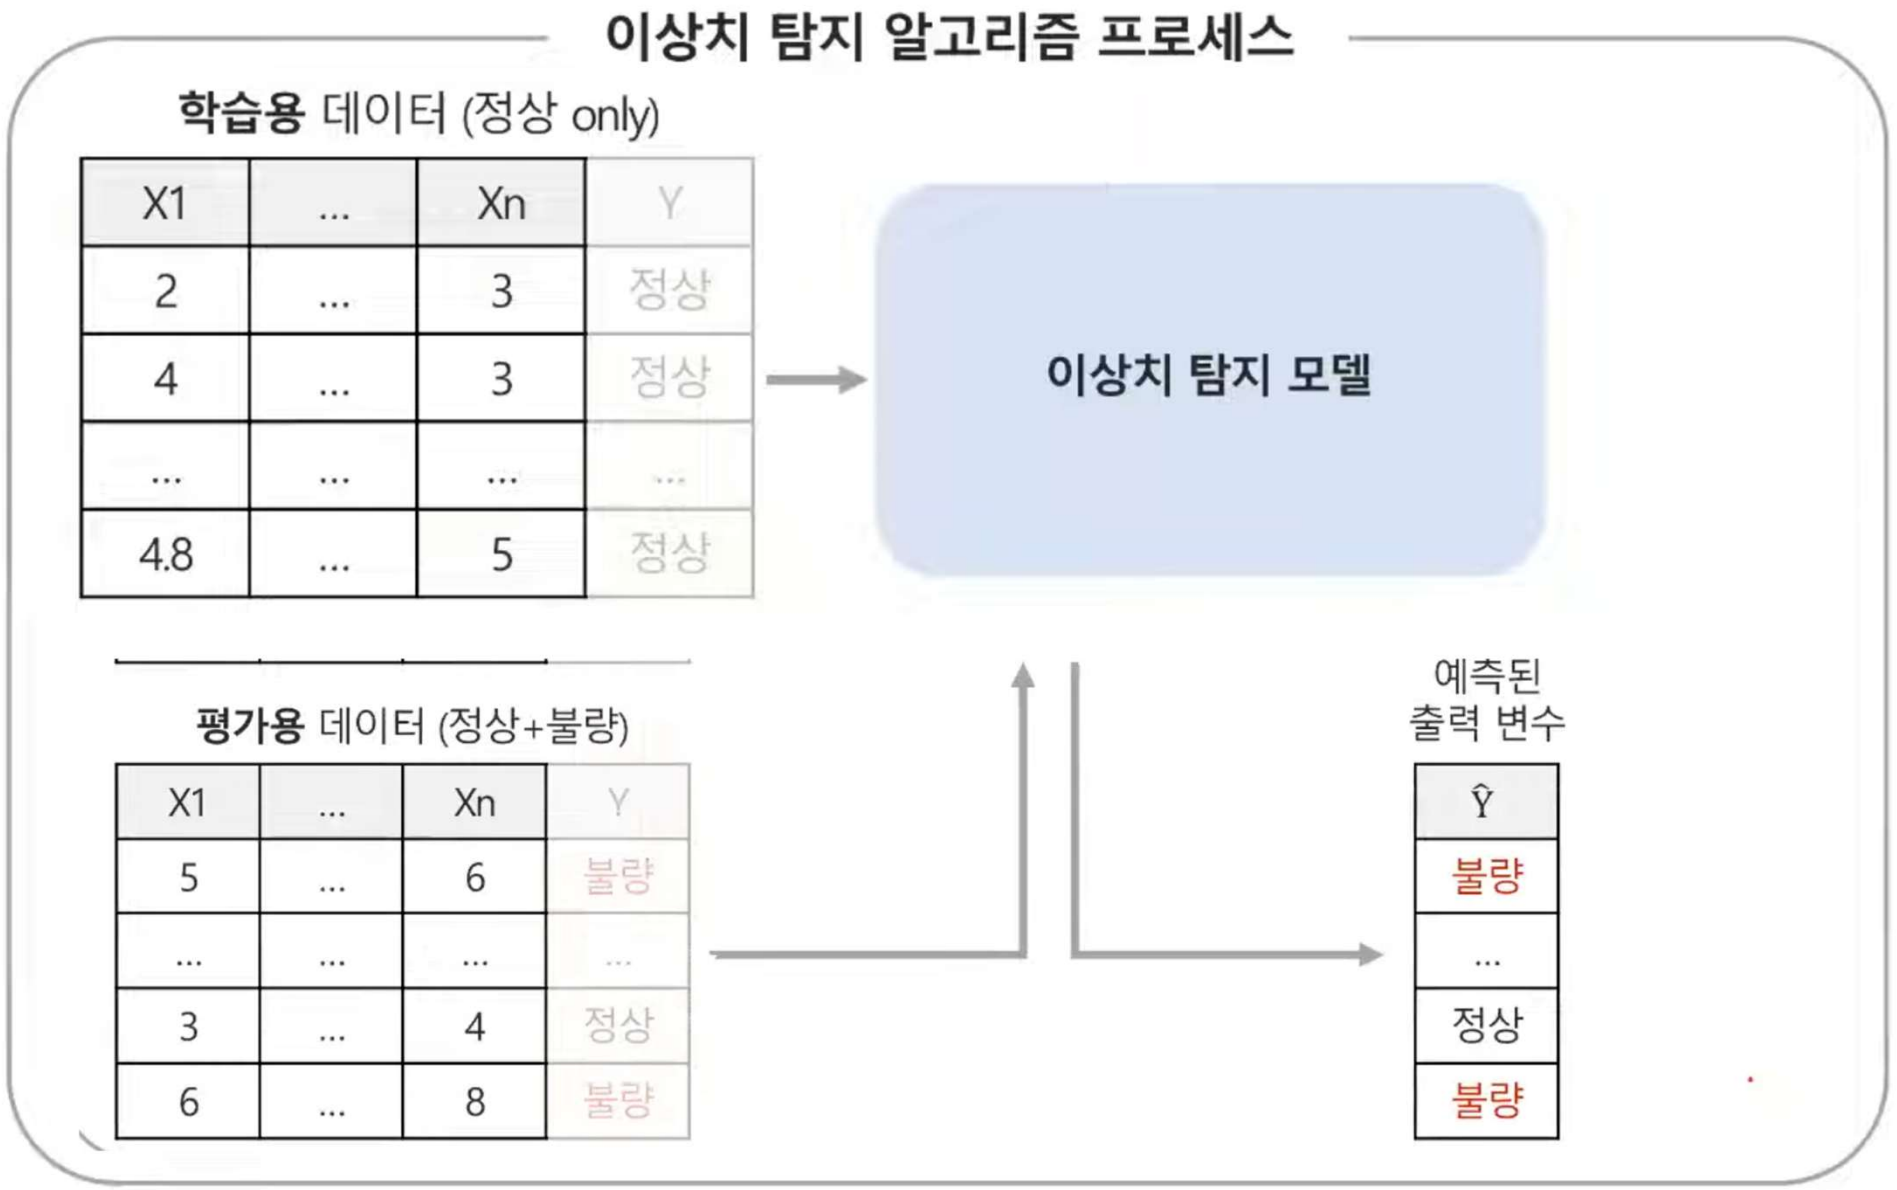
학습용 데이터 **(정상 only)**

X1	...	Xn	Y
2	...	3	정상
4	...	3	정상
...	...	...	...
4.8	...	5	정상

평가용 데이터 (정상+불량)

X1	...	Xn	Y
5	...	6	불량
...	...	...	...
3	...	4	정상
6	...	8	불량

이상치 탐지 알고리즘


이상치 탐지 알고리즘 프로세스
학습용 데이터 (정상 only)
X1 ... Xn Y
2 ... 3 정상
4 ... 3 정상
... ...
4.8 ... 5 정상
이상치 탐지 모델
평가용 데이터 (정상+불량)
X1 ... Xn Y
5 ... 6 불량
... ...
3 ... 4 정상
6 ... 8 불량
예측된
출력 변수
Ŷ
불량
...
정상
불량

이상치 탐지 알고리즘

□ **언제 이상치 탐지 알고리즘 사용?**

- 정상 데이터만 있고 이상치 데이터는 없는 경우 (평가는 어려움)
- 정상 데이터는 충분히 있으나 이상치 데이터가 극소수인 경우

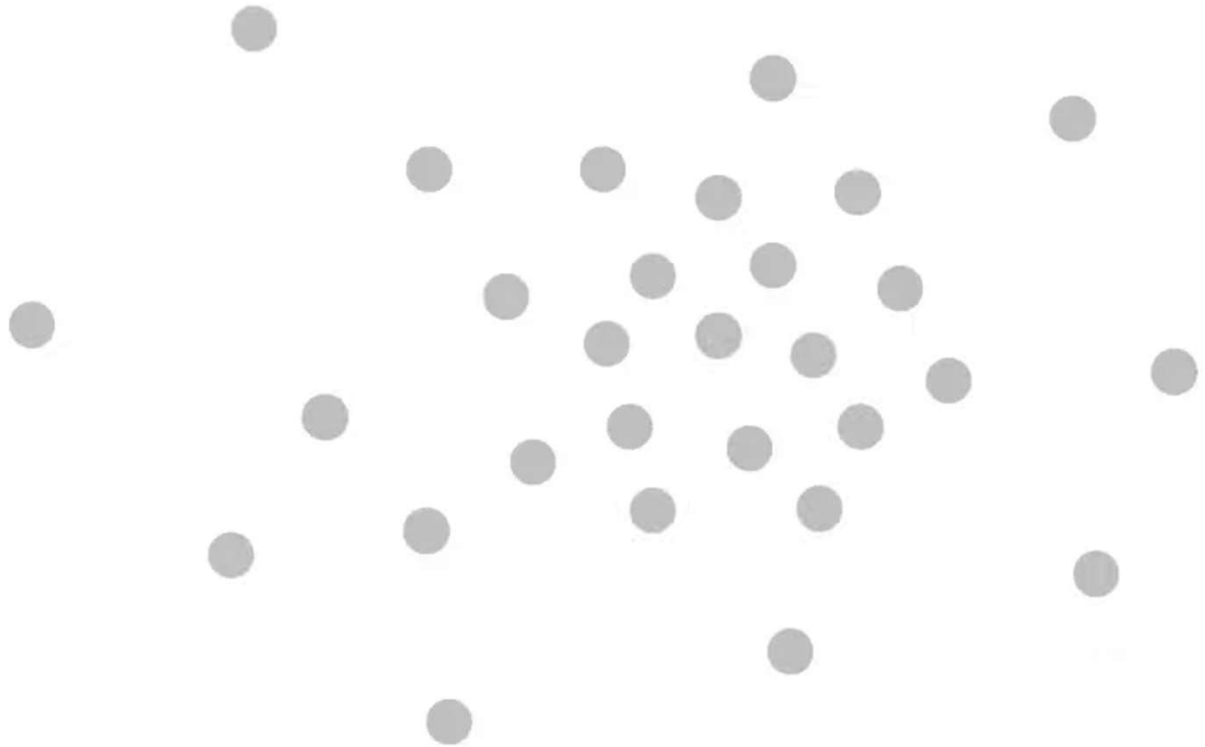
□ **이상치 탐지 알고리즘 이슈**

- 정상 데이터를 정의하기 어려운 경우가 많음
- 이상치는 탐지하나 어떤 종류의 이상치 인지는 모름 (이상치 종류 多)

  ⇒ 별도의 사후분석(pose-hoc analysis) 필요

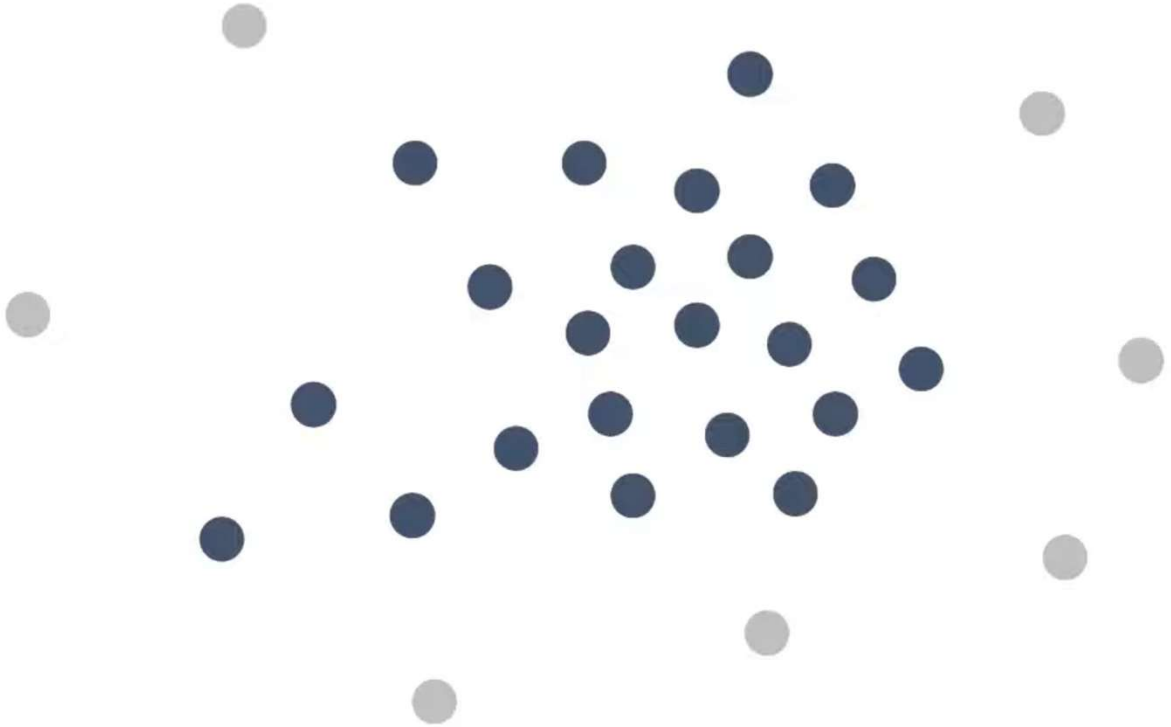
밀도 기반 이상치 탐지 알고리즘

- 정상 데이터로부터 추정된 **밀도**를 기반으로 각 객체의 정상/이상 여부를 판단하는 방법론



밀도 기반 이상치 탐지 알고리즘

❖ 정상 데이터로부터 추정된 **밀도**를 기반으로 각 객체의 정상/이상 여부를 판단하는 방법론



밀도 있게 **뭉쳐 있는 관측치**들 ⇒ 정상 관측치로 예측

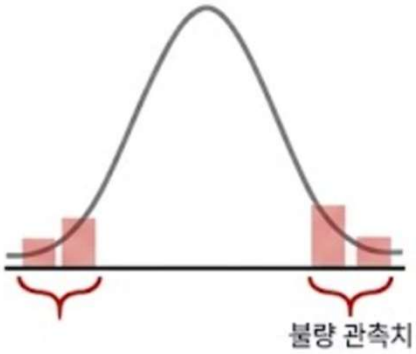
밀도 기반 이상치 탐지 알고리즘

❖ 정상 데이터로부터 추정된 밀도를 기반으로 각 객체의 정상/이상 여부를 판단하는 방법론

❖ 밀도를 추정하기 위한 다양한 방법론

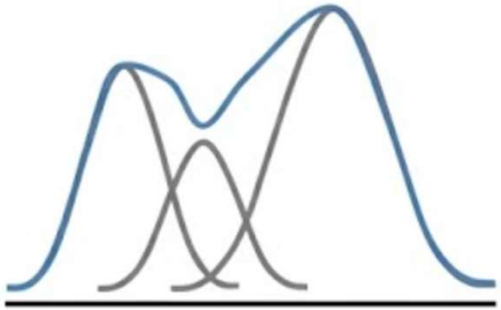
Gaussian Density Estimation

가우시안 밀도 추정



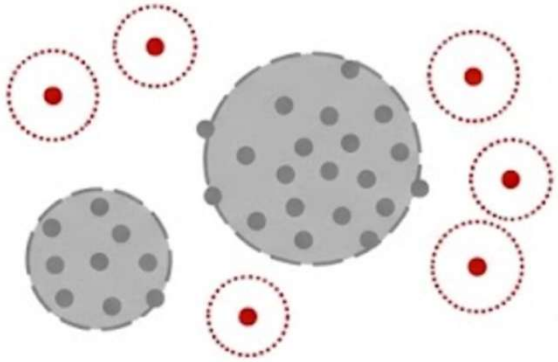
Mixture of Gaussian Density Estimation

가우시안 혼합 모델 밀도 추정



Local Outlier Factor

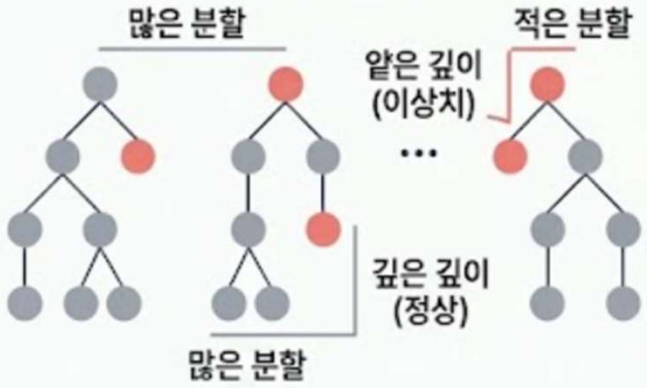
국소 이상치 계수 (LOF)



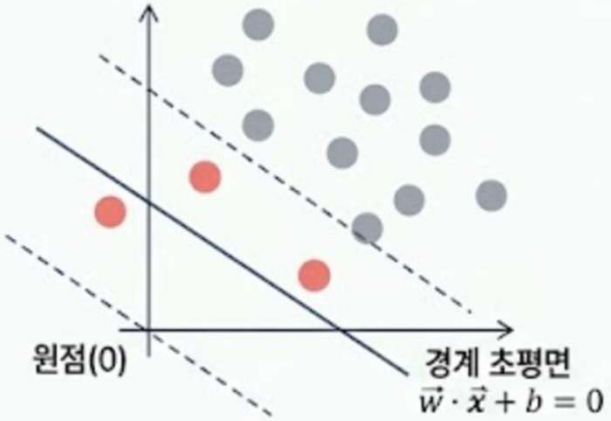
모델 기반 이상치 탐지 알고리즘

❖ 정상 데이터로부터 학습한 모델을 기반으로 각 객체의 정상/이상 여부를 판단하는 방법론

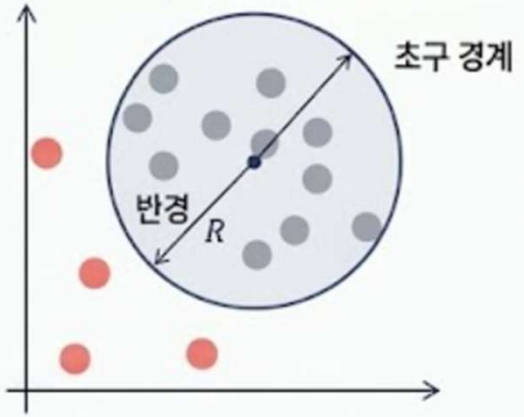
Isolation Forest
(아이솔레이션 포레스트)



One-Class SVM
(원클래스 SVM)



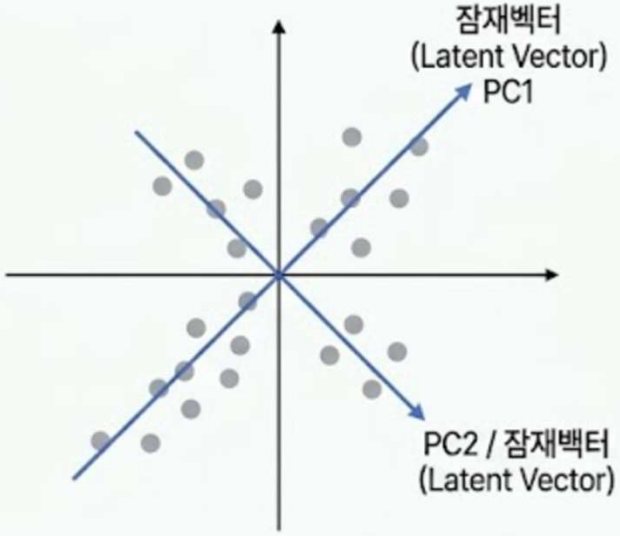
Support Vector Data Description (SVDD)



재구성 오차 기반 이상치 탐지 알고리즘

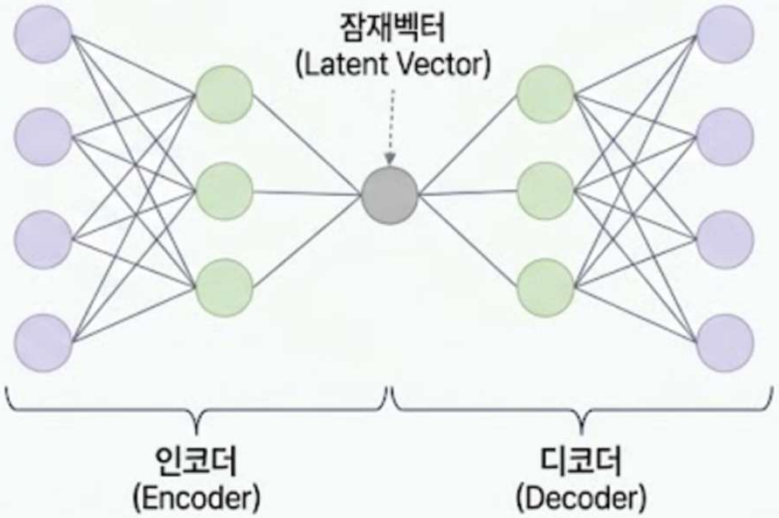
❖ 특징을 요약할 수 있는 feature extraction 방법론

Principal Component Analysis (PCA)
주성분 분석



Principal Component Analysis (PCA)

Autoencoder
오토인코더



Autoencoder

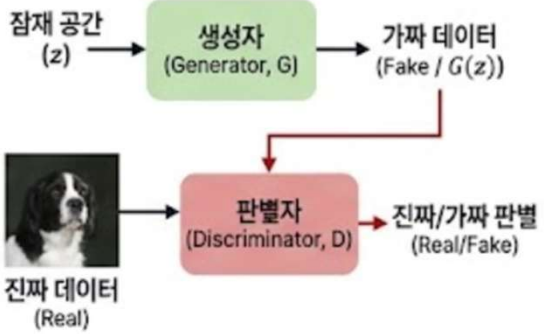
생성적 적대 신경망 기반 이상치 탐지 알고리즘

❖ 정상 데이터의 분포를 모사하는 생성 모델을 기반으로 각 객체의 정상/이상 여부를 판단하는 방법론

❖ 생성 및 복원 능력을 평가하기 위한 다양한 방법론

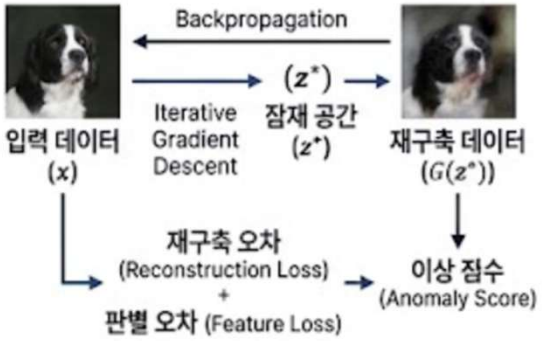
Generative Adversarial Network (GAN)

생성적 적대 신경망 개념



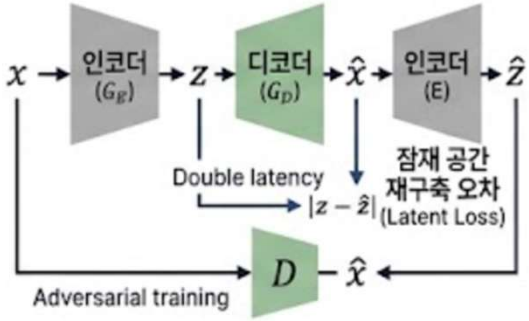
AnoGAN

잠재 공간 탐색을 통한 이상탐지



GANomaly

인코더-디코더-인코더 기반 이상탐지



시계열 이상탐지 성능지표

❖ 탑티어 SOTA 모델 검증 및 연구 무결성을 위한 표준 평가 체계

① F_1-Score, Precision, Recall

기본 분류 성능 (Threshold-dependent)

- 극단적 불균형 데이터셋에서 모델의 오경보(FP, False Positive)와 미탐지(FN, False Negative) 간의 균형을 평가하는 대표적인 지표
- 정밀도(Precision): 탐지한 것 중 실제 이상치 비율 / 재현율(Recall): 실제 이상치 중 탐지한 비율

② AUPRC (PR-AUC)

정밀도-재현율 곡선 영역 (Threshold-independent)

- 이상치(소수 클래스) 탐지에만 엄격하게 초점을 맞춰 모델을 매우 냉정하게 평가하며, 불균형 데이터셋에 특화된 핵심 지표
- 임계치(Threshold) 설정에 무관하게 모델 자체의 순수한 탐지 능력을 평가할 수 있어 SOTA 연구에서 필수적으로 요구됨

③ AUROC (ROC-AUC)

수신자 판단 특성 곡선 영역 (Threshold-independent)

- 정상과 비정상 데이터를 점수(Score) 순으로 정렬할 때 모델의 기초적인 변별력(Ranking)을 측정하며, 임계치 설정에 무관한 지표
- 전통적인 통계적 판단 기준으로 널리 쓰이나, 정상 데이터가 압도적으로 많은 불균형 시계열에서는 수치가 과장될 수 있어 AUPRC와 병행함

④ 시계열 구간/이벤트 연속성 지표

사건 및 연속 구간 평가 (Event / Range-based)

- 단순 점(Point) 단위 평가를 넘어 시계열 사건의 연속적 성격을 반영하는 최신 검증 지표
- Affiliation F1, VUS-PR, Range-based F1 (R-F1) 등, 예측구간과 실제구간 사이의 시간적 거리를 고려하여 평가의 객관성을 크게 높임

⚠ **[Point Adjustment (PA) 적용 시 무결성 검증 주의사항]**

시계열 이상 구간 중 한 지점만 맞춰도 전체를 정답 처리하는 PA 기법은 F1-Score를 과도하게 부풀리는(Overestimation) 딜레마가 있습니다.
연구의 신뢰성을 위해 학계 표준에 따라 PA를 적용한 결과(With PA)와 미적용한 결과(Without PA)를 반드시 나란히 병기하여 대조 검증해야 합니다.

프로젝트 3. 이상탐지 모델 적용, 성능 최적화

구분	수행 내용	학습 목표
1. 데이터 분석	• 데이터셋: SKAB • 데이터 특성 분석 및 전처리	산업 시계열 데이터의 특성을 이해하고, 분석 결과를 바탕으로 이상탐지 문제 정의
2. 이상탐지 모델 설계 및 구현	• 지도·비지도 등 학습 방식 자율 선택 • 서로 다른 접근 방식의 모델 2종 이상 구현 및 비교	데이터 특성에 적합한 모델을 선정하고, 이상탐지 모델을 설계·구현하여 성능 비교
3. 성능 개선 및 최적화	• 성능 평가지표: 최소 3개 • 성능 개선을 위한 실험 자율 설계 및 수행	다양한 실험을 통해 탐지 성능을 개선하고, 최적화 방법의 효과 검증
4. 결과 분석 및 해석	• 모델별 성능 평가 및 결과 분석 • 성능 개선 효과 및 한계 분석	객관적인 성능 비교와 결과 해석을 통해 모델의 특성 및 연구적 시사점 도출

**모델 학습에 라벨을 사용했는지 명확하게 밝힐 것