

[현장 발표 큐시트] 제조 설비 고장 예측 머신러닝 5 단계 실증

• 과목: 어프렌티스 프로젝트 1 (채민선 교수님) | • 발표자: 석사과정 진찬언 (एको프로 HN) | • 발표 제한시간: 5 분 이내
(목표: 3 분 50 초)

1. 5 분 발표 타임라인 배분표 (3 분 50 초 완벽 통제)

슬라이드	핵심 주제	시간 배분	누적 시간	발표 핵심 및 교수님 질문 방어 포인트
1 번 표지	연구 개요 및 5 단계 완수	약 30 초	0:00 ~ 0:30	공작기계 센서 실측 데이터 기반 5 대 핵심 절차 완수 소개
2 번 슬라이드	1 단계: 데이터셋 & 문제정의	약 40 초	0:30 ~ 1:10	3.4% 희소 불균형, 센서 스케일 편차, 물리 파생 특성 3 종
3 번 슬라이드	2 단계: 데이터 분할 비교	약 45 초	1:10 ~ 1:55	2 분할(정보누수/급락) vs 3 분할(6:2:2 증화/86.8% 실전 성능)
4 번 슬라이드	4 단계: 스케일링 & 누수방지	약 45 초	1:55 ~ 2:40	로버스트 스케일러(이상치 방어) + Train fit 단방향 변환 원칙
5 번 슬라이드	3 단계: 하이퍼파라미터 튜닝	약 40 초	2:40 ~ 3:20	트리 깊이 10 규제 + 임계값 0.35 -> 재현율 50%에서 86.8%로 급증
6 번 슬라이드	5 단계: 최종평가 & 총괄결론	약 40 초	3:20 ~ 4:00	시험셋 1 회 블라인드 검증, 고장 68 건 중 59 건 적중, 5 대 미션 완료

[슬라이드 1] 표지: 제조 설비 고장 예측 머신러닝 실증 (약 30 초 소요 | 0:00 ~ 0:30)

• 핵심 포인트: 프로젝트 목적, 5 대 머신러닝 절차 실증, 발표 흐름 안내

📌 [실제 발표 대본] (차분하고 또박또박한 어조로)

"안녕하세요. 어프렌티스 프로젝트 1 발표를 맡은 진찬언입니다. 저는 이번 과제에서 실제 공작기계 센서 데이터를 바탕으로, 수업 시간에 배운 머신러닝 5 대 핵심 절차를 직접 구현하고 검증했습니다. 발표는 데이터 정의부터 검증셋 분리의 필요성, 스케일링에서의 데이터 누수 방지, 하이퍼파라미터 튜닝 효과, 그리고 최종 시험 평가까지 순서대로 말씀드리겠습니다."

👉 현장 행동 지침: 청중과 눈을 맞추며 또박또박 인사 후, 하단 4 대 배지(분할, 스케일러, 누수차단, 블라인드 검증)를 가볍게 언급하며 슬라이드를 넘깁니다.

[슬라이드 2] 1 단계: 데이터셋 획득 및 문제 정의 (약 40 초 소요 | 0:30 ~ 1:10)

• **핵심 포인트:** 1 만 건 로그, 3.4% 희소 불균형, 센서 단위 편차, 물리 파생 특성 3 종(온도차/동력/공구부하)

🔥 [실제 발표 대본] (차분하고 또박또박한 어조로)

"첫 번째로 데이터와 예측 문제입니다. 사용한 데이터는 공작기계 센서 로그 1 만 건이며, 가공 중 고장 여부를 사전에 감지하는 이진 분류 과제입니다. 왼쪽 차트를 보시면 고장률이 3.4%에 불과한 희소 불균형 데이터이고, 회전수와 토크, 온도 등 센서별 수치 범위 편차가 매우 큼니다. 이러한 한계를 극복하기 위해 설비 방열과 동력, 공구 피로를 반영한 물리 파생 특성 3 가지를 추가하여 고장 판별력을 확보했습니다."

📌 **현장 행동 지침:** 왼쪽 도넛 차트(3.4% 고장률)와 수평 막대(회전수 2,886 vs 토크 76)를 지목하며 센서 스케일 차이가 큼을 시각적으로 짚어줍니다.

[슬라이드 3] 2 단계: 데이터 분할 및 비교 실험 (검증셋 유무) (약 45 초 소요 | 1:10 ~ 1:55)

• **핵심 포인트:** 교수님 핵심 질문: 검증 데이터 유무에 따른 차이 입증, 2 분할(정보누수/급락) vs 3 분할(6:2:2 층화/86.8% 안정)

🔥 [실제 발표 대본] (차분하고 또박또박한 어조로)

"두 번째로 데이터 분할과 검증셋의 필요성입니다. 왼쪽 그래프를 보시면 검증셋 없이 학습과 시험을 8 대 2 로 나누면, 시험 데이터를 보면서 모델을 고치게 되어 시험 점수는 높게 나와도 실전에서 성능이 급락합니다. 반면 학습 60, 검증 20, 시험 20 으로 3 단계 층화 분할을 하면, 검증셋으로만 파라미터를 튜닝하고 시험셋은 온전히 보존할 수 있어 정직한 실전 성능을 측정할 수 있었습니다."

📌 **현장 행동 지침:** 왼쪽 막대 그래프의 붉은색 '실전 급락 위험' 배지와 녹색 '정직한 성능 86.8% 유지' 배지를 명확히 대비하여 강조합니다.

[슬라이드 4] 4 단계: 데이터 스케일링 비교 및 데이터 누수 방지 (약 45 초 소요 | 1:55 ~ 2:40)

• **핵심 포인트:** 스케일러 3 종 비교(이상치 왜곡 92% vs 8%), 로버스트 선정, Train fit 단방향 변환 원칙

🔑 [실제 발표 대본] (차분하고 또박또박한 어조로)

"네 번째로 데이터 스케일링과 누수 방지입니다. 왼쪽 차트처럼 모터 기동 시 발생하는 토크 이상치 때문에, MinMax 나 Standard 는 데이터 왜곡이 심합니다. 따라서 중앙값과 사분위수를 쓰는 로버스트 스케일러를 채택했습니다. 또한 스케일러 기준값은 오직 학습 데이터 60%에서만 계산하고, 검증과 시험 세트에는 변환만 적용하여 미래 정보가 학습에 유출되는 데이터 누수를 완전히 막았습니다."

📌 **현장 행동 지침:** 왼쪽 파이프라인 도식의 'Train fit → Valid/Test transform ONLY' 화살표를 손으로 짚으며 교수님 강조 원칙을 지켰음을 어필합니다.

[슬라이드 5] 3 단계: 하이퍼파라미터 조정 및 과적합 제어 (약 40 초 소요 | 2:40 ~ 3:20)

• **핵심 포인트:** 교수님 핵심 질문: 조정이 왜 필요한가? 트리 깊이 10 규제 + 임계값 0.35 하향 -> 재현율 50%에서 86.8% (+36.8%p)

🔑 [실제 발표 대본] (차분하고 또박또박한 어조로)

"세 번째로 하이퍼파라미터 튜닝입니다. 랜덤 포레스트 모델에서 트리 깊이와 분류 임계값을 검증셋 기준으로 튜닝했습니다. 깊이 제한이 없으면 학습 데이터는 100% 다 맞지만 정작 희소 고장 재현율은 50%에 그칩니다. 왼쪽 차트처럼 트리 깊이를 10 으로 규제해 과적합을 잡고, 결정 임계값을 0.35 로 조정한 결과, 고장 재현율이 50%에서 86.8%로 36.8%p 대폭 향상되었습니다."

📌 **현장 행동 지침:** 차트 상단의 붉은색 '+36.8%p ↑' 캡슐 배지를 강하게 가리키며, 불균형 데이터에서 임계값 조정의 강력한 효과를 수치로 각인시킵니다.

[슬라이드 6] 5 단계: 최종 성능 평가 및 결론 (약 40 초 소요 | 3:20 ~ 4:00)

• **핵심 포인트:** 시험셋 2,000 건 블라인드 1 회 검증 실측치, 혼동행렬(59/68 적중), 5 대 미션 완수

📌 [실제 발표 대본] (차분하고 또박또박한 어조로)

"마지막 5 단계 최종 평가와 결론입니다. 모든 튜닝을 마친 뒤, 밀봉해 두었던 2 천 건의 시험 데이터를 단 한 번 평가했습니다. 왼쪽 혼동 행렬을 보시면 실제 고장 68 건 중 59 건을 성공적으로 검출하여 재현율 86.8%, F1 점수 0.868, ROC-AUC 0.986 을 기록했습니다. 이로써 검증셋 분리, 스케일링 누수 방지, 파라미터 튜닝이라는 머신러닝 5 대 핵심 절차를 성공적으로 완수했습니다. 경청해 주셔서 감사합니다."

👉 **현장 행동 지침:** 우측 상단 2 단 KPI 대시보드(정확도 99.1%, 재현율 86.8%, F1 0.868, AUC 0.986)를 차례로 짚은 뒤 정중하게 목례합니다.

📊 발표 현장 핵심 실측 수치 암기 카드 (Numbers At A Glance)

데이터 총 규모 10,000 건	고장 건수 / 비율 339 건 (3.39%)	결측치 현황 0 건 (완전성 확보)	데이터 분할 비율 학습 60 : 검증 20 : 시험 20
최종 정확도 99.10%	최종 정밀도 86.76%	최종 재현율 86.76%	최종 F1-Score 0.8676
최종 ROC-AUC 0.9859	최적 임계값 0.35 (기본 0.50)	재현율 개선폭 50.0% -> 86.8% (+36.8%p)	시험셋 고장 검출 68 건 중 59 건 적중

3. 질의응답(Q&A) 완벽 방어 치트시트 (나에게 들어올 예상 질문 4 선)

교수님 또는 동료 질문 시: 먼저 '10 초 핵심 요약'으로 결론을 제시하고, '30 초 상세 논리'로 썰기를 박습니다.

Q1. 고장률이 3.4%밖에 안 되는데, SMOTE 같은 오버샘플링을 쓰지 않고 임계값(0.35) 조정을 택한 이유는?

🔊 10 초 핵심 요약: 공작기계 센서의 물리 법칙을 훼손하지 않고, 제조 현장의 미감지 비용을 최소화하기 위해서입니다.

- 상세 설명: 공작기계 센서는 온도, 토크, 회전수가 맞물리는 물리적 연속성을 가집니다. SMOTE 로 가상 데이터를 합성하면 '회전수는 0 인데 토크가 최대'와 같은 비물리적 노이즈가 유입될 위험이 있습니다. 따라서 원천 데이터의 물리적 정합성을 100% 보존하면서, 현장에서 치명적인 고장 미감지를 방지하기 위해 검증셋 기준으로 결정 임계값을 0.35 로 낮추어 재현율 86.8%를 확보했습니다.

Q2. 랜덤 포레스트 트리 깊이를 10 으로 제한한 객관적 기준은 무엇인가요?

🔊 10 초 핵심 요약: 검증 세트의 F1 점수와 과적합 격차를 모니터링하여 최적의 일반화 균형점을 찾았습니다.

- 상세 설명: 트리 깊이 제한이 없을 때는 학습 정확도 100% 대비 과적합 격차가 38%에 달해 노이즈까지 외우는 문제가 있었습니다. 깊이를 4, 6, 8, 10 으로 탐색한 결과, 깊이 10 에서 학습과 검증 세트 간 성능 격차가 9.3%로 안정화되면서도 복잡한 물리 결합 특성을 충분히 학습할 수 있는 최적의 균형점으로 확인되어 선정했습니다.

Q3. StandardScaler 대신 RobustScaler 를 선택한 물리적 이유는 무엇인가요?

🔊 10 초 핵심 요약: 모터 급기동 시 발생하는 일시적 토크 스파이크(이상치)에 전체 스케일 기준이 왜곡되는 것을 막기 위함입니다.

- 상세 설명: 공작기계 모터는 시동 시 일시적으로 토크가 최대 76.6Nm 까지 튀는 이상치가 존재합니다. StandardScaler 는 평균과 표준편차를 쓰기 때문에 극단 이상치 하나에 전체 스케일이 흔들립니다. 반면 RobustScaler 는 중앙값과 IQR(사분위범위)을 기준으로 하므로, 이상치 노이즈를 완벽히 방어하고 정상 50% 영역의 신호 해상도를 온전히 보존할 수 있습니다.

Q4. 데이터 누수(Data Leakage)를 코드로 어떻게 방지했는지 구체적으로 설명해주세요.

🔊 10 초 핵심 요약: 스케일러의 fit 은 오직 Train(60%)에서만 수행하고, Valid 와 Test 에는 transform 만 적용했습니다.

- 상세 설명: 전체 데이터에 fit_transform 을 먼저 적용하고 분할하면 미래 시험 데이터의 평균과 중앙값이 학습에 섞여 들어가는 전형적인 데이터 누수가 발생합니다. 이를 막기 위해 데이터를 먼저 3 단계로 엄격히 분할한 뒤, 오직 학습 데이터로만 스케일러 기준값을 산출하고 검증과 시험 세트에는 그 기준값을 변환만 적용하여 실전 격리 원칙을 완벽히 준수했습니다.

4. 9월 16일 동료 리뷰어 등록용 핵심 질문 3선 (변별력 확보)

채민선 교수님 지침: '최소 3개 이상의 질문 의무 등록', '질문 수준에 따라 본인이 돋보일 수 있다.'
아래 3개 질문을 동료 학생의 발표 게시물에 남기시면 변별력을 확실하게 인정받으실 수 있습니다.

질문 1 [데이터 누수 검증 / 가장 치명적인 질문]

"발표 잘 들었습니다. 데이터 전처리하실 때 스케일러를 전체 데이터에 먼저 적용하고 나누셨는지, 아니면 학습 데이터로만 기준값(fit)을 산출하고 검증과 시험 데이터에는 변환(transform)만 적용하셨는지 궁금합니다."

📌 질문 의도: 머신러닝 실무에서 가장 흔하게 범하는 데이터 누수(Data Leakage)를 제대로 알고 방어했는지 짚어내는 수준 높은 질문입니다.

질문 2 [검증셋 유무 비교 / 2단계 과제 핵심 연계]

"2단계 미션에서 검증 데이터가 없을 때와 있을 때의 차이를 분석하셨는데, 검증 데이터가 없을 때는 모델 하이퍼파라미터를 어떤 기준으로 조정하셨고, 그로 인해 시험 데이터에 어떤 오버피팅 현상이 나타났는지 궁금합니다."

📌 질문 의도: 검증 데이터의 존재 목적(오버피팅 방지 및 객관적 일반화 평가)을 명확히 이해하고 있는지 확인하는 질문입니다.

질문 3 [불균형 데이터 분할 / 제조 도메인 연계]

"제조 데이터 특성상 불량 데이터가 매우 희소했을 텐데, 데이터를 학습과 시험으로 나누실 때 일반 무작위 분할을 하셨는지, 아니면 불량 비율을 세 세트에 균등하게 맞춰주는 층화 분할(Stratified Split)을 적용하셨는지 궁금합니다."

📌 질문 의도: 불균형 제조 데이터셋에서 단순 무작위 분할 시 발생하는 타겟 누락 문제를 층화 분할로 해결했는지 묻는 질문입니다.

☑ 발표 직전 1분 최종 점검 체크리스트

- ☐ 발표 제한 시간은 5분 엄수이며, 준비된 대본은 3분 50초 템포로 여유 있게 마무리됩니다.
- ☐ 말이 빨라지지 않도록 호흡을 가다듬고, 슬라이드 간 전환 시 1초간 침묵(Pause)을 유지합니다.
- ☐ 차트의 수치(99.1%, 86.8%, 0.868, 0.986)를 언급할 때 손으로 해당 배지를 정확히 짚어줍니다.
- ☐ 질문을 받으면 당황하지 않고 '좋은 질문 감사드립니다'로 시작해 10초 요약 답변을 먼저 말합니다.