

제조 가공 설비 고장 예측 프로젝트 — 동료 질의응답 구두 대본

발표자: 진찬언 (에코프로에이치엔) | 질의자: 이은용 님 | 지도교수: 채민선 교수님

[질문 1] 스케일러별 성능 차이 및 이상치 취약도 비교

"실제로 코드를 돌려보면 스케일러를 안 쓰든, MinMax 나 Standard, Robust 를 쓰든 검증 점수는 100% 똑같이 나옵니다. 이번에 쓴 랜덤 포레스트 같은 트리 모델은 숫자의 크기가 아니라 데이터의 '순서'만 보고 쪼개기 때문에, 스케일링을 해도 결과가 바뀌지 않는 게 정상이고요.

장표에서 비교한 건 모델 점수가 아니라, 모터가 급기동할 때 토크가 76Nm 까지 튀면서 정상 구간(30~50Nm)이 찌그러지는 '데이터 분포 왜곡'을 본 것입니다. 나중에 신경망 같은 거리 기반 모델로 확장할 때 생길 왜곡을 미리 막으려고 RobustScaler 를 골랐습니다."

[질문 2] 검증-시험 성능 수치 관계 및 표본 변동성 대책

"5 페이지의 86.8%는 최종 시험 실측치인 86.76%를 보기 편하게 소수점 첫째 자리로 반올림해 적은 것입니다.

실제 튜닝은 검증 데이터에서 임계값을 0.35 로 맞추며 먼저 끝냈고요(재현율 80.9%), 마지막에 밀봉해 둔 시험 데이터로 딱 한 번 평가해서 86.8%가 나온 거라 시험셋으로 튜닝한 건 아닙니다.

시험 데이터의 고장이 68 건뿐이라 1 건만 틀려도 1.5%p 씩 흔들리는 건 맞습니다. 그래서 점수 하나만 믿지 않고, 임계값과 상관없는 ROC-AUC(0.986)와 교차 검증을 함께 확인했습니다."

[질문 3] 도메인 파생 특성의 데이터 누수 여부 및 소거 실험 결과

"파생 변수는 정답 라벨이나 미래 데이터를 쓴 게 아니라, 가공 중에 실시간으로 찍히는 센서값들을 물리 공식(토크 × 속도 = 동력)으로 묶은 거라 데이터 누수가 아닙니다. 원래 설비는 복합 부하가 걸릴 때 고장 나니까요.

실제로 파생 변수를 완전히 빼고 원천 센서 5 개로만 돌려봐도 시험 재현율이 69.1%(AUC 0.981)가 나옵니다. 공식을 단순 암기한 게 아니라는 뜻이고요.

여기에 파생 변수를 더해주면 재현율이 86.8%로 17.6%p 더 오르는데, 트리가 일일이 쪼개기 힘든 물리적 곱셈 관계를 모델이 쉽게 이해하도록 도와줬기 때문입니다."