ISSN 3058-6003

INDAI 콜로키움 2026 논문집

Industrial AI Research Center Colloquium



일시 : 2026년 11월 2일 19:00~
장소 : 충북대학교 개신문화관

INDAI 충북대학교 산업인공지능연구센터

INDAI 콜로키움 2026 - 프로그램 세부일정

포스터 발표

19:15 - 19:30 Session 1: 창의자율과제 Chair : 김영진

순서	팀 명	이 름	지도교수
1	Bird Eye	김태현, 이범준, 이가진	김승구
2	Clothoid	윤수한, 정준범, 전양호	기석철
3	NaviScan	이전혁, 오현지, 송동건	박태형
4	오프롱	강한빈, 김민성, 정현일	박태형
5	RobotV	김수민, 김태우, 신재웅	황영배
6	엔젤	이재형, 이동헌, 손현택	윤재중
7	나로	서정훈, 정인수, 윤경민	유재수
8	천리안	차동현, 김상혁, 성우제	유재수
9	Ariadne	조태현, 김민규, 김여겸	문성태
10	멤리서치	서정무, 김재환, 이원표	김성진

19:30 - 20:00 Session 2: 산업인공지능학과 Chair : 김현진

순서	학 번	이 름	지도교수(공동 지도교수)
1	2025254001	노경진	강현수
2	2025254002	전양호	김성진
3	2025254003	이동채	문성태
4	2025254004	이한울	전명근
5	2025254005	이소현	전명근
6	2025254006	이경준	반유석
7	2025254007	남기현	최민
8	2025254008	곽소영	최민
9	2025254009	추정원	문성태
10	2025254010	송공호	박태형
11	2025254011	김완수	이의종
12	2025254012	이은혜	황영배
13	2025254013	송재익	유재수
14	2025254014	정회성	윤재중
15	2025254015	이일주	유재수
16	2025254016	이도현	황영배
17	2025254017	박성혁	류관희
18	2025254018	오지택	김형원
19	2025254019	안기현	류관희
20	2025254021	이원표	김성진
21	2025254022	이혜빈	강현수

INDAI 콜로키움 2026 논문집

2026년 11월 2일(월), 충북대학교 개신문화관

Session 1 : 창의자율과제

26INDAI_C001	단일 천장 영상의 관측 표면 BEV 기하 보정 Geometric Refinement of Observed-Surface BEV from a Single Ceiling Image 김태현, 이범준, 이가진, 김승구	/ 3
26INDAI_C002	추론형 자율주행 VLA의 Jetson Thor 경량화와 nusc_coc를 이용한 nuScenes 도메인 적응 Accelerating a Reasoning Driving VLA on Jetson Thor and Adapting It to nuScenes with Auto-Labeled CoC 윤수한, 정준범, 전양호, 기석철	/ 6
26INDAI_C003	관심 영역 추출을 이용한 핸드헬드 스캐너 기반 3차원 객체 검출 Handheld Scanner-Based 3D Object Detection Using Region-of-Interest Extraction 오현지, 이전혁, 송동건, 박태형	/ 11
26INDAI_C004	LiDAR 보정을 활용한 험지 이동로봇의 강인한 3차원 객체 검출 Robust 3D Object Detection for Rough-Terrain Mobile Robots Using LiDAR Compensation 강한빈, 김민성, 정현일, 박태형	/ 14
26INDAI_C005	의미적 장소 검색과 기하학적 검증을 이용한 UAV - UGV 위치추정 UAV - UGV Localization Using Semantic Place Retrieval and Geometric Verification 김수민, 김태우, 신재웅, 황영배	/ 18
26INDAI_C006	AI 기반 배터리 상태 추정 및 고장진단 알고리즘을 융합한 BMS 시뮬레이션 모델 개발 Development of a BMS Simulation Model Integrating AI-based Battery State Estimation and Fault Diagnosis Algorithms 이재형, 이동헌, 손현택, 윤재중	/ 22
26INDAI_C007	사용자 리뷰를 고려한 전자상거래 재구매 예측 모델 A User Review Aware Repurchase Prediction Model for E-Commerce 서정훈, 정인수, 윤경민, 유재수	/ 26
26INDAI_C008	학술 지식 네트워크 학습을 이용한 개인 맞춤형 미래 연구 주제 예측 Personalized Future Research Topic Prediction Using Academic Knowledge-Network Learning 차동현, 김상혁, 성우제, 송상호, 유재수	/ 29
25INDAI_C009	지하 재난 대응 드론을 위한 자기 교란 강인 UWB-IMU 융합 항법 연구 A Study on Magnetically Robust UWB-IMU Fusion Navigation for Underground Disaster Response Drones 조태현, 김민규, 김여겸, 문성태	/ 33
25INDAI_C010	산화물 반도체 소자의 특성 개선을 위한 IGZO 박막 제조 공정 연구 IGZO Thin-Film Fabrication Processes for Improving the Characteristics of Oxide Semiconductor Devices 서정무, 김재환, 이원표, 김성진	/ 39

INDAI 콜로키움 2026 논문집

2026년 11월 2일(월), 충북대학교 개신문화관

Session 2 : 산업인공지능학과

26INDAI_D001	정찰 드론 영상에서 적 전차 탐지 및 식별을 위한 합성데이터 기반 딥러닝 모델의 성능 평가 Performance Evaluation of Synthetic-Data-Based Deep Learning Models for Enemy Tank Detection and Identification in Reconnaissance Drone Imagery 노경진, 김영진, 강현수	/ 45
26INDAI_D002	원격주행을 위한 딥러닝 기반 적응형 카메라 뷰 선택 시스템 A Deep Learning-based Adaptive Camera View Selection System for Teleoperated Driving 전양호, 김영진, 김성진	/ 48
26INDAI_D003	근대 국어 문서 해석을 위한 OCR 인식 방식 개선 연구 Improving OCR for Modern Korean Handwritten Documents Using GAN-based Data Augmentation 이동채, 김영진, 문성태	/ 51
26INDAI_D004	계층 청킹과 리랭킹 컷오프를 적용한 사내 기술문서 검색 시스템 An In-House Technical Document Search System with Hierarchical Chunking and Re-ranking Cutoff 이한울, 채민선, 전명근	/ 54
26INDAI_D005	태양광 시스템 고장진단을 위한 단계적 특징 선택 기반 발전량 추정 프레임워크 A Staged Feature Selection Framework for PV Power Estimation to Support Fault Diagnosis in Photovoltaic Systems 이소현, 김한진, 전명근	/ 59
26INDAI_D006	질의응답 멀티에이전트 협업 구조의 비교 평가 Comparative Evaluation of Multi-Agent Collaboration Architectures for Question Answering 이경준, 김영진, 반유석	/ 63
26INDAI_D007	4방향 시점 라벨 재구축 및 외형-자세 후기 결합을 통한 쇼핑몰 의류 이미지 시점 분류 연구 Viewpoint Classification of Shopping-Mall Clothing Images via Four-Direction Label Reconstruction and Appearance-Pose Late Fusion 남기현, 채민선, 최민	/ 66
26INDAI_D008	외란 광원 환경에서의 딥러닝 기반 고정밀 화재 감지 시스템 Deep Learning-Based High-Precision Fire Monitoring System under Interfering Light Sources 곽소영, 김영진, 최민	/ 68
26INDAI_D009	멀티카메라 보행자 재식별에서의 배경 편향 분석 및 완화 기법에 관한 연구 Background Sensitivity Analysis and Feature Consistency-Based Mitigation for Multi-Camera Person Re-Identification 추정원, 채민선, 문성태	/ 70
26INDAI_D010	PCB 적층 프레스 공정을 위한 시계열 데이터 기반 이상탐지 Time-Series Data-Based Anomaly Detection for the PCB Lamination Press Process 송공호, 김영진, 박태형	/ 74
26INDAI_D011	분산 MSA 환경에서 TraceID 기반 대조학습을 활용한 로그 이상 탐지 및 원인 서비스 식별 Log Anomaly Detection and Root-Cause Service Identification Using TraceID-based Contrastive Learning in Distributed Microservices 김완수, 김한진, 이의종	/ 77

INDAI 콜로키움 2026 논문집

2026년 11월 2일(월), 충북대학교 개신문화관

Session 2 : 산업인공지능학과

26INDAI_D012	Diffusion Model과 카메라 특징 보정을 활용한 다중 카메라 환경에서의 보행자 재식별 A Study on Person Re-Identification in Multi-Camera Environments using Diffusion Model and Camera Feature Calibration 이은혜, 김영진, 황영배	/ 83
26INDAI_D013	Graph Embedding을 활용한 온톨로지 기반 의미 관계 검색 최적화 Optimizing Ontology-based Semantic Relation Retrieval via Graph Embedding 송재익, 강대익, 유재수	/ 86
26INDAI_D014	온프레미스 sLLM과 GraphDB 기반 MES LOT 추적 프레임워크 An On-Premise sLLM- and GraphDB-Based Framework for MES LOT Traceability 정회성, 채민선, 윤재중	/ 88
26INDAI_D015	공개 데이터를 활용한 YOLOv8 기반 꿀벌 질병 탐지 연구 A Study on YOLOv8-Based Honeybee Disease Detection Using Public Data 이일주, 채민선, 유재수	/ 92
26INDAI_D016	객체 자세 추정과 SLAM을 비동기 결합한 6D 객체 지도 생성 시스템 6D Object-Level Mapping Based on Asynchronous Fusion of Object Pose Estimation and SLAM 이도현, 박정철, 김한진, 황영배	/ 95
26INDAI_D017	스마트 항만 생산성 향상을 위한 디지털트윈 기반 YT 운행 경로 최적화 시스템 개발 Digital Twin-Based YT Route Optimization System for Improving Smart Port Productivity 박성혁, 김한진, 류관희	/ 100
26INDAI_D018	콜리메이터 지그 기반 CCTV 카메라 포커스 및 상면 편심 자동 검사 시스템 Automated Inspection System for Focus and Image Plane Tilt of CCTV Cameras Based on Optical Collimator Jig 오지택, 김영진, 김형원	/ 103
26INDAI_D019	딥러닝 기반 주행영상 도로 균열 세그멘테이션의 소수 클래스 정확도와 프레임 간 안정성 개선 방법에 관한 연구 Deep Learning-Based Road Crack Segmentation from Driving Video: A Study on Methods for Improving Minority-Class Accuracy and Temporal Stability 안기현, 강대익, 류관희	/ 106
26INDAI_D020	원통형 이차전지 배터리 팩 스팟용접에서의 안전관리를 위한 열화상 기반 이상 감지 연구 Thermal Imaging-Based Anomaly Detection for Safety Management in Spot Welding of Cylindrical Rechargeable Battery Packs 이원표, 김한진, 김성진	/ 109
26INDAI_D021	절차 그래프 기반 행동 후보와 지식 검색을 활용한 연구개발계획서 작성 Agent A Research Proposal Writing Agent Using Procedural-Graph Action Candidates and Knowledge Retrieval 이혜빈, 강대익, 강현수	/ 112

INDAI 콜로키움 2026 논문집

2026년 11월 2일(월), 충북대학교 개신문화관

Session 1

산업인공지능연구센터 창의자율과제



단일 천장 영상의 관측 표면 BEV 기하 보정

김태현, 이범준, 이가진, 김승구*

충북대학교 전자공학전공, 충북대학교 전자공학과*

2026233009@chungbuk.ac.kr, 2024233004@chungbuk.ac.kr, dodeng387@chungbuk.ac.kr,
*kimsk@cbnu.ac.kr

Geometric Refinement of Observed-Surface BEV from a Single Ceiling Image

Taehyeon Kim, BeomJoon Lee, Gajin Lee, Seungku Kim*

Department of Electronic Engineering, Chungbuk National Univ.,

*Department of Electronic Engineering, Chungbuk National Univ.

Abstract

A single ceiling image can map indoor space, but directly projecting elevated visible surfaces distorts their shape and location in bird's-eye view (BEV). We present a geometry-guided coordinate refinement path for observed rack and cargo surfaces, using predicted semantic groups, depth, normals and calibrated camera rays. We evaluate surface geometry independently of placement through relative point error, overlap after ground-truth (GT) centre alignment, and principal-axis orientation error. On a fixed, previously inspected 80-view development set, the learned free-coordinate update reduces relative shape error from 51.64 to 22.67 cm, raises GT-centre-aligned IoU from 26.56% to 36.66%, and reduces axis error from 50.68° to 36.88°. Raw-coordinate pooled IoU falls from 15.97% to 6.70%. GT object correspondence and centres are used only for supervision and conditional evaluation. The results establish neither original-coordinate map improvement nor independent-scene generalization.

Key words : Ceiling camera, BEV, Observed surface, Geometric projection, Coordinate refinement



그림 1. 단일 영상에서 관측 표면 BEV까지의 경로. RGB · 카메라 기하 · 예측 깊이/법선으로 초기 예측 좌표와 semantic 그룹을 구한 뒤, 학습한 보정기가 점별 XY 좌표를 갱신한다.

Figure 1. Pipeline from a single image to an observed-surface BEV. Initial predicted coordinates, semantic labels, and groups are obtained from RGB, camera geometry, and predicted depth/normals. A learned correction module then updates the XY coordinates of each point.

Ⅰ. 서 론

BEV(Bird's-Eye View)는 위에서 본 평면 지도다[2,3]. 단일 360도 파노라마 영상과 깊이 정보로 실내 BEV 의미 지도를 생성하는 연구도 보고되었다[1]. 그러나 천장 영상에서 높이가 있는 랙 · 적재물의 픽셀을 바닥에 직접 옮기면 관측 표면의 위치와 면적이 왜곡된다. 본 논문은 단일 천장 영상에서 예측한 랙 · 적재물의 관측 표면점을 공통 BEV 격자에 투영하고, 점별 좌표를 갱신하는 프레임워크를 제안한다. 핵심 기여는 이웃 표면의 기하 연속성을 이용해 관측 표면의 상대 형상과 방향을 보정하고, 이를 물체 중심의 위치 오차와 분리해 평가하는 데 있다.

Ⅱ. 본론

1. 입력과 초기 투영

RGB, 보정된 카메라 광선 · 자세, 예측 깊이 · 법선을 입력한다[4]. 초기 예측 단계의 semantic, 예측 그룹 및 초기 metric XY에서 랙 · 적재물 표면점을 선택하고 5 cm 격자에 놓을 좌표와 국소 기하 특징을 얻는다.

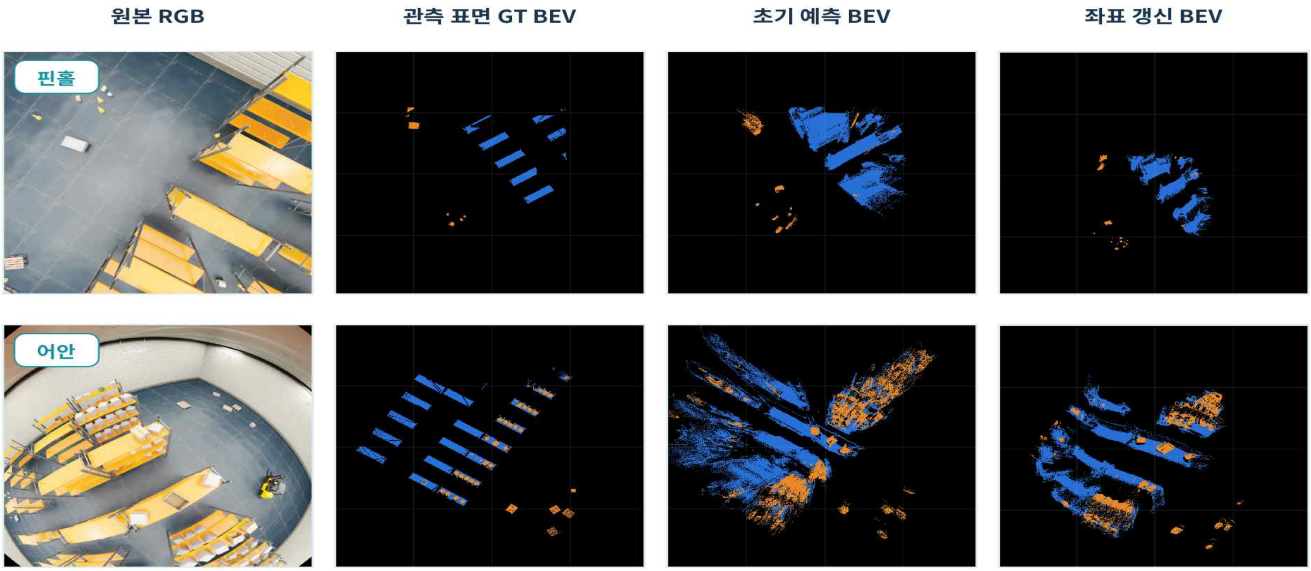


그림 2. 핀홀 · 어안의 원본 RGB, 관측 표면 GT, 초기 예측 BEV, 학습한 좌표 갱신 BEV. 예측 패널은 GT 중심 정렬을 하지 않은 원좌표다(파랑: 랙, 주황: 적재물).

Figure 2. Original RGB images, observed-surface ground truth (GT), initial predicted BEV, and learned coordinate-corrected BEV for pinhole and fisheye cameras. The predicted BEV panels show the original coordinates without alignment to the GT object centers (blue: racks; orange: stored items).

2. 관측 표면 좌표 보정

깊이 · 법선의 연속성과 예측 class · 그룹을 이용해 표면점의 이웃 문맥을 구성한다. 자유 갱신형 보정기는 이 문맥에서 점별 XY 이동량을 학습해 초기 예측 좌표에 더한다. 그룹 중심을 고정하지 않으며 갱신 좌표를 같은 5 cm 격자에 투영해 랙 · 적재물 관측면의 BEV 점유를 얻는다. GT 물체 대응과 중심은 학습 및 평가에만 사용한다.

3. 평가 장면과 비교 조건

본 평가는 물체 밀도 · 가림과 카메라 투영 조건이 다른 장면에서 좌표 갱신의 형상 보정 효과를 살피기 위해 설계했다. NVIDIA Isaac Sim에서 랙 · 팔레트 · 상자의 수와 배치를 바꾼 20개 창고 장면을 구성했다. 각 장면의 두 카메라 자세를 핀홀 · 어안으로 짝지어 기록해 렌즈별 40뷰, 총 80뷰를 얻었다. 좌표 갱신 모듈은 별도 12개 창고 배치의 960뷰로 학습하였다. 두 비교 조건은 동일한 초기 예측 좌표 · 격자 · GT를 공유하며 좌표 갱신의 적용 여부만 다르다. 이 장면들은 개발 중 반복 검토했으므로 결과는 개발 평가에 한정한다.

4. 평가 지표

이번 평가는 위치 보정을 제외한 표면 기하에 초점을 두므로 세 지표를 사용한다. 상대 형상 오차는 대응한 물체의 예측점과 GT점에서 각각 물체 중심을 뺀 뒤 점별 XY 거리의 물체 평균을 구한다. 중심 이동의 영향을 제거해 학습 보정이 표면 내 점의 상대 배치를 개선했는지 측정한다. GT 중심 정렬 IoU는 대응 표면점을 GT 물체 중심까지 평행이동한 후 두 점유의 겹침을 계산한다. 주축 각도 오차는 중심을 제거한 관측 표면의 2차 모멘트로 긴 축을 구해 GT의 축과 비교한다. 방향이 정의되는 표면에서 회전 왜곡을 측정한다.

표 1. 동일 80뷰의 초기 예측과 좌표 갱신

Table 1. Initial Predictions and Coordinate Refinement on the Same 80 Views

평가지표	초기 예측	좌표 갱신
상대 형상 오차(cm)	51.64	22.67
GT 중심 정렬 IoU(%)	26.56	36.66
주축 각도 오차(°)	50.68	36.88

Ⅲ. 결론

본 논문은 단일 천장 영상의 예측 표면점을 BEV에 옮기고, 학습 좌표 보정의 효과를 물체 위치와 분리해 검증했다. 대응한 관측 표면의 상대 형상 · 점유 · 방향은 개선됐지만 원좌표 점유와 중심 위치는 악화했다. 따라서 물체별 관측면 지도화에는 형상과 위치의 보정이 함께 필요하다. 후속 연구에서는 별도 위치 보정으로 물체 중심의 지도상 위치 오차를 줄이고, 사선 관측에서 남은 방향 · 각도 오차도 보정한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Z. Teng et al., “360BEV: Panoramic Semantic Mapping for Indoor Bird's-Eye View,” WACV, pp.373-382, 2024.

[2] Y. Ma et al., “Vision-Centric BEV Perception: A Survey,” IEEETPAMI, vol. 46, no. 12, pp. 10978-10997, 2024.

[3] J. Philion and S. Fidler, “Lift, Splat, Shoot: Encoding Images from Arbitrary Camera Rigs by Implicitly Unprojecting to 3D,” ECCV, 2020.

[4] Y. Shi, Y. Song, and M. Z. Shou, “Edit2Perceive: Image Editing Diffusion Models Are Strong Dense Perceivers,” CVPR, pp.43568-43577, 2026.

추론형 자율주행 VLA의 Jetson Thor 경량화와 nusc_coc를 이용한 nuScenes 도메인 적응

윤수한, 정준범, 전양호*, 기석철**

충북대학교 지능로봇공학전공, *충북대학교 산업인공지능학과, **충북대학교 지능로봇공학과

soohan98@chungbuk.ac.kr, wjdwnsqja08@chungbuk.ac.kr, *yhjeon@avgenuys.kr, **sckee@chungbuk.ac.kr

Accelerating a Reasoning Driving VLA on Jetson Thor and Adapting It to nuScenes with Auto-Labeled CoC

Soohan Yoon, Junbeom Jeong, Yangho Jeon*, Seok-Cheol Kee**

Dept. of Intelligent Systems and Robotics, Chungbuk National Univ.,

*Dept. of Industrial Artificial Intelligence, Chungbuk National Univ.,

**Dept. of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

Reasoning vision-language-action (VLA) models for autonomous driving explain their decisions in text before planning a trajectory, which makes them slow on in-vehicle hardware. We run Alpamayo 1.5 (11.08B parameters) on the NVIDIA Jetson Thor, where the original PyTorch model takes 3,524 ms per request. Porting it to TensorRT Edge-LLM with NVFP4 weights, DFlash speculative decoding and the action caching of FlashDrive gives 542 ms. Comparing each stage's GPU time with its memory-bandwidth bound and with the host time between stages, we then remove the remaining bottlenecks without training: drafts taken from the previous frame's rationale and from a corpus of rationales, a reduced-vocabulary verification head, a synchronizing memory release in the encoder cache, and per-step host synchronization in the action expert, replaced by a non-uniform flow-matching time grid. This gives 450 ms within a +/-2 % equivalence margin of the baseline's ADE, 1.9x faster than the fastest FlashDrive configuration under the same protocol; the stack's ADE is 6.1 % above the original model's, a gap that comes from the port. For streaming KV reuse we re-rotate the cached keys along the three M-RoPE axes. A 3-camera student without the telephoto camera, distilled from the 4-camera model and pruned to 5.86B, recovers 80 % of the accuracy lost by dropping the camera at 271 ms, and removing the visual tokens where the side cameras overlap the front camera brings it to 206 ms with no significant ADE change. We also adapt the model to a new domain without human labels: on nuScenes, two-stage low-rank fine-tuning with auto-labeled chain-of-causation reasoning (nusc_coc) reduces the 6.4 s ADE on a held-out test split from 4.37 m to 1.81 m (-59%, paired difference -2.56 m, 95% CI [-3.05, -2.08]).

Key words : Vision-Language-Action, Autonomous Driving, Edge Inference, Speculative Decoding, Domain Adaptation

Ⅰ. 서 론

최근 자율주행에서는 카메라 영상으로부터 판단 근거 문장과 미래 궤적을 함께 생성하는 VLA(Vision-Language-Action) 모델이 주목받고 있다[1]. Alpamayo 1.5[2]는 Qwen3-VL[3] 구조의 8B 비전-언어 모델과 flow-matching 행동 전문가로 구성된 모델(전체 11.08B)로, 카메라 4대×4프레임에서 인과 사슬(CoC) 추론 문장과 6.4초 궤적을 출력한다. 그러나 차량용 SoC인 Jetson Thor에서 원본 PyTorch 구현은 요청 1회에 3,524 ms가 걸린다.

이 모델을 가속한 FlashDrive[4]는 스트리밍 KV 재사용, DFlash 추측 디코딩[5], W4A8 양자화, 행동 캐싱을 결합하였으나, 같은 공개 코드를 Thor의 평가 클립 644개에서 측정하면 841 ms(원본 대비 4.2배)에 머문다. 본 논문은 단계별 병목을 측정해 원인을 찾고 고치는 방식으로 두 경로의 지연을 줄인다. 첫째, 모델을 바꾸지 않고 TensorRT Edge-LLM[6] 위에서 학습 없는 기법을 설계한다. 둘째, 망원 카메라를 뺀 3캠 학생 모델을 지식증류와 FFN 프루닝[7]으로 줄이고, 시야가 겹치는 영역의 시각 토큰을 제거한다.

또한 차량 · 카메라 · 도시가 다른 새 도메인에서의 정확도도 탑재 전에 확인해야 한다. Alpamayo는 PhysicalAI-AV[11]로 학습되어 다른 환경에서는 성능이 떨어질 수 있고, 새 데이터에는 사람이 쓴 CoC 라벨이 없다. 이를 위해 nuScenes[12]를 새 도메인의 대리로 삼아, 자동 생성한 CoC(nusc_coc)로 Alpamayo를 적응시켰다.

기여는 다음과 같다. (1) 단계별 GPU 시간, 호스트 시간, 메모리 대역폭 하한을 비교해 decode · 호스트 · action의 병목을 찾고, 모델 밖 초안, 검증 어휘 축소, 동기화 제거, 시간 격자 재설계로 4캠 요청당 450 ms를 기준 구성 대비 정확도 ±2% 안에서 얻었다(같은 조건의 FlashDrive보다 1.9배). (2) RoPE가 적용된 KV를 스트리밍으로 재사용할 때 생기는 위치 오류를 M-RoPE 축별 재회전으로 고쳤다. (3) 3캠 압축 학생(5.86B)이 카메라 제거로 잃은 정확도의 80%를 회복한 채 271 ms로 동작하고, 카메라 겹침 토큰 제거로 206 ms까지 줄어듦을 Thor에서 실측하였다. (4) nusc_coc를 이용한 2단계 LoRA 적응으로 nuScenes test ADE를 4.37 m에서 1.81 m로 59% 줄였다.

Ⅱ. 관련 연구

1. VLA 추론 가속

FlashDrive[4]는 Alpamayo에 대해 스트리밍 KV 재사용, DFlash, W4A8 양자화, 행동 캐싱을 공동 설계하였다. RoPE 적용 전 key를 저장하므로 프레임 KV를 옮겨도 위치 오류가 없고, 이전 창의 문맥으로 계산된 KV를 재사용하는 근사는 행동 전문가 미세조정으로 보완한다. 본 논문은 RoPE가 적용된 key를 저장하는 TensorRT 런타임에서 병목을 분석해 학습 없이 줄이는 데 초점을 둔다.

2. 추측 디코딩과 경량화

추측 디코딩[8]은 초안 토큰을 원 모델이 한 번에 검증해 출력을 바꾸지 않고 호출 수를 줄인다. DFlash[5]는 블록 확산 초안 모델을, REST[9]는 말뭉치에서 검색한 초안을 쓴다. 모델 경량화에서는 활성 중요도로 폭을 줄이고 지식증류로 회복하는 Minitron[7]이 대표적이다.

3. 도메인 적응과 CoC 라벨

Alpamayo-R1[1]은 판단 근거를 CoC 문장으로 먼저 생성하고 그 문맥에서 궤적을 만들며, 대규모 CoC는 자동 라벨러로 만든다. nuScenes[12]의 개방 루프 planning은 L2 오차로 보고되지만 자차 속도 · 이력만으로도 낮은 오차를 얻을 수 있다는 지적이 있어[13], 본 논문은 도메인 적응 결과에 등속 기준선을 함께 보고한다.

Ⅲ. 제안 방법

1. 모델 구조와 병목 분석

그림 1은 추론 과정과 단계별 적용 기법이다. 카메라 4대의 최근 4프레임은 비전 인코더에서 시각 토큰 2,880개가 되어 약 3,086 토큰의 프롬프트를 이루고, 8B 언어 모델이 이를 처리(prefill)한 뒤 추론 문장을 생성(decode)하면 행동 전문가가 언어 모델의 층별 KV를 참조해 궤적을 만든다. 기준 구성(542 ms)은 TensorRT Edge-LLM을 Alpamayo 1.5와 Thor로 확장하고, 주행 클립 64개로 보정한 NVFP4 양자화, DFlash 초안 모델, FlashDrive의 행동 캐싱과 미세조정 행동 헤드[4]를 옮겨 구축하였다.

병목은 세 가지 측정으로 분석하였다. 첫째, 런타임의 단계별 GPU 시간과 요청 단위 벽시계 시간을 함께 기록하고, 둘의 차이를 GPU가 기다리는 호스트 시간으로 보았다. 둘째, 각 단계가 읽는 데이터 양을 Thor의 메모리 대역폭(273 GB/s)으로 나눈 이론 하한과 실측을 비교하였다. 셋째, 기법마다 추론 문장 일치 수와 궤적 차이를 확인해 출력이 바뀌는지 가렸다. 기준 구성의 542 ms는 vision 108, prefill 206, decode 107, action 88, 호스트 33 ms였으며, 2~4절은 이 중 decode, 호스트, action에서 찾은 문제와 수정이다.



그림 1 Alpamayo 1.5의 추론 구조와 단계별 적용 기법
Fig. 1 Inference pipeline of Alpamayo 1.5 and the techniques applied to each stage

2. decode: 모델 밖 초안과 검증 어휘 축소

분석. decode에서 언어 모델은 검증마다 가중치 전체(약 4.3 GB)를 읽으므로 이론 하한은 약 16 ms이고 실측은 23.7 ms였다. decode는 메모리 대역폭에 묶여 있어, 지연을 줄이려면 검증 횟수를 줄여야 한다. 생성 문장을 보면 연속 프레임의 추론 문장은 대부분 같았고, 평가에 쓰지 않은 클립의 문장 4,986개 중 가장 흔한 문장이 910번 나올 만큼 표현이 반복되었다.

문제. DFlash 초안은 이 반복을 쓰지 못해 매 라운드 초안 모델을 호출하였고, 검증용 lm_head는 실제로 쓰이는 토큰이 861개뿐인데도 155,697개 전체 어휘를 계산하였다.

수정. greedy 검증은 초안의 출처와 무관하게 출력을 원 모델과 같게 만들므로, 그림 2처럼 직전 프레임의 문장(시간축 초안)과 문장 코퍼스의 접미사 색인(CoC 검색 초안)에서 초안을 가져왔다. 또한 검증용 lm_head를 8,704개 어휘로 줄여 행렬 곱을 약 1/18로 줄였다(어휘 밖 단어가 필요할 때만 출력이 바뀐다).

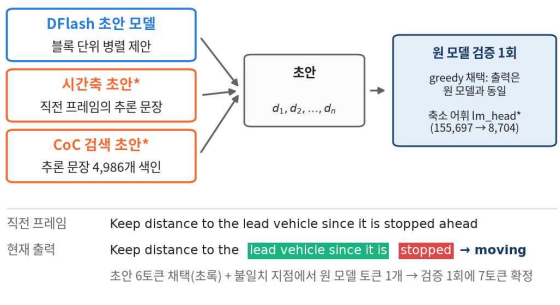


그림 2 모델 밖에서 가져오는 초안과 검증
Fig. 2 Drafts from outside the model and their verification

3. 호스트와 action: 동기화 제거와 시간 격자

분석. 호스트 시간(33 ms)을 구간별로 추적하자, 이미지 임베딩 캐시가 항목을 비울 때 부르는 cudaFree가 장치 전체를 동기화해 비전 인코더가 끝날 때까지 호스트가 멈추고 있었다. action(88 ms)에서는 FlashDrive의 행동 캐싱이 8스텝 중 4스텝에서 직전 속도를 재사용하면서도 스텝마다 CPU 동기화와 호스트 갱신을 수행하고 있었다.

수정. 캐시 메모리를 stream-ordered 메모리 풀로 바꾸고 16장의 이미지 해시를 8개 스레드로 병렬 계산하였다(−20.7 ms, 출력 동일). 재사용 스텝은 직전 속도로 구간을 한 번에 적분하는 것과 같으므로 격자 {0, 1/8, 2/8, 7/8, 1}로 접어 동기화를 8회에서 1회로 줄였다. 이어서 격자를

gold644에서 비균등 격자 {0, 2/8, 7/8, 1}로 호출을 3회로, 학생 모델에서는 {0, 7/8, 1}로 2회까지 줄였다(그림 3).

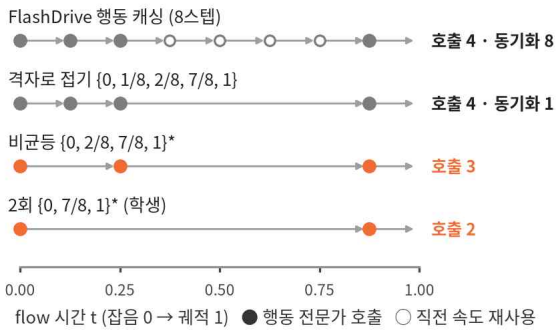


그림 3 행동 전문가의 flow 시간 격자
Fig. 3 Flow-matching time grids of the action expert

4. 스트리밍 KV의 재회전

분석. 100 ms 간격의 연속 창에서는 카메라마다 4프레임 중 3프레임이 겹치므로 그 KV를 옮겨 재사용할 수 있다(그림 4). 그러나 그대로 재사용하자 추론 문장이 200창 중 78창만 전체 prefill과 같았고 궤적이 평균 1.84 m 달라졌다.

문제. TensorRT 런타임은 RoPE가 적용된 key를 저장하므로, 옮긴 key가 옛 위치의 회전을 그대로 갖는다.

수정. 위치 p에서 q로 옮긴 key를 다음과 같이 다시 회전한다[10]. Qwen3-VL의 M-RoPE는 회전 차원을 시간 · 세로 · 가로 축에 나누어 쓰므로[3] 축별 위치 차이로 회전하는 CUDA 커널로 구현하였고, 단독 검증 오차는 8.8×10^{-4} (FP16 수준)였다.

$$k' = R(q)R(p)^{\mathrm{T}}\mathrm{k} = \mathrm{R}(\mathrm{q}-\mathrm{p})\mathrm{k} \qquad (1)$$



그림 4 스트리밍 KV 재사용과 key 재회전
Fig. 4 Streaming KV reuse with key re-rotation

5. 3-카메라 학생 모델과 겹침 토큰 제거

분석. 2~3절의 수정 후 450 ms 중 vision과 prefill이 약 70%를 차지하여, 입력과 모델 자체를 줄여야 했다. 망원 카메라를 빼면 vision과 prefill이 20% 안팎 줄지만, 학습 없이는 ADE가 93% 나빠졌다.

수정. 3캠 입력(좌 측방 · 전방 광각 · 우 측방)으로 학생을 학습하였다. PhysicalAI-AV[11]에서 4캠 원 모델이 생성한 궤적과 추론 문장을 목표로 한 증류 손실에 정답 궤적 손실을 더하고, Minitron[7] 방식으로 FFN 활성 중요도에 따라 LLM과 행동 전문가의 FFN 폭을 3,072(5.86B)와 2,048(5.18B)로 줄였다. 비교로 정답 궤적만으로 학습한 B(11.08B)와 LLM FFN만 7,168로 줄인 P(8.81B)를 함께 평가한다. 압축 후에도 남는 vision · prefill을 줄이기 위해 카메라 기하를 보면, 120° 측방 카메라는 시야의 약 53° 가 전방 광각과 겹친다(그림 5). 그래서 이미지당 18×10개의 시각 토큰 중 겹치는 안쪽 8열을 지워 3캠 시각 토큰 2,160개 중 640개를 줄이고, 지운 수만큼 행동 전문가의 M-RoPE 위치 오프셋을 보정한다. 점수 계산과 학습이 필요 없다.

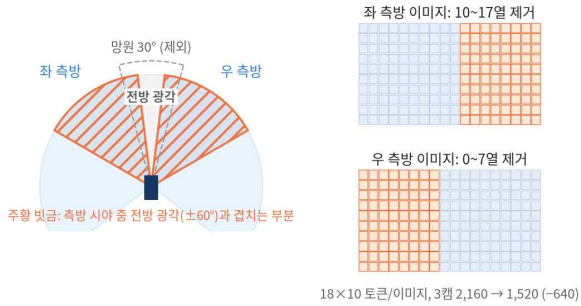


그림 5 카메라 겹침 영역의 시각 토큰 제거
Fig. 5 Removing visual tokens where the cameras overlap

6. nusc_coc를 이용한 nuScenes 도메인 적응

그림 7은 도메인 적응 과정이다. 차량 · 카메라 · 도시가 모두 다른 nuScenes v1.0-trainval의 835개 scene을 PhysicalAI-AV[11] 형식으로 변환하였다. 전방 · 좌 · 우 카메라를 Alpamayo의 광각 · 측방 입력에 대응시키고, 없는 망원 카메라는 전방 영상의 중앙을 잘라 합성하였으며, 자차 운동은 CAN 버스 50 Hz로 만들었다. CoC 라벨은 공개 자동 라벨러[14]와 Qwen3.5-35B-A3B[15]로 생성하였고(메타 행동 → keyframe → 라벨 → 3단계 검증), 3,218개 이벤트 중 2,433개가 검증을 통과하였다(이하 nusc_coc).



그림 7 nusc_coc를 이용한 nuScenes 도메인 적응 과정
Fig. 7 Domain adaptation of Alpamayo 1.5 to nuScenes with auto-labeled CoC (nusc_coc)

학습은 두 단계이다. 두 단계 모두 기록된 미래 궤적의 flow-matching 손실(가중치 1.0)과 CoC 교차 엔트로피(0.2)를 쓰고, 언어 모델에 LoRA[16](r=64)를 붙이며 비전 인코더는 고정한다. **S1**은 nusc_coc 중 train scene의 검증 통과 이벤트 1,953개로 CoC와 궤적을 함께 학습한다. **S2**는 라벨이 없는 밀집 시점 8,060개(1초 간격)에서 S1이 스스로 생성한 CoC를 문맥이자 앵커로 두고 행동 전문가 전체를 학습한다. 공식 val 150 scene은 dev 50 · test 100 scene(각 3시점)으로 나누고, 분할 · 체크포인트 선택 규칙 · test 1회 개봉을 결과보다 먼저 등록하였다.

Ⅳ. 실험 및 결과

1. 실험 환경

모든 측정은 Jetson AGX Thor(MAXN, CPU performance 거버너)에서 GPU 작업 하나만 실행하며 수행하였다. 지연은 latency30(30클립)에서 입력 파일마다 50 °C까지 냉각하고 45회 워밍업한 뒤 잰 요청 단위 벽시계 시간의 평균이다. 정확도는 NVIDIA 공식 평가 클립 gold644의 6.4초

ADE로, greedy 추론 문장과 잡음 0의 궤적 1개(K=1)를 기본으로 클립 단위 부트스트랩 95% 신뢰구간을 구하였다. 학생 모델에는 6개 샘플(잡음 1)의 minADE6도 보고한다.

도메인 적응의 학습과 평가는 RTX PRO 6000 Blackwell 2장에서 하였다(S1 약 2시간, S2 약 4시간). 평가는 nuScenes test 100 scene × 3시점(300 샘플)의 6.4초 ADE(K=1)이며, 모든 모델이 같은 확산 초기 잡음과 생성 seed를 쓰고 차이는 scene 단위 bootstrap 95% CI로 낸다.

2. 누적 가속

표 1은 원본에서 최종 구성까지의 과정이다. 큰 이득은 DFlash(decode)와 NVFP4 양자화(prefill), 호스트 병목 제거에서 나왔으며, 이 단계는 기존 도구의 이식이다. 그 위에 제안 기법은 542 ms를 450 ms(p90 486 ms, 2.2 FPS)로 17% 더 줄였고, gold644 ADE 변화는 −0.58% [−1.31, +0.29]로 ±2% 동등 마진 안에 있었다(추론 문장 640/644 일치). 그림 6처럼 4캠에서는 decode(107→65 ms) · action(88→55 ms) · 호스트(33→17 ms)가 줄고, vision과 prefill이 남은 시간의 약 70%를 차지한다.

표 1 Jetson Thor에서의 누적 가속 (latency30)
Table 1 Cumulative acceleration on Jetson Thor

구성	지연(ms)	ADE(m)
원본 PyTorch (BF16)	3,524	1.455
TensorRT FP16 엔진	2,550	—
+ FlashDrive 헤드 · 캐싱	2,266	—
+ DFlash 추측 디코딩	1,487	—
+ NVFP4 LLM (주행 보정)	831	—
+ 호스트 · 비전 · 행동 NVFP4 (기준)	542	1.553
+ 캐시 · 스텝 접기 · 정적 KV*	509	—
+ 시간 격자 · graph · 가드*	484	—
+ lm_head 축소 · 초안 FP16*	467	—
+ CoC 검색 초안* (최종)	450	1.544

*는 제안 기법. ADE는 gold644, K=1, greedy, 잡음 0. —는 미측정.

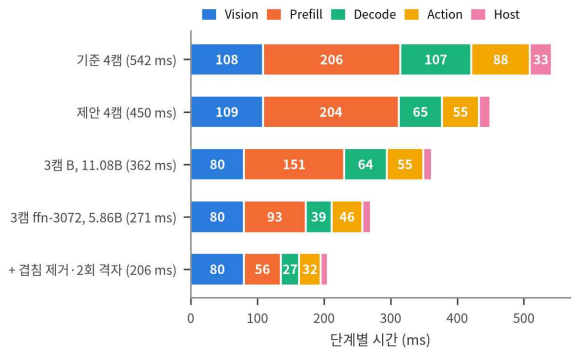


그림 6 단계별 GPU 시간 (latency30 평균)
Fig. 6 Per-stage GPU time (latency30 mean)

3. FlashDrive와의 비교

표 2는 FlashDrive 공개 코드를 같은 Thor, 같은 644클립, 같은 조건(K=1, greedy, 잡음 0)으로 측정한 결과이다. FlashDrive는 단일 요청 경로가 없어 직전 창으로 KV를 채운 2창 스트림으로 실행하였다. 본 구성은 독립 요청에서 FlashDrive 최고 설정보다 1.9배, 같은 스트리밍 조건에서 3.1배 빨랐다. 다만 원본 대비 ADE는 FlashDrive가 +3.0%(유의하지 않음)인 반면 본 구성은 +6.1% [+0.9, +11.5]였다. 기준 구성도 같은 수준이므로(표 1) 이 차이는 신규 기법이 아니라 이식 단계(NVFP4, 캐싱 적분)에서 온다. 스트리밍 수치는 비교용이며, 처리 시간이 창 간격보다 길어 실시간 연속 실행의 지연은 아니다.

표 2 같은 조건에서 FlashDrive와의 비교 (gold644)
Table 2 Comparison with FlashDrive under one protocol

구성	지연(ms)	속도	ADE(m)
원본 PyTorch	3,565	1.0배	1.455
FlashDrive BF16 compile	901	4.0배	1.499
FlashDrive W4A8 compile	841	4.2배	1.499
본 논문 독립 요청	441	8.1배	1.544
본 논문 스트리밍	271	13.2배	1.511

FlashDrive와 스트리밍은 2창 스트림(t0 − 100 ms 창으로 KV를 채운 뒤 t0 창 측정).

4. 스트리밍 재사용

latency30의 10클립을 100 ms 간격으로 20창씩 실행하면, 재회전 후 추론 문장 일치가 78/200에서 136/200으로, 전체 prefill과의 궤적 차이가 1.84 m에서 0.68 m로 줄었다. 시간축 초안은 이 조건에서 decode를 156 ms에서 80 ms로 줄였다(문장 200/200 동일).

5. 3-카메라 학생 모델

표 3은 학생 모델의 결과이다. 망원 카메라를 학습 없이 빼면 ADE가 93% 나빠지지만, 학습한 학생은 이 하락의 78~85%를 회복하였다. 5.86B 학생(ffn-3072)은 80% [73, 87]를 회복한 채 271 ms로 동작하며, 학습 분할 클립을 뺀 val+test 319클립에서도 84%를 회복하였다. K=1 ADE는 정답 학습(B)이 가장 좋지만 minADE6는 증류 학생이 더 좋았다. 겹침 토큰 제거와 2회 격자는 ffn-3072를 206 ms로 줄였고 ADE 변화는 +1.3% [−1.3, +3.6]로 유의하지 않았다. 이때 vision(80 ms)이 남은 시간의 39%로 다음 병목이다(그림 6).

표 3 3-카메라 학생 모델 (Jetson Thor)
Table 3 3-camera students on Jetson Thor

모델	크기	지연	ADE	minADE6	회복
4캠 최종	11.08B	450	1.544	0.940	—
3캠 zero-shot	11.08B	—	2.977	—	0%
B: 정답 학습	11.08B	362	1.762	1.108	85%
P: 7168, 증류	8.81B	327	1.822	1.003	81%
ffn-3072, 증류	5.86B	271	1.832	1.076	80%
ffn-2048, 증류	5.18B	249	1.858	1.076	78%
+ 겹침 제거	5.86B	206	1.855	—	78%

지연은 latency30 K=1(ms), ADE는 gold644 K=1 잡음 0(m), minADE6는 K=6 잡음 1. 회복은 3캠 zero-shot과 4캠 사이 하락분 중 회복한 비율. 마지막 행은 ffn-3072에 겹침 제거와 2회 격자를 적용.

6. nusc_coc 도메인 적응 결과

표 4는 nuScenes test 결과이다. 원본은 등속 외삽보다도 ADE가 0.93 m 나빴으나, nusc_coc로 학습한 S1에서 2.06 m, S1+S2에서 1.81 m로 원본 대비 59% 줄었고(⊿ADE −2.56 m [−3.05, −2.08], 89/100 scene 개선), 사전 등록한 게이트(CI 상한 < 0, 궤적 표지 누락 ≤ 1%)를 통과하였다. S2의 추가 이득(S1 대비)은 −0.26 m [−0.41, −0.11]로 유의하였고, 도시별로도 보스턴 −2.64 m, 좌측통행인 싱가포르 −2.48 m로 모두 개선되었다. nuScenes 표준식 지표(keyframe 2,301개)에서도 L2 평균

(1-3초)이 1.33 m에서 0.60 m로 줄었고, 충돌률은 유의한 차이가 없었다. 적응 모델은 더 강한 등속 · 등회전 기준선보다도 1.43 m 낮아 자차 상태의 외삽 이상을 학습하였다.

표 4 nuScenes test 결과

Table 4 Domain adaptation results on the nuScenes test split

방법	ADE(m)	ADE@3s	원본 대비
등속 외삽 (CV)	3.44	0.92	−21%
등속 · 등회전 (CTRV)	3.24	0.82	−26%
원본 Alpamayo 1.5	4.37	1.18	—
S1: nusc_coc SFT	2.06	0.56	−53%
S1+S2 (적응 모델)	1.81	0.49	−59%

nuScenes test 100 scene × 3시점(300 샘플), K=1, 모든 모델이 같은 초기 잡음 사용. ADE@3s는 3초까지의 평균 변위 오차(m).

원본이 스스로 생성한 CoC로 같은 학습을 한 대조 대비 S1의 차이는 +0.00 m [−0.19, +0.22]로 궤적 개선은 CoC 내용보다 nuScenes 궤적 지도에서 왔다. 검증 탈락 라벨까지 쓴 대조와의 차이는 +0.08 m [−0.08, +0.24]로 품질 필터의 효과는 유의하지 않았다. 다만 종방향 행동(정지 · 감속 · 가속 · 유지)을 명시한 추론 문장의 비율은 원본 34%, 대조 37%에서 S1 91%로 높아져, 자동 라벨은 궤적보다 추론 문장의 내용을 바꾸었다. S1 레시피는 seed 3회 반복에서 2.01 ± 0.04 m로 안정적이었고, 학습 이벤트를 25%(485개) · 50%로 줄여도 2.22 m · 2.04 m로 이득의 대부분이 유지되었다.

7. 한계

지표는 open-loop ADE이며, 회복률의 상한인 4캠 모델은 PhysicalAI-AV로 미세조정하지 않아 도메인 적응 효과가 섞여 있을 수 있다. 학생 모델의 스트리밍 재사용은 행동 전문가를 스트리밍 입력으로 미세조정하지 않아 ADE가 2~3% 높았으며, 이는 향후 과제이다. 도메인 적응 모델은 아직 압축 · Thor 이식을 하지 않아 정확도만 보고하며, nuScenes의 망원 입력은 합성이고 자동 라벨은 Qwen 계열의 문체 편향을 가진다.

V. 결 론

본 논문은 Alpamayo 1.5를 Jetson Thor에서 단계별 병목을 분석해 두 경로로 가속하였다. 학습 없는 기법으로 4캠 요청당 450 ms(원본 대비 7.8배)를 기준 구성 대비 정확도 ±2% 안에서 얻었고, 같은 조건에서 FlashDrive보다 1.9배 빨랐다. 망원 카메라를 뺀 5.86B 학생은 카메라 제거로 잃은 정확도의 80%를 회복한 채 271 ms로 동작했고, 겹침 토큰 제거와 2회 시간 격자로 206 ms를 얻었다. 또한 사람 라벨 없이 자동 생성한 CoC(nusc_coc)로 2단계 LoRA 미세조정하여 nuScenes test ADE를 4.37 m에서 1.81 m로 59% 줄였다. 향후 적응 모델을 3캠 학생으로 증류해 Thor에 탑재하고, vision의 커널 수준 분석과 closed-loop 평가를 수행할 예정이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] NVIDIA, "Alpamayo-R1: Bridging Reasoning and Action Prediction for Generalizable Autonomous Driving in the Long Tail," arXiv:2511.00088, 2025.

[2] NVIDIA, "Alpamayo-1.5-10B," Hugging Face model card, 2026.

[3] Qwen Team, "Qwen3-VL Technical Report," arXiv:2511.21631, 2025.

[4] Z. Li, Y. Liang, H. Zhang, J. Chen, Y. Liang, and Z. Liu, "FlashDrive: Flash Vision-Language-Action Inference for Autonomous Driving," Proc. CoRL, 2026 (arXiv:2608.12932).

[5] J. Chen, Y. Liang, and Z. Liu, "DFlash: Block Diffusion for Flash Speculative Decoding," Proc. ICML, 2026.

[6] NVIDIA, "TensorRT Edge-LLM," GitHub repository, 2026.

[7] S. Muralidharan et al., "Compact Language Models via Pruning and Knowledge Distillation," Proc. NeurIPS, 2024.

[8] Y. Leviathan, M. Kalman, and Y. Matias, "Fast Inference from Transformers via Speculative Decoding," Proc. ICML, 2023.

[9] Z. He, Z. Zhong, T. Cai, J. D. Lee, and D. He, "REST: Retrieval-Based Speculative Decoding," Proc. NAACL, 2024.

[10] G. Gerganov et al., "llama.cpp: LLM inference in C/C++ (context shift)," GitHub repository, 2023.

[11] NVIDIA, "PhysicalAI-Autonomous-Vehicles Dataset," Hugging Face, 2025.

[12] H. Caesar et al., "nuScenes: A Multimodal Dataset for Autonomous Driving," Proc. CVPR, 2020.

[13] Z. Li et al., "Is Ego Status All You Need for Open-Loop End-to-End Autonomous Driving?," Proc. CVPR, 2024.

[14] NVlabs, "alpamayo-coc-autolabeler," GitHub repository, 2026.

[15] Qwen Team, "Qwen3.5-35B-A3B," Hugging Face model card, 2026.

[16] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models," Proc. ICLR, 2022.

관심 영역 추출을 이용한 핸드헬드 스캐너 기반 3차원 객체 검출

오현지, 이전혁*, 송동건**, 박태형***

충북대학교 지능로봇공학전공, *충북대학교 제어로봇공학전공, **충북대학교 산업인공지능학과,

***충북대학교 지능로봇공학과

hyunji@chungbuk.ac.kr, *davian@chungbuk.ac.kr, **sdg0226@naver.com,
***taehpark@chungbuk.ac.kr

Handheld Scanner-Based 3D Object Detection Using Region-of-Interest Extraction

Hyun-Ji Oh, Jeon-Hyeok Lee*, Dong-Geon Song**, Tae-Hyoung Park***

Department of Intelligent Systems and Robotics, Chungbuk National Univ.,

*Department of Control and Robot Engineering, Chungbuk National Univ.,

**Department of Industrial AI, Chungbuk National Univ.,

***Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

Handheld scanners enable rapid acquisition of three-dimensional point clouds, but the continuous change of the sensor pose during scanning makes the ground direction of the point cloud inconsistent and leaves unnecessary ground and ceiling points in the data, which increase the input size of object detection networks and hinder feature extraction in the height range where objects exist. This paper proposes a handheld scanner-based 3D object detection method using ground plane estimation and region-of-interest extraction. The proposed method registers consecutive frames into a submap, corrects the pose of the point cloud based on a ground plane estimated by RANSAC, and extracts only the height range where objects are likely to exist before feeding the point cloud into a 3D object detection network. Experimental results in an indoor environment show that the proposed preprocessing improves AP@0.3 from 70.63% to 85.33%, an absolute gain of 14.70%p, while achieving an average inference time of 5.51 ms (181.5 FPS) on an NVIDIA RTX 3090.

Key words : Handheld LiDAR, Point cloud preprocessing, Ground plane estimation, Region of interest, 3D object detection

I. 서 론

핸드헬드 스캐너는 사용자가 직접 들고 이동하며 주변 환경의 3차원 점군을 획득하는 장치로, 공간을 자유롭고 빠르게 스캔할 수 있어 건설 현장 측량이나 실내 지도 작성 등에 널리 사용된다[1]. 한편 정밀한 지도를 생성하기 위해서는 스캔 과정에서 함께 획득되는 보행자 등 주변 객체를 검출하여 처리하는 과정이 필요하다[2]. 그러나 핸드헬드 스캐너는 센서의 위치와 자세가 고정되어 있지 않아 스캔 위치에 따라 동일한 객체라도 점군의 3차원 형태가 달라지므로 객체 검출이 어렵다.

이에 본 논문에서는 객체 관심 영역 추출을 통해 객체 후보 영역을 제한한 뒤 객체를 검출하는 핸드헬드 스캐너 기반 3차원 객체 검출 방법을 제안한다.

II. 본론

2.1. 전체 시스템

본 논문에서는 객체 관심 영역 추출을 이용한 핸드헬드 스캐너 기반 3차원 객체 검출 방법을 제안한다. 그림 1은 제안 방법의 전체 구조를 나타낸다. 제안 방법은 연속으로 취득한 프레임을 정합하여 서브맵을 생성함으로써 단일 프레임의 희소성을 보완하고[3], 추정된 지면 평면을 기준으로 획득된 점군을 보정하여 센서 위치에 관계없이 일관된 좌표계를 확보한다. 이후 객체가 존재할 가능성이 높은 높이 영역만을

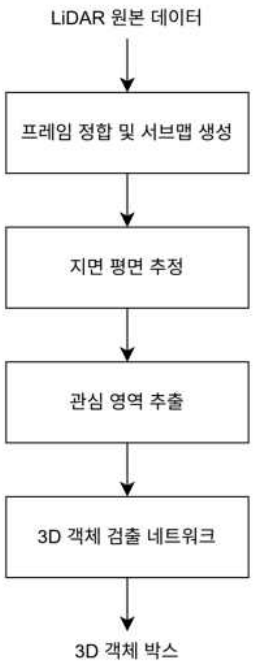


그림 1. 제안 시스템 구조도

Fig. 1. Proposed system architecture

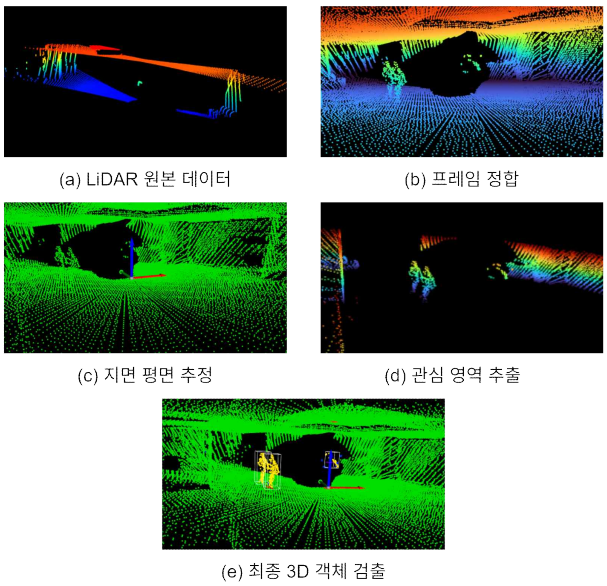


그림 2. 제안 방법의 단계별 처리 결과
Fig. 2. Step-by-step results of the proposed method

추출하여 3차원 객체 검출 네트워크에 입력함으로써 불필요한 배경 점을 줄이고 검출 성능과 처리 속도를 향상시킨다.

2.2. 객체 관심 영역 추출

핸드헬드 스캐너는 데이터 취득 과정에서 롤(roll)과 피치(pitch) 변화가 발생하므로 점군의 z축이 실제 지면의 수직 방향과 일치하지 않게 된다. 이를 보정하기 위해 RANSAC[4]을 이용하여 지면 평면을 추정한다. 지면 평면은 식 (1)과 같이 표현된다.

$$ax + by + cz + d = 0 \quad (1)$$

여기서 a, b, c는 지면 평면의 법선 벡터 성분이고 d는 원점으로부터의 거리이며, 추정된 법선 벡터가 기준 좌표계의 z축과 일치하도록 점군에 회전 변환을 적용한다. 이후 보정된 z축을 기준으로 객체가 존재할 가능성이 높은 높이 범위만을 선택하여 지면과 천장 등 불필요한 점을 제거한다. 이를 통해 핸드헬드 스캐너의 자세 변화에도 일관된 높이 기준을 확보하고, 객체 검출에 필요한 영역만으로 입력 점군을 구성한다.

그림 2는 제안 방법의 처리 단계에 따른 점군 변화를 나타낸다. LiDAR 원본 데이터(a)는 프레임 정합을 통해 주변 구조와 객체 정보가 누적된 서브맵(b)으로 생성되며, 지면 평면 추정(c)을 통해 높이 방향이 정규화된다. 이후 관심 영역 추출(d)로 지면과 천장 영역의 점이 제거되고, 최종적으로 전처리된 점군에서 3차원 객체 검출(e)을 수행한다.

III. 실험

3.1. 실험 환경

실험에는 그림 3과 같은 핸드헬드 스캐너를 이용하여 실내 환경의 점군 데이터를 취득하였다. 취득한 데이터는 총 50,000개 프레임으로 구성되며, 학습과 평가에 서로 다른 촬영 시나리오를 사용하여 각각 45,000개와 5,000개 프레임으로 분리하였다. 검출 대상은 보행자이며, 각 서브맵에 3차원 바운딩 박스를 수동으로 라벨링하였다. 서브맵은 20개 프레임을 누적하여 생성하였고, 객체 검출 범위는 핸드헬드 스캐너로부터 10 m 이내로 설정하였다.



그림 3. 핸드헬드 스캐너
Fig. 3. Handheld scanner

실험은 전처리를 적용하지 않은 경우와 제안한 지면 평면 추정 및 관심 영역 추출을 적용한 경우를 구분하고, 두 경우 모두 동일한 PointPillar[2] 모델로 학습 및 평가하여 전처리의 효과만을 비교하였다. 검출 성능 지표는 IoU 임계값 0.3 기준의 평균 정밀도(AP@0.3)를 사용하였으며, 학습과 추론은 NVIDIA RTX 3090 GPU 환경에서 수행하였다.

표 4. 전처리 적용 여부에 따른 객체 검출 성능 비교
Table. 1. Detection performance with and without the proposed preprocessing

Method	AP@0.3
PointPillars[2]	70.63
Ours	85.33

표 5. 제안 방법의 추론 시간 및 처리 속도
Table. 2. Inference time of the proposed method

GPU	Inference time	FPS
NVIDIA RTX 3090	5.51 ms	181.50

3.2. 3차원 객체 검출 비교 평가

표 1은 전처리 적용 여부에 따른 객체 검출 성능을 비교한 결과이다. 전처리를 적용하지 않은 경우 AP@0.3은 70.63%이였으며, 제안 방법을 적용한 경우 85.33%으로 14.70% 향상되었다. 이는 기존 대비 약 20.80%의 상대적 성능 향상으로, 지면 평면 추정과 관심 영역 추출이 객체 검출에 효과적인 입력 점군을 구성하는 데 기여함을 보여준다.

표 2는 제안 방법의 처리 속도를 나타낸다. NVIDIA RTX 3090 환경에서 객체 검출의 평균 추론 시간은 5.51 ms로, 약 181.50FPS의 처리 성능을 보였다. 이를 통해 제안 방법이 높은 검출 성능을 유지하면서 실시간 처리가 가능한수준의 연산 성능을 갖는 것을 확인하였다.

IV. 결론

본 논문에서는 지면 평면 추정과 관심 영역 추출을 이용한 핸드헬드 스캐너 기반 3차원 객체 검출 방법을 제안하였다. 실내 환경 실험 결과 제안한 전처리를 적용한 경우 AP@0.3이 70.63%에서 85.33%으로 약

20.80% 향상되었으며, NVIDIA RTX 3090 환경에서 평균 추론 시간 5.51 ms 약 181.50FPS의 실시간 처리 성능을 확인하였다. 향후 실외 환경과 다양한 객체 클래스로 검출 대상을 확장하여 제안 방법의 범용성을 높이고자 한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] R. Otero, S. Lagüela, I. Garrido, and P. Arias, "Mobile Indoor Mapping Technologies: A Review," Automation in Construction, vol. 120, Art. no. 103399, Dec. 2020.

[2] A. H. Lang, S. Vora, H. Caesar, L. Zhou, J. Yang, and O. Beijbom, "PointPillars: Fast Encoders for Object Detection from Point Clouds," Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition (CVPR), pp. 12697–12705, June 2019.

[3] K. Koide, M. Yokozuka, S. Oishi, and A. Banno, "GLIM: 3D Range-Inertial Localization and Mapping with GPU-Accelerated Scan Matching Factors," *Robotics and Autonomous Systems*, vol. 179, Art. no. 104750, 2024.

[4] M. A. Fischler and R. C. Bolles, "Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography," Communications of the ACM, vol. 24, no. 6, pp. 381–395, June 1981.

LiDAR 보정을 활용한 험지 이동로봇의 강인한 3차원 객체 검출

강한빈, 김민성*, 정현일**, 박태형***
충북대학교 지능로봇공학전공, *충북대학교 제어로봇공학전공, **충북대학교 산업인공지능학과,
***충북대학교 지능로봇공학과
strong_b7326@chungbuk.ac.kr, *kim_min_sung@naver.com, **chohi@mobigen.com,
***taehpark@cbnu.ac.kr

Robust 3D Object Detection for Rough-Terrain Mobile Robots Using LiDAR Compensation

Hanbin Kang, Minsung Kim*, Hyunll Chong**, Taehyoung Park***
Department of Intelligent Robotics Engineering, Chungbuk National Univ.,
*Department of Control and Robotics Engineering, Chungbuk National Univ.,
**Department of Industrial AI, Chungbuk National Univ.,
***Department of Intelligent Robotics Engineering, Chungbuk National Univ.

Abstract

Rough-terrain navigation induces variations in robot attitude and vibrations, resulting in LiDAR tilt and motion distortion that degrade 3D object detection performance. To address these challenges, this study proposes a lightweight LiDAR-IMU-Camera-based 3D pedestrian detection system. Ego-motion-based deskewing and gravity alignment are applied to LiDAR point clouds, followed by DBSCAN clustering of points within camera-defined regions of interest (ROIs). The optimal cluster is selected based on image alignment, track priors, and similarity to typical human dimensions. Subsequently, Tiny PointNet predicts residual offsets relative to an anchor box to refine the final 3D bounding box. Experimental results on a self-collected rough-terrain dataset demonstrate that the combined application of deskewing and gravity alignment improves detection performance, while the proposed detection pipeline achieves a 21.79 percentage-point improvement in AP25 compared with CenterPoint under identical correction conditions.

Key words : Rough Terrain, LiDAR, Camera-LiDAR Fusion, Deskewing, Gravity Alignment, 3D Object Detection

Ⅰ. 서 론

최근 자율주행 및 이동로봇 기술은 비정형 · 비포장 환경으로 적용 범위가 확대되고 있다[1]. 그러나 험지에서는 roll · pitch 변화와 LiDAR scan 중 ego-motion으로 인해 point cloud의 자세 오차와 motion distortion이 발생하며, 이는 Camera-LiDAR 정합 및 객체 검출 성능을 저하시킬 수 있다[2, 3].

본 연구에서는 LiDAR 보정을 검출 전처리로 결합한 험지 이동로봇용 3차원 보행자 검출 방법을 제안하고, 자체 험지 주행 데이터에서 LiDAR 기반 객체 검출[7]과의 비교 및 보정 · 구성 요소별 ablation을 통해 그 효과를 분석한다.

Ⅱ. 본론

1. 전체 시스템 구성

제안 시스템의 전체 구성은 Fig. 1과 같다. Camera에서 검출된 2D bounding box를 기반으로 ROI를 생성하고, LiDAR point cloud에는 IMU 보정과 모션 왜곡 보정을 적용한다. ROI 내부 point를 Clustering 한 후 2D bbox 중심 근접도, Track Prior 및 사람 크기 유사도를 이용하여 최고 점수 cluster를 선택하며, TinyPointNet을 통해 최종 3D Bounding Box를 생성한다.

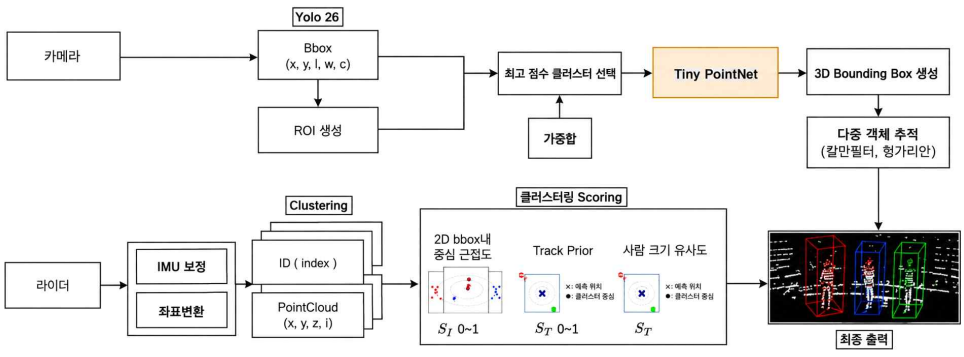


그림 1 제안하는 보행자 인지 시스템의 전체 구조

Fig. 1 Overall framework of the proposed pedestrian perception system.

2. 모션 왜곡 보정 (Motion Distortion Compensation)

회전형 LiDAR는 하나의 point cloud를 순간적으로 획득하는 것이 아니라 일정한 scan period 동안 순차적으로 주변 환경을 측정한다. 이동 플랫폼이 scan 도중 병진 또는 회전 운동을 수행하면 scan 시작 시점과 종료 시점 사이의 sensor pose가 달라지며, 서로 다른 pose에서 측정된 point가 하나의 point cloud에 포함된다. 이러한 motion distortion은 LiDAR-IMU 기반 odometry 및 point cloud processing에서 중요한 보정 대상으로 다루어진다[2, 3].

Fig. 2는 동일 장면에서 모션 왜곡 보정 전후의 LiDAR point cloud를 비교한 결과이다.

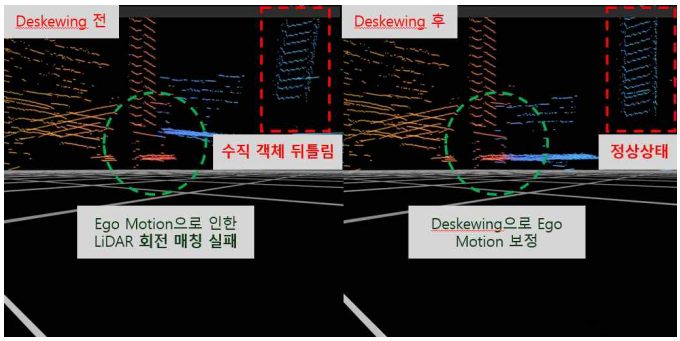


그림 2 보정 전후 LiDAR point cloud의 정성적 비교

Fig. 2 Qualitative comparison of LiDAR point clouds before and after compensation.

본 연구에서는 각 LiDAR point의 측정 시각 t_i에 해당하는 sensor pose를 추정하고 이를 기준 시점 t_{ref}의 좌표계로 변환한다.

$$p_i^{ref} = T_{ref}^{-1} T_i p_i \tag{1}$$

여기서 p_i는 시각 t_i에서 취득된 LiDAR point이며, $T(t_i)$와 T_{ref}는 각각 해당 시점과 기준 시점의 sensor pose를 나타낸다. 이를 통해 하나의 scan 내부에서 발생하는 ego-motion의 영향을 감소시킨다.

3. IMU 보정 (Gravity Alignment)

IMU 보정(Gravity Alignment)은 험지 주행에 따른 LiDAR 좌표계의 roll 및 pitch 변화를 보정한다. IMU에서 관측한 중력 방향을 이용하면 roll과 pitch를 제약할 수 있으며, 기존 연구에서는 이를 이용해 point cloud registration을 4-DoF 문제로 단순화하였다[4]. 본 연구에서는 추정된 중력 방향을 기준으로 LiDAR point cloud를 정렬하고 yaw는 유지한다.

$$P_{aligned} = R_{gravity} P_{deskew} \tag{2}$$

Yaw는 중력 정보만으로 직접 결정할 수 없으므로 유지하며, 결과적으로 translation 3축과 yaw로 구성된 4-DoF 표현을 사용한다.

4. Camera ROI 기반 LiDAR 후보 추출

Camera의 2D detection 결과를 이용하여 LiDAR point cloud의 탐색 영역을 제한하는 방식은 기존 연구에서도 활용되어 왔다[5]. 본 연구에서는 YOLO로 검출한 2D bounding box 내부에 투영되는 LiDAR point를 ROI 후보로 사용한다.

RGB 영상에서 YOLO를 이용하여 보행자의 2D bounding box를 검출한 후, LiDAR point P_L을 LiDAR-Camera extrinsic parameter를 이용하여 camera coordinate frame으로 변환한다.

$$P_C = T_C^L P_L \tag{3}$$

이후 camera intrinsic matrix K를 이용하여 영상 좌표 (u, v)로 투영한다.

$$s\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K\begin{bmatrix} X_C \\ Y_C \\ Z_C \end{bmatrix} \tag{4}$$

Fig. 3은 동일한 RGB frame에서 보정 전후의 Camera-LiDAR projection 결과를 비교한다. Raw 상태, Deskew 적용 상태, Deskew와 Gravity Alignment를 함께 적용한 상태를 나란히 제시하여 객체 bounding box와 projected LiDAR point 사이의 정합 변화를 확인한다.



그림 3 LiDAR 보정 전후의 Camera-LiDAR 투영 결과

Fig. 3 Camera-LiDAR projection results before and after LiDAR compensation.

이후 bounding box 내부에 투영된 LiDAR point만을 추출하여 후단 군집화 과정의 입력으로 사용한다.

5. Clustering 및 클러스터링 Scoring

카메라의 2D bounding box 내부에는 실제 보행자 point뿐만 아니라 객체 뒤쪽의 벽, 지면 또는 주변 구조물에 해당하는 LiDAR point가 함께 포함될 수 있다. 따라서 ROI 내부의 모든 point를 객체로 사용하는 경우 잘못된 3차원 위치 및 크기 추정이 발생할 수 있다.

본 연구에서는 ROI 내부 point에 DBSCAN을 적용하여 복수의 cluster 후보를 생성한다. 각 cluster에 대해 2D bounding box 중심과 projected cluster 중심 사이의 근접도를 이용한 image score S_image, 이전 frame의 Kalman filter 예측 위치와 현재 cluster 중심의 일관성을 나타내는 track score S_track, 사람의 일반적인 기하학적 크기와 cluster 형상의 유사성을 나타내는 human geometry score S_human을 계산한다.

$$S = w_1 S_{img} + w_2 S_{track} + w_3 S_{human} \tag{5}$$

가중치 w_1, w_2, w_3는 각 score의 영향도를 조절하며, 최종적으로 가장 높은 S를 갖는 cluster를 보행자 후보로 선택한다. Fig. 4는

Camera ROI 내부 point 추출, DBSCAN 군집화, 각 cluster의 scoring 및 Top-1 cluster 선택 과정을 순차적으로 나타낸다.



그림 4 DBSCAN 군집화와 기하 기반 Scoring을 이용한 보행자 후보 선택
Fig. 4 Pedestrian candidate selection using DBSCAN clustering and geometry-based scoring.

6. TinyPointNet 기반 3D Bounding Box 생성

선택된 LiDAR cluster는 일정한 개수의 point로 sampling 또는 padding한 뒤 TinyPointNet에 입력한다. PointNet은 point-wise MLP와 symmetric pooling 연산을 이용하여 point 순서에 독립적인 global feature를 생성할 수 있다[6].

$$p_i = (x_i, y_i, z_i) \tag{6}$$

Point-wise feature extraction 이후 global max pooling을 통해 객체 전체의 geometry feature를 생성하고, 최종 prediction head에서 객체의 3차원 중심, 크기 및 yaw를 회귀한다.

$$B = [x, y, z, w, l, h, \theta] \tag{7}$$

Fig. 5는 제안 방법을 통해 추정된 최종 3차원 bounding box의 정성적 결과를 나타낸다. 평지, 경사 또는 요철 조건의 대표 frame을 배치하여 차체 자세 변화가 존재하는 상황에서도 객체 후보가 유지되고 3차원 box가 생성되는 과정을 확인한다.

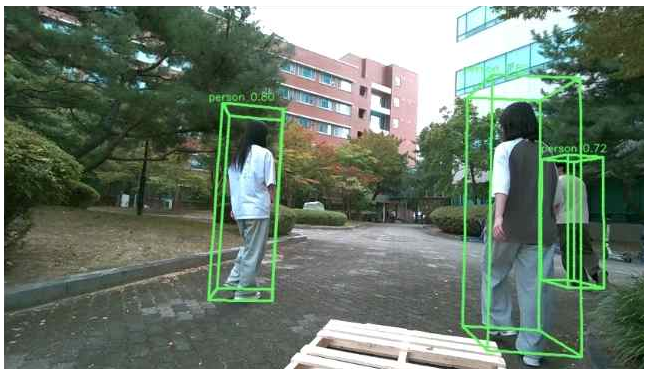


그림 5 험지 환경에서의 3차원 보행자 검출 정성적 결과
Fig. 5 Qualitative 3D pedestrian detection results in rough-terrain environments.

7. 다중 객체 추적

최종 3차원 bounding box는 frame 간 객체 위치의 연속성을 유지하기 위해 다중 객체 추적 단계로 전달된다. 각 track의 state는 Kalman filter를 이용하여 다음 frame의 객체 위치를 예측하고, prediction과 현재 detection 간 association은 Hungarian algorithm을 이용하여 수행한다. 추적 결과는 객체 ID의 시간적 연속성을 제공하는 동시에 다음 frame의 S_track 계산에 사용되는 prior 위치를 제공한다.

Ⅲ. 실험 결과

1. 실험 환경 및 평가 방법

제안 방법의 성능은 자체 구축한 험지 주행 데이터 중 선별한 단일 시퀀스(수동 라벨링된 251 frame)를 대상으로 평가하였다. 동일한 입력 시퀀스에서 기준 모델인 CenterPoint[7]와 제안 방법의 3차원 객체 검출 성능을 비교하고, 제안 방법에 대해서는 Deskewing과 Gravity Alignment의 적용 여부를 조합한 ablation 실험과, 두 보정을 모두 적용한 조건에서 파이프라인 구성 요소별 ablation 실험을 수행하였다. 평가 지표로 Precision, Recall, F1-score, AP25 및 AP50을 사용하였다. Precision, Recall 및 F1-score는 3D IoU 0.25 기준으로 계산하였다. CenterPoint와 TinyPointNet은 JRDB 데이터셋으로 사전학습한 뒤 자체 구축한 평지 주행 데이터로 추가 학습하였으며, 험지 평가 시퀀스는 학습에 사용하지 않았다. 추론 시간은 RTX 5080 GPU에서 batch 크기 1로 측정하였으며, 적용된 LiDAR 보정과 제안 방법의 YOLO 2D 검출 시간을 포함한다.

2. CenterPoint와 제안 방법 비교

Table 1은 CenterPoint와 제안 방법의 검출 성능을 비교한 결과이다. CenterPoint에 Deskewing과 Gravity Alignment를 적용하면 F1-score는 3.24%p 증가하였으며, AP50은 16.99%p 향상되었다. 이는 LiDAR의 motion distortion과 자세 변화가 엄격한 IoU 기준의 3차원 bounding box 정합에 영향을 미칠 수 있음을 보여준다.

표 1 CenterPoint와 제안 방법의 3차원 객체 검출 성능 비교
Table 1 Comparison of 3D object detection performance between CenterPoint and the proposed method.

방법	Deskew	중력보정	F1 (%)	AP25 (%)	AP50 (%)	추론 시간 (ms)
CenterPoint	×	×	73.61	73.50	32.88	18.7
CenterPoint	✓	✓	76.85	76.93	49.87	21.8
제안방법	✓	✓	98.89	98.72	51.74	42.2

본 결과는 선별된 단일 시퀀스에 대한 결과이며, Camera ROI 기반 후보 제한과 geometry-based cluster selection을 포함한 제안 파이프라인이 해당 시퀀스에서 안정적으로 동작했음을 보여준다. 또한 Table 1의 두 번째 행과 세 번째 행은 동일한 보정 조건에서의 비교이므로, 두 방법 간 AP25 21.79%p, AP50 1.87%p의 차이는 LiDAR 보정이 아닌 검출 구조의 차이에 기인한다. 제안 파이프라인을 구성하는 각 요소의 기여도는 4절의 구성 요소 ablation(Table 3)에서 분석한다.

3. Deskewing 및 Gravity Alignment Ablation

Table 2는 제안 방법에서 Deskewing과 Gravity Alignment의 영향을 분석한 ablation 결과이다. 보정을 적용하지 않은 경우 F1-score는 97.46%, AP50은 44.62%였으며, Deskewing만 적용한 경우 AP50은

47.78%, Gravity Alignment만 적용한 경우 48.31%로 증가하였다.

표 2 Deskewing 및 Gravity Alignment에 따른 제안 방법의 성능 변화
Table 2 Ablation results for Deskewing and Gravity Alignment.

Deskew	중력보정	Precision (%)	Recall (%)	F1 (%)	AP25 (%)	AP50 (%)	추론 시간 (ms)
×	×	97.76	97.17	97.46	96.59	44.62	39.06
✓	×	97.79	98.58	98.19	97.97	47.78	41.91
×	✓	98.17	97.57	97.87	97.08	48.31	39.31
✓	✓	98.59	99.19	98.89	98.72	51.74	42.21

특히 두 보정을 함께 적용한 경우 AP50은 무보정 대비 7.12%p, F1-score는 1.43%p 향상되었다. 이는 Deskewing과 Gravity Alignment의 효과가 단순한 객체 검출 여부보다 3차원 bounding box의 공간적 정합 정확도에서 더 크게 나타났음을 시사한다.

4. 구성 요소 Ablation

Table 3은 Deskewing과 Gravity Alignment를 모두 적용한 조건에서 Camera ROI, 제안 클러스터링, TinyPointNet을 순차적으로 추가한 결과이다. Camera ROI를 적용하면 F1-score가 51.33%p 향상되었으며, 제안 클러스터링과 TinyPointNet은 AP50을 각각 13.55%p, 19.26%p 향상시켰다. 이는 Camera ROI가 객체 후보 검출을, 제안 클러스터링과 TinyPointNet이 3차원 bounding box의 정합 정확도를 주로 개선함을 보여준다.

표 3 구성 요소별 ablation 결과
Table 3 Ablation results for each component of the proposed method.

구성	F1 (%)	AP25 (%)	AP50 (%)
LiDAR 전체 클러스터링	40.40	33.34	7.57
+ Camera ROI	91.73	86.76	18.93
+ 제안 클러스터링	93.45	89.83	32.48
+ TinyPointNet (제안 방법)	98.89	98.72	51.74

Ⅳ. 결론

본 연구에서는 험지 환경에서의 보행자 인지를 위해 LiDAR의 모션 왜곡 및 자세 변화를 보정하고, Camera ROI 기반 Clustering과 Scoring, TinyPointNet을 결합한 3차원 객체 검출 시스템을 제안하였다. 이를 통해 LiDAR point cloud의 보정부터 객체 후보 선택 및 3D Bounding Box 생성까지 하나의 경량 파이프라인으로 구성하였다.
자체 험지 주행 시퀀스에서 두 LiDAR 보정을 함께 적용한 경우 제안 방법의 AP50은 무보정 대비 7.12%p 향상되었으며, CenterPoint에서도 동일 보정 적용 시 AP50이 16.99%p 증가하였다. 향후에는 다양한 지형, 이동 속도 및 다중 시퀀스를 대상으로 평가 범위를 확대할 예정이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Min, C., Si, S., Wang, X., Xue, H., Jiang, W., et al., "Autonomous Driving in Unstructured Off-Road Environments: How Far Have We Come?," Journal of Field Robotics, Vol. 43, No. 5, pp. 3403-3439, 2026.

[2] Xu, W., Cai, Y., He, D., Lin, J., and Zhang, F., "FAST-LIO2: Fast Direct LiDAR-Inertial Odometry," IEEE Transactions on Robotics, Vol. 38, No. 4, pp. 2053-2073, 2022.

[3] Shan, M., Berrio, J. S., Worrall, S., and Nebot, E., "Probabilistic Egocentric Motion Correction of LiDAR Point Cloud and Projection to Camera Images for Moving Platforms," Proceedings of the IEEE 23rd International Conference on Intelligent Transportation Systems, pp. 1-8, 2020.

[4] Kubelka, V., Vaidis, M., and Pomerleau, F., "Gravity-Constrained Point Cloud Registration," Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems, pp. 4873-4879, 2022.

[5] Qi, C. R., Liu, W., Wu, C., Su, H., and Guibas, L. J., "Frustum PointNets for 3D Object Detection from RGB-D Data," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 918-927, 2018.

[6] Qi, C. R., Su, H., Mo, K., and Guibas, L. J., "PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 652-660, 2017.

[7] Yin, T., Zhou, X., and Kr□henb□hl, P., "Center-based 3D Object Detection and Tracking," Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 11784-11793, 2021.

의미적 장소 검색과 기하학적 검증을 이용한 UAV-UGV 위치추정

김수민, 김태우, 신재웅*, 황영배**
충북대학교 제어로봇공학전공, *충북대학교 지능로봇공학전공, **충북대학교 지능로봇공학과
tnals4026@chungbuk.ac.kr, gomtae8@gmail.com, *siuoeipep@chungbuk.ac.kr,
*ybhwang@chungbuk.ac.kr

UAV-UGV Localization Using Semantic Place Retrieval and Geometric Verification

Sumin Kim, Taewoo Kim, Jaewoong Shin*, Youngbae Hwang**
Department of Control and Robotics Engineering, Chungbuk National Univ.
*Department of Intelligent Systems and Robotics, Chungbuk National Univ.,
**Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

This paper proposes a localization method for UAV and UGV cooperation by combining semantic place recognition with geometric pose estimation under different viewpoints. SigLIP2 is used to retrieve similar keyframes from an existing ORB-SLAM3 map using full image features. A local 3D map is constructed using up to 14 temporally adjacent keyframes, and the camera pose is estimated through ORB feature matching and PnP optimization. Experiments on the CoPeD dataset achieved retrieval rates of 65% and 80% for the top two candidates, outperforming DBoW2 in both scenarios. The method generated pose estimates for all 20 selected queries, demonstrating its potential for localization across different viewpoints, although absolute accuracy remains subject to map alignment uncertainty.

Key words : UAV-UGV Localization, Semantic Place Recognition, VLM, SLAM, Geometric Pose Estimation

Ⅰ. 서 론

무인항공기(Unmanned Aerial Vehicle, UAV)와 무인지상차량(Unmanned Ground Vehicle, UGV)의 통합 운용은 서로 다른 이동 능력과 관측 범위를 활용하여 단일 로봇의 환경 인식 및 임무 수행 범위를 확장할 수 있다. 이러한 협력 운용에서 관측 정보를 공간적으로 결합하고 상호 위치에 기반한 이동을 수행하기 위해서는 두 로봇의 위치와 자세를 공통 좌표계에서 표현하는 것이 필수적이다. 그러나 각 로봇이 독립적으로 위치추정과 지도 생성을 수행하면 서로 다른 로컬 좌표계가 형성되므로, 한 로봇의 관측을 이용하여 다른 로봇의 지도 좌표계에서 위치와 자세를 추정할 필요가 있다.

그러나 UAV와 UGV는 이동 자유도, 카메라 장착 높이 및 관측 방향의 차이로 인해 동일한 공간에서도 서로 다른 시점을 갖는 경우가 일반적이다[1]. 특히 동일한 공간을 관측하더라도 시점 변화에 따라 영상에 나타나는 대상의 형태와 크기, 가려짐 및 배경 구성이 달라질 수 있다. 이러한 변화는 두 영상에서 반복적으로 검출되는 국소 특징점의 수를 감소시키거나 잘못된 대응을 발생시켜, 특징점 매칭에 의존하는 기하학적 위치추정을 어렵게 할 수 있다. 따라서 시점 차이가 큰 환경에서는 국소 특징점에 의존하는 장소 검색을 보완할 수 있는 영상 수준의 특징 정보를 활용할 필요가 있다.

본 연구에서는 시점 차이에 따른 장소 검색의 어려움을 보완하고자 시각-언어 사전학습 모델인 SigLIP2[2]의 영상 인코더를 이용하여 전체 영상의 특징을 추출한다. 이를 기반으로 상대 로봇이 생성한 ORB-SLAM3 지도[3]에서 유사 키프레임을 검색하고, 검색된 키프레임의 시간순 주변 지도점을 활용하여 단일 질의 영상의 ORB 특징점과 3차원 지도점 간 대응을 생성한다. 이후 PnP 기반 위치 가설 생성과 재투영 오차 기반 자세 정제를 통해 기존 지도 좌표계에서 질의 로봇의 위치와 자세를 추정한다. 이를 통해 전체 영상의 의미적 · 시각적 특징과 기하학적 정보를 결합한 UAV-UGV 간 위치추정 방법의 적용 가능성을 평가한다.

Ⅱ. 본론

본 연구의 UAV-UGV 위치추정 시스템은 전체 영상 임베딩 기반 키프레임 검색과 시간순 부분 지도 기반 기하학적 위치추정으로 구성한다. 위치를 추정하려는 로봇을 질의 로봇, 기존 지도를 제공하는 로봇을 지도 로봇으로 정의한다. 질의 로봇의 영상 한 장으로 지도 로봇의 유사 키프레임을 검색한 후, 해당 키프레임 주변의 3차원 지도점을 이용하여 지도 좌표계에서 질의 카메라의 위치와 자세를 추정한다. UAV와 UGV 중 어느 로봇이 질의 로봇이 되더라도 같은 처리 구조를 적용한다.

지도 로봇은 사전에 ORB-SLAM3를 이용하여 희소 지도를 구축해야 한다. 각 키프레임에는 전체 영상의 SigLIP2 특징, 촬영 시각, 카메라 위치 · 자세, ORB 특징점의 픽셀 좌표와 디스크립터, 특징점에 연결된 맵포인트 ID를 저장한다. 맵포인트에는 지도 좌표계의 3차원 좌표와 ORB 기술자 및 관측 관계를 유지한다. 질의 로봇의 기존 로컬 지도나 궤적은 위치추정 입력에 포함되지 않으며, 관측 영상과 지도 로봇의 3차원 맵포인트를 사용한다.

1. 영상 임베딩 기반 키프레임 검색

질의 로봇의 영상과 지도 로봇의 키프레임을 비교하기 위해 SigLIP2 영상 인코더를 사용한다. 입력은 정류된 좌측 적외선 영상이며, 단일 채널의 밝기값을 세 채널로 복제한 뒤 모델의 전처리를 적용한다. SigLIP2-base-patch16-256을 이용하여 전체 영상의 정보를 768차

원 특징 벡터로 표현한다. 지도 키프레임의 특징은 사전에 계산하여 저장하고, 질의 영상의 특징은 검색 시 생성한다.

질의 영상의 특징 벡터를 $\mathbf{f}_q$, 지도 키프레임 $\boldsymbol{k}$ 의 특징 벡터를 $\mathbf{f}_q$라 하면 코사인 유사도는 다음과 같다.

$$s_k = \frac{\mathbf{f}_q^T \mathbf{f}_k}{\|\mathbf{f}_q\|_2 \|\mathbf{f}_k\|_2} \quad (1)$$

모든 검색 대상 키프레임에 대해 코사인 유사도를 계산하고, 유사도가 높은 상위 2개를 후속 위치추정의 기준 키프레임으로 선택한다. 이때 특징 유사도는 관측 장면의 유사성을 나타내는 검색 점수이며, 동일한 물리적 장소나 정확한 카메라 위치를 보장하지 않는다. 따라서 검색된 키프레임의 실제 3차원 지도점을 이용하는 기하학적 위치추정 단계를 별도로 수행한다.

검색 성능은 CoPeD 데이터셋의 Race5 UAV→Wilbur UGV와 Ptah UGV→Race1 UAV 두 방향에서 평가하였다. Race5-Wilbur에서는 질의 영상 20개와 검색 대상 키프레임 353개를, Ptah-Race1에서는 질의 영상 15개와 키프레임 622개를 사용하였다. 비교 방법은 ORB 특징을 시각단어 벡터로 변환하는 DBoW2 기반 검색으로, ORB-SLAM3의 후보 검색 구현을 이용하였다[4]. 두 방법에는 동일한 질의 영상과 검색 대상 키프레임을 적용하였다.

평가 지표인 top-$\boldsymbol{n}$ 은 상위 $\boldsymbol{n}$ 개 후보 중 정답으로 표시된 키프레임이 하나 이상 포함된 질의의 비율이다. 영상 쌍 검수에서 동일 장소의 관측으로 표시한 경우를 정답으로 인정하고, 정답 표시가 없는 경우는 비적중으로 집계하였다.

표 1 SigLIP2 영상 특징과 DBoW2 기반 키프레임 검색 결과

Table 1 Results of Keyframe Retrieval Using SigLIP2 Image Features and DBoW2

검색 방향	방법	top-$\boldsymbol{n}$ 적중률(%)			검색 시간(ms)
		1	2	5	
Race5→Wilbur	SigLIP2	60.0	65.0	75.0	9.76
Race5→Wilbur	DBoW2	5.0	40.0	75.0	9.92
Ptah→Race1	SigLIP2	66.7	80.0	100.0	10.08
Ptah→Race1	DBoW2	60.0	60.0	60.0	12.24

표1의 검색 시간은 질의 영상에서 특징을 새로 생성하는 시간과 후보 선정시간의 합이다. SigLIP2는 영상 전처리와 임베딩 생성을, DBoW2는 ORB 특징 추출과 BoW 변환을 특징 생성시간에 포함하였다. 시간은 이 실험에서 상위 5개 후보 선정까지 측정한 값이다.

실험 결과, SigLIP2는 두 방향 모두에서 DBoW2보다 높은 적중률을 보였다. 후속 위치 추정에 사용하는 상위 2개 후보의 적중률은 Race5-Wilbur에서 65.0%, Ptah-Race1에서 80.0%였다. 처리시간은 Race5-Wilbur에서 두 방법이 유사하였고, Ptah-Race1에서는 SigLIP2가 더 짧았다.

2. 시간순 부분 지도 기반 기하학적 위치추정

검색된 상위 2개 키프레임만으로는 질의 영상과 대응되는 지도점을 충분히 확보하지 못할 수 있으므로, 시간순 주변 키프레임을 이용하는 방식으로 부분 지도를 구성한다. 각 기준 키프레임에서 시간순 이전 3개와 이후 3개를 선택하고, 기준 키프레임을 포함한 두 목록의 중복을 제거한다. 중복 제거로 14개보다 적어지면 선택 구간의 이전 · 이후 방향으로 번갈아 확장하여 최대 14개의 서로 다른 키프레임을 확보한다. 확장은 동일한 SLAM 실행과 지도 성분 내부에서만 수행한다. 즉, 선정된 키프레임 집합을 $\boldsymbol{S}$, 키프레임 $\boldsymbol{k}$ 가 실제로 관측한 MapPoint 집합을 $\boldsymbol{P}_k$라 하면 부분 지도는 다음과 같다.

$$\boldsymbol{P}_S = \bigcup_{k \in S} \boldsymbol{P}_k, \quad |\boldsymbol{S}| \le 14 \quad (2)$$

동일한 맵포인트는 ID를 기준으로 중복 제거하고, 원본 3차원 좌표와 특징점 관측 연결을 유지한다. 추가 키프레임은 맵포인트를 공급하는 역할을 하며, 질의 영상은 한 장만 사용한다. 두 기준 키프레임이 같은 지도 성분에 속하면 구성된 부분 지도를 두 위치 가설 생성에 공통으로 사용한다.

지도 및 참조 궤적의 미터 단위 스케일은 각 로봇의 사전 SLAM에서 스테레오 카메라의 알려진 기선 길이 또는 IMU를 결합한 시각-관성 초기화를 통해 추정한다. 따라서 본 위치추정에서는 스케일을 별도로 추정하지 않고, 기존 지도 좌표계에 대한 회전과 병진만 계산한다.

질의 영상에서 ORB 특징점과 기술자를 추출한 후[5], 선정된 키프레임 각각과 BoW 기반 특징점 매칭을 수행한다. 이 단계의 BoW는 장소를 다시 검색하기 위한 것이 아니라, 이미 선정된 키프레임과 질의 영상 사이의 ORB 대응을 찾는 데 사용한다. 기술자 거리 비율과 특징점 방향 일관성을 검사하며, 여러 키프레임에서 같은 질의 특징점 또는 MapPoint에 대한 대응이 생성되면 해밍 거리가 작은 대응을 우선하여 중복 배정을 제거한다.

지도 좌표계를 M, 질의 카메라 좌표계를 C로 정의한다. 지도점 $\mathbf{P}_i^M$와 실제 질의 픽셀 $\mathbf{u}_i$의 대응이 주어졌을 때, 예측 픽셀은

$$\widehat{\mathbf{u}}_i = \pi_K\left(R_{CM}\boldsymbol{P}_i^M + \boldsymbol{t}_{CM}\right) \quad (3)$$

여기서 π_K는 카메라 내부 파라미터를 포함한 투영 함수이며, R_{CM}과 t_{CM}은 지도 좌표를 카메라 좌표로 변환하는 회전과 병진이다. 고유한 2D-3D 대응이 6개 이상이면 MLPnP 기반 RANSAC을 적용하고[6], 유효한 모델을 얻지 못하면 4개 이상의 대응에서 AP3P 기반 대체 계산을 수행한다[7]. 이후 ORB-SLAM3의 Pose 최적화와 투영 기반 추가 매칭을 수행하여 대응을 확장하고 재투영 잔차를 줄인다. 최종 고유 inlier 수가 많은 가설을 우선 선택하며, 동률이면 재투영 오차와 기존 검색 순위를 이용한다. 지도 좌표계에서의 카메라 Pose는 $T_{MC} = T_{CM}^{-1}$로 얻는다.

위치추정 실험은 Race5-Wilbur와 Ptah-Race1의 각 10개 시작점을 선정하여 위치 추정을 시도하였다. 각 질의는 독립적인 단일 영상으로 처리하였다. 위치 차이는 동일 시각의 추정 카메라 중심과 정합 궤적의 카메라 중심 사이 거리로, 회전 차이는 두 자세의 상대 회전각으로 계산하였다. 정답 데이터가 주어지지 않은 관계로, 두 방향의 결과 모두 정합 궤적에 대한 차이로 제시한다.

처리시간은 ORB 특징 생성부터 부분 지도 MapPoint 수집, 대응 검색, PnP · Pose 정제 및 최종 가설 선정까지 측정하였다. SigLIP2 검색, 키프레임 목록 선정, 초기 지도 로딩은 포함하지 않았으며, 각 질의의 실제 1회 실행 계측값을 사용하였다.

표 2 Race5 UAV→Wilbur UGV의 위치추정 결과

Table 1 Localization Results for Race5 UAV to Wilbur UGV

시작점 번호	위치 차이(m)	회전 차이(°)	처리시간(ms)
1	0.584	3.492	63.20
2	0.676	3.546	45.71
3	0.430	5.068	44.79
4	0.523	5.513	19.41
5	0.606	3.320	78.11
6	0.604	3.271	47.93
7	7.327	115.117	90.94
8	0.232	7.457	55.58
9	0.650	6.232	40.85
10	26.832	171.527	88.77

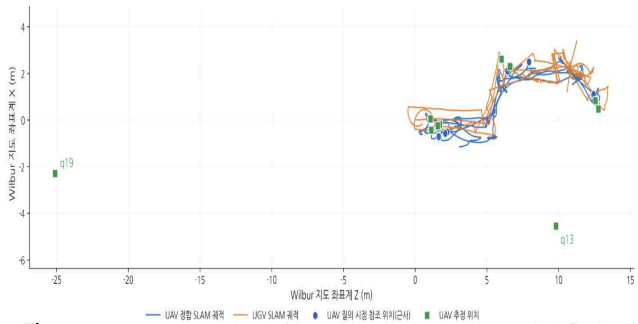


그림 1 Race5-Wilbur의 정합 SLAM 궤적 및 UAV 위치추정 결과 비교

Fig. 1 Comparison of Aligned SLAM Trajectories and UAV Localization Results for Race5-Wilbur

Race5-Wilbur의 선정된 10개 질의 모두에서 Pose를 생성하였으며, 평균 처리시간은 57.53 ms였다. 참조가 존재하는 9개에서 위치 차이 RMSE는 9.284 m, 중앙값은 0.606 m였으며, 8개가 위치 1 m · 회전 10° 이내에 해당하였다.

큰 차이를 보인 번호7과 번호10은 최종 inlier가 각각 15개와 9개로, 다른 선정 질의보다 기하학적 지지가 적었다. 특히 영상쌍 검수에서도 두 질의의 검색 상위 2개 모두 정답으로 표시되지 않았다. 적절한 지도 영역을 검색하지 못했을 가능성과 소수 대응으로 생성된 잘못된 위치 가설을 충분히 배제하지 못한 문제가 함께 나타난 사례로 해석할 수 있다.

표 3 Ptah UGV→Race1 UAV의 위치추정 결과

Table Localization Results for Ptah UGV to Race1 UAV

시작점 번호	위치 차이(m)	회전 차이(°)	처리시간(ms)
1	0.292	0.936	19.02
2	0.206	1.382	89.58
3	0.234	1.443	132.44
4	0.385	1.549	130.52
5	0.695	2.811	129.12
6	0.554	2.973	48.23
7	0.677	0.522	24.26
8	1.132	0.448	20.84
9	0.650	2.756	51.63
10	43.121	58.614	117.78

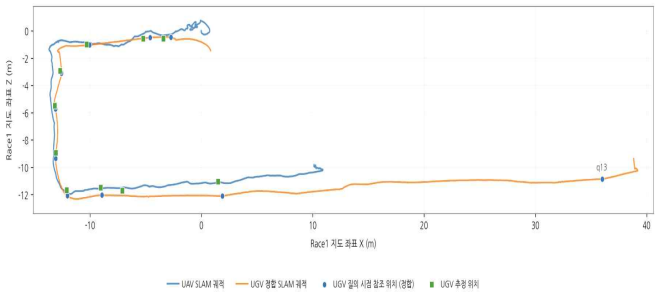


그림 2 Ptah-Race1의 정합 SLAM 궤적 및 UGV 위치추정 결과 비교

Fig. 2 Comparison of Aligned SLAM Trajectories and UGV Localization Results for Ptah-Race1

Ptah-Race1의 선정된 10개 질의 모두에서 Pose를 생성하였으며, 평균 처리시간은 76.34 ms였다. 잠정 정합 궤적에 대한 위치 차이 RMSE는 13.648 m, 중앙값은 0.580 m였고, 8개가 위치 1 m · 회전 10° 이내에 해당하였다. q13에서는 위치 차이가 43.121 m로 크게 나타났으며, 최종 inlier도 20개로 다른 선정 질의보다 적었다. 따라서 충분한 대응으로 지지되지 않은 위치 가설이 선택되었을 가능성이 있다.

Ⅲ. 결론

본 연구에서는 UAV와 UGV 간 관측 시점 차이를 고려하여, 전체 영상 임베딩 기반 키프레임 검색과 시간순 부분 지도 기반 기하학적 위치추정을 결합한 방법을 제안하였다. SigLIP2로 검색한 상위 2개 키프레임을 기준으로 최대 14개 키프레임의 MapPoint를 수집하고, 단일 질의 영상의 ORB 특징점과 3차원 지도점 사이의 대응을 이용하여 카메라의 위치와 자세를 추정하였다.

CoPeD 데이터셋의 검색 비교실험에서 SigLIP2의 Top-2 적중률은 Race5-Wilbur에서 65.0%, Ptah-Race1에서 80.0%로 나타나, DBoW2의 40.0%와 60.0%보다 높았다. 위치추정 평가를 위해 각 방향에서 선정한 10개 질의에서는 각각 8개가 정합 궤적 기준 위치 차이 1 m · 회전 차이 10° 이내에 해당하였다. 이는 전체 영상의 의미적 특징을 이용한 장소 검색과 기존 희소 지도의 기하 정보를 결합하여, 서로 다른 로봇의 관측 사이에서 위치추정을 수행할 수 있음을 보여준다.

다만 일부 질의에서는 최종 위치 가설을 지지하는 대응이 적고 정합 궤적과의 차이가 크게 나타나, 유사 키프레임 검색과 Pose 생성만으로 정확한 위치추정을 보장할 수 없었다. 또한 평가에 사용한 궤적에는 SLAM 및 지도 정합의 불확실성이 포함되었다. 향후 잘못된 검색 후보와 낮은 지지의 위치 가설을 배제하는 검증 절차를 개선하고, 독립적인 정답 궤적과 다양한 시점 조건을 이용하여 정확도와 안정성을 평가할 필요가 있다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Y. Zhou, L. Quang, C. Nieto-Granda, and G. Loianno, "CoPeD-Advancing Multi-Robot Collaborative Perception: A Comprehensive Dataset in Real-World Environments," IEEE Robotics and Automation Letters, vol. 9, no. 7, pp. 6416-6423, 2024..

[2] M. Tschannen et al., "SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features," arXiv preprint arXiv:2502.14786, 2025.

[3] C. Campos, R. Elvira, J. J. G□mez Rodr□guez, J. M. M. Montiel, and J. D. Tard□s, "ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial, and Multimap SLAM," IEEE Transactions on Robotics, vol. 37, no. 6, pp. 1874-1890, 2021.

[4] D. G□lvez-L□pez and J. D. Tard□s, "Bags of Binary Words for Fast Place Recognition in Image Sequences," IEEE Transactions on Robotics, vol. 28, no. 5, pp. 1188-1197, 2012.

[5] E. Rublee, V. Rabaud, K. Konolige, and G. Bradski, "ORB: An Efficient Alternative to SIFT or SURF," Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 2564-2571, 2011.

[6] S. Urban, J. Leitloff, and S. Hinz, "MLPnP: A Real-Time Maximum Likelihood Solution to the Perspective-n-Point Problem," ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences, vol. III-3, pp. 131-138, 2016.

[7] T. Ke and S. I. Roumeliotis, "An Efficient Algebraic Solution to the Perspective-Three-Point Problem," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 4618-4626, 2017.

AI 기반 배터리 상태 추정 및 고장진단 알고리즘을 융합한 BMS 시뮬레이션 모델 개발

이재형, 이동헌, 손현택, 윤재중*

충북대학교 전기공학전공, *충북대학교 전기공학부

meyesjaylee@chungbuk.ac.kr, leedh3014@chungbuk.ac.kr, sonht0952@chungbuk.ac.kr,

*jjyun@chungbuk.ac.kr

Development of a BMS Simulation Model Integrating AI-based Battery State Estimation and Fault Diagnosis Algorithms

Jaehyung Lee, Dongheon Lee, Hyunteak Son, *Jaejung Yun

School of Electrical Engineering, Chungbuk National Univ.,

*School of Electrical Engineering, Chungbuk National Univ.

Abstract

This paper presents LSTM-based algorithms for state-of-charge (SOC) estimation, state-of-health (SOH) estimation, and fault diagnosis of lithium-ion batteries, and validates their integration into a MATLAB/Simulink-based battery-management simulation environment. Voltage, current, temperature, and incremental-capacity features obtained from cylindrical-cell tests were used to train the LSTM models in Python. The trained SOC and SOH networks were exported through ONNX, converted for MATLAB, and implemented using Simulink Predict blocks in conjunction with a Table-Based Battery model. Fault diagnosis was performed by predicting the normal battery voltage and comparing it with the measured voltage using a three-sigma criterion, and the resulting fault signal was linked to a protection function that disconnects the battery current path. The Python-based models achieved root mean square errors (RMSEs) of 1.85% for SOC estimation, 0.11% for SOH estimation, and 1.61% for fault-voltage prediction. In the integrated MATLAB/Simulink environment, the SOC estimation error was approximately 0.04%, while the estimated SOH showed an error of approximately 2.2% relative to the reference SOH, and the battery current was successfully interrupted when a fault was detected. These results demonstrate that the developed LSTM-based state-estimation and fault-diagnosis algorithms can be integrated with a battery model and protection logic for system-level verification.

Key words : Lithium-ion battery, Long-Short Term Memory, State Of Charge , State of Health, Incremental capacity, Fault diagnosis

Ⅰ. 서 론

전기자동차와 에너지저장시스템 등 배터리 기반 응용 분야가 확대됨에 따라, 배터리의 안전성, 수명 및 운용 효율을 확보하기 위한 배터리 관리 시스템(Battery Management System, BMS)의 중요성이 높아지고 있다. 리튬이온 배터리는 반복적인 충·방전 과정에서 열화가 진행되며, 운전 조건에 따라 전압, 온도 및 가용 용량이 달라진다. 또한, 과전류와 같은 비정상적인 운전은 배터리의 성능과 안전성을 저하시킬 수 있다[1]. 따라서 배터리 관리 시스템에는 전압·전류·온도를 측정하는 기능과 함께, 배터리의 상태를 파악하고 이상 징후를 감지하여 적절한 운용과 보호 동작을 지원하는 기능이 요구된다[2].

배터리의 상태를 나타내는 주요 지표인 충전상태(State of Charge, SOC)와 수명상태(State of Health, SOH)는 각각 잔여 충전량과 열화 정도를 판단하는 데 활용된다[3]. SOC 추정은 배터리의 가용 에너지를 파악하고 충·방전 운용 범위를 설정하기 위해 필요하며, SOH 추정은 용량 감소에 따른 성능 변화를 평가하고 유지보수 및 교체 시점을 판단하는 데 필요하다. 이와 함께 과전류 및 전압 센서 이상과 같은 고장은 비정상적인 운전이나 상태 판단 오류로 이어질 수 있으므로, 상태 추정과 더불어 고장진단 기술을 확보해야 한다. 이러한 기능은 배터리의 현재 상태와 잠재적 위험을 함께 파악함으로써 시스템의 신뢰성을 높이는 데 기여할 수 있다.

배터리의 전압 응답은 SOC, 충·방전 전류 및 내부 임피던스에 따라 달라지며, 열화가 진행됨에 따라 충전 특성과 가용 용량도 변화한다. 따라서 상태 추정과 고장진단을 위해서는 다양한 운전 조건에서 확보한 데이터를 바탕으로 배터리의 시간적 변화와 열화 특성을 반영할 필요가 있다[4]. 특히 고장진단에서는 부하 변화에 따른 정상적인 전압 변동과 고장으로 인한 이상 변동을 구분하는 것이 중요하다. 이를 위해 운전 데이터로부터 정상 상태의 전압 응답을 예측하고, 예측 전압과 측정 전압의 차이를 이용하여 이상 여부를 판단하는 접근이 필요하다[5]. 이에 배터리 시험으로 확보한 시계열 데이터와 열화 특징을 활용하여 SOC 및 SOH를 추정하고, 정상전압 예측을 통해 고장을 판별하는 데이터 기반 알고리즘을 구성하고자 하였다.

또한, 개발된 상태 추정 및 고장진단 알고리즘을 배터리 관리 시스템에 적용하기 위해서는 개별 알고리즘의 성능 평가와 함께, 배터리 모델에 연계한 동작 검증이 필요하다. SOC·SOH 추정과 고장진단은 배터리의 충·방전 과정에서 발생하는 데이터를 이용하므로, 동일한 운전 조건에서 각 알고리즘의 입력 데이터 처리와 출력 결과를 함께 확인할 수 있어야 한다. 이를 위해 배터리 모델과 상태 추정 및 고장진단 알고리즘을 하나의 시뮬레이션 환경으로 통합할 필요가 있다. 통합 시뮬레이션 모델은 충·방전에 따른 배터리 상태 변화와 알고리즘의 동작을 함께 분석하고, 과전류 및 센서 이상과 같은 고장 조건을 반복적으로 재현하여 진단 기능을

검증하는 데 활용할 수 있다.

본 논문에서는 원통형 셀의 시험 데이터와 배터리 모델을 이용하여 Long Short-Term Memory(LSTM) 모델 기반 상태 추정 및 고장진단 알고리즘을 개발하였다. LSTM 모델의 시계열 학습 특성을 활용하여 정상전압을 예측하고, 측정 전압과 비교하여 고장을 판별하였다. 또한, SOC · SOH 추정 및 고장진단 알고리즘을 MATLAB/Simulink 기반 배터리 모델과 연계한 통합 시뮬레이션 모델을 구축하고, 충 · 방전 및 고장 시나리오에서 상태 추정과 고장진단 동작을 검증하였다.

Ⅱ. 본론

2.1 배터리 시험 및 데이터 구성

대상 셀은 INR18650-35E이며 표 1에 배터리 사양을 나타내었다. 해당 밸터리를 사용하여 그림 1의 충 · 방전 장치와 온도 챔버로 용량, SOC-OCV 및 수명 시험을 수행하고 전압 · 전류 · 온도 · 용량 데이터를 수집하였다. 원시 데이터의 문자형 수치를 변환하고 결측치 처리, 데이터 병합 · 분할, 정규화 및 필터링을 수행하였다. 입력과 목표값을 구성한 후 학습용과 검증용 데이터로 분리하였다.

표 1 INR18650-35E 배터리 사양
Table 1 Specifications of INR18650-35E

Parameter	INR18650-35E
Cathode Material	NCA
Anode Material	Graphite
Nominal capacity	3.5Ah
Nominal voltage	3.6V
Discharge cutoff voltage	2.65V
Charge cutoff voltage	4.2V

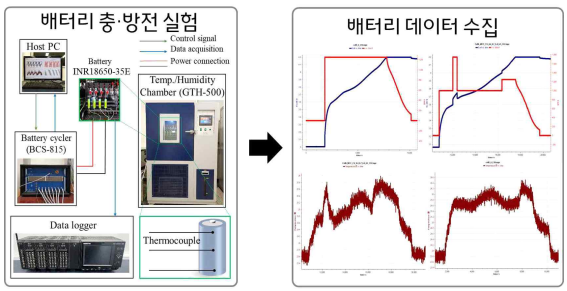


그림 1 배터리 시험 및 데이터 수집 환경
Fig. 1 Battery test and data acquisition setup

2.2 LSTM 기반 SOC 추정

SOC 추정에는 용량 시험과 동적 부하 프로파일(DST, IM240, US06)의 전압 · 전류 · 온도를 입력으로 사용하였다. 시계열 구간 단위로 입력을 구성하고 SOC를 출력하도록 PyTorch 기반 LSTM을 학습하였다. 배치 크기는 128, 학습률은 0.0003, 학습 횟수는 100 epoch로 설정하였다.

그림 2는 기준 SOC와 추정 SOC를 비교한 결과이다. 추정값은 방전에 따른 SOC 감소 경향을 추종하였으며, SOC 추정 오차 RMSE(Root Mean Squared Error)는 1.85%로 나타났다.

2.3 IC 특징 기반 SOH 추정

SOH 추정을 위해 정전류(CC) 충전 구간의 증분용량(Incremental Capacity, IC) 곡선을 계산하였다. IC는 전압 변화에 대한 용량 변화율로

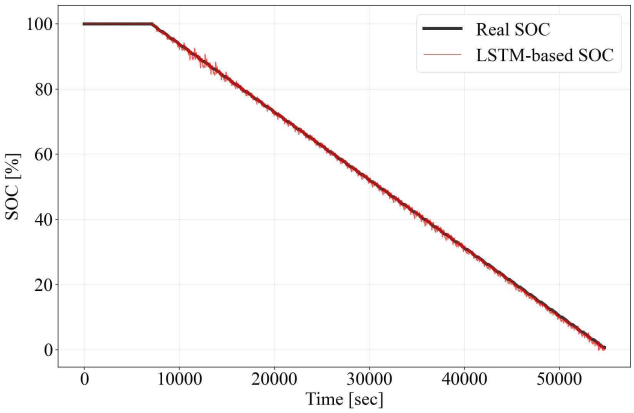


그림 2 LSTM 기반 SOC 추정 결과
Fig. 2 SOC estimation using the LSTM model.

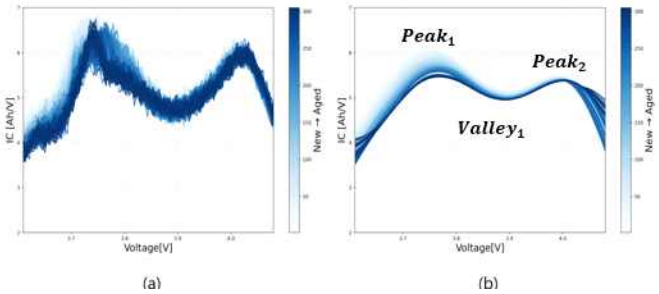


그림 3 SG 필터 적용 전후 IC 곡선
Fig. 3 IC curves before (a) and after (b) SG filtering.

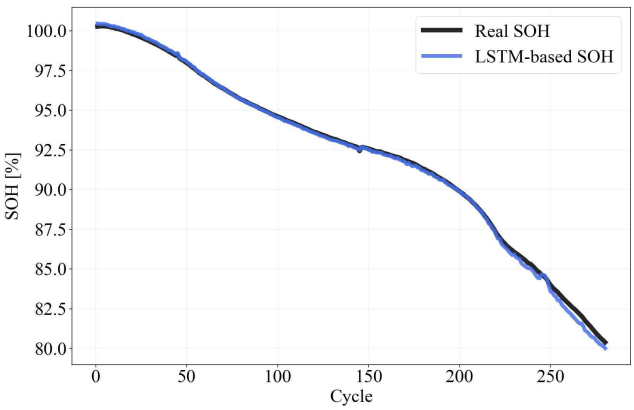


그림 4 LSTM 기반 SOH 추정 결과
Fig. 4 SOH estimation using the LSTM model.

정의되며, 수식 (1)과 같다.

$$IC = dQ/dV \quad (1)$$

차분 정에서 나타나는 노이즈를 완화하기 위해 Savitzky-Golay(SG) 필터를 적용하였다[6]. 그림 3에서 필터 적용 후 두 개의 peak와 한 개의 valley가 구분되며, 사이클에 따른 곡선의 변화 경향을 확인할 수 있다.

IC 곡선에서 peak와 valley의 전압 위치 및 IC 높이를 추출하였다. 이와 함께 CC 충전 시간, 최대온도, 정격전압 도달 시간 및 CC 충전 초기전압을 열화 특징 후보로 구성하였다. 피어슨 상관계수 분석을 통해 SOH와 높은 상관성을 갖는 특징을 선정하여 LSTM 입력으로 사용하였다.

SOH 모델은 1개 층과 32개 노드, 시퀀스 길이는 3으로 구성하였으며, 배치 크기 8, 학습률 0.0001, 100 epoch로 학습하였다. 280사이클 중 1~200사이클은 학습에, 201~280사이클은 검증에 사용하였다. 그림 4

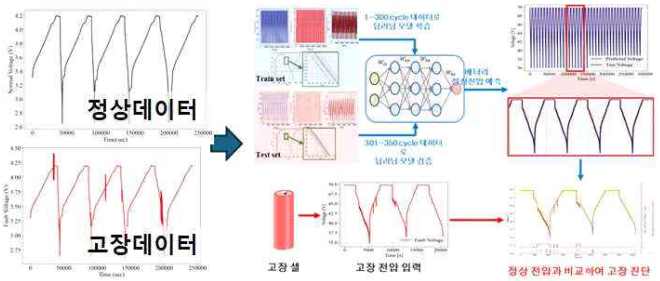


그림 5 정상전압 예측 기반 고장진단 절차
Fig. 5 Fault diagnosis using normal-voltage prediction.

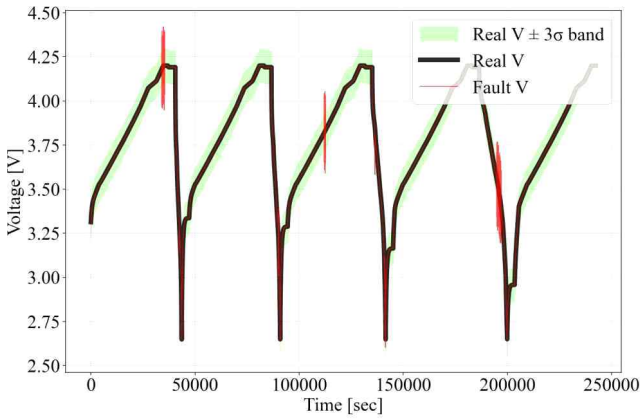


그림 6 전압 이상 및 3σ 범위를 이용한 고장진단
Fig. 6 Voltage anomalies and the three-sigma band.

는 사이클 증가에 따른 SOH 변화와 추정 결과를 보여준다. IC 및 충전 특성에서 추출한 특징으로 열화에 따른 SOH 감소를 추정하였으며, SOH 추정 오차 RMSE는 0.11%이다.

2.4 정상전압 예측 기반 고장진단

고장진단은 현재 배터리 데이터로부터 다음 상태의 정상전압을 예측하는 LSTM 모델을 이용하였다. 예측된 정상전압과 측정전압의 차이를 기반으로 정상 범위를 정의하고, 해당 범위를 벗어나는 전압 편차를 고장으로 판정하였다. 학습 및 검증에는 정상 운전 데이터와 과전류 및 전압 센서 이상 조건에서 생성된 고장 데이터를 사용하였다.

고장 시나리오는 과전류와 전압 센서 이상으로 구성하였다. 보고서의 전류 부호 기준에서 −8 A 미만을 과전류 조건으로 설정하고, 전압 센서에는 실제값과의 차이가 50~200 mV인 고장을 주입하였다.

정상전압 예측 모델은 배치 크기 256, 학습률 0.0002, 8 epoch로 학습하였다. 측정 전압을 예측 정상전압과 비교하여 3σ 범위 안에 있으면 정상, 범위를 벗어나면 고장으로 판정하였다[7].

그림 6은 정상 전압, 고장 전압 및 3σ 범위를 보여준다. 고장 주입 구간에서 정상 범위를 벗어나는 전압 편차가 나타났다. 정상 전압 및 고장 전압 예측 오차 RMSE는 각각 약 0.55%와 1.61%이다. 고장진단 결과는 전압 예측 오차를 기준으로 평가하였다.

2.5 Python 기반 LSTM 모델의 MATLAB/Simulink 통합

앞서 개발한 SOC · SOH 추정 및 고장진단 알고리즘의 시스템 수준 적용 가능성을 확인하기 위해 MATLAB/Simulink 기반 통합 시뮬레이션 환경을 구성하였다. SOC와 SOH 추정 모델은 Python/PyTorch 환경에서 학습한 후 ONNX(Open Neural Network Exchange) 형식으로 추출하고, MATLAB 환경의 네트워크 객체 및 MAT 파일로 변환하였다. 변환된 네트워크는 Simulink의 Predict 블록에 연동하여 Python에서 학습한 LSTM의 가중치와 구조를 활용하도록 구성하였다. 그림 7은 Table-Based Battery 기반 SOC 추정 모델, 그림 8은 열화 파라미터 계산과 LSTM을 연계한 SOH 추정 모델, 그림 9는 고장 데이터 생성 및 고장진단 알고리즘 모델을 보여준다. SOC 추정 모델은 그림 7과 같이 Table-Based Battery의 충 · 방전 동작에서 출력되는 전압, 전류 및 온도 신호를 입력으로 사용하고, Python 학습 과정과 동일한 정규화를 거쳐 LSTM 모델에 전달하도록 구성하였다. SOH 추정 모델은 그림 8과 같이 배터리 모델에서 산출되는 전압 · 전류 신호로부터 IC peak · valley와 충전시간 등의 열화 파라미터를 계산하고, 이를 LSTM 입력으로 사용하였다. 고장진단은 그림 9와 같이 전압 센서 신호에 고장 성분을 주입한 뒤 정상 신호와의 편차를 이용하여 고장 여부를 판정하고, 판정 결과에 따라 회로 제어 신호를 생성하도록 구성하였다.

그림 10은 Table-Based Battery 기반 SOC 추정 결과를 보여주며, 실제 SOC와 추정 SOC가 전 구간에서 유사한 경향을 보였다. 그림 11은 SOH 추정 결과를 나타내며, 1사이클 종료 후 추정 SOH와 실제 SOH의 MAE(Mean Absolute Error) 차이는 약 2.2%로 확인되었다. 그림 12는 전압 센서 고장 주입 후 보호 제어에 의해 배터리 전류가 즉시 차단되는 결과를 보여준다. 이와 같이 Python 환경에서 개발한 알고리즘은 MATLAB/Simulink 기반 통합 환경에서도 유사한 성능과 동작을 보였으며, SOC 추정 오차 MAE는 약 0.04%로 나타났고 SOH는 실제 96.52%에 대해 93.64%로 추정되었다.

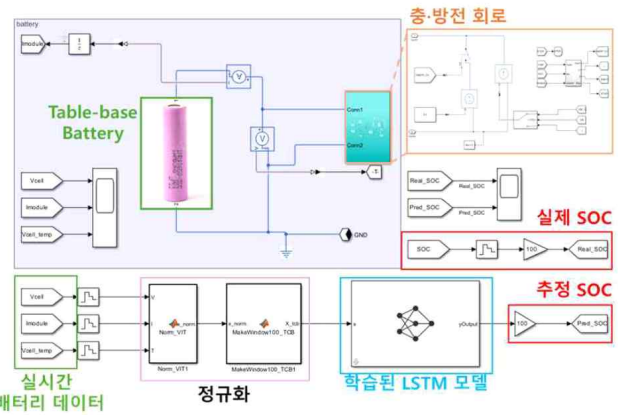


그림 7 MATLAB/Simulink 기반 Table-Based Battery 모델을 활용한 SOC 추정 모델
Fig. 7 SOC estimation model using the MATLAB/Simulink Table-Based Battery model.

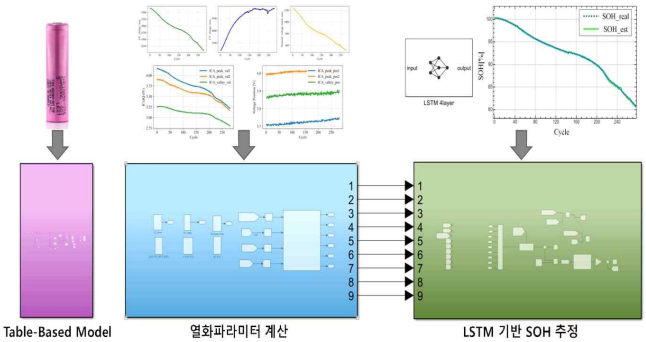


그림 8 MATLAB/Simulink 기반 Table-Based Battery 모델을 활용한 SOH 추정 모델
Fig. 8 SOH estimation model using the MATLAB/Simulink Table-Based Battery model.

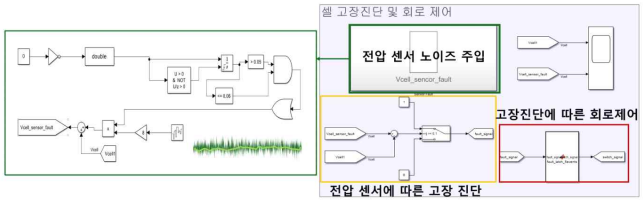


그림 9 고장 데이터 생성 및 고장진단 알고리즘 모델
Fig. 9 Fault-data generation and fault-diagnosis algorithm model.

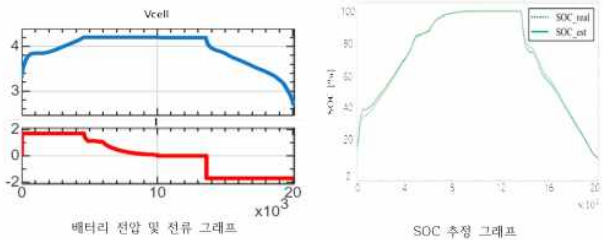


그림 10 SOC 추정 알고리즘 검증
Fig. 10 Verification of the SOC estimation algorithm.

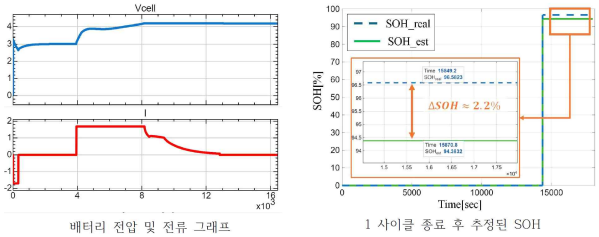


그림 11 SOH 추정 알고리즘 검증
Fig. 11 Verification of the SOH estimation algorithm.

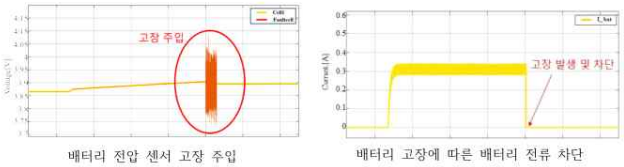


그림 12 배터리 고장 발생 시 배터리 전류 차단
Fig. 12 Battery-current cutoff under a battery fault condition.

Ⅲ. 결론

본 논문에서는 LSTM 기반 SOC · SOH 추정과 정상전압 예측 기반 고장진단을 구현하였다. 전압 · 전류 · 온도 시계열과 IC 및 충전 특징을 이용하여 상태 변화를 추정하고, 과전류 및 전압 센서 이상을 3σ 기준으로 판별하였다. 또한 Python/PyTorch에서 학습한 SOC 및 SOH 모델을 ONNX를 통해 MATLAB/Simulink에 배포하고, Table-Based Battery 및 BMS/UPS 통합 시뮬레이션 모델에 연계하여 배터리 신호 생성부터 특징 계산과 상태 추정까지의 연속 동작을 검증하였다. 개발된 알고리즘은 설정된 SOC · SOH 및 고장진단 성능 목표를 만족하였으며, 향후 다양한 셀, 온도 및 열화 조건을 확대하고 추가 평가하여 실제 BMS 적용 범위를 확장할 예정이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Tran & Fowler, A Review of Lithium-Ion Battery Fault Diagnostic Algorithms: Current Progress and Future Challenges, Algorithms, 2020

[2] Lu et al., A review on the key issues for lithium-ion battery management in electric vehicles, Journal of Power Sources, 2013

[3] Vennam et al., A survey on lithium-ion battery internal and external degradation modeling and state of health estimation, Journal of Energy Storage, 2022

[4] Chen et al., An LSTM-SA model for SOC estimation of lithium-ion batteries under various temperatures and aging levels, Journal of Energy Storage, 2024

[5] Liao et al., Fault diagnosis method for lithium-ion batteries based on the combination of voltage prediction and Z-score, International Journal of Green Energy, 2024

[6] Wang et al., State of health estimation of lithium-ion battery in wide temperature range via temperature-aging coupling mechanism analysis, Journal of Energy Storage, 2022

[7] Xue et al., Fault diagnosis and abnormality detection of lithium-ion battery packs based on statistical distribution, Journal of Power Sources, 2021

사용자 리뷰를 고려한 전자상거래 재구매 예측 모델

서정훈, 정인수, 윤경민, 유재수*

충북대학교 정보통신공학전공, *충북대학교 정보통신공학부

nne7741@chungbuk.ac.kr, isjung0616@naver.com, gmyun@chungbuk.ac.kr, *yjs@chungbuk.ac.kr

A User Review Aware Repurchase Prediction Model for E-Commerce

Jeonghun Seo, Insoo Jung, Gyeongmin Yun, *Jaesoo Yoo

Department of Information and Communication Engineering, Chungbuk National Univ.,

*School of Information and Communication Engineering, Chungbuk National Univ.

Abstract

Predicting customer repurchase behavior is an important task in e-commerce customer relationship management. Although customer reviews may provide valuable insights into purchase experiences, it remains unclear whether review text offers additional predictive information beyond structured data, such as transaction records, delivery information, and star ratings. This paper proposes ARC (Anchored Residual Content), a repurchase prediction model that uses predictions from structured data as a fixed anchor and incorporates only the portion of review embeddings unexplained by structured information as a correction term.

Key words : repurchase prediction, customer reviews, text-tabular data fusion, e-commerce

Ⅰ. 서 론

전자상거래 시장에서 신규 고객을 지속적인 구매 고객으로 전환하는 것은 기업의 장기적인 수익성을 높이기 위한 중요한 과제이다. 특히 첫 구매를 완료한 고객 가운데 향후 다시 구매할 가능성이 높은 고객과 그렇지 않은 고객을 조기에 구분한다면 기업은 쿠폰, 할인 혜택, 개인화 추천, 리마인드 메시지와 같은 고객 유지 활동을 보다 효율적으로 집행할 수 있다.

따라서 고객의 재구매 여부를 정확하게 예측하는 것은 고객 관계 관리와 마케팅 자원의 효율적인 배분이라는 측면에서 실질적인 의미를 갖는다. 전자상거래 플랫폼에는 고객의 구매 행위를 설명할 수 있는 다양한 형태의 데이터가 축적된다. 대표적으로 주문 금액, 구매 상품의 종류와 수량, 결제 수단, 배송 소요 기간 및 배송 지연 여부와 같은 정형 정보가 존재한다. 이러한 정보는 고객의 구매 조건과 거래 경험을 비교적 직접적으로 나타내므로 기존의 고객 행동 예측 연구에서 널리 활용되어 왔다.

한편, 대부분의 전자상거래 플랫폼은 거래 정보와 함께 고객이 직접 작성한 상품 리뷰도 수집한다. 리뷰에는 고객이 상품의 품질을 어떻게 평가하였는지뿐만 아니라 배송 속도, 상품 상태, 판매자 응대, 기대와 실제 경험 간의 차이 등 정형 변수만으로 충분히 표현하기 어려운 정보가 포함될 수 있다. 따라서 리뷰 텍스트는 고객의 향후 재구매 행동을 설명하는 추가적인 정보원으로 활용할 수 있다.

기존 연구에서는 콜센터 이메일, 고객 상담 기록과 같은 비정형 텍스트 정보를 정형 정보와 함께 사용함으로써 고객 이탈률 예측에 활용하는 등 고객과 기업 간 상호작용 과정에서 생성된 데이터가 고객 행동의 변화를 설명할 수 있음을 보여주었다.[1]

그러나 상품에 대한 리뷰를 직접적으로 재구매 예측에 활용한 연구는 제한적으로 시도되었다. 리뷰는 구매 이후의 만족도나 불만을 표현하므로 향후 구매 행동과 관련될 수 있음을 직관적으로 알 수 있으나 실제 예측 관점에서 어느 정도의 추가 정보를 모델에게 제공하는지는 명확하게 알 수 없다. Olist 데이터를 이용하여 리뷰 데이터를 재구매 예측에 추가한 선행 연구에서 AUC는 0.6338에서 0.6353으로 증가하는데 그쳤으며, 텍스트 정보의 추가에 따른 성능 향상 폭은 매우 제한적이었다.[2]

이와 같은 현상은 재구매 예측 문제의 데이터 특성에 따른 것으로 재구매는 전체 고객 가운데 일부에서만 발생하는 희소한 사건이므로 리뷰와 같은 고차원 텍스트 데이터를 수치적인 데이터인 기존 정형 변수에 단순히 결합할 경우 제한된 재구매 사례에 모델이 과적합 되는 문제가 발생하기 때문이다. 본 논문에서는 이러한 문제를 고려하여 정형 고객 정보를 활용하면서 리뷰 데이터가 제공하는 정보를 제한적으로 반영하는 ARC(Anchored Residual Content) 모델을 제안한다. 제안하는 모델은 정형 데이터로부터 얻어진 예측 결과를 고정된 기준점으로 사용하고 리뷰 데이터 중 정형 정보만으로 설명하기 어려운 잔차 성분을 추가적인 보정 신호로 활용한다. 이를 통해 정형 데이터가 충분한 예측 신호를 포함할 경우에는 이를 활용하면서, 해당 신호가 불안정하거나 부족한 경우 리뷰 데이터를 통해 기존 정형 모델의 성능을 최대한 유지하도록 설계하였다.

Ⅱ. 본론

본 논문에서는 첫 구매 고객을 대상으로 일정 시점 이후의 재구매 여부를 예측하는 문제를 다룬다. 재구매 예측에서는 고객별로 관측 가능한 정보의 범위가 시간에 따라 달라지므로, 예측 시점과 정답간의 관측 구간을 명확하게 정의해야 한다.

고객 i의 첫 구매 시점을 a_i, 첫 개무 이후 30일이 경과한 시점을 예측 시점 t_i 라고 할 때, i의 다음 구매 시점을 r_i라고 정의하고 정답 레이블 y_i는 수식1로 표현된다.

$$y_i = 1(t_i < r_i \leq t_i + 90) \quad (1)$$

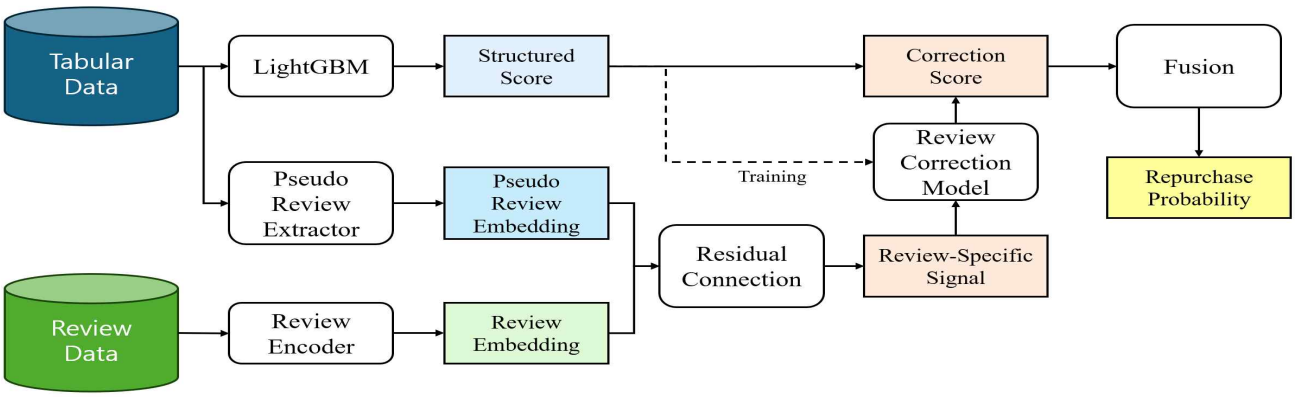


그림 1 제안하는 ARC 모델의 구조

Fig. 1 Proposed ARC Model Architecture

모델의 모든 입력값은 r_i 까지 관측할 수 있는 정보로 제한되며, 입력값은 정형 데이터 S_i와 리뷰 데이터 R_i로 정의한다. 정형 데이터에는 주문 금액, 배송비, 구매 품목 개수, 결제 수단, 실제 배송 기간 및 지연 여부, 상품 속성, 고객과 판매자의 거리가 포함된다. 리뷰 데이터에는 t_i 이전에 작성이 완료된 리뷰의 제목과 내용로 구성되며 최종적으로 제안하는 모델의 목적은 수식2 로 정의된다.

$$p_i = P(S_i, R_i) \qquad (2)$$

그림 1은 제안하는 모델의 구조를 나타낸다. 제안하는 모델은 그림과 같이 세 갈래의 흐름으로 구성된다. 먼저 정형 경로는 정형 데이터로 정형 점수를 만든다. 다음으로 리뷰 경로는 언어 모델을 통해 리뷰 데이터를 임베딩한다. 마지막으로 의사 리뷰 경로는 정형 데이터로부터 이 고객과 비슷한 상황의 사용자가 남긴 리뷰로 실제 고객이 남긴 리뷰와의 차이가 해당 고객의 고유한 정보로 이용된다. 이때 의사 리뷰 생성기는 정형 데이터로터 고객의 리뷰 임베딩을 예측하는 회귀 모델로 모델의 출력은 별점, 상품 배송 여부, 상품 정보 등 정형 정보가 비슷한 고객들이 평균적으로 작성하는 리뷰를 벡터로 나타낸다. 잔차 추출 단계에서는 실제 리뷰 임베딩에서 의사 리뷰 임베딩을 빼 해당 고객의 리뷰에 대한 고유 신호를 추출하게 된다. 리뷰 보정 모델은 고유 신호로부터 정형 점수를 얼마나 반영할지를 나타내는 보정 점수를 학습한다. 이때 정형 점수를 offset으로 두어 보정 모델이 정형 모델이 설명하지 못한 부분만 학습하게 한다. 마지막으로 정형 점수와 보정된 리뷰 점수를 더해 재구매 확률을 계산한다.

표 1 데이터셋 분할

Table 1 Dataset Split

구분	시간 구간	학습 데이터	평가 데이터
F1	17.09. ~ 17.11.	7,721	15,712
F2	17.12. ~ 18.02.	18,192	18,758
F3	18.03 ~ 18.05.	30,511	13,558

평가에는 Olist Brazilian E-Commerce Public Dataset(2017-2018)을 사용하였다. 데이터셋 내 고객은 총 70,044명이며 90일 내 재구매율은 0.89%(626명)으로 나타났다. 공정한 학습을 위하여 과거 고객으로 학습하고 이후 고객으로 평가하는 시간순 분할을 사용하였다. 표 1은 데이터 분할을 보여준다.

표 2 성능 평가 결과

Table 2 Evaluation Result

모델	입력	AUC	AP
Logistic Regression	정형	0.531	0.013
LightGBM	정형	0.555	0.011
Logistic Regression	리뷰	0.477	0.008
Early Fusion(LightGBM)	정형+리뷰	0.540	0.016
ARC	정형+리뷰	**0.589**	**0.127**

표 2는 성능 평가 결과를 나타낸다. 비교 대상은 정형 데이터만 사용한 로지스틱 회귀 모델과 LightGBM, 리뷰 임베딩만 사용한 로지스틱 회귀 모델, 정형 데이터와 리뷰 임베딩을 하나의 입력으로 결합한 Early Fusion 제안하는 ARC 모델로 구성하였다. 모든 모델은 동일한 데이터와 파라미터에서 학습하였으며 평가 지표로는 AUC, AP를 사용하였다.

성능 평가 결과 제안하는 기법은 AUC 0.589 및 AP 0.127로 모든 비교군 중 가장 높은 성능을 보였다. 이는 ARC가 정형 데이터와 리뷰 데이터를 효과적으로 활용하여 고객의 재구매율을 예측함을 보여준다.

표 3 딥러닝 기반 모델과의 비교

Table 3 Comparison with Deep Learning-based Models

모델	AUC	AP	Lift@10%
MLP Fusion	0.502	0.009	1.14
Gated Fusion	0.516	0.010	1.00
ARC	**0.555**	**0.011**	**1.53**

표 3은 딥러닝 기반 융합 모델과의 비교 결과를 나타낸다. 비교 대상은 정형 피처와 리뷰 임베딩을 연결하여 다층 퍼셉트론으로 학습하는 MLP Fusion과, 게이트를 통해 정형 표현과 리뷰 표현의 기여도를 조절하는 Gated Fusion이다. 두 모델은 ARC와 동일한 시간순 분할에서 학습하였다. 실험 결과 MLP Fusion과 Gated Fusion의 AUC는 각각 0.502, 0.516으로 무작위 수준에 가까웠으나, ARC는 AUC 0.555, Lift@10% 1.53으로 가장 높은 성능을 보였다. 이는 재구매 사례가 희소한 환경에서 정형 정보와 리뷰 정보를 함께 학습하는 딥러닝 융합 모델이 과적합되기 쉬운 반면, 정형 점수를 고정하고 리뷰의 잔차 성분만 보정에 활용하는 ARC가 더 안정적임을 보여준다.

Ⅲ. 결론

본 논문에서는 정형 데이터와 리뷰 데이터를 활용한 사용자 리뷰 기반 재구매 예측 기반 모델인 ARC를 제안하였다. ARC는 정형 데이터로 학습한 모델의 예측을 정형 점수로 고정하고 의사 리뷰 임베딩을 이용하여 리뷰 고유 신호를 정형 점수의 보정으로 반영한다. 이러한 구조를 통해 고

객의 평점이나 배송 경험처럼 정형 데이터에 이미 반영된 정보의 중복 학습을 방지하고, 리뷰에서 유용한 신호가 발견되지 않는 경우에는 정형 모델의 예측으로 수렴하도록 설계하였다. Olist 데이터셋을 활용한 실험에서 ARC는 비교 모델 가운데 가장 우수한 성능을 보였다. 향후에는 리뷰의 분량과 다양한 구매 주기를 가진 데이터로 실험을 확장할 예정이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] K. Coussement and D. Van den Poel, "Integrating the voice of customers through call center emails into a decision support system for churn prediction," Information & Management, vol. 45, no. 3, pp. 164-174, 2008.

[2] K. Matuszelański and K. Kopczewska, "Customer churn in retail e-commerce business: Spatial and machine learning approach," Journal of Theoretical and Applied Electronic Commerce Research, vol. 17, no. 1, pp. 165-198, 2022.

학술 지식 네트워크 학습을 이용한 개인 맞춤형 미래 연구 주제 예측

차동현, 김상혁, 성우제, 송상호*, 유재수**

충북대학교 정보통신공학전공, *충북대학교 산업인공지능연구센터, **충북대학교 정보통신공학부

cdh@chungbuk.ac.kr, tiensh@chungbuk.ac.kr, woojess@chungbuk.ac.kr, *ssh@chungbuk.ac.kr, **yjs@chungbuk.ac.kr

Personalized Future Research Topic Prediction Using Academic Knowledge-Network Learning

DongHyeon Cha, Sanghyeuk Kim*, Wooje Sung, Sangho Song**, Jaesoo Yoo

Department of Information and Communication Engineering, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**Department of Information and Communication Engineering, Chungbuk National Univ.

Abstract

We predict whether a scholar will adopt a topic absent from their prior publication history. Separate graph-attention encoders learn representations of a scholar's local knowledge network and a population-level global knowledge network. A candidate topic queries the local history through attention, and an interaction representation predicts subsequent adoption. In a PubMed/MeSH evaluation with 3,000 scholars per observation window, the model achieved F1 scores of 0.7937-0.8002, exceeding the validation-selected structural-feature baseline by 4.65-9.20 percentage points, with higher recall but lower precision than the baseline. Because random negatives are far less connected than positives, we also matched negatives to positives in connection count; the model retained F1 scores of 0.7348-0.7458 and outperformed the baseline by 3.91-5.32 percentage points. These results support combining individual histories with global topic structure for known-scholar candidate prediction on balanced candidate sets, but they do not establish top-K recommendation performance.

Key words : Research topic prediction, Knowledge networks, Graph attention, Personalized prediction

Ⅰ. 서 론

연구 문헌이 증가하면서 연구자가 기존 전문성과 연결되는 새로운 주제를 탐색하기 어려워지고 있다. 분야 전체에서 주목받는 주제라도 개인의 경험과 거리가 멀 수 있고, 덜 알려진 주제라도 과거 연구와 밀접하게 연결될 수 있다. 개인 맞춤형 연구 지원에는 분야의 주제 관계와 연구자별 지식 축적 과정을 함께 고려해야 한다.

본 연구는 특정 연구자의 과거 논문에 없던 주제가 이후 논문에 등장할지를 예측한다. 이는 분야 전체의 유망 주제 예측이나 관련 논문 검색과 구별된다. Wu et al.[1]은 개인 · 전역 지식 네트워크의 구조를 요약한 16개 특징으로 신규 주제 채택을 예측하였다. 그러나 고정된 특징만으로는 같은 연구 이력에서도 후보에 따라 달라지는 관련성을 표현하기 어렵다.

이에 개인과 집단의 주제 관계를 각각 학습하는 이중 그래프 어텐션 모델을 제안한다. 후보의 전역 표현으로 개인 이력의 가중치를 조절하고 두 표현의 상호작용으로 채택을 예측한다. 분야에 처음 등장하는 주제가 아니라 기존 주제 중 해당 연구자에게 새로운 주제를 대상으로, 구조적 특징 기반 방법과 동일한 후보 조건에서 비교한다. 또한 무작위 음성 후보가 양성 후보보다 덜 연결되어 있어 생기는 후보 인기도의 영향을 점검하기 위해, 연결 수를 맞춘 음성 후보에서도 성능을 비교한다.

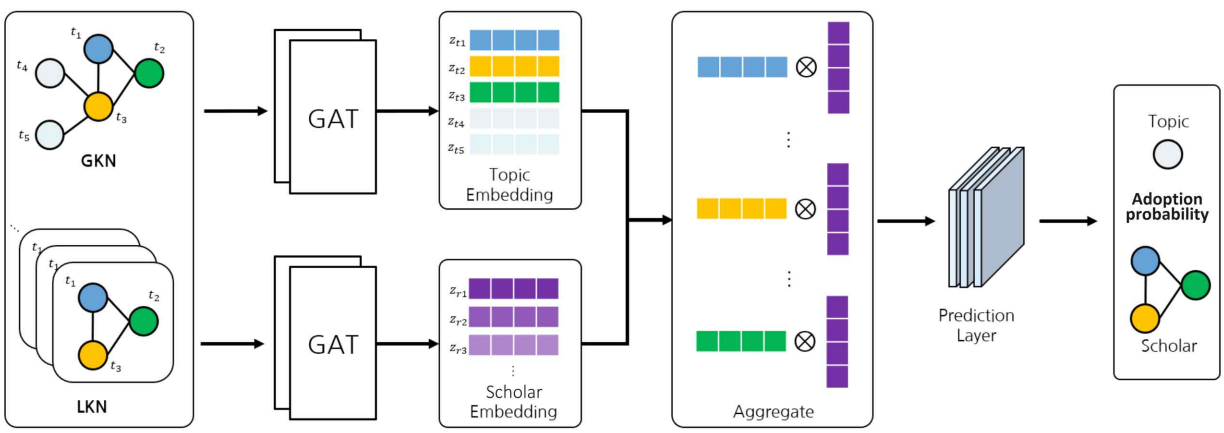


그림 1 전역 · 개인 지식 네트워크의 표현 학습과 후보 주제 채택 예측 과정

Fig. 1 Dual-network representation learning and candidate-topic adoption prediction.

Ⅱ. 제안 방법

제안 방법은 지식 네트워크 구성, 지역 · 전역 표현 학습, 후보에 조건화된 이력 요약, 상호작용 기반 예측으로 구성된다. 그림 1은 전체 처리 흐름을 보여준다.

2.1. 예측 대상과 지식 네트워크

지역 지식 네트워크(Local Knowledge Network, LKN)는 연구자 개인의 관측 기간 논문에 등장한 주제를 노드로 표현한다. 같은 논문에 함께 등장한 서로 다른 주제 쌍을 간선으로 연결하고, 여러 논문의 관계를 합쳐 개인 네트워크를 구성한다. 따라서 한 연구자가 다룬 모든 주제를 일괄 연결하는 방식과는 다르다. 전역 지식 네트워크(Global Knowledge Network, GKN)는 표본 연구자들의 관측 기간 동시 출현 관계를 집계한다. 동일한 주제라도 개인 이력과 집단에서 연결되는 이웃이 다를 수 있다.

후보 주제는 관측 기간 GKN에 존재하지만 해당 연구자의 LKN에는 없는 주제로 제한한다. 후보가 예측 기간 논문에 등장하면 양성, 등장하지 않으면 음성으로 정의한다. 미래의 동시 출현 관계를 네트워크 입력으로 사용하지 않으며, 예측 기간의 주제는 정답 구성에만 사용한다. 이 조건은 연구자의 기존 주제 재등장과 신규 채택을 구분하고, 모델이 과거의 정보로 미래 기록을 판별하도록 한다.

2.2. 이중 그래프 어텐션 표현 학습

주제 입력은 학습 가능한 임베딩과 GKN 차수의 정규화된 로그 값으로 구성한다. 로그 변환은 주제별 연결 수의 큰 차이를 압축하고, 차수 값은 임베딩과 함께 명시적인 구조 정보를 제공한다. 지역 · 전역 분기는 임베딩 표를 공유하지만 인코더 파라미터와 이웃 집합은 분리한다. 이를 통해 같은 주제의 식별 정보는 공유하면서도 개인과 집단의 맥락은 서로 다르게 학습한다.

각 분기는 두 층의 그래프 어텐션 네트워크(GAT)[2]로 구성하며, 중심 주제와 이웃의 특징에 따라 관계별 가중치를 학습한다. 첫 층은 다중 헤드의 출력을 연결하고 둘째 층은 하나의 헤드로 256차원 표현을 생성한다. 어텐션 점수에는 음수 기울기 0.2의 LeakyReLU를 적용하여 기울기를 유지한 뒤 이웃 내에서 정규화한다. 간선은 양방향으로 입력하며 자기 연결을 포함한다.

2.3. 후보 조건부 이력 요약과 예측

후보의 전역 표현을 질의로 사용하여 LKN 주제 표현과 내적을 계산한다. 이를 표현 차원의 제곱근으로 나누고 소프트맥스로 정규화한 가중치로 지역 주제의 가중합을 구한다. 같은 연구자라도 후보에 따라 이력의 가중치가 달라진다. 인코더 어텐션은 이웃 관계를, 후보 조건부 어텐션은 현재 후보와 관련된 이력을 반영한다. 후보를 과거 이력에 추가하지 않고 GKN 표현으로 이력을 조회한다.

연구자 표현 s와 후보 표현 z를 식 (1)과 같이 결합하여 상호작용 표현 q를 구성한다.

$$q = [s; z; (s \odot z); |s - z|] \quad (1)$$

하다마르곱은 좌표별 곱셈 상호작용을, 절댓값 차이는 표현 간 차이를 제공한다. 원래 두 벡터도 유지하여 이력과 후보의 역할을 보존한다. 결합 벡터를 두 층의 예측 신경망에 입력하고 시그모이드로 채택 확률을 계산한다. 이진 교차 엔트로피 손실로 공유 임베딩, 두 인코더와 분류기를 함께 학습한다.

2.4. 노드 제거 기반 예측 해석

과거 주제 노드 v와 연결 간선을 LKN에서 제거한 뒤, 학습된 파라미터와 GKN을 고정한 채 LKN을 다시 인코딩한다. 동일한 연구자–후보 쌍의 민감도는 식 (2)로 계산한다.

$$\Delta_v = p - p^{(-v)} \quad (2)$$

p는 원래 확률이고, (−v)는 주제 v와 연결 간선의 제거를 뜻한다. 양수는 예측을 지지하고 음수는 억제하는 방향의 민감도이다. 남은 노드의 표현과 이력 가중치도 변하므로 인과적 영향이나 합산 가능한 기여도로 해석하지 않는다.

Ⅲ. 성능 평가

3.1. 데이터와 평가 조건

PubMed Knowledge Graph(PKG)[3]의 서지 기록과 MeSH 주제 식별자를 사용하였다. Wu 등[1]에 따라 2014–2018년 논문 수가 18–50편인 저자로 제한하였다. 사분위 범위 규칙으로 지나치게 적거나 많은 출판 기록을 제외한 범위이다. 이 중 2019–2020년에도 논문이 있는 저자 20,000명을 무작위 추출하고, 관측 · 예측 기간 모두 LKN이 있는 적격 집단에서 조건별 3,000명을 표본 추출하였다.

관측 기간은 2018년, 2016–2018년, 2014–2018년이며 예측 기간은 모두 2019–2020년이다. PKG 저자 식별자로 논문을 연결하고 개인 내 중복 논문을 제거하였다. 네트워크 구성 시 Animals, Humans 등을 포함한 9개 MeSH 체크 태그를 제외하고, 추가로 147개 일반 주제와 연결된 간선을 두 기간에서 제외하였다. GKN에는 집계된 동시 출현 횟수가 10회 이상인 간선을 사용하였다. 후보 어휘와 모든 구조적 특징은 관측 기간 자료로만 구성하였다.

각 연구자에 대해 양성 후보 하나당 미채택 후보 하나를 무작위로 추출하여 양성 · 음성을 1:1로 구성하였다. 연구자–후보 쌍을 모은 뒤 각 정답 집단을 섞어 학습 60%, 검증 20%, 시험 20%로 분할하였다. 같은 후보 쌍은 한 분할에만 속하지만 연구자 3,000명은 모든 분할에 포함된다. 따라서 이 평가는 새로운 연구자를 대상으로 한 일반화가 아니라, 학습에 등장한 연구자의 새로운 후보 쌍을 판별하는 조건이다. 제안 방법과 비교 모델에는 동일한 후보와 분할을 적용하였다. 연구자당 평균 시험 후보 수는 관측 기간 1년, 3년, 5년에서 각각 40.2개, 37.7개, 36.1개이며 절반이 채택 후보이다.

비교 모델은 기존 방법[1]의 16개 구조적 특징을 사용하는 LightGBM, XGBoost, CatBoost이며, 조건별 검증 F1으로 선정하였다. 특징은 LKN의 구조, LKN 주제들이 GKN에서 이루는 관계 및 후보와 이력의 연결성을 요약한다. 모든 모델의 판정 임계값은 0.05–0.95에서 0.01 간격으로 검증 F1을 최대화하도록 선택하고 시험에 그대로 적용하였다. 대표 결과는 정밀도와 재현율의 조화평균인 F1으로 제시하고, 정확도, 정밀도, 재현율과 임계값에 의존하지 않는 ROC–AUC, PR–AUC를 함께 보고한다.

후보 인기도의 영향을 점검하기 위해 두 가지를 추가하였다. 첫째, 음성 후보를 양성 후보와 연결 수가 비슷한 미채택 후보로 선택한 평가 조건(연결 수 맞춤 조건)을 구성하였다. 이 조건에서도 기준 모델은 무작위 음성 조건과 같은 방식으로 검증 F1을 기준으로 선정하였다. 둘째, 후보 주

제의 연결 수만 사용하는 기준 모델을 두어 인기도만으로 얻을 수 있는 성능을 확인하였다.

3.2. 결과 및 논의

표 1은 세 관측 조건 모두에서 검증 기준으로 선정된 LightGBM과 제안 방법의 시험 F1을 비교한다. 제안 방법은 F1 0.7937–0.8002로, LightGBM보다 4.65–9.20퍼센트포인트(%p) 높았다. 개인 이력과 전역 맥락을 함께 학습한 표현이 세 조건에서 일관되게 더 높은 판별 성능을 보였다.

표 1 관측 기간별 주제 채택 예측 성능(F1)
Table 1 Topic-adoption prediction across observation windows

관측 기간	LightGBM	제안 방법	차이(%p)
1년	0.7082	0.8002	+9.20
3년	0.7356	0.7994	+6.38
5년	0.7472	0.7937	+4.65

연구자 3,000명, 양성 · 무작위 음성 1:1. 차이는 F1의 퍼센트포인트(%p) 차이이다.

관측 기간이 길어질수록 LightGBM의 성능이 높아져 두 방법의 차이는 감소하였다. 다만 이력 · 네트워크 · 후보가 함께 달라지므로 특정 요소의 효과로 단정할 수 없다.

3.3. 정밀도와 재현율 분석

표 2는 무작위 음성 조건의 세부 지표이다. 제안 방법은 정확도(0.7832–0.7864)와 재현율(0.8340–0.8560)이 LightGBM(각각 0.7363–0.7568, 0.6400–0.7186)보다 높았지만, 정밀도(0.7512–0.7571)는 LightGBM(0.7781–0.7927)보다 2.10–4.15%p 낮았다. 정밀도 0.75 안팎은 채택으로 판정한 후보의 약 24–25%가 실제로는 채택되지 않았다는 뜻이므로, 제안 방법의 F1 향상은 오답 추천을 더 허용하면서 채택 후보를 더 많이 찾아낸 결과이다. 임계값에 의존하지 않는 지표인 ROC-AUC는 제안 방법이 0.8571–0.8686으로 LightGBM의 0.7782–0.8116보다, PR-AUC는 0.8330–0.8657로 0.8208–0.8436보다 높았다. 순위 기반 지표에서는 제안 방법이 열세가 아니므로, 낮은 정밀도를 순위 구분 성능의 부족으로 해석하기는 어렵다. 이는 검증 F1을 최대화하도록 선택한 판정 임계값이 재현율 쪽 운용점을 택한 영향일 수 있으나, 임계값별 정밀도-재현율 균형은 직접 평가하지 않았다.

표 2 무작위 음성 후보에서의 세부 성능
Table 2 Detailed performance with random negatives

구분	정확도	정밀도	재현율	ROC-AUC	PR-AUC
1년 제안 방법	0.7863	0.7512	0.8560	0.8584	0.8330
1년 LightGBM	0.7363	0.7927	0.6400	0.7782	0.8208
3년 제안 방법	0.7864	0.7534	0.8515	0.8686	0.8657
3년 LightGBM	0.7509	0.7837	0.6931	0.8018	0.8379
5년 제안 방법	0.7832	0.7571	0.8340	0.8571	0.8497
5년 LightGBM	0.7568	0.7781	0.7186	0.8116	0.8436

연구자 3,000명, 양성 · 무작위 음성 1:1. AUC는 임계값에 의존하지 않는 지표이다.

연결 수 맞춤 조건에서는 제안 방법의 정밀도가 0.6496–0.6729로, 이 조건의 LightGBM(0.5524–0.5702)보다 높았다. 이 조건의 LightGBM은 재현율이 0.8907–0.9263으로 시험 후보의 약 78–84%를 채택으로 판정하였고, F1(0.6921–0.6953)은 모든 쌍을 채택으로 예측할 때의 0.6667보다 2.5–2.9%p 높은 데 그쳤다. 연구자 약 20,000명 코호트에서는 무작위 음성 조건에서도 제안 방법의 정밀도(0.8221–0.8265)가 LightGBM(0.8105–0.8155)보다 높았고 F1은 0.8534–0.8561 대 0.8200–0.8315였다. 따라서 정밀도가 낮다는 결과는 연구자 3,000명의 무작위 음성 조건에서 LightGBM과 비교했을 때 나타난 것이며 모든 조건에서 일관되게 나타난 것은 아니다.

3.4. 후보 인기도 통제 분석

무작위 음성 후보의 평균 연결 수는 관측 기간별 2.12–3.76으로 채택 후보의 33.00–52.42보다 훨씬 작아, 모델이 개인 맞춤 관계가 아니라 널리 연결된 주제인지를 구분했을 가능성이 있다. 실제로 후보 주제의 연결 수만 사용한 기준 모델도 F1 0.7073–0.7441, ROC-AUC 0.7581–0.7871을 보여 F1이 LightGBM(0.7082–0.7472)과 거의 같았다. 이에 음성 후보를 양성 후보와 연결 수가 비슷한 후보로 바꾸었다. 이 조건에서 후보의 평균 연결 수는 채택 후보 33.00–52.42, 음성 후보 30.61–49.22로 비슷하며, 연결 수만 사용한 기준 모델은 모든 쌍을 채택으로 예측해 F1 0.6667, ROC-AUC 0.5018–0.5038에 그쳐 연결 수로는 양성과 음성을 구분할 수 없게 되었다.

표 3 연결 수를 맞춘 음성 후보에서의 성능
Table 3 Performance with connection-matched negatives

구분	연결 수 기준	XGBoost	제안 방법
1년 F1	0.6667	0.6925	0.7458
1년 ROC-AUC	0.5018	0.6818	0.7855
3년 F1	0.6667	0.6942	0.7407
3년 ROC-AUC	0.5038	0.6976	0.7843
5년 F1	0.6667	0.6957	0.7348
5년 ROC-AUC	0.5019	0.7026	0.7752

연구자 3,000명, 양성 · 연결 수를 맞춘 음성 1:1. 연결 수 기준은 후보 주제의 연결 수만 사용한 기준 모델이며, XGBoost는 검증 F1으로 선정한 기준 모델이다.

표 3과 같이 이 조건에서 제안 방법의 F1은 0.7348–0.7458로, 검증 F1으로 선정된 XGBoost(0.6925–0.6957)보다 관측 기간별로 5.32, 4.65, 3.91%p 높았다(95% 신뢰구간 5.08–5.57, 4.40–4.90, 3.66–4.18%p). ROC-AUC도 0.7752–0.7855로 XGBoost의 0.6818–0.7026보다 높았다. 연구자 10,000명 코호트에서도 같은 경향이 유지되어 제안 방법의 F1은 0.7691, 0.7652, 0.7637이고 차이는 5.86, 4.90, 4.56%p였다. 한편 제안 방법의 F1은 무작위 음성 조건보다 5.4–5.9%p 낮아, 무작위 음성 조건의 성능 일부는 후보 인기도에 기인한 것으로 보인다. 따라서 제안 방법의 우위가 후보 인기도만으로 설명되지는 않지만, 이 분석은 연결 수만 통제하므로 개인 이력과 전역 구조 정보 각각의 기여를 분리하지는 못한다.

3.5. 한계

평가는 하나의 서지 데이터베이스, 정해진 주제 어휘와 예측 기간에 한정된다. 양성과 음성을 같은 수로 구성한 이진 분류이므로 실제 채택률에서의 성능, 전체 후보의 추천 순위와 확률 보정을 직접 보여주지 않는다. 특히 채택 비율이 낮은 환경에서는 같은 재현율과 오탐률에서도 정밀도가 표 2보다 낮아지므로, 본 결과를 Top-K 추천의 정확도로 해석할 수 없다. 연구자별 후보 수와 채택 비율이 다른 환경에서의 성능 분포도 분석하지 않았다. 따라서 결과는 개인화된 주제 탐색을 지원할 예측 구성 요소의 가능성이며 실제 추천 환경에는 별도 검증이 필요하다.

Ⅳ. 결론

개인 · 전역 지식 네트워크를 학습하고 후보에 따라 연구 이력을 요약하는 미래 주제 채택 예측 방법을 제안하였다. PubMed/MeSH의 연구자 3,000명 평가에서 세 관측 조건 모두 구조적 특징 기반 모델보다 높은 F1을 확인하였고, 연결 수를 맞춘 음성 후보에서도 3.91-5.32%p 높아 후보 인기도만으로는 우위를 설명하기 어렵다. 다만 무작위 음성 조건에서는 LightGBM보다 정밀도가 낮았다. 노드 제거 분석은 어떤 과거 주제에 예측이 민감한지 점검하는 수단을 제공한다. 향후 미관측 연구자, 실제 채택률과 전체 후보 순위(Top-K), 연구자별 후보 수에 따른 평가를 통해 연구 주제 탐색 지원으로의 적용 범위를 검토할 필요가 있다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Z. Wu, H. Jiang, L. Xiao, H. Wang, and J. Mao, "Study on the predictability of new topics of scholars: A machine learning-based approach using knowledge networks," Journal of Informetrics, vol. 19, 101637, 2025.

[2] P. Veličković et al., "Graph Attention Networks," International Conference on Learning Representations, 2018.

[3] J. Xu et al., "Building a PubMed Knowledge Graph," Scientific Data, vol. 7, 205, 2020.

지하 재난 대응 드론을 위한 자기 교란 강인 UWB-IMU 융합 항법 연구

조태현, 김민규, 김여겸, 문성태*

충북대학교 지능로봇공학전공, *충북대학교 지능로봇공학과

jungsubond@cbnu.ac.kr, kmk6061602@cbnu.ac.kr, yeogyeom1@cbnu.ac.kr, *stmoon@cbnu.ac.kr

A Study on Magnetically Robust UWB-IMU Fusion Navigation for Underground Disaster Response Drones

Tae-Hyeon Jo, Min-Kyu Kim, Yeo-Gyeom Kim, Sung-Tae Moon*

Department of Intelligent Systems and Robotics, Chungbuk National Univ.,

*Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

Reliable heading estimation for small indoor drones is challenged by magnetic disturbances from steel structures and electrical facilities and by the short baseline available for mounting two ultra-wideband (UWB) tags. This paper proposes an interacting multiple model extended Kalman filter (IMM-EKF) that fuses magnetometer heading with dual-UWB ranges. Two modes share inertial prediction and a tightly coupled dual-tag range update and differ only in the noise variance assigned to the magnetic heading, so that magnetic innovation likelihoods continuously shift the mode probabilities while the geometric heading correction from the UWB tags is preserved. In a physics-based Gazebo comparison, the proposed estimator achieved an overall heading RMSE of 6.94°, a 14.43% reduction relative to soft covariance scaling, and the smallest maximum cross-track error of 0.16 m. The estimator was then implemented on the mission computer of a quadrotor and flight-tested. Against an RTK reference outdoors, it achieved a horizontal position RMSE of 0.210 m and a heading RMSE of 2.92°. In a GNSS-denied indoor hall where the magnetic-field magnitude varied by 39-47%, it maintained a path-tracking RMSE of 0.166 m, 100% positioning availability, and no heading flips, comparable to the outdoor flights; indoor heading accuracy was not assessed for lack of a reference.

Key words : Indoor Flight, Dual UWB, Magnetic Disturbance, IMM-EKF, UAV Navigation

Ⅰ. 서 론

지하철 역사, 지하 터널, 대심도 지하 공간과 같이 사람의 접근이 제한되거나 위험한 실내 시설에서 소형 드론은 근접 점검, 진입 전 상황 파악, 인명 수색에 활용될 수 있다. 이러한 임무를 수행하려면 위성 항법(GNSS) 신호가 차단된 환경에서도 위치와 헤딩을 안정적으로 추정해야 한다. 카메라나 LiDAR 기반 SLAM은 특징점이 부족한 반복 구조와 조도 변화에서 추정이 이탈하기 쉽고 연산 부담이 커 소형 기체에 탑재하기 어려우므로, 인프라 기반 UWB(Ultra-Wideband) 측위가 유용한 보완 수단이 된다[1].

이 중 헤딩은 특히 유지하기 어렵다. 자이로 적분은 단기 자세 전파를 제공하지만 오차가 누적되므로 지자기 센서가 절대 방위 기준을 제공한다[2]. 그러나 실내의 철골 구조물, 전력 설비, 배관은 국소 자기장을 왜곡하여 이 기준을 신뢰할 수 없게 만든다[3, 4]. 기존 적응형 기법은 잔차가 임계값을 넘으면 지자기 관측을 배제하는 하드 스위칭(hard switching)이나, 잔차에 따라 관측 공분산을 연속적으로 키우는 소프트 스케일링(soft scaling)으로 대응한다. 어느 경우든 절대 방위 정보원은 지자기 하나뿐이어서, 교란이 지속되면 헤딩 보정은 오염된 지자기나 자이로 적분에 의존하게 된다.

공간적으로 떨어진 두 수신 장치를 이용하면 자기장과 무관한 두 번째 절대 방위 기준을 얻을 수 있다. Dual 안테나 GPS 헤딩 추정과 같은 원리를 UWB 태그 두 개에 적용한 Dual UWB 방식이 그 예이다[5, 6]. 다만 소형 드론은 태그 간 기선(baseline)을 길게 둘 수 없어 거리 오차가 큰 헤딩 오차로 증폭된다. 지자기는 비교란 구간에서 정밀하고 Dual UWB는 교란 구간에서도 유효하여 두 정보원은 서로를 보완한다.

본 논문은 두 정보원을 상호작용 다중 모델 확장 칼만 필터(Interacting Multiple Model Extended Kalman Filter, IMM-EKF)로 융합한다. 두 모드는 동일한 관성 예측과 Dual UWB 거리 강결합 갱신을 공유하고 지자기 관측 잡음 분산만 달리하며, 지자기 혁신(innovation)의 우도로 모드 확률을 갱신한다. 따라서 교란 모드로 전이하면 지자기 보정은 억제되지만 UWB 기하 보정은 유지된다. 본 논문의 기여는 다음과 같다. 첫째, 별도의 임계값 없이 지자기 신뢰도를 우도로 표현하는 2-모드 IMM-EKF를 설계하였다. 둘째, 무작위 Pilot 시뮬레이션과 물리 기반 Gazebo 시뮬레이션으로 기존 기법과 정량 비교하였다. 셋째, 제안 추정기를 쿼드로터에 탑재하여 RTK 기준 실외 비행에서 측위 및 헤딩 정확도를, 자기 교란이 실측된 GNSS 음영 실내 비행에서 경로 추종 성능을 검증하였다.

Ⅱ. 관련 연구

UWB는 광대역 신호의 시간 분해능을 이용해 정밀한 거리 측정을 제공하며[7, 8], 원시 거리를 항법 필터에 직접 반영하는 강결합 UWB/IMU 추정이 제안되었다[9]. UAV용 UWB 측위 특성 분석[1]과 이동형 앵커 시스템[10]도 주로 위치 정확도에 초점을 둔다. 헤딩 측면에서 Dual 안테나 GPS[5]와 UWB 거리 · 도래각 기반 쿼드로터 자세 추정[6]은 수신 장치 간 기하로 자기장과 무관한 헤딩을 얻지만, 기선이 짧을수록 정밀도가 떨어진다. 자기 교란 대응으로는 관성-지자기 EKF[2], 공분산 설계[11], 교란 영향 분석[4], 지자기 신뢰도에 따라 가중치를 조절하는

AMO-HEAD[12] 등이 있으나, 단일 관측 모델 안에서 지자기 잡음만 조절하므로 교란 시 독립적인 절대 방위 정보원이 없다(표 1). IMM은 복수의 가설을 측정 우도로 확률 갱신하는 추정 구조로[13, 14], 본 연구는 이를 기동 모드가 아닌 지자기 관측 신뢰도 가설에 적용한다.

표 1 헤딩 추정 기법 비교

Table 1 Comparison of heading estimation methods

기법	자기 교란 강건성	기선 의존성	절대 방위 정보원
지자기 융합 KF[2]	낮음	없음	지자기
하드 스위칭[3]	보통	없음	지자기
소프트 스케일링[12]	보통	없음	지자기
Dual UWB 단독[5, 6]	높음	높음	UWB
제안 기법	**높음**	**낮음**	**지자기+UWB**

Ⅲ. 제안 기법

1. 상태 및 관성 예측

항법 좌표계는 북-동-하(NED)를 따르며, 추정기는 수평 운동과 헤딩만 다룬다. 상태 벡터는 식 (1)과 같다.

$$x_k = \left[p_k^T \;\; v_k^T \;\; \psi_k\right]^T \tag{1}$$

여기서 p_k와 v_k는 2차원 위치와 속도, ψ_k는 헤딩이다. 측정 수평 가속도 $\widetilde{a_k}$, 수직축 각속도 $\widetilde{\omega_k}$, IMU 주기 Δt에 대해 두 모드는 동일한 예측식 (2)~(4)를 사용한다.

$$p_{k+1} = p_k + v_k\Delta t + \frac{1}{2}R(\psi_k)(\widetilde{a_k} - n_a)\Delta t^2 \tag{2}$$

$$v_{k+1} = v_k + R(\psi_k)(\widetilde{a_k} - n_a)\Delta t \tag{3}$$

$$\psi_{k+1} = \psi_k + (\widetilde{\omega_k} - n_g)\Delta t \tag{4}$$

$R(\psi_k)$는 수평면 회전 행렬, n_a와 n_g는 영평균 백색 가우시안 잡음이며, 공분산은 표준 EKF 선형화로 전파한다[14].

2. Dual UWB 강결합 거리 갱신

태그 m의 기체 좌표 오프셋을 r_m^b, 앵커 위치를 a_a^n이라 하면 거리 관측 모델은 식 (5)와 같다.

$$z_{m,a,k} = \left\| p_k + R(\psi_k)r_m^b - a_a^n \right\| + n_u \tag{5}$$

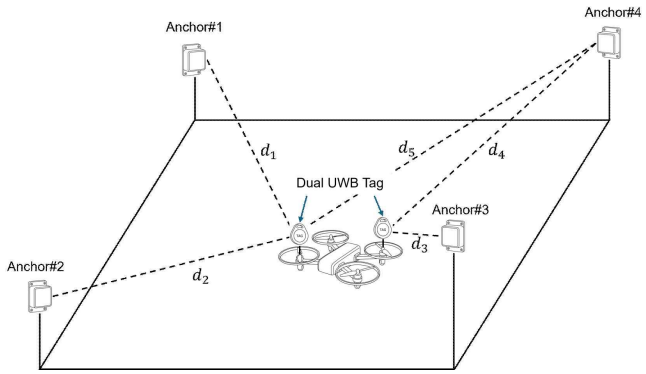


그림 1 Dual UWB 기반 헤딩 관측 구성

Fig. 1 Dual-UWB configuration for heading observation

태그 오프셋 때문에 예측 거리는 위치뿐 아니라 헤딩의 함수가 되며, 거리 혁신은 측정 야코비안과 칼만 이득을 통해 위치와 헤딩을 함께 보정한다. 좌·우 태그는 반대 부호의 오프셋으로 같은 헤딩 상태를 갱신하므로 두 태그의 거리 차가 곧 절대 헤딩 관측이 된다(그림 1). 거리는 태그·앵커 조합별 스칼라로 순차 갱신하여 일부 앵커만 수신되어도 갱신이 가능하고, 잡음이 큰 거리는 혁신 공분산이 커져 이득이 자동으로 줄어든다. 두 모드는 UWB 거리가 도착할 때마다 이 갱신을 공통으로 수행하므로 지자기 보정이 억제되어도 UWB 관측 경로는 끊기지 않는다.

3. 지자기 관측 모드

지자기 헤딩 $\widetilde{\psi_{\mathrm{mag,k}}}$는 식 (6)으로 관측되며 $j=1,\ 2$는 모드 번호이다.

$$\widetilde{\psi_{\mathrm{mag,k}}} = \mathrm{H_{mag}x_k} + \mathrm{n^j_{mag,k}}, \qquad \mathrm{H_{mag}} = [0\ \ 0\ \ 0\ \ 0\ \ 1] \tag{6}$$

정상 모드 M_1은 작은 분산 $R_{\mathrm{normal}}(\sigma = 5^\circ)$으로 지자기 보정을 허용하고, 교란 모드 M_2는 $R_{\mathrm{disturbed}} \gg \mathrm{R_{normal}}(\sigma = 90^\circ)$로 지자기 칼만 이득을 사실상 0으로 만든다. 갱신은 비동기로 수행되고, 같은 처리 주기에서는 UWB 갱신이 지자기 갱신보다 먼저 이루어진다. 모드 우도에 쓰는 지자기 혁신은 거리 보정 후·지자기 보정 전의 상태에서 계산하여, 이미 지자기로 보정된 사후 추정치로 우도를 계산하는 것을 방지한다.

4. 모드 상호작용, 확률 갱신 및 융합

IMM 주기는 상호작용·혼합, 모드별 필터링, 우도 산출, 출력 융합으로 구성된다[13, 14](그림 2). 모드 i에서 j로의 전이 확률을 π_{ij}, 이전 모드 확률을 μ_{k-1}^i라 하면 예측 확률과 혼합 가중치는 식 (7)과 같고, 각 모드는 식 (8)의 혼합 초기치에서 출발한다.

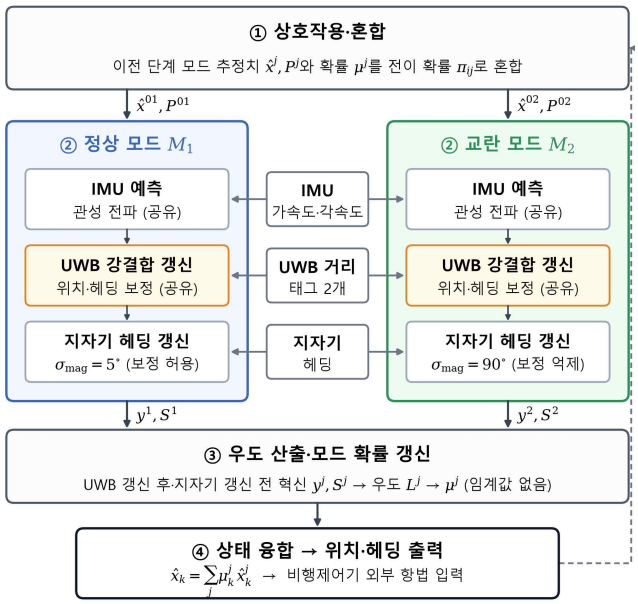


그림 2 제안 IMM-EKF 처리 구조

Fig. 2 Processing structure of the proposed IMM-EKF

$$\bar{c}_j = \sum_{i=1}^{2}\pi_{ij}\mu_{k-1}^i, \qquad \mu_{k-1}^{i|j} = \frac{\pi_{ij}\mu_{k-1}^i}{\bar{c}_j} \tag{7}$$

$$\widehat{x_{k-1}^{0j}} = \sum_{i=1}^{2}\mu_{k-1}^{i|j}\widehat{x_{k-1}^{i}} \tag{8}$$

혼합 공분산에는 모드 간 추정치 차이의 외적이 더해지며, 헤딩은 단위벡터의 원형 평균으로 혼합하여 $\pm\pi$ 경계에서 불연속이 생기지 않게 한다. 지자기 혁신 y_k^j와 혁신 공분산 S_k^j로부터 우도와 모드 확률을 식 (9), (10)으로 갱신한다.

$$L_k^j = \frac{1}{\sqrt{2\pi S_k^j}}\exp\left[-\frac{(y_k^j)^2}{2S_k^j}\right] \tag{9}$$

$$\mu_k^j = \frac{L_k^j \overline{c_j}}{\sum_{m=1}^{2} L_k^m \overline{c_m}} \tag{10}$$

큰 자기기 혁신은 분포가 좁은 정상 모드에서 우도가 급격히 낮아지므로 확률이 M_2로 이동하고, 자기장이 다시 예측과 일치하면 M_1로 복귀한다. 이는 이분법적 채택 · 배제가 아닌 연속적 확률 갱신이다. 최종 추정치와 공분산은 식 (11), (12)와 같이 모드 추정치의 확률 가중합으로 구하므로 모드가 바뀌어도 추정값이 튀지 않는다.

$$\hat{x_k} = \sum_{j=1}^{2} \mu_k^j \hat{x_k^j} \tag{11}$$

$$P_k = \sum_{j=1}^{2} \mu_k^j \left[P_k^j + (\hat{x_k^j} - \hat{x_k})(\hat{x_k^j} - \hat{x_k})^T \right] \tag{12}$$

전이 확률은 $\pi_{12} = 0.01$, $\pi_{21} = 0.10$, 초기 모드 확률은 $[0.9,\ 0.1]$로 설정하였다. 명시적 잔차 임계값은 없지만 전이 확률과 관측 분산이 적응 거동을 결정하는 설계 변수가 된다.

5. 시스템 구현

제안 추정기는 ROS 2 노드로 구현되어 임무 컴퓨터에서 IMU, 지자기, 태그별 UWB 거리를 입력받아 위치 · 헤딩과 두 모드의 확률을 출력한다. 출력은 PX4 비행제어기의 외부 항법 입력으로 전달되어 위치 · 자세 제어에 사용되며, 비행제어기 자체의 지자기 · GNSS 융합은 비활성화하여 헤딩이 제안 추정기로부터만 결정되도록 하였다. 시뮬레이션과 실기체는 동일한 추정기 코드와 공용 거리 메시지를 사용하므로 시뮬레이션에서 검증한 구성이 그대로 실비행에 적용된다. 또한 좌 · 우 태그를 통신 포트가 아닌 모듈 고유 ID로 식별하여, 부팅마다 포트 순서가 바뀌어 생길 수 있는 180° 헤딩 반전을 원천적으로 방지하였다. 전체 시스템 구성을 그림 3에 나타내었다.

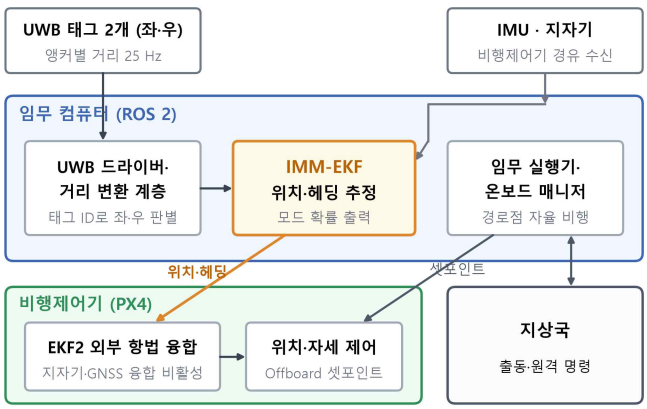


그림 3 제안 추정기를 탑재한 드론 시스템 구성
Fig. 3 Architecture of the drone system

IV. 실험 환경

1. 시뮬레이션

Pilot 시뮬레이션은 물리 기반 기체 모델 없이 2차원 평면 데이터로 알고리즘 동작을 평가한다. 15 m × 15 m 영역에서 시행마다 UWB 앵커 4개와 기준 경로를 무작위로 생성하고 경로 일부에 국소 자기 교란을 적용하여, 몬테카를로 300회로 하드 스위칭, 소프트 스케일링, 제안 기법의 오차 분포를 비교하였다. Gazebo 시뮬레이션은 IMU, 지자기 센서, UWB 태그 2개를 탑재한 쿼드로터 모델을 사용한다(그림 4). 7×7 격자(10 m 간격)의 앵커 49개 안에서 약 25 m × 40 m 영역을 고도 2.0 m, 1.0 m/s로 약 115 m의 'ㄹ'자 경로를 따라 비행하며, 경로의 처음 약 30 %는 비교란 구간이고 이후 구간에서는 지자기 측정에 정상 상태 편이가 더해진다. 두 시뮬레이션 모두 태그 기선은 0.424 m이며 주요 설정을 표 2에 정리하였다.

표 2 시뮬레이션 설정
Table 2 Simulation configurations

항목	Pilot	Gazebo
모델	2차원 평면 데이터	물리 기반 쿼드로터
경로	시행마다 무작위	고정 경로점, 약 115 m
비행 영역	15 m × 15 m	약 25 m × 40 m
UWB 앵커	4개, 무작위 배치	49개, 7×7, 10 m 간격
태그 수 · 기선	2개, 0.424 m	2개, 0.424 m
속도 · 고도	1.0 m/s, –	1.0 m/s, 2.0 m
IMU/지자기/UWB	250/100/25 Hz	250/100/25 Hz
가속도/자이로 잡음	0.8 m/s², 5°/s	0.8 m/s², 5°/s
지자기 헤딩 잡음	5°	5°
거리 잡음	0.30 m	0.16–0.32 m (거리 비례)

Gazebo에서는 다섯 기법을 비교하였다. 단일 UWB+지자기는 태그 1개로 위치를, 지자기($\sigma = 5^\circ$)로 헤딩을 무조건 보정한다. Dual UWB 단독은 두 태그만 사용하고 지자기를 쓰지 않는다. 하드 스위칭은 잔차가 25° 를 넘으면 지자기 표준편차를 90° 로 키우고, 소프트 스케일링은 $\sigma_{\mathrm{mag}}(y) = \min(\sigma_0 \exp(k|y|),\ 100^\circ)$ ($\sigma_0 = 5^\circ$, $k = 0.5$)로 연속 조절한다. 하드 스위칭과 소프트 스케일링은 Dual 태그 헤딩 보정이 없으므로, 비교 결과는 독립 UWB 기준과 확률적 지자기 적응의 결합 효과를 나타낸다. 평가 지표는 전 구간 및 정상 · 교란 구간별 헤딩 RMSE, 구간 간 증가율, 교란 구간 표본 비율, 계획 경로 대비 최대 수직 이탈(cross-track error)이다.

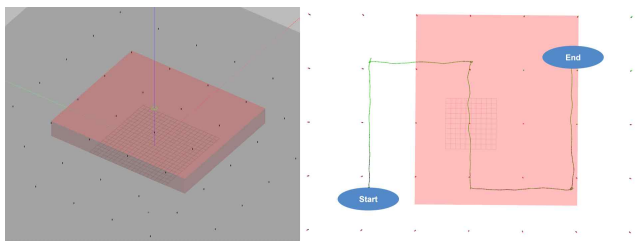


그림 4 Gazebo 환경과 비행 경로(붉은 영역: 교란 구간)
Fig. 4 Gazebo environment and planned flight path

2. 실비행 실험

실험 기체는 PX4 기반 쿼드로터(Pixhawk 6X)로, 좌 · 우에 UWB 태그 2개(기선 약 0.5 m)를 장착하고 ROS 2 임무 컴퓨터에 제안 추정기를 탑재하였다. 실내 실험은 벽면과 천장이 전파 흡수체로 마감된 시험 홀에서 수행하였으며, 비행 중 수신 위성 수가 0개로 GNSS 음영이 성립하였다. 20 m × 10 m 앵커 필드에 UWB 앵커 9개를 5 m 간격의 3×3 격자로 설치하되 높이를 0.68 m와 0.10 m로 섞어 수직 기하를 분산하였고, 지하 주차장의 기둥열을 모사한 단면 0.48 m × 0.52 m, 높이 1.8 m의 모의 기둥 6개를 배치하였다(그림 5, 그림 8(a)). 기체는 동서 8 m, 남북 18 m 구역을 왕복하는 'ㄹ'자 탐색 경로(경로점 8개, 약 75 m)를 자율 비행한 뒤 이륙 지점으로 복귀 · 착륙하였으며 이를 5회 반복하였다. 실외 실험은 RTK-GNSS 고정해(고정률 100 %)가 유지되는 개활지에서 8 m × 4 m 사각 경로를 3회 비행하였다.



그림 5 실내 비행 시험 환경(전파 흡수체 시험 홀)
Fig. 5 Indoor flight test environment

위치 정확도는 RTK 기준 궤적을 추정 좌표계로 2차원 강체 정합한 뒤 수평 RMSE로 평가하였다. 헤딩은 실내에 절대 기준이 없으므로 비교란 실외에서 롤·피치로 수평 보정한 지자기 헤딩을 기준으로, 일정 오프셋을 제거하여 RMSE를 산출하였다. 경로 추종은 지령 경로점을 이은 폴리라인까지의 수직 거리로, 측위 성공률은 비행제어기가 외부 위치·요(yaw)를 융합한 시간 비율로 평가하였다. 평가 구간은 이륙 5 s 후부터 착륙 5 s 전까지이며 모든 비행에서 추정기 설정을 고정하였다.

V. 실험 결과 및 고찰

1. 시뮬레이션 결과

Pilot 시뮬레이션 300회에서 제안 기법은 위치와 헤딩 RMSE 모두 분포의 평균이 가장 낮고 폭이 가장 좁았다. 하드 스위칭은 이분법적 동작으로 분포의 오른쪽 꼬리가 길어 일부 조건에서 큰 헤딩 오차가 발생하였고, 소프트 스케일링은 중심은 개선되었으나 교란이 지속되는 구간에서 오차가 누적되었다. 그림 6의 예와 같이 모드 확률은 정상 구간에서 M_1이 우세하다가 교란 구간에서 혁신이 커지면 M_2로 이동하고, 교란이 끝나면 다시 M_1로 복귀하여 별도의 교란 정보 없이 적응하였다.

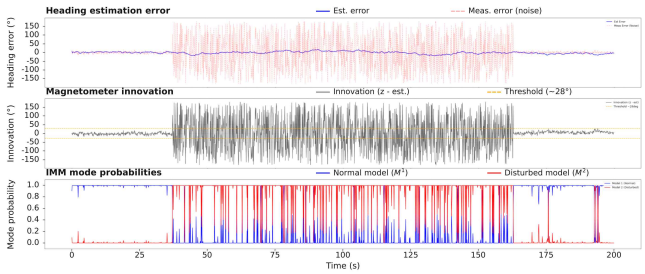


그림 6 Pilot 예시의 헤딩 오차, 지자기 혁신, 모드 확률
Fig. 6 Pilot example of IMM mode probabilities

Gazebo 결과를 표 3에 나타내었다. 제안 기법은 전 구간 헤딩 RMSE 6.94±0.36° 로 다섯 기법 중 가장 낮았으며, 소프트 스케일링(8.11±0.75°) 대비 14.43 % 감소하였다. 정상·교란 구간에서도 각각 5.89±0.22° , 7.47±0.41° 로 가장 낮았다. 단일 UWB+지자기는 교란 구간에서 24.47° (증가율 310.7 %)로 크게 열화되었고 하드 스위칭도 16.25° 에 머물렀다. Dual UWB 단독은 증가율이 6.8 %로 작지만 정상 구간 오차가 7.74° 로 지자기를 쓰는 기법보다 커서 짧은 기선의 정밀도 한계가 드러난다. 제안 기법의 증가율 26.9 %는 지자기를 사용하는 기법 중 가장 작다. 교란 구간 표본 비율은 63.8-65.2 %(평균 64.2 %)로 노출 조건이 유사하였고, 최대 수직 이탈도 0.16 m로 가장 작아(소프트 스케일링 0.32 m) 헤딩 개선이 경로 추종 성능으로 이어졌다. 그림 7의 헤딩 오차 이력에서도 제안 기법은 교란 구간 진입 후 0° 부근에 집중된다.

표 3 Gazebo 시뮬레이션 성능 비교
Table 3 Performance comparison in Gazebo

기법	전체 RMSE(°)	정상 RMSE(°)	교란 RMSE(°)	증가율 (%)	최대 이탈 (m)
단일 UWB +지자기	19.96±0.70	5.96±0.28	24.47±0.39	310.7	1.58
Dual UWB 단독	8.09±0.29	7.74±0.84	8.26±0.35	6.8	0.60
하드 스위칭	13.48±0.46	6.05±0.21	16.25±0.59	168.8	1.49
소프트 스케일링	8.11±0.75	6.60±0.57	8.84±1.15	33.9	0.32
제안 기법	**6.94±0.36**	**5.89±0.22**	**7.47±0.41**	**26.9**	**0.16**

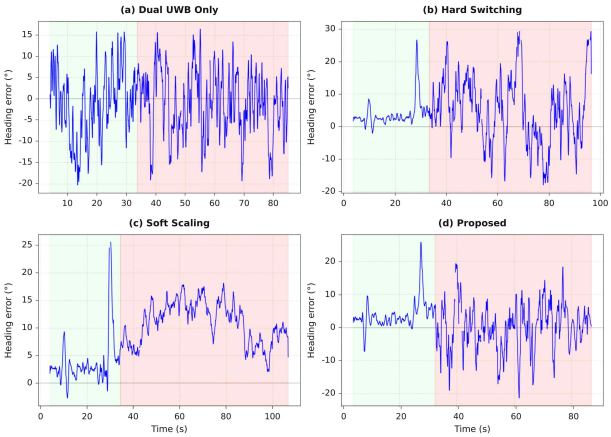


그림 7 기법별 헤딩 오차 이력(녹색: 정상, 적색: 교란)
Fig. 7 Heading-error histories of the compared methods

2. 실내 자기 교란 실측

실내 시험 홀의 비행 구간 자기장 크기는 0.35-0.57 gauss로 위치에 따라 평균 대비 39-47 % 변동하였고, 동쪽 변에서 크고 서쪽 변에서 작은 공간 구배가 5회 비행에서 동일하게 나타났다(그림 8(a)). 같은 기체와 센서가 실외에서는 0.48-0.53 gauss(변동 10-11 %)로 지구 자기장 수준에 머물렀으며(그림 8(b)), 기체 헤딩은 전 구간 북향으로 고정되었으므로 이 변동은 기체가 아닌 공간의 왜곡이다. 지자기 헤딩과 추정 헤딩 간 잔차의 표준편차도 실내 6.7-7.4° 로 실외 5.2-5.3° 의 약 1.4배였고 95 백분위수는 12-14° 에 달하였다. 시험 홀은 실제 교란 환경으로, 지자기를 무조건 신뢰하면 이 크기의 오차가 헤딩에 그대로 유입된다. 한편 UWB는 9개 앵커 모두 총 수신 세기와 첫 경로 세기의 차가 2.3-2.9 dB인 가시선 수신 특성을 보였고, 거리 잔차 RMS는 17.8-18.2 cm, 앵커별 평균 편향은 −10~+25 cm였다.

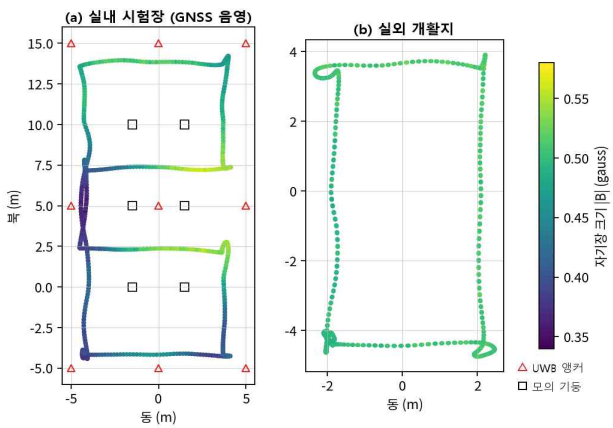


그림 8 비행 구간 자기장 크기: (a) 실내, (b) 실외
Fig. 8 Magnetic-field magnitude: (a) indoor, (b) outdoor

3. 실비행 측위 · 헤딩 성능

RTK 기준 실외 3회 비행에서 위치 RMSE는 0.200–0.222 m(평균 0.210 m), 헤딩 RMSE는 2.80–3.08° (평균 2.92°)였다(그림 9). 정합 회전각은 세 비행에서 0.2° 이내로 일치하여 앵커 좌표계와 기준 좌표계의 관계가 안정적으로 유지되었다. 위치 오차는 변을 이동하는 동안 커지고 경로점에서 작아지는 속도 비례 성분이 지배적이었으며, 최대 오차(0.38–0.41 m)는 이동 중 일부 구간에서만 나타났다. 실내는 위치 · 헤딩의 절대 기준값이 없으므로 헤딩 RMSE는 실외 결과로 한정되며, 실내 성능은 경로 추종 오차로 평가하였다. 경로 추종 RMSE는 실외 0.166–0.212 m(평균 0.190 m), 실내 0.164–0.172 m(평균 0.166 m)였고 실내 5회는 같은 경로에서 0.01 m 이내로 재현되었다. 오차는 경로점 선회 직후 0.4–0.5 m의 봉우리를 보이고 직선 구간에서는 0.1 m 안팎이었다.

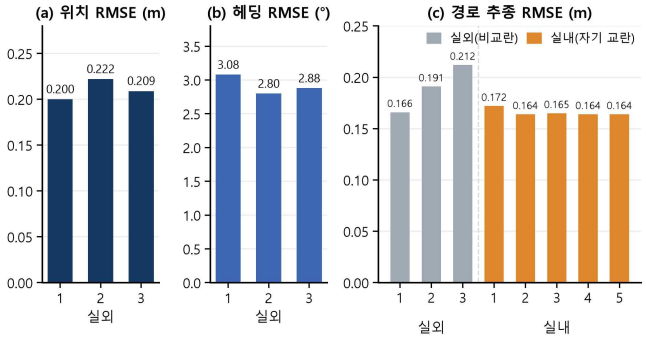


그림 9 실비행 위치 · 헤딩 · 경로 추종 RMSE
Fig. 9 RMSE results of the flight tests

8회 비행 합계 598 s 동안 외부 위치 · 요 융합이 끊긴 구간은 없어 측위 성공률은 모두 100 %였고, 180° 헤딩 반전도 발생하지 않았다. 실내 경로 오차가 비교란 실외와 같은 수준이고 헤딩 반전이 없었다는 점은 교란 조건에서도 헤딩이 크게 열화되지 않았음을 간접적으로 시사하나, 실내 헤딩 정확도를 직접 정량화한 것은 아니다. 또한 같은 시험 홀에 앵커 4개를 둔 사전 비행(동일 속도 상한, 유사 경로)에서 제안 필터의 헤딩 잔차 표준편차(비행제어기 헤딩 대비)는 2.6–4.0° 로, 태그별 삼변측량 위치를 차분하는 기하 방식의 4.5–6.0° 보다 작았다.

4. 자율 비행 수행

실내 5회 비행 모두 자동 이륙, 경로점 8개의 탐색 경로 비행, 이륙 지점 복귀, 자동 착륙을 조종자 개입 없이 완주하였고(5/5), 출동 명령부터 착륙 완료까지 104.5–111.3 s가 소요되었다. 직선 구간 이동 속도는 1.2–1.4 m/s였으며, 태그가 수신한 앵커는 프레임당 평균 8.95–8.99개(최소 7개)로 4개 이상 수신 비율이 100 %였다. 비행 궤적은 앵커 필드의 변에서 0.5 m 안쪽까지 전역에 걸쳐 있었다.

이상의 결과에서 지자기와 Dual UWB의 상호 보완적 융합은 실제 기체에서 실외 기준 0.3 m 이하의 위치 정확도와 약 3° 의 헤딩 정확도로, 자기 교란 실내에서는 실외와 동등한 경로 추종으로 이어졌다.

VI. 결 론

본 논문은 자기 교란이 빈번한 실내에서 소형 드론의 헤딩을 강건하게 추정하기 위한 IMM–EKF를 제안하였다. 두 모드는 관성 예측과 Dual UWB 강결합 갱신을 공유하고 지자기 관측 잡음 분산만 달리하며 우도 기반으로 융합된다. Gazebo 시뮬레이션에서 제안 기법은 전 구간 헤딩 RMSE 6.94° 로 소프트 스케일링 대비 14.43 % 개선되었고 최대 경로 이탈 0.16 m를 기록하였다. 실기체 탑재 비행에서는 실외 RTK 기준 위치 RMSE 0.210 m, 헤딩 RMSE 2.92° 를 얻었으며, 자기장 크기가 39–47 % 변동하는 GNSS 음영 실내에서도 경로 RMSE 0.166 m, 측위 성공률 100 %, 헤딩 반전 0건으로 실외와 동등한 경로 추종 성능을 유지하였다. 제안 구조는 교란 검출기나 임계값 조정 없이 PX4 기체의 외부 항법 입력으로 연동되어, GNSS 음영 지하 시설의 점검 · 수색 드론에 적용하기 쉽다. 본 실험에서 기준 부재로 평가하지 못한 실내 헤딩 정확도를 향후 독립 헤딩 기준을 갖춘 교란 환경에서 모드 확률 거동과 함께 정량화하고, UWB 비가시선(NLOS) 모드와 적응형 전이 확률을 도입하며, 실제 지하 공간으로 검증을 확장할 계획이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP–2026–RS–2020–II201462).

참 고 문 헌

[1] J. P. Queralta, C. M. Almansa, F. Schiano, D. Floreano, and T. Westerlund, "UWB–based System for UAV Localization in GNSS–Denied Environments: Characterization and Dataset," Proc. IEEE/RSJ Int. Conf. Intelligent Robots and Systems (IROS), pp. 4521–4528, 2020.

[2] A. M. Sabatini, "Quaternion–based Extended Kalman Filter for Determining Orientation by Inertial and Magnetic Sensing," IEEE Trans. Biomedical Engineering, vol. 53, no. 7, pp. 1346–1356, 2006.

[3] M. H. Afzal, V. Renaudin, and G. Lachapelle, "Magnetic Field Based Heading Estimation for Pedestrian Navigation Environments," Proc. Int. Conf. Indoor Positioning and Indoor Navigation (IPIN), pp. 1–10, 2011.

[4] B. Fan, Q. Li, and T. Liu, "How Magnetic Disturbance Influences the Attitude and Heading in Magnetic and Inertial Sensor–Based Orientation Estimation," Sensors, vol. 18, no. 1, 76, 2018.

[5] T.–D. Q. Tran and V.–H. Nguyen, "Heading Estimation for Autonomous Robot Using Dual–Antenna GPS," Int. J. Mechanical Engineering and Robotics Research, vol. 9, no. 12, pp. 1566–1572, 2020.

[6] E. Sato, I. Maruta, and K. Fujimoto, "Quadrotor Pose Estimation and Real–Time Control Using UWB–Based Bidirectional Measurements of Distance and Angle of Arrival," Advanced Robotics, vol. 39, no. 13, pp. 864–882, 2025.

[7] S. Gezici and H. V. Poor, "Position Estimation via Ultra–Wide–Band Signals," Proc. IEEE, vol. 97, no. 2, pp. 386–403, 2009.

[8] Y. Shen and M. Z. Win, "Fundamental Limits of Wideband Localization–Part I: A General Framework," IEEE Trans. Information Theory, vol. 56, no. 10, pp. 4956–4980, 2010.

[9] J. D. Hol, F. Dijkstra, H. Luinge, and T. B. Schon, "Tightly Coupled UWB/IMU Pose Estimation," Proc. IEEE Int. Conf. Ultra–Wideband (ICUWB), pp. 688–692, 2009.

[10] S. Moon and W. Youn, "A Novel Movable UWB Localization System Using UAVs," IEEE Access, vol. 10, pp. 41303–41312, 2022.

[11] R. B. Widodo and H. Morimoto, "Attitude Estimation Using Kalman Filtering: External Acceleration Compensation Considerations," J. Sensors, vol. 2016,

6943040, 2016.
[12] Q. Guo, S. Yang, J. Lyu, J. Sun, D. Lin, and S. He, "AMO-HEAD: Adaptive MARG-Only Heading Estimation for UAVs Under Magnetic Disturbances," IEEE Trans. Instrumentation and Measurement, vol. 74, 8516316, 2025.
[13] H. A. P. Blom and Y. Bar-Shalom, "The Interacting Multiple Model Algorithm for Systems with Markovian Switching Coefficients," IEEE Trans. Automatic Control, vol. 33, no. 8, pp. 780-783, 1988.
[14] Y. Bar-Shalom, X.-R. Li, and T. Kirubarajan, Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software, John Wiley & Sons, 2001.

산화물 반도체 소자의 특성 개선을 위한 IGZO 박막 제조 공정 연구

서정무, 김재환, 이원표*, 김성진**

충북대학교 컴퓨터공학전공, *충북대학교 산업인공지능학과, **충북대학교 컴퓨터공학과
seojm1012@gmail.com, robinjh0314@gmail.com, *cenornd1@ceno-tech.com, **ksj@cbnu.ac.kr

IGZO Thin-Film Fabrication Processes for Improving the Characteristics of Oxide Semiconductor Devices

Jeong Moo Seo, Jae Hwan Kim, Won Pyo Lee*, Sung-Jin Kim**
Department of Computer Engineering, Chungbuk National Univ.,
*Department of Industrial Artificial Intelligence Engineering, Chungbuk National Univ.,
**Department of Computer Engineering, Chungbuk National Univ.

Abstract

This study investigates IGZO thin-film processing for diversified artificial-intelligence semiconductor applications by linking reference transistor characterization, channel-structure evaluation, and low-temperature post-treatment. RF-sputtered IGZO TFTs were evaluated at nine positions per specimen, with mean mobilities of 4.58-6.93 cm^2 /V · s. Preliminary a-IGZO/GO-In_2O_3 composite and crystalline-amorphous IGZO bilayer experiments identified process issues related to device variation and post-treatment. Oxygen-plasma treatment combined with annealing at 150 ° C yielded a mobility of 6.30 cm^2 /V · s and an on/off ratio of 5.0 × 10^5 at 80 W. The threshold-voltage shift after 500 s of negative bias stress decreased to −1.08 V, while white-light photosensitivity reached 4.1 × 10^3 . These complementary evaluations provide a basis for refining IGZO processing toward stable switching and photosensing applications.

Key words : IGZO, RF sputtering, Plasma treatment, Thin-film transistor, Process optimization

Ⅰ. 서 론

비정질 인듐-갈륨-아연 산화물(a-IGZO)은 투명 산화물 TFT의 채널 소재로 활용된다[1]. 소자 성능과 안정성은 제조 공정과 결함 상태의 영향을 받으며[2,3], 저온 공정은 열 예산을 줄이는 주요 연구 방향이다[4]. 본 연구는 IGZO를 중심으로 기준 소자의 전기적 특성, 복합층 · 이중층 구조, 저온 산소 플라즈마 후처리를 검토하고, 이들의 평가 결과를 연결하여 광감지 및 인공지능 반도체 응용을 위한 공정 개선 방향을 도출하고자 하였다.

Ⅱ. 본론

2.1 IGZO 기준 소자의 제작 및 전기적 특성 평가

본 연구는 IGZO 채널의 구조와 후처리가 소자 특성에 미치는 영향을 중심으로 구성하였다. 기준 TFT의 전기적 특성 평가, 복합층 · 이중층 예비 실험의 공정 검토, 저온 산소 플라즈마에 의한 광응답 · 안정성 평가를 연결하여 IGZO 공정 개선 방향을 분석하였다.

RF 스퍼터링으로 형성한 IGZO 채널과 MoW 소스 · 드레인 전극을 갖는 TFT를 평가하였다. A-D 소자에서 각각 3×3 위치의 소자 9개를 측정하고, 전달 특성으로부터 이동도(μ), 문턱전압(Vth), 문턱하 기울기(SS)를 비교하였다. 그림 1은 기준 소자의 전달 특성이며, 표 1은 시편별 평균값이다.

평균 이동도는 4.58-6.93 cm^2 /V · s, 평균 Vth는 8.88-10.33 V, 평균 SS는 1.37-2.08 V/dec 범위였다. C 시편은 평균 이동도가 가장 높았으나 SS는 A 시편이 가장 낮았다. 따라서 IGZO 공정 평가는 이동도뿐 아니라 스위칭 특성과 위치별 편차를 함께 고려해야 한다. 이를 후처리 공정 검토의 평가 기준으로 설정하였다.

표 1 기준 소자의 전기적 특성

Table 1 Electrical properties of reference TFTs

	μ (cm^2 /V · s)	Vth (V)	SS (V/dec)
A	4.58 ± 0.31	9.53	1.37
B	5.36 ± 0.50	8.88	1.46
C	6.93 ± 0.75	10.33	2.08
D	6.06 ± 0.36	10.05	1.63

2.2 IGZO 복합층 · 이중층을 통한 공정 조건 검토

이동도와 스위칭 특성을 함께 관리하기 위해 IGZO 채널 구조와 후처리 조건을 검토하였다.

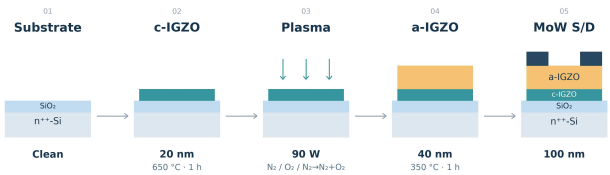


그림 1 결정질-비정질 IGZO 이중층 제작 공정 과정

Fig. 1 Fabrication process of crystalline-amorphous IGZO bilayer TFTs

그림 1에서 보는 것과 같이 IGZO 이중층은 20 nm 하부층을 650 ° C에서, 40 nm 상부층을 350 ° C에서 각각 1시간 열처리하는 구조로 설계하였다. 하부층에 무처리, N_2 , O_2 , $N_2 \rightarrow N_2 + O_2$ 플라즈마 조건을 적용하여 전달 특성을 비교하였다(그림 2). 복합층에서 확인한 소자 편차와 이중층의 조건별 전달 특성을 함께 검토하여 채널 구조 · 열처리 · 플라즈마 조건을 연계한 평가의 필요성을 도출하였다.

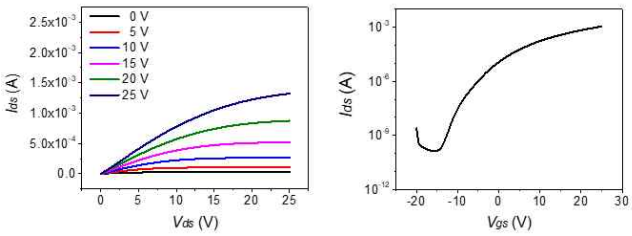


그림 2 IGZO 이중층 구조 소자의 전기적 특성
Fig. 2 Electrical characteristics of IGZO bilayer devices

복합층 · 이중층 평가가 채널 구조와 열처리 조건의 영향을 검토하는 과정이라면, 저온 후처리 평가는 IGZO 채널의 기능을 유지하면서 광응답과 안정성을 조절하는 접근이다. 이러한 공정 설계 관점에서 산소 플라즈마와 저온 열처리를 결합한 IGZO 후처리 특성을 분석하였다.

2.3 저온 산소 플라즈마에 의한 IGZO 특성 개선

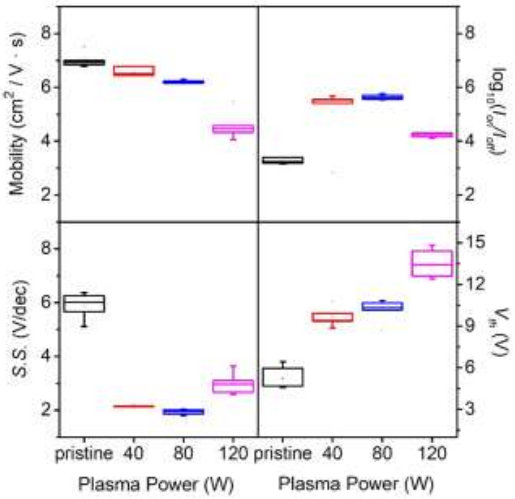


그림 3 저온 산소 플라즈마 공정 적용 소자의 전기적 특성
Fig. 3 Electrical characteristics of devices treated with low-temperature oxygen plasma

IGZO의 광감지 특성과 바이어스 안정성을 평가하기 위해 산소 플라즈마와 150 ° C 저온 열처리를 결합하고, 플라즈마 전력을 40, 80, 120 W로 변화시켰다. 80 W 소자는 μ=6.30 cm² /V · s, Ion/Ioff=5.0×10⁵, Vth=8.68 V, SS=2.04 V/dec를 나타냈다. 이 결과는 IGZO의 전하 수송과 스위칭 특성을 함께 평가하는 저온 후처리 조건의 검토 근거가 된다. 전기적 특성에 이어 후처리의 기능적 효과를 확인하기 위해 바이어스 안정성과 광응답을 평가하였다. 500 s 음의 바이어스 스트레스 후 문턱전압 변화는 무처리 소자의 −7.0 V에서 80 W 소자의 −1.08 V로 감소하였다. 백색광 조사 시 광감도는 4.1×10³ 으로 무처리 대비 약 200배 향상되었다. 이는 추가 흡수층 없이 IGZO 후처리를 통해 광감지 특성과 바이어스 안정성을 함께 개선할 수 있음을 보여준다.
광응답과 안정성의 개선은 산소 공공 관련 결함의 패시베이션 및 수산기 관련 서브갭 상태의 변화와 연관될 가능성이 있다. 다만 구조별 소자와 저온 후처리 소자는 독립된 실험군이므로 수치 차이를 단일 공정 변수의 효과로 해석하기보다 각 실험의 평가 항목을 연결하여 공정 방향을 검토하였다.

2.4 IGZO 공정 연구의 종합 및 응용 방향

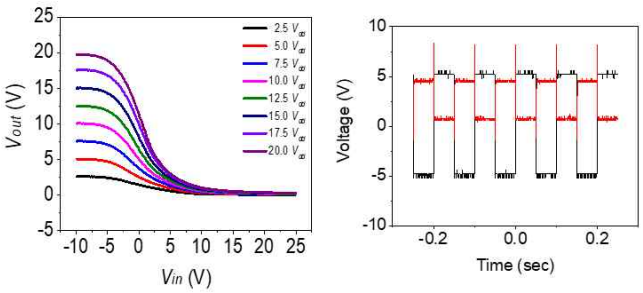


그림 4 이중층 소자 논리 게이트 동작 검증
Fig. 4 Verification of logic gate operation in IGZO bilayer devices

IGZO 기준 소자 평가는 이동도 · 스위칭 특성 · 소자 편차의 관리 기준을 제시하였고, 복합층 · 이중층 예비 실험은 채널 구조와 후처리 조건의 검토 항목을 구체화하였다. 저온 산소 플라즈마 평가는 이러한 공정 연구를 광응답과 바이어스 안정성의 기능 평가로 확장하였다. 세 실험은 IGZO 채널의 공정-특성 관계를 전기적 성능, 구조 변화, 광감지 기능의 관점에서 상호 보완적으로 분석한 결과이다.
향후에는 동일 구조의 IGZO 소자에서 공정 변수를 통제하고 반복 제작 · 시간 경과별 측정을 수행하여 재현성을 검증할 계획이다. 메모리 응용은 산화물 저항 스위칭과 전도성 필라멘트 연구[5-7] 및 멤리스터의 연산 응용[8]을 바탕으로 IGZO ReRAM의 스위칭 · 보존 · 반복 동작을 평가하는 후속 연구로 추진하고자 한다.

Ⅲ. 결론

본 연구는 IGZO를 중심으로 기준 소자 평가, 복합층 · 이중층 공정 검토, 저온 산소 플라즈마 후처리의 광응답 · 안정성 평가를 연계하였다. 기준 소자에서는 이동도와 스위칭 특성의 균형 및 소자 편차 관리의 필요성을 확인하였다. 구조별 예비 실험은 공정 개선 항목을 제시하였으며, 80 W 저온 후처리는 광감도와 바이어스 안정성의 개선 가능성을 보여주었다. 향후 공정 이력과 소자 특성을 연결한 반복 검증을 통해 IGZO 광감지 소자의 재현성을 확보하고, IGZO ReRAM 및 공정-성능 예측모델 연구로 발전시키고자 한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] K. Nomura et al., “Room-temperature fabrication of transparent flexible thin-film transistors using amorphous oxide semiconductors,” Nature, 432, 488-492, 2004. doi:10.1038/nature03090.

[2] T. Kamiya, K. Nomura, and H. Hosono, “Present status of amorphous In-Ga-Zn-O thin-film transistors,” Sci. Technol. Adv. Mater., 11, 044305, 2010.

doi:10.1088/1468-6996/11/4/044305

[3] E. Fortunato, P. Barquinha, and R. Martins, "Oxide Semiconductor Thin-Film Transistors: A Review of Recent Advances," Adv. Mater., 24, 2945-2986, 2012. doi:10.1002/adma.201103228.

[4] M.-G. Kim, M. G. Kanatzidis, A. Facchetti, and T. J. Marks, "Low-temperature fabrication of high-performance metal oxide thin-film electronics via combustion processing," Nat. Mater., 10, 382-388, 2011. doi:10.1038/nmat3011.

[5] R. Waser and M. Aono, "Nanoionics-based resistive switching memories," Nat. Mater., 6, 833-840, 2007. doi:10.1038/nmat2023.

[6] D. B. Strukov, G. S. Snider, D. R. Stewart, and R. S. Williams, "The missing memristor found," Nature, 453, 80-83, 2008. doi:10.1038/nature06932

[7] D.-H. Kwon et al., "Atomic structure of conducting nanofilaments in TiO_2 resistive switching memory," Nat. Nanotechnol., 5, 148-153, 2010. doi:10.1038/nnano.2009.456.

[8] J. J. Yang, D. B. Strukov, and D. R. Stewart, "Memristive devices for computing," Nat. Nanotechnol., 8, 13-24, 2013. doi:10.1038/nnano.2012.240.

INDAI 콜로키움 2026 논문집

2026년 11월 2일(월), 충북대학교 개신문화관

Session 2

산업인공지능학과 졸업프로젝트



정찰 드론 영상에서 적 전차 탐지 및 식별을 위한 합성데이터 기반 딥러닝 모델의 성능 평가

노경진, 김영진*, 강현수**
충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 정보통신공학부
pod111@chungbuk.ac.kr, *you359@chungbuk.ac.kr, **hskang@chungbuk.ac.kr

Performance Evaluation of Synthetic-Data-Based Deep Learning Models for Enemy Tank Detection and Identification in Reconnaissance Drone Imagery

Kyeong-Jin Noh, Young-Jin Kim*, Hyunsoo Kang**
Department of Industrial AI, Chungbuk National Univ.,
*Industrial AI Research Center, Chungbuk National Univ.,
**School of Information and Communication Engineering, Chungbuk National Univ.

Abstract

Limited annotated real tank imagery motivates synthetic training data. Seven M1A1 compositions combine real photographs (R), close-framing and varied-turret synthetic imagery (C), and synthetic location views (D). All conditions use 600 anchor draws per epoch and compare EMA snapshots at 993 successful optimizer updates. N5 restores a completed 992-update checkpoint and adds 16 minibatches with reset gradients, RNG and loader state; N6 completes a fresh 100-epoch run with no subsequent extension. On 385 real photographs, N1 reaches 19.27% AP50:95 versus 15.77% for N7. On the same 41 positive photographs, N7 reaches 53.69% versus 44.56% for N1, while full-set negative-image false-positive rate rises from 34.30% to 46.22%. Overall real-image gains are not reproduced under this update budget. Unequal hardware, sampling, exposure and EMA/BN states, reused development data and a single seed limit causal and statistical claims.

Key words : Synthetic data, Tank detection, M1A1, YOLOv8, Domain gap

Ⅰ. 서론

정찰 드론의 활용이 확대되면서 영상에 나타난 전차를 신속하고 일관되게 탐지 및 식별할 필요성이 커지고 있다. 대량의 영상을 사람이 모두 검토하는 방식은 처리 시간과 판독자의 숙련도에 영향을 받으므로, AI 기반 자동 탐지가 요구된다. 그러나 실제 전차 영상은 촬영과 수집이 어렵고, 다양한 객체 크기와 시점과 배경을 포함한 영상에 박스 정답을 부여하는 데에도 시간과 비용이 든다.

드론 영상의 자동 분석과 자료 구축에는 시점 및 크기 변화와 대규모 수집, 수작업 주석의 어려움이 있다[1]. 항공영상의 소형 객체 탐지 검토는 작은 크기, 시점, 방향 변화, 복잡한 배경과 가림이 주요 과제이다[2]. 항공영상의 밀집 주석자료 부족을 배경으로 여러 비행 높이의 다중모달(Multimodal) 합성자료를 제시하였다[3].

본 연구는 부족한 실사 학습 자료를 합성데이터로 보완하여 전차 탐지 성능을 높일 수 있는지 확인하는 것을 목적으로 한다. 합성데이터는 객체의 크기 및 포탑 회전 및 촬영 시점을 조절하고 박스 정답을 함께 생성할 수 있다[4,5]. 다만 합성 환경에서의 성능이 실제 영상으로 그대로 이어지는지는 검증이 필요하다.

Ⅱ. 데이터 및 연구 방법

먼저 전차 10종을 구분하는 실험에서 YOLO8s, YOLO11s, YOLO26s 세 모델과 합성데이터 수량에 따른 검출 성능을 비교하였다. 대상 차종은 T90A, T55A, Type99, M1A1, Type10, Leopard2A7, T14Armata, AMX56Leclerc, K2, ChallengerII이다.

학습 자료는 차종별 1,000장, 총 10,000장으로 구성된 D1과 차종별 5,000장, 총 50,000장으로 구성된 D5로 구성하였다. D1에서는 세 모델을 비교하고, YOLO26s에서는 D1과 D5를 비교하여 자료 수량의 영향을 살펴보았다. 평가에는 합성데이터 사진 2,000장과 실사 사진 385장으로 실사 사진은 10개 차종의 정답 객체 586개을 사용했으며 결과는 표 2에 제시하였다.

다음으로 M1A1 한 차종의 자료 조합을 비교하였다. 실사 자료 R과 합성데이터 C, D는 각각 사진 200장으로 구성된다. 표 1의 정답 객체 수는 각 사진에 표시된 전차 정답 박스의 개수이며, 같은 전차가 여러 사진에 나타나더라도 사진별로 각각 집계한다. R은 사진 200장에 정답 객체 227개가 포함되어 있다. C와 D는 사진마다 정답 객체가 1개씩 포함되므로 각각 200개이다. N1은 R, N2는 C, N3은 D를 사용한다. N4는 R+C, N5는 R+D, N6는 C+D를 사용하며 N7은 R+C+D를 사용한다.

표 1. N1~N7 모델의 자료 구성

Table 1. Dataset compositions of models N1 to N7.

조건	자료	사진 수(장)	정답 객체 수(개)
N1	R	200	227
N2	C	200	200
N3	D	200	200
N4	R+C	400	427
N5	R+D	400	427
N6	C+D	400	400
N7	R+C+D	600	627

합성데이터는 Unity 6000.6.3.f1로 제작하였다. C는 고정 배경, D는 지형, 주거지, 화학공장, 군사 캠프의 네 배경으로 구성하였다. C는 전차 크기와 카메라 시야각으로 계산한 화면 맞춤 거리의 1.05~1.20배에서 방위 0~360° , 수평 기준 내려다보는 각 5~65° 와 포탑 방향 8개 45° 구간을 변화시켰다. D는 높이 50m, 내려다보는 각 45~80° , 수직 시야각 60° 조건에서 각 배경마다 50장씩 선정하였다.

Ⅲ. 실험 결과

표 2는 전차 10종 실험의 검출 결과이다. 합성데이터의 평균 검출 성능(mAP50:95)은 약 89~91%였지만 실사 자료에서는 1% 미만이었다.

표 2는 여러 차종을 구분한 기존 실험이며, 표 3과 표 4는 M1A1 한 차종의 검출 결과이다. 차종 범위와 평가 조건이 다르므로 표 2는 실사 자료에서 성능이 낮아진 배경 사례로 제시하고 N1~N7과 직접 순위를 비교하지 않는다.

표 2. 기존 10차종 모델의 합성 · 실사 사진 검출 결과 (%)

Table 2. Synthetic and real-image detection results for prior ten-class models.

기존 모델	합성 mAP50	합성 mAP 50:95	실사 mAP50	실사 mAP 50:95
YOLO26s D1	98.45	89.23	1.48	0.68
YOLO26s D5	98.82	89.91	0.69	0.25
YOLO11s D1	98.87	90.52	1.06	0.50
YOLO8s D1	98.18	89.93	1.68	0.73

표 3은 표 1의 일곱 개 자료 조합을 비교한 결과이다. 비교에는 합성데이터 200장, 항공 사진 239장, 전체 실사 사진 385장을 사용했다. AP50와 AP50:95는 검출 성능 지표이며, 같은 자료와 같은 지표에서 값이 높을수록 성능이 좋다. 전체 실사 사진에서 AP50:95는 실사만 사용한 N1이 19.27%로 가장 높았고 N7은 15.77%, N5는 10.71%, N6는 1.06%였다. 합성 사진에서는 N5가 58.88%, 항공 사진에서는 N4가 19.33%로 가장 높아 모든 평가 자료에서 우세한 조합은 없었다.

표 3. N1~N7 자료 조합별 M1A1 검출 결과

Table 3. M1A1 detection results by dataset composition for N1 to N7.

조건	합성AP 50:95	항공AP 50:95	전체 실사 AP50	전체 실사 AP 50:95	FP	FPR
N1	0.002	17.378	26.400	19.265	168	34.30
N2	3.277	0.002	0.014	0.004	22	4.36
N3	55.981	0.000	0.000	0.000	1	0.00
N4	1.783	19.326	23.098	16.545	238	48.84
N5	58.879	8.478	14.667	10.712	247	46.51
N6	54.754	1.646	2.103	1.061	4	0.87
N7	57.315	16.028	21.661	15.774	235	46.22

정답 검출(TP), 오탐(FP), 미검출(FN)은 각각 찾아낸 정답, 잘못된 검출, 놓친 정답의 개수이다. 전체 실사 385장에서 N1은 각각 33개, 168개, 26개, N7은 40개, 235개, 19개였다. FPR은 M1A1이 없는 실사 사진 344장 중 오탐이 한 번 이상 발생한 사진의 비율이며 34.30%에서 46.22%로 높아졌다. 표 3에서 FP는 개수, AP와 FPR은 %이다. 합성데이터만 사용한 N2, N3의 낮은 오탐 사진 비율은 전차를 거의 검출하지 못한 결과와 함께 해석해야 한다.

그림 1은 한 사진에 있는 M1A1 전차 2대를 보여준다. N1, N4, N5, N7은 모두 정답 2개를 검출했으며 오탐과 미검출은 없었다. 그림의 GT와 녹색 박스는 정답, 주황색 박스는 모델의 검출 결과이다. 전차 주변 영역을 잘라 확대해 제시했으며 개수는 원본 사진 전체에서 집계했다.



그림 1 동일 실사진의 다중 전차 검출

Fig. 1 Multiple tank detections in one real photograph.

표 4는 전체 실사 385장 중 M1A1 전차가 포함된 이미지는 총 41장, 정답 객체 59개의 결과이다. N1에서 N7로 자료를 조합했을 때 AP50:95는 44.56%에서 53.69%,으로, 정답 검출 수는 33개에서 40개로 증가했다. 오탐도 4개에서 6개로 늘

었고 정밀도는 89.19%에서 86.96%로 낮아졌다. N5와 N6의 AP50:95는 각각 52.51%과 3.45%였다. 표 4의 정밀도 P는 검출 결과 중 정답의 비율, 재현율 R은 전체 정답 중 찾아낸 비율이며 F1은 두 지표를 함께 반영한 값이다. TP, FP, FN은 개수이고 나머지는 %이다.

이 41장에는 M1A1이 없는 사진이 없어 오탐 사진 비율을 계산하지 않았다. 항공 239장과 전차 포함 41장은 전체 실사의 일부이므로 서로 독립된 평가 결과로 합산하거나 자료 사이의 점수 차이를 모델 개선으로 해석하지 않는다.

표 4. M1A1이 포함된 실사 사진 41장의 N1 · N7 검출 결과
Table 4. N1 and N7 on the same 41 positive images.

조건	AP50	AP50:95	P	R	F1	TP	FP	FN
N1	65.996	44.563	89.19	55.93	68.75	33	4	26
N7	77.715	53.690	86.96	67.80	76.19	40	6	19

그림 2에는 M1A1 전차 1대가 있지만 N1, N4, N5, N7 모두 이를 검출하지 못했다. N4에서는 오탐 1개도 발생했으며 나머지 세 모델의 오탐은 없었다. 박스 색과 표시 방법은 그림 1과 같으며 개수는 원본 사진 전체에서 집계했다. 두 사진은 검출과 미검출을 보여주는 예시이므로 그림만으로 실패 원인을 확정할 수는 없다.

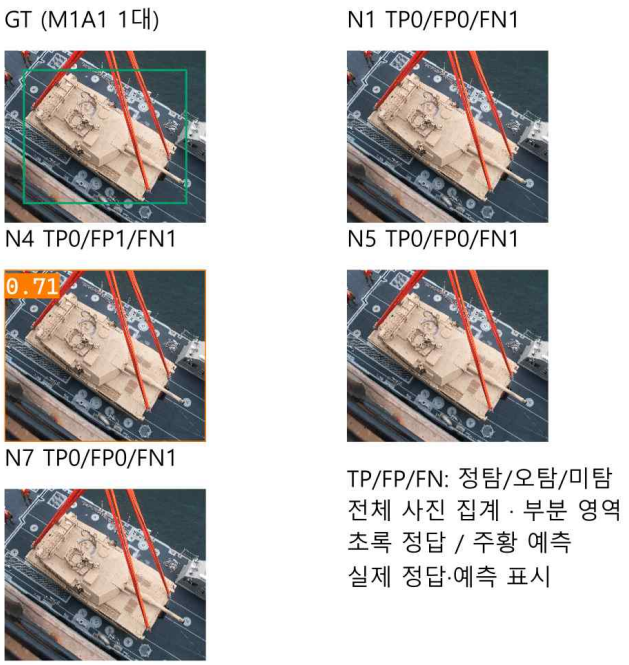


그림 2 인양띠가 겹친 실사진의 미검출
Fig. 2 Missed detection with lifting slings.

Ⅳ. 결론

실사만 사용한 N1과 R, C, D를 모두 사용한 N7을 비교한 결과, 전체 실사 385장의 AP50:95는 19.27%에서 15.77%로 3.49%p 낮아졌다. 반면 M1A1이 포함된 41장에서는 44.56%에서 53.69%로 높아졌고 재현율도 55.93%에서 67.80%로 증가했다. 정밀도는 89.19%에서 86.96%로 낮아졌으며, M1A1이 없는 사진의 오탐 발생 비율은 34.30%에서 46.22%로 높아졌다. 따라서 합성데이터 추가의 효과는 평가 자료에 따라 달랐으며 전차 검출 증가와 오탐 증가를 함께 고려해야 한다.

이번 결과는 M1A1 한 차종과 현재 평가 자료에서 관찰된 결과이다. 자료 조합 외의 실험 환경과 자료 사용 방식도 완전히 같지는 않아 성능 차이를 합성 자료의 효과만으로 단정할 수 없다. 실사 정답 객체가 59개이고 일부 자료는 기존 실험에서도 사용되었으므로 새로운 실사 사진과 반복 실험을 통해 추가로 확인할 필요가 있다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성사업임(IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] P. Zhu et al., Detection and Tracking Meet Drones Challenge, IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 44, no. 11, pp. 7380–7399, 2022.

[2] W. Hua and Q. Chen, A survey of small object detection based on deep learning in aerial images, Artificial Intelligence Review, vol. 58, article 162, 2025.

[3] G. Rizzoli et al., SynDrone – Multi-Modal UAV Dataset for Urban Scenarios, Proc. IEEE/CVF International Conference on Computer Vision Workshops (ICCVW), pp. 2210–2220, 2023.

[4] J. Tobin et al., Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World, IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017.

[5] J. Tremblay et al., Training Deep Networks With Synthetic Data: Bridging the Reality Gap by Domain Randomization, Proc. IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2018.

[6] T.-Y. Lin et al., Microsoft COCO: Common Objects in Context, Computer Vision – ECCV 2014, Lecture Notes in Computer Science, vol. 8693, pp. 740–755, 2014.

원격주행을 위한 딥러닝 기반 적응형 카메라 뷰 선택 시스템

전양호, 김영진*, 김성진**
충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 컴퓨터공학과
yhjeon@chungbuk.ac.kr, *you359@cbnu.ac.kr, **ksj@cbnu.ac.kr

A Deep Learning-based Adaptive Camera View Selection System for Teleoperated Driving

Yang Ho Jeon, Young Jin Kim*, SungJin Kim**
Department of Industrial AI, Chungbuk National Univ.,
*Industrial AI Research Center, Chungbuk National Univ.,
**School of Computer Engineering, Chungbuk National Univ

Abstract

Remote drivers watch several camera feeds in a fixed layout, although only a small share of driving situations requires attention to a particular view. This study aims to select, at each moment, the camera views a remote driver should attend to. The proposed system keeps the travel-direction view always visible and highlights zero to two auxiliary views. Because no public benchmark exists, we automatically generate pseudo labels of the views to watch from the 3D annotations, vehicle signals, and maps of the nuScenes dataset, combining each object's collision risk at its closest approach with the vehicle's upcoming maneuver. A lightweight model fuses camera features, vehicle signals, and per-camera risk from the past two seconds, and is trained with simulated detection errors, since real detectors are imperfect. In offline experiments, the pseudo labels kept 96% of hazards in view while highlighting fewer than half a view per frame on average. Under corrupted inputs, the model captured hazards as well as rule-based selection at the same display load, and agreed with human judgments 14-17 percentage points more often than a rule using the same past-only information. Robustness to camera failures and validation with real operators remain future work.

Key words : Teleoperated driving, Adaptive camera view selection, Pseudo label, Multimodal fusion, Robustness

Ⅰ. 서 론

현존하는 어떤 자율주행차도 모든 조건과 환경에서 운행하지는 못하며, 자율주행차가 모든 도로 상황을 스스로 해결할 수는 없다[1,2]. 이 공백을 이 공백을 원격지의 사람이 메우는 것이 원격 운행이고, 그중 원격 운전은 자율주행 상용화에 필수적인 요소로 꼽힌다[3]. 원격 운행은 오퍼레이터가 차량을 직접 조종하는 원격 운전과 경로 · 판단만 돕는 원격 지원으로 나뉘며, 본 논문의 원격주행은 전자를 뜻한다[4].

원격 운전의 어려움은 대부분 오퍼레이터가 차량과 물리적으로 떨어져 있다는 데서 오고, 낮은 상황인식이 핵심 난제로 꼽힌다[2,3]. 원격 오퍼레이터의 상황인식은 주로 카메라 영상을 보는 것으로 형성되는데, 영상을 더 보여 준다고 나아지지는 않는다[5]. 전방 영상에 버드아이 뷰를 더해도 원격 운전자의 상황인식은 향상되지 않았고 일부 중요한 요소는 오히려 알아차리기 어려워졌다[6]. 반면 표현을 상황에 맞추면 효과가 있었다. 카메라 시점만 바꿔도 과업 시간과 정신적 부담이 줄었고, 원격 운전 단계에 따라 표시 요소를 바꾸는 동적 GUI는 고정 GUI보다 사용성과 과업 시간에서 우수했으며, 위험 객체를 영상 위에 표시하면 위험 지각이 쉬워졌다[5,7,8].

문제는 언제 무엇을 강조할지가 자명하지 않다는 것이다. 본 연구의 측정에서 실제 위험은 전체 프레임의 13.2%에서만 나타나며, 항상 한 화면을 강조하면 정밀도가 4.7%에 그친다. 기존 적응형 연구는 뷰별 전송 품질이나 GUI 정보 요소의 수를 조정했을 뿐 어느 카메라를 강조할지를 학습 문제로 다루지 않았고, 이를 위한 공개 벤치마크도 없다.[5,9]

본 논문은 진행 방향 화면을 항상 표시한 채 나머지 5개 중 0~2개를 보조 뷰로 강조하는 적응형 뷰 선택 시스템을 제안한다. 기여는 공개 데이터셋 nuScenes[10]의 3D 정답 박스 · CAN · 지도로 '봐야 할 화면' 의사 라벨을 자동생성하는 방법, 영상 · CAN · 위험도를 융합하고 검출 오류로 증강 학습한 경량 모델, 같은 표시량 비교와 사람이 판정한 골드셋을 포함한 오프라인 검증이다. 6개 화면을 모두 유지하고 선택한 화면만 강조하는 하이라이트 방식을 전제로 한다.

Ⅱ. 본론

2.1 의사 라벨 생성

각 keyframe(2 Hz)에서 차량 · 보행자 정답 박스를 카메라에 투영해 보이는 채널에 배정하고, 객체마다 최접근 시각 t*와 최접근 거리 DCA로 정의한 TTC를 구해 위험 가중치를 식 (1)로 계산한다.

$$w = \rho_{※r} \cdot \rho_{path}(DCA) \cdot \max(\exp(-TTC/\tau), w_{\neq ar}) \quad (1)$$

반경 방향 TTC는 옆으로 스쳐 갈 주차 차량을 충돌 임박으로 오판해 위험량의 62.9%가 정지 · 주차 객체에서 나왔으므로 최접근 기하를 쓴다. 채널 위험도 risk(c)는 w의 합을 지수이동평균으로 평활한 값이고, 기동(직진, 회전, 차선변경, 후진, 정지)은 지도의 차로 · 교차로 정보와 [−1, +5]초 궤적으로 판정한다. 보조 뷰는 역할을 나눈 슬롯으로 고른다. 슬롯 1은 기동이 만드는 사각지대(예: 차선변경 시 후측방)로 검출과 무관하게 켜고, 나머지는 risk(c) ≥ 0.12인 채널을 위험 순으로 채운다.

실제 위험은 TTC < 5 s이면서 DCA < 3 m인 객체로 정의하며, 5초는 원격주행의 지연과 인지 · 조작 시간을 고려한 값이다[11]. 34,149장의 라벨은 평균 0.47장을 켜서 실제 위험의 96.3%를 화면에 담는다(정밀도 10.6%). 라벨은 사람 검수 2회(무작위 20장, 표적 16장)를 통과했고, 라벨 판정에 쓰지 않은 방향지시등과의 같은 방향 일치율은 좌회전 73.9%, 우회전 67.2%였다. 사람이 판정한 골드셋과는 Top-1 73.3%, Top-2 88.9% 일치했다.

2.2 융합 모델과 학습

모델은 과거 4keyframe(약 2초)만 본다. 화면별 MobileNetV3-small[12] 특징(576차원)에 카메라 위치 임베딩과 위험도를 더해 채널 토큰 6개를, CAN 신호(속도, 조향, 가속도, 회전율, 방향지시등)로 토큰 1개를 만들고, 2층 Transformer로 화면 간 정보를 섞은 뒤 채널별 GRU로 시간축을 처리한다(그림 1). 출력은 화면별 독립 시그모이드로 0~2장을 표현하며, 손실은 포컬 BCE, soft label KL, 레이아웃 CE, 시간 일관성 항의 합이다. 실제 검출은 불완전하므로 모델 입력의 위험도에는 누락, 오검출, 위치 오차, 카메라 고장을 주입하고, 학습에서도 에폭마다 다른 오류를 주입한다.

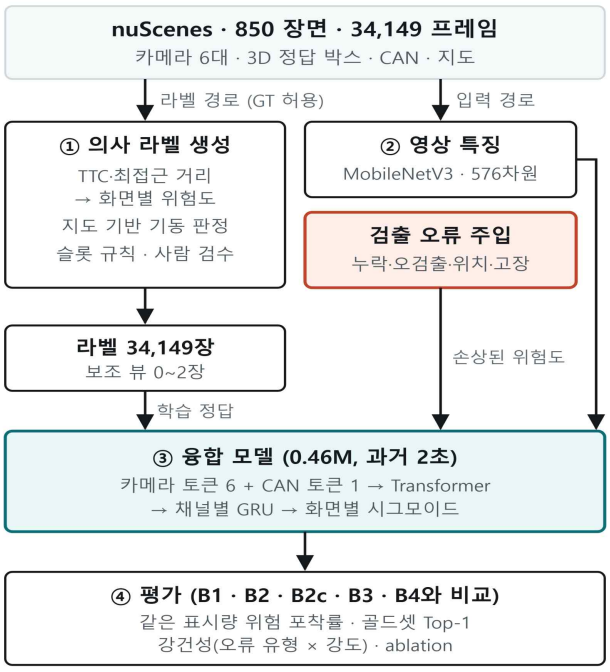


그림 1 제안 시스템의 구조
Fig. 1 Overview of the proposed system

2.3 실험 구성

데이터는 장면 단위로 나눠 학습 595개, 검증 128개, 시험 127개 장면(각 23,898장, 5,143장, 5,108장)을 썼다. 비교 방법은 목적에 따라 세 가지다. 첫째, 현행 방식은 진행 방향 화면만 표시하고 보조 뷰를 켜지 않는다. 이 방식에서도 위험의 59.0%는 진행 방향 화면에 들어오므로, 나머지 위험을 보조 뷰가 얼마나 담는지가 비교의 출발점이다. 현행 방식은 보조 뷰가 없어 골드셋 지표를 계산할 수 없으므로 표 2에서는 제외했다. 둘째, 규칙 기반 방법은 의사 라벨을 만든 뷰 선택 규칙을 손상된 위험도 입력에 그대로 적용한다. 미래 5초 궤적으로 판정한 기동을 쓰는 규칙은 실제 운용에서 알 수 없는 정보를 쓰므로 상한으로 두고, 제안 모델처럼 과거 2초 궤적으로 기동을 추정하는 규칙을 같은 정보 조건의 주 비교 대상으로 삼는다. 셋째, 입력 축소 모델은 제안 모델에서 CAN과 위험도를 빼고 영상만 쓰는 모델과, 시간 모델 없이 현재 프레임만 보는 모델이다. 이 둘로 다중 신호 융합과 시간 모델의 효과를 확인한다. 규칙을 그대로 쓰면 의사 라벨 기준으로는 정의상 고득점이 나오므로, 정답 박스 기하로 직접 계산한 위험 포착률을 같은 표시량(0.48장)에서 비교하고, 시험 분할에서 층화 추출한 골드셋 300장을 연구자가 직접 판정한다(그림 2). 판정을 마친 285장 중 강조할 화면이 있다고 판정한 장면은 90장이다.

표 1 실험 환경
Table 1 Experimental setup

항목	내용
데이터	nuScenes v1.0-trainval, 34,149 keyframe, 장면 단위 분할 595/128/127
입력	과거 4 keyframe: 영상 특징 6×576, CAN 8, 화면별 위험도 6
모델	Transformer 2층(d=128) + 채널별 GRU, 0.46M 파라미터
학습	AdamW 0.0001, 배치 16, 최대 100 에폭(조기 종료 10), 검출 오류 증강 clean · light · medium · heavy
환경	RTX 5060 Ti 16GB, PyTorch 2.14.0, seed 42

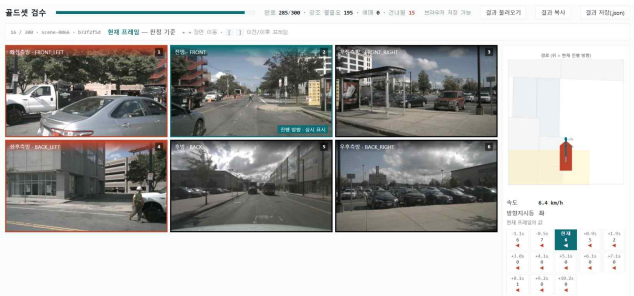


그림 2. 골드셋 검수 화면
Fig. 2 Gold-set annotation interface

2.4 실험 결과

표 2 실험 결과
Table 2 Comparison on the test split

방법	골드 Top-1	포착률*	Flicker*
규칙(미래 기동, 상한)	73.3%	94.3%	0.54
규칙(과거 정보만)	51.1%	96.0%	0.53
영상만 쓰는 모델	54.4%	72.9%	0.61
단일 프레임 모델	68.9%	90.1%	0.77
제안 모델	**63.3%**	**93.8%**	**0.52**

같은 표시량(0.48장)에서 보간한 값. 골드 Top-1은 정답이 있는 90장 기준

제안 모델은 같은 표시량에서 위험의 93.8%를 포착해 두 규칙(94.3~96.0%)과 대등했고, 1.5초 안에 강조가 다시 바뀌는 비율(Flicker)은 0.52로 가장 낮았다(표 2). 골드셋 Top-1은 63.3%로 과거 정보만 쓰는 규칙(51.1%)보다 높았고(짝비교 22:11, McNemar $p = 0.080$), 미래 기동을 아는 규칙(73.3%)과는 유의한 차이가 없었다. 영상만 쓰는 모델의 포착률은 72.9%로 크게 낮았고, 구성 요소를 하나씩 뺀 실험에서도 위험도 입력을 빼면 포착률이 20.0%p, GRU를 빼면 3.8%p 낮아지고 Flicker가 0.76으로 커져, 위험도와 시간 모델이 위험 포착과 안정성의 핵심임을 확인했다.

누락, 오검출, 위치 오차, 카메라 고장을 heavy 강도로 주입한 강건성 실험에서, clean과 네 손상 조건 모두 제안 모델의 골드셋 Top-1이 과거 정보만 쓰는 규칙보다 14.416.7%p 높았고(그림 3) 위험 포착률 차이는 −2.6−0.2%p로 대등했다. 손상에 따른 Top-1 하락 폭은 모델 −3.3~+1.1%p, 규칙 −5.6~+0.0%p로 차이가 없어, 학습 모델의 이점은 열화 기울기가 아니라 과거 정보만으로 진행 의도를 읽는 데서 오는 수준 차이로 해석된다. 위험도 입력을 뺀 모델의 Top-1이 74.4%로 가

장 높았는데, 이는 사람이 위험 객체보다 진행 의도를 기준으로 화면을 고른다는 점을 시사한다. 카메라 3대 고장에는 모든 방법의 포착률이 17%p 이상 떨어졌다.

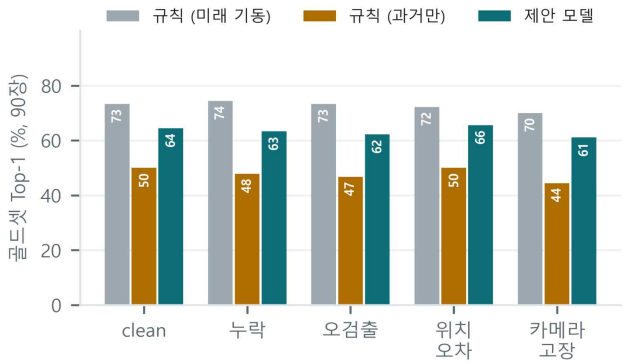


그림 3 손상 조건별 골드셋 Top-1
Fig. 3 Gold-set Top-1 under heavy input corruptions

2.5 해석 및 한계

연구자는 판정한 285장 중 195장을 '강조 불필요'로 보았는데, 의사 라벨은 그중 54%에서 화면을 켰다. 위험 객체의 상당수가 상시 표시되는 전방 화면에 있어 측방 강조가 필요 없다고 본 것으로, TTC · DCA 기반 위험 정의가 사람의 주의 기준보다 넓다. 차선변경은 학습 데이터의 0.8%(258프레임)에 불과해 모델이 충분히 배우지 못했고, 후진은 전체 8프레임이 모두 학습 분할에 있어 평가하지 못했다. 모든 결과는 오프라인 검증이며 실제 오퍼레이터의 주의 배분 효과는 측정하지 않았다.

Ⅲ. 결론

본 논문은 진행 방향을 유지한 채 보조 뷰 0~2장을 고르는 적응형 뷰 선택 시스템과 공개 데이터 기반 의사 라벨 생성 방법을 제안했다. 의사 라벨은 항상 1장을 강조하는 방식보다 53% 적게 켜면서 위험을 더 많이 담았고, 학습 모델은 손상 입력 전반에서 규칙과 대등한 위험 포착률을 내면서 과거 정보만 쓰는 규칙보다 사람 판정과 일관되게 더 잘 일치했다. 향후 첫째, 사람이 실제로 주의를 두는 기준(진행 의도, 잠재 위험)을 라벨에 반영하고, 둘째, 카메라 고장 같은 채널 결손에 대응하는 학습을 보강하며, 셋째, 실제 오퍼레이터 평가로 주의 배분 효과를 검증할 계획이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] N. Goodall, "Non-Technological Challenges for the Remote Operation of Automated Vehicles," Transportation Research Part A: Policy and Practice, vol. 142, pp. 14-26, 2020.

[2] F. Tener and J. Lanir, "Driving from a Distance: Challenges and Guidelines for Autonomous Vehicle Teleoperation Interfaces," Proc. CHI ' 22, 2022.

[3] L. Zhao et al., "Remote Driving of Road Vehicles: A Survey of Driving Feedback, Latency, Support Control, and Real Applications," IEEE Trans. Intelligent Vehicles, vol. 9, no. 10, pp. 6086-6107, 2024.

[4] D. Majstorović, S. Hoffmann, F. Pfab, A. Schimpe, M.-M. Wolf, and F. Diermeyer, "Survey on Teleoperation Concepts for Automated Vehicles," Proc. IEEE SMC, pp. 1290-1296, 2022.

[5] M.-M. Wolf, H. Schmidt, M. Christl, J. Fank, and F. Diermeyer, "A User-Centered Teleoperation GUI for Automated Vehicles," Multimodal Technologies and Interaction, vol. 9, no. 8, 78, 2025.

[6] A. Boker and J. Lanir, "Bird's Eye View Effect on Situational Awareness in Remote Driving," Adjunct Proc. AutomotiveUI ' 23, pp. 36-41, 2023.

[7] O. Musicant, A. Botzer, and B. Richmond-Hacham, "Safety, Efficiency, and Mental Workload in Simulated Teledriving of a Vehicle as Functions of Camera Viewpoint," Sensors, vol. 24, no. 18, 6134, 2024.

[8] S. P. Srinivasan, P. Tribulowski, and A. Lindner, "Evaluation of Different HMIs to Improve Operator Hazard Perception and User Experience in Teleoperation of Automated Shuttles," Advances in Human Factors of Transportation (AHFE 2024), pp. 161-171, 2024.

[9] M. Hofbauer, C. B. Kuhn, M. Khlifi, G. Petrovic, and E. Steinbach, "Traffic-Aware Multi-View Video Stream Adaptation for Teleoperated Driving," Proc. IEEE VTC2022-Spring, 2022.

[10] H. Caesar et al., "nuScenes: A Multimodal Dataset for Autonomous Driving," Proc. CVPR, 2020.

[11] S. Neumeier et al., "Teleoperation: The Holy Grail to Solve Problems of Automated Driving? Sure, but Latency Matters," Proc. AutomotiveUI ' 19, 2019.

[12] A. Howard et al., "Searching for MobileNetV3," Proc. ICCV, 2019.

근대 국어 문서 해석을 위한 OCR 인식 방식 개선 연구

이동채, 김영진*, 문성태**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 지능로봇공학과

dennis98lee@chungbuk.ac.kr, *kimyou35971@gmail.com, **stmoon@chungbuk.ac.kr

Improving OCR for Modern Korean Handwritten Documents Using GAN-based Data Augmentation

DongChae Lee, YoungJin Kim*, SeongTae Moon**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

This study applies GAN-based data augmentation to improve OCR performance for modern Korean handwritten documents. The generated character images were used to train PaddleOCR, EasyOCR, and KR-TrOCR. Experimental results showed that all models improved, with KR-TrOCR achieving the largest performance gain and the highest final recognition accuracy.

Key words : GAN, Data Augmentation, Handwritten OCR, PaddleOCR, EasyOCR, KR-TrOCR, Modern Korean Documents

Ⅰ. 서 론

본 논문에서는 근대 국어 손글씨 문서의 OCR 인식 성능을 향상시키기 위해 GAN 기반 데이터 증강 기법을 적용하고, 이를 통해 생성된 학습 데이터셋을 PaddleOCR, EasyOCR, KR-TrOCR 모델에 각각 적용하여 성능 변화를 비교하고자 한다. 디지털 아카이빙과 문서 자동화 기술의 발전에 따라 광학문자인식(OCR) 기술의 활용 범위는 지속적으로 확대되고 있으나, 일반 OCR 기술은 비교적 정형화된 인쇄체 문서나 일정한 문자 형태를 대상으로 높은 성능을 보이는 반면, 근대 국어 손글씨 문서와 같이 필체의 다양성, 흘림체, 불규칙한 글자 형태가 혼재하는 경우에는 인식 성능이 크게 저하될 수 있다. 또한 근대 국어 손글씨 자료는 학습에 활용할 수 있는 데이터의 양이 제한적이기 때문에, 기존 OCR 모델만을 적용하는 방식으로는 다양한 필체와 변형된 글자 형태를 충분히 학습하기 어렵다. 특히 딥러닝 기반 OCR 모델은 충분한 학습 데이터의 확보 여부가 성능에 직접적인 영향을 미치므로, 실제 근대 손글씨 자료가 부족한 환경에서는 모델의 일반화 성능과 인식률 향상에 한계가 존재한다.[1]

이러한 문제를 해결하기 위해 본 연구에서는 생성적 적대 신경망(GAN)을 활용하여 기존 손글씨 데이터의 특징을 학습하고, 이를 기반으로 새로운 손글씨 이미지를 생성하여 학습 데이터셋을 확장하였다.[2][3] GAN 기반 데이터 증강은 실제 데이터의 부족을 보완하면서도 기존 손글씨의 형태적 특성을 반영한 추가 학습 데이터를 확보할 수 있다는 점에서 일반적인 OCR 적용 방식과 차별성을 가진다. 생성된 데이터셋은 서로 다른 구조와 특성을 갖는 PaddleOCR, EasyOCR, KR-TrOCR에 동일하게 적용하였으며, 학습 전후의 문자 인식 성능을 비교하여 데이터 증강의 효과를 분석하였다. 이를 통해 단순한 OCR 모델 적용을 넘어, 근대 국어 손글씨에 적합한 학습 데이터 확보가 인식 성능 향상에 필수적인 요소임을 확인하고, 각 OCR 모델 가운데 증강 데이터 학습을 통해 가장 큰 성능 개선을 보이는 모델을 비교 · 분석하는 것을 본 연구의 목적으로 한다.

Ⅱ. 본론

본 연구에서는 근대 국어 문서에서 글자 영역을 수작업으로 분리하고, 각 글자 이미지에 해당 문자의 라벨을 부여하여 학습용 데이터셋을 구성하였다. 근대 국어 문서는 필체와 글자 형태가 일정하지 않기 때문에, 문서 전체를 그대로 사용하는 것보다 글자 단위로 데이터를 분리하여 학습에 활용하는 방식이 적합하다.[1]

분리된 글자 이미지는 학습 과정에서 입력 크기를 통일하기 위해 64×64 픽셀 크기로 정규화하였다. 각 글자는 해당 문자별 폴더에 저장하였으며, 예를 들어 '가'에 해당하는 이미지는 '가' 폴더 내부에 001, 002와 같은 순번 형태의 파일명으로 저장하여 문자별 데이터셋을 구성하였다.

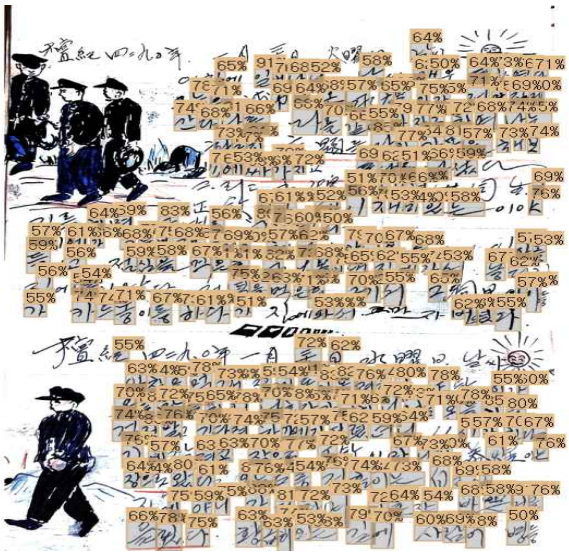


그림 1 DataSet 1차 생성 방식
Fig. 1 First DataSet Creation Method

분리 및 정규화된 글자 이미지는 별도의 추가 전처리 없이 GAN 학습에 그대로 사용하였다. 앞서 구성한 글자 단위 데이터셋을 기반으로 일반 GAN 모델을 학습하였으며, GAN은 생성자(Generator)와 판별자(Discriminator)로 구성된다. 생성자는 새로운 글자 이미지를 생성하고, 판별자는 해당 이미지가 실제 데이터인지 생성된 데이터인지 구분한다. 두 모델은 반복적으로 경쟁 학습을 수행하며, 이 과정을 통해 생성자는 원본 손글씨의 형태적 특징과 유사한 새로운 글자 이미지를 생성하도록 개선된다.

학습된 GAN은 기존 글자의 형태적 특징을 바탕으로 새로운 한 글자 단위 이미지를 생성하며, 생성된 이미지는 해당 문자 라벨에 맞는 폴더에 추가하여 기존 데이터셋과 결합하였다. 이를 통해 제한된 원본 데이터의 양을 확장하고, 이후 OCR 모델의 추가 학습에 활용할 수 있는 증강 데이터셋을 구축하였다[3].

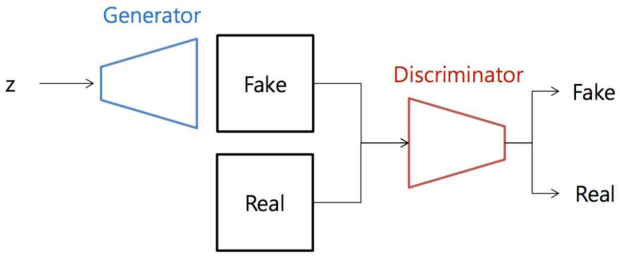


그림 2 GAN모델 작동 방식
Fig. 2 How GAN Models Work

GAN을 통해 생성된 글자 단위 이미지는 OCR 모델의 추가 학습 데이터로 활용하였다. OCR은 입력 이미지에서 문자 영역을 검출하고, 검출된 영역의 문자를 인식하여 텍스트로 변환하는 과정을 수행한다.

본 연구에서는 GAN으로 생성한 글자 이미지와 기존 원본 데이터를 함께 구성하여 PaddleOCR, EasyOCR, KR-TrOCR에 동일하게 적용하였다. 이를 통해 각 모델이 추가된 손글씨 데이터를 학습한 이후 인식 성능이 어떻게 변화하는지 비교할 수 있도록 하였다.

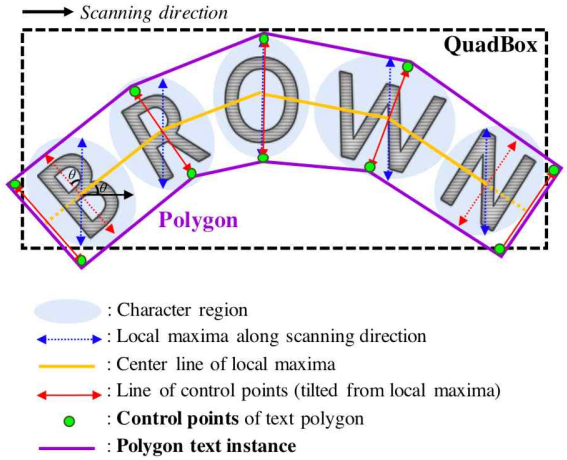


그림 3 OCR 작동 방식
Fig. 3 How OCR Models Work

앞서 구축한 GAN 기반 증강 데이터셋을 PaddleOCR, EasyOCR, KR-TrOCR에 동일하게 적용하여 추가 학습을 진행하였다. 세 모델은 서로 다른 구조와 인식 방식을 사용하지만, 동일한 학습 데이터를 적용함으로써 데이터 증강에 따른 성능 향상 정도를 비교할 수 있도록 구성하였다. 각 모델에 대해 추가 학습 전의 인식 성능을 기준으로 설정하고, GAN으로 생성한 데이터를 학습한 이후의 인식 성능을 다시 측정하였다. 이후 학습 전·후의 인식률 변화와 최종 인식 성능을 비교하여 각 OCR 모델이 증강 데이터에 얼마나 효과적으로 반응하는지 분석하였다[4, 5].

GAN 기반 증강 데이터셋을 적용한 이후 세 OCR 모델의 인식 성능을 비교하였다. 실험 결과 PaddleOCR, EasyOCR, KR-TrOCR 모두 학습 전보다 인식 성능이 향상되었으며, 데이터 증강이 근대 국어 손글씨 인식에 긍정적인 영향을 주는 것을 확인하였다.

특히 KR-TrOCR은 세 모델 중 가장 큰 인식률 향상 폭을 보였으며, 추가 학습 이후 최종 인식률 또한 가장 높게 나타났다. 이는 GAN으로 생성한 글자 단위 데이터가 Transformer 기반의 문자 인식 과정에서 효과적으로 활용되었기 때문으로 판단할 수 있다.[4] 반면 PaddleOCR과 EasyOCR 역시 성능 향상은 나타났지만, KR-TrOCR에 비해서는 상대적으로 낮은 증가폭을 보였다.

표 1 실험 결과
Table 1 Experimental results

모델	학습 전	학습 후	학습 폭
Paddle	71.2%	78.6%	+7.4%p
EASY	68.5%	76.9%	+8.4%p
KR-TrOCR	73.8%	86.7%	+12.9%

Ⅲ. 결론

본 논문에서는 근대 국어 손글씨 문서의 부족한 학습 데이터를 보완하기 위해 GAN을 활용하여 글자 단위 데이터를 생성하고, 생성된 데이터셋을 PaddleOCR, EasyOCR, KR-TrOCR에 적용하여 인식 성능의 변화를 비교하였다. 실험 결과 세 모델 모두 추가 학습 이후 인식률이 향상되었으며, 특히 KR-TrOCR은 73.8%에서 86.7%로 증가하여 가장 큰 성능 향상 폭과 가장 높은 최종 인식률을 나타냈다.

이러한 결과를 통해 GAN 기반 데이터 증강이 근대 국어 손글씨 OCR의 학습 데이터 부족 문제를 보완하고 인식 성능을 향상시키는 데 효과적으로 활용될 수 있음을 확인하였다.[1] [5] 향후에는 실제 근대 국어 손글

씨 데이터를 추가로 확보하고 GAN의 생성 품질을 개선하여, 보다 다양한 필체와 문서 유형을 대상으로 인식 성능과 일반화 가능성을 검증할 필요가 있다. 또한 차세대 생성 모델인 Diffusion 기반 이미지 생성 기법을 적용하여 기존 GAN과의 데이터 생성 품질 및 OCR 성능 향상 효과를 비교하고, 생성 데이터의 다양성 · 안정성 · 학습 기여도를 정량적으로 검증할 예정이다. 이를 바탕으로 KR-TrOCR을 포함한 다양한 OCR 모델에 대해 동일한 조건의 비교 실험을 수행하여 근대 국어 손글씨 인식에 가장 적합한 데이터 증강 및 학습 방식을 도출하고자 한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] 이종원, 신준혁, & 김해동. (2023). K-TrOCR: 한국어 가변 특성을 고려한 트랜스포머 기반의 엔드투엔드 손글씨 인식 모델. 정보처리학회 논문지. 소프트웨어 및 데이터 공학, 12(11), 485-492.

[2] 백진성, 서지윤, 정상중, 정도운. (2022). "지능형 OCR 시스템을 위한 한글 필기체 생성 및 분류 모델에 관한 연구". 융합신호처리학회논문지, 23(4), 222-227.

[3] 김민규, 임형택, 이계식. (2022). PaperCleaner, GAN 알고리즘을 활용한 한글 문서 자동 복원 프로그램. *한국지식정보기술학회 논문지*, 17(6), 1331-1339.

[4] 이혁. (2026). 저화질 한글 공공 문서 OCR을 위한 TrOCR 기반 텍스트 인식 모델 성능 평가. *한국정보전자통신기술학회 논문지*, 19(2), 279-291.

[5] 박시은, 안진현. (2026). 한국어 손글씨 인식을 위한 TrOCR 모델 미세조정. *2026년도 한국통신학회 동계종합학술발표회 논문집*.

계층 청킹과 리랭킹 컷오프를 적용한 사내 기술문서 검색 시스템

이한울, 채민선*, 전명근**
충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 지능로봇공학과
nhyui0326@chungbuk.ac.kr, *mschae@chungbuk.ac.kr, **mgchun@chungbuk.ac.kr

An In-House Technical Document Search System with Hierarchical Chunking and Re-ranking Cutoff

Han Wool Lee, Min-Seon Chae*, Myung-Geun Chun**
Department of Industrial AI, Chungbuk National Univ.,
*Industrial AI Research Center, Chungbuk National Univ.,
**Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

Shared folders in companies accumulate heterogeneous technical documents, yet a naive retrieval-augmented generation (RAG) system with fixed-size chunks and vector-only search splits tables and sentences, misses exact terms and answers without evidence. This paper designs and implements a hybrid RAG pipeline for in-house technical document search. The pipeline parses each file format with a dedicated parser assisted by a vision language model, separates the retrieval unit (350-character child chunks) from the answer unit (2,500-character parent chunks), tags every chunk with its folder path and file name, and combines dense vector search with morpheme-based full-text search. A cross-encoder re-ranker with a score cutoff filters out low-relevance chunks before they reach the language model. Three systems were rebuilt from one shared parsing result over 1,424 documents and evaluated on 300 in-house and 49 out-of-domain (OOD) questions. Compared with the fixed-chunk baseline, the proposed pipeline raised answer accuracy from 0.419 to 0.660 (95% CI of the difference: +0.176 to +0.307), page-level HitRate@5 from 0.340 to 0.453 and the hallucination blocking rate from 0.878 to 0.939, while lowering the false refusal rate from 0.417 to 0.180. Additional experiments showed that late chunking reduced accuracy with a decoder-based embedding model, while with jina-embeddings-v3, an encoder that supports late chunking, the drop was not significant and gains on context-dependent questions were offset by losses on questions about similar documents.

Key words : Retrieval-Augmented Generation, Hybrid Search, Hierarchical Chunking, Re-ranking, Document Parsing

Ⅰ. 서 론

기업의 공유 폴더에는 PDF, HWP, Word, Excel, PowerPoint 등 서로 다른 포맷의 기술문서가 누적되지만, 필요한 수치나 규정, 절차를 찾으려면 사용자가 파일을 하나씩 열어 보아야 한다. 대규모 언어 모델(LLM)은 자연어 질문에 유창하게 답하지만 사내 문서를 학습하지 않았으므로 근거 없이 그럴듯한 답을 만드는 환각(hallucination)이 발생한다[1]. Lewis 등[2]이 제안한 검색 증강 생성(Retrieval-Augmented Generation, RAG)은 질문과 관련된 문서를 먼저 검색해 LLM에 근거로 제공함으로써 이 문제를 완화한다. 그러나 문서를 고정 길이로 자르고 벡터 유사도로만 검색하는 기본 RAG는 문장과 표가 청크 경계에서 끊기고, 고유명사 · 연도 · 코드처럼 정확히 일치해야 하는 용어를 놓치며, 관련 문서가 없어도 답변을 생성한다.

본 논문은 사내 기술문서 검색을 위한 하이브리드 RAG 파이프라인을 설계하고 구현한다. 제안 파이프라인은 포맷별 파서와 시각 언어 모델(VLM)로 이기종 문서의 텍스트를 추출하고, 작은 자식 청크로 검색한 뒤 큰 부모 청크로 답변하도록 검색 단위와 답변 단위를 분리한다. 검색 단계에서는 의미 기반 벡터 검색과 형태소 기반 전문 검색(full-text search)을 결합한 하이브리드 검색을 수행하고, 교차 인코더(cross-encoder) 리랭킹과 점수 컷오프로 관련성이 낮은 청크를 걸러 낸 뒤 LLM에 전달한다. 구현한 파이프라인은 Open WebUI 기반 사내 서비스로 운영되며, 색인부터 답변 생성까지 모든 처리가 사내 서버 안에서 이루어진다. 동일한 파싱 결과로 재구축한 기본 RAG 및 초기 구현과 비교해 응답 정확도, 검색 정밀도, 환각 차단률의 개선을 정량적으로 검증하였다.

연구 범위는 사내 공유 폴더 가운데 2026년 정부지원사업 폴더의 문서 1,424건과, 이를 대상으로 작성한 질문 349건으로 한정한다. 대상 문서는 대부분 대외비이므로 공개 벤치마크를 통한 비교는 범위에서 제외하고, 같은 문서와 질문에서 설계 단계가 다른 세 시스템을 비교하는 방식으로 개선 효과를 측정한다. 세 시스템은 같은 파싱 결과를 쓰므로 VLM 보정 자체의 효과는 측정 대상에서 제외한다.

Ⅱ. 본론

1. 관련 연구

RAG[2]는 검색기(retriever)가 찾은 문서를 생성 모델의 입력에 함께 넣어 답변을 생성하는 구조로, 모델을 다시 학습하지 않고도 지식을 갱신하고 근거 문서를 제시할 수 있다. 검색기는 크게 두 계열로 나뉜다. Karpukhin 등[3]의 밀집 검색(DPR)은 질문과 문서를 같은 벡터 공간에 임베딩해 의미 유사도로 찾고, BM25[4]로 대표되는 희소 검색은 용어의 출현 빈도로 정확한 단어 일치를 찾는다. Chen 등[5]은 하나의 다국어 모델(M3)로 밀집 · 희소 · 다중 벡터 검색을 함께 지원하고, 여러 방식을 결합할 때 단일 방식보다 검색 성능이 높아짐을 보였다.

청킹 측면에서 RAPTOR[6]는 청크를 재귀적으로 군집 · 요약해 트리 구조로 색인함으로써 긴 문서의 상위 문맥을 검색에 반영하고, Günther 등[7]의 후기 청킹은 문서 전체를 먼저 인코딩한 뒤 토큰 임베딩을 청크 구간

별로 풀링해 청크 벡터에 주변 문맥을 담는다. 대규모 벡터 검색에는 계층적 근접 그래프인 HNSW[8]가 널리 쓰인다.

앞선 연구들은 검색기, 청킹, 색인 기법을 각각 공개 데이터셋에서 평가하였다. 반면 사내 문서 검색에서는 HWP와 스캔본 같은 국내 문서 포맷, 연도만 다르고 양식이 같은 문서, 대외비로 인한 외부 서비스 사용 제한이 함께 나타난다. 본 연구는 이 조건에서 파싱부터 답변 생성까지를 하나의 파이프라인으로 구성하고, 기법을 단계적으로 더한 세 시스템을 같은 문서 집합에서 비교한다는 점에서 기존 연구와 다르다.

2. 제안하는 시스템

본 연구는 사내 문서 검색의 문제를 ① 청크 크기 트레이드오프, ② 청크 절단에 따른 문맥 소실, ③ 양식이 같은 유사 문서 간 출처 혼동, ④ 고유명사 · 연도 · 코드 질의 취약, ⑤ 그림 · 표 · 스캔본의 색인 누락, ⑥ 근거 없는 답변 생성의 여섯 가지로 정의하고, 각 문제에 대응하는 기법을 파이프라인의 블록으로 배치한다.

제안 시스템의 구성은 그림 1과 같다. 사용자는 웹 브라우저의 Open WebUI에서 질문하고, 질의응답 파이프라인(Pipelines)이 질문 재작성, 하이브리드 검색, 리랭킹 · 컷오프, 답변 생성을 차례로 수행해 답변과 출처를 돌려준다. 부모 · 자식 청크와 벡터 · 형태소 색인, 파일 적재 상태와 대화 기록은 PostgreSQL(pgvector) 하나에 저장하고, 임베딩 · 리랭킹 · 답변 생성 모델은 LiteLLM 게이트웨이를 통해 호출한다. 문서 색인 배치는 공유 폴더의 문서가 추가되거나 수정될 때 동작해 텍스트를 추출하고, 청크로 나누어 벡터와 형태소 색인어로 저장한다. 각 단계의 세부 모듈은 다음과 같다.

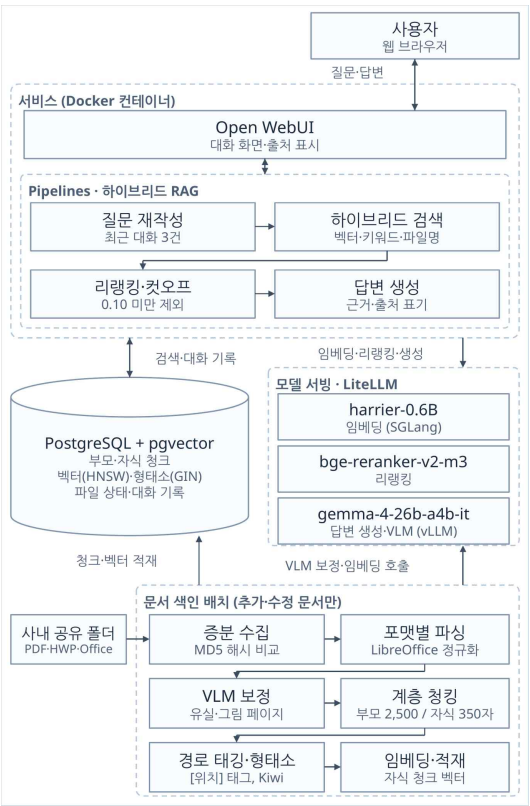


그림 1 제안 시스템 구성도
Fig. 1 System configuration of the proposed pipeline

(1) 증분 수집: 수집기는 공유 폴더의 파일을 수정 시각과 크기로 먼저 비교하고, 내용의 MD5 해시가 같으면 경로가 달라도 다시 적재하지 않는다. 적재 상태는 처리 중 · 완료 · 실패로 기록하며, 실패한 파일은 다음 실행에서 재시도한다.

(2) 포맷별 파싱과 VLM 보정: 파서는 확장자에 따라 분기한다. PDF는 pdfplumber[9]로, DOCX · PPTX · XLSX는 MarkItDown[10]과 포맷 전용 라이브러리로 본문과 표를 추출하며, HWP · DOC · PPT · XLS 같은 구형 포맷은 LibreOffice로 최신 포맷으로 변환한 뒤 같은 경로로 처리한다. 페이지마다 글리프 수 대비 추출 글자 수, 표 구조 대비 텍스트 양을 검사해 텍스트가 오류 없이 사라진 페이지를 찾고, 이 페이지와 그림 · 스캔 페이지는 이미지로 렌더링해 시각 언어 모델[11]이 원문과 대조한 설명 텍스트를 생성한다(문제 ⑤).

(3) 계층 청킹: 추출된 텍스트를 문장 단위로 분해한 뒤 약 2,500자의 부모 청크를 만들고(인접 부모 간 500자 중첩), 각 부모 안에서 문장 경계를 따라 약 350자의 자식 청크를 만든다. 검색은 자식 청크로 수행하고 LLM에는 자식이 속한 부모 청크를 전달하므로, 정밀한 검색과 충분한 답변 문맥을 함께 얻는다(문제 ①). 부모 청크는 걸쳐 있는 페이지 번호를 함께 저장해 출처 표기에 사용한다.

(4) 경로 태깅과 형태소 추출: 모든 자식 청크의 앞에 「[위치: 상위 폴더 > 파일명]」 태그를 붙여 키워드 색인과 리랭커 입력에 반영함으로써, 연도만 다르고 양식이 같은 문서를 구분한다(문제 ③). 임베딩에는 태그를 뺀 본문만 넣어 의미 벡터가 태그에 치우치지 않게 한다. 또한 한국어 형태소 분석기 Kiwi[12]로 일반 명사, 고유 명사, 외국어, 숫자 토큰만 추출해 전문 검색용 색인어로 저장한다(문제 ④).

(5) 임베딩 · 색인: 자식 청크는 1,024차원 임베딩 모델로 벡터화해 PostgreSQL pgvector의 HNSW 인덱스[8]에, 형태소 색인어는 tsvector GIN 역색인에 저장한다. 하나의 데이터베이스가 의미 검색과 키워드 검색을 모두 처리하므로 별도의 검색 엔진이 필요 없다. 문제 ②에 대응하는 후기 청킹은 부모 청크 단위로 요청하도록 구현하였으나 임베딩 서빙 엔진(SGLang)이 이 옵션을 무시해, 운영 시스템은 청크별 일반 임베딩으로 동작한다. 후기 청킹의 효과는 4절의 추가 실험에서 별도로 검증하였다.

(6) 하이브리드 검색과 근거 기반 답변: 질의응답 흐름은 알고리듬 1과 같다. 후속 질문은 최근 대화 이력을 참고해 독립적인 검색어로 재작성하고, 벡터 검색 · 전문 검색 · 파일명 일치의 세 경로에서 후보를 모은 뒤 가중합으로 1차 점수를 매긴다. 상위 후보는 교차 인코더 리랭커(bge-reranker-v2-m3)[5]가 질문과 부모 문맥을 함께 읽어 매긴 점수와 1차 순위를 7:3으로 합한 최종 점수로 다시 정렬하며, 리랭커 점수 0.10 미만의 후보는 제외하되 모두 미달이면 최종 점수 상위 2개만 남긴다. LLM은 남은 근거 안에서만 답하도록 지시받고, 근거가 부족하면 「문서에서 확인되지 않음」으로 응답하며, 모든 답변에 파일명과 페이지를 출처로 표기한다(문제 ⑥).

알고리듬 1. 하이브리드 검색과 근거 기반 답변 생성

```
입력: 질문 q, 대화 이력 H, 근거 개수 K(=8), 컷오프 τ(=0.10)
출력: 답변 a, 출처 집합 S
q′ ← Rewrite(q, H)   ▷ 독립 검색어로 재작성
C ← VecSearch(Embed(q′), 5K)
      ∪ FtsSearch(Morph(q′), 5K)
      ∪ FileNameMatch(q′, 5K)
for each c ∈ C do
    s(c) ← 0.75 · s_vec(c) + 0.25 · s_fts(c) + 0.35 · s_file(c)
end for
P ← s 기준 상위 max(150, 1.5K)개 후보
for each c ∈ P do
    r(c) ← CrossEncoder(q′, 경로(c) ⊕ 부모(c) ⊕ c)
    f(c) ← 0.7 · r(c) + 0.3 · 1차 순위(c)
end for
V ← { c ∈ P | r(c) ≥ τ }
if V = ∅ then V ← f 기준 상위 2개   ▷ LLM이 거절 판단
R ← V에서 f 기준 상위 K개, 부모 중복 제거
a ← LLM(근거 한정 지시, R, q)
S ← { (파일명(c), 페이지(c)) | c ∈ R }
return a, S
```

제안 시스템의 구현 환경은 표 1과 같다. 모든 모듈은 Python으로 구현하고, 의미 검색과 키워드 검색을 하나의 관계형 데이터베이스에서 처리하도록 PostgreSQL과 pgvector를 사용한다. 답변 생성과 페이지 이미지 해석에는 사내 서버의 같은 LLM을 사용하므로 문서가 외부로 전송되지 않는다.

표 1 구현 환경

Table 1 Implementation environment

구분	내용
언어	Python 3
파싱	pdfplumber, MarkItDown, python-docx 등
형태소 분석	Kiwi (kiwipiepy)
저장소	PostgreSQL + pgvector, tsvector
색인	HNSW (코사인 거리), GIN 역색인
임베딩	harrier-0.6B (1,024차원)
리랭커	bge-reranker-v2-m3, 컷오프 0.10
LLM · VLM	gemma-4-26b-a4b-it (사내 서버)
서비스	Open WebUI Pipeline

3. 실험 설계

설계 단계별 효과를 분리하기 위해 세 시스템을 비교하였다. 「기본 RAG」는 512토큰 고정 길이 청크와 벡터 검색만 사용하는 구성으로, 구현 이력에 이 구성이 없어 비교를 위해 새로 구현하였다. 「초기 구현」은 계층 청킹과 하이브리드 점수를 처음 적용한 최초 버전이며, 「제안 파이프라인」은 여기에 경로 태깅, 파일명 보정, 리랭킹 컷오프를 더한 현행 버전이다. 세 시스템은 하나의 공유 파싱 캐시에서 재구축해 파싱 결과를 동일하게 맞추었고, 모두 공통으로 색인된 1,424개 문서(20개 하위 폴더, 7개 포맷)를 대상으로 하였다. 생성 모델(gemma-4-26b-a4b-it)과 LLM에 전달하는 근거 개수(K=8)도 같게 두었다.

평가셋은 사내 질문 300건과 문서 범위 밖(out-of-domain, OOD) 질문 49건으로 구성하였다. 질문은 LLM이 만든 초안으로, 처음 구성한 130건(사내 100, OOD 30)은 연구자가 원문과 대조해 검수 · 수정하였고, 추가한 219건(사내 200, OOD 19)은 근거 인용의 위치, 정답 수치, 세 시스템 공통 문서 여부를 자동으로 점검해 통과한 문항만 사용하였다. 사내 질문은 문제 ①~④를 겨냥한 질문 200건과 일반 질문 100건이고, 유형별로는 규정 85건, 수치 81건, 조건 81건, 절차 53건이다. 응답 정확도는 정답 대비 수치 · 규정 · 조건 · 절차의 일치 여부를 LLM 평가자[13]가 0~1점으로 채점한 평균이고, HitRate@5는 상위 5개 검색 결과에 정답 문서(페이지 기준은 정답 페이지까지)가 포함된 질문의 비율이다. 평가자의 편향을 줄이기 위해 채점 LLM에는 시스템 이름과 출처 표기를 뗀 답변을 질문, 검수된 정답과 함께 한 건씩 제시하고, 네 범주의 일치 여부(1/0/해당 없음)를 먼저 판정한 뒤 종합 점수를 매기게 하였다(temperature 0). 세 시스템의 답변은 모두 같은 생성 모델로 만들었으므로, 평가자가 자기 생성물을 선호하는 편향[13]이 있더라도 세 시스템에 공통으로 작용한다. 같은 답변을 다시 채점했을 때 점수가 달라진 질문은 300건 중 9건(정확도 0.660→0.658)이었고, 오거절은 거절 문구 규칙으로, HitRate는 LLM 없이 내용 해시와 페이지로 판정하였다. 환각 차단률은 OOD 질문에 답변을 거절한 비율이며, 보조 지표로 사내 질문을 잘못 거절한 비율(오거절률)과 응답 지연을 측정하였다. 시스템 간 차이는 질문 단위 대응 표본 부트스트랩[14](2,000회)으로 95% 신뢰구간을 구하였다.

4. 실험 결과 및 분석

표 2는 세 시스템의 성능이다. 제안 파이프라인의 응답 정확도는 0.660으로 기본 RAG(0.419)보다 0.241 높았고, 95% 신뢰구간 [+0.176, +0.307]이 0을 포함하지 않았다. 초기 구현 대비로도 0.220 [+0.165, +0.278] 높았던 반면, 기본 RAG와 초기 구현의 차이(+0.021)는 유의하지 않았다. 평가자에 따른 차이를 확인하기 위해, 개인정보를 가린 사내 질문 답변 900건을 생성 모델과 다른 계열의 LLM(Claude Opus 5.5)으로 같은 기준에 따라 다시 채점하였다. 두 평가자 점수의 상관계수는 0.936, 0.5점 기준 정답 판정 일치율은 0.958(κ = 0.915)이었고, 제안 파이프라인과 기본 RAG의 차이도 +0.274 [+0.213, +0.335]로 같은 결론을 보였다. 생성 모델과 같은 평가자의 점수는 세 시스템 모두에서 오히려 0.023~0.056 낮아, 자기 생성물을 선호하는 편향은 나타나지 않았다.

표 2 시스템별 성능 비교 (단위: 응답지연은 초, 그 외 0~1, 차이 = 제안 − 기본 RAG)

Table 2 Performance comparison of the three systems

지표	기본 RAG	초기 구현	제안	차이	95% CI
응답 정확도	0.419	0.440	0.660	+0.241	[0.176, 0.307]
HitRate@5 (문서)	0.477	0.477	0.510	+0.033	[−0.027, 0.093]
HitRate@5 (페이지)	0.340	0.400	0.453	+0.113	[0.043, 0.180]
환각 차단률	0.878	0.837	0.939	+0.061	[−0.020, 0.163]
오거절률	0.417	0.367	0.180	−0.237	[−0.303, −0.170]
응답지연(초)	5.8	8.7	13.8	+8.0	–

검색 정밀도는 페이지 기준 HitRate@5가 0.340에서 0.453으로 유의하게 올랐으나, 문서 기준 HitRate@5의 차이(+0.033)는 신뢰구간이 0을 포함하였다. 환각 차단률은 0.878에서 0.939로 높아졌으나 신뢰구간이 0을 포함하였고, 오거절률은 0.417에서 0.180으로 유의하게 낮아졌다(표 2). 반면 응답 지연은 평균 5.8초에서 13.8초로 늘었는데, 리랭킹 호출과 부모 청크로 커진 프롬프트(평균 3,248→11,677 토큰)가 주된 원인이었다.

문제 유형별로 보면 제안 파이프라인의 응답 정확도는 ①~④와 일반 질문 모두에서 가장 높았고 기본 RAG와의 차이도 모두 유의하였다(① 0.279→

0.643, ② 0.464→0.658, ③ 0.476→0.733, ④ 0.456→0.662). 그러나 ①과 ③에서는 문서 기준 HitRate@5가 기본 RAG보다 높지 않았다(① 0.425→0.425, ③ 0.545→0.473).

후기 청킹의 효과를 확인하기 위해, 같은 부모 청크를 문맥 창으로 후기 청킹 임베딩을 생성한 두 변형을 별도 서버에 구축하였다. 평균 풀링 변형의 응답 정확도는 0.554로 제안 파이프라인보다 0.106 [−0.162, −0.047] 낮았고, 마지막 토큰 풀링 변형은 0.350으로 더 낮았다(그림 2).

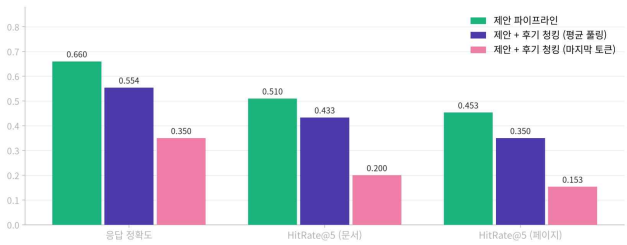


그림 2 후기 청킹 변형 비교
Fig. 2 Comparison of late chunking variants

하락의 원인이 임베딩 모델에 있는지 확인하기 위해, 후기 청킹을 지원하는 양방향 인코더 jina-embeddings-v3[15]로 임베딩 모델만 바꾸어 자식 청크를 하나씩 임베딩한 단독 색인과 부모 단위 후기 청킹 색인을 비교하였다(표 3). 후기 청킹의 응답 정확도는 0.604로 단독(0.643)보다 0.039 [−0.090, +0.014] 낮았으나 유의하지 않았다. 문제 ② 질문에서는 0.624에서 0.654로 올랐고, ③ 질문에서는 0.700에서 0.595로 낮아졌다. 한편 제안 파이프라인을 같은 설정으로 네 번 더 실행한 5회의 응답 정확도는 0.653~0.672(범위 0.019)였고 검색 결과는 300문항 중 297문항이 5회 모두 같아, 후기 청킹의 하락(−0.106)은 실행 간 변동보다 훨씬 크고 jina-v3의 차이(−0.039)는 그에 가까운 크기이다.

표 3 jina-v3 임베딩의 후기 청킹 비교 (단위: 0~1, 제안: harrier 임베딩, 차이 = 후기 청킹 − 단독)
Table 3 Late chunking with jina-embeddings-v3

지표	제안	단독	후기 청킹	차이	95% CI
응답 정확도	0.660	0.643	0.604	−0.039	[−0.090, 0.014]
HitRate@5 (문서)	0.510	0.550	0.507	−0.043	[−0.097, 0.010]
HitRate@5 (페이지)	0.453	0.480	0.430	−0.050	[−0.100, 0.000]
환각 차단률	0.939	0.898	0.959	+0.061	[−0.020, 0.143]
오거절률	0.180	0.187	0.227	+0.040	[−0.017, 0.097]

결과는 세 가지로 해석된다. 첫째, 개선의 대부분은 초기 구현과 제안 파이프라인 사이에서 나타났다. 이 구간에서 더해진 경로 태깅, 파일명 보정, 리랭킹 컷오프가 정답 페이지를 상위로 올리고 근거가 충분한 부모 청크만 LLM에 전달해, 응답 정확도와 오거절률을 함께 개선한 것으로 보인다. 다만 이 개선에는 응답 지연이 약 2.4배 늘어나는 비용이 따랐다. 둘째, 문서 기준 HitRate@5의 차이는 유의하지 않았으나 페이지 기준과 응답 정확도의 차이는 유의하였다. 같은 문서 안에서 정답 위치를 찾고 그 근거를 답변으로 연결하는 능력이 주로 개선되었다는 뜻이다. ① · ③ 유형에서 문서 기준 HitRate@5가 오르지 않았는데도 정확도가 오른 것은, 같은 내용이 다른 버전 · 같은 양식의 다른 파일에도 있어 정답 문서가 아닌 파일로 답한 경우가 있고, 내용 해시로 정답 문서를 판정하는 HitRate는 이를 검색 실패로 집계하기 때문이다. 셋째, 후기 청킹은 디코더 계열 임베딩 모델에서 오히려 정확도를 낮췄다. 이 모델은 입력 끝에 붙는 특수 토큰의 은닉 상태를 문장 벡터로 쓰도록 학습되었는데, 후기 청킹[7]은 학습되지 않은 일반 토큰 위치에서 벡터를 만든다. 부모 청크 300개를 표본으로 비교한 결과, 평균 풀링 벡터는 서로 다른 문서의 청크끼리도 코사인 유사도가 0.898로 몰려(제안 파이프라인 0.547) 변별력을 잃었다. 그 결과 문서 수준의 문맥이 필요한 ① · ③ 유형에서는 정답 문서를 조금 더 자주 찾았으나, 수치형 · 일반 질문에서는 근거 청크를 놓쳐 오거절이 54건에서 77건으로 늘었다. 후기 청킹을 지원하는 인코더에서는 다른 문서 청크끼리의 유사도가 0.349로 구분이 유지되고 정확도 하락도 유의하지 않아, 이 하락이 모델과의 불일치에서 비롯되었다는 해석을 뒷받침하였다. 다만 같은 부모 안 자식 벡터끼리의 유사도가 0.535에서 0.949로 높아져 청크마다의 차이가 줄었고, 부모 청크 문맥과 경로 태그를 이미 쓰는 제안 파이프라인에서는 ② 질문의 개선과 ③ · ④ · 일반 질문의 하락이 상쇄된 것으로 보여 전체 정확도는 오르지 않았다.

Ⅲ. 결론

본 논문은 사내 기술문서 검색을 위한 하이브리드 RAG 파이프라인을 설계 · 구현하고, 공유 파싱 캐시로 재구축한 세 시스템을 동일한 조건에서 비교하였다. 제안 파이프라인은 기본 RAG 대비 응답 정확도를 0.419에서 0.660으로, 환각 차단률을 0.878에서 0.939로 높였고 오거절률을 0.417에서 0.180으로 낮췄다.

본 연구의 기여는 다음과 같다. 학문적으로는 사내 문서 검색의 문제를 여섯 가지로 정의해 기법과 하나씩 대응시키고, 기법을 단계적으로 더한 세 시스템을 같은 파싱 결과에서 비교해 청킹 · 검색 설계의 효과를 분리해 측정하였다. 또한 후기 청킹이 디코더 기반 임베딩 모델에서는 성능을 낮추고, 후기 청킹을 지원하는 인코더에서도 전체 성능을 높이지 못한다는 부정적 결과와 그 원인을 보고하였다. 실용적으로는 대외비 문서를 외부로 보내지 않고 사내 서버에서 근거(파일 · 페이지)와 함께 답하는 검색 서비스를 구현해 운영하였다.

다만 문서 기준 검색 정밀도와 환각 차단률의 향상은 통계적으로 유의하지 않았고 응답 지연은 약 2.4배로 늘었다. 평가셋은 한 폴더의 1,424개 문서에서 만든 349건이며 추가한 219건은 사람 검수 없이 자동 점검만 거쳤다. 정확도 채점에 답변 생성과 같은 LLM을 평가자로 사용하였으며, 다른 계열 평가자와의 일치는 확인하였으나 사람 평가와의 일치도는 검증하지 못하였다. 또한 경로 태깅, 파일명 보정, 리랭킹이 함께 더해져 기법별 기여는 분리하지 못하였다. 향후에는 기법별 제거 실험(ablation)으로 기여를 분리하고, 리랭킹 대상 축소와 캐시로 지연을 줄이며, 문맥이 필요한 청크에만 후기 청킹을 선택적으로 적용하는 방법을 검증하며, 평가 대상을 확대할 계획이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Z. Ji et al., "Survey of Hallucination in Natural Language

Generation," ACM Computing Surveys, vol. 55, no. 12, pp. 1–38, 2023.

[2] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems 33, pp. 9459–9474, 2020.

[3] V. Karpukhin et al., "Dense Passage Retrieval for Open-Domain Question Answering," Proc. EMNLP, pp. 6769–6781, 2020.

[4] S. Robertson and H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," Foundations and Trends in Information Retrieval, vol. 3, no. 4, pp. 333–389, 2009.

[5] J. Chen et al., "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," Findings of ACL 2024, pp. 2318–2335, 2024.

[6] P. Sarthi et al., "RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval," Proc. ICLR, 2024.

[7] M. G□nther et al., "Late Chunking: Contextual Chunk Embeddings Using Long-Context Embedding Models," arXiv:2409.04701, 2024.

[8] Y. Malkov and D. Yashunin, "Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs," IEEE Trans. Pattern Analysis and Machine Intelligence, vol. 42, no. 4, pp. 824–836, 2020.

[9] J. Singer-Vine, "pdfplumber," GitHub repository, https://github.com/jsvine/pdfplumber

[10] Microsoft, "MarkItDown," GitHub repository, https://github.com/microsoft/markitdown

[11] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual Instruction Tuning," Advances in Neural Information Processing Systems 36, 2023.

[12] bab2min, "Kiwi: Korean Intelligent Word Identifier," GitHub repository, https://github.com/bab2min/Kiwi

[13] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," Advances in Neural Information Processing Systems 36 (Datasets and Benchmarks Track), 2023.

[14] B. Efron and R. J. Tibshirani, An Introduction to the Bootstrap, Chapman & Hall/CRC, 1993.

[15] S. Sturua et al., "jina-embeddings-v3: Multilingual Embeddings With Task LoRA," arXiv:2409.10173, 2024.

태양광 시스템 고장진단을 위한 단계적 특징 선택 기반 발전량 추정 프레임워크

이소현, 김한진*, 전명근**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 지능로봇공학과

shiljcf@chungbuk.ac.kr, *gks359@chungbuk.ac.kr, **mgchun@chungbuk.ac.kr

A Staged Feature Selection Framework for PV Power Estimation to Support Fault Diagnosis in Photovoltaic Systems

Sohyun Lee, Hanjin Kim*, Myung-Geun Chun**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

Accurate estimation of expected photovoltaic (PV) power under current operating conditions can support system monitoring and fault diagnosis. This study proposes a staged feature selection framework combining feature-group construction, model-specific SHAP analysis, and Sequential Forward Floating Selection (SFFS). Using hourly data from Chungbuk, Korea (2020-2024), 69 input features were constructed across five groups: Time, Current, Lag, Rolling, and Diff. For Random Forest, LightGBM, and LSTM, SHAP identified the top 20 candidate features for each model, and SFFS selected 9, 10, and 14 features, respectively. Compared with the full-feature models, NMAE decreased from 2.592% to 2.382%, 2.516% to 2.401%, and 4.215% to 3.510%, respectively. Commonly selected features represented current environmental conditions, historical power states, and short-term changes, while model-specific feature combinations differed. These results show that the framework derives model-specific subsets while reducing input dimensionality and improving PV power estimation performance.

Key words : Photovoltaic system, Power estimation, Condition monitoring, Feature selection, SHAP, SFFS

Ⅰ. 서론

태양광 발전시스템의 출력은 일사량, 기온, 구름, 계절적 조건 등 다양한 환경요인의 영향을 받아 지속적으로 변동하므로, 단순한 발전량 감소만으로 이상 여부를 판단하는 데에는 한계가 있다. 태양광 발전량 모델은 미래 발전량 예측뿐만 아니라, 현재 환경 및 운전조건에서 기대되는 발전량을 산정하여 실제 발전량과 비교함으로써 시스템 상태를 평가하는 데에도 활용될 수 있다. 특히 상태 모니터링 및 고장진단에서는 현재 조건에서 기대되는 발전량을 정확하게 추정하고, 이를 실제 발전량과 비교하는 것이 중요하다. 기존 연구에서도 환경정보를 기반으로 기대 발전량을 추정하고 실제 발전량과의 편차를 이용하여 성능 저하 및 이상상태를 판단하는 방법이 제안되고 있으나[1], 발전량 추정에 효과적인 입력 특징의 구성과 선택에 대한 체계적인 분석은 상대적으로 부족하다.

태양광 발전량 추정 연구에서는 기상조건과 발전량 사이의 비선형 관계를 반영하기 위해 기계학습 기법이 널리 활용되고 있다. 기계학습 기반 발전량 추정에서는 모델의 구조뿐만 아니라 입력 특징의 구성도 추정 성능에 중요한 영향을 미친다. 특히 태양광 발전량의 시간적 특성을 반영하기 위해 시간 정보와 과거값(Lag), 이동평균(Rolling) 등의 특징이 활용되고 있으며[2], 과거 발전량의 변화량(Diff)을 입력 특징으로 활용하여 단기 변동 특성을 반영하는 방법도 제안되고 있다[3]. 이러한 특징들은 현재의 환경조건과 과거 발전 상태 및 시간적 변화 양상을 함께 반영하여 발전량 추정에 활용될 수 있다. 그러나 다양한 시간적 · 환경적 특징을 함께 사용하면 입력 특징 수가 증가하고, 중복되거나 기여도가 낮은 특징이 포함될 수 있다[4]. 따라서 다수의 입력 특징 중 발전량 추정에 유효한 특징을 체계적으로 선별하는 과정이 필요하다. 또한 입력 특징의 유효성은 모델의 학습 특성에 따라 달라질 수 있으므로, 모델별로 적합한 특징 조합을 탐색하는 것이 중요하다.

개별 특징의 중요도만을 기준으로 선택할 경우, 특징 간 조합에 따른 발전량 추정 성능의 변화를 충분히 반영하기 어렵다. SHAP은 모델 예측에 대한 각 입력 특징의 기여도를 정량적으로 분석하는 데 활용할 수 있으며[5], SHAP을 이용하여 후보 특징을 선별한 후 Sequential Forward Floating Selection(SFFS)을 적용함으로써 발전량 추정 성능이 우수한 특징 조합을 탐색할 수 있다. SFFS는 현재 선택된 특징 집합에 후보 특징을 순차적으로 추가하고, 필요에 따라 기존 특징을 조건부로 제거하면서 성능이 우수한 특징 조합을 탐색하는 방법이다[6]. 따라서 본 연구에서는 SHAP을 이용한 후보 특징 선별과 SFFS를 이용한 최종 특징 조합 탐색으로 구성된 단계적 특징 선택 방법을 적용하였다.

본 연구에서는 태양광 발전시스템의 향후 상태 모니터링 및 고장진단에 활용하기 위한 단계적 특징 선택 기반 발전량 추정 프레임워크를 제안한다. 제안한 프레임워크는 입력 특징 그룹 구성, 모델별 SHAP 중요도 분석, SFFS 기반 특징 조합 탐색 및 성능 평가로 구성된다. 이를 Random Forest, LightGBM, LSTM에 적용하여 모델별 유효 특징 조합과 특징 그룹의 선택 차이를 분석하고, 입력 특징 수 감소에 따른 발전량 추정 성능을 비교하였다.

Ⅱ. 본론

2.1 발전량 추정 프레임워크의 구성

본 연구에서는 공공데이터포털에서 제공하는 한국동서발전(주)의 '전국 태양광 발전량 예측값 학습데이터' 중 충북 지역의 2020년부터 2024년까지의 1시간 단위 데이터를 사용하였다[7]. 원천 데이터는 기온, 습도, 풍속, 적운량, 일조, 대기권 밖 일사량 계산값, 일사량, 발전량 등으로 구성된다. 발전량은 목표변수와 과거 발전량 기반 특징 생성에 활용하였으며, 현재 시점의 발전량 자체는 입력 특징에 포함하지 않았다. 또한 발전설비 용량 차이에 따른 영향을 줄이기 위해 발전량을 설비용량으로 나눈 정규화 발전량을 목표변수로 사용하였으며, 성능 평가 시에는 정규화 이전의 발전량 단위로 역변환하였다.

태양광 발전량 추정을 위해 입력 특징을 Time, Current, Lag, Rolling, Diff의 다섯 그룹으로 구성하였다. Time 그룹은 월, 일, 시간 및 주기성을 반영한 시간 정보를 나타내며 Current 그룹은 현재 시점의 기상 · 일사량 정보를 포함한다. Lag 그룹은 1시간, 3시간, 24시간 전의 발전 상태와 환경 조건을 나타내며, Rolling 그룹은 최근 3시간과 24시간 구간의 평균적인 발전 상태와 환경 조건을 나타낸다. Diff 그룹은 직전 시간과 전일 동일 시간 대비 발전 상태와 환경 조건의 변화량을 나타낸다. 이를 통해 표 1에서 보는 바와 같이 총 69개의 입력 특징을 구성하였다.

표 1 태양광 발전량 추정을 위한 초기 입력 특징 구성
Table 1 Initial input features for photovoltaic power estimation

그룹	개수	입력특징 변수
Time	6	month, day, hour, doy, sin_hour, cos_hour
Current	7	Temp, RH, WS, Cloud, Sunshine, ETR, GHI_surface
Lag	24	Temp_lag1, Temp_lag3, Temp_lag24, RH_lag1, RH_lag3, RH_lag24, WS_lag1, WS_lag3, WS_lag24, Cloud_lag1, Cloud_lag3, Cloud_lag24, Sunshine_lag1, Sunshine_lag3, Sunshine_lag24, ETR_lag1, ETR_lag3, ETR_lag24, GHI_surface_lag1, GHI_surface_lag3, GHI_surface_lag24, Target_lag1, Target_lag3, Target_lag24
Rolling	16	Temp_mean3, Temp_mean24, RH_mean3, RH_mean24, WS_mean3, WS_mean24, Cloud_mean3, Cloud_mean24, Sunshine_mean3, Sunshine_mean24, ETR_mean3, ETR_mean24, GHI_surface_mean3, GHI_surface_mean24, Target_mean3, Target_mean24
Diff	16	Temp_diff1, Temp_diff24, RH_diff1, RH_diff24, WS_diff1, WS_diff24, Cloud_diff1, Cloud_diff24, Sunshine_diff1, Sunshine_diff24, ETR_diff1, ETR_diff24, GHI_surface_diff1, GHI_surface_diff24, Target_diff1, Target_diff24

그림 1은 제안한 단계적 특징 선택 기반 발전량 추정 프레임워크를 나타낸다. 먼저 발전량과 기상 · 일사량 데이터를 바탕으로 입력 특징 그룹을 구성하고, 발전량 추정 모델을 설정한다. 이후 각 모델에 대해 SHAP 중요도 분석을 수행하여 후보 특징을 선정하고, SFFS를 적용하여 최종 특징 조합을 탐색한다. 선택된 특징으로 모델을 재학습하고, 발전량 추정 성능을 평가한다. 제안한 프레임워크는 입력 특징 그룹과 추정 모델을 각각 설정하여, 그룹이나 모델이 변경되더라도 동일한 단계적 특징 선택 절차를 적용할 수 있도록 설계하였다.

2.2 단계적 특징 선택 및 성능 평가

데이터는 미래 정보가 학습 과정에 포함되는 것을 방지하고 실제 운용 환경과 유사한 평가 조건을 구성하기 위해 시간 순서에 따라 2020~2022년을 학습 데이터, 2023년을 검증 데이터, 2024년을 시험 데이터로 구분하였다. 표 2는 Random Forest, LightGBM, LSTM에 대해 SHAP 분석을 수행하여 선정한 상위 20개의 후보 특징을 나타낸다. Random Forest에서는 Time 3개, Current 4개, Lag 7개, Rolling 3개, Diff 3개의 특징이 선정되었으며, LightGBM에서는 Time 4개, Current 4개, Lag 5개, Rolling 4개, Diff 3개, LSTM에서는 Time 3개, Current 4개, Lag 4개, Rolling 5개, Diff 4개의 특징이 선정되었다. 선정된 상위 20개 특징을 SFFS 후보로 사용하여 모델별 특징 조합의 유효성을 평가하였다.



그림 1 단계적 특징 선택 기반 태양광 발전량 추정 프레임워크
Fig. 1 Framework for photovoltaic power estimation based on staged feature selection

표 2 SHAP 기반 상위 20개 후보 특징 선정 결과
Table 2 Top-20 candidate features selected based on SHAP

그룹	입력특징 변수		
	Random Forest	LightGBM	LSTM
Time	hour, sin_hour, cos_hour	hour, doy, sin_hour, cos_hour	hour, sin_hour, cos_hour
Current	Cloud, Sunshine, ETR, GHI_surface	Cloud, Sunshine, ETR, GHI_surface	RH, Cloud, ETR, GHI_surface
Lag	ETR_lag1, ETR_lag3, ETR_lag24, GHI_surface_lag1, GHI_surface_lag24, Target_lag1, Target_lag24	ETR_lag1, ETR_lag24, GHI_surface_lag24, Target_lag1, Target_lag24	ETR_lag24, Target_lag1, Target_lag3, Target_lag24
Rolling	Cloud_mean3, Target_mean3, Target_mean24	ETR_mean3, ETR_mean24, Target_mean3, Target_mean24	Sunshine_mean24, ETR_mean3, ETR_mean24, Target_mean3, Target_mean24
Diff	ETR_diff1, Target_diff1, Target_diff24	ETR_diff1, Target_diff1, Target_diff24	Temp_diff1, ETR_diff1, Target_diff1, Target_diff24

표 3은 표 2의 SHAP 상위 20개 후보 특징에 SFFS를 적용하여 도출한 모델별 최종 특징 선택 결과를 나타낸다. SFFS 적용 결과 Random Forest에서는 9개, LightGBM에서는 10개, LSTM에서는 14개의 특징이 최종 선정되었다. SHAP 상위 20개 후보에는 세 모델 모두 Time 그룹의 특징이 포함되었으나, SFFS 이후에는 LSTM에서만 해당 그룹의 특징이 최종 선택되었다. Current 그룹에서는 현재 구름 · 일사 조건을 나타내는 Cloud와 GHI_surface가 세 모델에 공통으로 선택되었으며, LightGBM의 Sunshine과 LSTM의 RH가 추가로 선택되었다. Lag 그룹에서는 Target_lag1과 Target_lag24가 공통으로 선택되어 직전 및 전일 발전 상태를 반영하였다. Rolling 그룹에서는 Random Forest와 LightGBM이 Target_mean24를, LSTM은 Target_mean3과 ETR_mean3을 선택하여 평균 정보의 시간 범위와 대상 변수에 차이가 나타났다. Diff 그룹에서는 ETR_diff1과 Target_diff1이 공통으로 선택되어 단기 변화 정보를 반영하였으며, Random Forest와 LightGBM은 Target_diff24를, LSTM은 Temp_diff1을 선택하였다. 이러한 결과는 특징 선택 과정에서 개별 특징의 중요도뿐 아니라 특징 간 조합과 모델별 차이를 함께 고려하는 것이 중요함을 보여준다.

표 3 SFFS 기반 모델별 최종 특징 선정 결과
Table 3 Final feature subsets selected by SFFS for each model

그룹	입력특징 변수		
	Random Forest	LightGBM	LSTM
Time	-	-	hour, sin_hour, cos_hour
Current	Cloud, GHI_surface	Cloud, Sunshine, GHI_surface	RH, Cloud, GHI_surface
Lag	ETR_lag1, Target_lag1, Target_lag24	GHI_surface_lag24, Target_lag1, Target_lag24	ETR_lag24, Target_lag1, Target_lag24
Rolling	Target_mean24	Target_mean24	ETR_mean3, Target_mean3
Diff	ETR_diff1, Target_diff1, Target_diff24	ETR_diff1, Target_diff1, Target_diff24	Temp_diff1, ETR_diff1, Target_diff1

표 4는 전체 69개 입력 특징을 사용한 경우와 단계적 특징 선택으로 도출된 최종 특징을 이용하여 재학습한 경우의 발전량 추정 성능을 비교한 결과이다. Random Forest는 전체 특징 사용 시 NMAE 2.592%, RMSE 14.029 MWh, R^2 0.958이었으나, 9개의 최종 특징을 사용한 경우 각각 2.382%, 13.001 MWh, 0.964로 향상되었다. LightGBM은 전체 특징 사용 시 NMAE 2.516%, RMSE 13.712 MWh, R^2 0.960에서 10개의 최종 특징을 사용한 경우 각각 2.401%, 13.243 MWh, 0.962로 개선되었다. LSTM 역시 전체 69개 특징 사용 시 NMAE 4.215%, RMSE 22.293 MWh, R^2 0.893에서 14개의 최종 특징을 사용한 경우 각각 3.510%, 19.626 MWh, 0.917로 향상되었다. 이러한 결과는 모델별로 유효한 특징 조합을 선택함으로써 입력 특징 수를 줄이면서 발전량 추정 성능을 개선할 수 있음을 보여준다. 또한 동일한 단계적 특징 선택 절차를 세 모델에 적용하여 각각 다른 유효 특징 집합을 도출하였다는 점에서 제안한 프레임워크의 모델별 적용 가능성을 확인하였다.

표 4 단계적 특징 선택에 따른 발전량 추정 성능 비교
Table 4 Comparison of photovoltaic power estimation performance with and without staged feature selection

모델	특징 구성	특징 수	NMAE(%)	RMSE(MWh)	R^2
Random Forest	전체 특징	69	2.592	14.029	0.958
	제안 방법	9	2.382	13.001	0.964
LightGBM	전체 특징	69	2.516	13.712	0.960
	제안 방법	10	2.401	13.243	0.962
LSTM	전체 특징	69	4.215	22.293	0.893
	제안 방법	14	3.510	19.626	0.917

Ⅲ. 결론

본 연구에서는 태양광 발전시스템의 향후 상태 모니터링 및 고장진단에 활용하기 위한 단계적 특징 선택 기반 발전량 추정 프레임워크를 구성하였다. 현재 시점의 기상 · 일사량 정보와 과거 발전량 및 환경정보를 이용하여 기대 발전량을 추정하기 위해 Time, Current, Lag, Rolling, Diff의 5개 그룹으로 총 69개의 초기 입력 특징을 구성하였다. 이후 모델별 SHAP 중요도 상위 20개 특징을 후보 특징으로 선정하고, SFFS를 적용하여 최종 특징 집합을 도출한 후 선택된 특징을 이용하여 모델을 재학습하였다. 특징 선택 결과 Random Forest, LightGBM, LSTM의 입력 특징 수는 각각 69개에서 9개, 10개, 14개로 감소하였다. 선택된 특징으로 재학습한 결과 Random Forest의 NMAE는 2.592%에서 2.382%, LightGBM은 2.516%에서 2.401%, LSTM은 4.215%에서 3.510%로 감소하였다. 또한 세 모델 모두에서 현재 기상 · 일사 조건, 과거 발전 상태 및 단기 변화 정보를 반영하는 특징이 선택되었으며, Time 그룹의 특징은 LSTM에서만 최종 선택되는 등 모델별 특징 조합에 차이가 나타났다. 특히 Rolling 그룹에서는 Random Forest와 LightGBM이 24시간 발전량 평균을, LSTM은 3시간 발전량 및 대기권 밖 일사량 평균을 선택하여 모델별로 활용하는 시간적 정보에 차이가 나타났다. 이러한 결과는 제안한 프레임워크가 입력 특징 수를 줄이면서 모델별 적합한 특징 집합을 도출하고 발전량 추정 성능을 개선하는 데 효과적임을 보여준다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] W. Oh, M. Kim, J. Kim, and N. Park, "Power estimation and degradation detection in photovoltaic systems using machine learning," Sustainable Energy Technologies and Assessments, vol. 90, 105030, 2026.

[2] H. S. E. Mansour, A. S. Mohamed, H. M. H. Farh, et al., "High-resolution photovoltaic power forecasting using machine learning models under seasonal and stress conditions," Scientific Reports, vol. 16, 19029, 2026.

[3] X. Ren, Y. Liu, F. Zhang, and L. Li, "A Deep Learning Quantile Regression Photovoltaic Power-Forecasting Method under a Priori Knowledge Injection," Energies, vol. 17, no. 16, 4026, 2024.

[4] M. Ali, A. Rabehi, A. Souahlia, et al., "Enhancing PV power forecasting through feature selection and artificial neural networks: a case study," Scientific Reports, vol. 15, 22574, 2025.

[5] M. P. Bakht, M. N. H. Mohd, B. S. K. K. Ibrahim, N. Khan, U.

U. Sheikh, and A. A.-H. Ab Rahman, “Advanced automated machine learning framework for photovoltaic power output prediction using environmental parameters and SHAP interpretability,” Results in Engineering, vol. 25, 103838, 2025.

[6] P. Pudil, J. Novovičov, and J. Kittler, “Floating search methods in feature selection,” Pattern Recognition Letters, vol. 15, no. 11, pp. 1119-1125, 1994.

[7] 한국동서발전(주), “한국동서발전(주)_전국 태양광 발전량 예측값 학습데이터,” 공공데이터포털, [Online]. Available: data.go.kr, Accessed: Sep. 18, 2026.

질의응답 멀티에이전트 협업 구조의 비교 평가

이경준, 김영진*, 반유석**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 전자공학과

kjlee@chungbuk.ac.kr, *you359@chungbuk.ac.kr, **ban@cbnu.ac.kr

Comparative Evaluation of Multi-Agent Collaboration Architectures for Question Answering

Kyeongjoon Lee, Youngjin Kim*, Yuseok Ban**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**Department of Electronics Engineering, Chungbuk National Univ.

Abstract

This study compares six multi-agent collaboration architectures with a single-agent baseline for small business question answering. Using a common model, data, and retrieval tools, we evaluated 36 questions for requirement fulfillment, evidence consistency, response time, and token usage. No architecture performed best across all metrics, suggesting trade-offs between answer quality and processing cost. The findings are exploratory, given the small question set, single-run evaluation, and use of one judge model.

Key words : Multi-agent systems, Question answering, Agent collaboration, Performance evaluation

Ⅰ. 서론

1.1 연구 배경 및 필요성

소상공인 지원 상담에는 정책 · 상권 · 통계 · 법률 등 여러 분야의 정보를 함께 활용해야 하는 질의가 포함된다. 이에 소상공인시장진흥공단의 AI 서비스 고도화 사업은 복합 질의를 분야별로 분배하고 결과를 통합하는 대화형 서비스를 추진하고 있다. 그러나 본 프로젝트의 저장 실행기록에서는 복합 질의의 일부 요구가 누락되거나 조회 결과와 기록된 답변이 일치하지 않는 사례가 관찰되었다. 이러한 문제는 사용자가 필요한 정보를 다시 질문하거나 답변의 근거를 별도로 확인해야 하는 부담으로 이어질 수 있다.

이러한 문제를 개선하려면 분야별 정보 조회뿐 아니라 작업 분배, 근거 전달 및 답변 통합 과정을 검토해야 한다. 본 프로젝트는 이를 수행하기 위해 분야별 전문 에이전트가 협업하는 멀티에이전트 시스템을 도입하고 있다. 이러한 시스템에서는 에이전트 간 정보 전달과 조정 방식이 주요 설계 요소이다[1]. 또한, LLM의 답변은 제공된 근거와 불일치할 수 있으므로[2], 역할 분리와 함께 근거 전달 및 결과 통합 방식을 검토해야 한다. 따라서 협업 구조에 따른 답변 품질의 차이를 비교하여 요구사항 누락과 근거 불일치를 줄일 수 있는 구조를 설계할 필요가 있다.

1.2 연구 목적 및 범위

본 연구의 목적은 소상공인 대상 다분야 질의응답에서 멀티에이전트 협업 구조에 따른 답변 품질과 처리 비용을 비교하는 것이다. 정책 · 상권 · 통계 · 법률을 대상으로 단일 에이전트와 여섯 가지 MAS 구조에 동일한 모델 · 데이터 · 조회 도구 및 실행 한도를 적용한다. 단일 분야와 복합 분야를 포함한 36개 질의를 통해 요구사항 충족률, 근거 일치율, 응답 시간 및 토큰 사용량을 평가하고, 구조별 품질과 비용의 관계를 살펴본다. 근거 공유 방식과 검증 절차 등 세부 설계 요소의 영향은 후속 연구에서 분석한다.

Ⅱ. 관련 연구

2.1 LLM 기반 질의응답 시스템

대규모 언어모델(LLM) 기반 질의응답 시스템은 사용자의 자연어 질문을 해석하고 그에 대한 답변을 생성한다. 이 과정에서 사실과 다르거나 주어진 근거와 일치하지 않는 내용을 생성하는 환각 현상이 발생할 수 있다[2]. 이러한 문제를 완화하기 위한 접근법 중 하나인 검색 증강 생성(RAG)은 질의와 관련된 외부 문서를 검색하고, 이를 답변 생성의 근거로 활용하는 방식이다[3]. 다만 외부 근거를 활용하더라도 환각이 완전히 해소되는 것은 아니므로, 검색된 정보의 적절성과 답변의 근거 일치 여부를 확인할 필요가 있다[2]. 정책 · 상권 · 통계 · 법률 등 여러 분야의 정보를 함께 요구하는 질의에서는 근거 검색과 더불어 분야별 정보 조회와 결과 통합을 수행하는 작업 구성도 고려할 필요가 있다.

2.2 멀티에이전트 협업 유형과 구조

LLM 기반 멀티에이전트 시스템(MAS)의 협업 메커니즘은 협업 유형, 협업 전략, 의사소통 구조 및 조정 방식의 관점에서 구분할 수 있다[1]. 표 1은 해당 분류 기준을 정리한 것이다.

표 1 멀티에이전트 협업 분류([1]을 바탕으로 재구성)
Table 1 Collaboration taxonomy (adapted from [1])

분류 기준	구분
협업 유형	협력, 경쟁, 협력 · 경쟁 혼합
협업 전략	규칙 기반, 역할 기반, 모델 기반
의사소통 구조	중앙집중형, 분산형, 계층형
조정 방식	정적, 동적

협업 유형 · 전략은 목표의 관계와 상호작용 기준을, 의사소통 구조 · 조정 방식은 정보 전달 관계와 실행 흐름의 변경 여부를 나타낸다[1]. 에이전트 간 대화를 지원하는 AutoGen[4]과 다중 모델의 답변 토론 방식[5]은 상호작용을 활용하는 대표 사례이다.

Ⅲ. 제안하는 시스템

3.1 질의응답 시스템의 공통 구성

그림 1은 정책 · 상권 · 통계 · 법률 정보를 활용하는 단일 턴 질의응답의 공통 구성이다. LangGraph로 실행 흐름을 구성하고, 정형 데이터는 Text-to-SQL 기반 읽기 전용 SQL 도구로, 문서는 벡터 검색 도구로 조회한다. 모든 설계안은 동일한 데이터와 조회 도구를 사용하며, 조회 근거로 최종 답변을 생성한다.

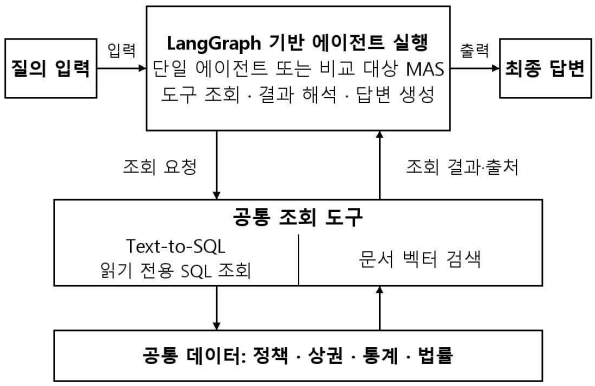


그림 1 질의응답 시스템의 공통 구성
Fig. 1 Common configuration of the QA system

3.2 비교 대상 에이전트 구성 및 협업 구조

단일 에이전트를 기준선으로 설정하고, 분류 체계[1]를 본 연구의 질의응답 환경에 적용하여 표 2의 여섯 가지 MAS 설계안을 구성한다. 이들은 본 연구의 비교 설계안이며, 중앙 조정 · 병렬 수행형을 기준으로 검토와 동적 조정의 효과도 분석한다.

표 2 비교 대상 에이전트 설계안
Table 2 Agent configurations for comparison

설계안	역할 및 수행 방식
단일 에이전트 (기준선)	단일 에이전트가 조회 · 통합 · 답변을 수행한다.
중앙 조정 · 병렬 수행형	중앙 조정자가 작업을 배정하고 병렬 결과를 통합한다.
순차 근거 전달형	선행 조회 근거를 후속 작업의 조건으로 전달한다.
분산 상호 협력형	참여 에이전트가 근거를 교환하여 답변을 보완한다.
계층적 조정형	상위 조정자가 하위 조정자와 작업 그룹을 관리한다.
협력 후 검토형	병렬 결과 통합 후 누락 · 근거 불일치를 검토한다.
동적 작업 조정형	중간 결과에 따라 추가 작업을 배정하거나 종료한다.

그림 2는 설계안별 협업 흐름을 요약한다. 작업 수와 역할은 예시이며, 조회 도구는 공통으로 사용한다. 근거 교환 · 검토 · 재계획의 실행 한도와 종료 조건은 실험 전에 확정하였다.

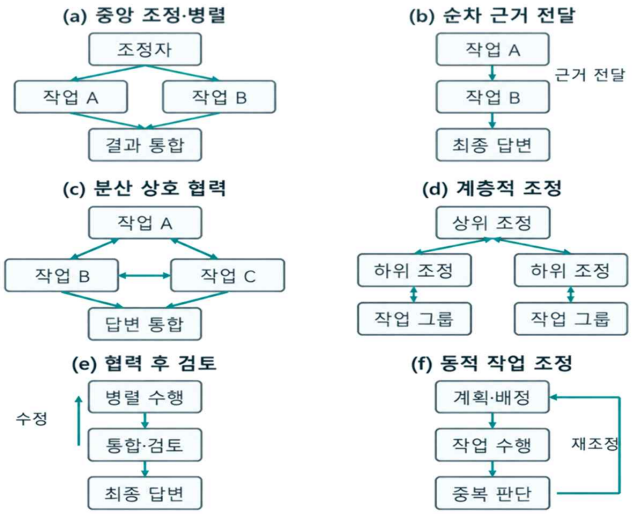


그림 2 여섯 가지 MAS 설계안의 협업 흐름
Fig. 2 Collaboration flows of six MAS designs

Ⅳ. 실험 및 결과 분석

4.1 데이터셋과 질의 유형

정책 · 상권 · 통계 · 법률의 정형 데이터와 문서 데이터를 활용하여 36문항의 평가용 질의 집합을 구성하였다. 질의는 단일 분야 질의와 복합 분야 질의로 구분하였다. 복합 질의에는 분야별 정보를 독립적으로 조회하여 종합하는 경우와 선행 조회 결과를 후속 조회에 활용하는 경우를 포함하였다. 답변에 필요한 조건과 요구가 명확한 질의를 사용하고, 대화 이력이나 사용자 재질문이 필요한 질의는 제외하였다. 각 문항에는 필수 답변 항목과 평가에 사용할 기준 근거를 마련하였다.

4.2 비교 조건 및 평가 지표

모든 설계안에 동일한 36개 질의 · 데이터 · 조회 도구를 제공하고 Solar Pro 4 모델을 사용하였다. 생성 온도는 0으로, 문항별 모델 호출 20회 · 도구 호출 24회 · 실행 시간 300초를 상한으로 설정하였다. 구조별로 각 문항을 1회 실행하고 실패 건수도 기록하였다.

그림 3과 같이 LangSmith에서 설계안별 실행 기록과 평가 점수를 관리하였다[6]. 질문은 LangGraph 시스템에 제공하고, 필수 답변 항목과 정답 근거는 평가기에만 제공하였다. 최종 답변과 평가 점수를 연결하여 구조별 결과를 집계하였다.

요구사항 충족률은 필수 항목 중 충족한 항목의 비율, 근거 일치율은 검증 가능한 주장 중 기준 근거가 뒷받침하는 주장의 비율로 평가하였다. 답변 생성 실패는 두 지표에 0점으로 포함하여 36문항 평균을 산출하였다. 시간은 실패를 포함한 실행 시간, 토큰은 답변 생성 과정의 전체 모델 호출 입력 · 출력 합계로 측정하였다.

LangSmith에 연결한 Claude Opus 4.6을 채점 모델로 사용하여, 공통 평가 기준에 따라 요구사항 충족률과 근거 일치율을 각각 평가하였다. 토큰 평균은 사용량 기록이 완전한 문항으로 산출하였으며, 채점 모델의 시간 · 토큰과 중단된 실행 시도의 사용량은 제외하였다.

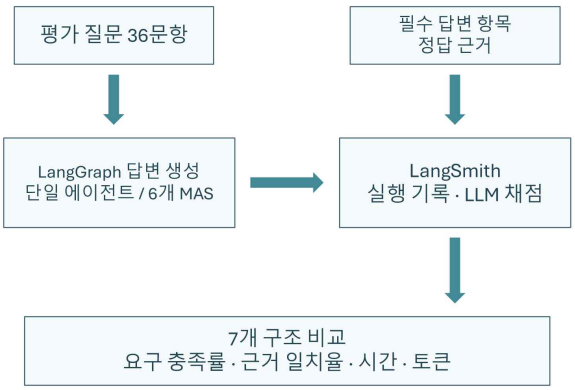


그림 3 LangSmith 기반 실험 및 평가 구성
Fig. 3 Experiment and evaluation with LangSmith

4.3 구조별 비교 결과

표 3에서 단일 에이전트는 요구 충족률 90.28%로 가장 높았다. 분산 상호 협력형은 단일 대비 근거 일치율이 3.22%p 높고 평균 시간이 10.3% 짧았으나, 평균 토큰은 15.1% 많고 요구 충족률은 13.89%p 낮았다. 협력 후 검토형은 근거 일치율이 75.61%로 가장 높았으며, 단일 대비 4.22%p 높았으나 평균 시간과 토큰은 각각 31.5%, 47.7% 증가하였다. 따라서 본 실험에서는 근거 일치율 개선이 요구 충족률이나 처리 비용의 개선으로 일관되게 이어지지는 않았다. 시간은 여러 실험을 병렬 실행한 환경에서 측정되었으며, 토큰 평균은 사용량 기록이 완전한 문항을 기준으로 비교하였다.

표 3 설계안별 평가 결과
Table 3 Evaluation results by architecture

설계안	답변 품질		처리 효율	
	요구 충족률 (%)	근거 일치율 (%)	시간 (s)	토큰 수
단일 에이전트	90.28	71.39	77.30	51,957
중앙 조정 · 병렬	83.36	71.53	75.09	57,915
순차 근거 전달	88.44	73.17	105.47	82,619
분산 상호 협력	76.39	74.61	69.36	59,798
계층적 조정	80.36	66.53	121.86	79,636
협력 후 검토	89.36	75.61	101.67	76,761
동적 작업 조정	81.28	68.39	103.06	88,924

주: 품질 · 시간은 전체 36문항의 평균이며, 답변 생성 실패는 품질 점수 0점으로 처리하였다.

4.4 실험의 한계

본 실험은 36문항에 대해 구조별로 한 번씩 실행하고, 단일 채점 모델로 평가하였다. 반복 실행에 따른 변동성과 신뢰구간을 확인하지 않았으므로, 관측된 차이만으로 구조별 우열을 확정하기 어렵다. 또한 여러 실험의 병렬 실행이 응답 시간에 영향을 주었을 수 있으며, 토큰 평균에 포함된 문항이 구조별로 달라 비교에 한계가 있다. 향후 질의 집합을 확대하고 반복 실험 및 복수 평가자를 통해 결과의 신뢰성을 검증할 필요가 있다.

V. 결론

본 연구는 소상공인 질의 36개에 대해 단일 에이전트와 여섯 가지 MAS 구조를 비교하였다. 단일 에이전트는 요구 충족률, 협력 후 검토형은 근거 일치율에서 가장 높았다. 본 평가셋에서는 복잡한 협업 구조가 모든 지표의 향상으로 이어지지 않았다. 소규모 · 단회 실행의 한계를 고려하여, 향후 반복 실험과 질의 유형별 분석으로 결과를 검증할 필요가 있다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] K.-T. Tran et al., "Multi-Agent Collaboration Mechanisms: A Survey of LLMs," arXiv preprint arXiv:2501.06322, 2025.

[2] L. Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," ACM Transactions on Information Systems, vol. 43, no. 2, pp. 1-55, 2025.

[3] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," Advances in Neural Information Processing Systems, vol. 33, 2020.

[4] Q. Wu et al., "AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation," Proceedings of the First Conference on Language Modeling, 2024.

[5] Y. Du, S. Li, A. Torralba, J. B. Tenenbaum, and I. Mordatch, "Improving Factuality and Reasoning in Language Models through Multiagent Debate," Proceedings of the 41st International Conference on Machine Learning, vol. 235, pp. 11733-11763, 2024.

[6] LangChain, "Evaluation types," LangSmith Documentation, https://docs.langchain.com/langsmith/evaluation-types, accessed Oct. 10, 2026.

4방향 시점 라벨 재구축 및 외형-자세 후기 결합을 통한 쇼핑몰 의류 이미지 시점 분류 연구

남기현, 채민선*, 최민**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 정보통신공학부

khnam@chungbuk.ac.kr, *mschae@cbnu.ac.kr, **mchoi@cbnu.ac.kr

Viewpoint Classification of Shopping-Mall Clothing Images via Four-Direction Label Reconstruction and Appearance-Pose Late Fusion

Kihyeon Nam, Min-Seon Chae*, Min Choi**

Department of Industrial AI, Chungbuk National University

*Industrial AI Research Center, Chungbuk National University

**School of Information and Communication Engineering, Chungbuk National University

Abstract

Online fashion retailers register product images taken from multiple viewpoints, but sorting them by viewpoint is still largely manual. Public datasets such as DeepFashion2 provide only coarse viewpoint labels that merge side and back views, and we found that 26.3% of its frontal labels are actually side views. We reconstruct torso-based four-direction labels (front, back, left, right) for 5,963 DeepFashion2 images, train ConvNeXt-Tiny classifiers with label-swapping horizontal flip augmentation, and fuse their ensemble with a keypoint-based pose classifier through late fusion. The fused model achieves 86.3% accuracy on the DeepFashion2 test set and 93.5% on 200 real shopping-mall images, 3.1 and 4.8 percentage points higher than a single appearance model. The reconstructed labels improve front/non-front accuracy over the original labels by 6.0 percentage points for ResNet50 and 6.7 for ConvNeXt-Tiny on DeepFashion2 (6.8 to 9.3 on the shopping-mall images), and on DeepFashion2, injecting 10% label noise reduces accuracy as much as discarding 75% of the clean labels.

Key words: Viewpoint Classification, Fashion Image, Label Reconstruction, Label Noise, Appearance-Pose Late Fusion

Ⅰ. 서 론

온라인 쇼핑몰은 상품마다 정면 · 후면 · 측면 등 여러 방향의 착용 이미지를 등록하며, 대표 이미지 선정과 상세페이지 배치를 위해 이를 방향별로 정렬해야 한다. 이 작업은 대부분 수작업으로 이루어져 상품 수가 많을수록 운영 비용이 증가한다.

딥러닝 기반 자동 분류를 위해서는 방향 라벨이 있는 학습 데이터가 필요하나, 대표적인 공개 의류 데이터셋인 DeepFashion2[1]는 시점을 '착용 안 함 / 정면 / 측면 또는 후면'의 3단계로만 제공하여 측면과 후면 및 좌 · 우를 구분할 수 없다. 사람의 몸 방향을 세분화하여 추정하는 연구[2]는 보행자 및 일반 인물을 대상으로 하여 쇼핑몰 의류 이미지에서는 검증되지 않았으며, 공개 데이터셋의 라벨 오류는 학습과 평가를 모두 왜곡할 수 있다.

본 논문에서는 DeepFashion2 이미지에 몸통 기준의 4방향(정면 · 후면 · 좌측면 · 우측면) 라벨을 직접 구축하고, 외형 기반 분류 모델과 관절기반 자세 모델을 결합하여 실제 쇼핑몰 이미지에서도 동작하는지 검증한다. 주요 기여는 다음과 같다. 첫째, DeepFashion2 시점 라벨의 오류를 정량화하고 라벨 노이즈 주입 시험으로 그 영향을 분석하였다. 둘째, 명확한 기준의 4방향 라벨 5,963장을 구축하고 그 효과가 모델에 관계없이 유지됨을 보였다. 셋째, 외형 모델과 자세 모델의 오류가 상호보완적임을 확인하고 두 모델을 결합하여 실제 쇼핑몰 이미지에서 93.5%의 정확도를 달성하였다.

Ⅱ. 본론

1. 4방향 라벨 구축

DeepFashion2 학습 셋에서 시점 라벨이 정면인 이미지와 측면 · 후면인 이미지를 각 3,000장 무작위로 추출하여 직접 라벨링 하였다. 판단 기준은 인물의 몸통(가슴 · 어깨선) 방향이며, 어깨 폭이 정면 대비 절반 이하(약 60° 이상 회전)로 보이면 측면으로 판단하고 인물의 왼쪽 몸이 보이면 좌측면으로 정의하였다. 판단이 불가능한 37장(0.6%)을 제외한 5,963장(정면 2,442, 좌측면 1,386, 우측면 1,075, 후면 1,060)을 사용하였다. 구축한 라벨과 비교한 결과 DeepFashion2 '정면' 라벨의 26.3%가 실제로는 측면이었으며, 정면/비정면 기준 일치율은 82.4%로 기존 라벨을 그대로 사용하기 어려움을 확인하였다. 또한 '측면 · 후면' 라벨은 후면 35.2%, 좌측면 31.4%, 우측면 24.9%, 정면 8.5%가 혼재되어 있었다.

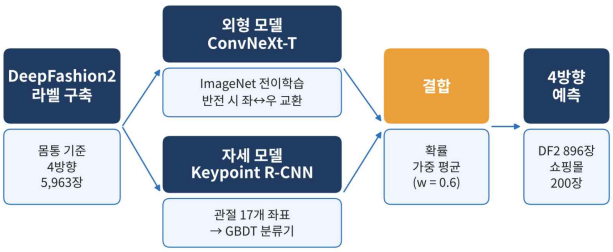
2. 외형-자세 결합 분류 모델

그림 1과 같이 외형 모델과 자세 모델의 예측을 결합한다. 외형 모델은 ImageNet[3]으로 사전학습된 ConvNeXt-Tiny[4]를 전이 학습하며, 비교를 위해 ResNet50[5]도 동일 조건으로 학습하였다. 좌우 반전 증강 시 좌측면과 우측면이 뒤바뀌므로, 식 (1)과 같이 이미지 x를 반전 h(x)할 때 라벨 y도 좌↔우 교환 함수 s(·)로 변환하였다(정면 · 후면은 유지).

$$(\tilde{x},\tilde{y}) = (h(x), s(y)) \tag{1}$$

자세 모델은 COCO로 사전학습된 Keypoint R-CNN[6]으로 17개 관

절의 좌표와 신뢰도를 추출하고, 인물 영역으로 정규화한 51차원 특징으로 그래디언트 부스팅 분류기를 학습한다. 최종 예측은 식 (2)와 같이 두 모델의 클래스 확률을 가중 평균하는 후기 결합으로 구하며, 가중치 w는 검증셋에서 0.6으로 결정하였다.



$$p = w \cdot p_A + (1-w) \cdot P_p \qquad (2)$$

그림 1 제안 방법의 전체 구조
Fig. 1 Overall structure of the proposed method

데이터는 같은 의류가 학습과 평가에 중복되지 않도록 의류 단위로 학습 4,170장, 검증 897장, 평가 896장으로 분할하였다. AdamW[11](학습률 1×10^{-4}), 배치 크기 32, 최대 30 epoch, 검증 Macro F1 기준 조기 종료를 적용하였고, seed를 달리한 3회 학습의 평균±표준편차를 보고하였다. 외부 검증을 위해 국내 쇼핑몰 의류 이미지 200장(방향별 50장)을 동일 기준으로 분류하여 평가셋으로 사용하였으며, 결합에는 3개 외형 모델의 확률 평균(앙상블)을 사용하였다.

3. 실험결과

표 1 방법별 4방향 분류 정확도 (%)
Table 1 Four-direction accuracy by method (%)

방법	DF2 평가셋	쇼핑몰
관절 규칙 기반	66.85	72.00
자세 모델 (관절+GBDT)	81.70	90.00
ResNet50	80.99±1.15	85.67±4.25
ConvNeXt-T	83.15±0.78	88.67±1.15
ConvNeXt-T 앙상블	84.26	91.00
외형-자세 결합 (제안)	86.27	93.50

좌·우 판별 능력은 식 (3)의 좌↔우 혼동률로 측정하였다. 여기서 $N_{A\to B}$는 실제 A를 B로 예측한 수, N_A는 실제 A의 수이며 L, R은 좌측면과 우측면이다.

$$R_{LR} = \frac{N_{L\to R} + N_{R\to L}}{N_L + N_R} \qquad (3)$$

표 1에서 관절 규칙 기반 방법(어깨 폭·좌우 순서로 판별)은 66.85%에 그쳐 몸통의 부분 회전을 구분하기 어려웠으나, 구축 라벨로 학습한 모델은 관절만 사용해도 81.70%에 도달하였다. ConvNeXt-Tiny는 ResNet50보다 2.2%p 높고 좌↔우 혼동률도 0.73%로 낮았다. 외형 모델과 자세 모델은 DF2 평가셋에서 각각 86장, 63장을 단독으로 맞혀 상호보완적이었으며, 이를 결합하면 86.27%(쇼핑몰 93.50%)로 단일 외형 모델 대비 3.1%p(4.8%p) 향상되고 좌↔우 혼동률은 0.28%로 감소하였다. 두 모델이 모두 틀린 78장 중 87%는 같은 오답이어서, 남은 오류는 몸통이 부분 회전한 모호한 사례에 집중되었다. 방향별로는 우측면이 가장 낮았으며(쇼핑몰 결합 82%) 주로 정면으로 오분류되었다.

표 2 어블레이션 실험 결과 (%, ResNet50 / ConvNeXt-T)
Table 2 Ablation study results (%, ResNet50 / ConvNeXt-T)

구분	설정	DF2	쇼핑몰
학습 라벨 (정면/비정면)	DF2 원래 라벨	76.49 / 78.50	86.00 / 83.83
	구축 라벨	82.51 / 85.19	92.83 / 93.17
좌우 반전 (4분류)	반전 없음	78.79 / 81.62	79.17 / 86.33
	반전, 라벨 유지	63.69 / 67.04	63.50 / 63.33
	반전, 라벨 교환	80.99 / 83.15	85.67 / 88.67
사전학습	사용 안 함 (4분류)	38.28 / 38.99	29.17 / 25.83

표 2와 같이 구축 라벨로 학습하면 DeepFashion2 원래 라벨 대비 정면/비정면 정확도가 6.0~6.7%p(쇼핑몰 6.8~9.3%p) 높았다. 반전 시 라벨을 교환하지 않으면 좌↔우 혼동률이 약 35%로 증가하였고 사전학습 없이는 성능이 크게 저하되었으며, 이러한 경향은 두 모델에서 동일하였다. 또한 학습 라벨의 10%만 오염시켜도 정확도가 77.86%로 떨어져, 오염 없는 라벨을 25%(1,042장)만 사용한 결과와 같았다.

Ⅲ. 결론

본 논문에서는 공개 데이터셋 시점 라벨의 한계를 정량적으로 확인하고 몸통 기준 4방향 라벨 5,963장을 구축하였으며, 외형 모델과 관절 기반 자세 모델을 결합하여 DeepFashion2 평가셋 86.3%, 실제 쇼핑몰 이미지 93.5%의 정확도를 달성하였다. 구축 라벨의 효과는 모델에 관계없이 유지되었고, 라벨 노이즈 실험으로 정확한 라벨의 가치를 정량적으로 확인하였다. 향후 재라벨링 일치율 검증, 쇼핑몰 평가셋 확대, 최신 자세 추정 모델 적용을 통해 정면·측면 경계의 오류를 개선하고자 한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Y. Ge, R. Zhang, X. Wang, X. Tang, and P. Luo, "DeepFashion2: A Versatile Benchmark for Detection, Pose Estimation, Segmentation and Re-Identification of Clothing Images," Proc. CVPR, 2019.

[2] J. Zhao, H. Ye, Y. Zhan, H. Luan, and H. Zhang, "Human Orientation Estimation under Partial Observation," Proc. IROS, 2024.

[3] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "ImageNet: A Large-Scale Hierarchical Image Database," Proc. CVPR, 2009.

[4] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A ConvNet for the 2020s," Proc. CVPR, 2022.

[5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," Proc. CVPR, 2016.

[6] K. He, G. Gkioxari, P. Piotr Dollar, and R. Girshick, "Mask R-CNN," Proc. ICCV, 2017.

외란 광원 환경에서의 딥러닝 기반 고정밀 화재 감지 시스템

곽소영, 김영진*, 최민**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 정보통신공학부

sykwak@chungbuk.ac.kr, *you359@chungbuk.ac.kr, **mchoi@chungbuk.ac.kr

Deep Learning-Based High-Precision Fire Monitoring System under Interfering Light Sources

Soyoung Kwak, Yoo-shin Kim*, Min Choi**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**School of Information and Communication Engineering, Chungbuk National Univ

Abstract

경광등, 용접 아크광, 반사광 등 광학 외란은 산업 현장의 영상 기반 화재 감지에서 오경보를 유발한다. 본 논문은 YOLOv8 후보 탐지, ROI 추적 · 동적 크롭, CNN-LSTM 시계열 검증으로 구성된 2-Stage 파이프라인을 제안하고 영상 단위 5-fold 교차검증으로 평가한다. 화재 영상 20개와 비화재 영상 41개에서 Stage 1 단독 대비 비화재 영상 오경보율은 53.8%에서 10.3%로 감소하였고 시드 3개의 평균은 7.7%였으며 화재 검출률은 95%를 유지하였다. SSIM 시계열의 주기성 지표는 화재와 외란을 유의하게 구분하지 못해, 단순 주기성이 아닌 학습된 시공간 특징이 기여함을 확인하였다. 프레임당 연산 시간은 평균 8.7~17.7 ms이다.

Key words : Fire Detection, Optical Interference, False Alarm Reduction, YOLOv8, CNN-LSTM

Ⅰ. 서 론

스마트 팩토리와 자동화 물류 현장이 확산되면서 CCTV 영상을 이용한 상시 화재 감시가 중요해지고 있다. 화재 감지는 색상 · 형태 · 움직임 규칙을 결합한 방법[1]에서 CNN과 YOLO 계열 탐지기를 적용한 방법[2, 3]까지 연구되어 왔다. 그러나 AGV나 지게차의 경광등, 용접 아크광, 투광등, 반사광처럼 화염과 색 · 밝기가 비슷한 광학 외란이 상시 존재하는 산업 현장에서는 단일 프레임 탐지기가 이를 화염으로 오인해 오경보를 일으키기 쉽다.

Venâncio 등은 CNN으로 화재 후보를 찾은 뒤 후보의 시간적 변화를 분석하는 2단계 구조로 감시 영상의 오탐을 줄였다[4]. 본 논문은 이를 산업 외란 환경에 적용하여 YOLOv8 후보 탐지, ROI 추적 및 크롭, CNN-LSTM 검증의 파이프라인을 제안하고 지속성 필터와 시계열 모델의 효과를 영상 단위로 분리 평가한다.

Ⅱ. 본 론

1. 2-Stage 시공간 검증 기반 화재 감지 방법

그림 1과 같이 Stage 1 YOLOv8n[5]이 10 FPS 영상에서 신뢰도 0.4 이상의 화재와 연기 후보 박스를 탐지하고, IoU 기반 추적기가 객체별 트랙으로 연결해 ROI를 128×128로 동적 크롭한다. 추적기는 박스가 30% 이상 겹치면 같은 객체로 잇고 탐지가 끊겨도 1초간 트랙을 유지한다. 한 트랙에 ROI가 30프레임, 즉 3초 분량 쌓이면 CNN이 프레임별 공간 특징을, LSTM[6]이 시간 특징을 학습해 화재 확률을 출력하고, 0.75 이상이면 화재로 판정한다. 3초 미만으로 사라지는 점멸 후보는 Stage 2로 전달되지 않는다.

2. 실험 구성

Stage 1은 D-Fire 21,527장으로 학습하였고 test mAP50은 0.758이다. Stage 2 평가에는 FIRESENSE[7]와 YouTube 영상 61개를 사용하였으며 화재 영상 20개, 비화재 영상 41개로 이루어진다. 같은 영상의 클립이 학습과 시험에 섞이지 않도록 영상 단위 층화 5-fold 교차검증을 수행하였으며, 실제 화염인 벽난로와 가스 토치는 주 지표에서 분리해 보고한다. 지표는 영상 단위 화재 검출률과 비화재 영상 오경보율이고 95% 신뢰구간은 영상 부트스트랩으로 구하였고, RTX 5070 Laptop GPU에서 PyTorch로 측정하였다. Stage 2의 하이퍼파라미터는 AdamW 학습률 1e-3, 배치 16, LSTM 은닉 64, 드롭아웃 0.5로 고정하고 최대 50 epoch로 학습하였으며 민감도를 따로 분석하였다.

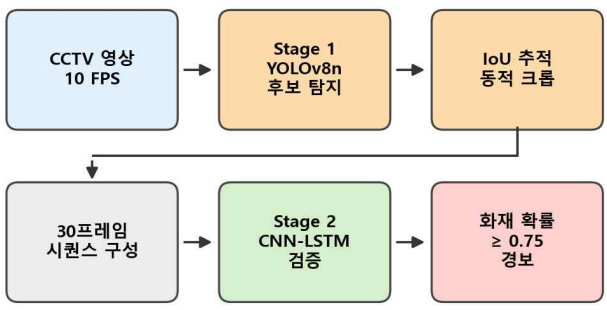


그림 1 제안하는 2-Stage 화재 감지 파이프라인

Fig. 1 Proposed 2-stage fire detection pipeline

3. 결과 및 분석

(1) 시스템 단위 성능

표 1과 같이 Stage 1 단독은 모든 화재를 검출하지만 비화재 영상의 53.8%에서 오경보를 일으켰다. 지속성 필터를 더하면 30.8%, Stage 2까지 적용하면 10.3%로 감소하였고 화재 검출률은 95%를 유지하였다. 마지막 행은 확률 0.75 이상이 3회 연속일 때만 경보하는 보수적 판정이다. 시드 3개의 평균 오경보율은 7.7±2.6%p이고 Stage 2의 순수 기여는 20.5%p이다. 규칙 기반 판별기의 영상 단위 AUC는 0.58로 CNN-LSTM의 0.85보다 낮았다.

표 1 시스템 단위 성능 (비화재 주 집합 39개 영상)

Table 1 System-level performance

방법	화재 검출률	비화재 오경보율[95% CI]	지연 (s)
Stage 1 단독	100% (20/20)	53.8% [38,69]	0.2
+ 지속성 필터	100% (20/20)	30.8% [18,46]	2.9
+ Stage 2 (제안)	95.0% (19/20)	10.3% [3,21]	3.5
+ Stage 2 (3회)	85.0% (17/20)	2.6% [0,8]	5.0

(2) 시퀀스 길이와 시간 특성

입력 시퀀스 길이를 10, 20, 30프레임으로 늘리면 오경보율은 23.1%, 12.8%, 10.3%로 감소하지만 경보까지 걸리는 시간의 중앙값은 1.0초, 3.0초, 3.5초로 길어져, 그림 2와 같이 상충 관계가 있다. 시간 처리 모듈을 평균 풀링, GRU, Transformer로 바꾸면 화재 검출률은 모두 85%로 LSTM의 95%보다 낮았고 영상 단위 AUC도 0.79에서 0.83으로 LSTM의 0.85보다 낮았다. 학습률과 은닉 크기를 바꾸면 검출률은 75%에서 95%, 오경보율은 5.1%에서 10.3%였다. SSIM의 주기성은 화재와 비화재를 유의하게 구분하지 못하여 AUC 0.61, p값 0.19였고 학습된 시공간 특징이 기여한 것으로 해석된다.

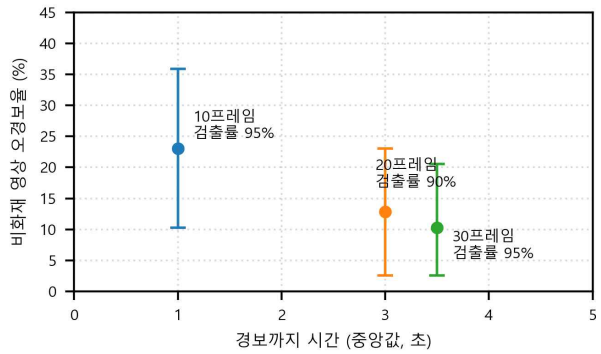


그림 2 시퀀스 길이별 오경보율과 경보 지연

Fig. 2 False alarm rate versus alarm delay by sequence length

(3) 연산 효율과 한계

프레임당 연산 시간은 평균 8.7~17.7 ms로 10 FPS 입력을 실시간 처리할 수 있다. 그림 3과 같이 카테고리별로는 AGV, 투광등, 스트로브, 아크 용접, 반사광, 일반 장면에서 오경보가 없었고, 남은 4건은 회전 경광등, 지게차 경광등, 햇빛 LED, 공장 공사 영상이다. 영상 수가 61개로 제한적이어서 신뢰구간이 넓으므로, 향후 실제 산업 현장 CCTV 영상으로 검증 범위를 확대할 계획이다.

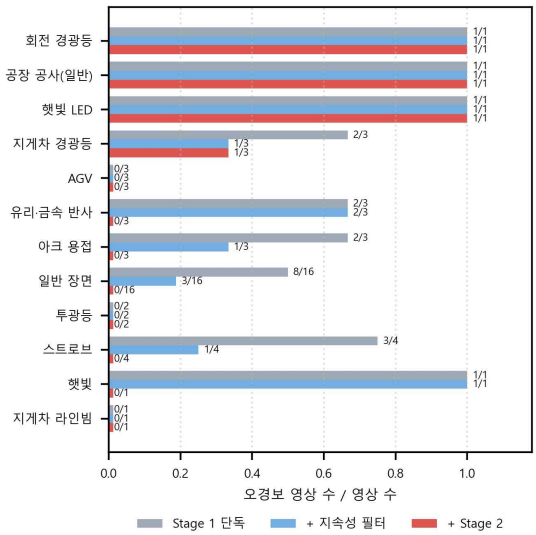


그림 3 카테고리별 오경보 영상 수 (통제된 불꽃 제외)

Fig. 3 False-alarm videos by interference category

Ⅲ. 결 론

본 논문은 YOLOv8 후보 탐지와 CNN-LSTM 시계열 검증의 2-Stage 파이프라인으로 오경보율을 53.8%에서 10.3%로 낮추면서 화재 검출률 95%를 유지하였으며, 향후 실제 CCTV 데이터로 검증할 예정이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] P. Foggia et al., "Real-time fire detection for video-surveillance applications using a combination of experts based on color, shape, and motion," IEEE Trans. Circuits Syst. Video Technol., 2015.

[2] P. V. A. B. de Venâncio et al., "An automatic fire detection system based on deep convolutional neural networks for low-power, resource-constrained devices," Neural Comput. Appl., 2022.

[3] K. Muhammad et al., "Convolutional neural networks based fire detection in surveillance videos," IEEE Access, vol. 6, pp. 18174-18183, 2018.

[4] P. V. A. B. de Venâncio et al., "A hybrid method for fire detection based on spatial and temporal patterns," Neural Comput. Appl., vol. 35, no. 13, pp. 9349-9361, 2023.

[5] G. Jocher et al., "Ultralytics YOLOv8," 2023. [Online]. Available: https://github.com/ultralytics/ultralytics

[6] S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Comput., vol. 9, no. 8, pp. 1735-1780, 1997.

[7] FIRESENSE database of videos for flame and smoke detection, Zenodo, 2017. https://zenodo.org/records/836749

멀티카메라 보행자 재식별에서의 배경 편향 분석 및 완화 기법에 관한 연구

추정원, 채민선*, 문성태**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 지능로봇공학과

ykchu@chungbuk.ac.kr, *mschae@cbnu.ac.kr, **stmoon@cbnu.ac.kr

Background Sensitivity Analysis and Feature Consistency-Based Mitigation for Multi-Camera Person Re-Identification

JeongWon Chu, Min-Seon Chae*, Sung-Tae Moon**

Department Of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

This study investigates the sensitivity of a CLIP-ReID model to background context changes in multi-camera person re-identification (Re-ID) and compares learning strategies for mitigating such sensitivity. CLIP-ReID can leverage generalized representations learned from vision-language pretraining; however, because its image representation reflects the overall visual context, non-identity cues such as background, location, illumination, and camera viewpoint may be incorporated into the learned features together with person-specific characteristics. In this study, a CLIP-ReID ViT-B/16 baseline model was trained on the MSMT17 dataset, and its performance was evaluated under six background manipulation conditions: Original, BG-blur, Foreground-only, Query-swap, Gallery-swap, and Both-swap. The baseline achieved 71.1% mAP and 87.3% Rank-1 accuracy under the Original condition, whereas performance dropped substantially to 22.4% mAP and 46.7% Rank-1 under the Both-swap condition, in which the backgrounds of both query and gallery images were replaced. These results demonstrate that CLIP-ReID is highly sensitive to changes in background context. As mitigation strategies, BG-swap Augmentation and Feature Consistency Loss were compared. BG-swap Augmentation improved Both-swap mAP to 51.4%, demonstrating a strong adaptation effect; however, this improvement also reflects the effects of increased training data and direct exposure to the background-replacement distribution. In contrast, Feature Consistency Loss maintained the Original mAP at 71.1% while improving Both-swap mAP to 33.0% and Both-swap+Blur mAP to 37.4%, indicating that feature-level background invariance can be encouraged without degrading performance on the original data. The significance of this study lies in quantitatively characterizing the sensitivity of CLIP-ReID to background context changes and comparatively analyzing the adaptation effect of data augmentation and the feature-alignment effect of consistency-based learning.

Keywords: Person Re-Identification, CLIP-ReID, Background Sensitivity, Feature Consistency Loss, Multi-Camera Surveillance

Ⅰ. 서 론

보행자 재식별은 서로 다른 카메라에서 촬영된 동일 인물을 식별하는 기술로, 공공안전, 스마트시티, 교통관제, 출입통제, 실종자 수색 등 다중 CCTV 기반 지능형 영상분석 분야에서 중요성이 커지고 있다. 기존 Re-ID 연구는 CNN 기반 지역 특징 학습[1], Transformer 기반 전역 문맥 학습[2], 그리고 최근의 비전-언어 사전학습 기반 표현 학습으로 발전해 왔다. 특히 CLIP은 대규모 이미지-텍스트 사전학습을 통해 일반화된 시각 표현을 제공하며[3], CLIP-ReID는 ID별 learnable text token을 활용하여 CLIP의 시각 표현을 Re-ID 문제에 전이한다.[4] 이러한 방식은 기존 CNN 기반 Re-ID보다 풍부한 의미 표현을 활용할 수 있다는 장점이 있으나, 이미지 전체의 문맥 정보를 강하게 반영하는 CLIP의 특성상 인물 고유 특징뿐 아니라 배경, 장소, 조명, 카메라 시점과 같은 비식별 단서가 feature에 함께 반영될 가능성이 있다.

실제 멀티카메라 Re-ID 환경에서는 동일 인물이 서로 다른 카메라, 조명, 시점, 배경에서 관측되므로, 모델은 배경이나 장소가 아닌 인물의 의복, 체형 등 ID-relevant feature에 기반하여 동일 인물 여부를 판단해야 한다. 그러나 학습 데이터에서 특정 ID가 특정 카메라나 배경과 함께 반복적으로 등장할 경우, 모델은 사람 자체의 특징보다 배경 문맥이나 카메라 환경과 같은 ID-irrelevant feature에 의존할 수 있다. 이 경우 동일 인물이라도 배경이 바뀌면 다른 인물로 잘못 판단하는 미탐이 발생할 수 있고, 서로 다른 인물이라도 유사한 배경에서 촬영되면 동일 인물로 오인할 수 있다. 특히 CLIP-ReID와 같이 이미지 전체의 의미적 문맥을 활용하는 모델에서는 배경 정보가 인물 표현에 혼입될 가능성이 있으므로, 배경 변화에 따른 성능 저하를 정량적으로 분석하고 이를 완화하는 방법이 필요하다.

본 연구는 CLIP-ReID 기반 보행자 재식별 모델의 배경 편향을 분석하고, 배경 변화에 강건한 인물 표현을 학습하기 위한 방법을 비교한다. 먼저 MSMT17 데이터셋에서 CLIP-ReID ViT-B/16 baseline을 학습한 뒤, 기존 배경 편향 관련 연구[8]를 참고하여, 본 연구에서는 Original, BG-blur, Foreground-only, Query-swap, Gallery-swap,

Both-swap 조건을 구성하고 배경 조작에 따른 성능 변화를 측정하였다.

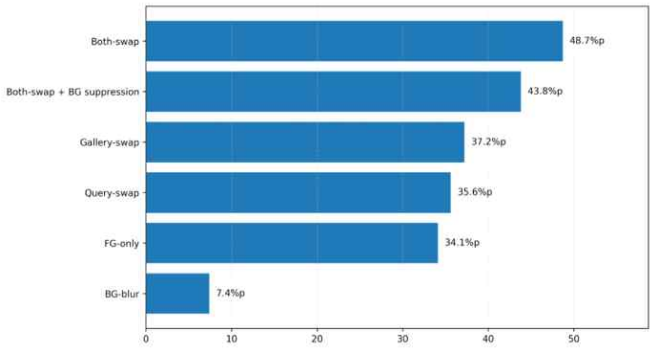


그림 1 mAP Drop으로 본 배경 민감도
Fig. 1 Background Sensitivity Measured by mAP Drop

그 결과 baseline은 Original 조건에서 mAP 71.1%, Rank-1 87.3%를 기록하였으나, query와 gallery의 배경을 모두 교체한 Both-swap 조건에서는 mAP 22.4%, Rank-1 46.7%로 크게 하락하였다. 이후 BG-swap Augmentation과 Feature Consistency Loss를 각각 적용하여 완화 효과를 분석하였다. BG-swap Augmentation은 Both-swap mAP를 51.4%까지 향상시켜 배경 교체 분포에 대한 강한 적응 효과를 보였으나, 학습 데이터가 증가하고 배경 교체 분포를 직접 학습한다는 점에서 근본적인 배경 불변성 학습으로 보기는 어렵다. 반면 Feature Consistency Loss는 원본 이미지와 배경 교체 이미지의 feature를 직접 정렬하여 Original mAP를 71.1%로 유지하면서 Both-swap 및 Both-swap+Blur 조건의 성능을 점진적으로 개선하였다. 본 연구의 주요 기여는 CLIP-ReID의 배경 민감도를 정량적으로 확인하고, 데이터 증강 기반 적응 효과와 feature consistency 기반 배경 불변 학습의 가능성을 비교 분석한 데 있다.

Ⅱ. 본론

1. 제안 방법

본 연구는 CLIP-ReID의 재식별 성능이 배경 문맥 변화에 얼마나 민감한지를 정량적으로 분석하고, 이를 완화하기 위한 학습 방법의 효과를 비교한다. 전체 절차는 CLIP-ReID baseline 학습, 배경 조작 데이터 생성, 배경 민감도 평가, 완화 학습, 최종 성능 비교의 순서로 구성된다. 먼저 MSMT17 데이터셋을 이용하여 ViT-B/16 기반 CLIP-ReID를 학습한 후, 사전학습된 segmentation 모델[5]을 이용하여 person mask를 추출하고 인물 전경과 배경을 분리한다. 이후 배경 blur, 전경만 유지하는 Foreground-only, 다른 이미지의 배경으로 교체하는 BG-swap 조건을 구성하여 입력 배경 변화에 따른 재식별 성능 변화를 분석한다.

BG-blur는 전경을 유지하면서 배경 영역만 blur 처리한 조건이며, Foreground-only는 배경을 제거하고 인물 영역만 유지한 조건이다. BG-swap은 대상 영상의 전경과 다른 영상에서 추출한 배경을 합성하여 배경 문맥을 변경한 조건이다.

$$\Delta_{bg}(c) = mAP_{original} - mAP_c \quad (1)$$
$$c \in \{BG-blur, FG-only, Query-swap, Gallery-swap, Both-swap\}$$

배경 조작에 따른 성능 변화는 Original 조건과 조작 조건 간 mAP 차이인 mAP Drop for Background Sensitivity Analysis로 측정하며, 수식 (1)에 의한 mAP Drop값이 클수록 모델이 배경 변화에 민감하다는 것을 의미한다. 값이 클수록 배경 변화에 대한 모델의 민감도가 높은 것으로 해석한다.

첫 번째 방법인 BG-swap Augmentation은 원본 학습 영상과 배경 교체 영상을 함께 사용하여 모델이 다양한 배경 조건을 직접 경험하도록 하는 방법이다. 이 방법은 배경 교체 조건에 대한 적응 성능을 크게 향상시킬 수 있으나, 학습 데이터 증가와 합성 영상 분포에 대한 직접적인 노출 효과가 포함된다. 따라서 본 연구에서는 이를 배경 변화에 대한 강한 augmentation 기반 baseline으로 활용한다.

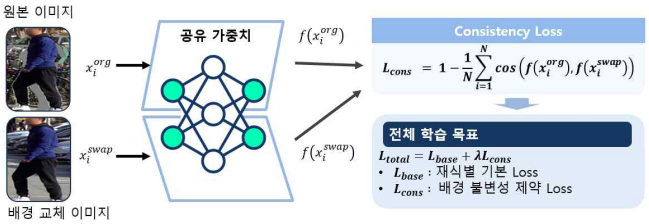


그림 2 전체 학습 목표 구성
Fig. 2 Overall Training Objective

두 번째 방법인 Feature Consistency Loss는 동일한 인물의 원본 영상과 배경 교체 영상에서 추출된 feature가 서로 유사하도록 학습하는 방법이다.

$$L_{cons} = 1 - \frac{1}{N}\sum_{i=1}^{N} \cos\left(f(x_i^{original}), f(x_i^{BG-swap})\right) \quad (2)$$

원본 영상 $x_i^{original}$과 배경 교체 영상 $x_i^{BG-swap}$에서 추출한 feature를 각각 f_i, f'_i라 할 때, 두 feature 간 cosine similarity를 이용하여 consistency loss를 수식 (2) 와 같이 정의하였다. 두 feature가 가까워질수록 loss가 감소하도록 구성함으로써, 배경이 변경되더라도 동일 인물의 표현이 유지되도록 유도하였다.

$$L_{total} = L_{id} + L_{triplet} + L_{i2t} + \lambda_{cons} L_{cons} \quad (3)$$

전체 학습 손실은 수식 (3)과 같이 기존 CLIP-ReID에서 사용하는 ID loss, triplet loss[6] 및 image-text alignment 계열 손실과 consistency loss의 결합으로 그림 2 와 같이 구성하였다. 이때 consistency loss의 가중치는 λ_{cons}로 설정하며, 기본 실험에서는 λ_{cons}는 1.0으로 적용하였다.

2. 실험

실험은 MSMT17[9] 데이터셋을 사용하였다. 학습 데이터는 1,041명의 ID와 32,621장의 영상으로 구성되며, 평가에는 query 11,659장과 gallery 82,161장을 사용하였다. 전체 데이터는 15개의 카메라 환경을 포함한다. Backbone은 CLIP-ReID ViT-B/16을 사용하였으며 입력 영상은 256×128 크기로 resize하였다. Optimizer는 AdamW, batch size는 64로 설정하였고, Stage 2는 60 epoch 동안 학습하였다. 성능 평가는 mAP와 Rank-1을 중심으로 수행하였다.

BG-swap 학습과 평가에서 동일한 배경이 사용되는 것을 방지하기 위해 배경 풀을 데이터 분할에 따라 분리하였다. 학습용 BG-swap 영상은 MSMT17 train 데이터에서 추출된 배경으로 생성하였으며, 평가용 배경 교체 영상은 test의 query 및 gallery에서 별도로 구성하였다. 따라서 학습과 평가 단계에서 학습용 배경 풀과 평가용 배경 풀 간 영상 중복이 발생하지 않도록 구성하였다. 보완실험에서도 학습용과 평가용 BG-swap 배경 풀이 분리되어 있음을 확인하였다.

그림 1에 나타낸 바와 같이 Baseline은 Original 조건에서 mAP 71.1%, Rank-1 87.3%를 기록하였다. 배경만 blur한 경우 mAP는 63.7%로 비교적 제한적인 감소를 보였으나, Foreground-only에서는 37.0%, query와

gallery의 배경을 모두 교체한 Both-swap에서는 22.4%까지 감소하였다. Query-swap과 Gallery-swap에서도 각각 mAP 35.5%, 33.9%로 큰 성능 저하가 나타났다.

배경 교체 성능 저하가 합성 경계나 색감 차이와 같은 합성 흔적만으로 발생하는지 확인하기 위해, 동일 카메라 및 유사 촬영 조건에서 추출한 배경을 이용한 추가 대조실험을 수행하였다.

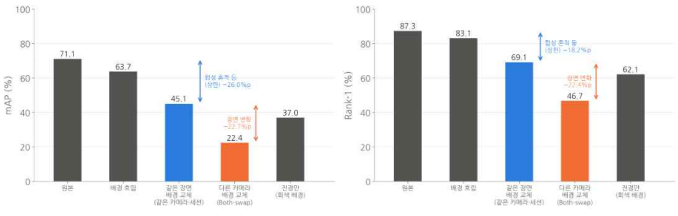


그림 3 배경 조작 조건별 Baseline 성능

Fig. 3 Baseline Performance under Background Manipulation Conditions

해당 조건에서 Baseline mAP는 그림 3에서 나타낸 바와 같이 45.1%로 Original 71.1%보다 26.0%p 감소하였으나, 완전히 다른 배경을 적용한 Both-swap의 22.4%보다는 높은 성능을 보였다. 이는 합성 자체에 의한 성능 감소가 일부 존재하지만, 배경 문맥의 변화 정도가 커질수록 추가적인 성능 하락이 발생함을 보여준다. 따라서 본 연구에서는 이러한 결과를 특정 배경에 대한 직접적인 의존성으로 단정하기보다, CLIP-ReID가 배경을 포함한 주변 시각 문맥 변화에 높은 민감도를 보이는 것으로 해석한다.

그림 4의 Query-swap과 Gallery-swap의 mAP는 각각 35.5%, 33.9%로 유사하였으나 Rank-1은 각각 48.2%, 69.4%로 큰 차이를 보였다. 이는 query와 gallery가 검색에서 수행하는 역할의 차이와 관련된다. Query의 배경이 변경되면 검색의 기준점이 되는 query feature 자체가 변화하여 모든 gallery와의 유사도 순위에 영향을 준다.

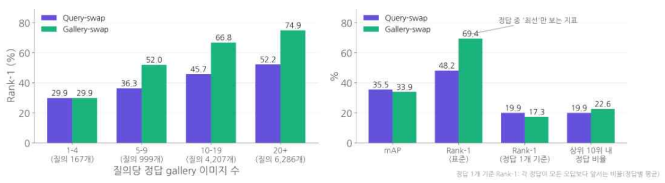


그림 4 정답 Gallery 수에 따른 Query-swap과 Gallery-swap의 Rank-1 비교

Fig. 4 Rank-1 Comparison between Query-Swap and Gallery-Swap by the Number of Correct Gallery Matches

반면 Gallery-swap에서는 원본 query가 유지되며, 동일 ID에 여러 개의 gallery 영상이 존재할 경우 그중 하나가 높은 순위를 유지할 가능성이 있다. 그림 4에서처럼 실제로 동일 ID의 gallery 영상 수가 1~4장인 경우 두 조건의 Rank-1 차이는 거의 없었으나, 20장 이상인 경우 Query-swap 52.2%, Gallery-swap 74.9%로 차이가 확대되었다. 이는 Gallery-swap의 높은 Rank-1이 복수의 정답 gallery가 존재하는 Re-ID 평가 구조의 영향을 받음을 보여준다.

표 1 완화 방법별 성능 비교

Table 1 Performance Comparison of Mitigation Methods

Model	Org mAP (%)	Org Rank-1 (%)	Both swap mAP (%)	Both swap Rank-1 (%)	Both swap+blur mAP (%)
Baseline	71.1	87.3	22.4	46.7	27.3
Aug-Baseline	67.4	85.7	51.4	75.5	51.0
Ours	**71.1**	**87.3**	**33.0**	**58.6**	**37.4**

표 1은 비교군에 대한 실험 결과를 나타낸다. BG-swap Augmentation은 Both-swap 조건에서 mAP를 Baseline 22.4%에서 51.4%로 크게 향상시켰으나 Original mAP는 71.1%에서 67.4%로 감소하였다. 반면 Feature Consistency Loss를 적용한 모델은 Original mAP 71.2%를 유지하면서 Both-swap mAP를 33.0%, Both-swap+Blur mAP를 37.4%로 향상시켰다. 따라서 BG-swap Augmentation은 합성 분포에 대한 직접적인 적응 효과가 큰 방법인 반면, Feature Consistency Loss는 원본 성능을 유지하면서 배경 변화에 대한 feature 일관성을 높이는 방법으로 해석할 수 있다.

단일 실행 결과의 변동성을 확인하기 위해 서로 다른 학습 seed를 사용하여 3회 반복실험을 수행하였다. Baseline의 Both-swap mAP는 22.6±0.4%였으며, Feature Consistency Loss를 적용한 모델은 λ_{cons} 값이 0.1일때 27.3±0.2%, λ_{cons} 값이 1.0일때 33.2±0.2%를 기록하였다. 특히 λ_{cons} 값을 1.0으로 진행했을 시에는 Baseline 대비 평균 10.6%p의 성능 향상을 보였으며, Original mAP는 71.1±0.1%로 유지되었다. 이는 Feature Consistency Loss의 개선 효과가 서로 다른 학습 seed에서도 일관되게 나타남을 보여주며, 원본 재식별 성능을 유지하면서 배경 변화에 대한 강건성을 개선할 수 있음을 뒷받침한다.

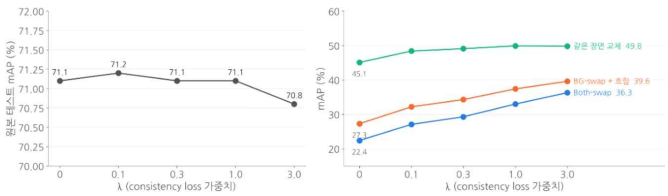


그림 5 가중치별 민감도 실험 결과

Fig. 5 Sensitivity Analysis Results for Different λ Values

추가로 consistency loss의 가중치 λ에 대한 민감도 실험을 수행하였다. λ를 0에서 0.1, 0.3, 1.0, 3.0으로 증가시킬수록 Both-swap mAP는 22.4%에서 27.1%, 29.3%, 33.0%, 36.3%로 지속적으로 향상되었다. 반면 λ를 3.0으로 한 실험에서는 Original mAP가 70.8%로 소폭 감소하였다. 그림 5에서 보이듯이 이는 consistency 제약을 강화할수록 배경 변화 강건성이 향상되는 반면, 지나치게 큰 가중치는 원본 영상의 판별 성능과의 trade-off를 발생시킬 수 있음을 보여준다. 본 연구에서는 Original 성능을 유지하면서 Both-swap 성능이 충분히 개선된 λ값 1.0을 기본값으로 선정하였다.

Ⅲ. 결론

본 연구는 CLIP-ReID 기반 보행자 재식별 모델의 성능이 배경 문맥 변화에 얼마나 민감한지를 배경 조작 실험을 통해 정량적으로 분석하고, 이를 완화하기 위한 BG-swap Augmentation과 Feature Consistency Loss의 효과를 비교하였다. Baseline은 Original 조건에서 mAP 71.1%, Rank-1

87.3%를 기록하였으나, query와 gallery의 배경을 모두 교체한 Both-swap 조건에서는 mAP 22.4%, Rank-1 46.7%로 크게 감소하였다. 또한 동일 카메라 및 유사 촬영조건의 배경으로 교체한 대조실험에서도 mAP가 45.1%로 감소하였으며, 완전히 다른 배경을 적용한 경우에는 22.4%까지 추가로 하락하였다. 이는 합성 과정 자체의 영향이 존재함과 동시에, 배경 문맥의 변화 정도가 커질수록 재식별 성능 저하가 증가함을 보여준다.

BG-swap Augmentation은 Both-swap mAP를 51.4%까지 향상시켜 가장 큰 적응 효과를 보였으나, Original mAP가 67.4%로 감소하였으며 학습 데이터 증가와 합성 분포에 대한 직접적인 노출 효과를 포함한다. 반면 Feature Consistency Loss는 Original mAP를 71.1% 수준으로 유지하면서 Both-swap mAP를 33.0%, Both-swap+Blur mAP를 37.4%로 개선하였다. 서로 다른 seed를 이용한 3회 반복실험에서도 λ_{cons} 값이 1.0인 모델은 Both-swap mAP 33.0±0.3%를 기록하여 Baseline의 22.7±0.4% 대비 평균 10.6%p 향상되었으며, Original mAP는 71.1±0.1%로 유지되었다. 따라서 본 연구에서는 원본 판별 성능과 배경 변화 강건성을 함께 고려하여 λ_{cons} 값을 1.0으로 최종 선정하였다.

또한 consistency loss 가중치에 대한 민감도 분석에서 λ_{cons} 가 증가함에 따라 Both-swap 성능이 향상되는 경향을 확인하였으나, 큰 가중치에서는 Original 성능이 소폭 감소하여 배경 강건성과 원본 판별력 간 trade-off가 존재함을 확인하였다. 이에 본 연구에서는 원본 성능을 유지하면서 배경 변화에 대한 강건성을 개선할 수 있는 λ_{cons} 는 1.0을 기본값으로 사용하였다.

이상의 결과는 CLIP-ReID가 배경을 포함한 주변 시각 문맥 변화에 높은 민감도를 가질 수 있음을 보여주며, Feature Consistency Loss가 원본 재식별 성능을 유지하면서 이러한 민감도를 완화할 수 있는 하나의 학습 전략임을 확인하였다. 향후에는 BG-swap Augmentation과 Feature Consistency Loss를 결합하고, 배경 교체 비율, mask 품질 및 합성 방식에 따른 영향을 세분화하여 분석할 예정이다. 또한 Market-1501 및 DukeMTMC-reID와 같은 다른 데이터셋 및 합성데이터셋에 대한 평가와 attention map 분석을 통해 다양한 환경에서도 배경 민감도 완화 효과가 유지되는지 검증할 필요가 있다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Y. Sun, L. Zheng, Y. Yang, Q. Tian, and S. Wang, "Beyond Part Models: Person Retrieval with Refined Part Pooling (and A Strong Convolutional Baseline)," Proceedings of the European Conference on Computer Vision (ECCV), pp. 480-496, 2018.

[2] S. He, H. Luo, P. Wang, F. Wang, H. Li, and W. Jiang, "TransReID: Transformer-Based Object Re-Identification," Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 15013-15022, 2021.

[3] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, "Learning Transferable Visual Models From Natural Language Supervision," Proceedings of the 38th International Conference on Machine Learning (ICML), vol. 139, pp. 8748-8763, 2021.

[4] S. Li, L. Sun, and Q. Li, "CLIP-ReID: Exploiting Vision-Language Model for Image Re-Identification without Concrete Text Labels," Proceedings of the AAAI Conference on Artificial Intelligence, vol. 37, no. 1, pp. 1405-1413, 2023.

[5] Ultralytics, "YOLO Segmentation," Ultralytics Documentation, 2026.

[6] A. Hermans, L. Beyer, and B. Leibe, "In Defense of the Triplet Loss for Person Re-Identification," arXiv preprint arXiv:1703.07737, 2017.

[7] Q. Wang, H. Huang, Y. Zhong, W. Min, Q. Han, D. Xu, and C. Xu, "Swin Transformer Based on Two-Fold Loss and Background Adaptation Re-Ranking for Person Re-Identification," Electronics, vol. 11, no. 13, Art. no. 1941, 2022.

[8] M. Tian, S. Yi, H. Li, S. Li, X. Zhang, J. Shi, J. Yan, and X. Wang, "Eliminating Background-Bias for Robust Person Re-Identification," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 5794-5803, 2018.

[9] L. Wei, S. Zhang, W. Gao, and Q. Tian, "Person Transfer GAN to Bridge Domain Gap for Person Re-Identification," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 79-88, 2018.

PCB 적층 프레스 공정을 위한 시계열 데이터 기반 이상탐지

송공호, 김영진*, 박태형**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 지능로봇공학과
song5@chungbuk.ac.kr, *you359@cbnu.ac.kr, **taehpark@cbnu.ac.kr

Time-Series Data-Based Anomaly Detection for the PCB Lamination Press Process

Gong-Ho Song, Young-Jin Kim*, Tae-Hyeong Park**

Department of Industrial AI, *Industrial AI Research Center, Chungbuk National Univ.
**Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

In multilayer PCB manufacturing, the lamination press bonds dozens of layers in one cycle and forms internal defects such as voids and delamination, yet no quality decision is made during the process: the press recorded zero defects while the shipping inspection judged 511. This study proposes a cycle-level anomaly detection pipeline that uses only the records the equipment already keeps (the press time series, work log, lot history, and nonconformity records) without dedicated sensors, and fixes each design choice by comparing supervised and unsupervised algorithms under identical conditions. Lot-level combinations of the four sources did not separate defective lots once date-grouped validation removed event clustering. On cycles generated from six real press cycles, augmentation raised the AUROC of feature-based logistic regression from 0.668 to 0.973; supervised models led on anomaly types seen in training (0.973 versus 0.910) but fell to 0.847 on unseen types, mainly on a missing-value anomaly. On the public SECOM data, the same model dropped from 0.826 to 0.725 once leakage from pre-split resampling and feature selection was removed, and to 0.595 under a chronological split. Unsupervised detection is therefore the safer default for anomalies not yet observed.

Key words : PCB lamination press, time-series anomaly detection, supervised and unsupervised learning, data augmentation, dataset construction

Ⅰ. 서론

고다층 인쇄회로기판(PCB)은 수십 층의 회로층을 적층 프레스의 한 사이클로 압착해 접합한다. 보이드 · 박리 · 휨 같은 내부 결함은 프레스 안에서 수지가 용융 · 유동 · 경화되는 동안 형성되므로[1] 적층 전 검사로 선별할 수 없고, 층 사이에 생겨 외관으로 드러나지 않는다. 그림 1과 같이 대상 현장인 국내 반도체용 PCB 제조사의 생산관리시스템에서 2022년 1월부터 2026년 6월까지 프레스 공정은 양품 4,017,290 PNL에 불량 0을, 출하검사 공정은 불량 511을 표시하며, 그림 2와 같이 결함은 공정이 종료된 뒤 외관에서 판정된다.

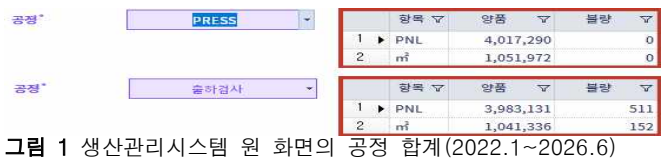


그림 1 생산관리시스템 원 화면의 공정 합계(2022.1~2026.6)
Fig. 1 Production system: press 0 defects, shipping inspection 511



그림 2 부적합 보고서에 첨부된 결함 원 사진
Fig. 2 Defect photos attached to nonconformity reports

공정 중 판정이 필요한 이유는 세 가지이다. 첫째, 열과 압력이 로트 전체에 동시에 작용하는 배치 공정이어서 한 번의 조건 이탈이 로트 전체의 손실이 되며, 부적합 매수의 86.3%를 차지한 온도 관련 결함은 후단 인수 검사에서야 검출되었다. 둘째, 현행 판정은 프레스 종료 뒤 중앙 17.9시간에 이루어져 그 사이 같은 설비가 평균 6.8사이클을 더 운전한다. 셋째, 설비 알람 650건 중 제품 품질을 판정하는 항목은 없고, 불량 라벨은 공정 이력 밖의 부적합 문서에만 남는다.

선행 연구는 해석 대리모델[2]이나 초음파 계측[1] · 결함 삽입 영상[3] 같은 별도 장치를 전제로 하거나, 라벨이 있는 공개 데이터의 지도 진단[4][5]과 라벨이 없는 공정의 비지도 탐지[6]를 다루었다. 본 연구는 전용 센서 없이 설비 기록만으로 사이클마다 정상 여부를 판정하는 이상탐지 구성을 제안하고, 각 단계를 같은 조건의 비교 실험으로 결정한다.

Ⅱ. 본론

1. 제안하는 이상탐지 구성

그림 3과 같이 제안 구성은 다섯 단계이다. ① 네 원천을 로트 번호로 연결하고 결측을 보존한 채 사이클 동기화, 단위 통일, 프로그램별 표준화를 한다. ② 사이클을 특징 벡터나 256점 시계열로 만들고 같은 프로그램 기준 곡선과의 잔차를 입력으로 하며, 정상 변형으로 학습 데이터를 늘린다[7]. ③ 비지도 탐지기를 기본으로 결측 규칙을 병행하고, 불량이 축적된 유형부터 지도 모델을 더한다. ④ 정상 사이클 점수의 95번째 백분위(오경보율 5%)를 임계로 한다. ⑤ 경보 사이클에는 이탈한 조건과 초래 가능한 불량을 제시한다.

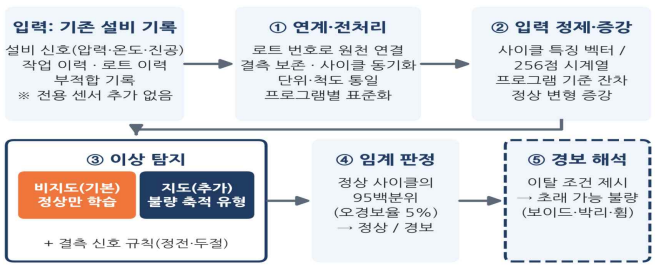


그림 3 제안하는 시계열 데이터 기반 이상탐지 구성
Fig. 3 Proposed anomaly detection pipeline

2. 데이터셋과 실험 구성

원천은 설비 신호(압력 · 보조 압력 · 온도 · 진공), 작업 이력 8,856 사이클, 로트 이력 9,312 로트, 부적합 기록 72건(71건 연결)이다. 불량이 28일에만 집중되어 같은 날의 로트를 한 겹에 두는 날짜 묶음 교차검증을 사용하였다. 불량 사이클의 신호가 없으므로 실 사이클 6개의 정상 변형에 PRESS 불량 코드 6종과 조합 이탈 2종을 정상 산포의 0.5~5배로 주입하였고, 실 라벨 비교에는 SECOM[8]을 사용하였다. 지도 5종(로지스틱 회귀 · 랜덤 포레스트 · XGBoost · 1차원 합성곱 · LSTM 분류기)과 비지도 7종(Robust Z · Isolation Forest · LOF · 오토인코더 · 시계열 오토인코더 3종)을 비교하였고, 임계는 시험 데이터를 보지 않고 정하였다(시드 5회).

3. 실험 결과

로트 단위로 네 원천을 조합하면, 날짜 묶음 평가에서 날짜만 입력한 기준선(AUROC 0.765)을 넘는 조합이 없었다. 그림 4와 같이 사이클 시계열에서는 증강으로 특징 기반 로지스틱 회귀의 AUROC가 0.668에서 0.973으로 향상되었다. 학습한 유형에서 우수하던 지도 모델은 학습하지 않은 유형에서 0.847로 낮아져 비지도 Robust Z(0.910)보다 낮았고, 차이는 주로 결측형 이상(순간정전)에서 나왔다. 표 1과 같이 이탈이 초래할 수 있는 불량(문헌 근거의 가정)별로는 압력 · 진공 이탈(보이드)이 가장 잘, 온도 이탈(휨)이 가장 낮게 검출되었다. 같은 레시피의 실 사이클 10개로 시험하면 순위는 유지되었으나(AUROC 0.933~1.000) 실 정상 오경보율이 0.34~0.50이었다.

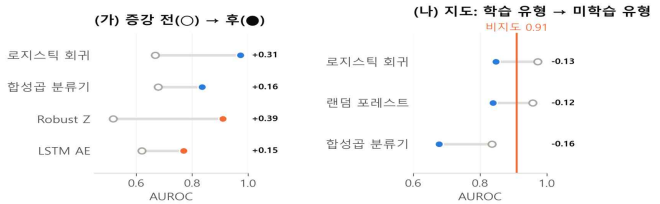


그림 4 사이클 시계열 실험: 증강 효과와 학습하지 않은 유형의 이상
Fig. 4 Cycle experiment: augmentation and unseen anomalies

표 1 불량별 성능(AUROC, 새 이탈 · 하한은 지도 모델, 하한은 재현율 0.9의 이탈 크기)
Table 1 Performance by the defect each deviation can cause

불량(원인 이탈)	지도	비지도	새 이탈	하한
보이드(압력 · 진공)	0.991	0.974	0.987	1 σ
박리(온도 · 설비 · 정전)	0.956	0.903	0.789	2 σ
휨(온도)	0.930	0.833	0.831	2 σ

4. 평가 조건에 따른 SECOM 결과의 차이

SECOM에서는 지도 랜덤 포레스트(AUROC 0.754)가 비지도 최고(0.591)보다 높았다. 표 2와 같이 결측 대체 · 특징 선택 · SMOTE를 분할 전에 전체 데이터로 하면 시험 정보가 학습에 섞이고 SMOTE의 합성 불합격 표본이 시험에 들어가 정밀도가 0.762로 부풀려진다. 이 처리를 학습 겹 안으로 옮겨 누설을 막으면 AUROC가 0.101 낮아지고, 앞 70%로 학습해 뒤 30%를 시험하는 시간순 분할에서는 공정의 시간 변화가 더해져 0.130 더 낮아진다. 현장 운용은 시간순 분할에 가깝고, 선행 보고 재현율 0.654[5]는 누설을 막은 조건(0.648)과 같은 수준이다.

표 2 같은 모델의 평가 조건별 결과(SECOM, 평균 대체+특징 선택+SMOTE+로지스틱 회귀)
Table 2 Same model under different evaluation protocols

평가 조건	처리 범위	AUROC	재현율	정밀도
분할 전 처리	전체 데이터	0.826	0.763	0.762
겹 안 처리(10겹)	학습 겹	0.725	0.648	0.131
시간순 분할	앞 70%(학습)	0.595	0.469	0.092

Ⅲ. 결론

본 연구는 PCB 적층 프레스에서 전용 센서 없이 설비 기록만으로 동작하는 사이클 단위 이상탐지 구성을 제안하였다. 첫째, 기존 기록으로 데이터셋을 구축하여 판정 시점을 출하 검사에서 사이클 종료 직후로 앞당길 근거를 마련하였다. 둘째, 증강은 아홉 모델 모두의 성능을 높였고, 학습하지 않은 유형의 이상에서는 비지도(0.910)가 지도(0.847)보다 높았다. 셋째, 같은 모델의 AUROC가 평가 조건만으로 0.826에서 0.595까지 달라져, 선행 보고치와는 누설을 막은 조건에서만 비교할 수 있다. 현장에서는 비지도를 기본으로 두고 불량이 쌓이는 유형부터 지도를 더한다. 사이클 수치는 생성 데이터의 값이므로 운용 임계는 프로그램별 실 정상 사이클로 정하고, 불량 사이클 59개와 정상 대조 173개로 블라인드 검증한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] T. B. Hudson, P. J. Follis, J. J. Pinakidis et al., "Porosity detection and localization during composite cure inside an autoclave using ultrasonic inspection," Composites Part A: Applied Science and Manufacturing, vol. 147, art. 106337, 2021. doi: 10.1016/j.compositesa.2021.106337.

[2] J. Park, D. Kim, S. Yang, M. Kim, and H. So, "A comprehensive review of machine learning approaches for predicting warpage and thermal resistance in advanced semiconductor packaging," JMST Advances, vol. 8, no. 2, pp. 71-90, 2026. doi: 10.1007/s42791-026-00131-w.

[3] D. Kumar, P. C. Agraharam, Y. Liu, and S. Namilae, "Anomaly detection for composite manufacturing using AI models," J. Intelligent Manufacturing, vol. 36, no. 8, pp. 5801-5817, 2025. doi: 10.1007/s10845-024-02522-z.

[4] A. A. Nuhu, Q. Zeeshan, B. Safaei, and M. A. Shahzad, "Machine learning-based techniques for fault diagnosis in the semiconductor manufacturing process: A comparative study," The Journal of Supercomputing, vol. 79, pp. 2031-2081, 2023. doi: 10.1007/s11227-022-04730-x.

[5] M. Salem, S. Taheri, and J.-S. Yuan, "An experimental evaluation of fault diagnosis from imbalanced and incomplete data for smart semiconductor manufacturing," Big Data and Cognitive Computing, vol. 2, no. 4, art. 30, 2018. doi: 10.3390/bdcc2040030.

[6] D. Ribeiro et al., "Isolation forests and deep autoencoders for industrial screw tightening anomaly detection," Computers,

vol. 11, no. 4, art. 54, 2022. doi: 10.3390/computers11040054.

[7] B. K. Iwana and S. Uchida, "An empirical survey of data augmentation for time series classification with neural networks," PLOS ONE, vol. 16, no. 7, art. e0254841, 2021. doi: 10.1371/journal.pone.0254841.

[8] M. McCann and A. Johnston, "SECOM," UCI Machine Learning Repository, 2008. [Dataset]. doi: 10.24432/C54305.

분산 MSA 환경에서 TraceID 기반 대조학습을 활용한 로그 이상 탐지 및 원인 서비스 식별

김완수, 김한진*, 이의종**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 소프트웨어학과
zzangdol@cbnu.ac.kr, *gks359@cbnu.ac.kr, **kongjjagae@cbnu.ac.kr

Log Anomaly Detection and Root-Cause Service Identification Using TraceID-based Contrastive Learning in Distributed Microservices

Wansoo Kim, Hanjin Kim*, Euijong Lee**

Dept. of Industrial Artificial Intelligence, Chungbuk National Univ.

*Industrial AI Research Center, Chungbuk National Univ.

**School of Computer Science, Chungbuk National Univ.

Abstract

Microservice-based web services change often as services are added or modified. Graph-based detectors such as DeepTraLog must rebuild their graphs and retrain after every change, leaving new services unmonitored in the meantime. This paper proposes TraceID-CLB, a graph-free log anomaly detector that uses the trace ID propagated by distributed tracing as its only structural key. Log lines of the same trace are encoded by a BERT model trained once with a contrastive objective, and each trace is scored by its distance to a bank of normal references; a new service is covered by registering only its normal traces, without retraining or anomaly labels. On a self-built 11-service MSA, four service additions took 5.8 s in total versus 774 s of retraining for DeepTraLog, while existing-service AUC stayed at 0.961. TraceID-CLB reached a detection F1 of 0.907 (graph baseline 0.755) and ranked the root-cause service first in 88.3% of anomalous traces; with the same latency and missing-service criteria added to both, the graph baseline remained slightly higher (0.980 vs. 0.955).

Key words : Microservice, Distributed Tracing, Trace ID, Contrastive Learning, Log Anomaly Detection, Incremental Adaptation

Ⅰ. 서 론

마이크로서비스 아키텍처(MSA)는 하나의 애플리케이션을 회원, 알림, 공통코드처럼 기능 단위의 서비스로 나누는 구조이다[1]. 서비스별로 따로 배포하고 확장할 수 있어, 하나의 프로그램으로 동작하던 모놀리식 구조의 웹 시스템이 MSA로 옮겨 가고 있다. 특히 운영 중인 웹 시스템은 법령 개정이나 업무 절차 변경, 기능 고도화에 따라 서비스가 수시로 추가되거나 수정되는데, MSA는 이러한 변경을 서비스 단위로 빠르게 반영할 수 있다는 점에서 유리하다. 그러나 서비스 수가 늘어날수록 장애를 찾고 감시하는 일은 오히려 어려워진다.

이 어려움은 로그가 남는 방식에서 비롯된다. 그림 1은 본 연구에서 구축한 시스템에서 같은 요청(traceId 0556f5f1)의 로그가 두 구조에 어떻게 남는지 비교한 것이다. 모놀리식 구조에서는 한 프로세스가 요청을 처리하므로 로그가 app.log 한 파일에 시간 순서대로 남는다(그림 1(a)). 반면 MSA에서는 같은 요청이 게이트웨이를 거쳐 user, notification, code 서비스의 컨테이너를 차례로 지나므로 로그가 서비스별 파일로 나뉘어 기록되고, 같은 시각에 처리된 다른 요청의 로그와 섞인다(그림 1(b)). 이 예에서 code 서비스의 예외는 notification 서비스의 경고로 이어졌다. 이처럼 장애는 호출 관계를 따라 다른 서비스로 번지므로, 원인 서비스를 찾으려면 운영자가 여러 서비스의 로그를 모아 요청 단위로 다시 묶고 시간 순서로 대조해야 한다. 이 작업은 서비스 수가 많아질수록 길어지며, MSA의 로그 추적이 모놀리식 구조와 근본적으로 다른 이유도 여기에 있다.

이를 자동화하기 위해서는 세 가지 기술이 필요하다. 요청마다 고유한 식별자(traceId)를 부여해 서비스 경계를 넘어 전달하는 분산 추적[10], 형식이 제각각인 로그 문장을 정형화해 학습하는 로그 표현 기법[5],[8], 그리고 서비스 사이의 관계를 반영해 이상과 원인을 판정하는 탐지 모델이다. 로그 시퀀스 기반 기법[6],[8]은 한 서비스의 로그 흐름만 학습하므로 여러 서비스에 걸친 장애를 놓치기 쉽다. 이를 보완한 그래프 기반 기법[2-4]은 서비스 간 호출 관계와 장애 전파를 그래프로 표현해 정확도를 높였다. 대표적인 DeepTraLog[2]는 분산 추적의 호출 계층과 서비스 내부 로그 이벤트를 트레이스 이벤트 그래프(TEG)로 결합하고, GGNN과 Deep SVDD로 정상 그래프의 경계를 학습한다.

그러나 그래프 기반 기법은 구성 변화에 대한 적응 비용이 크다는 한계가 있다. 그래프의 노드는 학습 시점의 이벤트 사전에 등록된 식별자이므로, 새 서비스가 배포되면 사전과 그래프를 다시 만들고 GNN을 재학습해야 한다. 본 연구에서 재현한 DeepTraLog는 서비스를 하나 추가할 때마다 111~241초의 재학습이 필요했고, 재학습 전에는 사전에 없는 이벤트 때문에 새 서비스의 이상을 구분하지 못했다. 즉 재학습이 끝나기 전까지 신규 서비스는 감시 공백 상태에 놓인다. 서비스가 자주 바뀌는 운영 환경에서는 변경 때마다 이 비용이 반복되므로, 탐지 정확도와 함께 구성 변화에 빠르게 적응하는 확장성이 요구되지만 기존 연구는 이를 함께 다루지 못하였다.

본 논문은 이러한 적응 비용 문제를 해결하기 위해, 그래프 대신 분산 추적이 요청마다 이미 부여하는 traceId만을 구조 정보로 사용하는 로그 이상 탐지 기법 TraceID-CLB(TraceID Contrastive Learning Based)를 제안한다. 같은 traceId의 로그 묶음을 두 부분으로 나눈

양성쌍으로 BERT 인코더를 한 번 대조학습한 뒤 고정하고, 이상 여부는 정상 트레이스로 만든 기준 뱅크와의 거리로 판정한다. 새 서비스는 정상 트레이스를 고정된 인코더로 임베딩해 기준 뱅크에 등록하기만 하면 탐지 대상이 되므로, 재학습과 이상 레이블이 모두 필요하지 않다. 또한 이상으로 판정된 트레이스에서는 서비스별 점수, 누락된 호출, 오류 로그를 합산해 원인 서비스를 상위 K개로 제시한다. 본 논문의 목표는 그래프 방식보다 높은 정확도가 아니라, 같은 판정 기준에서 그래프 방식에 근접한 정확도를 유지하면서 서비스 추가에 따른 재학습 비용을 없애는 것이다.

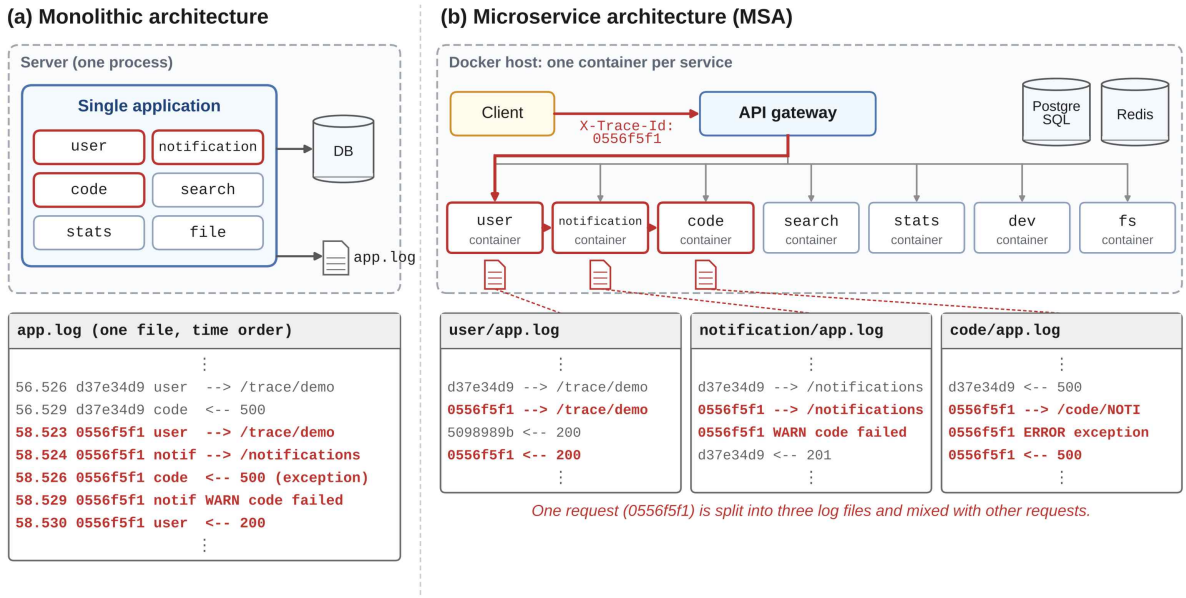


그림 1 (a) 모놀리식 아키텍처 (b) 마이크로서비스 아키텍처
Fig. 1 (a) a monolithic architecture (b) a microservice architecture

Ⅱ. 관련 연구

2.1 로그 기반 이상 탐지

로그 기반 이상 탐지는 가변적인 로그를 정규화하는 파싱을 한다. Drain[5]은 고정 깊이 트리로 로그를 온라인 파싱하며 이후 연구에서 널리 쓰인다. DeepLog[6]는 템플릿 시퀀스를 LSTM으로 학습해 다음 로그의 예측이 빗나가면 이상으로 판정한다. LogRobust[7]는 소스 코드 변경으로 로그 형식이 바뀌는 불안정한 로그에서도 동작하도록 템플릿의 의미 벡터와 어텐션 기반 Bi-LSTM을 사용하지만, 정상·이상 레이블로 학습하는 지도 방식이다. LogBERT[8]는 BERT[9]의 마스킹 언어 모델로 정상 로그 시퀀스를 자기지도 학습한다. 그러나 이들 기법은 한 시스템 또는 한 서비스의 로그 시퀀스를 입력으로 가정하므로, 요청이 여러 서비스를 거치며 생기는 교차 서비스 장애를 다루기 어렵다. 또 템플릿 사전이 학습 시점에 고정되어, 새 서비스의 로그는 사전에 없는 입력이 된다.

2.2 TraceID 기반 로그 이상 탐지 기술

Dapper[10] 이후 분산 추적은 요청마다 고유한 traceId를 부여해 서비스 경계를 넘어 전파하며, 현재는 W3C Trace Context[11]로 표준화되어 주요 MSA 프레임워크가 지원한다. TraceAnomaly[12]는 트레이스의 서비스 호출 경로와 응답시간을 서비스 트레이스 벡터로 만들고, 이를 VAE 기반의 심층 베이지안 네트워크로 학습한다. DeepTraLog[2]는 traceId로 묶인 스팬과 로그를 TEG로 결합해 트레이스와 로그를 함께 활용한 대표 연구로, TrainTicket[13] 벤치마크에서 F1 0.954를 보고했다. 원인 식별에서는 MicroRCA[4]가 응답시간·자원 사용량 지표로 서비스 의존 그래프를 만들고, 그 위에서 원인 서비스의 순위를 매긴다. 이들 연구는 학습 시점의 호출 경로나 서비스 의존 그래프를 입력 구조로 삼으므로, 서비스 구성이 바뀌면 그 구조를 다시 만들고 학습 모델은 다시 학습해야 한다. 본 연구는 traceId로 로그를 묶기만 하고 그래프는 만들지 않는다.

표 1 관련 연구 비교
Table 1 Comparison with related work

기법	서비스 관계 표현	대조 양성쌍	새 서비스 반영
LogBERT[8]	없음(단일 서비스)	없음(MLM)	재학습
DeepTraLog[2]	TEG 그래프	없음	재구성·재학습
TraceCRL[3]	호출 그래프	그래프 증강	재구성·재학습
CLDTLog[15]	없음	레이블 기반	재학습
TraceID-CLB	**traceId 묶음**	**같은 traceId**	**정상 기준 등록**

2.3 대조 학습

대조 학습은 같은 표본에서 나온 두 뷰는 가깝게, 다른 표본은 멀게 배치하도록 표현을 학습한다. SimCLR[14]은 NT-Xent 손실로 레이블 없이 표현을 학습했다. TraceCRL[3]은 트레이스를 오퍼레이션 호출 그래프로 표현하고 그래프 증강과 GNN 인코더로 대조학습을 수행하지만, 그래프와 GNN이 전제이며 로그를 사용하지 않는다. CLDTLog[15]는 BERT를 트리플렛 손실과 분류 손실로 미세조정하지만, 양성쌍을 구성하는 데 정상·이상 레이블이 필요하다. 본 연구는 같은 traceId에 속한 로그 집합의 두 부분을 양성쌍으로 삼으므로 레이블도 그래프도 필요 없다. 표 1에 대표 기법과의 차이를 정리하였다.

Ⅲ. 로그 이상 탐지를 위한 TraceID-CLB

3.1 전체 구조

그림 2는 그래프 기반 방법과 TraceID-CLB의 구조를 비교한 것이다. 그래프 기반 방법(그림 2(a))은 이벤트 사전, 트레이스 이벤트 그

래프, GNN이 모두 학습 시점의 서비스 구성에 묶여 있어, 서비스가 바뀌면 점선으로 표시한 부분을 다시 만들고 학습해야 한다. TraceID-CLB(그림 2(b))는 인코더를 처음 한 번만 학습한 뒤 고정하고, 서비스 구성에 따라 달라지는 정보는 모두 정상 기준 뱅크에 둔다. 그래서 서비스 구성이 바뀌어도 다시 학습할 부분이 없다.

TraceID-CLB는 로그 수집, 문장 변환·인코딩, 판정, 원인 식별의 네 모듈로 구성된다. 로그 수집 모듈은 각 서비스가 남긴 로그 줄을 traceId로 묶어 트레이스를 만든다. 트레이스 T는 같은 traceId를 가진 로그 줄의 집합이다. 문장 변환·인코딩 모듈은 로그 한 줄을 서비스 레벨 메시지 형태의 문장으로 바꾼다. 변환한 문장은 BERT 인코더(bert-tiny[16], 2층, 은닉 차원 128, 4.4M 파라미터)로 임베딩하고, 줄 임베딩의 평균을 트레이스 임베딩으로 사용한다. 판정 모듈은 정상 데이터로 만든 기준 뱅크와 비교해 트레이스의 이상 점수를 계산하고(3.3절), 원인 식별 모듈은 이상으로 판정된 트레이스에서 원인 서비스의 순위를 매긴다(3.5절).

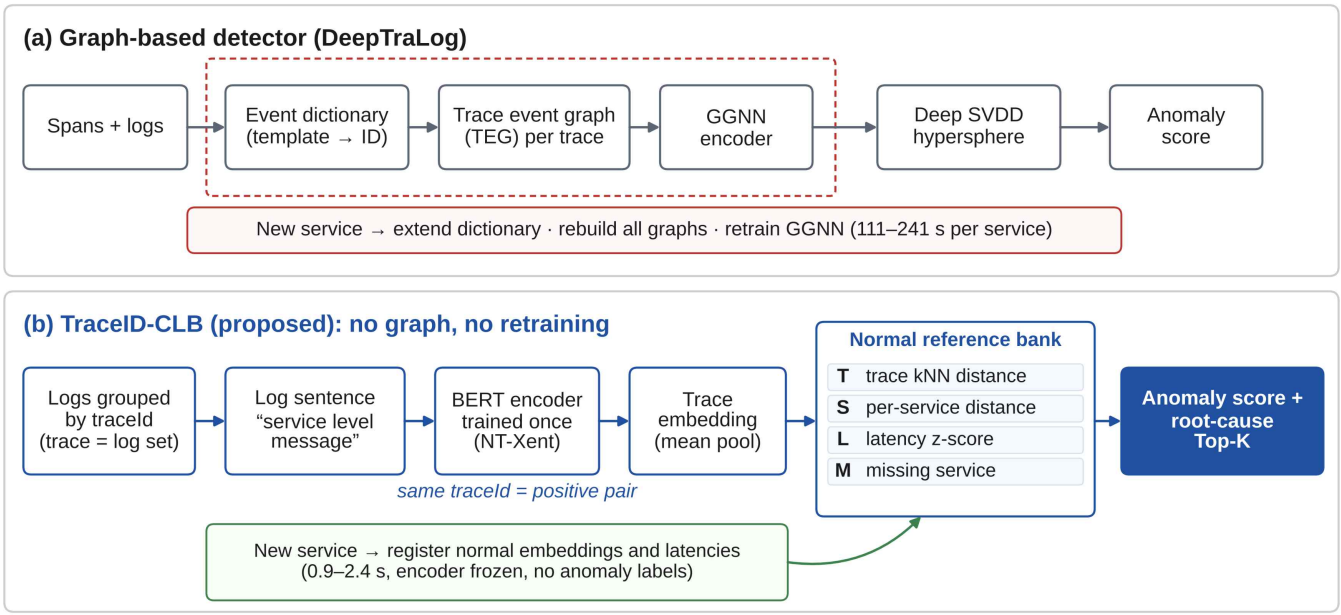


그림 2 (a) 그래프 기반 방법(DeepTraLog), (b) TraceID-CLB
Fig. 2 (a) the graph-based method (DeepTraLog) (b) TraceID-CLB

3.2 TraceID 대조학습

한 트레이스의 로그 줄을 무작위로 두 부분으로 나누어 두 뷰를 만들고, 같은 트레이스에서 나온 두 뷰는 양성쌍, 같은 배치 안의 다른 트레이스에서 나온 뷰는 음성쌍으로 삼는다. 인코더는 양성쌍의 코사인 유사도를 높이고 음성쌍의 유사도를 낮추는 NT-Xent 손실(온도 τ =0.1)[14]로 학습한다. 같은 요청을 처리한 서비스들의 로그가 임베딩 공간에서 가까워지므로, 그래프를 만들지 않아도 함께 호출되는 서비스의 관계가 트레이스 표현에 들어간다. 학습에는 정상 트레이스만 쓰며 장애 레이블은 필요 없다. 인코더는 사전학습된 bert-tiny의 마지막 2개 층과 128차원 투영층만 학습하며, 배치 크기 24, 학습률 2e-5로 1 에폭 학습한다.

3.3 정상 기준 기반 판정

판정에는 정상 데이터만으로 만든 네 가지 기준을 사용한다. 트레이스 기준(T)은 정상 트레이스 임베딩 뱅크에서 5-최근접 이웃까지의 평균 거리이다[17]. 서비스 기준(S)은 트레이스 안의 로그 줄을 그 서비스의 정상 로그 임베딩 뱅크(서비스당 최대 5,000개)와 비교한 거리를 표준화한 값 중 최댓값이다. 응답시간 기준(L)은 로그에 남은 응답시간을 (서비스, 메시지) 유형별 정상 분포로 표준화한 z값의 최댓값이고, 누락 기준(M)은 같은 진입 요청의 정상 트레이스 90% 이상에 나타나던 서비스 중 빠진 서비스의 수이다. 각 점수를 정상 보정 집합으로 표준화한 뒤 트레이스 x의 이상 점수를 $s(x) = T(x) + wS \cdot S(x) + wL \cdot L(x) + wM \cdot M(x)$로 계산하며, 가중치와 임계값은 시험셋과 분리한 검증 집합(정상·이상 각 500건)에서만 정했다. 평균 임베딩이 놓치기 쉬운 국소 지연은 L이, 호출 자체가 사라지는 연결 장애는 M이 보완한다.

3.4 재학습 없는 신규 서비스 등록

그래프의 입력은 사전의 번호여서 사전에 없는 이벤트를 표현할 수 없지만, TraceID-CLB의 입력은 로그 문장이어서 처음 보는 서비스명과 메시지도 그대로 읽는다. 따라서 새 서비스를 추가하는 작업은 학습이 아니라 기준 등록이다. 배포 직후 수집한 새 서비스의 정상 트레이스를 고정된 인코더로 인코딩해 T·S 뱅크에 넣고, 응답시간 분포(L)와 기대 서비스 목록(M)을 갱신하면 다음 요청부터 바로 판정된다. 이상 레이블도, 기존 데이터의 재처리도 필요 없다. 기준 뱅크는 최근접 이웃 검색만 하므로 정상 트레이스 50만 건을 넣어도 트레이스당 검색 시간은 0.36 ms, 메모리는 244 MB였다.

3.5 원인 서비스 식별

이상으로 판정된 트레이스에서는 그 트레이스에 나타난 서비스와, 나타나야 했지만 빠진 서비스를 원인 후보로 둔다. 후보마다 서비스 기준(S)과 응답시간 기준(L)의 점수, 호출 순서상 가장 먼저 사라진 서비스인지 여부, 다른 서비스의 WARN/ERROR 로그가 그 서비스의 이름을 언급했는지를 근거로 모은다. 근거별로 트레이스 안에서의 순위 점수를 구해 가중합하고, 점수가 높은 상위 K개 서비스를 원인 후보로 제시한다. 가중치는 검증 집합의 Top-1 적중률로 정했으며, 순위의 근거가 된 로그 줄을 함께 보여 주어 운영자가 바로 확인할 수 있게

하였다.

Ⅳ. 실험 및 결과 분석

4.1 실험 설계

실험용 MSA는 Spring Boot 기반 11개 서비스를 Docker로 배포하고, 게이트웨이가 생성한 traceId를 X-Trace-Id 헤더로 하위 서비스에 전파하도록 구성했다. 지연(Thread.sleep 삽입)·예외·연결(포트 차단) 장애 24개 시나리오로 207,535개 트레이스(이상 18.1%)를 수집했다. 비교 대상은 공개 코드로 재현한 DeepTraLog이다. 서비스 추가 실험은 6개 서비스로 시작해 analytics, user, manager, fs·dev를 차례로 배포하는 4단계로 구성했고, 모든 성능은 학습과 등록에 쓰지 않은 표본에서 3개 시드(42, 43, 44)의 평균으로 보고한다. 측정은 Apple M4 Pro(PyTorch 2.9, MPS) 단일 환경에서 수행했으며, 평가 지표는 Precision·Recall·F1, ROC-AUC, 원인 서비스 Top-K 적중률(HR@K)이다.

4.2 신규 서비스 적용 비용

그림 3(a)와 같이 TraceID-CLB는 서비스 하나를 추가할 때 0.9~2.4초, 4단계 누적 5.8초 만에 등록을 마쳤다. 같은 단계에서 그래프 방식은 사전 확장과 재학습에 111~241초, 누적 774초가 걸려 TraceID-CLB가 약 130배 빨랐다. 그림 3(b)에서 등록 전 새 서비스의 AUC는 0.42~0.52로 무작위 수준이었으나 등록 후 0.95~1.00으로 올랐고, 같은 시점의 기존 서비스 AUC는 0.961로 변하지 않았다. 재학습을 마친 그래프 방식의 새 서비스 AUC는 0.45~0.91이었다. 처음 학습에서도 TraceID-CLB는 729초로 그래프 방식(1,787초)보다 2.45배 빨랐고, 학습 가속기 메모리는 +2.3 GB로 그래프 방식(+4.8~5.3 GB)의 절반 이하였다(표 2).

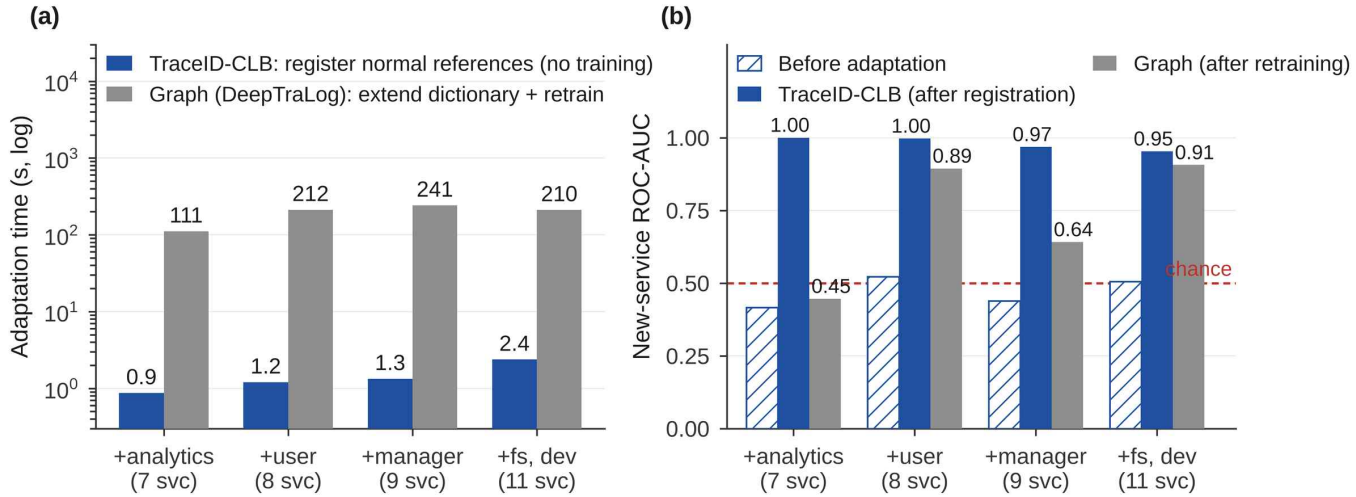


그림 3 (a) 서비스별 적용 시간 (b) 신규 서비스 AUC
Fig. 3 (a) Adaptation time and (b) new-service AUC

표 2 자체 MSA 실험 결과
Table 2 Results on the self-built MSA

지표	TraceID-CLB	그래프 (DeepTraLog)
처음 학습 시간(s)	729 ± 3	1,787 ± 24
학습 가속기 메모리	+2.3 GB (모델 16.9 MB)	+4.8~5.3 GB
F1 (AUC), 기본 입력	0.907 (0.948)	0.755 (0.817)
F1, 같은 기준 결합†	0.955	0.980
신규 서비스 적용(s)	0.9~2.4 (누적 5.8)	111~241 (누적 774)
적용 후 기존 서비스 AUC	0.961 = 0.961	재학습 필요
원인 HR@1/3/5	0.883 / 0.953 / 0.987	미제공‡

† 그래프 점수에도 응답시간(L)·누락(M) 기준을 같은 규칙으로 결합하고, 그래프 학습에 쓰지 않은 공통 시험 부분집합(50,535건)에서 비교한 결과. ‡ DeepTraLog는 트레이스 단위 이상 점수만 산출하여 원인 서비스 순위를 제공하지 않음.

4.3 탐지 및 원인 식별 정확도

탐지 정확도는 두 조건으로 나누어 비교하였다. 첫째, 각 방법을 원래 입력 그대로 쓴 조건(검증 집합을 뺀 전체 시험셋)에서 TraceID-CLB의 F1은 0.907(AUC 0.948)로 그래프 방식(F1 0.755, AUC 0.817)보다 15.2포인트 높았다(표 2). 그러나 재현한 그래프 방식은 이벤트 식별자만 입력으로 받아 로그에 남은 응답시간을 보지 않으므로, 이 차이의 상당 부분은 TraceID-CLB에만 더한 응답시간(L)·누락(M) 기준에서 나온다. 실제로 T 기준만 쓴 TraceID-CLB의 F1은 0.874였고, L·M을 더하자 지연 장애 재현율이 0.819에서 0.998로 올랐다. 둘째, 같은 L·M 기준을 그래프 점수에도 결합하고 그래프 학습에 쓴 트레이스를 뺀 공통 시험 부분집합(50,535건)에서 비교한 공정 비교(표 2의 †, 그림 4(a))에서는 그래프 방식의 F1이 0.980으로 TraceID-CLB(0.955)보다 2.5포인트 높았다. 따라서 본 논문은 정확도 우위를 주장하지 않으며, 정확도에 관한 주장의 근거는 두 번째 조건이다. 즉 TraceID-CLB는 같은 기준에서 그래프 방식보다 F1이 2.5포인트 낮은 대신, 4.2절과 같이 재학습 없이 수 초 만에 새 서비스를 탐지 대상에 넣는다.

원인 서비스 식별의 Top-1/3/5 적중률은 0.883/0.953/0.987로, ERROR 로그가 가장 많은 서비스를 고르는 규칙(0.079)을 크게 앞섰다. 그림 4(b)와 같이 연결 장애는 누락 순서만으로 0.999, 예외 장애는 로그의 서비스 언급을 더해 0.988까지 올랐다. 다만 지연 장애의 Top-1 적중률은 0.702에 머물렀다. 하위 서비스의 지연이 호출한 서비스의 응답시간에도 그대로 더해져 두 서비스가 함께 높은 점수를 받기 때문으로 보인다. 또 예외 장애는 오류 로그의 서비스명 언급에 의존해, 이 근거를 빼면 0.506으로 떨어졌다(표 3). 공개 벤치마크 TrainTicket(3시드)에서도 TraceID-CLB는 F1 0.925, AUC 0.974로 그래프 방식(F1 0.963)에 근접했고, 원인 Top-1 적중률은 0.936이었다. 단, TrainTicket은 원인 서비스에 ERROR 로그가 잘 남아 ERROR 규칙도 0.927로 높았다.

4.4 구성요소 제거 실험

표 3 구성요소 제거 실험 결과(자체 MSA, 3시드)

Table 3 Ablation results on the self-built MSA

제거 구성	제거 시	전체 구성
탐지 F1 (AUC)		
L · M 제거 (T만)	0.874 (0.915)	0.907 (0.948)
L · M 제거 (T+S)	0.878 (0.932)	0.907 (0.948)
S · M 제거 (T+L)	0.907 (0.948)	0.907 (0.948)
원인 식별 Top-1 (Top-3)		
서비스 언급 근거 제거	0.600 (0.938)	0.883 (0.953)
S 거리만 사용	0.570 (0.811)	0.883 (0.953)
TraceID 대조학습 제거, 4단계 평균 AUC		
로그 유실 0%	0.976	0.976
로그 유실 20%	0.606	0.631
로그 유실 30%	0.560	0.590

구성요소별 기여를 확인하기 위해 판정 기준, 원인 식별 근거, TraceID 대조학습을 하나씩 제거하였다(표 3). 판정 기준에서는 T 기준만 쓴 경우 F1이 0.874였고, 서비스 기준(S)을 더하면 0.878, 응답시간 기준(L)을 더하면 0.907로 올라 탐지 이득의 대부분은 L에서 나왔다. 누락 기준(M)은 전체 F1을 바꾸지 않았으나, 원인 식별에서는 연결 장애의 원인을 0.999로 찾는 핵심 근거였다. 원인 식별에서 서비스 언급 근거를 빼면 Top-1 적중률은 0.883에서 0.600으로 떨어졌지만 Top-3은 0.938을 유지하였고, 서비스 기준(S)의 거리만 쓰면 Top-1이 0.570이었다. 즉 원인 식별은 한 가지 근거가 아니라 여러 근거를 합산할 때 정확해진다.

TraceID 대조학습은 같은 bert-tiny를 대조학습 없이 쓴 사전학습 인코더와 비교하였다. 서비스를 4단계로 추가한 조건의 평균 AUC는 로그가 온전할 때 두 인코더 모두 0.976이었고, 차이는 데이터가 불완전한 운영 조건에서 나타났다. 그림 5(a)와 같이 시험 트레이스의 로그 줄 20%와 30%를 무작위로 지운 경우, 대조학습 인코더의 AUC는 사전학습 BERT보다 각각 2.5포인트, 3.0포인트 높았다. 그림 5(b)와 같이 기준 뱅크에 이상 트레이스가 5%, 10% 섞인 경우에도 기존 서비스 AUC가 각각 2.3포인트, 1.6포인트 높았다. 같은 traceId의 일부 로그끼리 가깝게 학습했기 때문에 로그 일부가 빠지거나 기준이 오염되어도 트레이스 표현이 덜 흔들린 것으로 보인다. BERT를 정적 단어 임베딩으로 바꾸는 제거 실험은 이번에 수행하지 못해 향후 과제로 남긴다.

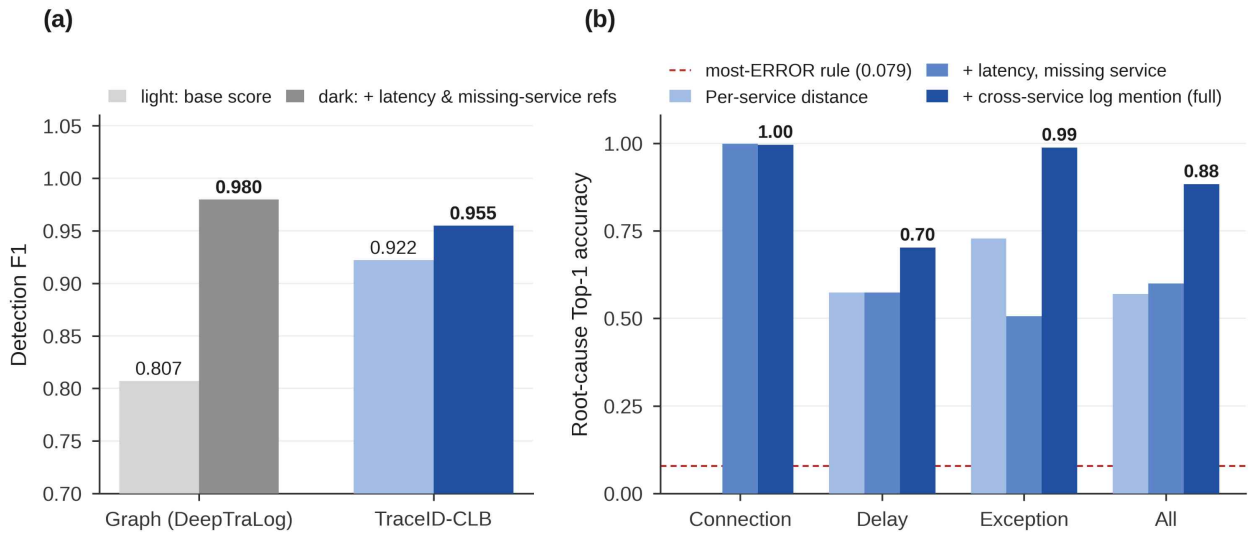


그림 4 (a) 응답시간 · 누락 기준을 결합한 탐지 F1 (b) 장애 유형별 원인 서비스 Top-1 적중률

Fig. 4 (a) Detection F1 with latency and missing-service criteria (b) Top-1 root-cause hit rate by fault type

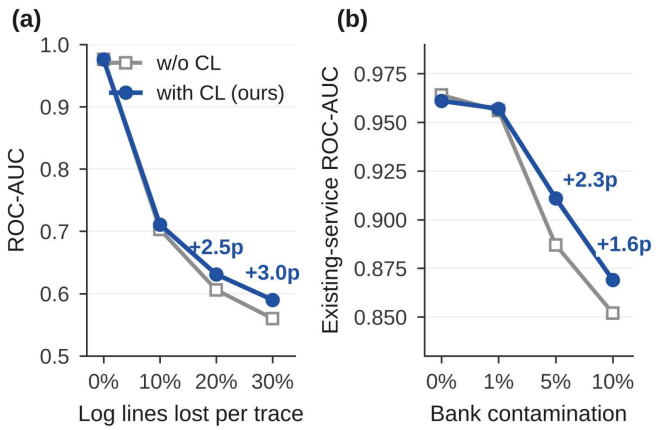


그림 5 (a) 로그 유실 (b) 기준 뱅크 오염 조건의 AUC

Fig. 5 (a) log loss (b) reference contamination

4.5 실시간 탐지기 적용

같은 모델과 기준으로 실시간 탐지기를 구현하였다. 로그 파일을 따라 읽으며 traceId로 묶고, 트레이스가 끝난 뒤 3초 안에 이상 여부와 원인 후보, 근거 로그를 화면에 보여 준다. 그림 6은 그림 1의 트레이스처럼 code 서비스에 예외 장애를 주입했을 때의 화면이다.

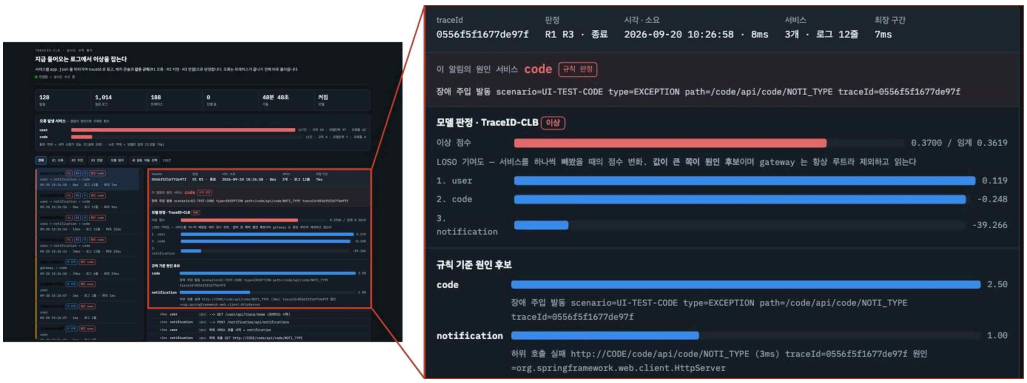


그림 6 실시간 탐지기 화면(code 서비스 예외 장애 주입)

Fig. 6 Real-time detector screen with an exception fault injected into the code service

V. 결 론

본 논문은 서비스가 자주 추가·수정되는 MSA 환경을 위해, 서비스 관계 그래프 없이 traceId 대조학습과 정상 기준 뱅크로 로그 이상을 탐지하고 원인 서비스를 찾는 TraceID-CLB를 제안하였다. 자체 구축한 11개 서비스 MSA에서 새 서비스 4개를 추가하는 데 걸린 시간은 그래프 방식의 774초에서 5.8초로 줄었고, 기존 서비스의 탐지 성능(AUC 0.961)은 그대로 유지되었다. 탐지 F1은 0.907, 원인 서비스 Top-1 적중률은 0.883이었다. 따라서 서비스가 바뀔 때마다 모델을 다시 학습하지 않고 정상 로그 등록만으로 새 서비스를 배포 직후부터 감시할 수 있다. 이를 통해 서비스가 수시로 추가·수정되는 운영 환경에서 배포 직후의 감시 공백과 재학습 비용을 줄이고, 원인 서비스와 근거 로그를 함께 제시해 운영자의 장애 분석 시간을 단축하는 효과가 기대된다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] N. Dragoni et al., "Microservices: Yesterday, Today, and Tomorrow," in Present and Ulterior Software Engineering, Springer, pp. 195-216, 2017.

[2] C. Zhang et al., "DeepTraLog: Trace-Log Combined Microservice Anomaly Detection through Graph-based Deep Learning," in Proc. ICSE, pp. 623-634, 2022.

[3] C. Zhang et al., "TraceCRL: Contrastive Representation Learning for Microservice Trace Analysis," in Proc. ACM ESEC/FSE, pp. 1221-1232, 2022.

[4] L. Wu et al., "MicroRCA: Root Cause Localization of Performance Issues in Microservices," in Proc. IEEE/IFIP NOMS, pp. 1-9, 2020.

[5] P. He et al., "Drain: An Online Log Parsing Approach with Fixed Depth Tree," in Proc. IEEE ICWS, pp. 33-40, 2017.

[6] M. Du et al., "DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning," in Proc. ACM CCS, pp. 1285-1298, 2017.

[7] X. Zhang et al., "Robust Log-Based Anomaly Detection on Unstable Log Data," in Proc. ACM ESEC/FSE, pp. 807-817, 2019.

[8] H. Guo, S. Yuan, and X. Wu, "LogBERT: Log Anomaly Detection via BERT," in Proc. IJCNN, pp. 1-8, 2021.

[9] J. Devlin et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in Proc. NAACL-HLT, pp. 4171-4186, 2019.

[10] B. H. Sigelman et al., "Dapper, a Large-Scale Distributed Systems Tracing Infrastructure," Google Technical Report, 2010.

[11] W3C, "Trace Context Level 1," W3C Recommendation, 2021.

[12] P. Liu et al., "Unsupervised Detection of Microservice Trace Anomalies through Service-Level Deep Bayesian Networks," in Proc. IEEE ISSRE, pp. 48-58, 2020.

[13] X. Zhou et al., "Fault Analysis and Debugging of Microservice Systems: Industrial Survey, Benchmark System, and Empirical Study," IEEE Trans. Software Engineering, vol. 47, no. 2, pp. 243-260, 2021.

[14] T. Chen et al., "A Simple Framework for Contrastive Learning of Visual Representations," in Proc. ICML, pp. 1597-1607, 2020.

[15] G. Tian et al., "CLDTLog: System Log Anomaly Detection Method Based on Contrastive Learning and Dual Objective Tasks," Sensors, vol. 23, no. 11, 5042, 2023.

[16] I. Turc et al., "Well-Read Students Learn Better: On the Importance of Pre-training Compact Models," arXiv:1908.08962, 2019.

[17] L. Bergman et al., "Deep Nearest Neighbor Anomaly Detection," arXiv:2002.10445, 2020.

Diffusion Model과 카메라 특징 보정을 활용한 다중 카메라 환경에서의 보행자 재식별

이은혜, 김영진*, 황영배**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 지능로봇공학과

eunhye4611@chungbuk.ac.kr, *you359@chungbuk.ac.kr, **ybhwang@cbnu.ac.kr

A Study on Person Re-Identification in Multi-Camera Environments using Diffusion Model and Camera Feature Calibration

Eunhye Lee, Youngjin Kim*, Youngbae Hwang**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**Department of Intelligent Systems and Robotics, Chungbuk National Univ.

Abstract

Person re-identification (Re-ID) models degrade severely in unseen CCTV environments. This paper selects representative gallery images by unsupervised clustering, generates diffusion images with poses matched to each camera's walking-direction distribution, fuses their features into gallery features, and subtracts per-camera feature means for calibration. In cross-domain evaluation between Market-1501 and DukeMTMC-reID, the proposed method raises the average mAP of CLIP-ReID from 43.4% to 58.9% on Market-1501 and from 50.2% to 58.1% on DukeMTMC-reID. Camera-wise direction-matched poses yield a small average gain, but consistently outperform common poses on cameras whose walking-direction distribution differs from the common poses.

Key words : Person Re-Identification, Generative AI, Cross-Domain Re-ID, Camera Feature Calibration

Ⅰ. 서 론

산업시설과 공공장소에 CCTV 설치가 확대되면서 여러 카메라 영상에서 특정 인물을 찾고 이동 경로를 파악하려는 수요가 늘고 있다. 보행자 재식별(Person Re-Identification, Re-ID)은 한 카메라에 촬영된 인물을 시야가 겹치지 않는 다른 카메라의 이미지에서 찾는 기술이다[1, 2]. 검색의 기준이 되는 인물 이미지를 쿼리(query)라 하고 검색 대상이 되는 이미지 집합을 갤러리(gallery)라 한다. 동일 인물이라도 카메라에 따라 시점과 보행 방향 그리고 조명과 색감이 달라 외형이 크게 변화한다. 따라서 Re-ID에는 카메라 간 차이에 강인한 특징 표현이 요구된다.

TransReID[3]와 CLIP-ReID[4] 등 최근 모델은 학습한 데이터셋에서 높은 성능을 보인다. 그러나 이들 모델은 두 가지 한계를 지닌다. 첫째, 학습 데이터셋의 카메라 조건에 맞추어 특징을 학습하므로 특징에 촬영 카메라의 편향이 남고[5] 학습에 사용하지 않은 카메라 환경에서는 학습 데이터에 없던 외형 변화에 대응하지 못해 정확도가 떨어진다[6]. 둘째, 갤러리에 존재하는 시점의 이미지만으로 비교하므로 쿼리와 다른 방향으로 촬영된 인물을 찾는 데 취약하다. 실제 현장은 학습에 사용하지 않은 카메라로 구성되는 경우가 대부분이어서 이 한계가 그대로 드러난다. 여기서 도메인은 카메라의 설치 환경과 촬영 조건 및 촬영된 인물에 따라 정해지는 이미지 데이터의 분포를 말하며 한 도메인의 데이터로 학습한 모델을 분포가 다른 도메인에 적용하는 상황을 교차 도메인(cross-domain)이라 한다. 본 논문은 데이터셋 하나를 하나의 도메인으로 보고 학습 데이터셋과 평가 데이터셋이 같으면 동일 도메인으로 보고 다르면 교차 도메인으로 본다.

카메라 간 외형 변화 가운데 시점과 자세의 차이는 갤러리 이미지만으로 보완하기 어렵다. 갤러리에는 인물마다 일부 시점의 이미지만 존재한다. 따라서 쿼리와 다른 방향으로 촬영된 갤러리 이미지는 동일 인물이라도 유사도가 낮아지기 쉽다. 생성 모델은 한 장의 이미지로부터 같은 인물을 다른 자세로 합성할 수 있어 갤러리에 없는 시점을 보충하는 수단으로 Re-ID에 활용되어 왔다[2, 7]. 최근에는 Diffusion Model이 생성적 적대 신경망(Generative Adversarial Network, GAN) 기반 방법보다 높은 이미지 품질과 신원 보존을 보이면서 이를 Re-ID에 적용하는 연구가 이어지고 있다[8, 9].

도메인 적응 기법[6, 10]은 새로운 환경마다 데이터 수집과 재학습이 필요하다. DG-Net[7]과 Pose-dIVE[9] 등 생성 기반 연구는 학습 단계의 증강에 머문다. Pose2ID[8]는 생성 이미지의 특징을 갤러리에 융합하여 성능을 높였다. 그러나 동일 도메인에서만 검증되었고 모든 카메라에 같은 8자세를 사용하며 갤러리와 쿼리 이미지마다 생성을 수행한다. 본 논문의 기여는 다음과 같다. 첫째로 인물 ID(identity) 라벨 없이 갤러리 군집화로 대표 이미지를 선정하고 생성 특징의 융합[8]과 카메라 특징 보정[5]을 결합하여 재학습 없이 교차 도메인 정확도를 높인다. 둘째로 카메라 내 자세 변이의 주된 요인이 보행 방향임을 보이고 각 카메라의 방향 분포에 맞추어 생성 자세를 선정하는 카메라별 방향 맞춤 자세를 제안한다. 평균 이득은 크지 않으나 카메라의 방향 분포가 공통 자세와 다른 카메라에서 유의한 향상을 보인다.

Ⅱ. 본론

1. 제안 방법 및 개요

그림 1처럼 갤러리 등록 단계에서는 갤러리를 군집화하여 군집마다 대표 이미지 1장을 고른다. 대표 이미지를 타깃 카메라의 방향 맞춤 자세 8개로 생성하여 생성 특징을 갤러리 특징에 융합한 뒤 카메라 보정을 적

용한다. 검색 단계에서 쿼리는 특징 추출과 보정만 거친 뒤 쿼리가 촬영된 카메라용 갤러리 특징과 코사인 유사도로 비교한다. 검색 단계에서 생성은 수행하지 않는다.

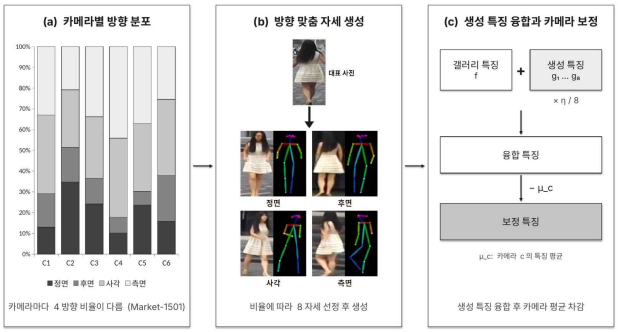


그림 1 제안 방법의 개요
Fig. 1 Overall structure of the proposed method

2. 카메라별 방향 맞춤 자세

DWPose[11]로 추출한 18개 관절을 목 기준으로 이동하고 몸통 길이로 정규화하여 36차원 자세 벡터를 만든다. 자세 벡터의 유클리드 거리로 카메라 내 변이는 각 벡터와 해당 카메라 평균 자세 사이 거리의 평균으로 정의하고 카메라 간 변이는 카메라 평균 자세 사이 거리의 평균으로 정의한다. 카메라 내 변이는 카메라 간 변이보다 Market-1501에서 4.2배이고 DukeMTMC-reID에서 4.6배 컸으며 자세 분포는 보행 방향에 따라 뚜렷이 나뉘었다.

이에 각 이미지를 어깨 폭과 좌우 어깨 순서에 따라 정면과 후면 및 사각과 측면의 네 방향으로 분류한다. 정규화한 어깨 폭이 데이터셋별 분포의 하위 삼분위 미만이면 측면으로 분류하고 상위 삼분위 미만이면 사각으로 분류하며 그 이상이면 좌우 어깨의 화면상 순서에 따라 정면과 후면으로 분류한다. 분류 규칙의 타당성을 검증하기 위해 카메라당 30장씩 무작위로 추출한 180장에 수동으로 방향 라벨을 부여하고 분류 결과와 비교하였다. 어깨 키포인트가 검출되지 않은 18장을 제외한 162장에서 일치율은 84.0%로 나타났다. 8개 자세는 카메라의 방향 비율에 비례하여 배분하되 각 방향에 최소 1개를 둔다. 각 방향 안에서는 K-means 군집 중심에 가장 가까운 실제 자세를 선정한다. Pose2ID[8]가 모든 카메라에 공통으로 사용하는 8자세는 정면 1개와 후면 1개 및 사각 3개와 측면 3개로 고정되어 있으며 이를 공통 8자세라 한다. 방향 맞춤 자세도 같은 8개로 두고 자세 선정 방식만 달리하여 비교한다.

3. 대표 이미지 선정 및 생성 특징 융합과 카메라 보정

대표 이미지는 인물 ID 라벨 없이 선정한다. 카메라 보정을 적용한 갤러리 특징을 SpCL[10]과 같이 k-상호 이웃 Jaccard 거리와 DBSCAN으로 군집화하며 군집 반경은 SpCL[10]의 기본값 0.6을 사용한다. 군집마다 다른 구성원과의 평균 유사도가 가장 높은 이미지를 대표로 두며 이 절차로 Market-1501에서 590장과 DukeMTMC-reID에서 859장이 선정되었다.

생성 모듈과 특징 융합 방식은 Pose2ID[8]의 사전학습 생성 모듈인 신원 유도 보행자 생성(Identity-Guided Pedestrian Generation, IPG)을 따르며 생성 자세만 카메라별로 선정한다. 갤러리 이미지 i는 Re-ID 특징이 가장 유사한 대표 이미지에 배정하고 그 대표의 생성 특징을 식 (1)로 융합한 뒤 식 (2)로 보정한다.

$$\tilde{f}_i = N\left(N(f_i) + \frac{\eta}{8}\sum_{k=1}^{8} N(g_{r(i),k})\right) \quad (1)$$

$$\hat{f} = N(f - \mu c) \quad (2)$$

f_i는 갤러리 이미지 특징이고 g_{r(i),k}는 이미지 i가 배정된 대표 r(i)를 k번째 자세로 생성한 이미지의 특징이다. N은 L2 정규화이고 η는 융합 계수이며 μ_c는 카메라 c의 특징 평균이다[5]. 방향 맞춤 자세가 카메라마다 다르므로 생성은 대표마다 카메라별로 한 번씩 수행하며 쿼리는 생성하지 않는다.

카메라 보정은 같은 카메라의 이미지가 조명과 배경이 비슷하여 특징에 카메라 편향이 남는다는 관찰[5]에 기반한다. 갤러리와 쿼리 각각에서 카메라별 특징 평균 μ_c를 빼면 카메라 공통 성분이 제거되어 인물 고유의 성분이 커진다.

4. 실험 설정

Market-1501[1]은 카메라 6대에 쿼리 3,368장과 갤러리 15,913장이고 DukeMTMC-reID[2]는 카메라 8대에 쿼리 2,228장과 갤러리 17,661장이다. 한 데이터셋으로 학습한 CLIP-ReID(ViT-B/16)[4]를 다른 데이터셋에 그대로 적용하여 쿼리 전체의 평균 mAP와 Rank-1로 평가하며 인물 ID 라벨은 평가에만 사용한다.

생성 모듈은 Pose2ID[8]의 사전학습 IPG를 추가 학습 없이 사용한다. 융합 계수 η는 0.25에서 2 가운데 두 교차 도메인 설정 모두에서 가장 높았던 0.5로 두었다. 유의성은 쿼리 단위 부트스트랩 95% 신뢰구간과 카메라 단위 Mann-Whitney 단측 검정으로 판단한다.

5. 실험 결과

표 1은 교차 도메인에서 제안 방법의 구성요소별 평균 mAP를 비교한 결과이며 생성 자세는 방향 맞춤 자세이다. DukeMTMC-reID로 학습한 모델의 Market-1501 평가에서 카메라 보정은 평균 mAP를 9.8%p 높였고 생성 특징 융합은 8.4%p 높였으며 두 구성요소를 결합하면 43.4%에서 58.9%로 15.5%p 향상되었고 Rank-1은 70.7%에서 78.4%로 높아졌다. Market-1501로 학습한 모델의 DukeMTMC-reID 평가에서는 카메라 보정이 4.3%p, 생성 특징 융합이 4.4%p 높았다. 둘을 결합하면 50.2%에서 58.1%로 7.9%p 향상되었으며 Rank-1은 68.9%에서 72.3%로 높아졌다. 두 구성요소의 효과가 누적되는 것은 생성 특징 융합이 갤러리에 없는 시점을 보완하고 카메라 보정이 카메라별 분포 편향을 제거하는 서로 다른 방식으로 작동하기 때문으로 해석된다. 동일 도메인에서는 제안 방법의 평균 mAP가 Market-1501에서 89.7%에서 89.9%였고 DukeMTMC-reID에서는 82.4%로 같아 두 구성요소는 학습하지 않은 도메인에서 주로 작동한다고 볼 수 있다.

표 1 제안 방법의 구성요소별 평균 mAP (%)
Table 1 Average mAP (%) by component of the proposed method

구성	Market-1501 평가 (DukeMTMC-reID 학습)	DukeMTMC-reID 평가 (Market-1501 학습)
Baseline (CLIP-ReID)	43.4	50.2
+카메라 보정	53.2	54.5
+생성 특징 융합	51.8	54.6
제안방법 (생성 특징 융합 + 카메라보정)	58.9	58.1

표 2는 같은 대표와 융합 조건에서 생성 자세만 공통 8자세와 방향 맞춤 자세로 바꾸어 비교한 결과이다. Market-1501 평가에서 방향 맞춤 자세는 공통 8자세보다 평균 mAP가 카메라 보정 미적용 시 1.7%p와 적용 시 0.9%p 높았고 두 차이 모두 부트스트랩 95% 신뢰구간이 0을 포함하지 않았다. DukeMTMC-reID 평가에서는 두 조건 모두 0.1%p 차이로 유의하지 않았다. 평균 이득은 크지 않으나 카메라 단위로 보면 효과가 나타나는 조건이 뚜렷하다. 교차 도메인 14대 가운데 방향 맞춤 배분이 공통 8자세와 같은 5대인 Market-1501의 1번과 4번 카메라, DukeMTMC-reID의 3번과 5번 및 8번 카메라에서는 방향 맞춤 자세가 공통 8자세보다 평균 0.1%p 낮았던 반면 배분이 다른 9대에서는 모두 높았고 평균 0.7%p 높았다. 두 집단의 차이는 Mann-Whitney 단측 검정에서 통계적으로 유의하였으며 p값은 0.0005였다. DukeMTMC-reID의 평균 이득이 작은 것은 8대 중 3대가 공통 8자세와 같은 배분이기 때문이다. 이는 카메라의 방향 분포가 공통 8자세와 다를수록 방향 맞춤 자세의 효과가 커짐을 보여준다. η를 0.25에서 2까지 바꾸어도 Market-1501에서 방향 맞춤 자세의 우위는 카메라 보정 적용 여부와 관계없이 유의하게 유지되었다.

표 2 생성 자세별 평균 mAP (%)
Table 2 Average mAP (%) by generation pose

생성자세	카메라 보정	Market-1501 평가 (DukeMTMC-reID 학습)	DukeMTMC-reID 평가 (Market-1501 학습)
공통 8 자세	미적용	50.1	54.5
방향 맞춤 자세	미적용	51.8	54.6
공통 8 자세	적용	58.0	58.0
방향 맞춤 자세	적용	58.9	58.1

제안 방법은 대표 이미지에 대해서만 생성하므로 생성 횟수는 Market-1501에서 4,130회이고 DukeMTMC-reID에서 7,731회였다. 갤러리와 쿼리 이미지마다 생성하는 Pose2ID[8]는 Market-1501에서 16,483회가 필요하다. RTX A4000 1대에서 대표 1장의 8자세를 생성하는 데 약 23초가 걸렸다.

카메라 보정은 평가 쿼리 전체로 카메라별 평균 μ_c를 구하는 설정이다. 이 가정을 완화하여 카메라당 무작위 쿼리 25장만으로 μ_c를 추정하면 제안 방법의 평균 mAP는 Market-1501에서 57.9%와 DukeMTMC-reID에서 57.6%로 전체 쿼리를 사용한 58.9%와 58.1%에서 1%p 안팎의 차이를 보였으며 5회 반복의 표준편차는 0.2%p였고 50장이면 58.4%와 57.9%로 차이가 0.5%p 이하였다. 쿼리 평균 대신 등록 단계의 갤러리 평균을 그대로 사용해도 58.4%와 57.9%를 얻어 평가 쿼리를 미리 확보하지 않아도 보정이 작동하였다.

Ⅲ. 결론

본 논문은 학습하지 않은 CCTV 환경에서 인물 ID 라벨 없이 갤러리 대표 이미지를 고르고 각 카메라의 보행 방향에 맞춘 자세로 생성한 특징을 융합하며 카메라 특징 보정을 적용하는 방법을 제안하였다. 교차 도메인 평균 mAP는 Market-1501에서 43.4%에서 58.9%로 DukeMTMC-reID에서 50.2%에서 58.1%로 높아졌다. 생성 특징 융합과 카메라 보정은 함께 적용할 때 효과가 가장 컸고 방향 맞춤 자세는 카메라의 방향 분포가 공통 8자세와 다른 카메라에서 효과를 보였다.

본 방법의 한계는 다음과 같다. 카메라 보정과 방향 맞춤 자세는 촬영 카메라 정보가 있는 환경에만 적용할 수 있다. 군집에 포함되지 않아 대표가 없는 인물은 융합의 이득을 받지 못하며 유사도 배정의 인물 일치율이 59.4%에 그쳐 다른 인물의 생성 특징이 융합되는 경우가 있다. 카메라 평균과 군집은 평가 이미지를 미리 확보한 설정에서 산출하였으며 운용 시에는 카메라별 특징을 누적하여 갱신해야 한다. 향후 배정 정확도와 군집 포괄률을 높이고 방향 내 자세 선정 방법을 개선하며 MSMT17 등 카메라 수가 많은 데이터셋으로 평가를 확장할 예정이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] L. Zheng et al., "Scalable Person Re-identification: A Benchmark," Proc. ICCV, 2015.

[2] Z. Zheng, L. Zheng, and Y. Yang, "Unlabeled Samples Generated by GAN Improve the Person Re-identification Baseline in vitro," Proc. ICCV, 2017.

[3] S. He et al., "TransReID: Transformer-based Object Re-Identification," Proc. ICCV, 2021.

[4] S. Li, L. Sun, and Q. Li, "CLIP-ReID: Exploiting Vision-Language Model for Image Re-Identification without Concrete Text Labels," Proc. AAAI, 2023.

[5] M. Song, J.-W. Park, and J.-S. Lee, "Exploring the Camera Bias of Person Re-identification," Proc. ICLR, 2025.

[6] Y. Ge, D. Chen, and H. Li, "Mutual Mean-Teaching: Pseudo Label Refinery for Unsupervised Domain Adaptation on Person Re-identification," Proc. ICLR, 2020.

[7] Z. Zheng et al., "Joint Discriminative and Generative Learning for Person Re-identification," Proc. CVPR, 2019.

[8] C. Yuan et al., "From Poses to Identity: Training-Free Person Re-Identification via Feature Centralization," Proc. CVPR, 2025.

[9] I. H. Kim et al., "Pose-dIVE: Pose-Diversified Augmentation for Person Re-Identification," Proc. CVPR Findings, 2026.

[10] Y. Ge et al., "Self-paced Contrastive Learning with Hybrid Memory for Domain Adaptive Object Re-ID," Proc. NeurIPS, 2020.

[11] Z. Yang et al., "Effective Whole-body Pose Estimation with Two-stages Distillation," Proc. ICCV Workshops, 2023.

Graph Embedding을 활용한 온톨로지 기반 의미 관계 검색 최적화

송재익, 강대익*, 유재수**
충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 정보통신공학부
songjx89@chungbuk.ac.kr, *kangdaeik@chungbuk.ac.kr, **yjs@chungbuk.ac.kr

Optimizing Ontology-based Semantic Relation Retrieval via Graph Embedding

Jaelk Song, Daeik Kang*, Jaesoo Yoo**
Department of Industrial AI, Chungbuk National Univ.,
*Industrial AI Research Center, Chungbuk National Univ.,
**School of Information and Communication Engineering, Chungbuk National Univ

Abstract

We enhance ontology-augmented knowledge graph embedding with directional constraints and attention-based adaptive hierarchy weights, modifying only the training loss. On a Korean defense-law knowledge graph containing 7,354 triples from 41 statutes and regulations, the proposed loss improves Filtered MRR by 6.8 percentage points for both TransO and TransC ($p < 0.001$). The TransC-based variant achieves the highest MRR (0.382) among nine models, while improving directionality and hierarchy preservation.

Key words : Knowledge Graph Embedding, Ontology, Directional Relation, Attention, Defense Law

Ⅰ. 서 론

법령 검색에서 "방위사업법이 시행령에 위임한다"와 "시행령이 방위사업법에 위임한다"는 전혀 다른 뜻이다. 이처럼 법령 사이의 관계에는 방향이 있고, 법률→ 시행령→ 시행규칙으로 이어지는 상 · 하위 계층이 있다. 그러나 현재 공공기관의 검색은 키워드나 단순 벡터 유사도에 의존하여 단어는 찾아도 관계의 방향과 계층은 구분하지 못한다. 이를 보완하는 기술이 지식 그래프 임베딩(KGE)이다. KGE는 법령 · 조문 같은 개체와 그 관계를(머리, 관계, 꼬리) 형태의 트리플로 표현한 지식 그래프를 벡터로 학습하여, "이 조문과 연결된 법령은 무엇인가"와 같은 질의에 계산으로 답하게 한다[1,2].

여기에 개체의 타입, 클래스 계층, 관계 규칙을 정의한 온톨로지를 결합하면 의미적으로 더 일관된 임베딩을 얻을 수 있어, 온톨로지 제약을 손실함수에 넣는 온톨로지 결합형 KGE가 TKRL[5], TransC[4], TransO[3]로 발전해 왔다[8]. 그러나 이들 모델에는 세 가지 공통 한계가 있다. 첫째, h + r ≈ t 형태의 평행이동 점수를 쓰기 때문에(A, 위임, B)와 (B, 위임, A)에 거의 같은 점수를 주어 방향을 구분하지 못한다. 둘째, 온톨로지 제약의 가중치를 사람이 고정하므로 도메인이 바뀌면 다시 조정해야 한다. 셋째, FB15K · YAGO 등 영어 대규모 일반 도메인에서만 검증되어 한국어 소규모 전문 도메인에서의 효과가 확인되지 않았다. 본 논문은 모델 구조(점수 함수)는 그대로 두고 학습 목표(손실 함수)만 바꾸어 세 한계를 해결한다. 주요 기여는(1) 정방향 트리플이 방향을 뒤집은 트리플보다 높은 점수를 받도록 강제하는 방향성 제약 손실 L_dir, (2) 계층 제약의 가중치를 데이터로부터 학습하는 적응형 가중치 L_hier_attn, (3) 관계가 법문에 명문화된 국방 분야 법령으로 구축한 한국어 KGE 벤치마크이다. 손실 수준의 설계이므로 특정 모델에 종속되지 않고 여러 KGE 베이스에 적용할 수 있다.

Ⅱ. 본론

1. 연구 방법

그림1과 같이 제안 방법은 일반적인KGE 학습 과정 중 입력 단계에 국방 법령 데이터셋(기여3)을, 손실 계산 단계에 두 손실(기여1 · 2)을 결합한다. 전체 손실은 식(1)이며, λ는 구조 학습이 안정된 뒤0에서1로 점진 증가시킨다.

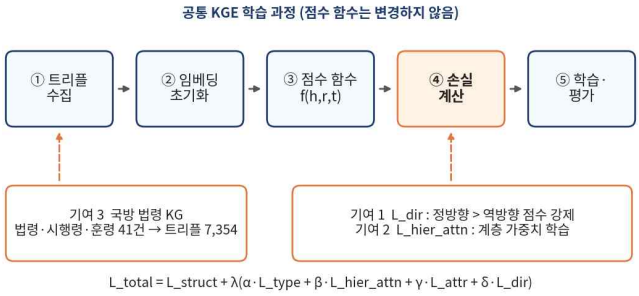


그림 1 제안하는 온톨로지 통합형 KGE 학습 구조
Fig. 1 Overview of the proposed ontology-integrated KGE

$$L_{struct} + \lambda(\alpha \cdot L_{type} + \beta \cdot L_{hier_{※n}} + \gamma \cdot L_{※r} + \delta \cdot L_{dir}) \quad (1)$$

$$L_{dir} = \max(0, \gamma_{dir} + f(h,r,t) - f(t,r,h)) \quad (2)$$

(1) 방향성 제약 손실L_dir: 식(2)와 같이 정방향 트리플의 거리 점수f가 머리와 꼬리를 바꾼 역방향보다 margin γ_dir 이상 작도록 강제한다. 온톨로지의 관계 속성을 이용해 방향성 관계 6종(인용 · 외부인용 · 위임 · 위임받음 · 소속 · 포함)에만 적용하고 대칭 관계는 제외한다.

(2) 적응형 계층 가중치 L_hier_attn: 고정 상수였던 클래스별 계층 손실의 가중치를 클래스 임베딩 기반 softmax 어텐션으로 계산하여, 어떤 계

층 제약을 강조할지 데이터로부터 학습한다. 학습 초기 warm-up 동안은 균등 가중을 유지하고, 가중치는 임베딩과 함께 end-to-end로 갱신된다.

(3) 국방 법령 데이터셋: 인용 · 위임 · 상하위 관계가 법문에 명문화되어 정답이 분명한 국방 분야를 검증 도메인으로 선정하였다. 방위사업법, 국방 과학기술혁신 촉진법과 그 시행령 · 시행규칙, 국방부 · 방위사업청 훈령 등 41건을 국가법령정보센터에서 수집하고, OWL Lite 수준 온톨로지에 따라 트리플을 추출 · 검증하여 엔티티 2,352개, 관계 12종, 트리플 7,354개의 지식 그래프를 구축하였다.

2. 실험 구성

데이터는 관계별 비율을 유지하여 train/valid/test = 5,877/730/747 (8:1:1)로 나누고, valid는 하이퍼파라미터 탐색에만, test는 최종 평가에 1회만 사용하였다. 비교 모델은 TransE[6], RotatE[7], DistMult[9], ComplEx[10]와 온톨로지 결합형 TKRL, TransC, TransO이며, 제안 손실을 TransO 구성과 TransC에 각각 적용하였다.

구현은 Python · NumPy 기반 자체 학습 엔진으로 하였고, 임베딩 100차원, 150 epoch, 학습률 0.05, 배치 1,024, 네거티브 샘플 8개, α=0.1, β=0.5, γ=0.5, δ=3.0, γ_dir=2.0을 사용하였다. 결과는 5개 시드 평균이며, 지표는 Filtered MRR과 Hits@K(head · tail 양방향), 방향성 관계 그룹의 Hits@1(Dir H@1), 계층 관계 그룹의 MRR(Hier MRR)이다.

3. 실험 결과 및 분석

표 1 핵심4개 모델 링크 예측 결과(5 seed 평균)

Table 1 Link prediction results of the four core models

Model	MRR	H@1	H@10	Dir H@1	Hier MRR
TransO (선행)	0.244	0.148	0.400	0.206	0.324
TransC (선행)	0.314	0.209	0.482	0.313	0.328
Ours (TransO)	0.312	0.207	0.477	0.289	0.429
Ours (TransC)	0.382	0.280	0.559	0.423	0.304

표1과 같이 Ours(TransO base)는 직접 비교 대상인 TransO 대비 모든 지표에서 향상되었고(MRR 0.244→0.312), 동일 손실을 TransC에 적용한 Ours(TransC base)는 MRR 0.382로 전체 1위를 기록하였다. 특히 TransO 베이스는 0.244→0.312, TransC 베이스는 0.314→0.382로 두 경우 모두 정확히 +6.8%p($p<0.001$) 향상되었다. 점수 함수가 달라도 동일한 폭으로 개선된다는 점은, 본 기여가 특정 모델이 아니라 어떤 베이스에도 적용 가능한 손실 수준의 베이스 독립적 방법론임을 보여준다.

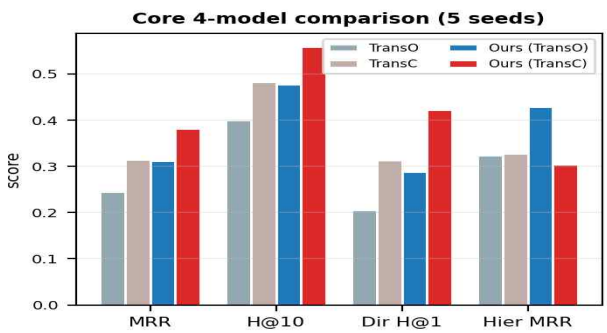


그림 2 핵심4개 모델의 지표별 비교

Fig. 2 Per-metric comparison of the four core models

기여별 효과도 사전에 정의한 기준으로 검증하였다. 방향성 측면에서 Dir H@1이 0.206에서 0.289로 +8.3%p 향상되어 L_dir의 효과를 확인하였다. 계층 측면에서는 L_hier_attn을 제거하면 계층 MRR이 5.7%p 하락하여 모듈의 기여가 확인되었다. 강건성 측면에서는 학습 데이터를 50% 축소했을 때 본 방법의 MRR 저하 폭이 구조 전용 베이스(TransE)보다 작아(0.111 < 0.114), 온톨로지 사전지식이 소규모 환경에서 데이터 효율을 높임을 확인하였다.

Ⅲ. 결론

본 논문은 점수 함수를 바꾸지 않고 손실 함수 수준에서 관계의 방향(L_dir)과 계층 가중치(L_hier_attn)를 학습하는 온톨로지 기반 KGE 학습 방법과 국방 법령 KGE 벤치마크를 제안하였다. 두 베이스 모두에서 MRR이 6.8%p 향상되어, 모델에 독립적이며 소규모 전문 도메인에 효과적인 방법임을 확인하였다. 한계로는 계층 · 일부 방향성 관계의 평가 표본이 적고 단일 도메인에서만 검증한 점이 있다. 향후 RotatE 등 다른 베이스로의 확장, 정 · 역방향 판별 지표를 통한 직접 검증, GraphRAG 등 LLM 기반 검색과의 통합을 연구할 계획이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Chicaiza, J., & Valdiviezo-D□az, P., "A Comprehensive Survey of Knowledge Graph-Based Recommender Systems," Information, 12(6), 232, 2021.

[2] Cao, J., et al., "Knowledge Graph Embedding: A Survey from the Perspective of Representation Spaces," ACM Computing Surveys, 56(6), 147, 2024.

[3] Shi, B., & Weninger, T., "TransO: a Knowledge-Driven Representation Learning Method with Ontology Information Constraints," World Wide Web, 2023.

[4] Lv, X., et al., "TransC: Differentiating Concepts and Instances for Knowledge Graph Embedding," EMNLP, 2018.

[5] Xie, R., et al., "Representation Learning of Knowledge Graphs with Hierarchical Types," IJCAI, 2016.

[6] Bordes, A., et al., "Translating Embeddings for Modeling Multi-relational Data," NeurIPS, 2013.

[7] Sun, Z., et al., "RotatE: Knowledge Graph Embedding by Relational Rotation in Complex Space," ICLR, 2019.

[8] Chen, J., et al., "Ontology Embedding: A Survey of Methods, Applications and Resources," arXiv:2406.10964, 2024.

[9] Yang, B., et al., "Embedding Entities and Relations for Learning and Inference in Knowledge Bases," ICLR, 2015.

[10] Trouillon, T., et al., "Complex Embeddings for Simple Link Prediction," ICML, 2016.

온프레미스 sLLM과 GraphDB 기반 MES LOT 추적 프레임워크

정회성, 채민선*, 윤재중**
충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 전기공학부
jhs4034@chungbuk.ac.kr, *mschae@chungbuk.ac.kr, **jjyun@chungbuk.ac.kr

An On-Premise sLLM- and GraphDB-Based Framework for MES LOT Traceability

Hoiseong Jeong, Min-Seon Chae*, JaeJung Yun**
Department of Industrial AI, Chungbuk National Univ.,
*Industrial AI Research Center, Chungbuk National Univ.,
**School of Electrical Engineering, Chungbuk National Univ

Abstract

This study proposes an on-premise framework that links MES LOT records and verifies source evidence using small language models and a graph database. For model-wise analysis, four models were evaluated under five conditions on a fixed snapshot with 84 questions (1,680 responses). With Qwen3 1.7B, the proposed system achieved a 54.8% overall pass rate, compared with 28.6% for Tool+RAG. The gain mainly reflected rule-based query-purpose and response-action corrections. In the RDB-versus-GraphDB evidence-citation comparison, adding GraphDB relation expansion to RDB retrieval raised required-evidence completeness from 75/80 to 80/80 and the overall pass rate from 84.5% to 89.3%. Operational performance requires further evaluation.

Key words : MES, LOT Traceability, Small Language Model, Graph Database, Evidence Verification

Ⅰ. 서 론

제조현장에서는 생산 · 품질검사 · 자재 수불 · 설비 상태가 서로 다른 MES 테이블과 알람 파일에 기록된다. 반품 또는 이상 검사 LOT의 이력을 확인하려면 데이터 구조를 파악하고 원본 기록 사이의 연결을 찾아야 한다. 제조 데이터와 문서에 분산된 지식을 연결하는 접근[1]과 자연어 기반 MES 질의[2]는 이러한 조회 부담을 줄이기 위한 연구 방향이다.

검색 증강 생성(RAG)[3]과 제조 지식그래프[4]를 결합하면 질의와 관계 조회를 연결할 수 있다. 국내에서도 그래프 질의 생성[5]과 온프레미스 RAG[6]가 연구되고 있다.

본 연구는 MES · PLC 기록을 LOT 번호와 원본 ID로 연결하고, 내부 인프라의 sLLM을 활용해 자연어 질의에 관련 기록과 인용 근거를 함께 제공하는 프레임워크를 제안한다.

제조 기록의 외부 반출 제약과 내부 자원 한계를 고려해 sLLM을 사용하되, 다단계 관계 선택에서 생기는 근거 누락을 그래프의 관계 경로와 원본 ID 대조로 보완하고자 한다. 이를 위해 LLM 모델별 성능을 분석하고, RDB와 GraphDB의 근거 인용 성능을 비교해 GraphDB 적용 효과를 검증한다.

Ⅱ. 본 론

2.1 제안 시스템 구성

제안 시스템은 자연어 LOT 질의를 조회 조건으로 변환하고, 원본 근거를 검증해 추적 결과를 제공한다. MES 테이블 22종과 PLC 알람 정보를 정규화한다. LOT · 원본 키 · 설비 · 라인 · 시각과 전문가 연계 규칙으로 사건 · 관계를 Neo4j에 저장하며, 전체 처리 흐름은 그림 1과 같다.

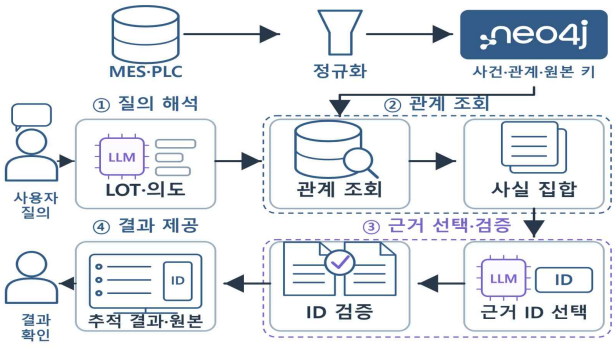


그림 1 질의 해석 · 관계 조회 · 근거 검증 · 결과 제공
Fig. 1 Query interpretation, retrieval, verification and delivery

각 모듈은 입력과 출력을 구분한다. 질의 해석은 질문에서 LOT · 조회 목적 · 필터를 얻고, 관계 조회는 해당 조건과 연계 규칙으로 사실 · 관계 · 원본 ID를 구성한다. 근거 검증은 응답 ID와 조회된 원본을 대조하며, 결과 제공은 검증한 사실을 시간순 이력과 원본 상세로 제시한다. 같은 LOT라도 조회 목적과 조건에 따라 필요한 근거 범위가 달라지므로 생산 · 품질 · 자재 · 반품 기록을 구분한다. 원본 ID는 설명을 실제 기록에 연결하는 키로 유지하고, 사건 내용과 출처를 함께 전달한다. 이때 모델이 선택한 목적과 시스템의 최종 범위 검증 결과를 구분하여 목적 · 응답 행동의 보정 여부를 확인한다. 관계의 존재와 해당 LOT에 대한 원본 근거의 충분성도 별도로 판단하며, 단순한 출력 형식의 충족과 근거를 갖춘 응답을 구분한다.

관계 중심의 질의응답[7]에서 원본 연결을 유지하려면 LOT 번호와 원본 키, 질의 조건의 범위를 함께 확인해야 한다. sLLM이 선택한 근거 ID를 조회 ID 집합과 대조하여 미전달 출처와 필요한 근거의 누락을 구분한다. 근거가 부족하거나 LOT가 존재하지 않을 때는 적절한 거절 또는 추가 확인이 필요한지 응답 행동을 검토한다. 누락된 원본과 연결 조건을 LLM의 생성 문장

으로 채우지 않고 검수 대상으로 남긴다.

질문 범위에 따른 목적 · 응답 행동 보정은 시스템 단계이다. 검증한 결과는 날짜순 사건과 원본 상세로 제공하되, 생산 구간과 알람의 시간 연관을 불량 원인 판정으로 간주하지 않는다. 목적 분류가 맞더라도 필수 근거가 빠질 수 있으므로 분류 성공과 원본 인용 성공을 구분한다. 이러한 누락과 불일치 사례는 향후 HITL 검토에서 원본 ID와 연계 규칙을 보완하기 위한 대상으로 활용한다.

2.2 실험 구성 및 평가 지표

LLM 모델별 성능을 분석하기 위해 Qwen3 0.6B · 1.7B[8], Gemma 3 1B[9] 및 SmolLM2 1.7B[10]를 B0(LLM), B1(RAG), B2(Tool), B3(Tool+RAG), P(제안 시스템)의 다섯 조건에서 비교하였다. 고정 스냅샷에 대해 기존 LOT 80문항과 부재 LOT 4문항을 조합별 1회 실행하여 총 1,680건을 수집하였다.

B0는 조회 근거 없이 질의와 공통 프롬프트를 제공하고, B1은 BM25 검색 근거, B2는 스냅샷 조회 도구를 사용한다. B3는 검색과 도구를 함께 사용하며 P는 최종 범위 검증과 목적 · 응답 행동 보정을 포함한다. 조회 입력은 동결된 기록이며 실제 MES · GraphDB의 실시간 조회 성능을 측정한 것은 아니다. 또한 GraphDB의 효과를 분리해 확인하기 위해 RDB 조회와 GraphDB 연계 조회의 근거 인용 성능을 비교하였다.

표 1 실측 평가 구성과 공통 생성 설정
Table 1 Evaluation setup and shared generation settings

항목	실측 실행의 공통값
평가 구성	84문항 × 4모델 × 5조건
생성 제어	temperature 0 / seed 42
토큰 한도	문맥 8,192 / 답변 최대 4,096
실행 제한	timeout 480초 / GGUF Q8_0
시험 반복	조합별 1회 / 총 1,680건

조회 목적 분류 Macro-F1은 84문항의 8개 목적별 F1을 동일 비중으로 평균한 최종 출력 지표이다. 필수 원본 ID 인용 F1은 기존 LOT 80문항에서 정답 · 응답 ID 집합의 정밀도와 재현율을 문항별로 계산한 평균이다. 종합 통과율은 유효 출력 · LOT · 목적 · 응답 행동과 필수 근거 인용 또는 적절한 거절을 함께 충족한 비율이다. 검색 · 생성 평가의 구분[11]에 따라 분류, 인용 및 처리시간을 별도로 해석하였다.

2.3 LLM 모델별 성능 분석

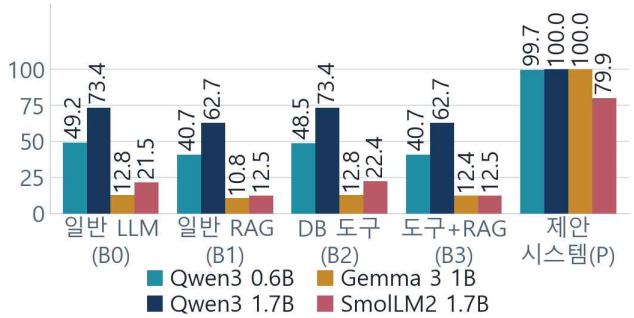


그림 2 조건별 조회 목적 분류 Macro-F1(시스템 최종값)
Fig. 2 Query-purpose Macro-F1 after system processing

그림 2의 목적 분류 성능은 LLM이 LOT의 데이터 확보를 위한 목적 분류를 하기 위한 성능을 나타낸다. Qwen3 1.7B의 B3와 P 원출력 Macro-F1은 모두 62.7%였으나, P의 질문 범위 검증과 규칙 보정 후에는 100.0%(84/84)가 되었다.

표 2 Qwen3 1.7B의 B3 대비 제안 시스템(P)
Table 2 Tool+RAG (B3) versus the proposed system (P)

지표	B3	P	변화
목적 Macro-F1 (%)	62.7	**100.0**	+37.3%p
원본 ID 인용 F1 (%)	54.0	**54.7**	+0.7%p
종합 통과율 (%)	28.6	**54.8**	+26.2%p
평균 응답시간 (초)	42.9	**49.3**	+6.4초

표 2에서 종합 통과는 B3의 24/84에서 P의 46/84로 증가하였다. P는 기존 LOT에서 42/80, LLM의 환각 증상 방지를 위한 부재 LOT 4개 문항에 대해서는 모두 통과하였다. 개선은 주로 조회 목적과 응답 행동의 시스템 보정에 해당한다. 한편 필수 정답 근거 인용을 통과한 문항은 두 조건 모두 50/80이며, 인용 F1의 증가는 0.7%p에 그쳤다.

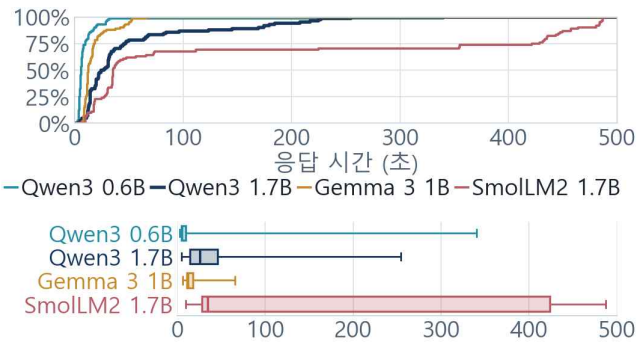


그림 3 P 조건의 모델별 응답시간 분포와 상자 요약
Fig. 3 Response-time ECDF and boxplots under P

그림 3은 P 조건의 모델별 84건을 누적분포와 상자 요약으로 나타낸다. 실패 · 시간 초과도 포함하므로 완료율은 정답률이 아니다. 상자는 1 · 3사분위수, 내부선은 중앙값, 수염은 최솟값-최댓값이다. Qwen3 1.7B의 평균은 B3 42.9초에서 P 49.3초로 6.4초 증가했고, P 중앙값 25.8초에서 지연 편차가 확인된다.

그림 4의 Qwen3 1.7B · P 최종 조회 목적은 84/84건 일치했다. 그러나 필수 원본 인용을 충족한 문항은 50/80건(62.5%)이다. 목적 분류 · 근거 완전성 · 종합 통과는 서로 다른 지표이며, 분류 개선만으로 근거를 갖춘 LOT 조회가 완료되었다고 볼 수 없다.



정답 / 최종	알람	HOLD	계보	자재	포장	검사	반품	전체
알람	10	0	0	0	0	0	0	0
HOLD	0	11	0	0	0	0	0	0
계보	0	0	10	0	0	0	0	0
자재	0	0	0	11	0	0	0	0
포장	0	0	0	0	10	0	0	0
검사	0	0	0	0	0	21	0	0
반품	0	0	0	0	0	0	10	0
전체	0	0	0	0	0	0	0	1

그림 4 Qwen3 1.7B · P의 조회 목적 혼동행렬(84건)
Fig. 4 System-final purpose confusion matrix (P)

행은 참조 목적, 열은 시스템 최종 목적이다. '전체'는 합계가 아닌 전체 LOT 이력 조회 목적이다.

2.4 문항 유형별 실패 분석과 규칙 보강 방향

표 3은 각 조건의 84문항에 대한 종합 통과율이다.

표 3 조건별 LOT 질의 종합 통과율(%, 각 84문항)
Table 3 Overall LOT-task pass rates (n=84)

모델	B0	B1	B2	B3	P
Qwen3 0.6B	0.0	0.0	0.0	0.0	**4.8**
Qwen3 1.7B	2.4	28.6	2.4	28.6	**54.8**
Gemma 3 1B	0.0	0.0	0.0	0.0	**4.8**
SmolLM2 1.7B	0.0	0.0	0.0	0.0	**1.2**

Qwen3 1.7B가 기존 LOT의 근거를 포함한 과업을 통과한 반면, P의 나머지 모델 통과는 부재 LOT 거절에 한정되었다. 이는 목적 분류 성능과 기록 조회 · 인용을 함께 충족하는 성능을 구분할 필요성을 보여준다.

Qwen3 1.7B의 P 조건은 84문항 중 46건(54.8%)을 통과하고 38건(45.2%)이 미통과하였다. 기존 LOT에서는 검사판정 · 계보 · 포장 · 자재 각 10건과 보류 2건이 통과했고 부재 LOT 4건은 모두 정상 거절하였다. 미통과 38건은 유효 출력이며 실행 · 형식 오류와 출력 잘림은 확인되지 않았다.

미통과는 보류 8건과 상태 · 경보 조회, 측정값 조회, 반품 조회 각 10건이다. 보류는 근거가 있어도 거절했고, 생산 구간 상태 · 경보는 조회 누락, 측정값은 근거 일부만 전달됐다. 반품은 입고만 제시해 LOT의 전후 수불을 포함한 조회 범위를 충족하지 못했다. 조회 범위 · 근거 전달 · 선택의 보완이 필요하다.

행동만 미충족 8건, 근거만 20건, 둘 다 10건이며 행동 18건과 근거 30건은 중복되어 합산하지 않는다. 기록 · 조회 범위 · 연결 · 생산 시간과 답변의 근거 선택을 전문가가 점검해 규칙과 모델의 개선 대상을 구분한다.

2.5 RDB 대비 GraphDB 근거 인용 효과

RDB · GraphDB 근거 인용 실험은 GraphDB 자체의 효과를 확인하기 위한 비교 실험으로, 모델별 분석에서 필수 인용이 두 조건 모두 50/80건에 그쳐 근거 선택 · 분할 전달을 조정한 뒤 84문항에서 관계형 DB(RDB) 테이블 조회와 GraphDB 관계 확장을 더한 연계 조회를 비교했다. 두 조건은 sLLM 조회계획 · 목적 · 행동 보정이 같고 관계 확장 여부만 다르며, 목적 F1은 모두 100.0%였다.

표 4 RDB 조회와 GraphDB 연계 조회의 근거 인용 비교
Table 4 Evidence citation with RDB versus GraphDB retrieval

지표	RDB	연계조회	차이
필수 후보 완전성	75/80	**80/80**	+5문항
최종 필수 인용	67/80	**71/80**	+4문항
원본 ID 인용 F1 (%)	67.9	**70.2**	+2.2%p
종합 통과율 (%)	84.5	**89.3**	+4.8%p

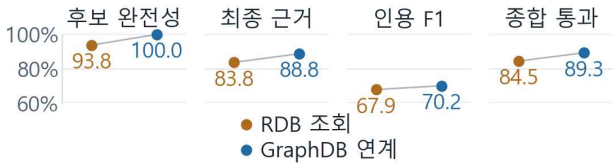


그림 5 RDB 대비 GraphDB 근거 보완 비교
Fig. 5 Evidence completion with RDB versus GraphDB

GraphDB 관계 확장은 RDB 조회에서 누락된 LOT-생산-이벤트 91건과 검사 의뢰-측정값 40건을 복구해 2문항이 추가 통과했다. 다른 2건은 선택 변화가 동반됐고 미통과 9건은 남았다.

Ⅲ. 결 론

제안 프레임워크는 분산된 제조 기록의 관계 조회와 원본 ID 검증을 자연어 LOT 질의에 연결하였다. LLM 모델별 성능 분석에서 Qwen3 1.7B를 사용한 시스템의 근거 기반 종합 통과율은 28.6%에서 54.8%로 높아졌지만, 인용 F1 변화는 작고 평균 응답시간은 증가하였다. RDB와 GraphDB의 근거 인용 비교에서는 GraphDB 관계 확장으로 필수 후보 완전성이 75/80에서 80/80, 종합 통과율이 84.5%에서 89.3%로 향상되어 GraphDB의 근거 연결 효과를 확인하였다.

향후에는 누락 근거와 과잉 거절 사례를 전문가 참여(HITL)로 검토하고, 필수 원본 ID · 연결 조건과 전문가 피드백을 보상 학습 데이터로 축적한다. 이를 활용한 강화학습[12]으로 LLM이 연계 규칙과 조회 전략의 보완 후보를 학습하도록 하되, 전문가 검증과 회귀 평가를 통과한 후보를 시스템에 반영하는 개선안을 제안한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] S. Knollmeyer et al., "Document GraphRAG: Knowledge Graph Enhanced Retrieval Augmented Generation for Document Question Answering Within the Manufacturing Domain," Electronics, 14(11), 2102, 2025.

[2] Z. Yuan et al., "Chat with MES: LLM-driven user interface for manipulating garment manufacturing system through natural language," Journal of Manufacturing Systems, 80, pp. 1093-1107, 2025. doi:10.1016/j.jmsy.2025.02.008.

[3] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," NeurIPS, 2020.

[4] H. Fan et al., "MetalMind: A knowledge graph-driven human-centric knowledge system for metal additive manufacturing," npj Advanced Manufacturing, 2, 25, 2025. doi:10.1038/s44334-025-00038-9.

[5] 차현우, 정인우, 문현석, "BIM 데이터의 추론 검색을 위한 GraphRAG기반 지식그래프 질의 자동 생성 모델 개발: 라멘교를 중심으로," 한국전산구조공학회논문집, 39(1), pp. 59-70, 2026. doi:10.7734/COSEIK.2026.39.1.59.

[6] 유재석, 홍아름, "제조업 AI 확산을 위한 On-Premise RAG의 실증적 타당성 분석 연구," 스마트미디어저널, 15(1), pp. 42-50, 2026. doi:10.30693/SMJ.2026.15.1.42.

[7] 남정재 외, “RGQA: Reasoning Guideline을 활용한 LLM 기반 KGQA,” 지능정보연구, 30(2), pp. 225-237, 2024.

[8] Qwen Team, “Qwen3 Technical Report,” arXiv:2505.09388, 2025.

[9] Gemma Team, “Gemma 3 Technical Report,” arXiv:2503.19786, 2025.

[10] L. Ben Allal et al., “SmolLM2: When Smol Goes Big—Data-Centric Training of a Small Language Model,” arXiv:2502.02737v1, 2025.

[11] S. Es et al., “RAGAs: Automated Evaluation of Retrieval Augmented Generation,” EACL System Demonstrations, pp. 150-158, 2024.

[12] L. Ouyang et al., “Training language models to follow instructions with human feedback,” Advances in Neural Information Processing Systems, vol. 35, 2022.

공개 데이터를 활용한 YOLOv8 기반 꿀벌 질병 탐지 연구

이일주, 채민선*, 유재수**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 정보통신공학부

arraybox@chungbuk.ac.kr, *mschae@cbnu.ac.kr, **yjs@chungbuk.ac.kr

A Study on YOLOv8-Based Honeybee Disease Detection Using Public Data

Il-Ju Lee, Min-Seon Chae*, Jaesoo Yoo**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**School of Information and Communication Engineering, Chungbuk National Univ

Abstract

This paper compares three YOLOv8 detectors (n, s, m) for honeybee disease detection on a public dataset under identical conditions. From the validation split of the AI Hub honeybee disease diagnosis image dataset (31,095 labels, 1920×1080), a class-balanced subset of 7,298 images was built for seven classes of larvae and adults (normal, varroa infestation, chalkbrood, foulbrood, deformed wing virus). Each model was trained with five random seeds, and the differences were tested with paired t-tests and bootstrap confidence intervals on 733 test images. The mean mAP@0.5 was 0.894 for YOLOv8n, 0.902 for YOLOv8s, and 0.909 for YOLOv8m, and only the m-n difference (1.5 percentage points, $p<0.001$) was significant in both tests. The gap came mostly from adult varroa, whose AP rose from 0.639 (n) to 0.717 (m), accounting for about 73% of the difference. Adult varroa errors were confusions with normal adults rather than missed detections; reducing another class to the same number of training objects did not lower its AP, and a 1280-pixel input gave no significant gain. On a CPU, YOLOv8n ran at 25.7 ms per image versus 119.1 ms for YOLOv8m, suggesting YOLOv8m for GPU environments and YOLOv8n for CPU-only environments.

Key words : YOLOv8, Honeybee disease, Object detection, Varroa mite, Public dataset, Class imbalance

Ⅰ. 서 론

꿀벌응애 등 병해충으로 2022년 국내 양봉농가의 월동 폐사율은 36%에 달하였고[1], 2025년 전국 감시에서 응애와 날개불구바이러스(DWV) 검출률은 가을에 각각 87.9%, 97.0%까지 증가하였다[2]. 영상 기반 YOLO 탐지 연구[3]-[7]는 주로 자체 데이터의 응애에 집중되었고, 공개 데이터[9]는 전체 성능(mAP 80%)만 제시하여 질병별 난이도를 알 수 없다. 이에 본 연구는 공개 데이터에서 YOLOv8[8] n, s, m을 같은 조건으로 비교하고, 검출이 어려운 질병과 그 원인을 분석한다.

Ⅱ. 본론

AI Hub 꿀벌 질병 진단 이미지 데이터[9]의 Validation 분할에서, 유충과 성충의 정상 및 질병 상태로 구성된 7개 클래스별로 최대 1,500장을 무작위 추출(seed 42)하였다. 긴 변을 640 px로 축소한 뒤 8:1:1로 분할하여 7,298장(train 5,836, val 729, test 733)을 구성하였으며, 원본이 532장뿐인 성충_응애는 전량을 사용하였다. 이미지 수는 맞추었으나 한 이미지에 정상 개체가 여러 개 포함되어, 학습 객체 수는 유충_정상 15,236개, 성충_응애 460개로 불균형이 남는다. 촬영 환경은 그림 1과 같이 백색 배경 단일 개체, 벌통 출입구, 소비(벌집틀)의 세 가지이다. 또한 응애 클래스의 박스는 진드기가 아니라 감염 개체 전체를 감싸므로, 판별 단서인 진드기는 박스 안의 작은 일부이다.

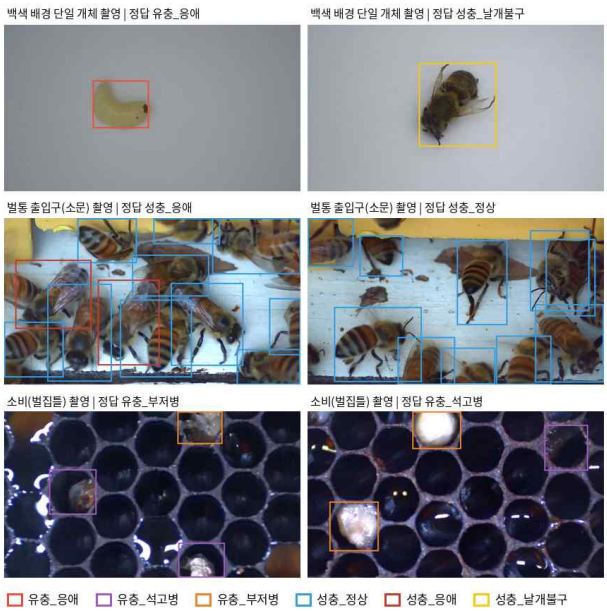


그림 1 촬영 환경별 정답 라벨 예시 (test 이미지)

Fig. 1 Ground-truth examples by imaging condition

세 모델은 COCO 사전학습 가중치에서 입력 640, 배치 16, 100 epoch으로 학습하였으며(Tesla V100 1장)[8], 학습 seed에 따른 변동을 확인하기 위해 seed 42, 1, 2, 3, 4로 5회씩 반복하였다. 각 학습에서는 검증 데이터의 mAP@0.5:0.95가 가장 높은 epoch의 가중치를 평가에 사

용하여, 학습 후반의 과적합이 결과에 반영되지 않도록 하였다. 평가 지표는 수식 (1)의 mAP이다.

$$mAP = \frac{1}{N}\sum_{i=1}^{N} AP_i \qquad (1)$$

수식 (1)에서 N은 클래스 수(7), AP는 클래스별 정밀도–재현율 곡선 아래 면적이며, IoU 0.5 기준 값을 mAP@0.5로 표기한다. 모델 간 차이는 seed별로 짝지은 대응표본 t–검정과 평가 데이터 부트스트랩(1,000회)의 95% 신뢰구간으로 검증하고, 다중 비교를 고려하여 본페로니 보정($\alpha' = 0.0042$)을 적용하였다.

표 1 모델별 성능 비교 (seed 5회 평균±표준편차, test 733장)
Table 1 Performance comparison of YOLOv8 models (mean±SD over five seeds)

모델	mAP@0.5	mAP@0.5:0.95	파라미터	GPU (ms)	CPU (ms)
YOLOv8n	0.894±0.001	0.759±0.002	3.0M	7.5	25.7
YOLOv8s	0.902±0.007	0.771±0.004	11.1M	7.7	54.1
YOLOv8m	0.909±0.004	0.777±0.003	25.9M	9.6	119.1

추론 시간: 이미지 1장 기준, GPU Tesla V100, CPU 8 스레드

표 1과 그림 2와 같이 5회 평균 mAP@0.5는 YOLOv8n 0.894, YOLOv8s 0.902, YOLOv8m 0.909로 모델이 클수록 높았으나, n과 m의 차이는 1.5%p였다. 대응표본 t–검정에서 유의한 차이는 m과 n뿐이었고($p<0.001$), 부트스트랩 95% 신뢰구간도 [+0.33, +3.22]%p로 0을 포함하지 않았다. 반면 CPU 추론 시간은 m이 n의 4.6배였다.

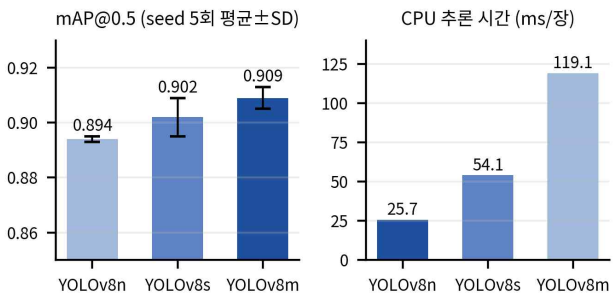


그림 2 모델별 정확도(seed 5회 평균±표준편차)와 CPU 추론 시간
Fig. 2 Accuracy (mean±SD over five seeds) and CPU inference time

클래스별로는 성충_응애와 유충_부저병이 세 모델 모두에서 낮았다(그림 3). 모델 크기의 효과는 성충_응애에 집중되어 n 0.639에서 m 0.717로 7.8%p 올랐으며($p<0.001$), 이는 전체 차이의 약 73%에 해당한다. 나머지 클래스의 차이는 2%p 이내였다[6], [10].

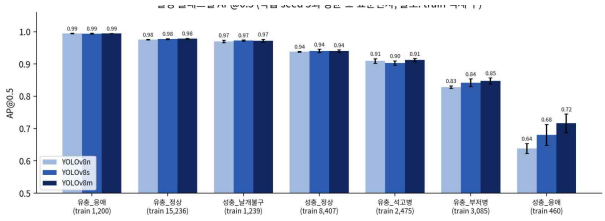


그림 3 클래스별 AP@0.5 (seed 5회 평균±표준편차)
Fig. 3 Per–class AP@0.5 (mean±SD over five seeds)

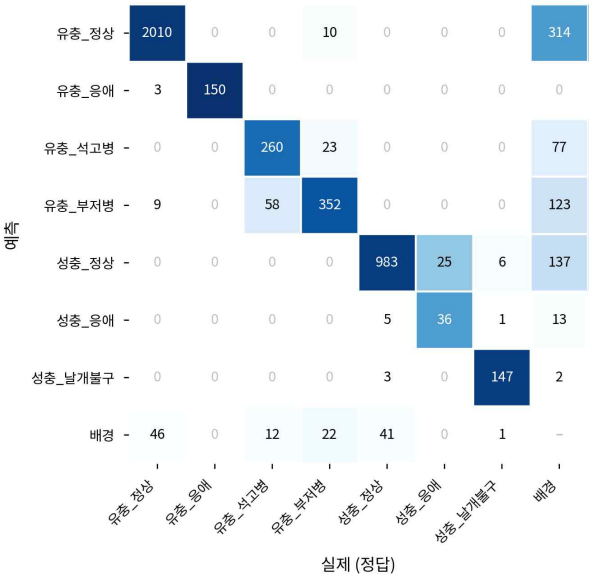


그림 4 YOLOv8m 혼동행렬 (seed 42, test 733장)
Fig. 4 Confusion matrix of YOLOv8m (seed 42)

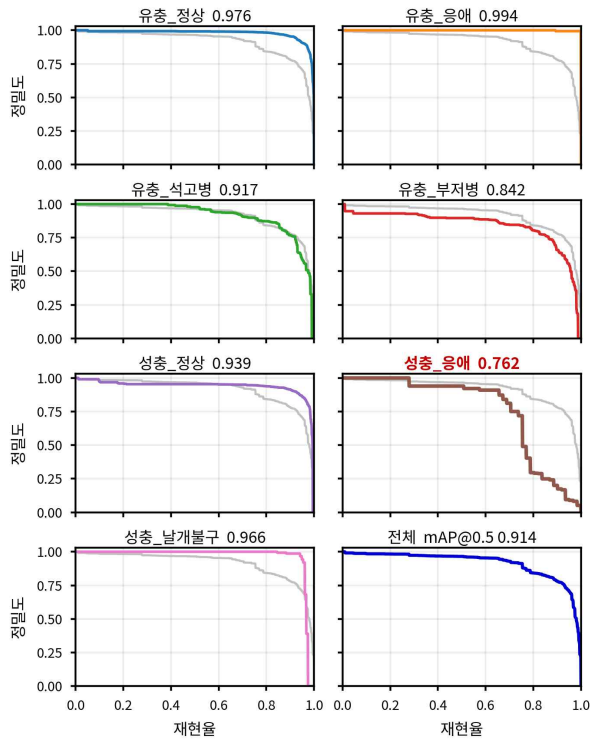


그림 5 YOLOv8m의 클래스별 PR 곡선 (seed 42, 회색: 전체 평균)
Fig. 5 Per–class PR curves of YOLOv8m (seed 42)

YOLOv8m(seed 42)의 혼동행렬(그림 4)에서 성충_응애 61개 중 25개는 성충_정상으로 예측되었고 미검출은 없었으며, 유충_부저병과 유충_석고병은 서로 23건, 58건 혼동되었다. PR 곡선(그림 5)에서 성충_응애는 재현율 0.75 이후 정밀도가 0.5 아래로 떨어졌다.

그림 6은 성충_응애 박스를 입력 해상도별로 확대한 것이다. 진드기가 보이는 경우 입력 640에서도 약 20 px로 남았으나, 일부 박스는 원본에서도 진드기가 보이지 않았다. 실제로 입력 해상도를 1280으로 높인 실험(YOLOv8n, seed 3회)에서 성충_응애 AP@0.5는 0.643에서 0.692로 올랐으나 유의하지 않았고(p=0.29), 성충_날개불구의 학습 객체를 성충_응애와 같은 460개로 줄여도 AP는 0.971에서 0.966으로 유지되었다. 반면 뒤집기·이동·크기 증강을 제거하면 성충_응애 AP가 16.0%p 낮아졌다. 따라서 성충_응애의 오류는 표본 수나 해상도보다 진드기의 가시성과 관련된 것으로 판단된다.



그림 6 성충_응애 박스의 해상도별 확대 (a) 진드기 보임 (b) 보이지 않음

Fig. 6 Adult varroa boxes at each input resolution

Ⅲ. 결론

학습 seed 5회 평균 mAP@0.5는 YOLOv8n 0.894, s 0.902, m 0.909였으며, 반복 학습과 부트스트랩 모두에서 유의한 차이는 m과 n(1.5%p)뿐이었다. 벌통 id 기준 5묶음 교차 검증에서는 mAP@0.5가 YOLOv8m 0.887, YOLOv8n 0.853으로 이미지 단위 분할보다 각각 2.2%p, 4.1%p 낮아져 이미지 단위 분할이 성능을 과대평가함을 확인하였다. 이때 m과 n의 차이는 3.4%p(p=0.023)로 커졌고 그 약 92%가 성충_응애에서 발생하였으나, 묶음 수가 5개로 적어 본페로니 기준에서는 유의하지 않았다. 따라서 GPU 환경이나 새 벌통에 적용할 때는 YOLOv8m이 적합하고, YOLOv8n은 CPU 환경에서 추론 속도(4.6배)가 중요할 때 사용하되 성충_응애 검출 성능의 하락을 고려해야 한다. 주된 오류는 성충_응애와 정상 성충, 유충_부저병과 석고병 사이의 혼동이었으며, 향후 벌통 수를 늘린 검증과 부저병·석고병 구분을 위한 특징 추출 구조를 검토할 계획이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] 강용락, 권순호, 정철의, "양봉농가 설문 기반 꿀벌 병해충 발생과 월동 폐사의 상관성 분석," Journal of Apiculture, vol. 39, no. 3, pp. 185-193, 2024, doi: 10.17519/apiculture.2024.09.39.3.185.

[2] J.-H. Kim et al., "Seasonal dynamics of honey bee pathogens and Varroa destructor infestation in South Korea," Front. Insect Sci., vol. 6, Art. no. 1891174, 2026.

[3] S. Bilik et al., "Visual diagnosis of the Varroa destructor parasitic mite in honeybees using object detector techniques," Sensors, vol. 21, no. 8, Art. no. 2764, 2021.

[4] 이용선, 조현수, 김보영, 문지훈, "서양꿀벌 군집에서 꿀벌응애 감염의 비파괴 검출을 위한 YOLOv8 기반의 2단계 프레임워크," 한국컴퓨터정보학회논문지, 제29권, 제10호, pp. 137-148, 2024.

[5] H.-G. Lee, J.-Y. Shin, S.-B. Kim, M.-J. Kim, M. S. Kim, H. Lee, and C. Mo, "Enhancing bee mite detection with YOLO: The role of data augmentation and stratified sampling," Agriculture, vol. 15, no. 11, Art. no. 1221, 2025.

[6] J.-Y. Shin, H.-G. Lee, S.-B. Kim, and C. Mo, "An automated AI-based vision inspection system for bee mite and deformed bee detection using YOLO models," Agriculture, vol. 16, no. 8, Art. no. 840, 2026.

[7] S. Bilik et al., "Machine learning and computer vision techniques in continuous beehive monitoring applications: A survey," Comput. Electron. Agric., vol. 217, Art. no. 108560, 2024.

[8] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," version 8.0.0, 2023. [Online]. Available: https://github.com/ultralytics/ultralytics

[9] ㈜에스엠시스템즈 외, "꿀벌 질병 진단 이미지 데이터," AI-Hub(한국지능정보사회진흥원), 2024. [Online]. Available: https://aihub.or.kr (dataSetSn=71667)

[10] K. Oksuz et al., "Imbalance problems in object detection: A review," IEEE Trans. Pattern Anal. Mach. Intell., vol. 43, no. 10, pp. 3388-3415, 2021.

객체 자세 추정과 SLAM을 비동기 결합한 6D 객체 지도 생성 시스템

†이도현, †박정철*, 김한진**, 황영배***
충북대학교 산업인공지능학과, *한국전자통신연구원 공간콘텐츠연구본부
**충북대학교 산업인공지능연구센터, ***충북대학교 정보통신공학부
ldh293@naver.com, *jucpark@etri.er.kr, **gks359@chungbuk.ac.kr, ***ybhwang@chungbuk.ac.kr

6D Object-Level Mapping Based on Asynchronous Fusion of Object Pose Estimation and SLAM

†Dohyeon Lee, †Jungchul Park*, Hanjin Kim**, Youngbae Hwang***
Department of Industrial AI, Chungbuk National Univ.,
*Spatial Content Research Division, Electronics and Telecommunications Research Institute.,
**Industrial AI Research Center, Chungbuk National Univ.,
***Department of Intelligent Systems and Robotics, Chungbuk National Univ

Abstract

This paper proposes a 6D pose-based object-level mapping method that asynchronously integrates camera poses estimated by SLAM with object pose estimates. The proposed system enables a mobile robot to store and update the positions and orientations of observed objects in a global map coordinate system while navigating through an environment. Beyond representing object geometry, maintaining such a map requires explicit management of object poses and erroneous observations. In addition, differences in the processing rates of SLAM and object pose estimation must be considered when combining their outputs. To address these issues, the proposed method verifies object candidates and pose estimates before incorporating them into the map and associates each observation with the camera pose at its image capture time. Object observations are stored relative to SLAM keyframes so that pose corrections resulting from loop closure can be reflected in the map. Repeated observations and depth information are used to manage object registration and removal, while agreement among observations guides pose updates. Experiments on public datasets show that the proposed method produces maps with fewer falsely registered objects than the evaluated comparison methods, and achieves higher mapping F1 scores even when identical object recognition results are supplied to the mapping modules. Restricting candidates to text-prompted detections made the per-frame processing about 1.6 times faster than the recognition scheme of SAM-6D. For the objects registered in the map, the stored 6D poses had a median rotation error of 2.9° , whereas fitting CAD models to the point-cloud maps of FM-Fusion resulted in 20.0° .

Key words : SLAM, 6D Object Pose Estimation, Pose Verification, Object-Level Mapping, Asynchronous Fusion
† These authors contributed equally to this work

Ⅰ. 서 론

최근 제조 및 물류 산업에서는 작업의 효율성을 위해 자율 주행 로봇과 로봇 매니퓰레이터를 활용한 물품 관리 자동화에 대한 연구가 활발히 진행되고 있다[1]. 이러한 환경에서 로봇이 물품을 탐색하고 이동 및 조작하기 위해서는 주변 환경에 대한 자신의 위치 정보를 추정하는 것뿐만 아니라, 물품의 위치와 방향을 정확하게 인식하는 과정이 필요하다. 특히 객체의 3차원 위치와 회전 정보를 추정하는 6D 객체 포즈 추정(Object Pose Estimation)은 로봇이 대상 객체를 인식하고 조작하기 위한 핵심 기술로 다루어지고 있다[2].

본 논문에서는 객체 포즈 추정 알고리즘과 SLAM의 위치 정보를 결합하여 객체의 6D 포즈를 3차원 지도 좌표계에 등록하고 지속적으로 관리하는 Object Pose Map 기반 시스템을 제안한다. 제안하는 시스템은 객체 포즈 추정 결과를 단일 프레임의 카메라 좌표계가 아닌 전역 지도 좌표계에 등록하고 관리함으로써, 주행 중인 로봇이 주변 객체의 위치 및 방향 정보를 지속적으로 기억하고 시각화할 수 있도록 한다. 또한 모든 프레임에서 객체 포즈 추정을 반복적으로 수행하지 않더라도 SLAM을 통해 추정되는 카메라의 위치 변화를 기반으로 기존 객체의 상대적인 위치를 표현할 수 있으며, 시야에서 벗어난 객체에 대해서도 등록된 정보를 유지할 수 있다.

그러나 개방형 문구 검출이나 영상 전체 분할로 얻은 객체 후보를 그대로 지도에 누적하면 잘못 인식된 객체가 반복하여 등록되고, 후보가 많을수록 포즈 추정에 걸리는 시간도 길어진다. 본 논문에서는 이를 해결하기 위해 대상 객체의 이름 문구로 검출한 상자만 후보로 사용하고, 후보와 포즈 가설을 단계별 기준으로 검증하며, 반복 관측과 관측 사이의 합의로 객체의 등록과 포즈를 결정하였다. 실험에서는 공개 데이터셋을 촬영 속도로 입력하여 기존 객체 수준 지도 방법과 지도에 등록된 객체의 정확도, 처리 속도, 6D 포즈 정확도를 비교하였다.

Ⅱ. 관련 연구

SLAM(Simultaneous Localization and Mapping)은 로봇이 이동하면서 자신의 위치를 추정하고 주변 환경의 지도를 작성하는 기술이다. 카메라 기반의 대표적인 SLAM으로는 단안, 스테레오, RGB-D 카메라에서 추출한 특징점을 이용하는 ORB-SLAM3[3]이 있으며, LiDAR 기반으로는 NDT 정합과 자세 그래프 최적화를 사용하는 hdl_graph_slam[4] 등이 있다. ORB-SLAM3와 hdl_graph_slam은 이전에 지나간 장소를 다시 인식하면 루프 폐쇄(Loop Closure)를 수행하여 그동안 누적된 위치 추정 오

차를 보정한다.

객체의 6D 포즈를 추정하는 기존 연구들은 대상 객체를 사전에 학습해야 하는 경우가 많았으나, 최근에는 CAD 모델을 이용하여 학습하지 않은 객체의 포즈를 추정하는 SAM-6D[5], FoundationPose[6]와 같은 Zero-shot 객체 포즈 추정 방법이 제안되었다. SAM-6D는 SAM[7]으로 영상 전체를 분할하여 객체 후보를 얻은 뒤, CAD 모델에서 렌더링한 템플릿 이미지와 비교하여 대상 객체를 찾고 6D 포즈를 추정한다. 이때 분할된 모든 후보를 템플릿과 비교하므로, 장면에 물체가 많을수록 후보 수와 처리 시간이 함께 늘어난다. FoundationPose는 CAD 모델 또는 객체의 참조 영상을 이용하여 새로운 객체의 포즈 추정을 수행한다. 이러한 연구는 객체의 6D 포즈를 추정 및 추적에 초점을 두고 있으며, 추정된 여러 객체를 SLAM의 전역 지도에 저장하거나 반복 관측에 따라 관리하는 연구와는 구분된다.

SLAM++[8]와 Fusion++[9]은 객체를 지도 구성 요소로 사용하여 카메라와 객체의 자세를 함께 추정하는 객체 수준 SLAM을 제안하였다. SLAM++은 사전에 정의된 객체의 3D 모델을 이용하여 객체를 인식하고 위치 추정과 지도 생성에 활용한다. Fusion++은 관측된 객체마다 복셀 기반 3D 모델을 생성하고, 객체의 6D 포즈를 포즈 그래프에서 관리하며 루프 폐쇄에 따른 보정을 반영한다. 본 연구는 SLAM 내부를 수정하지 않고 출력된 자세와 키프레임 정보를 이용하여 객체 지도를 생성한다.

최근에는 비전-언어 모델의 인식 결과를 활용하는 객체 수준 지도 생성 방법도 제안되었다. FM-Fusion[10]은 여러 프레임에서 얻은 객체의 특징 정보를 객체별 복셀 기반 3D 모델을 활용한 지도로 통합한다. DualMap[11]은 전역 지도와 국소 지도를 활용하여 환경 변화에 따른 객체 상태를 갱신하고, 자연어 기반 객체 탐지에 필요한 정보를 관리한다. 이러한 연구들은 객체의 의미와 공간 정보를 지도에 통합하는 데 초점을 두며, 객체를 점군이나 복셀로 저장하므로 지도에서 객체의 방향을 직접 얻을 수는 없다.

본 논문에서는 SLAM으로 추정한 카메라의 위치와 객체의 6D 포즈 추정 결과를 결합하여 객체의 위치와 자세를 지도 좌표계로 변환하고, 이후 객체 정보를 SLAM의 키프레임과 함께 저장하고 갱신하여, 로봇이 이동하는 동안 주변 객체의 위치와 자세를 실시간으로 확인할 수 있는 객체 수준의 지도를 생성하는 방법을 제안한다.

Ⅲ. 본론

1. 시스템 구성

본 논문에서는 서로 다른 주기로 출력되는 SLAM 자세와 객체 포즈를 촬영 시각에 맞춰 결합하고, 반복 관측을 이용하여 객체의 위치와 방향을 지도에서 관리하는 방법을 제안한다. 이를 위해 객체 후보와 포즈 가설을 단계별로 검증하고, 검증된 관측을 키프레임 기준으로 저장한다. 이후 관측의 누적 여부와 위치 · 방향의 일관성에 따라 객체를 등록하거나 삭제하고 지도에 저장된 포즈를 갱신한다. 전체 처리 과정은 그림 1에 나타내었다.

제안하는 시스템은 SLAM, 객체 인식 및 6D 포즈 추정, Object-Level Mapping 세 부분으로 구성된다. SLAM은 RGB-D 영상을 입력으로 하는 ORB-SLAM3 또는 LiDAR 점군을 입력받는 hdl_graph_slam을 사용하며, 내부 알고리즘을 수정하지 않고 센서 자세와 키프레임 정보를 이용한다. 객체 인식 및 6D 포즈 추정은 RGB-D 영상과 대상 객체의 CAD 모델을 입력받아 카메라 좌표계 기준의 객체 6D 포즈를 추정한다. 두 과정은 서로 다른 주기로 독립적으로 실행되며, Object-Level Mapping에서는



그림 1 전체 시스템 처리 과정
Fig. 1 Overall processing pipeline of the proposed system

각 출력의 촬영 시각과 좌표계를 맞추어 객체별 관측을 누적한다. SLAM용 센서와 객체 인식용 카메라가 다른 경우에는 두 센서 사이의 외부 보정 변환을 적용한다. 대상 객체의 CAD 모델은 사전에 주어지며, 각 CAD 모델을 42개 시점에서 렌더링하여 템플릿을 생성하고, 객체 인식에 사용할 특징을 미리 계산한다.

2. 객체 인식 및 포즈 검증

객체 인식 및 6D 포즈 추정은 후보 생성, 후보 검증, 객체 포즈 가설 생성, 포즈 검증의 순서로 동작한다. 후보 생성에는 YOLO-World[12]와 MobileSAM[13]을 사용한다. YOLO-World에 대상 객체를 설명하는 문구를 프롬프트로 입력하여 후보 상자를 얻고, MobileSAM으로 각 상자 내부의 객체 마스크를 생성한다. 영상 전체를 분할하는 방식과 달리 대상 객체의 문구에 해당하는 상자만 후보로 남기므로, 이후의 후보 검증과 포즈 추정을 수행하는 후보 수가 줄어든다.

문구 기반 검출 결과에는 대상 객체와 외형이 유사한 다른 객체가 포함될 수 있다. 본 논문에서는 객체 후보와 CAD 템플릿 사이의 유사도를 단계별로 평가하여 후보를 검증한다. 먼저 DINOv2[14]의 이미지 단위 특징으로 의미 유사도를 계산하고, 일정값 기준을 만족한 후보에 대해 마스크 내부의 패치 단위 특징을 이용하여 외형 유사도를 평가한다. SAM-6D에서는 의미 및 외형, 기하 정보를 결합한 점수로 후보를 평가하지만, 제안하는 단계별 평가 방법에서는 개별 기준값을 적용하여 한 단계라도 기준을 만족하지 못하면 해당 후보를 제외한다. 추가로 유사한 대상 객체들 사이의 색상 차이를 활용하기 위해 HSV 색 분포의 유사도 조건을 추가한다. 하나의 객체 후보가 여러 객체들의 기준을 통과한 경우에는 최종 점수가 가장 높은 객체로 판단한다.

후보 검증을 통과한 마스크에 대해서는 SAM-6D의 포즈 추정 네트워크를 이용한다. 마스크 영역의 깊이 정보로 관측 점군을 생성하고, 관측된 객체의 점군과 CAD 모델 점군의 대응 관계로부터 복수의 포즈 가설을 구한다.

포즈 가설은 이미지 기준 2D 투영을 통한 일치 여부 및 가설 사이의 일관성을 이용하여 검증한다. 먼저 각 포즈 가설에 따라 CAD 모델을 이미지에 투영한 영역과 객체 인식 결과인 마스크 사이의 IoU를 계산하고, 관측 점과 대응되는 CAD 모델 표면의 특징 유사도를 평가한다. 두 기준을 통과한 가설 중 절반 이상이 위치와 회전 차이의 임계값을 만족하는 하나의 집합으로 형성되는 경우에만 포즈 결과를 채택한다.

최종 결정된 포즈는 촬영 시각과 함께 객체 지도 관리에 전달한다. 이 때 마스크 IoU와 집합 비율을 기반으로 신뢰도 가중치를 구성한다. 해당 가중치는 여러 프레임에서 관측된 객체의 포즈를 결정할 때 사용한다.

3. 객체 지도 생성

객체 포즈 추정과 SLAM은 서로 다른 주기로 동작하므로, 객체 포즈를 지도에 등록할 때에는 결과가 반환된 시점이 아닌 영상의 촬영 시점에 해당하는 카메라 자세를 사용해야 한다. 이를 위해 촬영 시각 전후의 SLAM 자세를 보간하고, 루프 폐쇄에 따른 자세 보정을 반영하기 위해 각 관측을 촬영 시각에 가장 가까운 키프레임 기준으로 저장한다. T_{AB}를 좌표계 B에서 A로의 변환이라 하면, 관측의 저장과 지도 좌표계 변환은 다음과 같다.

$$T_{KO} = T_{MK}^{-1}\, T_{MC}(t)\, T_{CO} \tag{1}$$

$$T_{MO} = T_{MK}'\, T_{KO} \tag{2}$$

여기서 T_{CO}는 추정된 객체 포즈, $T_{MC}(t)$는 촬영 시각의 카메라 자세이며, T_{MK}와 T'_{MK}는 각각 관측 저장 시점과 현재의 키프레임 자세이다. 키프레임 자세가 보정되면 이에 연결된 관측도 최신 지도 좌표계로 변환한다.

새로운 관측은 같은 종류의 지도 객체 중 30 cm 이내에 있는 가장 가까운 객체에 연결하며, 연결할 객체가 없으면 후보 객체로 관리한다. 반복적인 관측을 통해 존재 확률이 기준값을 넘으면 확정 객체로 등록하고, 이후 시야 안에서 반복적으로 검출되지 않으면 존재 확률을 낮추며, 존재 확률이 일정 기준 이하로 떨어지면 해당 객체는 지도에서 삭제한다. 다만, 장애물에 가려진 상태를 고려하여 객체의 예상 깊이와 측정 깊이를 비교하여 해당 위치에 객체가 없는 것으로 판단하거나 가려진 상태를 구분하여 관리한다.

객체 포즈는 누적된 관측 사이의 위치 · 방향 일관성을 이용하여 결정한다. 각 관측 i에 대해 위치 차이가 25 mm 이하이고 객체의 회전 대칭을 고려한 방향 차이가 20° 이하인 관측들을 모아서 집합 N_i를 구성한다. 관측의 신뢰도 가중치를 w_j라 할 때, 다음과 같이 가중치 합이 가장 큰 집합의 기준 관측을 대표 관측으로 선택한다.

$$i^{*} = \arg\ \max_{\mathrm{i}} \sum_{\mathrm{j}\in \mathrm{N_i}} \mathrm{w_j} \tag{3}$$

객체의 방향은 대표 관측의 회전을 사용하고, 위치는 선택된 집합에 포함된 관측의 신뢰도 가중 평균으로 결정한다. 이를 통해 단순 평균에 비해 이상 관측의 영향을 줄인다. 새로운 관측이 추가되거나 키프레임 자세가 보정될 때마다 객체 포즈를 다시 계산하며, 저장된 객체는 최신 카메라 자세를 이용하여 영상에 투영한다.

Ⅳ. 실험 및 결과

1. 실험 환경 및 평가 방법

실험은 NVIDIA RTX 5090 Laptop GPU를 탑재한 PC에서 수행하였다. 객체 인식 및 검증 구성과 객체 지도 생성 방법이 최종 지도 성능에 미치는 영향을 평가하기 위해 YCB-Video[15], YCB-M[16], ObChange[17] 데이터셋을 사용하였다. YCB-Video와 YCB-M은 탁자 위에 객체가 배치된 장면이며, ObChange는 실내 공간을 반복 방문하며 촬영하여 카메라 이동과 방문 간 객체 배치 변화가 포함된 데이터셋이다. 객체 지도 생성 성능은 ObChange를 중심으로 평가하고, YCB-Video와 YCB-M에서도 보조적으로 비교하였다.

후보 생성에서 YOLO-World에 입력한 문구는 객체마다 하나씩 정하였으며, 데이터셋의 객체 이름 대신 영상에서 보이는 색과 종류를 나타내는 명사구로 하였다. 세 가지 공개 데이터셋에는 같은 문구를 사용하였고, ObChange에서는 데이터셋에 포함된 11종을 검출 대상으로 설정하였다.

객체 지도 생성 성능은 세 데이터셋에서 기존 객체 지도 생성 방법들과 비교하고, 정밀도, 재현율 및 F1으로 평가하였다. 영상은 촬영 속도로 입력하며, 객체 인식이 수행되는 동안 도착한 프레임은 건너뛰고 처리가 완료되면 최신 프레임을 입력한다. 카메라 자세 차이의 영향을 배제하기 위해 각 방법에는 데이터셋에서 제공하는 동일한 카메라 자세를 사용한다. 인식 결과가 반환될 때마다 객체 지도를 갱신하고, 영상이 종료된 시점에서의 지도를 평가한다. 지도에 등록된 객체의 점군과 정답으로 제공된 객체의 점군 IoU가 0.25 이상인 경우 올바르게 등록된 객체로 판단하고, 이를 바탕으로 정밀도, 재현율 및 F1을 계산한다. 3절에서는 프레임마다 출력한 객체 포즈의 정확도와 처리 시간을, 6절에서는 지도에 등록된 객체의 6D 포즈 정확도를 평가하였다.

2. 객체 인식 및 객체 검증

제안하는 객체 인식 및 6D 포즈 추정 구성이 객체 지도 생성에 미치는 영향을 확인하기 위해, 객체 후보 생성과 검증 방식을 바꾼 네 가지 구성으로 각각 지도를 만들어 비교하였다. 객체 후보 생성은 SAM-6D와 같이 FastSAM으로 영상 전체를 분할하는 경우와 제안 방법과 같이 문구 검출 상자를 사용하는 경우의 두 가지 구성으로, 객체 후보 검증은 SAM-6D의 총점 방식과 제안 방법의 단계별 기준으로 나누었다. 지도 생성 방법은 제안하는 방식으로 동일하게 적용하였으며, 표 1은 ObChange와 YCB-Video에서 3회 반복한 결과의 평균이다.

제안 방법은 SAM-6D 방식에 비해 ObChange에서 올바르게 등록한 객체는 3.4개 적었으나, 잘못 등록한 객체가 42.3개에서 23.0개로 감소하여 F1이 59.0 %에서 63.7 %로 높아졌다. YCB-Video에서도 잘못 등록한 객체가 26.0개에서 8.0개로 줄어 F1이 78.5 %에서 81.5 %로 높아졌다. SAM-6D 방식은 프레임마다 가장 높은 총점으로 객체를 선택하므로, 한 점수가 낮아도 다른 점수가 높은 잘못된 객체가 선택되고, 이러한 결과가 여러 프레임에서 반복되면 지도에 객체로 등록된다.

객체 후보 검증 방식으로 보면 후보 생성 방법 모두 제안하는 방법인 단계별 검증을 사용했을 때 잘못 등록한 객체 수가 줄었으며, YCB-Video 데이터셋에서의 문구 검출 기반 방법을 제외하고 F1이 높아졌다. 또한 단계별 검증을 사용한 두 구성은 처리한 프레임 수가 크게 달랐는데, 이는 3절의 처리 속도 차이에서 비롯된다.

표 1 객체 인식 구성에 따른 객체 지도 비교
Table 1 Object maps by recognition configuration

후보 생성	후보 검증	ObChange		YCB-Video	
		정밀도	F1	정밀도	F1
FastSAM	총점	53.5	59.0	66.8	78.5
FastSAM	제안 방법	59.9	61.4	77.8	82.4
YOLO-World	총점	55.0	58.4	79.5	85.1
YOLO-World	제안 방법	66.3	63.7	84.4	81.5

3. 객체 인식 구성에 따른 프레임 단위 성능과 처리 속도

2절의 네 가지 구성에 대해 YCB-Video와 YCB-M의 프레임마다 출력한 객체 포즈의 정확도와 처리 시간을 측정하였다. 출력한 포즈의 ADD-S[15]가 객체 지름의 10 % 미만이면 성공으로 보고 정밀도, 재현율, F1을 계산하였으며, 처리 시간은 후보 생성부터 포즈 검증까지의 프

레임당 평균이다. 결과는 표 2와 같다.

제안 구성은 SAM-6D 방식보다 처리 시간이 약 1.6배 짧았으며, 영상 전체 분할에 단계별 검증을 적용한 구성과 비교하면 약 6배 짧았다. 문구 검출 자체는 영상 전체 분할보다 느렸으나, 대상 객체의 상자만 후보로 남기므로 이후의 후보 검증과 포즈 추정 횟수가 줄었기 때문이다. 정확도에서는 제안 구성의 정밀도가 YCB-Video에서 가장 높았으나, 단계별 검증이 가려지거나 작게 보이는 객체의 후보도 제거하여 재현율과 F1은 가장 낮았다. 다만 객체 지도에서는 같은 객체가 여러 프레임에서 반복 관측되므로, 2절과 같이 프레임 단위의 누락이 지도의 재현율 감소로 크게 이어지지 않았다.

표 2 객체 인식 구성에 따른 프레임 단위 성능과 처리 시간
Table 2 Per-frame accuracy and processing time by recognition configuration

데이터셋	후보 생성	후보 검증	정밀도	재현율	F1	시간 (ms)
YCB-Video	FastSAM	총점	89.0	72.8	80.1	519
YCB-Video	FastSAM	단계별	90.0	60.3	72.2	2,017
YCB-Video	YOLO-World	총점	91.5	68.5	78.3	382
YCB-Video	YOLO-World	단계별	96.5	52.8	68.3	328
YCB-M	FastSAM	총점	92.3	55.4	69.3	469
YCB-M	FastSAM	단계별	89.0	44.5	59.4	2,033
YCB-M	YOLO-World	총점	92.9	48.8	64.0	352
YCB-M	YOLO-World	단계별	90.8	33.5	48.9	303

단계별은 제안 방법의 후보 검증이다. 정밀도 · 재현율 · F1은 %이다. 정확도는 YCB-Video 900장, YCB-M 925장에서 평가하였고, 시간은 장면 첫 장을 제외한 888장과 893장의 평균이다.

4. 객체 지도 생성

비교 대상은 객체 수준 지도 알고리즘인 FM-Fusion과 DualMap이다. 두 방법은 CAD 모델을 사용하지 않으므로 대상 객체의 이름을 문구로 입력하였고, 객체 인식부터 지도 생성까지 각 방법의 구성을 그대로 실행하였다. 다만 FM-Fusion의 기본 설정은 방 크기의 장면에 맞추어져 있어 작은 객체가 지도에서 걸러지므로 복셀 크기와 객체로 남기는 최소 점 개수를 줄였고, DualMap은 대상 객체가 검출되도록 문구 검출의 기준값을 낮추었다. 두 방법의 지도 생성 설정은 5절의 실험에서도 동일하게 사용하였다.

표 3 기존 객체 지도 방법과의 비교 (F1 %)
Table 3 Comparison with existing object-level mapping methods

방법	ObChange	YCB-Video	YCB-M
FM-Fusion	15.2	75.0	67.6
DualMap	20.2	33.3	35.1
제안 방법	63.7	81.5	78.4

표 3에서 확인할 수 있는 것처럼 방 전체를 촬영한 ObChange에서 세 방법이 올바르게 등록한 객체 수는 FM-Fusion 47개, DualMap 33개, 제안 방법이 45.3개였으며, 잘못 등록한 객체 수는 각각 497개, 220개, 23개였다. FM-Fusion은 제안 방법과 비슷한 수의 대상 객체를 찾을 수 있었고 DualMap은 이보다 적게 찾았으나, 두 방법의 F1이 낮은 주된 원인은 잘못 등록한 객체가 매우 많기 때문이다. 두 방법은 문구 기반 검출 결과를 그대로 지도에 누적하므로, 큰 가구나 배경의 일부에 대상 객체의 이름이 붙어 지도 객체로 등록되었다. 또한 두 방법은 객체를 점군으로 저장하여 지도에서 객체의 방향을 직접 얻을 수 없으나, 제안 방법은 등록한 모든 객체의 6D 포즈를 저장하며, 그 정확도는 6절에서 평가하였다.

5. 동일한 객체 인식 결과에서의 지도 생성 방법 비교

4절에서 두 방법의 F1이 낮은 주된 원인은 객체 인식 단계의 잘못된 검출이었으므로, 지도 생성 단계만 따로 비교하기 위해 제안 방법이 처리한 객체 인식 결과를 두 방법의 지도 생성 방법에 입력하였다. 즉, 이 실험은 두 방법 전체의 평가가 아니라 같은 입력에서의 지도 생성 방법의 차이를 본 것이며, 표 4은 해당 실험 결과이다.

같은 객체 인식 결과를 입력하였을 때 ObChange에서 두 방법의 F1은 56.8 %, 56.1 %로 4절의 15.2 %, 20.2 %보다 높아졌다. 제안 방법의 F1은 세 데이터셋 모두에서 가장 높았다. 이로부터 같은 객체 인식 결과에서도 객체를 등록하는 방법에 따라 지도에 등록된 객체의 F1이 달라짐을 확인하였다. 다만, 두 방법의 지도 생성은 각자의 검출기가 내는 결과를 받도록 설계되었으므로, 객체의 마스크마다 이름 하나가 주어지는 제안 방법의 입력 방법과는 다를 수 있다.

표 4 동일 객체 인식 결과를 입력한 지도 생성 방법의 비교
Table 4 Comparison of map generation methods given the same recognition results

방법	ObChange	YCB-Video	YCB-M
제안 방법의 객체 인식 + FM-Fusion 지도 생성	56.8	78.7	74.9
제안 방법의 객체 인식 + DualMap 지도 생성	56.1	66.3	51.3
제안 방법	63.7	81.5	78.4

6. 지도 객체의 6D 포즈 정확도

지도에 등록된 객체의 6D 포즈 정확도를 ObChange의 2 · 3회차 방문 8개에서 비교하였다. FM-Fusion과 DualMap은 객체를 점군으로 저장하므로, 맞게 등록된 객체의 점군에 같은 CAD 모델을 ICP로 정합하여 포즈를 구하였다. ObChange는 객체의 6D 정답 포즈를 제공하지 않으므로, 데이터셋이 정답 객체로 표시한 재구성 점군에 CAD 모델을 정합한 포즈를 정답으로 사용하였다. 비교 방법에 유리하도록 72개 초기 방향과 물체의 위쪽 방향 정보를 사용하였다. 정답 포즈를 구성할 때 머그컵과 캔은 영상에서 확인한 세운 자세로 제한하였다. 결과는 표 5와 같다.

표 5 지도 객체의 6D 포즈 정확도
Table 5 6D pose accuracy of map objects

방법	맞게 등록	위치 (cm)	방향 (°)	ADD-S (mm)	방향 10° 이내(%)	성공률 (%)
FM-Fusion + CAD 정합	20	2.5	20.0	12.9	35.0	85.0
DualMap + CAD 정합	10	5.2	106.8	18.8	30.0	40.0
제안 방법	17	2.6	2.9	12.4	76.5	88.2

제안 방법은 FM-Fusion과 위치 오차가 비슷하였으나, 방향 오차는 2.9°로 FM-Fusion(20.0°)과 DualMap(106.8°)보다 작았고, 방향 오차 10° 이내인 객체의 비율도 두 배 이상 높았다. ADD-S 성공률은

FM-Fusion과 차이가 작았는데, ADD-S는 가장 가까운 점 사이의 거리로 계산하여 머그컵의 손잡이가 반대쪽에 놓인 포즈도 성공으로 판정하기 때문이다. 점군 정합은 객체의 일부만 관측되면 손잡이와 같이 방향을 결정하는 부분을 구분하기 어려우나, 제안 방법은 영상의 외형 정보를 사용하는 포즈 추정과 관측 사이의 합의로 방향을 결정하였다.

위치 · 방향 오차와 ADD-S는 맞게 등록된 객체의 중앙값이며, 방향 10° 이내 비율과 ADD-S < 객체 지름의 10 %인 성공률은 맞게 등록된 객체 중 비율이다. 회전 대칭으로 구분할 수 없는 회전은 동일한 포즈로 취급하였다.

V. 결론

본 논문에서는 서로 다른 주기로 동작하는 SLAM과 객체 포즈 추정 결과를 촬영 시각에 맞춰 결합하여 6D 객체 지도를 생성하는 방법을 제안하였다. 객체 후보와 포즈 가설을 단계별로 검증하고, 반복 관측을 이용하여 객체의 등록과 삭제를 결정하도록 구성하였다. 또한, 관측 간 위치 · 방향의 일관성을 바탕으로 객체 포즈를 결정하고 키프레임 기준으로 저장하였다. 객체 지도 생성 실험에서 제안 방법은 ObChange에서 F1 63.7 %를 기록하여 FM-Fusion과 DualMap보다 높은 성능을 보였다. 비교 방법보다 잘못 등록된 객체가 적었으며, 동일한 객체 인식 결과를 입력한 비교에서도 세 데이터셋 모두에서 가장 높은 F1을 보였다. 또한 문구 기반 검출로 후보 수를 줄여 SAM-6D의 인식 방식보다 프레임당 처리 속도가 약 1.6배 빨랐으며, 지도에 저장한 6D 포즈는 방향 오차 중앙값이 2.9° 로, 점군 지도에 CAD 모델을 정합한 FM-Fusion의 20.0° 보다 작았다. 이를 통해 객체 인식 구성뿐 아니라 인식 결과를 지도에 등록하고 관리하는 방식도 최종 지도 성능에 영향을 미침을 확인하였다.

다만 단계별 검증은 오등록을 줄였으나, YCB-Video의 일부 구성에서는 F1이 감소하였다. 따라서 검증 기준을 설정할 때에는 오등록 억제와 올바른 객체의 누락을 함께 고려해야 한다. 전체 시스템 비교에는 CAD 모델 제공 여부와 객체 인식 구성의 차이가 포함되므로, 해당 성능 차이를 지도 생성 방법만의 효과로 해석하는 데에는 한계가 있다. 포즈 정확도 평가에서도 정답 포즈는 재구성 점군에 CAD 모델을 정합하여 만든 것이며, 모든 실험은 데이터셋이 제공하는 카메라 자세를 사용하였으므로, SLAM 자세 오차와 루프 폐쇄 보정이 지도에 미치는 영향은 향후 평가가 필요하다. 따라서 향후 연구로는 SLAM 자세를 사용한 실시간 평가를 수행하고, 객체 지도의 정보를 활용하여 현재 위치 추정과 상호 성능을 향상시키는 연구를 진행할 예정이다.

ACKNOWLEDGMENT

이 논문은 2026년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원(No.RS-2023-00228996, 우주상황인식을 위한 실-가상 연동형 국방 메타버스 기반기술 개발)을 받아 수행된 연구이며, 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] N. Correll et al., "Analysis and Observations From the First Amazon Picking Challenge," IEEE Transactions on Automation Science and Engineering, vol. 15, no. 1, pp. 172-188, 2018.

[2] G. Du, K. Wang, S. Lian, and K. Zhao, "Vision-based Robotic Grasping from Object Localization, Object Pose Estimation to Grasp Estimation for Parallel Grippers: A Review," Artificial Intelligence Review, vol. 54, no. 3, pp. 1677-1734, 2021.

[3] C. Campos et al., "ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial, and Multimap SLAM," IEEE Transactions on Robotics, vol. 37, no. 6, pp. 1874-1890, 2021.

[4] K. Koide, J. Miura, and E. Menegatti, "A Portable Three-Dimensional LIDAR-Based System for Long-Term and Wide-Area People Behavior Measurement," International Journal of Advanced Robotic Systems, vol. 16, no. 2, 2019.

[5] J. Lin et al., "SAM-6D: Segment Anything Model Meets Zero-Shot 6D Object Pose Estimation," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 27906-27916, 2024.

[6] B. Wen et al., "FoundationPose: Unified 6D Pose Estimation and Tracking of Novel Objects," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 17868-17879, 2024.

[7] A. Kirillov et al., "Segment Anything," in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), pp. 4015-4026, 2023.

[8] R. F. Salas-Moreno et al., "SLAM++: Simultaneous Localisation and Mapping at the Level of Objects," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 1352-1359, 2013.

[9] J. McCormac et al., "Fusion++: Volumetric Object-Level SLAM," in Proceedings of the 2018 International Conference on 3D Vision (3DV), pp. 32-41, 2018.

[10] C. Liu et al., "FM-Fusion: Instance-Aware Semantic Mapping Boosted by Vision-Language Foundation Models," IEEE Robotics and Automation Letters, vol. 9, no. 3, pp. 2232-2239, 2024.

[11] J. Jiang et al., "DualMap: Online Open-Vocabulary Semantic Mapping for Natural Language Navigation in Dynamic Changing Scenes," IEEE Robotics and Automation Letters, 2025.

[12] T. Cheng et al., "YOLO-World: Real-Time Open-Vocabulary Object Detection," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024.

[13] C. Zhang et al., "Faster Segment Anything: Towards Lightweight SAM for Mobile Applications," arXiv:2306.14289, 2023.

[14] M. Oquab et al., "DINOv2: Learning Robust Visual Features without Supervision," arXiv:2304.07193, 2023.

[15] Y. Xiang et al., "PoseCNN: A Convolutional Neural Network for 6D Object Pose Estimation in Cluttered Scenes," arXiv:1711.00199, 2017.

[16] T. Grenzdörffer, M. Günther, and J. Hertzberg, "YCB-M: A Multi-Camera RGB-D Dataset for Object Recognition and 6DoF Pose Estimation," in Proceedings of the IEEE International Conference on Robotics and Automation (ICRA), 2020.

[17] E. Langer, T. Patten, and M. Vincze, "Where Does It Belong? Autonomous Object Mapping in Open-World Settings," Frontiers in Robotics and AI, vol. 9, article 828732, 2022.

스마트 항만 생산성 향상을 위한 디지털트윈 기반 YT 운행 경로 최적화 시스템 개발

박성혁, 김한진*, 류관희**
충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 소프트웨어학부
alfxms123@chungbuk.ac.kr, *gks359@chungbuk.ac.kr, **khyoo@chungbuk.ac.kr

Digital Twin-Based YT Route Optimization System for Improving Smart Port Productivity

Seong-Hyuck Park, Hanjin Kim*, Kwan Hee Yoo**
Department of Industrial AI, Chungbuk National Univ.,
*Industrial AI Research Center, Chungbuk National Univ.,
**School of Computer Science, Chungbuk National Univ

Abstract

This study proposes a digital twin-based Yard Tractor (YT) route optimization system to improve transportation efficiency and mitigate vehicle concentration in smart container terminals. The system is designed to generate minimum-cost routes by incorporating predicted future Link states and vehicle concentration into dynamic routing costs while considering lane directions and intersection constraints. It also provides a framework for comparing actual and optimized routes under varying YT fleet deployment conditions. Experimental results demonstrated a Top-3 Next-Link prediction accuracy of 90.61% and a 21.36-26.32% reduction in Link concentration prediction error compared with the baseline. These results validate the predictive components supporting route optimization, while the resulting improvements in travel time and transport task throughput require further quantitative evaluation.

Key words : Yard Tractor, Smart Port, YT Route Optimization, Next-Link Prediction, Map Matching, Digital Twin

Ⅰ. 서 론

부산항 신항 3부두와 같은 대규모 컨테이너 터미널은 선박 대형화와 하역작업의 복잡성 증가에 대응하여 운영의 지능화가 요구되는 환경이다. 안벽의 QC(Quay Crane)와 장치장 사이에서 컨테이너를 운송하는 YT(Yard Tractor)는 터미널 내 주요 이송 장비로, 운행경로 선택과 대기시간에 따라 하역작업의 연속성과 운영효율이 달라질 수 있다. 특히 다수의 YT가 제한된 차선과 교차로를 공유하는 상황에서 특정 구간으로의 차량 집중은 불필요한 이동과 작업 지연을 초래할 수 있다. 따라서 현재 위치와 작업 상태를 확인하는 관제를 넘어 미래의 이동 및 집중 가능성을 반영하는 예측형 운행 의사결정이 필요하다.

기존 연구는 YT 운영정보를 활용한 터미널 내부 교통 속도 예측[1], YT 배차정책 최적화[2] 등에 초점을 두었으며, 디지털트윈은 실제 항만의 공간과 운영 상태를 연계하여 운영 대안을 가상환경에서 비교하는 기술로 연구되어 왔다[3, 4]. 그러나 미래 YT 이동구간과 Link 별 집중도를 예측하고 이를 동적 경로 비용과 운영 시나리오 평가에 연계하는 통합적 접근은 별도의 검증이 요구된다.

본 연구의 목적은 단순히 YT의 다음 이동 경로를 정확하게 예측하는 데 있지 않다. 예측된 경로와 Link별 차량 집중 정보를 실제 운행 의사결정에 활용할 수 있는 형태로 전환하고, 이를 디지털트윈 환경에서 사전에 비교 · 검토할 수 있는 방법을 제시하는 데 있다. 이를 통해 첫째, 현재 상태 중심의 항만 관제를 미래 상태를 고려하는 예측형 관제 · 의사결정 체계로 확장하고, 둘째, YT 대수 변화나 신규 투입과 같은 운영조건 변화가 경로와 Link 집중도, 작업 처리에 미치는 영향을 사전에 평가할 수 있는 기반을 제공하며, 셋째, 향후 실제 운영에서 YT 배치 및 경로 선택, 병목 구간 관리와 같은 운영정책 수립을 지원할 수 있는 디지털트윈 활용 방안을 제시한다.



그림 1 HJNC 부산신항 3부두의 YT 운행환경 및 Link 기반 도로망 예시
Fig. 1 Example of YT operating environment and Link-based road network at HJNC Busan New Port Terminal 3

Ⅱ. 디지털트윈 기반 YT 운행 경로 최적화 시스템

1. YT 운행데이터와 차선 기반 공간 Graph 구축

본 연구에서는 TOS에 기록된 YT의 Terminal x/y 위치 정보를 실제 항만 도로망과 연결하기 위해 CAD 도면을 기반으로 차선 단위의 공간 Graph를 구축하였다. 도면에서 확인되는 차선

위치와 진행 방향을 반영하고 교차구간의 연결 관계를 분리하여, 최종적으로 49개의 Lane chain, 1,007개의 Link 및 528개의 Node로 공간구조를 구성하였다. 그림 2과 같이 각 Link는 실제 YT가 이동할 수 있는 차선과 방향을 표현하며, 이후 Map Matching과 다음 Link 예측에서 후보 이동구간을 제한하는 기준으로 사용하였다.

실측자료는 고밀도 운행정보가 확보된 2026년 1월 8일 데이터를 활용하였다. 이 중 77대의 YT를 학습에 사용하고, 20대는 모델 학습 및 증강데이터 생성에 사용하지 않은 HOLDOUT으로 분리하여 최종 평가에 이용하였다. 또한, 실제 운행자료의 기간적 한계를 보완하기 위해 NORMAL, PEAK, LOW, CONGESTION 및 LOCAL_RESTRICTION 조건을 포함하는 30일 상당의 시나리오 데이터를 생성하였다.

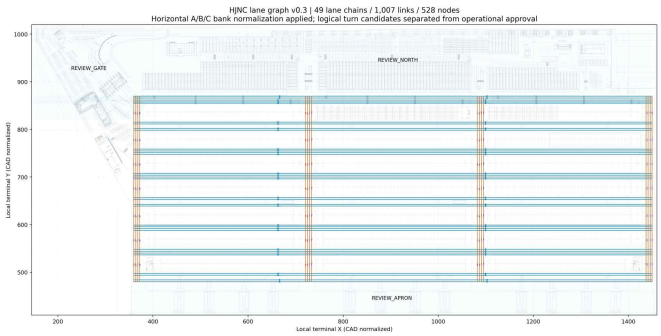


그림 2 CAD 기반 YT 차선 · 방향성 공간 Graph
Fig. 2 CAD-based lane-level graph for YT movements

2. 경로 최적화 및 디지털트윈 연계

예측된 YT 이동과 미래 Link 집중도를 동적 Link Cost에 반영하여, 단순 최단거리 대신 차량 집중구간을 고려한 최소비용 경로를 산출한다. 산출된 경로는 Unreal 기반 디지털트윈에 연계하여 실제 운행과 최적화 운행을 재현하고, 이동시간, Link 집중도 및 YT 운송작업 처리량을 비교하는 운영검증에 활용한다.



그림 4 디지털트윈 기반 YT 운행경로 최적화
Fig. 4 Digital twin-based YT route optimization

Ⅲ. 실험 및 분석

1. 실험 구성 및 평가 방법

실제 YT 운행정보 중 77대의 YT를 학습에 사용하고, 20대는 모델 학습 및 증강데이터 생성에 포함하지 않는 HOLDOUT 평가집합으로 구성하였다. 다음 Link 예측은 Top-1, Top-3, Top-5 정확도와 3-Link 연속경로 Top-3 정확도를 기준으로 평가하였다. 미래 Link 집중도는 예측 시점별 MAE를 계산하고 Persistence 모델과 비교하였다. 증강 효과는 증강 유무에 따른 동일 실제 HOLDOUT의 오차 변화를 기준으로 분석하였다.

경로 최적화의 운영 효과는 실제 복원경로, 정적 경로 탐색 기준선, 예측 이동시간 적용 경로 및 집중도까지 반영한 후보 경로를 동일한 작업조건에서 비교하는 방식으로 평가할 수 있다. 이동시간 감소율, 최대 동시 YT 수 감소율, 단위 기간 운송작업 완료 건수의 증가율을 주요 KPI로 설정하되, 운영 KPI의 개선 효과는 예측 모델 성능과 구별하여 별도의 동일 조건 비교 실험으로 평가한다.

2. 예측 성능 비교

실제 HOLDOUT을 이용한 다음 Link 예측에서 Graph-Markov-2는 Top-1 60.99%, Top-3 90.61%, Top-5 95.51%의 정확도를 기록하였다. 증강 MLP는 Top-1 60.87%, Top-3 89.98%로 유사한 성능을 보였다. 그러나 3-Link 연속경로 Top-3 정확도는 증강 MLP가 47.02%로 Graph-Markov-2의 42.78%보다 높았다. 따라서 단기 다음 Link의 최우선 후보를 정하는 문제와 연속된 후보 경로를 추정하는 문제에서 유리한 모델이 서로 다름을 확인하였다.

미래 Link 집중도는 5분 단위 YT 수를 이용하여 t+5, t+10, t+30으로 예측하였다. 모델 비교 결과 LightGBM의 MAE는 0.1916, 0.1884, 0.1882로 가장 낮았으며, Persistence 대비 21.36~26.32% 감소하였다. 이에 따라 단기 다음 Link는 Graph-Markov-2, 다단계 후보경로는 증강 MLP, 미래 Link 집중도는 LightGBM을 적용하였다.

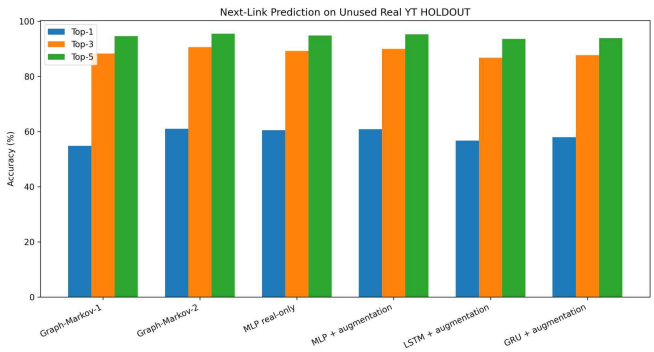


그림 3 실제 HOLDOUT 기반 다음 Link 예측 결과
Fig. 3 Next-Link prediction results on real HOLDOUT

시나리오 증강 적용 시 실제 1일 학습자료만 사용한 경우보다 HOLDOUT의 YT 수 MAE가 약 5.7~8.3% 감소하여 제한된 실측자료를 보완할 가능성을 확인하였다.

3. 경로 최적화 적용 및 운영 효과

연구에서 확인된 예측성능은 미래 Link 상태를 경로비용 산정에 반

영하기 위한 근거가 된다. 그러나 예측 오차의 감소가 곧바로 YT 운행시간이나 작업 처리량의 개선을 의미하지는 않는다. 경로 최적화의 실질적 기여를 검증하려면 실제 복원경로와 대체 후보 경로를 동일한 출발지 · 목적지, 작업 수요, 차량 투입조건 및 도로망 제약에서 실행하여 이동시간, Link 집중도 및 작업 완료 건수를 비교해야 한다.

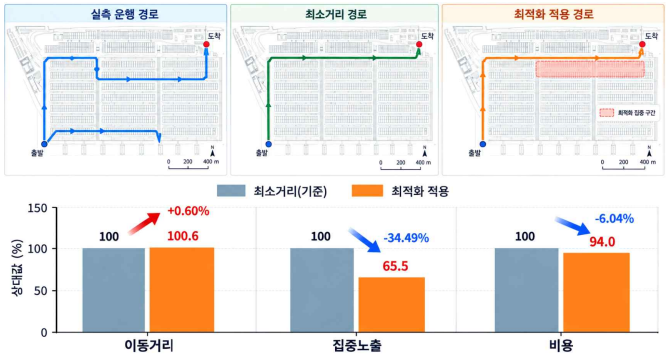


그림 4 실제 운행경로와 최적화 후보 경로 비교

Fig. 4 Comparison of Actual YT Travel Routes and Optimized Candidate Routes

그림 4는 실제 복원경로와 최적화 후보 경로를 비교한 결과이다. 최적화 적용 시 평균 이동 거리는 0.6% 증가하였으나, 집중노출은 34.49%, 종합 경로 비용은 6.04% 감소하였다. 이는 Link 집중도를 반영한 경로 최적화가 이동 거리의 소폭 증가에도 불구하고 차량 집중 완화와 경로 비용 절감에 효과적임을 보여준다.

표 1 경로 최적화 적용 전후 성능 비교

Table 1 Performance Comparison Before and After Route Optimization

구분	실측 운행	최소 거리	최적화 적용
표본(건)	2,172	724 x 3조건 (총 2,172건)	724 x 3조건 (총 2,172건)
이동거리 (평균)	566.10	1,057.35	1,063.73
집중노출 (평균)	87.24	98,67	64.64
비용 (평균)	982.31	1,304.02	1,225.31

경로 최적화의 운영적 효과는 실제 복원경로, 이동시간 기반 후보경로, 이동시간 · 집중도 통합 후보 경로를 비교하는 관점에서 분석하였다. 특히 Link 집중도 패널티의 적용 여부에 따른 경로 선택 특성을 구분하고, YT 투입 대수 변화와 국지적 통행 제한 조건이 경로 선택 및 Link별 차량 집중에 미칠 수 있는 영향을 검토하였다. 이러한 분석을 통해 개별 YT의 이동시간 최소화와 복수 YT의 특정 Link 집중 완화가 서로 다른 최적화 목적임을 구분하였으며, 운영조건에 따라 경로 비용의 구성요소를 달리 적용할 필요가 있음을 도출하였다.

Ⅳ. 결론

본 연구에서는 TOS 운행데이터와 CAD 기반 도로망을 이용하여 YT 이동을 Link 단위로 구조화하고, 다음 Link와 미래 Link 집중도를 예측하여 경로 최적화에 활용하는 디지털트윈 기반 운영지원 구조를 제안하였다. 실제 HOLDOUT에서 Graph-Markov-2는 다음 Link Top-1 60.99%, Top-3 90.61%를 기록하였으며, LightGBM은 Link 집중도 예측에서 Persistence 대비 21.36~26.32% 낮은 MAE를 보였다.

향후에는 현재 실측 고밀도 데이터가 사실상 단일 운행일에 집중되어 있으므로, 추가 운행일 자료를 확보하여 모델의 일반화 성능을 검증할 필요가 있다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] Kim, T., Heo, G., Lee, H. and Ryu, K. R. (2022), "Prediction of Traffic Speed in a Container Terminal Using Yard Tractor Operation Data," Journal of Korean Navigation and Port Research, Vol. 46, No. 1, pp. 33-41. KCI

[2] Kim, T. and Ryu, K. R. (2020), "Optimization of YT Dispatching Policy for Maximizing Quay Side Productivity in Container Terminals," Journal of Korean Navigation and Port Research, Vol. 44, No. 3, pp. 227-234. KCI

[3] Choi, H. D. and Yoo, J. H. (2020), "A Study on the Application of Digital Twin Technology for Container Terminals," Journal of Korean Navigation and Port Research, Vol. 44, No. 6, pp. 557-563. KCI

[4] Neugebauer, J., Heilig, L. and Voß, S. (2024), "Digital Twins in the Context of Seaports and Terminal Facilities," Flexible Services and Manufacturing Journal, Vol. 36, pp. 821-917.

콜리메이터 지그 기반 CCTV 카메라 포커스 및 상면 편심 자동 검사 시스템

오지택, 김영진*, 김형원**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 전자공학과

dhwlxor2000@chungbuk.ac.kr, *you359@chungbuk.ac.kr, **hwkim@chungbuk.ac.kr

Automated Inspection System for Focus and Image Plane Tilt of CCTV Cameras Based on Optical Collimator Jig

Jitack oh, Youngjin kim*, Hyungwon Kim**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**Department of Electronic Engineering, Chungbuk National Univ

Abstract

This paper proposes an automated inspection system to quantitatively evaluate focus alignment and image plane decentering (tilt) in the manufacturing process of fixed-focus CCTV cameras. Conventional manual inspection methods suffer from large physical space requirements (6m x 3m), environmental lighting variations, and subjective human judgments, which lead to unnecessary product rejections and undetected lens decentering errors. To overcome these limitations, an optical collimator jig is integrated into a compact darkroom enclosure to simulate an infinite optical imaging environment. The system captures images at a 1920x1080 resolution, divides the frame into a 3x3 grid of regions of interest (ROIs), and calculates focus sharpness for each region using OpenCV's Laplacian variance operator. A dual-criteria evaluation framework is established by assessing both the overall mean sharpness score and the maximum percentage deviation among the ROIs to effectively isolate lens tilt. Experimental results demonstrate a real-time processing speed of approximately 0.05 seconds per frame. Furthermore, the lightproof darkroom environment ensures 99.5% measurement repeatability while accurately identifying decentering defects.

Key words : CCTV Camera Inspection, Collimator Jig, Laplacian Variance, Image Plane Decentering, Automated Inspection, Focus Sharpness

Ⅰ. 서 론

보안용 화각 고정형 CCTV IP 카메라 제조 공정에서 렌즈의 초점 조절 및 정밀 검사는 제품의 최종 영상 품질을 결정짓는 핵심 공정이다. 최근 지능형 영상 보안 시스템이 고도화됨에 따라 수집되는 영상 데이터의 높은 정밀도와 해상력 확보가 필수적인 요소로 대두되고 있으며, 생산 과정에서 무한대 거리에 대한 정밀한 초점 형성 여부와 화면 전체 영역의 해상력 균일도를 엄격히 검증해야 한다[1]. 그러나 기존 양산 라인에서는 무한대 거리 결상 환경을 모사하기 위해 그림1과 같이 가로 6m, 세로 3m에 달하는 광범위한 물리적 검사 공간을 확보해야 했으며, ISO 12233 포커스 차트[2] 촬영 영상에 대한 작업자의 육안 검사(Visual Inspection)에 의존해 왔다[3].

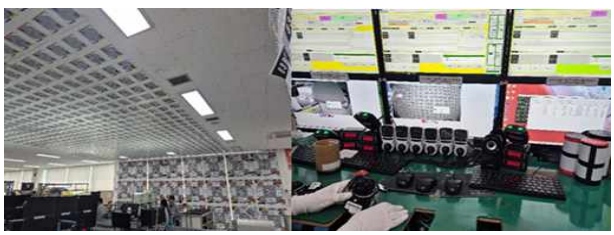


그림 1 기존 천장 차트 기반 수동 육안 초점 검사 방식
Fig. 1 Conventional Manual Visual Focus Inspection Using a Ceiling Chart.

이러한 기존 육안 검사 방식은 작업자의 숙련도 및 피로도에 따른 주관적 판단 오차를 유발하여 공정 불량률을 증가시킨다. 실제 국내 영상보안 전문기업인 아이디스(IDIS)의 사내 ERP 시스템(TIMS) 2025년 생산실적 데이터에 따르면, 연간 70만 대 생산 라인 기준으로 과잉 품질 판정에 따른 가상 불량이 약 0.11%(연간 약 770대), 검출력 부족으로 인한 저품질 제품의 고객 유출이 약 0.01%(연간 약 70대) 발생하는 등 상당한 품질 손실 비용이 지속되어 왔다. 더욱이 주·야간 조도 변화 등 검사 환경의 변동성에 취약할 뿐만 아니라, 렌즈 나사산 조작 과정에서 흔히 발생하는 상면 편심(Decentering) 불량을 선별하지 못하는 치명적인 한계가 있다. 단일 중앙부 평균 선명도만 평가할 경우, 그림 2와 같이 화면 외곽 초점이 비대칭하게 무너지는 광학적 쏠림 현상을 양품으로 오판정할 위험이 매우 크다.

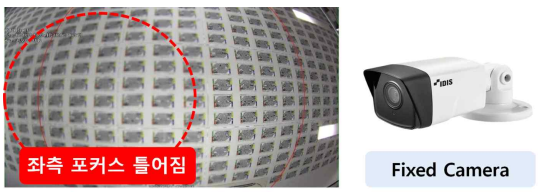


그림 2 Fixed Camera 좌측 포커스 틀어짐 불량
Fig. 2 Fixed camera left-side defocus error.

본 연구에서는 이러한 문제를 해결하기 위해 콜리메이터

(Collimator) 광학 지그 및 3x3 영역 분할 알고리즘 기반의 CCTV 카메라 포커스 및 상면 편심 자동 검사 시스템을 제안한다[4]. 제안하는 시스템은 소형 차광 암실 박스 내부에서 콜리메이터 지그[5]를 통해 평행 광선을 형성함으로써 짧은 물리적 거리에서도 수십 미터 이상의 무한대 무결상 광학 환경을 모사하여 공간 효율성을 극대화하고 외부 조도 영향을 완전히 차단한다. 또한, 수집된 1920x1080 고해상도 영상에 3x3 ROI 영역 분할 및 OpenCV 라플라시안(Laplacian) 2차 미분 연산 알고리즘[6]을 적용하여 전체 선명도 평균 점수와 영역 간 최대 편차율을 정량 산출하는 이중 정밀 검사 체계를 구축함으로써 상면 편심 불량을 정밀 선별한다. 아울러 FAIL 판정 시 현품표 바코드 리딩을 차단하는 FoolProof 시스템과 연동하여 불량품의 후공정 유입을 원천 차단하고 공정 추적성을 확보한다.

Ⅱ. 본 론

1. 하드웨어 및 광학 검사 환경 구축

본 연구에서 제안하는 자동 검사 시스템은 기존 검사 공간의 한계를 극복하고 외부 환경 요인을 차단하기 위해 차광 및 정밀 광학 하드웨어 구조로 설계되었다. 그림3의 핵심 장치인 콜리메이터 광학 지그(Optical Collimator Jig)는 내부 타깃 차트에서 발산된 빛을 비구면 렌즈를 통해 완전한 평행 광선으로 변환한다. 이를 통해 소형 암실 지그 내부의 짧은 물리적 거리에서도 CCTV 카메라가 수십 미터 이상의 먼 거리를 촬영하는 것과 동일한 무한대 결상 환경을 정밀하게 모사하도록 구현하였다. 외부 주·야간 조도 변동에 따른 오차를 방지하기 위하여 외부 빛을 완전히 차단하는 차광 암실 박스(Darkroom Box)를 설치하고 내부에 균일한 휘도를 제공하는 LED 조명을 배치하여 항상 고정된 광량 조건에서 검사가 진행되도록 설정하였다. 추가로 3D 프린터로 전용 안착 지그를 제작하여 카메라 모듈의 안착 위치 및 광축 유격을 정밀하게 고정시킴으로써 기계적 오차에 따른 측정 데이터의 불안정성을 최소화하였으며, 타깃 차트로는 ISO 12233 표준[2] 및 ISO 시멘스 스타(Siemens Star) 차트를 채택하여 360도 전 방향 공간 주파수 응답 평가가 가능하도록 구축하였다.

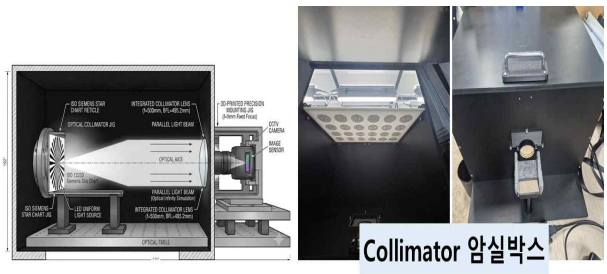


그림 3 콜리메이터 지그 기반 광학 검사 하드웨어 구성도
Fig. 3 Conceptual Layout of the Collimator Jig-Based Optical Inspection Hardware.

2. 소프트웨어 및 알고리즘 구현

소프트웨어 프레임워크는 Python 기반의 PyQt5 GUI와 MSS 스크린 캡처 라이브러리를 연동하여 그림4와 같이 모니터링 창으로부터 1920x1080 고해상도 영상을 실시간으로 수집하도록 개발되었다. 수집된 영상 데이터는 광학적 쏠림 및 상면 편심 현상을 감지하

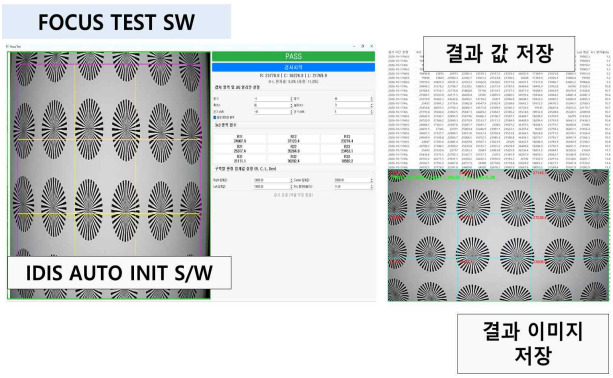


그림 4 3x3 ROI 라플라시안 포커스 및 상면 편심 자동 검사 소프트웨어 실행 화면
Fig. 4 Execution Screen of the Real-time 3x3 ROI Focus and Decentering Inspection Software.

기 위해 격자 형태의 3x3 9개 ROI(Region of Interest) 영역으로 균등 분할된다. 분할된 각 영역에는 OpenCV[7]의 라플라시안(Laplacian) 2차 미분 연산자가 적용되어 영상의 경계선 고주파 성분을 기반으로 영역별 선명도 점수 S_n를 정량적으로 산출한다[6]. 검증이 완료된 데이터는 3x3 ROI 별 점수가 합성된 오버레이 영상과 검사 수치, 타임스탬프 정보가 포함된 로그 파일로 자동 기록되어 공정 추적성을 보장하며, 검사 결과가 FAIL로 판정될 경우 현품표 바코드 리딩을 차단하여 불량품이 후공정에 유입되지 못하도록 방지하는 FoolProof 시스템을 구축하였다.

3. 이중 정밀 검사 평가 산식

단순 선명도 평가만으로는 상면 편심 불량을 검출하기 어렵기 때문에 전체 영역의 평균 선명도 점수와 영역 간 선명도 편차율을 동시 반영하는 이중 평가 알고리즘을 수식화하여 적용하였다. 9개 분할 영역 중 우측과 좌측 영역의 선명도 점수를 각각 S_R, S_L 이라 정의할 때, 상면 편심을 평가하기 위한 좌우 편차율 D_{RL}은 식 (1)과 같이 계산된다.

$$D_{RL} = \frac{2 \cdot |S_R - S_L|}{S_R + S_L} \times 100 \quad [\%] \tag{1}$$

전체 9개 영역의 선명도 평균 점수를 $\overline{S}$라 할 때, 시스템의 최종 검사 결과 R은 평균 선명도가 임계값 기준 이상이고 편차율이 허용 기준 이하인 조건 식 (2)를 동시에 만족할 때에만 PASS(합격)로 결정된다.

$$R = \begin{cases} PASS, \text{ if } \overline{S} \geq 19{,}000 \text{ and } D_{RL} \leq 11.0\% \\ FAIL, \ otherwise \end{cases} \tag{2}$$

4. 실험 구성 및 정량적 성능 평가

제안된 시스템의 정량적 성능을 검증하기 위해 고정 초점 렌즈 모듈 및 콜리메이터 검사 환경에서 반복 실험을 수행하였으며, 주요 성능평가 지표 결과는 표 1과 같다.본 시스템의 성능 평가 기준(평균 선명도 $\overline{S} \geq 19{,}000$, 편차율 $D_{RL} \leq 11\%$)은 기존 육안 검사에서 양품으로 판정된 IP 카메라 모듈 1,000대(IDIS DC-T4217 모델)의 측정 데이터 통계를 기반으로 설정되었다. 또한, 불량 검출력을 검증하기 위해 가초점거리(Hyperfocal Distance)에 초점이 맞춰진 정상 시료 10대를 대상으로 렌즈를 좌·우 1° 씩(최대

±90°) 미세 회전시키며 상면 편심 및 초점 변화량 검출 성능을 확인하였다. 차광 암실 박스 환경에서 1,000회 반복 측정을 수행한 결과, 외부 조도 영향 0% 및 측정 재현성 99.5%를 달성하여 정밀 검사 체계로서의 유효성을 입증하였다.

표 1 실험 결과
Table 1 Experimental results

평가 항목	성능 기준	구현 및 측정 결과	판정	비고
평균 초점	≥19,000	초점 정렬 시 최소 19,000 점 달성	합격	라플라시안 분산 평균값
상면 편심	≤11 %	정상 모듈 5.0 %~10.0 % 수준 검출	합격	9개 ROI 최고/최저 편차
검사 시간	≤1.0 초	약 0.05 초 (프레임당 50ms)	합격	실시간 화면 연산 처리
환경 재현성	외부조도 영향 0%	재현성 99.5% 확보	합격	차광 암실 박스 적용
데이터 추적성	자동 저장	합성 이미지 및 타임스탬프 결과	합격	FoolProof 시스템 연동

5 결과 분석 및 정성적 평가

실험 결과를 정성적으로 분석해보면, 3x3 ROI 영역 분할 알고리즘이 상면 편심 불량을 선별하는 데 매우 효과적임을 확인할 수 있다. 렌즈 기울어짐 불량이 발생한 모듈은 중앙부 선명도만 측정할 경우 임계값을 통과하여 양품으로 오판정될 위험이 존재하지만, 9개 영역으로 분할하여 편차를 산출한 결과 외곽부 점수 저하로 인해 Dev% 수치가 허용 기준인 11%를 크게 초과함으로써 불량품을 정밀하게 가시화하여 선별해냈다. 더불어, 차광 암실 구조와 정밀 안착 지그를 연동하여 작업자 숙련도나 조도에 따른 측정 흔들림을 완벽히 차단하였고, 0.05초의 빠른 연산 속도를 바탕으로 화면 상에 실시간 수치 오버레이 및 불량 제어가 가능함을 검증하였다.

Ⅲ. 결 론

본 연구에서는 콜리메이터 광학 지그와 3x3 ROI 라플라시안 분산 연산 알고리즘[6]을 결합한 CCTV 카메라 포커스 및 상면 편심 자동 검사 시스템을 개발하였다. 이를 통해 기존 양산 라인의 물리적 공간 제약을 대폭 절감하고 외부 조도 오차를 차단하여 99.5%의 높은 재현성을 확보하였다. 또한 평균 선명도와 편차율을 동시 검증하는 이중 정밀 평가 알고리즘을 구현하여 상면 편심 불량을 정량적으로 감지하고, FoolProof 바코드 차단 체계를 통해 생산 공정의 품질 안정성을 향상시켰다. 향후 연구에서는 실제 양산 과정에서 축적되는 대규모 샘플 데이터를 바탕으로 ROC(Receiver Operating Characteristic) 커브 분석을 적용하여, 과잉 불량률 및 미검출률을 최소화하는 판정 임계값 정제 작업을 진행할 예정이다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] ISO/IEC 30137-1:2019, "Information technology — Use of facial recognition in video surveillance systems — Part 1: System design requirements," International Organization for Standardization, 2019.

[2] ISO 12233:2023, "Photography — Electronic still-picture imaging — Resolution and spatial frequency responses," International Organization for Standardization, 2023.

[3] P. D. Burns and D. Williams, "Measuring camera spatial frequency response using slanted-edge analysis," Proc. SPIE, vol. 9404, p. 940407, 2015.

[4] TRIOPTICS GmbH, "Active Alignment in High-End Camera Module Assembly," Optical Metrology Application Note, 2020.

[5] W. J. Smith, Modern Optical Engineering: The Design of Optical Systems, 4th ed., McGraw-Hill Education, 2007.

[6] J. L. Pech-Pacheco, G. Cristóbal, J. Chamorro-Martinez, and J. Fernández-Valdivia, "Diatom autofocusing in optical microscopy: a comparative study," in Proc. 15th Int. Conf. Pattern Recognit. (ICPR), vol. 3, 2000, pp. 318-321.

[7] G. Bradski, "The OpenCV Library," Dr. Dobb's Journal of Software Tools, vol. 25, no. 11, pp. 120-123, 2000.

딥러닝 기반 주행영상 도로 균열 세그멘테이션의 소수 클래스 정확도와 프레임 간 안정성 개선 방법에 관한 연구

안기현, 강대익*, 류관희**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 소프트웨어학부

ankihyeon@chungbuk.ac.kr, *kangdaeik@cbnu.ac.kr, **khyoo@cbnu.ac.kr

Deep Learning-Based Road Crack Segmentation from Driving Video: A Study on Methods for Improving Minority-Class Accuracy and Temporal Stability

Kihyeon An, Daeik Kang*, Kwan-Hee Yoo**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**School of Computer Science, Chungbuk National Univ

Abstract

Thin road cracks in driving video pose two problems for segmentation: cracks form a minority class only a few pixels wide after downscaling, and predictions of the same crack flicker between frames as the vehicle moves. Crack labels cover 1.48% of image pixels in 25,449 frames, and even ground-truth masks of transverse cracks in adjacent frames have a median IoU of 0.000 before road-plane alignment and 0.438 after, so flicker can be measured only after alignment. Against criteria fixed in advance, temporal filtering raised crack temporal consistency by 13.0 percentage points (95% CI 8.8 to 18.5) at a Crack IoU cost of 0.5 points, though most propagated pixels were false positives, whereas loss weighting with copy-paste and the adaptive weighting mechanism (AWM) did not meet the criteria. In exploratory comparisons, accuracy rose with a larger model or 1280-pixel input, both below 30 FPS.

Key words : Road Crack Segmentation, Minority Class, Temporal Stability, Adaptive Weighting, Road-Plane Alignment

Ⅰ. 서 론

본 연구의 목표는 주행영상에서 도로 위 미세균열(화면상 폭이 좁은 균열)을 검출하는 것이다. 포장 상태 조사는 전용 장비를 갖춘 체계로 이루어진다[1]. 장비 조사가 미치기 어려운 지자체 도로에서는 차량 카메라 영상의 딥러닝 분석이 저비용 대안으로 연구되며[2], 영상 기반 균열률을 포장 파손 모형에 쓴 사례도 있다[3].

어려움은 두 가지이다. 첫째, 미세균열은 잘 보이지 않는다(소수 클래스 불균형, class imbalance). 균열은 면적이 작고 폭이 좁아, 입력을 축소하면 폭 방향 화소가 거의 남지 않는다. 둘째, 차량이 전진하면 같은 균열의 화면 위치가 바뀌고 검출 결과는 프레임마다 나타났다 사라진다(프레임 간 불안정성, temporal inconsistency). 움직임을 보정하지 않으면 이 깜빡임을 측정할 수조차 없다.

본 논문은 노면 정렬로 깜빡임을 재는 측정(mTC)을 먼저 세우고, 같은 사전 기준으로 시계열 필터링, 고정밀 세그멘테이션(손실 가중, 원근 비례 Copy-Paste, 입력 해상도), 두 문제를 한 손실 가중으로 다루는 적응형 가중 메커니즘(AWM)을 판정하였다. 네 모델은 기법을 얹는 실험대이며, 기준에 못 미친 결과도 진단과 함께 보고한다.

Ⅱ. 본 론

2.1 문제의 정량화

자료는 공개 데이터셋과 자체 촬영 영상의 라벨 프레임 25,449장이며, 대부분 1920×1080, 8개 클래스이다. 균열 3종(종방향과 횡방향의 선형균열, 거북등의 면적균열) 라벨은 화면 화소의 1.48%로, 차량(6.99%)의 4.7분의 1에 그친다. 자체 촬영 평가 후보 540장의 횡방향 균열 마스크 폭은 중앙값 8.5픽셀, 640 입력에서 2.8픽셀이다.

연속 라벨 영상의 인접 라벨 프레임 쌍(k=1)에서 근거리 노면은 차량 전진으로 중앙값 38.8픽셀 이동하였다. 이 이동과 직교하는 횡방향 균열은 정답 라벨끼리도 IoU 중앙값이 0.000이었고, 노면 평면 호모그래피로 정렬한 뒤에야 0.438로 회복되었다(정렬 수렴 99.4%).

2.2 제안 방법

고정밀 세그멘테이션은 균열을 더 자주, 더 크게 보도록 한다(그림 1). 클래스 빈도 가중에 Focal 손실[4]과 Dice 손실[5]을 더하고, 균열을 다른 영상의 도로 위에 원근 비례 크기로 붙이는 Copy-Paste 증강[6]으로 출현 횟수를 늘린다. 축소로 사라지는 폭은 1280 입력 학습과 640 타일 8개(20% 중첩) 타일링 추론[7]으로 비교한다.

시계열 필터링은 앞 프레임 마스크를 노면 평면 호모그래피로 옮겨 쓰는 후처리 후보 넷이며, 평가 밖 쌍에서 고른 추적 전파(현재 검출은 두고 놓친 균열만 최대 2프레임 이어 줌)를 검정한다. 일관성 측정은 이웃 프레임 워핑 방식[8]을 노면에 맞게 변형하였다.

AWM은 폭이 좁은 균열 화소(공간 항)와 일관성이 낮은 클래스(시간 항)에 큰 가중을 주는 손실 가중(식 (1))이며, 후처리와 독립이다.

$$L = L_{\mathrm{seg}}(W_{\mathrm{s}}) + \sum_{c,k} \lambda_{c,k} L_{\mathrm{tc,c,k}} \qquad (1)$$

여기서 W_s는 국소 폭이 기준보다 좁은 화소에 큰 값을 주는 공간 가중, $L_{tc,c,k}$는 간격 k(1 또는 2)로 정렬한 인접 예측의 불일치, c는 균열 3종과 포트홀이다. 세기 $\lambda_{c,k}$는 기준 모델의 일관성이 라벨 기준점(평가 밖 학습 구간 쌍)에 못 미치는 정도로 학습 전에 정한다. 구조는 그대로 두고 손실에만 쓰므로 네 모델에 같게 쓸 수 있고 추론 비용도 같다.

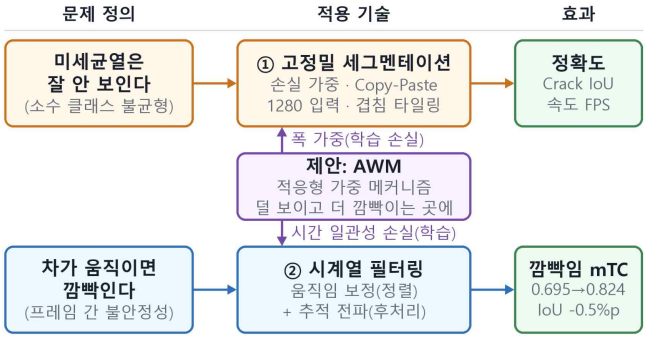


그림 1 문제, 적용 기술, 효과 지표의 대응

Fig. 1 Problems, applied techniques, and evaluation metrics

2.3 실험 및 결과

정확도는 자체 촬영 평가 343장의 균열 3종 평균 IoU(Crack IoU, 포트홀 제외)로, 깜빡임은 정렬 후 일치도 mTC(균열은 골격선 F)로, 속도는 A100에서 모델 단독 FPS로 잰다. 평가 343장은 학습과 주행 단위로 분리했으나, 연속 영상 한 편(평가의 약 55%)은 시간으로 나누어 앞부분을 학습에 썼다. 두 계열 세 모델과 참조 Mask2Former를 같은 학습 레시피(학습률 · 가중 감쇠만 계열 권장값)로 시드 3회씩 학습해 평균하였다. 판정 기준(95% 신뢰구간 조건, 예: 시계열 필터링은 손실 1%p 이내 · mTC +10%p 이상)은 결과 확인 전에 고정하였다.

표 1 기법 적용 전 모델의 정확도와 속도(같은 학습 레시피)

Table 1 Accuracy and speed of baseline models

모델	Crack IoU	거북등	종방향	횡방향	포트홀	FPS
SegFormer-b0	0.206	0.214	0.124	0.280	0.124	40.2
YOLO26n	0.168	0.134	0.129	0.242	0.186	73.3
YOLO11n	0.154	0.151	0.104	0.209	0.151	82.8
Mask2Former	0.251	0.274	0.184	0.295	0.207	17.8

표 1에서 경량 모델 중 가장 높은 SegFormer-b0[9](0.206, 40.2 FPS)에 기법과 후처리를 시험했다. Mask2Former는 0.251이지만 17.8 FPS로 영상 속도 30 FPS에 못 미쳤다. 정렬 · 후처리 포함 시스템은 약 10 FPS이다. 30 FPS 이상으로 속도를 맞춘 탐색에서 SegFormer-b0가 YOLO26n보다 3.8%p 높았다(CI 1.1~6.4).

정확도: 기법을 하나씩 더한 SegFormer-b0는 손실 가중만 −0.9%p, Copy-Paste만 +0.2%p, 둘 다 −2.8%p(CI −4.8~−0.7)였고, YOLO11n의 결합도 +1.2%p(유의하지 않음)로 기준에 미달했다. 손실 가중은 예측을 넓혔다(면적비 1.5~4.4배). AWM은 무가중 대비 −5.7%p(CI −8.2~−3.6)로 미달했고 시간 항이 횡방향 예측 면적을 0.23~0.35배로 줄였다. 탐색에서 1280 입력 학습은 +3.8%p(CI 2.3~5.4, 24.4 FPS), 640 가중치 타일링은 −6.7%p였다.

안정성: 시계열 필터링(추적 전파)은 Crack IoU를 0.5%p 잃고 균열 mTC를 13.0%p(95% CI 8.8~18.5) 높여 주 분석에서 사전 기준을 통과했으나, 블록 부트스트랩의 정확도 손실 하한은 −1.09%p로 민감도상 불안정하였다. 지표 계산에 정렬을 쓰지 않고 프레임마다 예측과 정답 균열의 겹침 여부만 본 추가 분석에서도, 정답이 이어지는 인접 쌍 중 한쪽만 겹치는 비율이 6.3%에서 3.8%로 줄었다(−2.5%p, CI −4.9~−0.4; 간격 2는 유의하지 않음; 정렬 품질은 2.1절). 다만 전파 화소의 정밀도는 11.3%로 같은 칸 원 예측(31.4%)보다 낮고 잔상은 32.7%에서 61.7%로 늘어, 이득에는 오검출 지속이 섞여 있다. 새 균열의 첫 검출률도 42.7%에서 48.4%로 저하되지 않았다(탐색).

Ⅲ. 결 론

본 논문은 노면 정렬로 깜빡임을 재고 대응 기술을 사전 기준으로 판정하였다. 안정성은 시계열 필터링으로 mTC +13.0%p, 정확도 손실 0.5%p였고 잔상은 늘었다. 정확도는 학습 기법은 기준에 못 미쳤고, 큰 모델과 1280 입력에서 올랐으나 30 FPS 미만이었다(탐색).

연속 라벨은 영상 두 편뿐이고 균열 폭은 화면 화소 기준이며, 결과는 PMS 균열률을 대신하지 않는다. 향후 시간 정보를 모델 구조에 넣는 방법, AWM 시간 항의 예측 억제 보완, 에지 장치 탑재를 검토한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임(IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] 서울특별시, 도로포장 유지관리 매뉴얼, 2018.

[2] H. Maeda et al., "Road damage detection and classification using deep neural networks with smartphone images," Comput.-Aided Civ. Infrastruct. Eng., vol. 33, no. 12, pp. 1127-1141, 2018.

[3] 박정권 외, "딥러닝 기반의 도로자산 모니터링 시스템을 활용한 아스팔트 도로포장 균열률 파손모델 개발," 한국ITS학회논문지, 제21권, 제5호, pp. 133-148, 2022.

[4] T.-Y. Lin et al., "Focal loss for dense object detection," ICCV, pp. 2999-3007, 2017.

[5] F. Milletari, N. Navab, and S.-A. Ahmadi, "V-Net: Fully convolutional neural networks for volumetric medical image segmentation," 3DV, pp. 565-571, 2016.

[6] G. Ghiasi et al., "Simple copy-paste is a strong data augmentation method for instance segmentation," CVPR, pp. 2917-2927, 2021.

[7] F. C. Akyon, S. O. Altinuc, and A. Temizel, "Slicing aided hyper inference and fine-tuning for small object detection," ICIP, pp. 966-970, 2022.

[8] Y. Liu et al., "Efficient semantic video segmentation with per-frame inference," ECCV, pp. 352-368, 2020.

[9] E. Xie et al., "SegFormer: Simple and efficient design for semantic segmentation with transformers," NeurIPS, vol. 34, pp. 12077–12090, 2021.

원통형 이차전지 배터리 팩 스팟용접에서의 안전관리를 위한 열화상 기반 이상 감지 연구

이원표, 김한진*, 김성진**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 컴퓨터공학과

muralkong@chungbuk.ac.kr, *gks359@chungbuk.ac.kr, **ksj@chungbuk.ac.kr

Thermal Imaging-Based Anomaly Detection for Safety Management in Spot Welding of Cylindrical Rechargeable Battery Packs

Won-Pyo Lee, Hanjin Kim*, Sung-Jin Kim**

Department of Industrial AI, Chungbuk National University.,

*Industrial AI Research Center, Chungbuk National University.,

**Department of Computer Engineering, Chungbuk National University

Abstract

This study investigates an unsupervised thermal-imaging anomaly detection approach for safety management in spot welding of cylindrical rechargeable battery packs. Thermal images were acquired using a UTi260B infrared camera, and 520 normal images and 27 overheating images were used for model training and evaluation. Three representative vision anomaly detection models, PaDiM, EfficientAD, and GANomaly, were compared under a normal-data-centered learning scheme. EfficientAD and GANomaly achieved F1-Score and AUROC values of 1.000 in the present test set, while PaDiM showed lower AUROC. The results indicate the feasibility of thermal-image-based anomaly detection, while broader defect data and temporal thermal analysis remain necessary for practical deployment.

Key words : Anomaly Detection, Unsupervised Learning, Secondary Battery, Thermal Imaging, Spot Welding

Ⅰ. 서 론

전기자동차 및 에너지저장장치의 확대와 함께 이차전지 배터리 팩의 안전성과 신뢰성 확보가 중요해지고 있다. 특히 원통형 셀을 전기적으로 연결하는 스팟용접 공정은 국부적으로 높은 열이 발생하며, 접합 상태가 불안정할 경우 접촉저항 증가와 국부 과열로 이어질 수 있다[1]. 따라서 제조단계에서 용접부의 이상 상태를 비접촉 방식으로 조기에 확인할 수 있는 검사기술이 요구된다.

기존 품질검사는 전류 · 전압 신호, 비파괴검사 또는 육안검사에 의존해 왔다. 그러나 RGB 영상은 주로 외관과 표면 형상 정보를 제공하므로 실제 온도분포나 열전달 특성을 직접 반영하기 어렵다. 반면 열화상 카메라는 용접부의 국부 과열과 공간적 열분포를 영상으로 관찰할 수 있어 배터리 용접부의 이상 진단에 활용 가능성이 있다[2].

실제 제조환경에서는 결함이나 위험 상태를 반복적으로 재현하기 어렵기 때문에 이상 데이터가 정상 데이터에 비해 매우 적다. 이에 정상 상태의 열패턴을 학습하고 정상 분포에서 벗어난 입력을 이상으로 판단하는 비지도 기반 시각적 이상 감지(Vision Anomaly Detection, VAD)가 유용한 대안이 될 수 있다[3].

Ⅱ. 본론

본 시스템은 열화상 데이터 수집 및 저장, 정상 데이터 학습, 이상 감지(추론) 및 모니터링 단계로 구성된다. 용접 직후 획득한 열화상 영상에서 정상 열패턴을 학습하고, 추론 단계에서 입력 영상이 정상 패턴에서 벗어나는 정도를 이상 점수와 Anomaly Map으로 표현하여 작업자가 이상 위치를 확인할 수 있도록 한다.

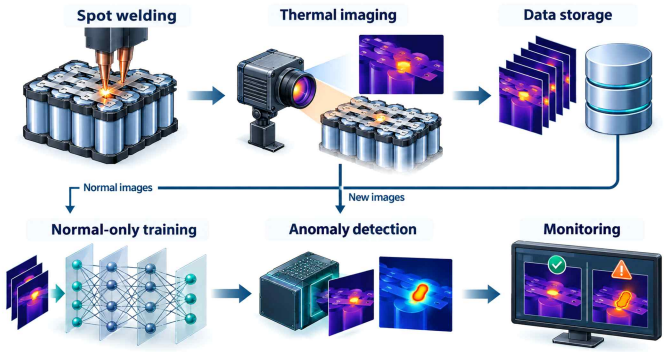


그림 1 열화상 카메라 기반 이상 감지 시스템 개요

Fig. 1 Overview of the thermal imaging-based anomaly detection system.

1. 열화상 데이터 및 학습 구성

열화상 영상은 UTi260B 카메라를 이용하여 수집하였다. 적외선 해상도는 256×192 pixel, 온도 측정 범위는 -20~550℃, FOV는 56° ×42° 이다. 데이터셋은 정상 520장과 과열 이상 27장으로 총 547장으로 구성하였다. 정상 데이터는 학습 80%, 검증 10%, 평가 10%로 분할 하였으며, 이상 데이터는 학습에서 제외하고 검증 20%, 평가 80%에 사용하였다.

학습 및 추론은 NVIDIA RTX 3090 GPU와 Intel i9-10900X CPU를 탑재한 워크스테이션에서 수행하였다. 소프트웨어 환경은 Python 3.10, PyTorch 2.2, Anomalib 2.2로 구성하였다. 모든 이미지는 열화상 카메라의 원 해상도인 256×192 pixel을 기준으로 전처리하여 동일한 조건에서 평가하였다.

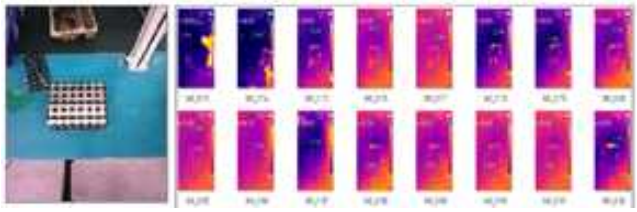


그림 2 원통형 배터리 팩 및 열화상 데이터 예시
Fig. 2 Examples of cylindrical battery-pack thermal images.

2. 대표 VAD 모델 및 성능 평가

세 가지 VAD 범주에서 분포 기반 PaDiM[4], 특징 기반 EfficientAD[5], 재구성 기반 GANomaly[6]의 3개 모델을 대표 모델로 선정하였다. 세 모델은 정상 데이터 중심으로 학습하고 F1-Score와 AUROC를 이용하여 정상·이상 판별 성능을 비교하였다.

PaDiM은 정상 이미지의 패치 특징 분포를 모델링하고 해당 분포로부터의 거리를 이상도로 계산한다. EfficientAD는 사전학습 특징과 정상 패턴 간 차이를 이용하여 빠르게 이상 영역을 검출하는 특징 기반 방식이다. GANomaly는 정상 패턴의 재구성 특성과 잠재공간 차이를 이용하여 이상 여부를 판단한다. 세 접근은 각각 분포, 특징, 재구성 관점에서 열화상 영상의 정상 패턴을 모델링한다.

표 1 대표 비전 이상 감지 모델의 성능 비교
Table 1 Performance comparison of representative VAD models.

Model	F1-Score	AUROC
PaDiM	0.9226	0.6842
EfficientAD	1.000	1.000
GANomaly	1.000	1.000

평가 결과 EfficientAD와 GANomaly는 본 평가 데이터에서 F1-Score와 AUROC가 모두 1.000으로 나타났고, PaDiM은 F1-Score 0.9226, AUROC 0.6842를 기록하였다. PaDiM은 일부 정상 영역에서도 추가 활성화가 발생하여 정상·이상 분포의 분리도가 상대적으로 낮았다. 반면 EfficientAD는 과열 이상 영역에 선택적으로 반응하고 정상 샘플에서는 불필요한 활성화가 적어 국소화 성능이 안정적으로 나타났다.

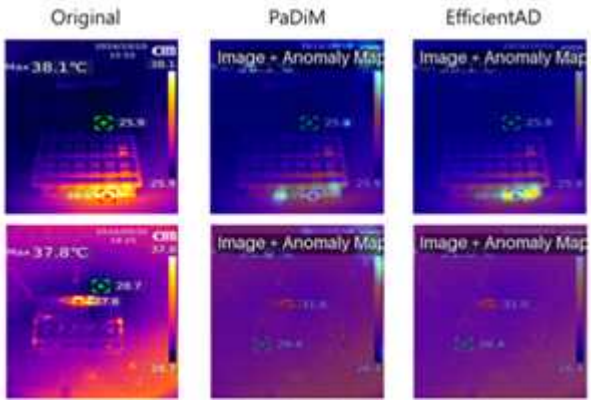


그림 3 Original, PaDiM 및 EfficientAD의 Anomaly Map 비교
Fig. 3 Comparison of anomaly maps for Original, PaDiM, and EfficientAD.

그림 3은 Original, PaDiM, EfficientAD 열을 발췌한 것이고, GANomaly열은 본 논문에서는 성능표의 정량 결과로만 제시하였다. 이러한 결과는 열화상 영상에서도 모델의 특징 학습 방식에 따라 이상 국소화 특성이 달라질 수 있음을 보여준다.

3. 결과 해석 및 적용 범위

PaDiM은 F1-Score가 0.9226으로 비교적 높았지만 AUROC가 0.6842에 머물렀다. 원 실험의 Anomaly Map에서도 비정상 샘플의 주요 과열부 외에 정상 영역에서 추가 활성화가 관찰되었고, 정상 샘플에서도 일부 영역이 반복적으로 이상으로 판단되는 경향을 보였다. 이는 열화상 데이터의 지역적 분포 변동에 분포 기반 모델이 민감할 수 있음을 시사한다.

EfficientAD는 비정상 샘플에서 실제 과열부를 중심으로 활성화하고 정상 샘플에서는 활성화가 거의 발생하지 않아 정량 성능과 공간적 국소화 결과가 일치하였다. GANomaly 역시 정량 지표에서는 높은 성능을 보였으나, 국소화 결과에 대한 시각적 비교는 수행하지 않았다. 따라서 본 결과는 모델별 정량 성능과 제공된 시각 자료의 범위 안에서 해석하는 것이 적절하다.

또한 원 연구의 이상 데이터는 안전사고와 직결되는 뚜렷한 과열 상태가 중심이어서 정상 데이터와의 분포 차이가 상대적으로 명확하였다. 실제 제조 현장에서는 용접 강도 저하, 접촉저항 증가, 미세한 열확산 차이와 같이 온도 차이가 작게 나타나는 이상도 존재할 수 있으므로, 현재 성능을 모든 용접 결함에 대한 일반화 성능으로 간주하기에는 제한이 있다.

Ⅲ. 결론

본 연구에서는 원통형 이차전지 배터리 팩 스팟용접 공정의 안전관리를 위하여 열화상과 비지도학습을 결합한 이상 감지 방법을 검토하였다. 정상 520장과 과열 이상 27장의 열화상 데이터를 바탕으로 PaDiM, EfficientAD, GANomaly를 비교한 결과, EfficientAD와 GANomaly가 본 평가에서 높은 정량 성능을 나타냈으며 EfficientAD는 Anomaly Map에서도 과열 이상 영역을 선택적으로 활성화하였다.

다만, 본 평가는 정상과의 분포 차이가 비교적 명확한 과열 중심의 소규모 데이터에 기반하므로, 이를 다양한 실제 용접 결함의 일반화 성능으로 직접 해석하기에는 제한이 있다. 향후에는 미세한 열적 차이를 갖는 이상 유형을 확대하고, 정지영상 중심 분석을 시계열 열화상 분석으로 확장하며, 경량 모델을 이용한 실시간 검증을 수행할 필요가 있다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] P. Stavropoulos, K. Sabatakakis, and H. Bikas, "Welding challenges and quality assurance in electric vehicle battery pack manufacturing," Batteries, vol. 10, no. 5, 2024.

[2] S. Shin, J. Park, K. Yi, F. Cenon IV, and H. Sohn, "Laser thermography inspection of weld defect in lithium-ion battery cap," Journal of Energy Storage,

vol. 109, Art. no. 115106, 2025.

[3] A. Shabayek, A. Rathinam, M. Ruthven, D. Aouada, and T. Amietszajew, "AI-enabled thermal monitoring of commercial Li-ion pouch cells with feature-adapted unsupervised anomaly detection," Journal of Power Sources, vol. 629, 2025.

[4] T. Defard et al., "PaDiM: a patch distribution modeling framework for anomaly detection and localization," ICPR, 2021.

[5] K. Batzner, L. Heckler, and R. K?nig, "EfficientAD: Accurate visual anomaly detection at millisecond-level latencies," WACV, 2024.

[6] S. Akcay, A. Atapour-Abarghouei, and T. P. Breckon, "GANomaly: Semi-supervised anomaly detection via adversarial training," ACCV, 2018.

절차 그래프 기반 행동 후보와 지식 검색을 활용한 연구개발계획서 작성 Agent

이혜빈, 강대익*, 강현수**

충북대학교 산업인공지능학과, *충북대학교 산업인공지능연구센터, **충북대학교 정보통신공학부

hbin2@cbnu.ac.kr, *kangdaeik@cbnu.ac.kr, **hskang@cbnu.ac.kr

A Research Proposal Writing Agent Using Procedural-Graph Action Candidates and Knowledge Retrieval

Hyebin Lee, Daeik Kang*, Hyunsoo Kang**

Department of Industrial AI, Chungbuk National Univ.,

*Industrial AI Research Center, Chungbuk National Univ.,

**School of Information and Communication Engineering, Chungbuk National Univ

Abstract

An LLM agent writing a research proposal over many steps often repeats finished actions, skips prerequisites and fails to propagate changes. We add retrieval over the call for proposals (RAG) and a procedural graph (PG) that lists the actions executable in the current state, and compare four configurations with and without each. Without PG, EXAONE3.5-7.8B completed 0/8 cases and Qwen3-8B 5/8; with PG both completed 8/8 with fewer calls, and RAG raised the share of relevant cited evidence from 0% to 51%-55%. A PG generated from the form by the LLM itself worked as well as a hand-made one, also on a second call for proposals.

Key words : LLM Agent, Procedural Graph, RAG, Execution State

Ⅰ. 서 론

연구개발계획서를 작성하려면 공고와 양식이 제시하는 요구사항을 신청자의 정보와 연결한 뒤, 이를 여러 항목에 일관되게 반영해야 한다. 이 과정을 AI 에이전트(Agent)에 위임하면, 에이전트는 현재 상황을 스스로 판단하여 질문, 공고 읽기, 절 작성, 통합, 검토와 같은 작업을 골라 수행한다. 그러나 이처럼 여러 단계가 이어지는 작업에서 에이전트는 진행 상황을 놓치기 쉽다. 이미 끝난 작업을 반복하거나 앞 단계가 끝나기 전에 다음 단계로 넘어가고, 입력 하나가 바뀌었을 때 영향을 받는 항목들을 일관되게 고치지 못한다. 또한 공고 원문의 근거 없이 그럴듯한 문장을 만들어 내기도 한다.

이러한 문제에 대처하기 위해 본 연구는 두 가지 보조 장치를 에이전트에 추가한다. 하나는 공고 원문에서 관련 부분을 검색하여 작성 근거로 제시하는 지식 검색(RAG)이고, 다른 하나는 각 작업의 선행 조건과 순서를 기록한 절차 그래프(PG)이다. PG는 실행 상태와 연결되어 에이전트가 지금 할 수 있는 일을 알려 주는 절차 메모리로 기능한다. RAG와 PG의 포함 여부에 따라 네 가지 구성을 만들고, 동일한 조건에서 업무 완료율과 효율을 비교한다.

Ⅱ. 본론

2.1 관련 연구

RAG는 외부 문서를 검색하여 얻은 내용을 생성 근거로 활용한다[1]. 작업 흐름에 관한 선행 연구로는 실행 경험에서 작업 패턴을 학습하는 Agent Workflow Memory[2]와 작업 흐름을 그래프로 표현하는 Procedural Graphs[3]가 있다. 본 연구의 PG는 이들과 달리 학습 과정 없이 사람이 정의하거나 LLM이 양식에서 한 번에 추출한다.

2.2 지식, 절차, 상태의 결합

지식 저장소는 공개 IRIS 공고(019311)의 공고문과 서식(약 14만 자)을 130개 조각으로 나누어 구축하였고, 단어 검색(BM25)과 의미 검색(bge-m3[4])의 결과를 결합하여 관련 조각을 찾는다. 작성 대상인 계획서는 목표, 방법, 선행연구, 인력, 일정, 예산, 기대효과, 안전의 8개 절로 구성된다.

PG의 각 노드는 작업 실행 전에 확인되어야 할 입력과 먼저 작성되어야 할 절을 명시한다. 예컨대 '방법' 절은 '목표' 절이 작성된 뒤에야, '일정'은 '방법' 뒤에야 쓸 수 있다(그림 2). 실행 상태에는 확인된 입력, 작성 완료된 절, 통합과 검토의 수행 여부가 기록되며, 입력이 변경되면 그 입력에 의존하는 절은 다시 작성 대상이 된다. 에이전트는 현재 상태와 PG를 대조하여 실행 가능한 작업 목록(PG 후보)을 구하고, 그중에서 다음 행동을 선택한다(그림 1).

2.3 비교 구성과 평가

네 구성은 모두 같은 모델, 규칙 설명, 도구를 사용하며 한 과제당 최대 32회의 행동을 허용한다. 규칙에 어긋난 선택은 공통 검사가 거부하지만, 거부된 선택도 행동 횟수에 포함되므로 잘못된 선택을 반복하면 계획서 작성을 시작하기도 전에 한도를 소진한다. 즉 PG의 역할은 잘못된 선택을 사후에 차단하는 것이 아니라 애초에 올바른 후보만 보여 주는 데 있다. 절 작성 근거로는 RAG 구성이면 검색한 관련 조각을, 그렇지 않으면 원문 앞부분을 같은 분량(2,500자)으로 받는다.

평가는 업무 완료 수와 오류 시도 비율(지금 할 수 없는 행동을 고른 비율)을 주지표로, 모델 호출 수, 출력 토큰, 응답 시간을 부가 지표로 하며, 본문이 인용한 근거 가운데 해당 절과 관련된 비율로 인용의 적절성을 평가한다.

2.4 실험 설정

실험은 보안과 비용을 고려하여 로컬 GPU(RTX 4060 8GB)에서 실행 가능한 모델로 진행하였다. EXAONE3.5 7.8B를 주 모델로 하고 Qwen3 8B와 Llama3.1 8B를 함께 평가하였으며, 재현성을 위해 온도는 0으로 고정하였다. 과제는 가상 신청 기업 8곳의 계획서 작성이며, 사례마다 빠진 입력, 중간에 변경되는 입력, 한 번 실패하는 도구를 다르게 배치하였다.

2.5 고정 상태에서의 다음 행동 선택

작업 도중의 상태를 고정하고 EXAONE이 다음 행동을 고르게 하였다. 앞 절이 없어 아직 쓸 수 없는 절이 있는 9개 상태를 순서를 바꿔 두 번씩(18회) 물었을 때, 정답은 상태만 줄 때 10회, 끝난 작업을 목록에서 지워도 10회였지만 PG 후보를 주면 18회 모두였다.

2.6 4구성 연속 실행

다음으로 과제 전체를 처음부터 끝까지 실행하였다.

EXAONE은 PG가 없을 때 끝난 작업을 235회 반복하며 모든 사례에서 행동 한도에 도달하였고, 한도를 48로 늘려도 같았다(표 1). 반면 PG가 있으면 8개 사례를 모두 완료하였고, 바뀐 입력 반영과 도구 실패 회복도 정상적

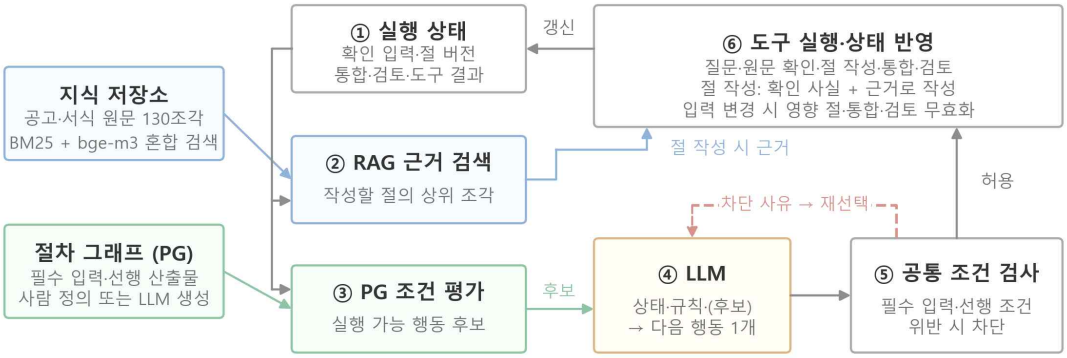


그림 1 상태 제어 구조

Fig. 1 State-controlled agent architecture

으로 처리하였다. PG 구성의 출력 토큰과 응답 시간이 더 큰 것은 실제로 본문을 작성했기 때문이다. 인용 근거의 관련성은 원문 앞부분만 받는 PG 구성에서 0%, RAG를 함께 쓰면 51%였고, RAG의 유무는 완료와 호출 수에 영향을 주지 않았다.

표 1 4구성 연속 실행 결과(EXAONE, 사례 8개 합계)

Table 1 End-to-end results of four configurations (EXAONE, 8 cases)

지표	Agent	RAG	PG	RAG+PG
업무 완료	0/8	0/8	8/8	8/8
오류 시도 비율	95%	95%	9%	9%
모델 호출	256	256	222	222
출력 토큰(천)	2.6	2.6	24.4	25.2
응답 시간(초)	120	118	672	695
관련 근거 인용	–	–	0%	51%

표 2 모델과 공고별 업무 완료(호출 수), 사례 8개

Table 2 Completed cases (model calls) by model and call for proposals

모델	공고	Agent	RAG	PG	RAG+PG
EXAONE	019311	0/8(256)	0/8(256)	8/8(222)	8/8(222)
Qwen3	019311	5/8(270)	5/8(270)	8/8(210)	8/8(210)
Llama3.1	019311	0/8(256)	0/8(256)	0/8(274)	0/8(276)
EXAONE	023857	0/8(256)	0/8(256)	8/8(202)	8/8(202)
Qwen3	023857	7/8(246)	7/8(246)	8/8(198)	8/8(198)

Qwen3는 PG 없이도 5건을 완료하였으나 선택의 43%가 오류였다(표 2). PG를 추가하면 오류가 0%로, 끝난 작업의 반복이 70회에서 0회로 줄어 8건 모두 완료하였으며, 호출은 270에서 210으로, 완료 1건당 시간은 142초에서 94초로 줄었다. Llama3.1은 PG 후보를 받고도 작성한 절을 반복 선택하여 모두 실패하였다. EXAONE과 Qwen3는 온도 0.7로 세 차례 반복해도 완료 수가 같았다.

2.7 PG 자동 생성과 다른 공고

동일한 LLM에게 양식의 각 절에 필요한 입력과 먼저 작성해야 할 절을 고르게 하여 PG를 자동 생성하였다. 공고당 13~15회 호출로 충분하며, 생성한 PG는 해당 공고의 모든 사례에 적용한다. 자동 PG는 입력을 사람보다 넉넉하게 선택하는 경향이 있었으나(필수 입력 정밀도 0.31~0.46), 업무 완료는 사람의 PG와 같았고 호출 수는 같거나 적었다. EXAONE의 자동 PG는 '일정'이 '방법' 뒤에 온다는 관계를 누락하였지만, 그로 인한 잘못된 후보는 선택되지 않았고 선택되더라도 공통 검사가 차단한다. 다른 공고(IRIS 023857, 7개 절, 가상 사례 8개)에서도 자동 PG만으로 같은 결과를 얻었다(표 2).

2.8 본문 품질

구성 이름을 가린 상태에서 LLM(Claude)으로 본문을 채점한 결과, 확인되지 않은 내용을 사실처럼 서술한 절의 비율은 Qwen3의 네 구성에서 14~17%로 비슷하였고, EXAONE은 PG 단독 27%, RAG+PG 41%로 RAG의 영향이 모델에 따라 달랐다. 다른 LLM의 독립 채점과는 사실 정확성 87%, 미확인 단정 94%가 일치하였다(κ 0.76).

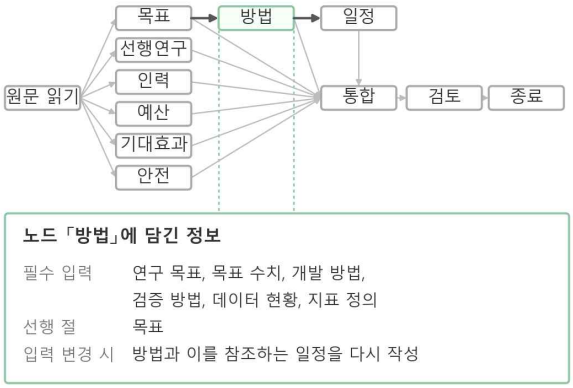


그림 2 PG 그래프와 노드 정보

Fig. 2 PG graph and node information

Ⅲ. 결론

PG 후보는 에이전트가 다음 행동을 올바르게 선택하도록 도왔다. 끝난 작업의 반복과 순서 위반이 크게 줄어, EXAONE은 두 공고 모두에서 완료가 0/8에서 8/8로 올랐고 Qwen3는 호출이 약 20%, 완료 1건당 시간이 12~33% 감소하였다. LLM이 양식에서 자동 생성한 PG도 같은 효과를 보였으므로, 실행 전에 PG를 한 번 추출하면 절차를 직접 설계하지 않고도 에이전트를 더 적은 비용과 시간으로 운용할 수 있다. RAG는 인용 근거의 관련성을 높였으나 확인되지 않은 단정은 줄이지 못했고, PG는 본문 품질을 낮추지 않았다. 다만 PG의 효과는 모델이 후보를 따르는 경우에만 성립한다.

ACKNOWLEDGMENT

이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성 사업임 (IITP-2026-RS-2020-II201462).

참 고 문 헌

[1] P. Lewis et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," NeurIPS, 2020.

[2] Z. Z. Wang et al., "Agent Workflow Memory," ICML, 2025.

[3] Y. Lu et al., "Procedural Graphs: Self-Evolving Execution Structures for LLM Agents," arXiv:2609.09153, 2026.

[4] J. Chen et al., "BGE M3-Embedding," arXiv:2402.03216, 2024.