

✓ 대상 데이터셋 개요 및 선정근거

Jena Climate Dataset (기상 다변량 시계열)

스케일러별 성능 비교 실습에 활용한 공개 벤치마크 데이터셋

1 데이터 개요

출처	Max Planck Institute (독일 예나)
관측 기간	2009년 ~ 2016년 (8개년)
기록 주기	10분 간격 (실습 시 1시간 단위 리샘플링)
데이터 규모	약 420,000행 × 14개 변수
데이터 유형	다변량 시계열 (Multivariate Time Series)
과제 유형	회귀(Regression), 기온 예측

3 데이터 선정 근거

- 변수 간 단위 편차가 커 스케일링 전·후 Ridge·SVR의 성능 변화 비교에 적합
- 풍속(wv)에 **돌풍 형태의 이상치가 존재**, **RobustScaler 효과 확인 가능**
- 공개 데이터로 실습 결과의 재현 및 타 사례와의 비교 용이

2 변수 구성 및 스케일 편차

타겟 y : T (degC)

기온, 약 -20 ~ 35 °C

연·일 단위 계절성 포함

입력 변수 x (총 14개 변수 중 주요 4종)

p (mbar)	기압	900 ~ 1050	
wd (deg)	풍향	0 ~ 360	
rh (%)	습도	0 ~ 100	
wv (m/s)	풍속	0 ~ 20+	

- 그 외 Tpot(K) 온위, Tdew(degC) 이슬점온도, VPmax(mbar) 대기압, sh(g/kg) 비습, rho(g/m³) 공기밀도 등 9개 변수
- ※ 막대 길이는 각 변수 최댓값의 log₁₀ 상대 크기. 기압(≈10³)과 풍속(≈10¹)의 **스케일 차이가 약 50배로**, **거리·정규화 기반 모형의 성능에 직접 영향**

✓ 스케일링 적용전 전처리

1. [중요] 스케일링 적용 전 반드시 처리해야 할 전처리 작업

- 1) 풍속 결측 이상치(-9999.0) 처리 (필수)
 1. wv (m/s)와 max. wv (m/s) 컬럼에 장비 오류로 기록된 센서 결측값 -9999.00이 약 18~20건 포함되어 있습니다.
 2. 처리 방법: -9999.0 값을 np.nan으로 변환 후 직전 값 대체(ffill) 또는 시계열 선형 보간(interpolate(method='time'))을 수행해야 합니다.
- 2) 풍향(wd (deg))의 삼각함수 인코딩
 1. 풍향은 0°~360° 값을 가지며, 0°와 360°는 물리적으로 같은 북풍입니다. 일반 스케일러(0~1 또는 표준화)를 그대로 적용하면 0과 360이 가장 먼 값으로 왜곡됩니다.
 2. 스케일링 전에 sin, cos주기 피쳐로 변환하는 해야 함
 3. $wd_x = \cos\left(\frac{2\pi \times wd}{360}\right)$, $wd_y = \sin\left(\frac{2\pi \times wd}{360}\right)$
 4. (변환된 wd_x, wd_y는 이미 -1 ~ 1 사이 범위이므로 추가 스케일링이 불필요하거나 단순 유지)

1. 전처리 완료 검증

- 1) 풍속 최솟값 (정상 범위: 0 이상): wv=0.00, max_wv=0.00
- 2) 풍속 최댓값: wv=28.49, max_wv=23.50
- 3) 풍향 sin 범위: [-1.00, 1.00]
- 4) 풍향 cos 범위: [-1.00, 1.00]
- 5) 전체 결측치 수: 0

1. Dataset 스케일링

✓ 대상 데이터셋 스케일링 대상

데이터셋을 분석한 결과, 피처들의 물리적 단위와 값의 범위(Scale) 차이가 매우 큼니다. 머신러닝 모델 학습을 위해 스케일링이 필요한 대상 Feature의 분류/정리

* 센서 결측값 선형 보간값으로 치환

1. 피처별 실제 스케일(범위) 요약 분석						
구분	Feature명	Feature명 (한글)	최소값(Min)	중앙값(Median)	최대값(Max)	특징 및 단위 수준
대형 단위	rho (g/m**3)	공기 밀도 (Air Density)	1059.45	1213.79	1393.54	공기 밀도 (~1200 단위)
	p (mbar)	대기압 (Pressure)	913.6	989.58	1015.35	대기압 (~1000 단위)
	Tpot (K)	온위 (Potential Temperature)	250.6	283.47	311.34	온위 (~280 단위)
중형 단위	rh (%)	상대습도 (Relative Humidity)	12.95	79.3	100	백분율 (0 ~ 100)
	T (degC)	기온 (Temperature)	-23.01	9.42	37.28	섭씨온도 (-20 ~ 37)
	Tdew (degC)	이슬점 온도 (Dew Point)	-25.01	5.22	23.11	이슬점 온도 (-25 ~ 23)
	H2OC (mmol/mol)	수증기 농도	0.8	8.96	28.82	수증기 농도 (0 ~ 30)
	VPmax (mbar)	포화 수증기압	0.95	11.82	63.77	포화 수증기압 (1 ~ 64)
	VPact (mbar)	실제 수증기압	0.79	8.86	28.32	실제 수증기압 (0 ~ 28)
	VPdef (mbar)	포화 수증기압 결손량	0	2.19	46.01	수증기압 결손량 (0 ~ 46)
	sh (g/kg)	비습 (Specific Humidity)	0.5	5.59	18.13	비습 (0 ~ 18)
소형 단위/이상치	wv (m/s)	풍속 (Wind Velocity)	-9999.00*	1.76	28.49	풍속 (0 ~ 28)
	max. wv (m/s)	최대 풍속 (Gust)	-9999.00*	2.96	23.5	최대 풍속 (0 ~ 24)
방위각(각도)	wd (deg)	풍향 (Wind Direction)	0	198.1	360	풍향 (0 ~ 360)

✓ 대상 데이터셋 스케일링 방법 및 선정 사유(복합 스케일링 적용)

스케일링 필수 대상 - 총 12개, 단위 편차(1,000 단위 vs 1 단위)가 매우 커 거리/가중치 기반 모델(Ridge, Lasso, SVR, MLP) **학습 시 특정 변수로 편향되는 것을 막기 위해 반드시 스케일링이 필요**

피처 유형	추천 스케일러	선정 사유
wv (m/s), max. wv (m/s) - 풍속	RobustScaler	순간 돌풍(Gust) 등 정상적인 자연 스파이크가 존재하므로 중앙값과 IQR 기준 스케일링이 가장 안정적임 (데이터에 극단적인 이상치가 섞여 있을 때 기존 스케일러들의 치명적인 약점을 보완해주기 때문입니다.)
p, Tpot, rho - 대기압, 온위, 공기밀도	StandardScaler	정규분포에 가까운 물리량이며 평균과 표준편차 기준 정규화에 적합
rh (%), sh, H2OC - 상대습도, 비습, 수증기 농도	MinMaxScaler 또는 StandardScaler	최소값이 0에 가깝고 상한이 존재하는 비율/농도 지표

Scaler는 Train에만 fit, Validation/Test는 transform을 적용

1. Dataset 데이터 분할 별 비교

✓ 데이터 분할에 따른 결과가 달라지는지 확인

Train/Test 분할과 Train/Validation/Test 분할 비교를 위한 분할결과

=== 시계열 6:2:2 분할 ===

Train 세트 : (252330, 14) (60.0%)

Validation 세트 : (84110, 14) (20.0%)

Test 세트 : (84111, 14) (20.0%)

=== 시계열 8:2 분할 ===

Train 세트 : (336440, 14) (80.0%)

Test 세트 : (84111, 14) (20.0%)

✓ 하이퍼파라미터, 사용자가 학습 시작 전에 직접 지정해야 하는 외부 설정값

1. 하이퍼파라미터 조정이 반드시 필요한 이유

- 1) 모델의 과적합(Overfitting)과 과소적합(Underfitting) 제어
 - 트리 모델(max_depth): 트리의 깊이가 너무 깊으면 훈련 세트의 노이즈까지 암기하여 Test 세트에서 오차가 폭증(과적합)하고, 너무 얕으면 기상 패턴을 전혀 학습하지 못합니다(과소적합).
 - 경사하강법(alpha, 규제 계수): 모델 복잡도에 페널티를 주어 가중치가 비정상적으로 커지는 현상을 억제합니다.
- 2) 학습 수렴(Convergence)과 발산 방지
 - 학습률(learning_rate, eta0):
 - 너무 크면 최적점을 지나쳐 손실 함수(Loss)가 무한대로 발산(Gradient Explosion)합니다.
 - 너무 작으면 수천 번 반복해도 최적점에 도달하지 못해 학습이 제자리걸음을 합니다.
- 3) 데이터셋 맞춤형 기본값 탈피
 - 라이브러리(scikit-learn, LightGBM 등)의 기본값(Default)은 범용적인 값일 뿐, 현재 데이터셋의 크기, 노이즈, 피처 수에 최적화된 값이 아닙니다. 하이퍼파라미터를 조정하는 것만으로도 예측 오차(RMSE)를 크게 개선할 수 있습니다.

하이퍼 파라미터 적용

- alpha (L2 규제 페널티 강도) : 모델의 가중치 크기를 제한
- learning_rate='adaptive' (적응형 학습률): SGD(경사하강법)가 헤매지 않고 최저점(최소 오차)에 잘 도달하도록 설정
- eta0=0.01 (초기 학습률) : 학습을 처음 시작할 때의 기본 보폭
- max_iter=3000 (최대 학습 반복 횟수) : 전체 데이터를 최대 3,000번 반복해서 보면서 학습
- tol=1e-4 (조기 종료 허용 오차) : 성능 개선 폭이 0.0001(1e-4)보다 작아지면 "이미 최적의 성능에 도달했다"고 판단하여, 3,000번을 다 채우지 않고 스스로 학습을 조기 종료

1. Dataset 하이퍼파라미터 조정

✓ 조정 기법 : Grid Search 적용

사전에 정의한 파라미터 조합 전체를 격자(Grid) 형태로 전수 조사

비교 항목	휴리스틱(Heuristic) 탐색	그리드 서치(Grid Search)
방식	분석가의 직관, 도메인 지식, 시각화 결과를 바탕으로 후보값을 수동 조정	사전에 정의한 파라미터 조합 전체를 격자(Grid) 형태로 전수 조사
장점	• 연산 비용이 매우 적음 • 탐색 범위를 빠르게 좁힐 수 있음	• 모든 조합을 테스트하므로 객관적인 비교 가능 • 자동화 파이프라인 구축 용이
단점	• 분석가의 주관에 개입되며 최적 조합을 놓칠 수 있음	• 조합 수가 늘어날수록 탐색 시간(연산량)이 기하급수적으로 증가
실무/과제 추천	대략적인 범위를 잡을 때 (초기 탐색)	확정된 범위 내에서 최적 조합을 결정할 때

"Test 세트의 성능을 보고 하이퍼파라미터를 튜닝하면 시험 문제를 미리 보고 공부하는 것과 같은 Data Leakage가 발생합니다. 따라서 오직 Validation 세트의 손실값(RMSE)만을 목적 함수로 삼아 최적 하이퍼파라미터를 선택한 후, 미지의 데이터인 Test 세트에서 일반화 성능을 최종 검증 함."

✓ 시계열 데이터 선형 회귀 분석(확률적 경사하강법 적용)

SGDRegressor 채택 사유

선형회귀 분석에 확률적 경사하강법(SGD)을 적용하는 `sklearn.linear_model.SGDRegressor` 도입 근거

스케일링 효과 정량 검증 (실데이터 테스트)

스케일링 미적용

RMSE 수십조 단위

손실 함수 발산 → 기울기 폭발(Gradient Explosion)



StandardScaler / RobustScaler 적용

RMSE $\approx$ 0.10

단위 정렬 후 안정적으로 수렴

1

전처리 필요성의 정량적 입증

피처 스케일에 민감하여 전처리 전·후 성능 차이가 가장 극명하게 드러나며, "전처리가 왜 필수적인가"를 확인 가능.

2

시계열 온라인 학습 구현

`partial_fit`을 지원하여 신규 시계열 데이터 유입 시 전체 재학습 없이 가중치만 점진적으로 갱신할 수 있음.

3

빠른 연산과 선형모델의 해석성

샘플 단위 가중치 갱신으로 연산 속도가 매우 빠르며, 선형회귀 계수를 그대로 해석할 수 있어 결과 설명이 용이 함.

1. 모델 성능 평가

✓ 최종 성능 평가

RMSE(Root Mean Squared Error, 평균 제곱근 오차), **MAE** (Mean Absolute Error, 평균 절대 오차), **R²** (R-Squared, 결정계수)

$$= \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$R^2 = 1 - \frac{\text{Residual Sum of Squares}}{\text{Total Sum of Squares}}$$

Train/Test 분할과 Train/Validation/Test 분할 비교 => 검증 데이터 유무에 따른 성능 차이 분석

=== [최종 평가 단계 6:2:2] Test 세트 성능 vs 지속성 기준선 ===

지표	지속성 기준선	SGD 모델	개선율
RMSE	0.9491	0.5886	38.0%
MAE	0.6849	0.4108	40.0%
R2	0.9863	0.9947	





=== [Train/Test 8:2] Test 세트 성능 vs 지속성 기준선 ===

지표	지속성 기준선	SGD 모델	개선율
RMSE	0.9491	0.5887	38.0%
MAE	0.6849	0.4105	40.1%
R2	0.9863	0.9947	

1. 모델 성능 평가

✓ 최종 성능 평가(시계열 6:2:2 분할)

SGDRegressor (확률적 경사 하강법) - $T(t+1h)$ 예측, Train/Test 8:2 - Test 세트 수행 결과
Test $n=13,947$ | RMSE=0.5887 MAE=0.4105 $R^2=0.9947$ | $\alpha=1e-05$
지속성 기준선 RMSE=0.9491 -> 모델 RMSE=0.5887 (기준선 대비 개선 +38.0%)



1. 모델 성능 평가

✓ 최종 성능 평가(시계열 8:2 분할)

SGDRegressor (확률적 경사 하강법) - $T(t+1h)$ 예측, 누수 제거 - Test 세트 수행 결과
Test $n=13,947$ | RMSE=0.5886 MAE=0.4108 $R^2=0.9947$ | $\alpha=1e-05$
지속성 기준선 RMSE=0.9491 -> 모델 RMSE=0.5886 (기준선 대비 개선 +38.0%)

