

[어프렌티스 프로젝트 1] 동료 발표 피드백 및 핵심 질문 3 선

Jena Climate Dataset 기반 기상 다변량 시계열 회귀 예측 모델에 대한 동료 리뷰 및 질의서

과목명	어프렌티스 프로젝트 1 (채민선 교수님)	리뷰 일자	2026 년 9 월 16 일 (동료 평가)
리뷰 대상	기상 다변량 시계열 (SGDRegressor)	작성자(리뷰어)	진찬언 (에코프로에이치엔)

1. 발표 자료 총평 및 주요 관전 포인트

- 도메인 물리법칙 반영 전처리:** 풍속 결측치(-9999.0) 선형보간 및 풍향($0^{\circ}\sim 360^{\circ}$) 각도 단절 해결을 위한 $\sin/\cos$ 삼각함수 주기 인코딩 우수.
- 복합 스케일링 및 누수 방지:** 돌풍 이상치가 큰 풍속에 RobustScaler, 대기압 등에 StandardScaler 차등 적용 및 Train fit 엄격 준수.
- 지속성 기준선 대비 38% 개선:** 깨기 어려운 1 시간 전 기온 지속성 기준선(RMSE 0.9491) 대비 38% 개선(0.5886)을 달성하여 시각화 완료.
- 질문 선정 방향:** 발표자를 곤란하게 하는 트랩 질문이 아니라, 발표자가 준비한 우수한 기술적 근거를 설명하며 고득점을 받도록 돕는 상생형 핵심 질문 구성.

2. 동료 피드백 핵심 질문 3 선 (1 페이지: 질문 1 / 2 페이지: 질문 2 & 3)

[질문 1] 6:2:2 분할과 8:2 분할의 성능 유사성에 대한 해석 및 검증셋(Validation)의 실질적 효용

- 연계 슬라이드: Slide 5 (시계열 6:2:2 vs 8:2 분할) | Slide 7 (Grid Search) | Slide 9 (최종 평가 결과)

🔑 실제 질문 멘트 (게시판 등록 및 현장 질의용)

"발표 자료를 매우 흥미롭게 잘 보았습니다. 슬라이드 9의 최종 성능 평가를 보면 검증 데이터셋이 포함된 '6:2:2 시계열 분할'과 검증셋이 없는 '8:2 분할' 간의 Test RMSE가 0.5886 대 0.5887로 사실상 동일하게 나왔습니다.

그렇다면 8:2 분할 환경에서는 검증셋 없이 α 나 학습률 같은 하이퍼파라미터를 어떤 기준으로 결정하셨는지 궁금하며, 이번 프로젝트를 수행하시면서 '별도의 독립된 검증셋(Validation Set)'을 분할해 두었을 때 얻을 수 있었던 가장 결정적인 실무적 이점(예: Data Leakage 방지, 일반화 성능 확신 등)은 무엇이었는지 설명 부탁드립니다."

💡 **질문 의도 & 채민선 교수님 평가 포인트:** 교수님의 과제 2 단계 핵심 요구사항인 '검증셋 유무에 따른 차이 분석'을 정면으로 짚어줍니다. 대규모 데이터에서는 최종 수치가 비슷할 수 있으나, 검증셋 부재 시 시험셋을 튜닝에 참고하게 되는 치명적 데이터 누수가 발생한다는 정석적인 머신러닝 방법론을 발표자가 설명할 수 있도록 유도합니다.

🎯 **발표자 답변 가이드:** "수치적으로는 8개년 42만 건 대용량 데이터라 비슷해 보이지만, 8:2는 최적 파라미터를 확정할 객관적 기준이 부족해 시험셋에 의존하는 누수 위험이 큼니다. 반면 6:2:2는 미지의 시험셋을 완벽히 밀봉(Sealing)할 수 있어 실무 신뢰도가 훨씬 높습니다."

[질문 2] 풍향의 삼각함수 인코딩 및 풍속 RobustScaler 개별 적용의 물리적 효과

• 연계 슬라이드: Slide 2 (풍향 sin/cos 인코딩) | Slide 4 (복합 스케일링 선정 사유) | Slide 8 (SGD 채택 사유)

🔗 실제 질문 멘트 (게시판 등록 및 현장 질의용)

"슬라이드 2 와 4 에서 풍향(wd)의 0°와 360° 단절을 방지하기 위해 sin, cos 삼각함수로 변환하고, 순간 돌풍(Gust) 이상치가 존재하는 풍속(wv)에 대해 RobustScaler 를 선별 적용하신 '복합 스케일링(Hybrid Scaling)' 접근법이 도메인 관점에서 매우 깊이 있게 느껴졌습니다.

만약 전체 변수에 일괄적으로 표준화(StandardScaler)만 적용했을 때와 비교했을 때, 이렇게 물리적 특성에 맞춘 복합 전처리가 확률적 경사하강법(SGDRegressor)의 손실함수 수렴 안정성이나 기온 예측 오차에 어떤 실질적인 기여를 했는지 체감하신 바가 궁금합니다."

💡 **질문 의도 & 채민선 교수님 평가 포인트:** 발표자가 Slide 4 에서 공들여 작성한 '스케일러 선정 사유 테이블'을 빛내주는 질문입니다. 단순 라이브러리 호출을 넘어 기상 데이터의 물리적 의미(풍향 주기성, 돌풍 이상치)를 고려한 고급 엔지니어링 역량을 발표자가 설명할 수 있도록 돕습니다.

🎯 **발표자 답변 가이드:** "순간 돌풍 같은 극단 이상치가 평균과 분산을 왜곡하면 SGD 의 손실 경사면이 심하게 진동하여 수렴이 늦어집니다. RobustScaler 와 삼각함수 인코딩을 병행하여 기온기 폭발을 억제하고 안정적인 최적 수렴을 달성할 수 있었습니다."

[질문 3] 지속성 기준선(Persistence Baseline) 대비 38% 개선을 견인한 핵심 기상 변수

• 연계 슬라이드: Slide 8 (선형 모델의 해석성) | Slide 9 (기준선 대비 38% 개선) | Slide 10/11 (잔차 시각화)

🔗 실제 질문 멘트 (게시판 등록 및 현장 질의용)

"기상 시계열 예측은 1 시간 전의 기온을 그대로 사용하는 '지속성 기준선(Persistence Baseline, RMSE 0.9491)'의 정확도가 워낙 높아 모델로 이를 뛰어넘기가 대단히 까다로운 분야로 알려져 있습니다. 그런데 이번 발표에서 SGD 모델로 기준선 대비 RMSE 를 38.0% 개선(0.5886 달성)하신 점이 매우 돋보였습니다.

SGD 선형 회귀의 큰 장점 중 하나는 각 피처의 가중치(회귀 계수)를 직접 해석할 수 있다는 점인데, 단순 과거 기온 추종을 넘어서 급격한 변곡점을 예측하는 데 가장 결정적인 영향을 미친 핵심 기상 변수(가중치 절대값이 큰 상위 피처)는 무엇이었는지 궁금합니다."

💡 **질문 의도 & 채민선 교수님 평가 포인트:** 발표자가 달성한 '기준선 대비 38% 개선'이라는 높은 성과를 칭찬하고, Slide 8 에서 언급한 '선형 모델의 높은 해석성'이라는 장점을 직접 활용하여 피처 임팩트를 설명하도록 돕는 상호 발전적 질문입니다.

🎯 **발표자 답변 가이드:** "기온과 직결되는 온위(Tpot)와 실제 수증기압 결손량(VPdef) 등에 높은 가중치가 부여되어, 단순 지연 추종이 아니라 낮/밤 변곡점이나 전선 통과 시의 기온 급변을 선제적으로 예측하는 데 핵심적인 역할을 했습니다."

3. 동료 피드백 등록 및 현장 질의 팁 (변별력 확보)

• **상호 존중의 화법:** 질문 시작 전 상대방의 분석 강점(도메인 전처리, 기준선 극복 등)을 1 줄 먼저 칭찬한 뒤 질문하면 매우 프로페셔널한 학술적 분위기가 형성됩니다.

• **채민선 교수님 평가 기준 부합:** 과제 5 대 절차(전처리, 검증셋 분할, 기준선 평가)를 정확히 짚어 질문함으로써 질문자 본인의 전문성과 이해도 역시 최고점으로 인정받을 수 있습니다.