7주차 강의

Model Architecture

Convolutional Neural Networks

김영진
you359@cbnu.ac.kr
충북대학교 산업인공지능연구센터

INDUSTRIAL AI RESEARCH CENTER

CONTENTS

I **Introduction to CNN**
Why CNN?, Filter/Kernel, Convolution

II **General CNN Structure**
Convolution Layer, Pooling Layer, Fully Connected Layer

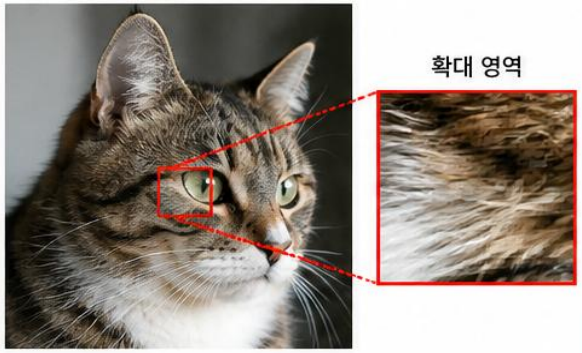
III **CNN Models : Case Study**
CNN History, LeNet5, AlexNet, VGGNet, Inception Net, ...

■ 왜 CNN이 필요한가?

1) 이미지 데이터의 특성

- **지역 상관성** : 인접한 픽셀들은 서로 독립적이지 않고 공간적으로 연관된 정보를 가짐
- **공간적 반복성** : 엣지, 코너, 질감 등의 특징은 이미지의 여러 위치에서 반복적으로 나타남
- **구성적/계층적 구조** : 단순한 특징들이 조합되어 점차 복잡하고 의미 있는 구조를 형성

1. 지역 상관성 (Local Correlation)

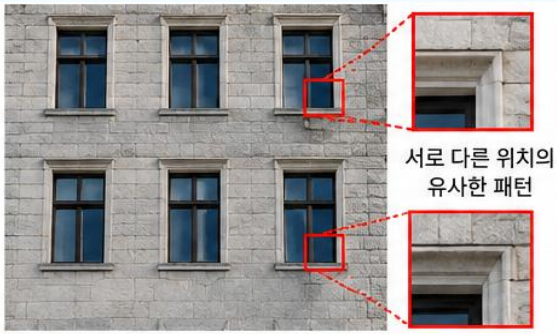


픽셀 값 예시 (확대 영역의 일부)

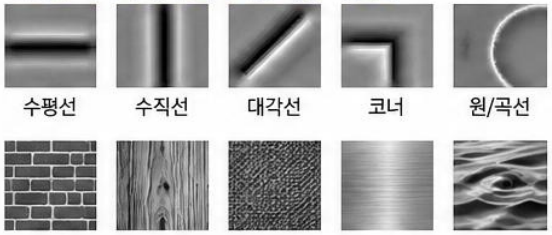
120	118	115	117	119
122	121	119	120	118
125	123	120	119	116
126	124	122	120	117
125	123	121	118	115

- 인접 픽셀 값이 서로 비슷한 값을 가짐
- 하나의 픽셀은 독립적인 정보가 아니라, 주변 픽셀들과 함께 의미 있는 패턴(질감, 경계 등)을 형성

2. 공간적 반복성 (Spatial Pattern Repetition)



다양한 이미지에서 반복되는 기본 패턴들



3. 계층적 구조 (Compositional / Hierarchical Structure)

저수준 특징 (Low-level features)

엣지, 코너, 색상 변화 등 단순한 시각 패턴



중간 수준 특징 (Mid-level features)

저수준 특징이 조합된 부분 구조 (예: 눈, 코, 입, 바퀴, 창문 등)



고수준 특징 (High-level features)

여러 부분 구조가 조합되어 형성된 의미 있는 객체



■ 왜 CNN이 필요한가?

2) 기존 MLP의 한계

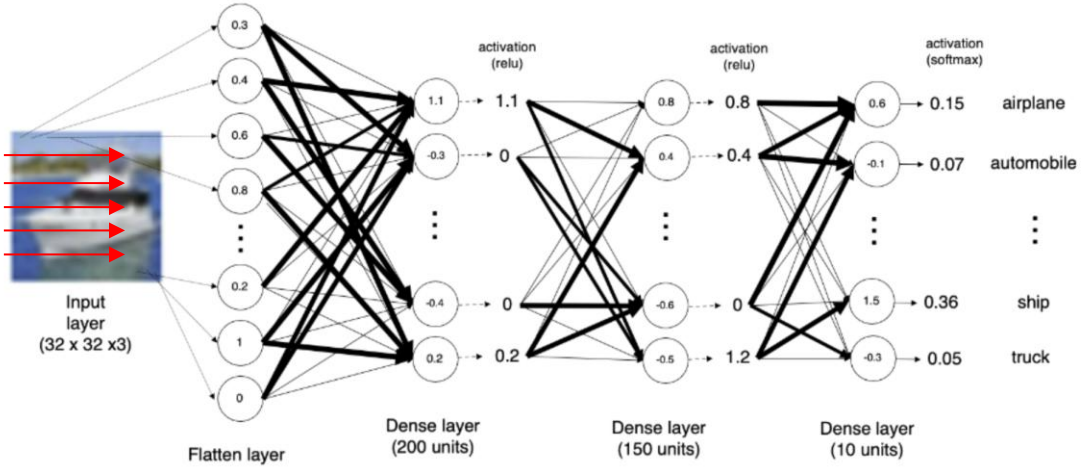
- **파라미터 폭발** : 입력 이미지의 크기에 따라 파라미터의 수가 폭발적으로 증가함

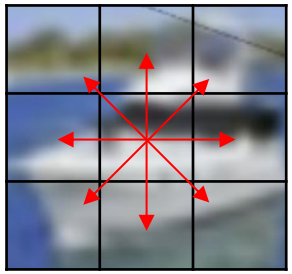
  ex) 224x224x3의 이미지를 100개 뉴런을 가진 MLP에 넣으면 150,528x100 → **15,052,800 (약 천만)**

  ▶ 파라미터의 폭발적 증가는 일반화 성능 하락 (데이터 요구량 증가), 메모리 낭비

- **공간 구조 무**시 : MLP는 이미지를 1열로 Flatten 시키므로 픽셀의 위치 정보 활용 불가

  ▶ 모든 픽셀을 독립적으로 취급, **픽셀의 이웃성 및 위치 구조 무시**

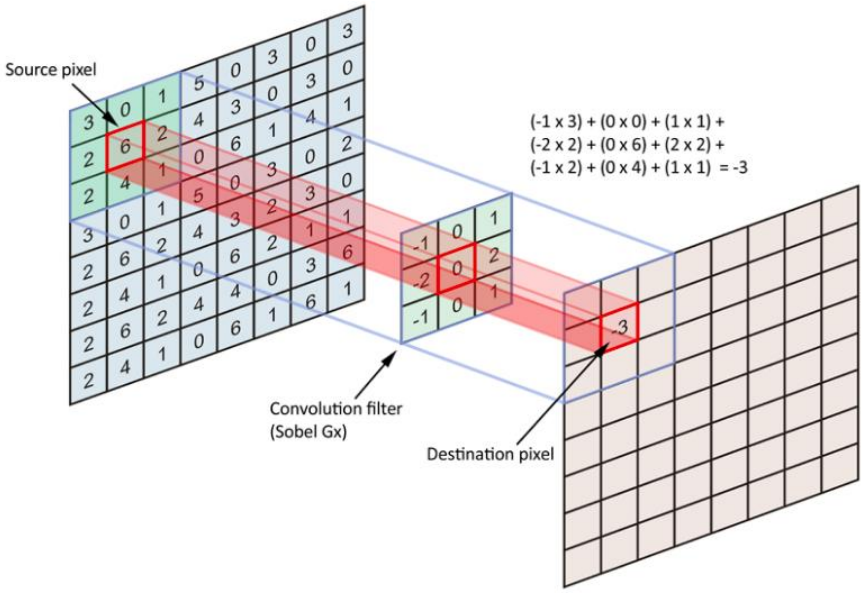


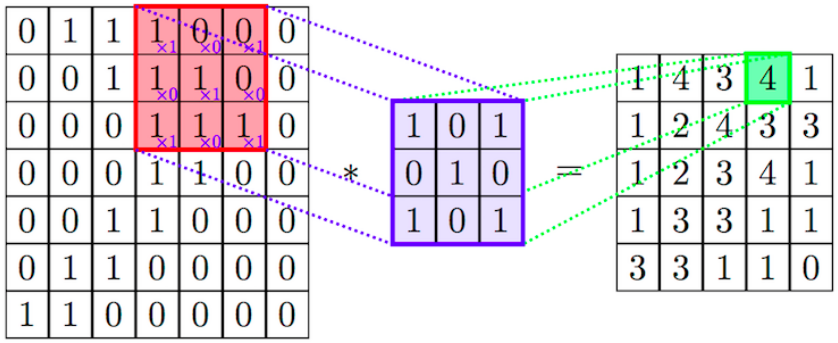


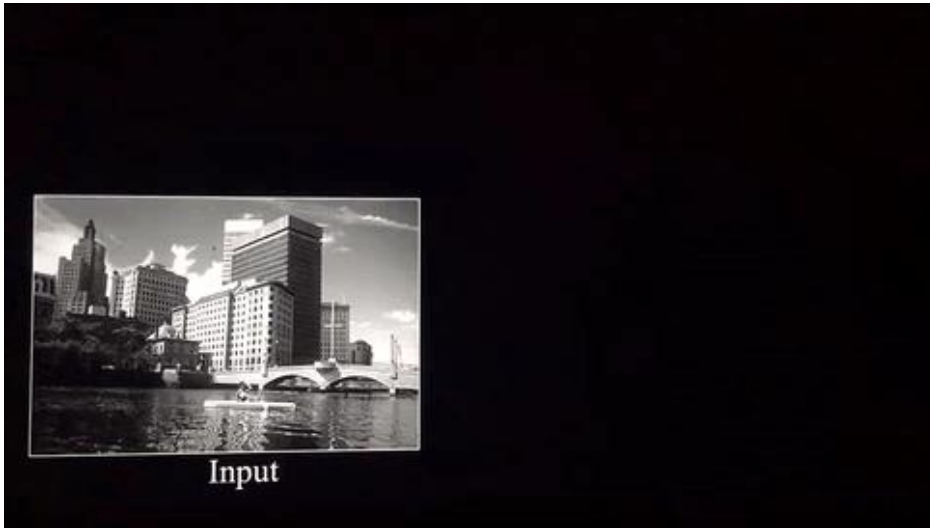
■ 컴퓨터 비전, 필터와 커널

- 과거 Computer Vision 에서는 이미지로부터 특징을 추출하기 위해 다양한 필터를 사용

컨볼루션 (Convolution) 연산

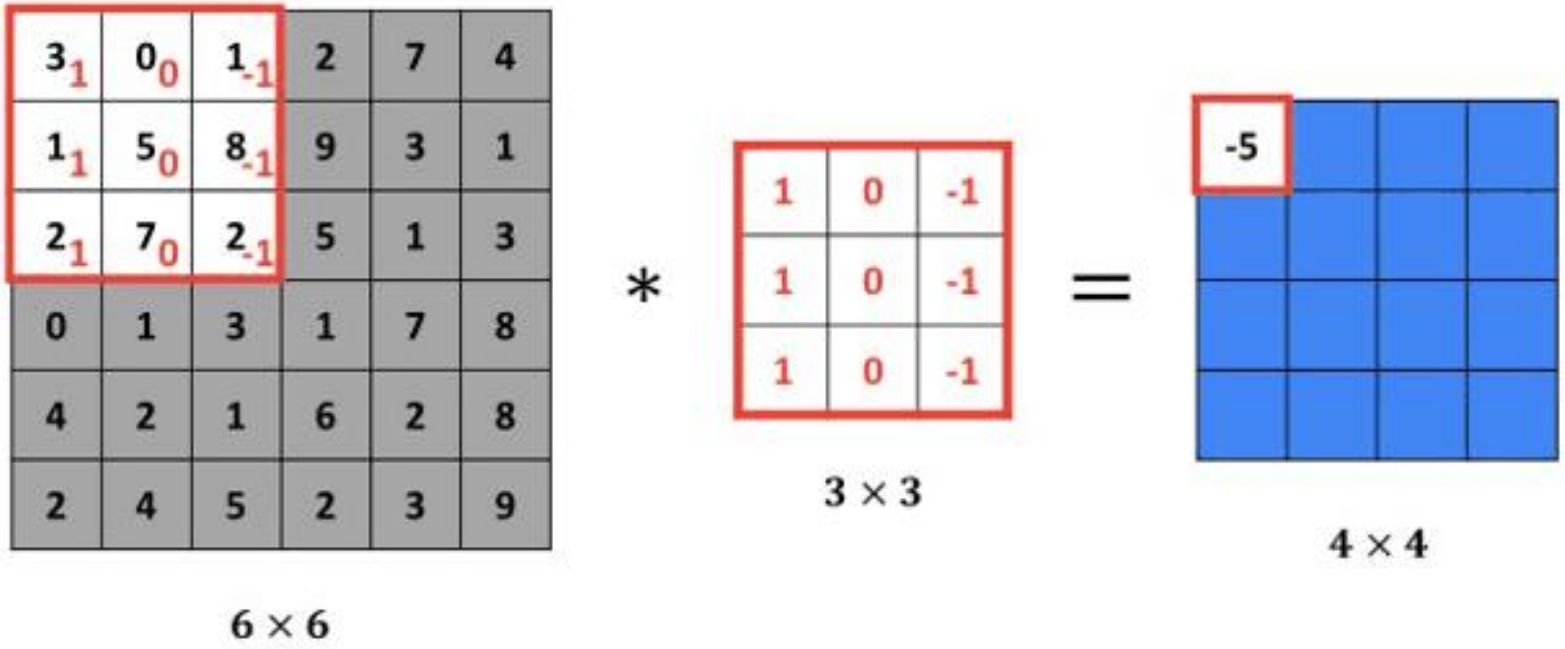






■ 컴퓨터 비전, 필터와 커널

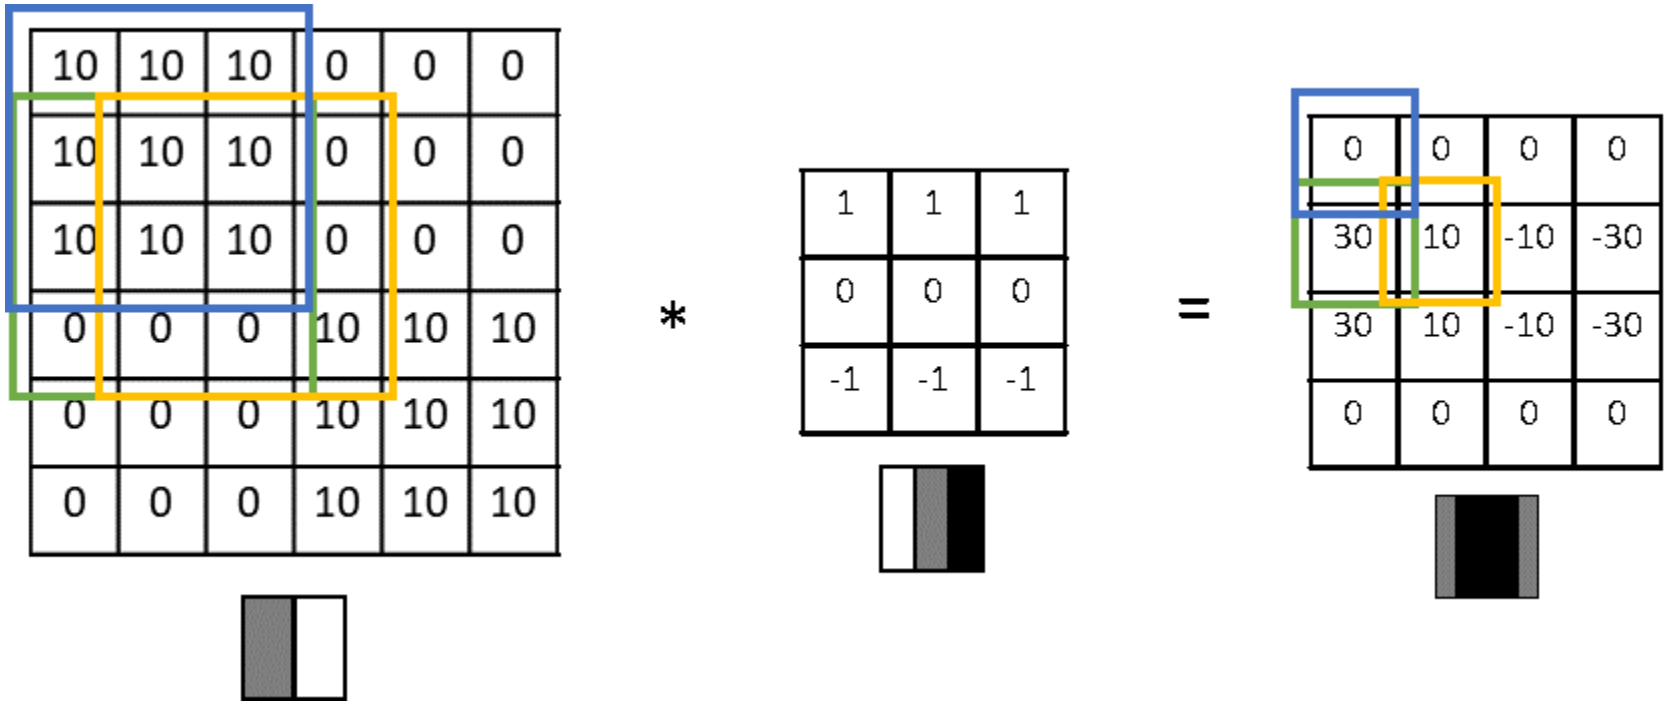
Vertical Edge Filter, Convolution Example



$$3\times1+1\times1+2\times1+0\times0+5\times0+7\times0+1\times-1+8\times-1+2\times-1=-5$$

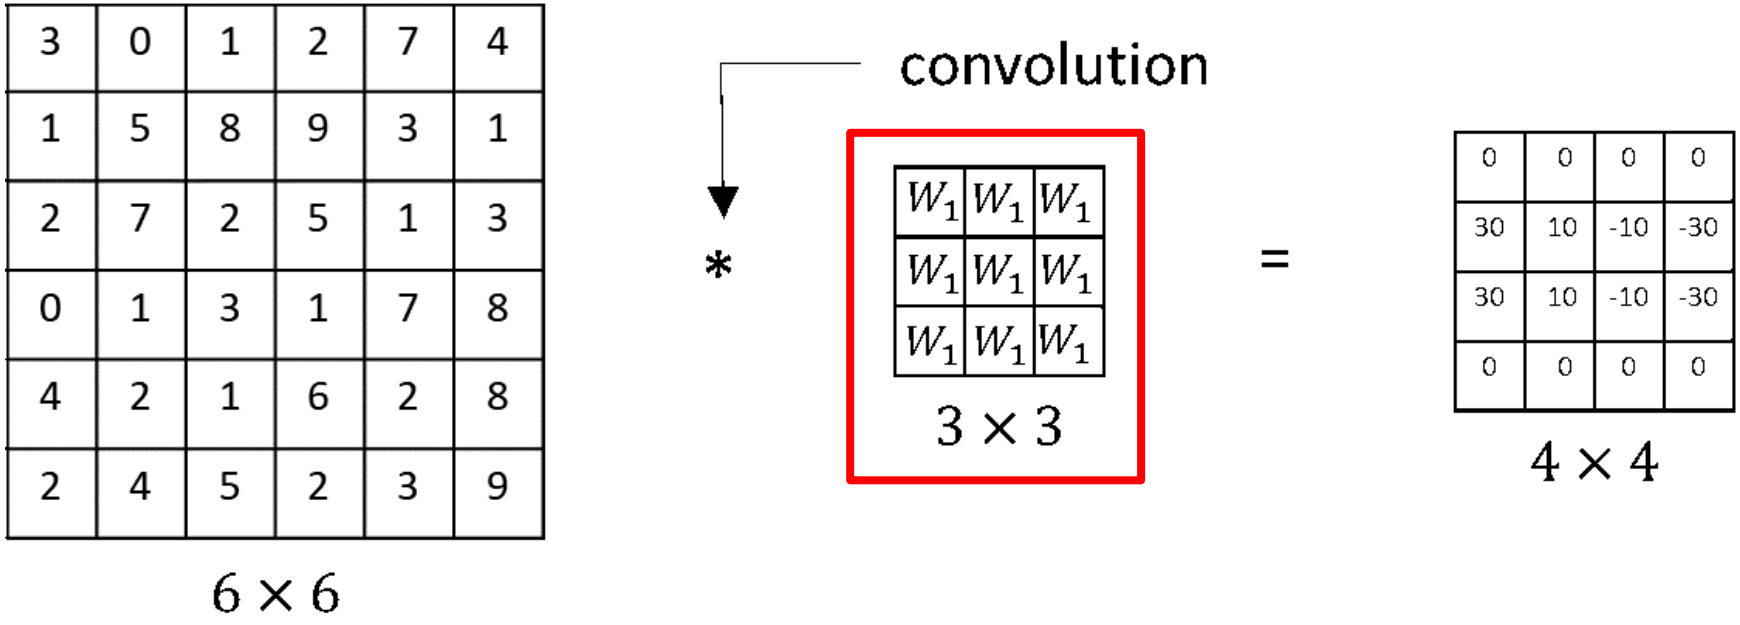
■ 컴퓨터 비전, 필터와 커널

Vertical Edge Filter, Convolution Example

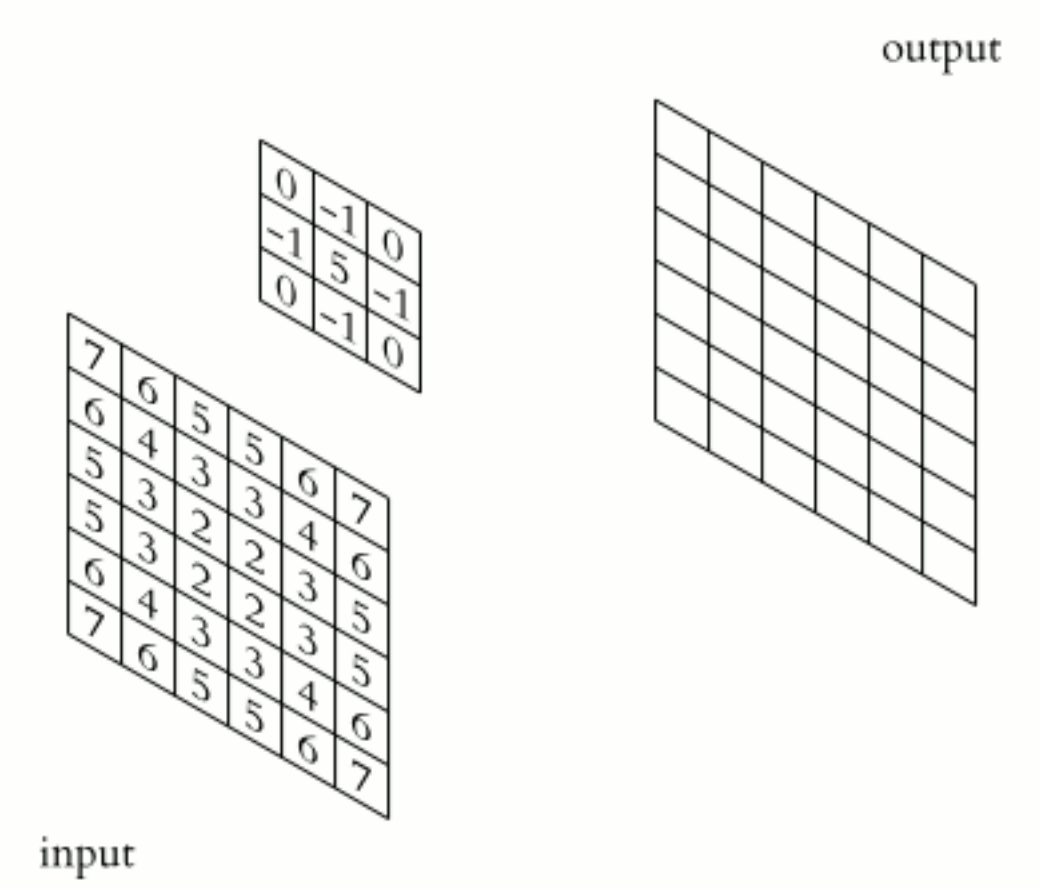


■ CNN에서의 필터

- CNN에서의 필터는 사람이 정의한 필터가 아니라, 데이터로부터 학습하는 필터임



Convolution



■ CNN의 핵심 아이디어 : Convolution 과 Pooling

1) **국소적 연결 (Local Connectivity)** : 국소적으로 인접한 픽셀만 고려함
   → MLP처럼 전체 데이터에 대해 연결하는 것이 아닌, 패치 단위 연결

2) **가중치 공유 (Weight Sharing)** : 같은 필터를 이미지 전영역에 재사용
   → 공간적 반복성 고려 (같은 모양의 엣지는 이미지 어디서나 같은 방식으로 탐지됨)
   → 파라미터 수가 이미지 크기에 무관
   → 이미지의 이웃성, 위치 정보 유지 → 이동 등가성(Equivariance) 확보

3) **계층적 표현 (Hierarchical Features)**
   → 레이어를 계층적으로 쌓음으로써 단순한 지역 패턴의 합성으로 복잡한 전역 구조 설명 가능

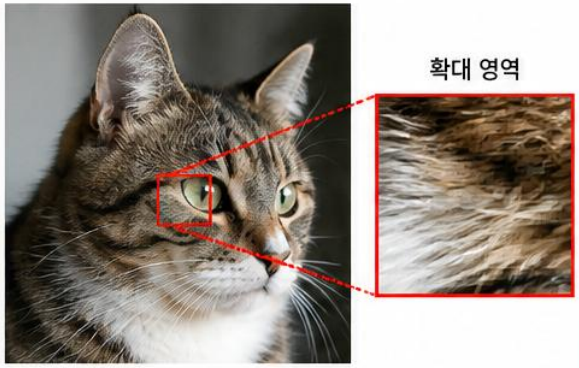
General CNN Structure

INDUSTRIAL AI RESEARCH CENTER

■ CNN의 핵심 아이디어 : Convolution 과 Pooling

1. 지역 상관성 (Local Correlation)

인접한 픽셀들은 서로 독립적이지 않고,
공간적으로 연관된 값을 갖는 경향이 있습니다.



픽셀 값 예시 (확대 영역의 일부)

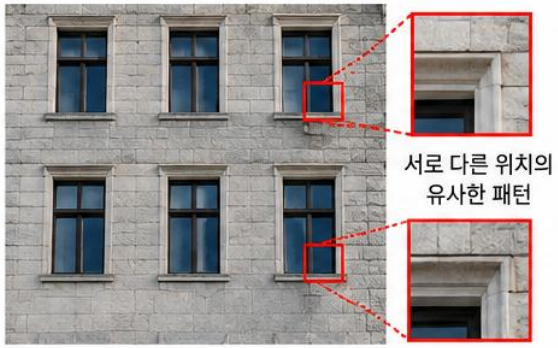
120	118	115	117	119
122	121	119	120	118
125	123	120	119	116
126	124	122	120	117
125	123	121	118	115

- 인접 픽셀 값이 서로 비슷한 값을 가짐
- 하나의 픽셀은 독립적인 정보가 아니라, 주변 픽셀들과 함께 의미 있는 패턴(질감, 경계 등)을 형성

➡ CNN은 작은 필터(국소 수용영역)를 이용하여 주변 픽셀들의 관계를 학습합니다.

2. 공간적 반복성 (Spatial Pattern Repetition)

엣지, 코너, 질감과 같은 기본적인 시각 패턴은
이미지의 여러 위치에서 반복적으로 나타납니다.



다양한 이미지에서 반복되는 기본 패턴들



➡ CNN은 가중치 공유(Weight Sharing)를 통해 동일한 필터로 이미지의 모든 위치에서 이러한 패턴을 효율적으로 검출합니다.

3. 계층적 구조 (Compositional / Hierarchical Structure)

이미지는 단순한 패턴(엣지, 코너 등)이 조합되어
점점 더 복잡하고 의미 있는 구조를 형성합니다.

저수준 특징 (Low-level features)
엣지, 코너, 색상 변화 등 단순한 시각 패턴



중간 수준 특징 (Mid-level features)
저수준 특징이 조합된 부분 구조 (예: 눈, 코, 입, 바퀴, 창문 등)



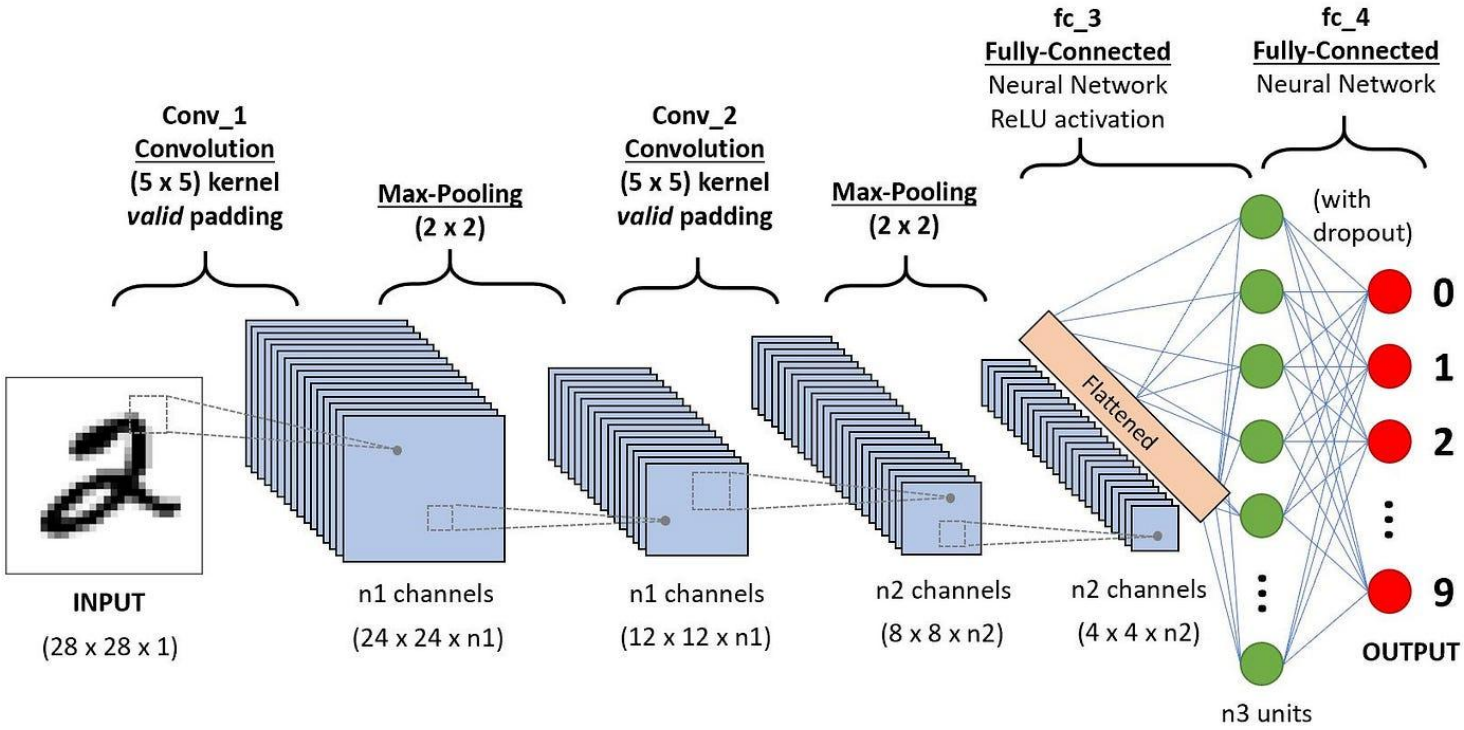
고수준 특징 (High-level features)
여러 부분 구조가 조합되어 형성된 의미 있는 객체



➡ CNN은 여러 층을 거치며 단순한 패턴에서 복잡한 구조로 계층적으로 특징을 학습합니다.

■ Convolutional Neural Network 란?

- CNN (Convolutional Neural Network) 는 이미지 처리에 특화된 신경망
- 이미지와 같은 2차원 데이터를 입력으로, 최적의 특징을 추출하여 특정 작업 수행



- CNN은 주로 Convolutional Layer, Pooling Layer, 그리고 Fully-connected Layer 로 구성됨
  ※ 참고: 최근 CNN 모델의 Fully-Connected Layer 는 Global Average Pooling Layer 로 대체되는 추세임

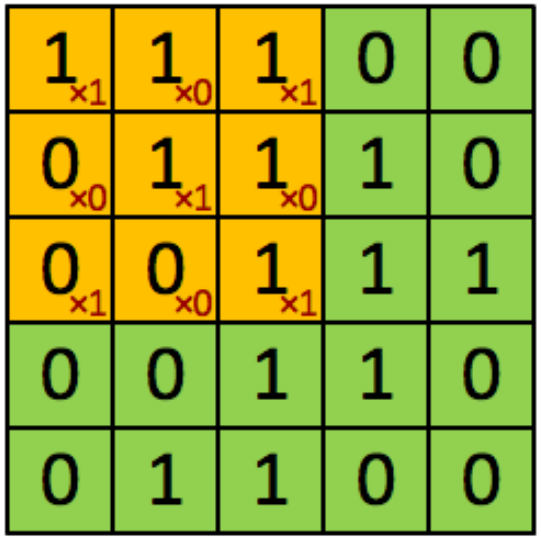
Convolution Layer

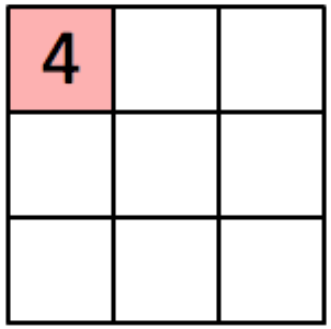
- Convolutional Layer
  - 이미지로부터 특징을 추출하는 CNN 모델의 핵심 층
  - 필터(커널)을 사용하여 입력 데이터로부터 특징 맵(feature map) 생성

- 우측 예시에서 필터(커널)

1	0	1
0	1	0
1	0	1

- 필터는 학습을 통해 결정됨





Convolution Layer - hyperparameter

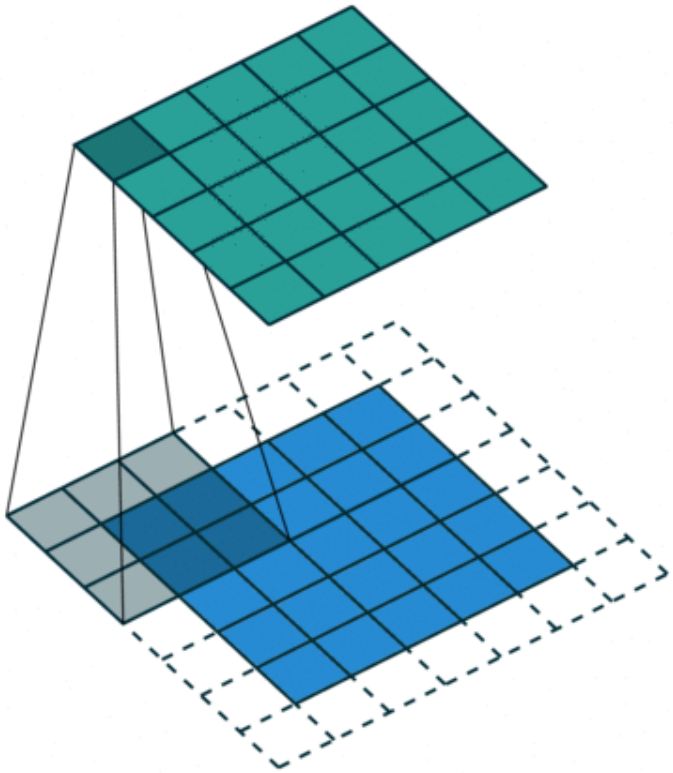
- **Zero padding** : convolution 연산 전, 입력의 가장자리를 0으로 채우는 것
  - padding이 적용되지 않은 Convolution의 연산은 출력 특징 맵의 크기가 작아짐

    ex) 5x5 입력, 3x3 커널의 경우 : 출력: 3x3

    → 레이어를 쌓을수록 데이터의 크기가 작아짐

    ※ 계산: O=(I-F)+1 = (5-3)+1 = 3

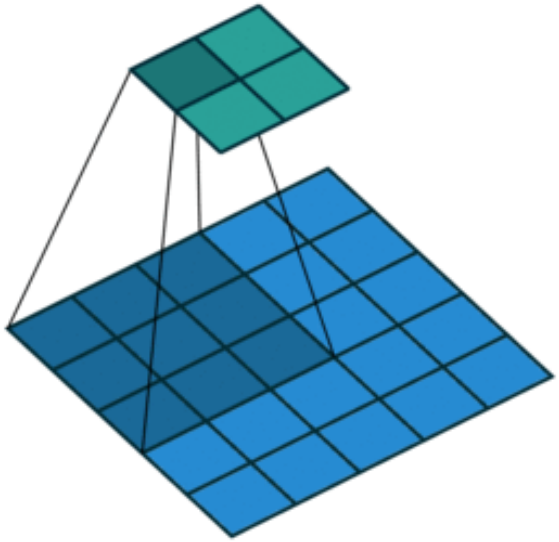
  - "valid" : padding 없이 convolution 연산
  - "same" : padding 추가해서 input과 output이 동일하도록 convolution 연산



Convolution Layer - hyperparameter

- **Stride :** convolution 연산 시 Stride S 만큼 건너뛰면서 슬라이딩
  - 종종 CNN 구조 설계 시 출력 사이즈를 줄이고자 하는 경우가 있음 (연산량 감소, 파라미터 감소 등)
  - 또한, Stride는 수용 영역 (Receptive Field)를 크게 만들어주는 효과가 있음

  ※ Receptive Field: 레이어의 특정 특징이 볼 수 있거나 영향을 받는 입력 이미지의 특정 영역



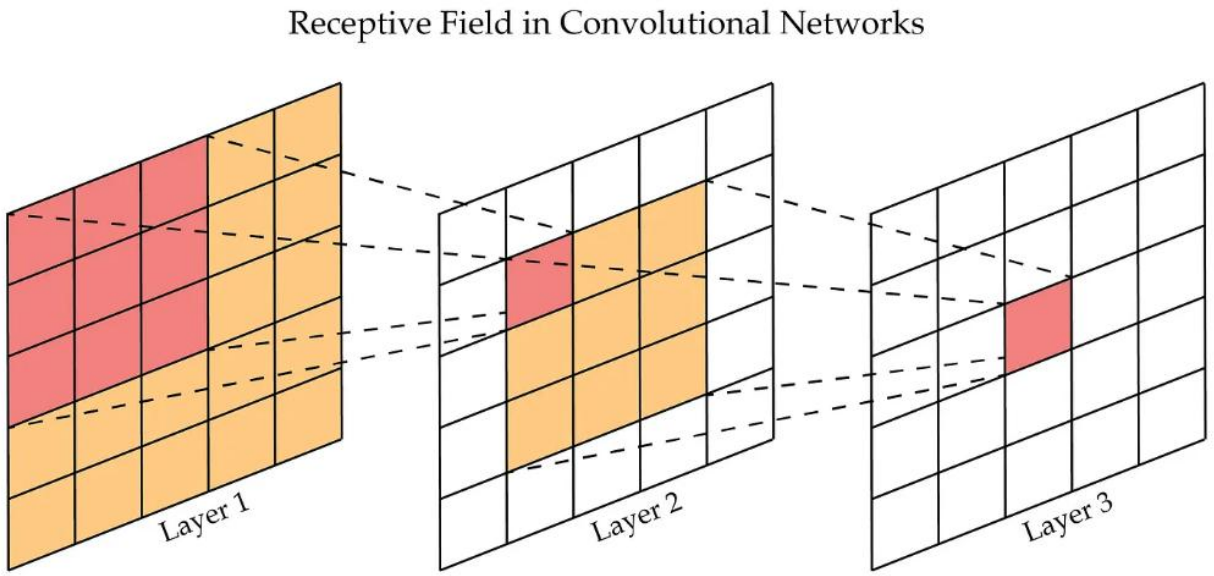
- Stride 적용 시 출력 특징 맵 계산 식

  $O = (I-F+2P)/S+1 = (5-3+0)/2+1 = 2$

■ Note! 수용 영역 (Receptive Field)

- **수용 영역 (Receptive Field) :** CNN 출력 레이어의 뉴런 하나에 미치는 입력 뉴런들의 공간 크기, 각 뉴런이 보고 처리하는 입력 이미지의 영역

  → 큰 Receptive Field는 입력 이미지의 넓은 영역을 고려하므로 전역적 정보 및 관련 특징을 인식하는데 도움이 됨

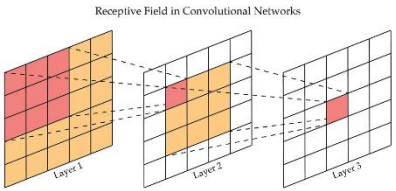


■ Note! 수용 영역 (Receptive Field)

➢ 수용 영역 (Receptive Field)의 계산

$$R_l = R_{l-1} + (K_l - 1)S_{l-1}$$

- R_l: l번째 Layer의 수용 영역
- K_l: l번째 Layer의 Kernel Size
- S_{l-1}: $l-1$번째 Layer의 Stride Size



[Stride 1]

Layer 2:

$1 + (3-1) * 1 = 3$

Layer 3:

$3 + (3-1) * 1 = 5$

[Stride 2]

Layer 2:

$1 + (3-1) * 1 = 3$

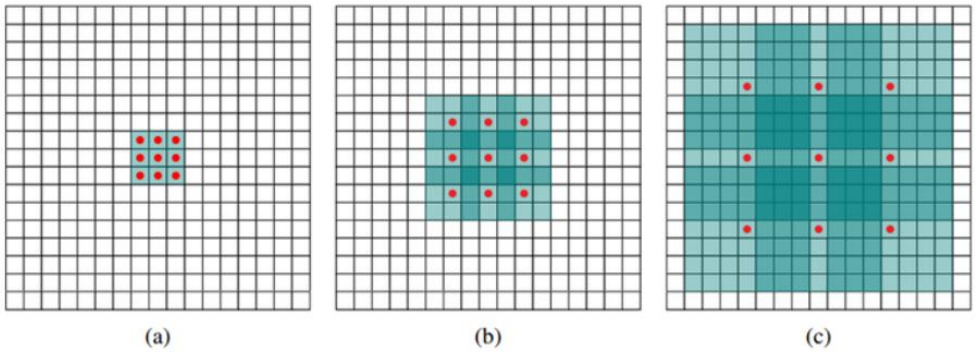
Layer 3:

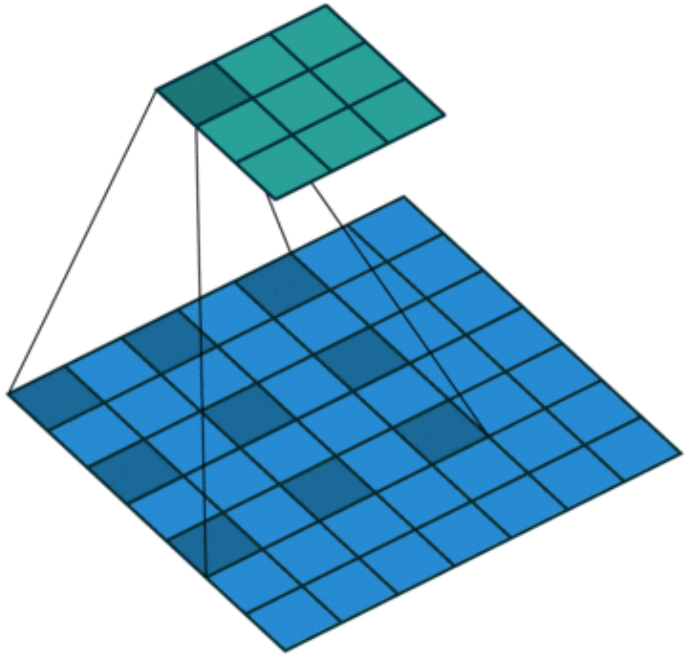
$3 + (3-1) * 2 = 7$

Convolution Layer - hyperparameter

- **dilation :** 커널 사이의 간격을 d만큼 조정
  - CNN의 수용 영역을 효과적으로 키우는 방법 중 하나

$$R_l = R_{l-1} + (K_l - 1)d_l S_{l-1}$$





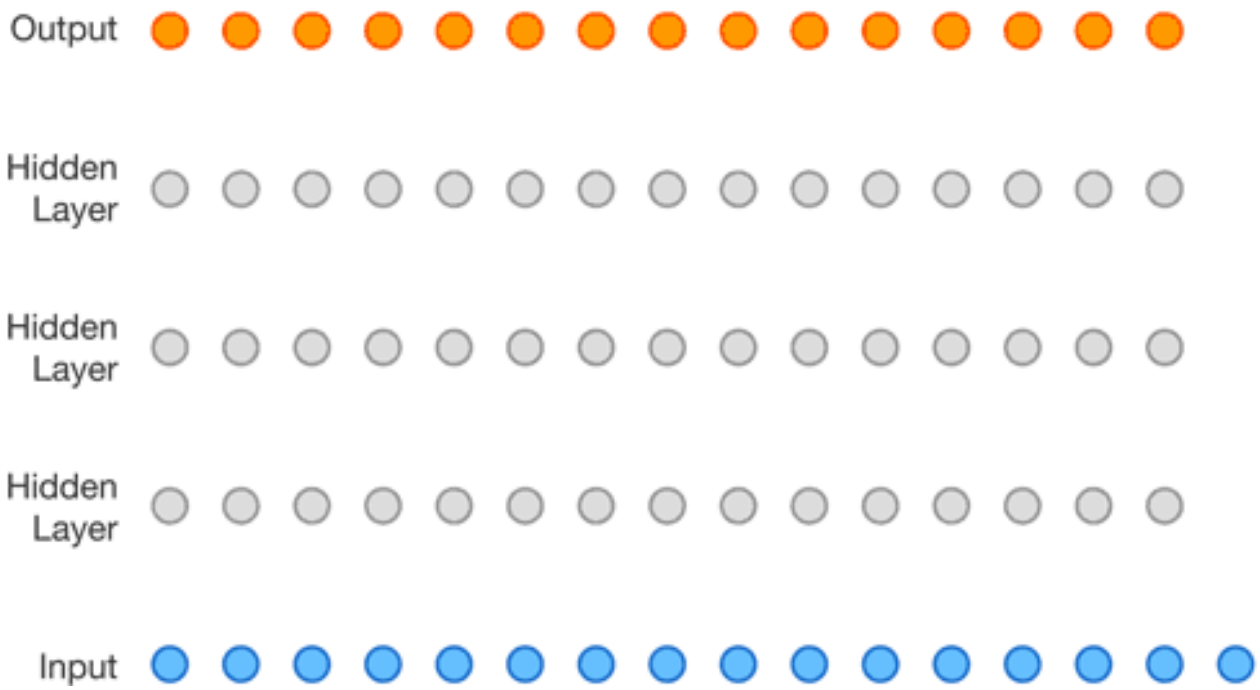
Layer 1 (d=1): $1 + (3 - 1) = 3$

Layer 2 (d=2): $3 + (3 - 1) * 2 * 1 = 7$

Layer 2 (d=4): $7 + (3 - 1) * 4 * 1 = 15$

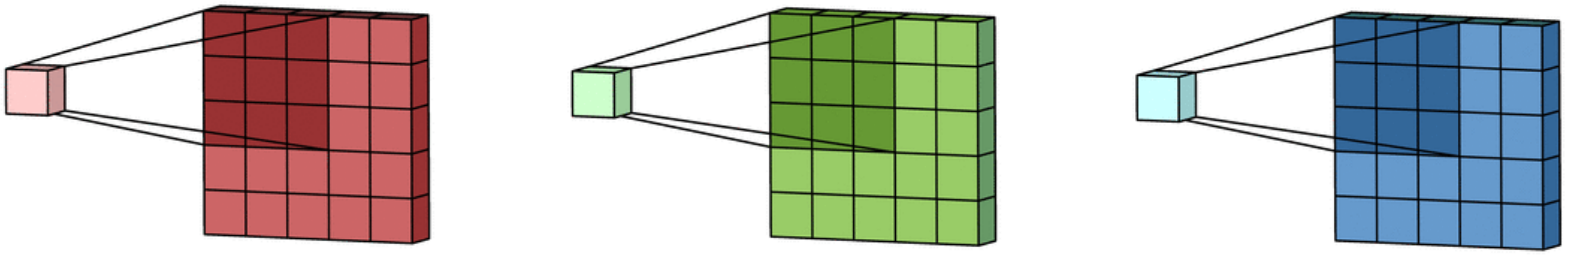
■ Note! Dilation 으로 수용영역을 극대화한 예시

➢ WaveNet은 층마다 2배씩 증가하는 dilation이 적용된 Causal Dilated Convolution을 통해 Convolution을 활용해서 시계열 데이터를 처리함



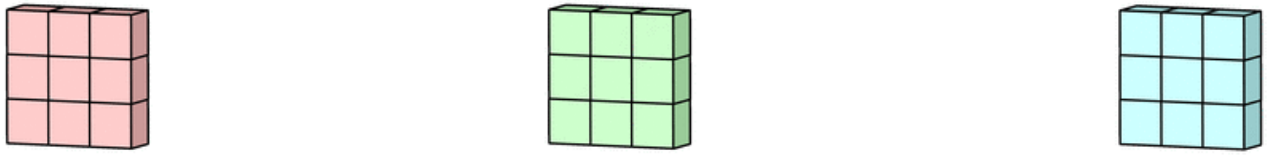
Convolution – Multi Channel version

- 입력 채널이 3이고 필터 개수가 1개인 경우
  - 각 입력 채널 별로 커널이 존재
    - → **각 입력 채널에 따라 서로 다른 가중치로 특징을 추출**



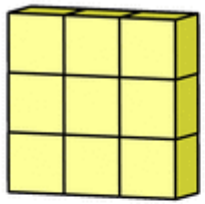
Convolution – Multi Channel version

- 입력 채널이 3이고 필터 개수가 1개인 경우
  - 각 입력 채널 별로 커널이 존재
    - → **채널별로 처리된 각 데이터들은 하나의 채널을 형성**



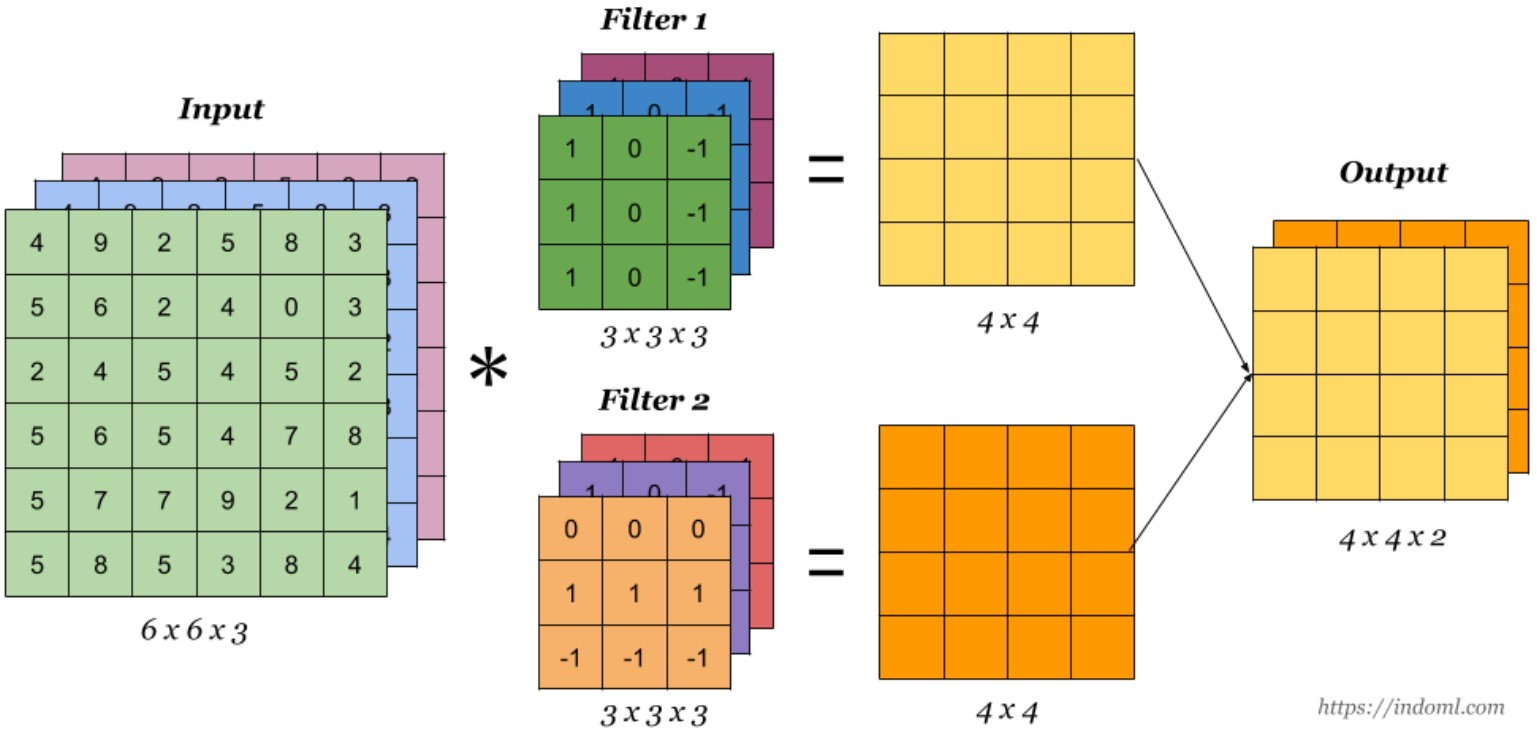
Convolution – Multi Channel version

- 입력 채널이 3이고 필터 개수가 1개인 경우
  - 각 입력 채널 별로 커널이 존재
    - → **합쳐진 채널에 Bias 항을 더하여 최종 특징 맵 출력**



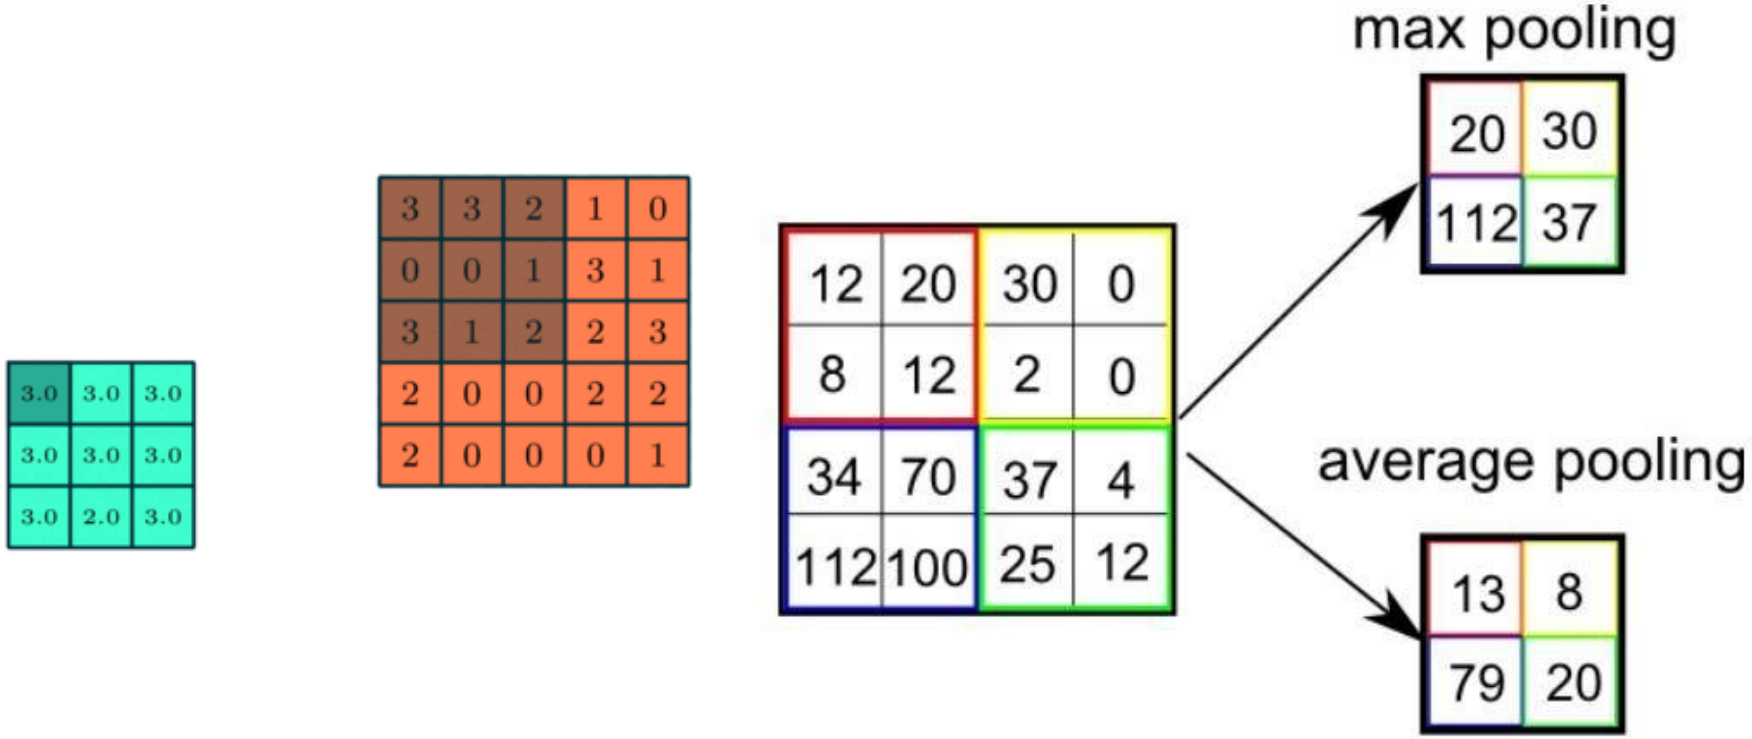
Convolution – Multi Channel version

- 입력 채널이 2개 이상인 경우 하나의 필터는 채널의 개수 만큼의 커널 집합으로 구성됨
  → 입력: HxWxC, 필터: KxKxD의 경우 출력 채널 : D



Pooling Layer

- Pooling Layer
  - 공간의 크기를 줄여 계산 량을 줄이고 과적합을 방지
  - 최대 풀링(max pooling), 평균 풀링(average pooling) 등을 주로 사용



[그림출처: https://medium.com/towards-data-science/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53]

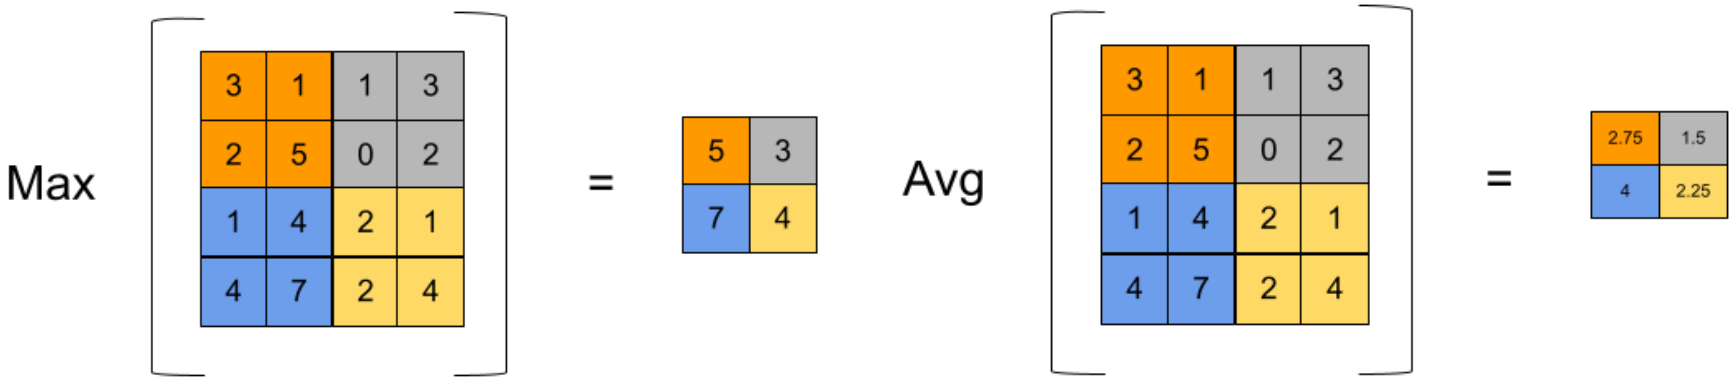
Pooling Layer

- 최대 풀링 (Max Pooling)

  - 커널 공간에서 가장 큰 값만 추출하여 최종 출력으로 결정 → 입력의 큰 값을 강조

- 평균 풀링 (Average Pooling)

  - 커널 공간 내 값을 평균 내어 최종 출력으로 결정



[그림출처: https://wikidocs.net/164835]

■ CNN이 효과적인 이유

1) 적은 파라미터

- MNIST 데이터셋 예시 (28x28=784)
  → MLP(은닉 100)의 경우 : **784x100=78,400개 파라미터**
  → CNN(5x5커널 크기, 6개 필터) : **5x5x1x6=150개 파라미터**

▶ 시작부터 500배 이상의 파라미터 수 차이, CNN은 적은 데이터로 학습 가능

2) 데이터 효율 + 일반화

- CNN은 이미지에 내제된 가정(Inductive Bias)을 반영함 → 복잡도 감소 → 일반화 향상

3) 연산 구조 이점

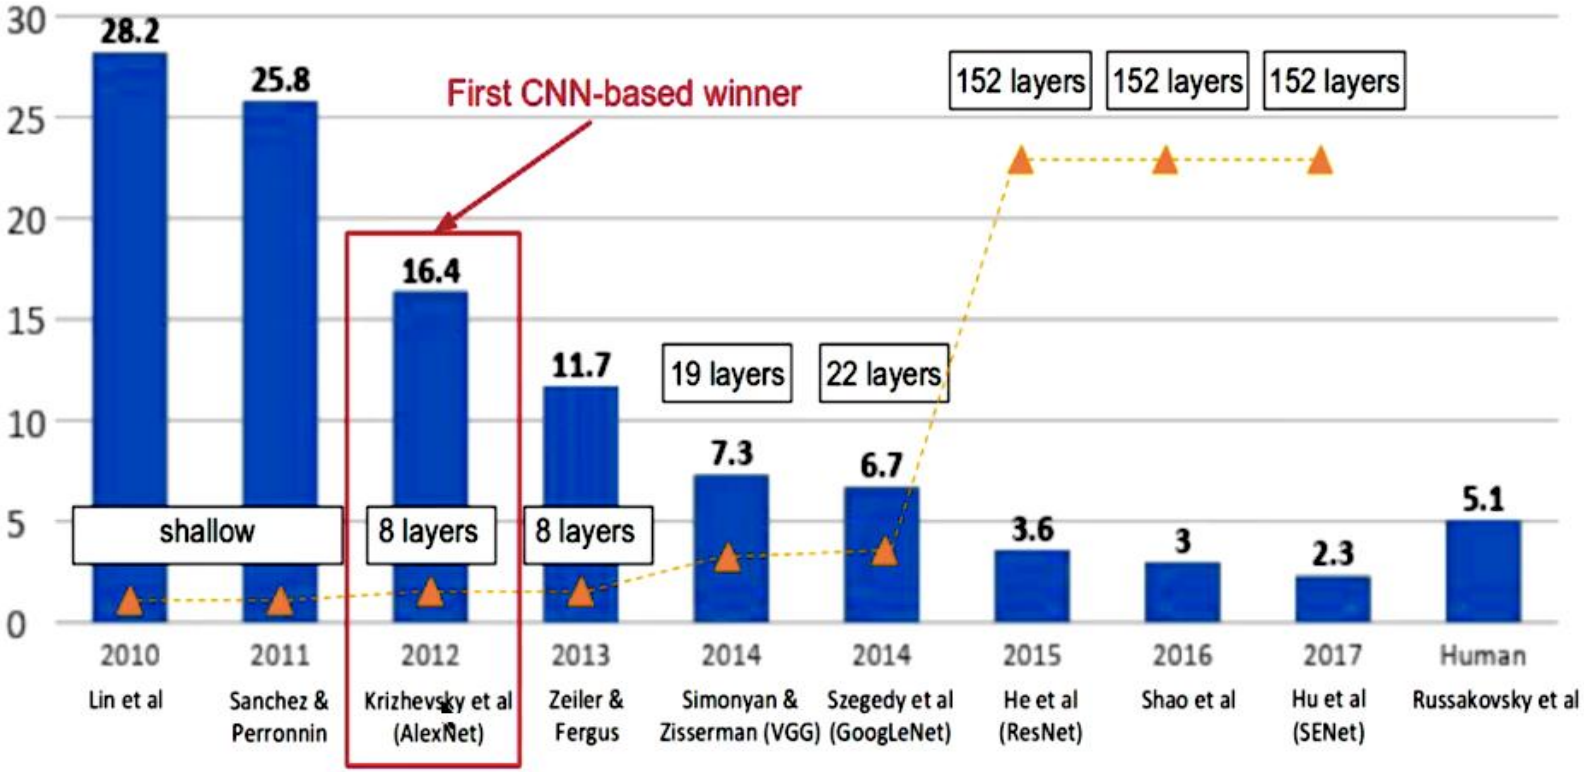
- Convolution과 Pooling은 병렬화 가능 (GPU 친화적)

INDUSTRIAL AI RESEARCH CENTER

■ CNN 모델의 발전

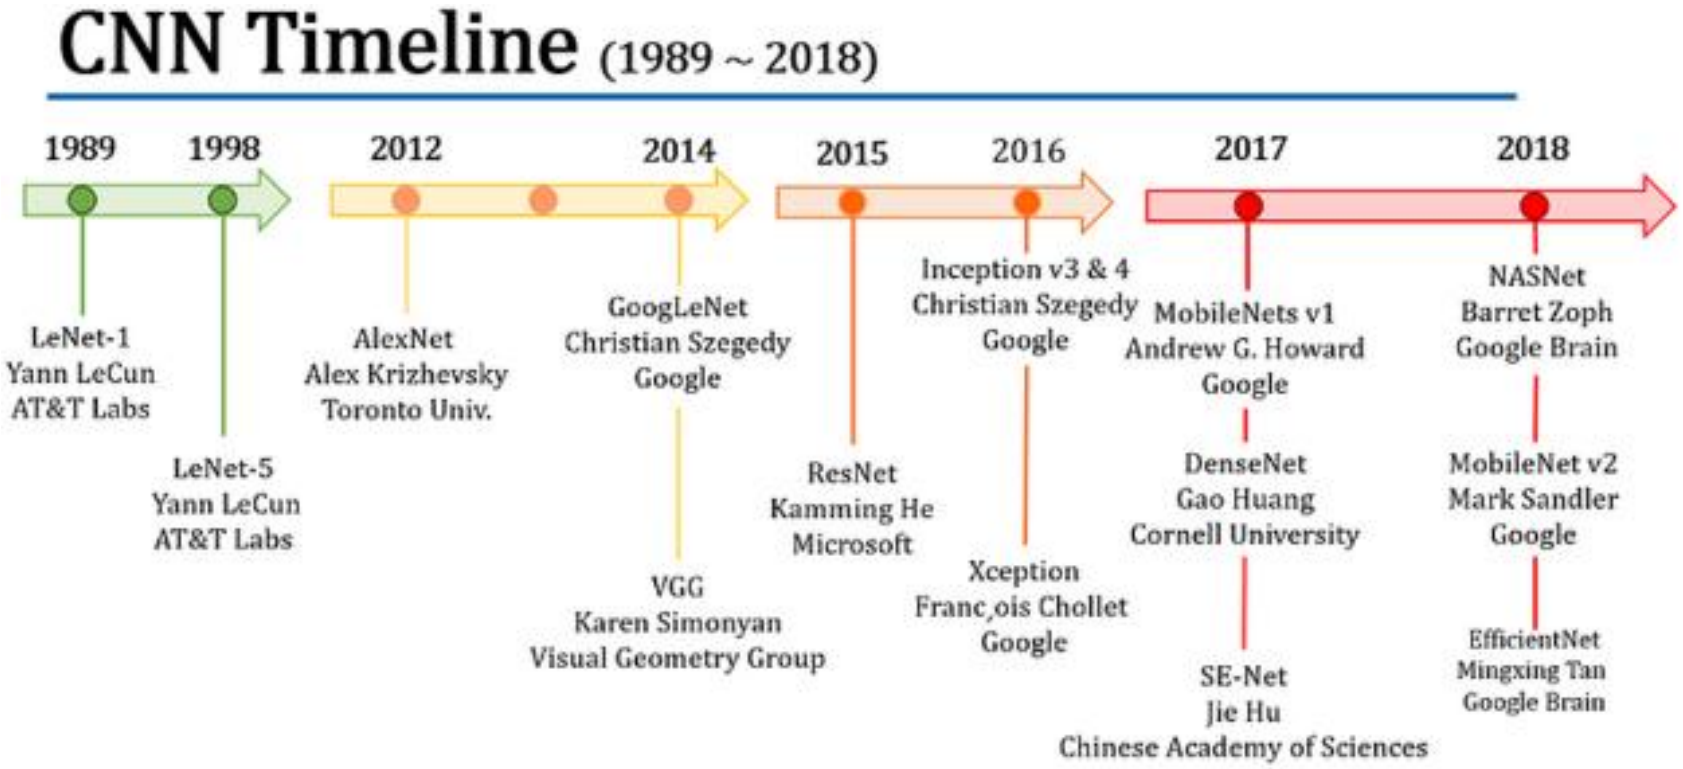
➢ CNN은 2012년 ILSVRC 대회에서 첫 우승한 이래로, 영상 처리 분야에서 주류 모델로 자리잡음

※ ILSVRC (ImageNet Large Scale Visual Recognition Challenge): ImageNet이 주관하여 개최한 세계적인 대규모 이미지 인식 대회



■ CNN 모델의 발전

➢ CNN 아키텍처는 1989년 LeNet-1을 시작으로 다양한 문제(연산량 최소화, 기울기 소실, 과적합 방지 등)를 해소하며 발전하고 있음



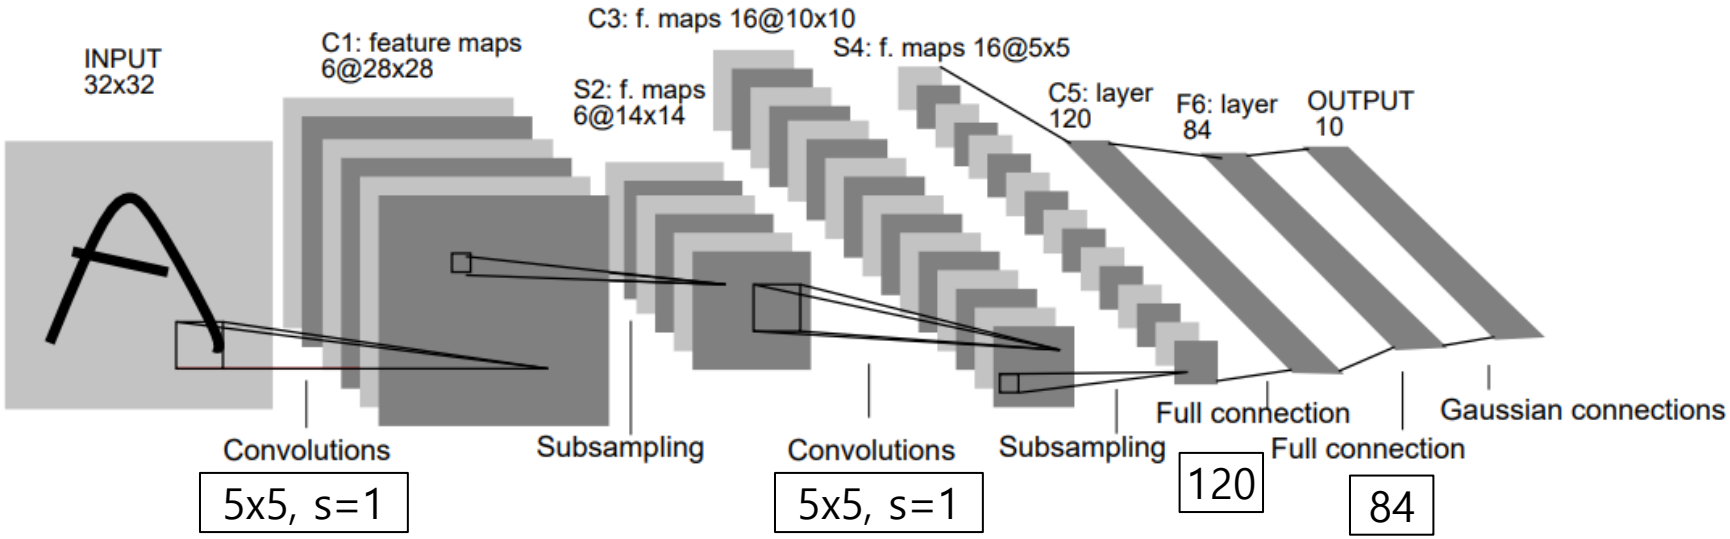
LeNet-5

- 60K Parameters (6만 이상)
- 초기 CNN의 구조

  → 레이어가 출력에 가까워질수록 특징 맵 크기는 작아지고, 개수는 늘어남

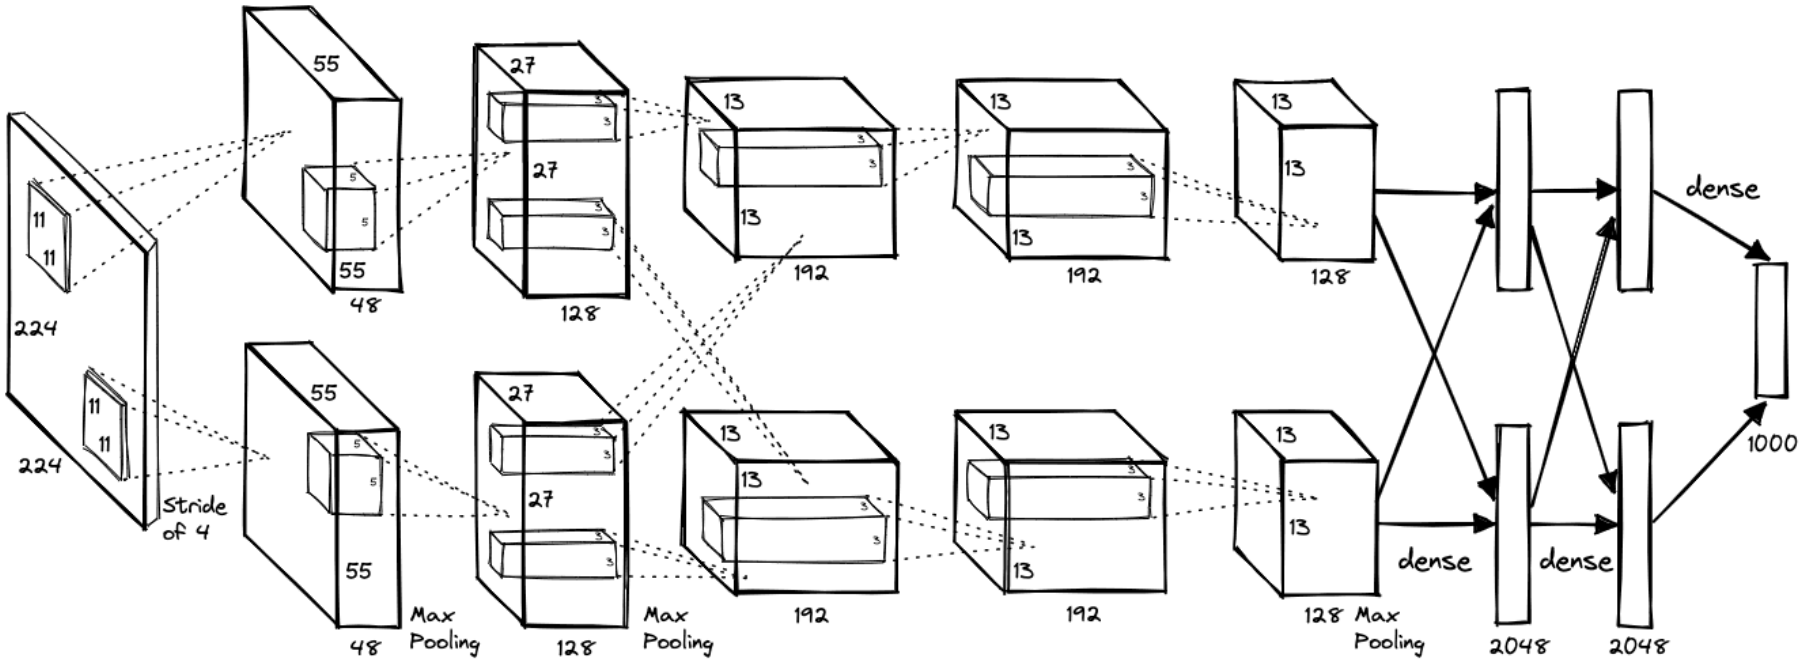
  → Convolution과 Pooling을 교차해서 구조를 만듬

  ▶ 공간(해상도)는 줄이고 특징은 늘려서 정보를 더 압축/추상화하고 표현력은 확대



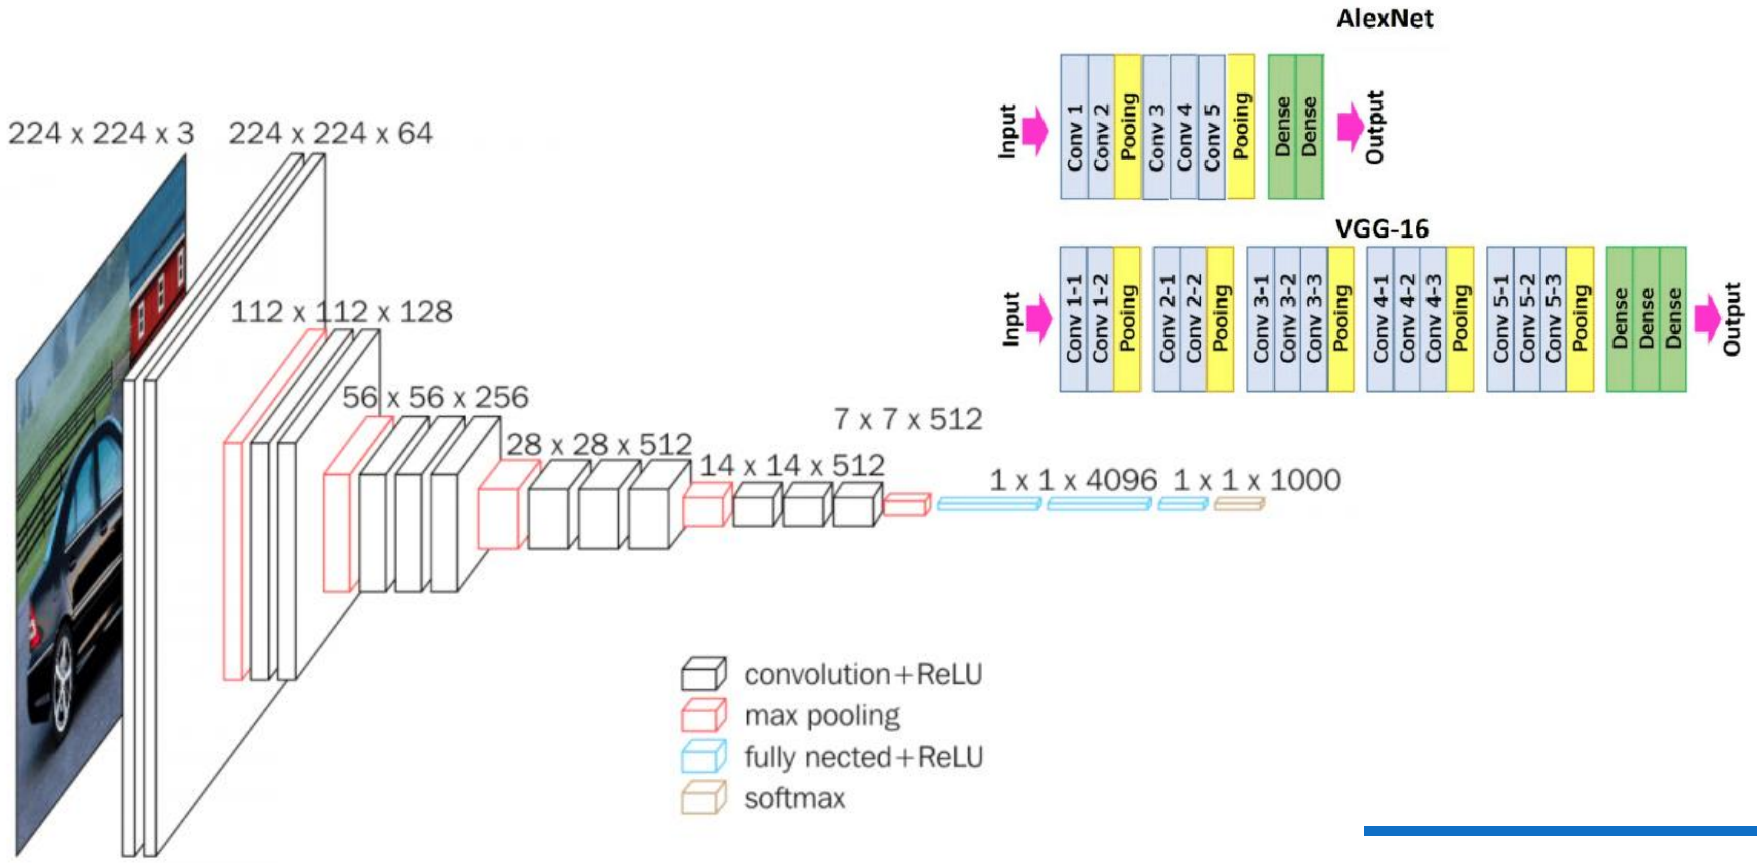
AlexNet

- 60M Parameters (6천만 이상)
- 입력 이미지 크기: 224x224
- 파라미터 간소화를 위해 초반 레이어에서 Stride=4를 통해 특징 맵을 4배 줄임



VGGNet

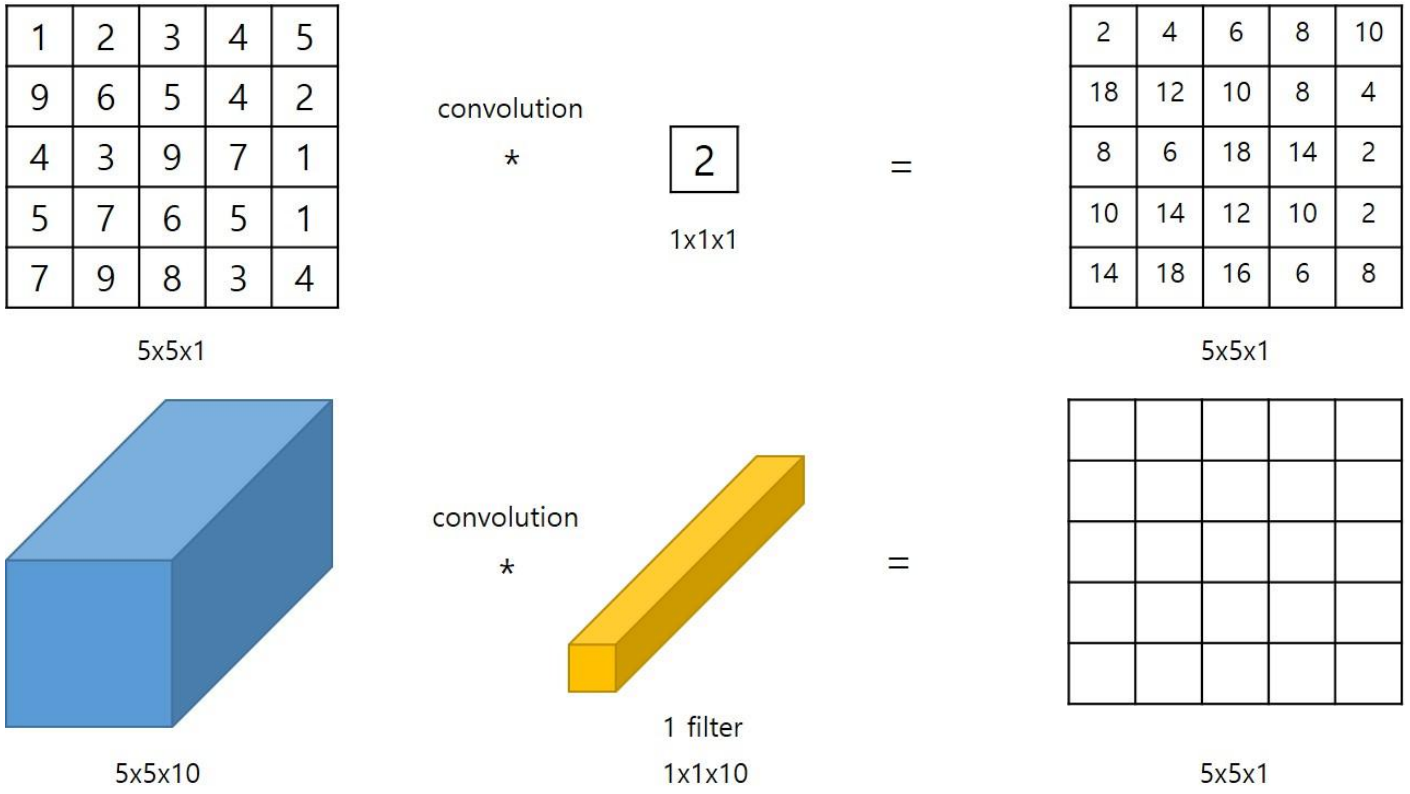
- 138M Parameters (1억개 이상)
- CONV=3x3 filter, s=1, same padding MAXPOOL=2x2, s=2



Inception Network (GoogleNet)

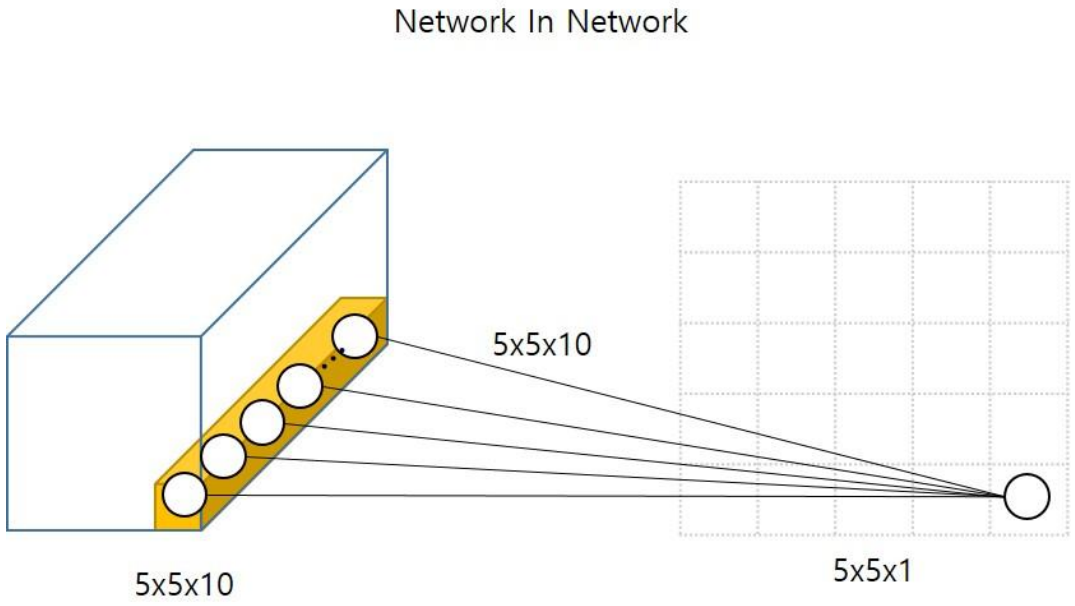
- 1x1 Convolution : 커널 size가 1x1인 Convolution

  → 채널의 크기를 자유롭게 변경할 수 있음 (확장 및 축소 모두 가능) → 표현력 증가



Inception Network (GoogleNet)

- Network in Network (NiN)
  - → 각 공간마다 작은 MLP를 얹어 복잡한 비선형 변환을 하자
  - → 적용 1: 채널 믹싱 강화 (서로 다른 특징을 채널 축으로 섞어 의미 있는 특징 구성)
  - → 적용 2: 연산 효율, 비싼 kxk conv는 얕게, 1x1 conv는 깊이 확보

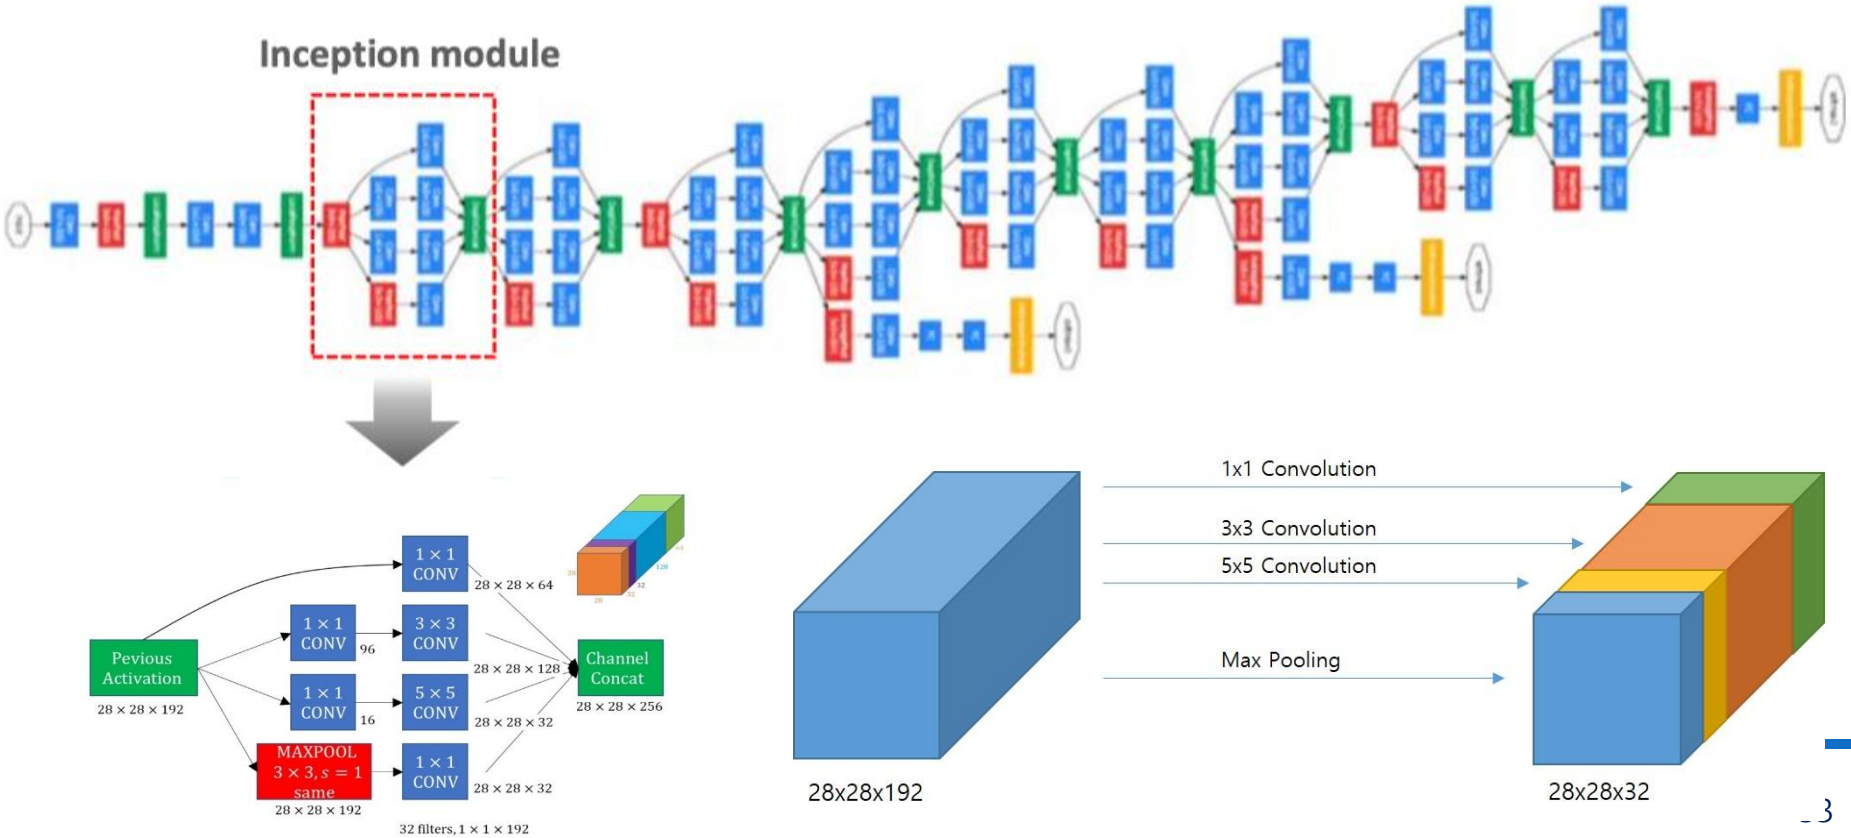


Inception Network (GoogleNet)

- Inception Network (2014)

  → 서로 다른 스케일의 특징을 동시에 추출 (1x1, 3x3, 5x5) // 1x1 Conv 도입으로 가능

  → Global Average Pooling 적용 (FC 대체) → 파라미터 최소화

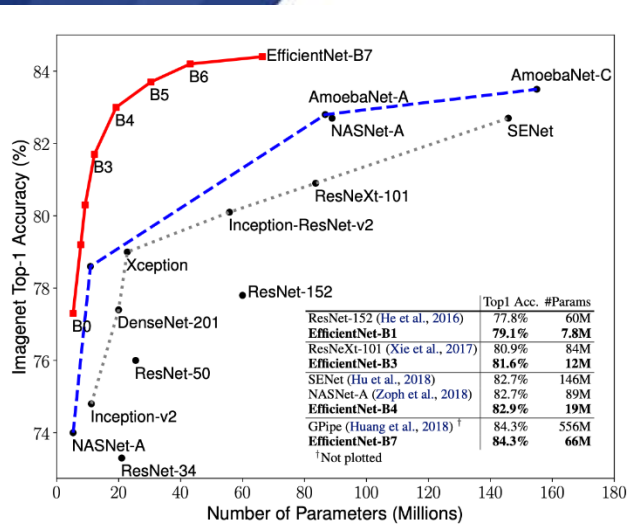


CNN Models : Case Study

ResNet (2015)

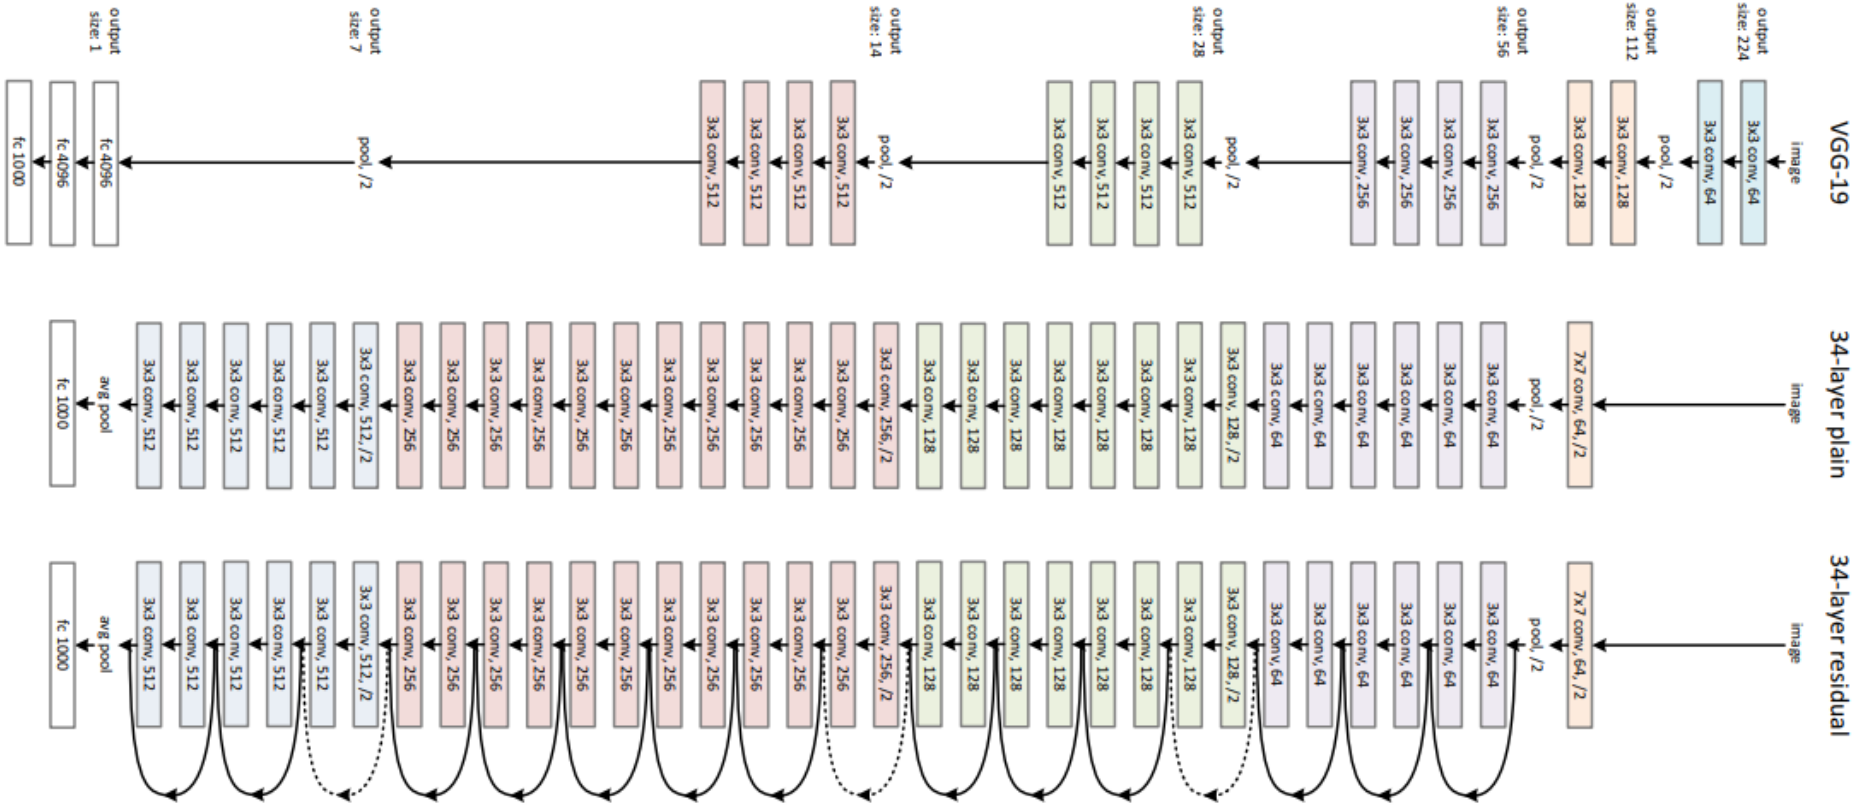
- 100개 층 이상의 깊은 Layer를 쌓기 시작
- Skip connection 적용된 Residual Block 이 주요 특징

  → Vanishing Gradient 완화



	Top1 Acc.	#Params
ResNet-152 (He et al., 2016)	77.8%	60M
EfficientNet-B1	**79.1%**	**7.8M**
ResNeXt-101 (Xie et al., 2017)	80.9%	84M
EfficientNet-B3	**81.6%**	**12M**
SENet (Hu et al., 2018)	82.7%	146M
NASNet-A (Zoph et al., 2018)	82.7%	89M
EfficientNet-B4	**82.9%**	**19M**
GPipe (Huang et al., 2018) †	84.3%	556M
EfficientNet-B7	**84.3%**	**66M**

†Not plotted



차후 수업에 관하여...

INDUSTRIAL AI RESEARCH CENTER

■ 차후 수업 진행 안내

주차	수업내용	수업방식
1	Lecture Introduction	대면수업
2	Introduction to Industrial AI	대면수업
3	Basic of Neural Network	대면수업
4	Learning Strategies: Supervised Learning	대면수업
5	Learning Strategies: Unsupervised Learning	대면수업
6	글로벌 제조 트렌드 특강	비대면수업
7	Model Architecture: Convolutional Neural Networks	대면수업
8	Model Architecture: Sequence Models	대면수업
9	Midterm exam	대면수업
10	Visual Anomaly Detection	대면수업
11	Temporal Anomaly Detection	대면수업
12	Predictive Maintenance with Time Series	대면수업
13	Final Project: Proposal	대면수업
14	Final Project: Discussion	대면수업
15	Final Project: Presentation	대면수업

감사합니다

Q&A