10주차 강의

Visual Anomaly Detection

Pattern Recognition Applications

김영진
you359@cbnu.ac.kr
충북대학교 산업인공지능연구센터

INDUSTRIAL AI RESEARCH CENTER

CONTENTS

I **Introduction to Visual Anomaly Detection**
Concepts & Applications

II **VAD Taxonomy**
Type of Supervision, Spatial Prediction Level, VAD Mechanism

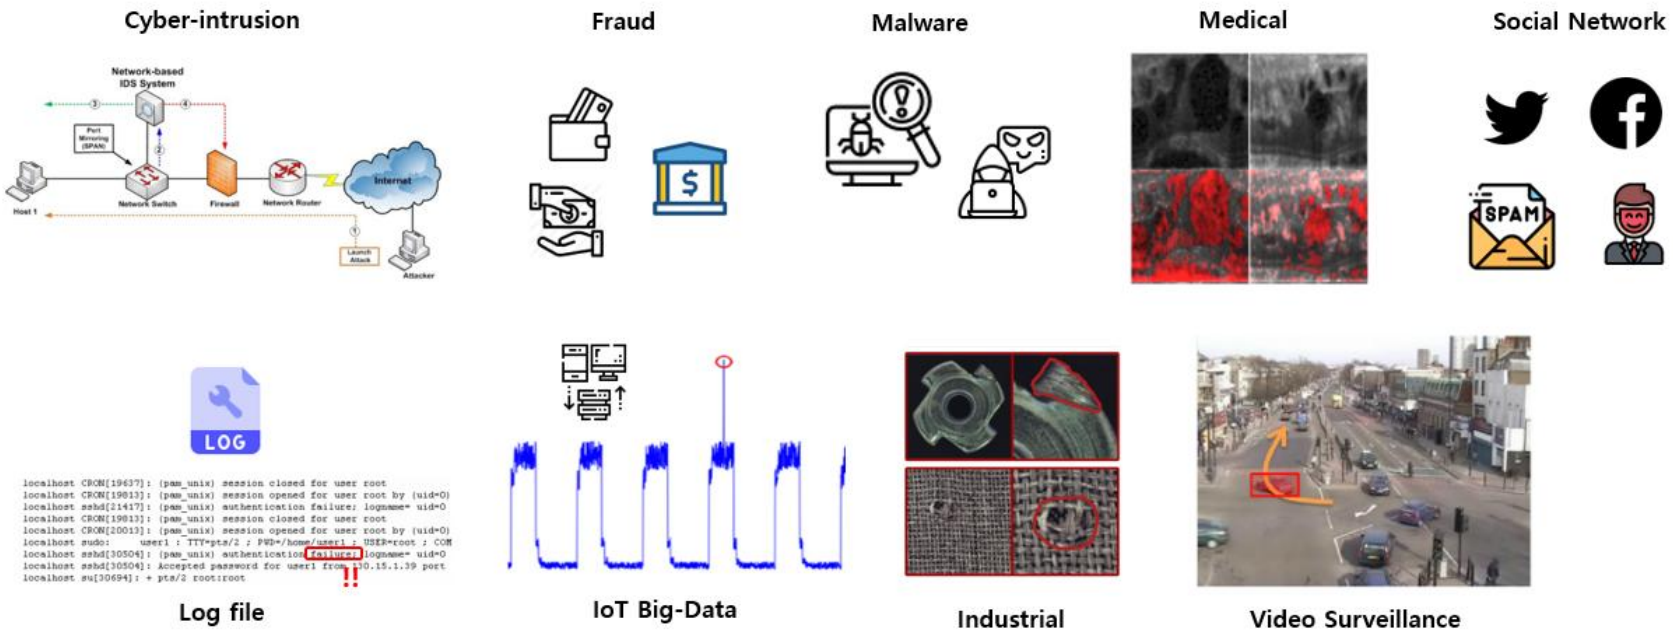
III **Case Study**
VAD Research Case Study

INDUSTRIAL AI RESEARCH CENTER

■ 이상 감지의 개념

이상 감지(Anomaly Detection)란 정상 데이터 분포에서 벗어난 패턴을 식별하는 문제

이상 감지(Anomaly Detection) 적용 사례

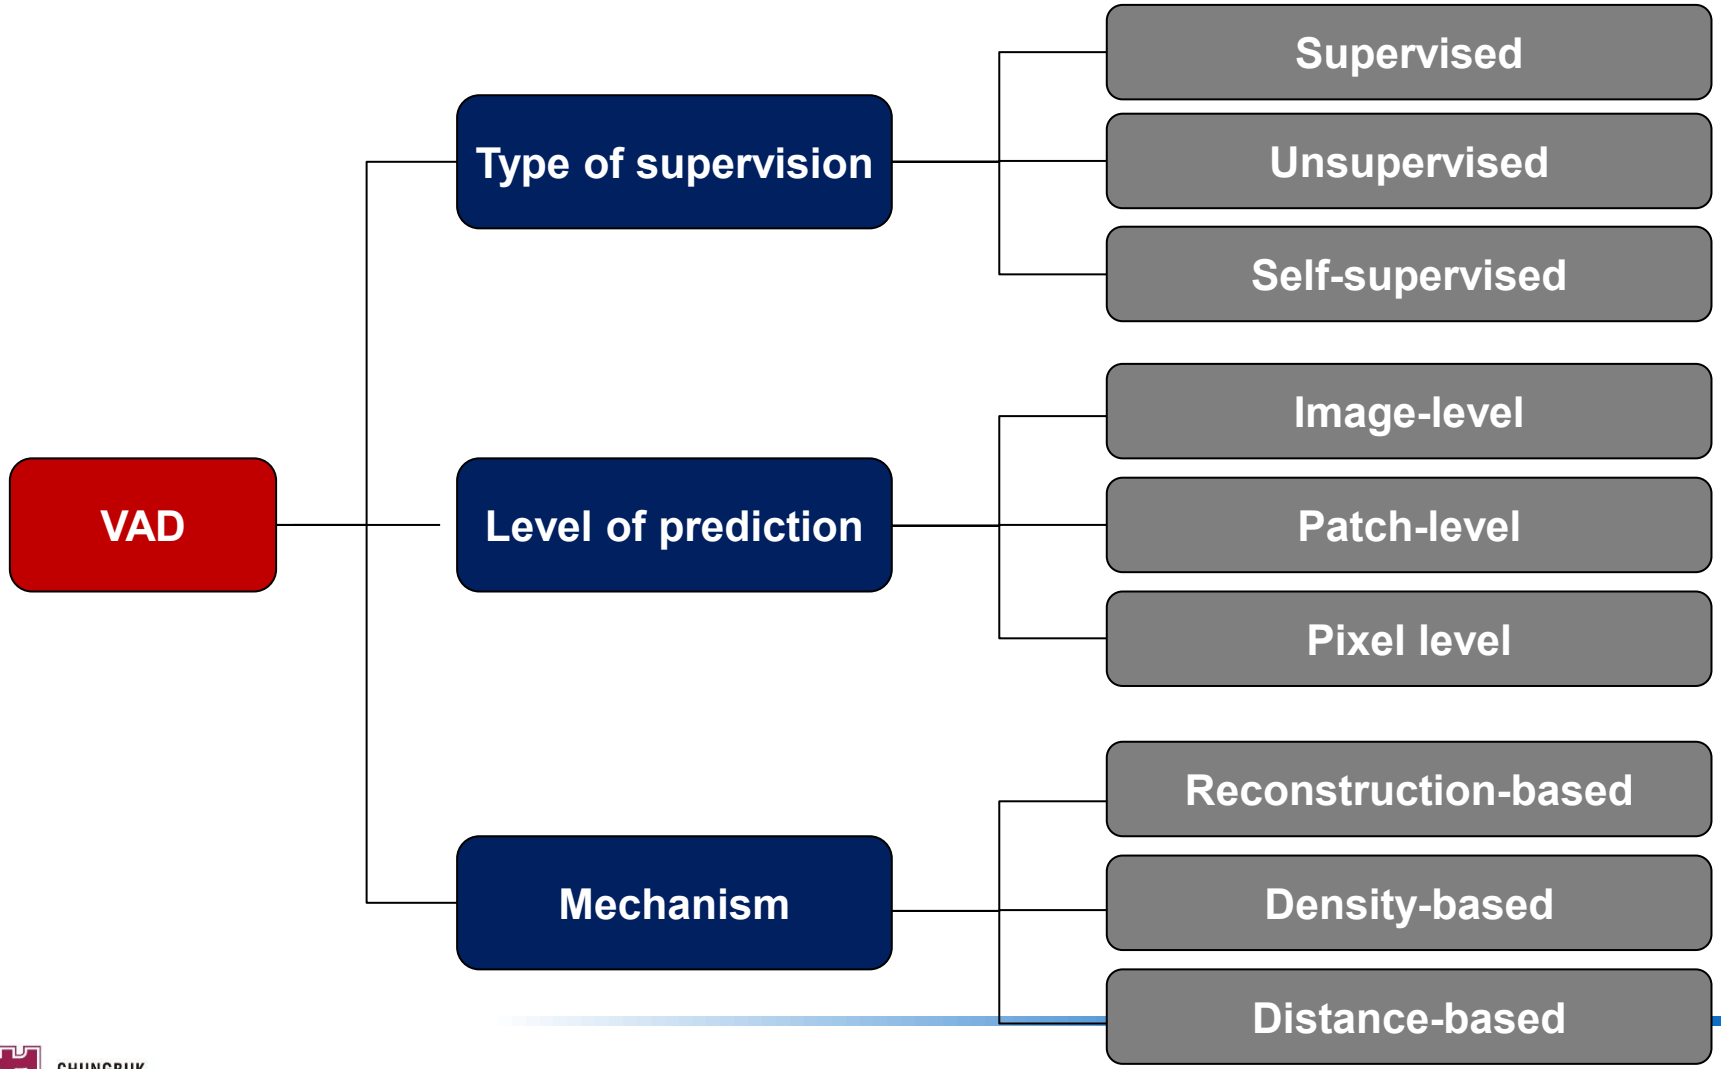


[이미지 출처: https://hoya012.github.io/blog/anomaly-detection-overview-1/]

VAD Taxonomy

INDUSTRIAL AI RESEARCH CENTER

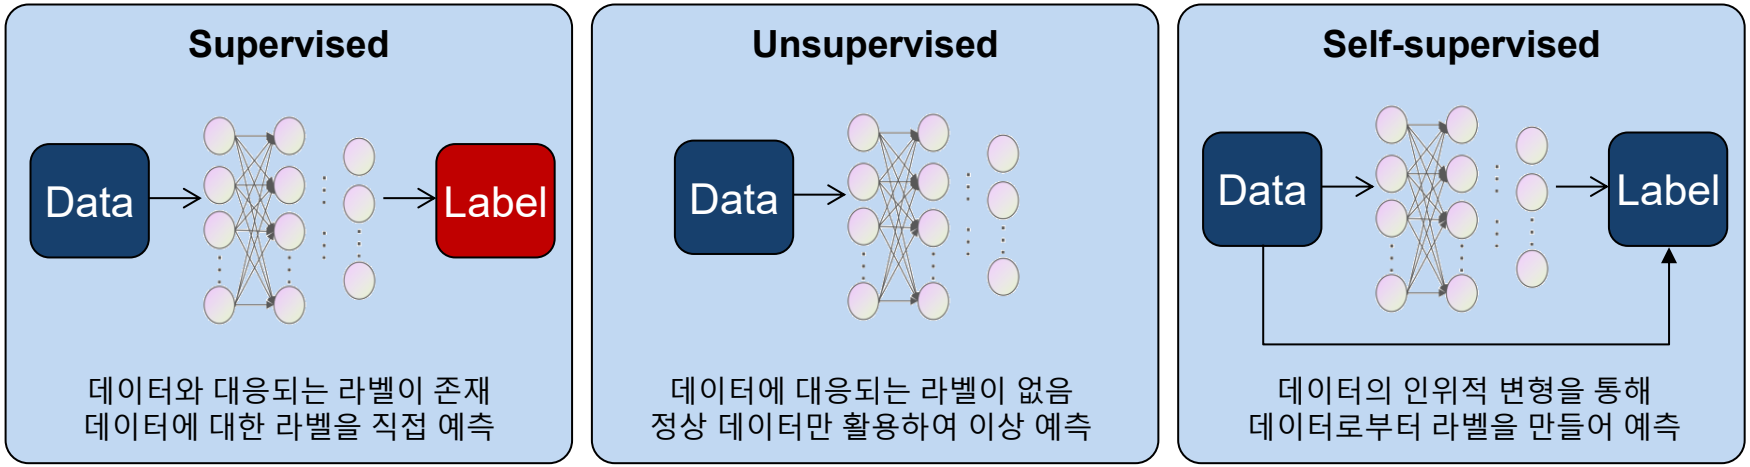
■ Visual Anomaly Detection 의 분류



■ Visual Anomaly Detection 의 분류

1) **Type of Supervision** : 라벨의 존재 여부 혹은 유형에 따른 분류

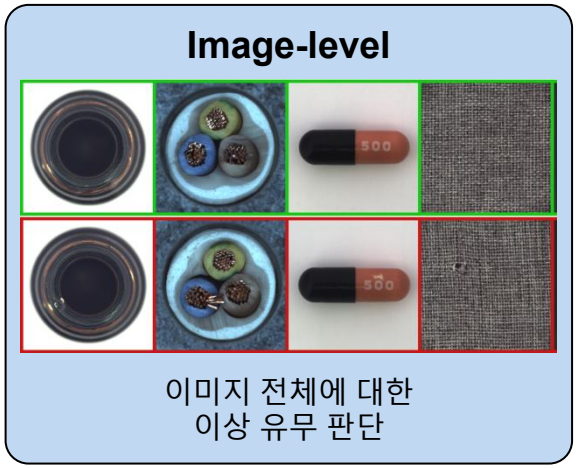
- **Supervised (지도)**
  - 이상 유형 별 라벨 존재
  - 이상 감지 문제에서는 잘 사용하지 않음 (이상 데이터 없음, 클래스불균형 문제 등)
- **Unsupervised (비지도)**
  - 라벨 없음
  - 정상 데이터만으로 모델을 만들고 이상 감지
- **Self-supervised (자기지도)**
  - 정상 데이터에 인위적 변형을 주고 그 변형을 예측/판별하도록 학습

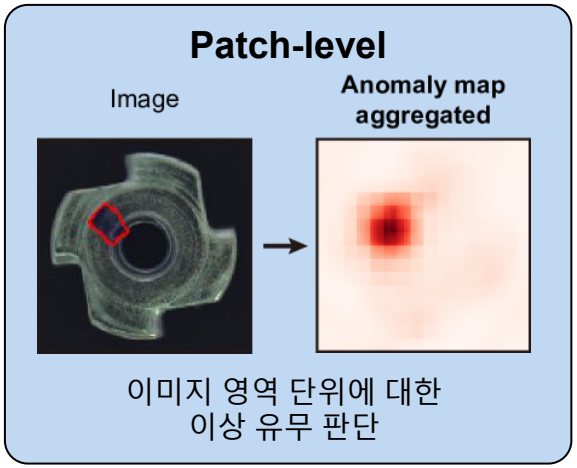


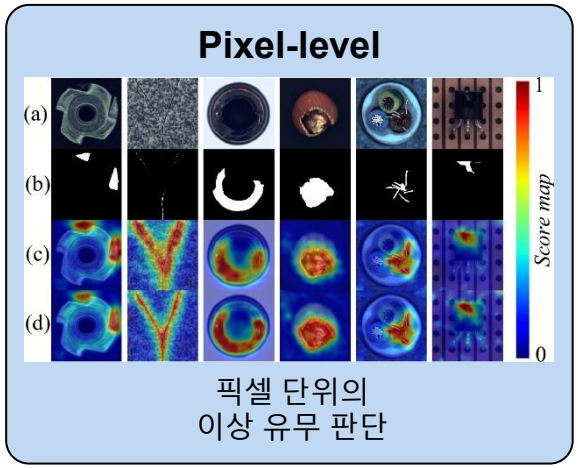
■ Visual Anomaly Detection 의 분류

2) **Level of prediction** : 이상 감지의 범위에 따른 분류

- **Image-level (이미지 단위, 전체)**
  - 이미지 전체에 대한 이상 유무만 판단 → 단순 이상 유무 판단
- **Patch-level (패치 단위, 영역)**
  - 이미지 내부의 패치(작은 영역) 단위로 이상 점수 산출 → 이상 위치 판단
- **Pixel-level (픽셀 단위, 점)**
  - 이상의 정확한 위치(픽셀 단위)까지 예측 → 정밀한 이상 위치 판단





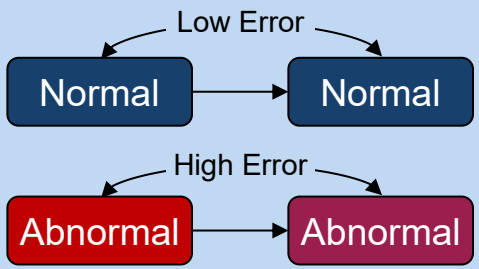


■ Visual Anomaly Detection 의 분류

3) **Mechanism** : 이상 감지의 동작 방식에 따른 분류

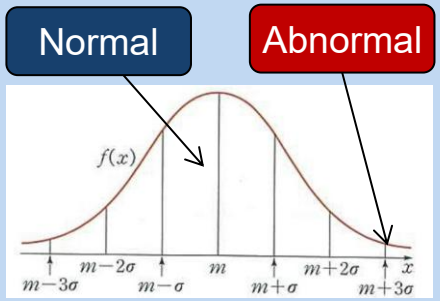
- **Reconstruction-based (복원, 재구성 기반)**
  - 정상만 학습 → 정상만 잘 복원/생성 → 재구성 오류(오차)가 이상 신호
- **Density-based (분포 기반)**
  - 정상의 확률밀도 또는 정상 특징 분포를 명시적으로 모델링 → 낮은 확률치 = 이상
- **Distance-based (거리 기반)**
  - 명시적 확률 모델 없이 특징 간 유사도(거리) 계산

Reconstruction-based



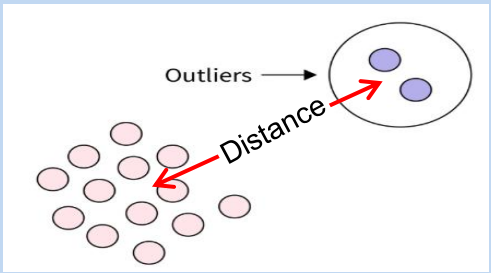
정상 데이터를 복원하고 실제 이미지와의 오류(오차)를 측정

Density-based



정상 데이터(학습)로부터 확률 밀도 함수를 모델링하고, 확률 밀도 추정

Distance-based



정상 데이터를 대표하는 특징으로부터 거리를 수치적으로 측정

DRAEM

Self-supervised | Pixel-level | Reconstruction-based

This ICCV paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

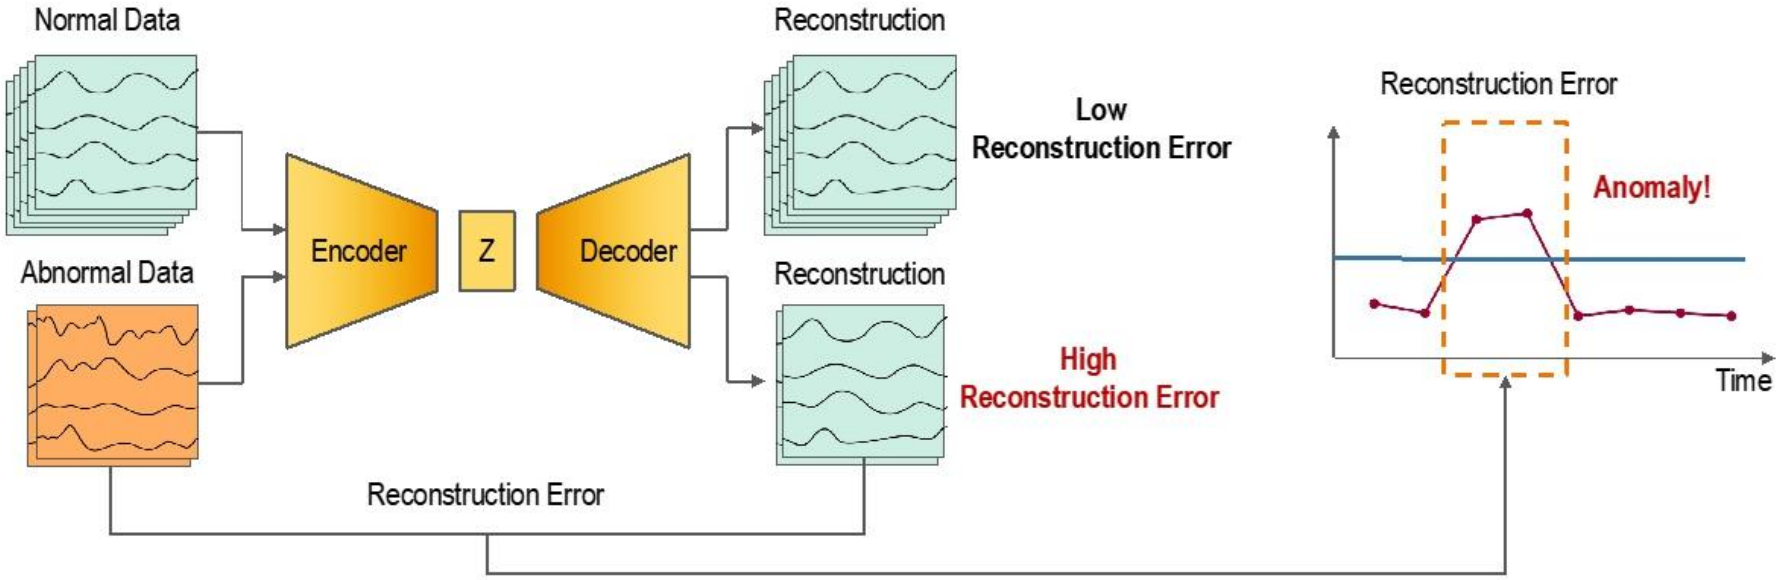
DRÆM – A discriminatively trained reconstruction embedding for surface anomaly detection

Vitjan Zavrtanik Matej Kristan Danijel Skočaj
University of Ljubljana, Faculty of Computer and Information Science
{vitjan.zavrtanik, matej.kristan, danijel.skocaj}@fri.uni-lj.si

Zavrtanik, Vitjan, Matej Kristan, and Danijel Skočaj. "Draem-a discriminatively trained reconstruction embedding for surface anomaly detection." *Proceedings of the IEEE/CVF international conference on computer vision*, 2021.

DRAEM

1) 기존 Reconstruction-based AD 접근 방법



문제점 : 비정상 데이터도 잘 복원해서 이상 수치가 낮게 나옴
(CNN의 표현 능력이 좋아서 한번도 못본 특성의 이미지도 잘 복원하는 경향이 있음)

DRAEM

2) 접근 방법

- 복원 기반과 판별 학습이 결합된 하이브리드 방법
- 비정상 이미지를 정상 이미지로 복원 → 정상 이미지와 비정상 이미지의 차이점 위주로 학습

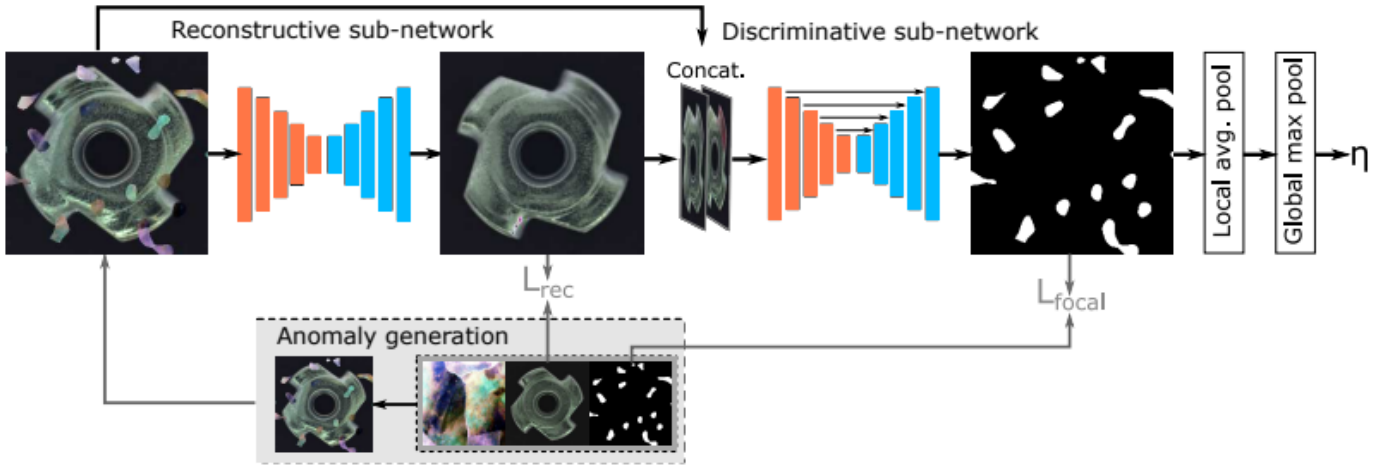


Figure 3. The anomaly detection process of the proposed method. First anomalous regions are implicitly detected and inpainted by the reconstructive sub-network trained using L_{rec}. The output of the reconstructive sub-network and the input image are then concatenated and fed into the discriminative sub-network. The segmentation network, trained using the Focal loss L_{focal}[14], localizes the anomalous region and produces an anomaly map. The image level anomaly score η is acquired from the anomaly score map.

https://github.com/VitjanZ/DRAEM

PaDiM

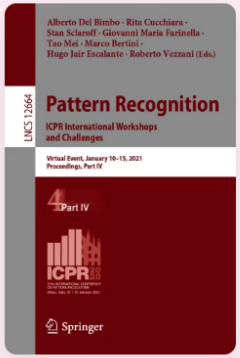
Unsupervised | Patch-level | Density-based

Home > Pattern Recognition. ICPR International Workshops and Challenges > Conference paper

PaDiM: A Patch Distribution Modeling Framework for Anomaly Detection and Localization

Conference paper | First Online: 05 March 2021

pp 475–489 | Cite this conference paper



Pattern Recognition. ICPR International Workshops and Challenges

(ICPR 2021)

Defard, Thomas, et al. "Padim: a patch distribution modeling framework for anomaly detection and localization." *International conference on pattern recognition*. Cham: Springer International Publishing, 2021.

■ PaDiM

1) 연구 배경

➢ 현실 문제:

- 불량 이미지 데이터는 거의 없고, 정상 이미지만 존재
- 이미지 내 이상 위치 정보는 제공되지 않음
- 기존 모델은 이미지 단위의 이상 감지를 수행함 -> 이상 위치 X
- 기존 모델(ex, Autoencoder, GAN)은 복잡하고 학습이 느림

2) 핵심 철학

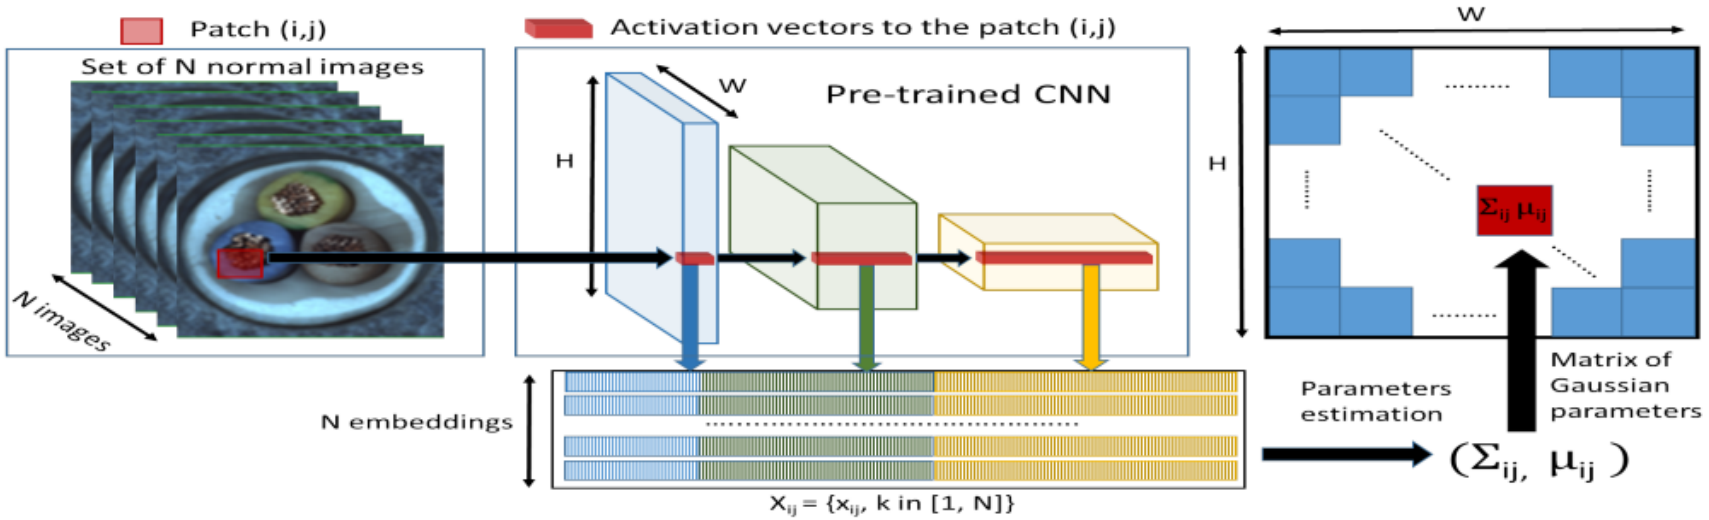
➢ 이미지 패치 별 정상 feature 의 분포를 모델링하면 이상을 탐지할 수 있음

PaDiM

2) 접근 방법

- patch-level embedding 생성 → 사전학습된 CNN에서 multi-layer feature 추출
- 분포 모델링 → 각 patch 위치 별 feature 를 가우시안 분포로 추정
- Anomaly Scoring → 테스트 이미지의 patch feature와 해당 위치 정상 분포 간 Mahalanobis distance 계산 (Mahalanobis distance : 확률분포상 거리)

Fig. 2. For each image patch corresponding to position (i, j) in the largest CNN feature map, PaDiM learns the Gaussian parameters (μ_{ij}, Σ_{ij}) from the set of N training embedding vectors $X_{ij} = \{x_{ij}^k, k \in [\![1, N]\!]\}$, computed from N different training images and three different pretrained CNN layers.



INDUSTRIAL AI RESEARCH CENTER

PatchCore

Unsupervised | Patch-level | Distance-based



This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.
Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.

Towards Total Recall in Industrial Anomaly Detection

Karsten Roth[1,*], Latha Pemula[2], Joaquin Zepeda[2], Bernhard Schölkopf[2], Thomas Brox[2], Peter Gehler[2]
[1]University of Tübingen [2]Amazon AWS

Roth, Karsten, et al. "Towards total recall in industrial anomaly detection." *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2022.

PatchCore

1) 기존 VAD 모델들의 문제점

관점	기존 문제점
모델 복잡성	GAN, VAE, Fflow 등은 학습 비용이 크고, 튜닝이 어려움
데이터 의존성	정상 데이터만으로 학습하는 과정에서, 모델이 불안정함
성능 균형 문제	일부 모델은 이상 탐지는 잘하나, 위치 탐지는 약함
확장성	실제 산업환경에서 빠르게 적용 가능해야 함

2) 핵심 철학

➢ 기존 Reconstruction-based, Density-based AD에서 요구되는 **재구성 과정이나 복잡한 확률모델 없이** 정상 feature space에서의 근접성 만으로 이상 감지를 하자

- 사전학습된 CNN feature는 이미 강력한 표현 공간을 형성한다 (추가 학습 불필요)
- 정상 feature manifold 주변의 local density를 잘 포착하면, 이상치는 단순히 "멀리 떨어진 feature" 로 식별 가능하다

PatchCore

3) 핵심 접근 방법

- Pretrained Encoder → 사전학습된 CNN의 feature layer 결합
- Memory Bank → 모든 정상 패치 feature를 저장
- Anomaly Scoring → Nearest Neighbor Search
- Localization → 패치 feature 별 anomaly score를 이미지 공간에 매핑

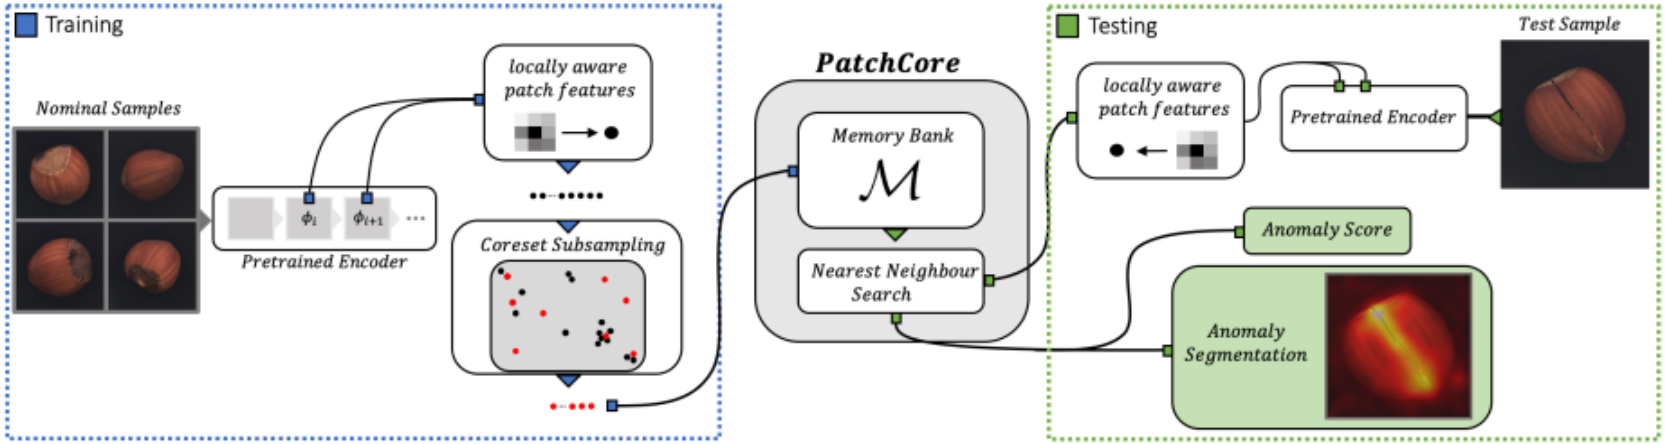


Figure 2. Overview of *PatchCore*. Nominal samples are broken down into a memory bank of neighbourhood-aware patch-level features. For reduced redundancy and inference time, this memory bank is downsampled via greedy coreset subsampling. At test time, images are classified as anomalies if at least one patch is anomalous, and pixel-level anomaly segmentation is generated by scoring each patch-feature.

차후 수업에 관하여...

INDUSTRIAL AI RESEARCH CENTER

■ 차후 수업 진행 안내

주차	수업내용	수업방식
1	Lecture Introduction	대면수업
2	Introduction to Industrial AI	대면수업
3	Basic of Neural Network	대면수업
4	Learning Strategies: Supervised Learning	대면수업
5	Learning Strategies: Unsupervised Learning	대면수업
6	글로벌 제조 트렌드 특강	비대면수업
7	Model Architecture: Convolutional Neural Networks	대면수업
8	Model Architecture: Sequence Models	대면수업
9	Midterm exam	대면수업
10	Visual Anomaly Detection	대면수업
11	Visual Anomaly Detection Experiments	대면수업
12	Temporal Anomaly Detection	대면수업
13	Temporal Anomaly Detection Experiments	대면수업
14	Final Project: Proposal & Discussion	대면수업
15	Final Project: Presentation	대면수업

감사합니다

Q&A