

머신러닝 프로그래밍

Machine Learning Programming

Lecture 12 : 군집화




충북대학교
CHUNGBUK NATIONAL UNIVERSITY



충북대학교
산업인공지능연구센터


비지도학습의 유형



비지도 학습의 유형

계층적 군집분석

계층적으로 각 데이터를 유사한 군집으로 묶어가며 진행하는 방법



응집형

하나의 데이터를 하나의 군집으로 보고 가까운 군집끼리 병합해 나가는 방식

분리형

전체 데이터를 하나의 군집으로 보고 분할해 나가는 방식


비지도 학습의 유형

계층적 군집분석


계층적으로 각 데이터를 유사한 군집으로 묶어가며 진행하는 방법

응집형

하나의 데이터를 하나의 군집으로 보고 가까운 군집끼리 병합해 나가는 방식



[부분 군집 다이어그램]



[덴드로그램]

비지도 학습의 유형

계층적 군집분석

계층적으로 각 데이터를 유사한 군집으로 묶어가며 진행하는 방법

응집형

데이터간 거리
측정 방식

· 수치형 데이터

유클리디안 거리

맨하탄 거리


민코우스키 거리

마할라노비스 거리

· 범주형 데이터

자카드 유사도

두 벡터의 교집합과 합집합의 비



코사인 유사도

두 벡터의 코사인 각도



비지도 학습의 유형

계층적 군집분석

계층적으로 각 데이터를 유사한 군집으로 묶어가며 진행하는 방법

응집형

군집간 거리
측정 방식

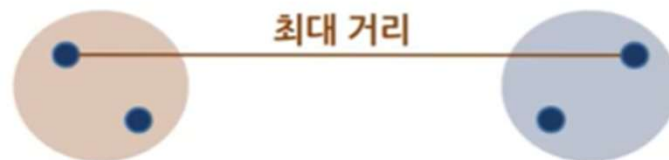
· 단일 연결법



· 중심 연결법



· 완전 연결법



· 와드 연결법




비지도 학습의 유형

계층적 군집분석

계층적으로 각 데이터를 유사한 군집으로 묶어가며 진행하는 방법

분리형 전체 데이터를 하나의 군집으로 보고 분할해 나가는 방식

대표적으로 다이아나(DIANA) 알고리즘 사용




비지도 학습의 유형

계층적 군집분석

계층적으로 각 데이터를 유사한 군집으로 묶어가며 진행하는 방법

분리형 전체 데이터를 하나의 군집으로 보고 분할해 나가는 방식

덴드로그램(Dendrogram)




비지도 학습의 유형

군집분석 평가지표

실루엣 계수(Silhouette Coefficient)

각각의 데이터별로 그 데이터가 속한 군집 내의 유사도와 인접한 군집의 유사도를 비교하는 지표



$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

-1에서 1사이의 값 (1일 수록 군집화가 잘 되었음을 의미)

· $a(i)$: i 번째 데이터에서 자신이 속한 군집내 다른 데이터 포인트들과의 평균 거리
- $a(1) = \text{mean}(a_{12}, a_{13}, a_{14})$

· $b(i)$: i 번째 데이터에서 가장 가까운 다른 군집내 다른 데이터 포인트들과의 평균 거리
- $b(1) = \text{mean}(b_{15}, b_{16}, b_{17})$

군집 내 응집도가 높고 군집간 분리도가 높아야 좋은 군집분석

비지도학습의 유형

비계층적 군집분석

거리 기반

· K-Means

밀도 기반

· DBScan

확률 기반

· 퍼지군집화

분포 기반

· EM알고리즘


그래프 기반

· 자기조직화지도(SOM)

비지도학습의 정의와 데이터

■ 비지도학습

- 실제값이 없는 데이터를 학습하여 패턴이나 상관관계를 찾는 방법
- 주요 적용 분야: 군집화, 차원 축소, 이상치 탐지, 밀도 추정 등
- 비지도학습 데이터: 라벨링되지 않은 이미지, 음성, 자연어 데이터 등




생도	키(x_{i1})	몸무게(x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

그림 1. 육사 생도의 키-몸무게 데이터

군집화의 기본 개념

- 군집화

- 실제값 없이 데이터를 유사성에 따라 여러 군집으로 분류하는 비지도학습의 한 유형으로 고객 세분화, 문서 분류, 신체 유형 그룹화 등에서 활용
- 유클리드 거리, 맨해튼 거리, 코사인 유사도 등 다양한 방식이 있으며 데이터 특성에 따라 선택




생도	키(x_{i1})	몸무게(x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

그림 1. 육사 생도의 키-몸무게 데이터 군집화 예

군집화의 기본 개념

▪ 유사도 측정(예시)



생도	키(x_{i1})	몸무게(x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75

그림 3. 군집화 유사도 측정 예

- 유클리드 거리 측정 $\text{Euclidean}(x_4, x_7) = \sqrt{\sum_{j=1}^2 (x_{4j} - x_{7j})^2} = \sqrt{(175 - 180)^2 + (74 - 78)^2} = \sqrt{41}$
- 맨해튼 거리 측정 $\text{Manhattan}(x_4, x_7) = \sum_{j=1}^2 |x_{4j} - x_{7j}| = |175 - 180| + |74 - 78| = 9$

k-평균 군집화의 핵심 원리

▪ k-평균 군집화

- N개의 관측값을 k개의 군집으로 나누는 알고리즘으로, 중심점을 활용하여 군집화를 수행
- 각 군집은 중심점(데이터의 평균 벡터)을 가지며, 데이터는 가장 유사한 중심점에 할당
- 모든 관측값은 k개의 중심점 중 가장 유사한(가까운) 중심점이 대표하는 군집으로 할당됨




그림 6. k-평균 군집화 예(k=3)

▪ k-평균 군집화의 동작 과정

- [1단계] 중심점 초기화 - [2단계] 군집 할당 - [3단계] 중심점 업데이트 - [4단계] 종료 조건 확인

k-평균 군집화의 핵심 원리

▪ [1단계] 중심점 초기화

- 군집 수 k 를 설정하고, 임의의 중심점을 정의하여 군집화 시작

표 1. 생도 키-몸무게 데이터

생도	키(x_{i1})	몸무게(x_{i2})
x_1	170	75
x_2	169	80
x_3	172	78
x_4	175	74
x_5	176	70
x_6	178	72
x_7	180	78
x_8	181	73
x_9	183	85
x_{10}	185	75




그림 7. 1단계 중심점 초기화 예

표2. 임의로 설정한 중심점의 키와 몸무게 값

중심점	키(c_{j1})	몸무게(c_{j2})
c_1	171	73
c_2	179	75
c_3	187	79

k-평균 군집화의 핵심 원리

▪ [2단계] 군집 할당

K-means 는 유클리드 거리

– 각 데이터는 가장 가까운 중심점에 할당됨

표 3. 각 데이터와 중심점 간 유클리드 거리

생도	중심점1(c_1)	중심점2(c_2)	중심점3(c_3)
x_1	2.23	9.0	17.46
x_2	7.28	11.18	18.02
x_3	5.09	7.61	15.03
x_4	1.12	4.12	13.0
x_5	5.83	4.12	14.21
x_6	7.07	5.83	11.40
x_7	10.29	3.16	7.07
x_8	10	2.82	8.48
x_9	16.97	10.77	7.21
x_{10}	14.14	6.0	4.47




그림 8. 2단계 군집 할당 예

- 2단계를 통해 할당된 군집
 - 군집1에 속한 데이터: x_1, x_2, x_3, x_4 ($N_1 = 4$)
 - 군집2에 속한 데이터: x_5, x_6, x_7, x_8 ($N_2 = 4$)
 - 군집3에 속한 데이터: x_9, x_{10} ($N_3 = 2$)

k-평균 군집화의 핵심 원리

▪ [3단계] 중심점 업데이트

– 할당된 군집의 데이터 평균을 계산해 중심점을 업데이트

$$\mathbf{c}_j = \left[\frac{1}{N_j} \sum_{i=1}^N r_{ij} x_{i1} \quad \frac{1}{N_j} \sum_{i=1}^N r_{ij} x_{i2} \right]^T$$

- $\mathbf{c}_j$: 군집 j 의 중심점
- N_j : 군집 j 에 속하는 데이터의 개수
- $\mathbf{x}_i$: 군집 j 에 속하는 i 번째 데이터(특징 벡터)
- x_{i1}, x_{i2} : $\mathbf{x}_i = [x_{i1} \ x_{i2}]^T$ 의 첫 번째 성분과 두 번째 성분
- $r_{ij} = \begin{cases} 1 & \text{if } j = \arg \min_k \|\mathbf{x}_i - \mathbf{c}_k\|^2 \\ 0 & \text{otherwise} \end{cases}$

k-평균 군집화의 핵심 원리

- 새로운 중심점 구하기

$$\mathbf{c}_j = \left[\frac{1}{4}(170+169+172+175) \quad \frac{1}{4}(75+80+78+74) \right]^T = [171.5 \quad 76.75]^T$$

표 9-4 새로운 중심점의 키와 몸무게 값

중심점	키(c_{j1})	몸무게(c_{j2})
$\mathbf{c}_1$	171.5	76.75
$\mathbf{c}_2$	178.75	73.25
$\mathbf{c}_3$	184	80




그림 9.3단계 중심점 업데이트 예

k-평균 군집화의 핵심 원리

▪ [4단계] 종료 조건 확인

- 중심점이 더 이상 이동하지 않으면 군집화 종료

표 9-5 최종 중심점 위치

중심점	키(c_{j1})	몸무게(c_{j2})
c_1	170.3	77.6
c_2	176.3	72
c_3	182.3	77.8




그림 10. 4단계 종료 조건 확인 예

k-평균 군집화 관련 고려 사항

■ 초기 중심점 설정 및 성능 측도

- 초기 중심점 설정에 따라 군집화 결과가 달라질 수 있다.
- [표 9-1]의 데이터에 새로운 임의의 중심점을 설정해 결과 차이를 살펴보자.

■ [1단계] 중심점 초기화

표 9-6 새로운 중심점

중심점	키(c_{j1})	몸무게(c_{j2})
c_1	171	74
c_2	179	71
c_3	182	80




그림 11. 1단계 중심점 초기화

k-평균 군집화 관련 고려 사항

▪ [2단계] 군집 할당




그림 12. 2단계 군집 할당

▪ [3단계] 중심점 업데이트




그림 13. 3단계 중심점 업데이트

k-평균 군집화 관련 고려 사항

초기 중심점에 따른 군집화 결과 비교




그림 14. 초기 중심점에 따른 군집화 결과 비교

k-평균 군집화 관련 고려 사항

- k-평균 군집화에서의 성능 측도

- 비지도학습에서는 실제값이 없어 성능을 시각적으로만 판단하기 어려움
- SSE(오차제곱합): 각 군집의 중심점과 데이터 간 거리 차이를 제곱해 합산, 값이 작을수록 군집화 성능이 좋음을 의미
- 예측 정확도 대신, SSE와 같은 성능 측도를 사용해 군집화 결과를 평가

$$SSE = \sum_{j=1}^k \sum_{i=1}^N r_{ij} (x_i - c_j)^2$$

- k : 군집의 개수
- c_j : 군집 j 의 중심점
- x_i : 군집 j 에 속하는 i 번째 데이터(특징 벡터)
- $r_{ij} = \begin{cases} 1 & \text{if } j = \arg \min_k \|x_i - c_k\|^2 \\ 0 & \text{otherwise} \end{cases}$

k-평균 군집화 관련 고려 사항

■ k-평균 군집화에서 k(군집의 개수) 설정

▪ 데이터의 군집 수를 사용자의 필요에 맞춰 설정

– 예를 들어, 두 개의 군집이 필요한 경우 k를 2로 설정

▪ 성능 지표 기반 설정

– 오차제곱합(SSE) 등의 지표를 사용하여 적절한 k를 선정

– SSE는 k 증가에 따라 감소하지만, 감소율이 완만해지는 지점을 엘보우 포인트로 간주하고, 이 지점을 기준으로 k를 선택한다.




그림 15. 군집 수에 따른 SSE 결과 비교

k-평균 군집화 관련 고려 사항

◆ K-평균 군집화에서 종료 조건

▪ 성능 측도 활용

- 오차제곱합(SSE) 등의 성능 지표를 사용하여 종료 조건을 설정
- SSE 값이 특정 임계값 이하로 떨어질 때까지 군집화를 반복한다
- SSE가 완전히 0이 되는 경우는 드물기 때문에, SSE가 일정 수준 이하로 줄어들면 종료한다.

▪ 중심점의 변화 없음

- 군집화 과정에서 중심점이 더 이상 변화하지 않을 때 종료.
- 중심점이 업데이트되지 않으면 군집 할당도 변하지 않으므로, 중심점의 위치가 고정되면 군집화를 종료한다.

▪ 정해진 반복 횟수

- 미리 설정한 반복 횟수만큼 군집화 과정을 수행한 후 종료
- 반복 횟수를 설정하되, 데이터의 특성에 따라 적절한 횟수를 결정하여 군집화가 적절히 이루어지도록 한다.

군집화의 기본 개념

▪ 밀도 기반 군집화

- 밀도를 기반으로 군집화
- 군집 수를 미리 정할 필요 없음
- 이상치 탐지에도 활용 가능




그림 5. 밀도 기반 군집화를 적용한 예

K-Means vs DBSCAN

K-Means



- 거리기반 알고리즘
- 군집 개수 K 지정 필요
- 노이즈와 이상치에 민감
- 원형의 분포를 나타내는 데이터에서 활용

DBSCAN




- 밀도기반 알고리즘
- 군집 개수 지정할 필요 없음
- 노이즈와 이상치에 강함
- 다양한 분포의 데이터에서 사용 가능

기타 비계측적 군집분석


확률 기반

- 퍼지군집화



분포 기반


- EM알고리즘



- E-Step : 각 데이터가 각 군집에 속할 기댓값을 계산
- M-Step : 군집 분포의 파라미터를 재추정

그래프 기반

- 자기조직화지도(SOM)



실습

12-1. k-means.py

과제 : k_value를 변경하고
실루엣 점수, SSE를 분석하여
최적의 k값찾기

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from sklearn.cluster import KMeans
5 from sklearn.metrics import silhouette_score
6 from sklearn.preprocessing import StandardScaler
7 from sklearn.decomposition import PCA
8 import warnings
9 warnings.filterwarnings('ignore')
10
11 file_path = r"F:\My_project\datasets\11_data.csv"
12 df = pd.read_csv(file_path)
13 X = df.select_dtypes(include=[np.number]) # 문자열 컬럼 제외하고 숫자형 데이터만 추출
14
15 if 'id' in X.columns:
16     X = X.drop(columns=['id']) # 식별 번호(id) 등 군집화에 방해되는 컬럼이 있다면 제거
17
18 X = X.dropna(axis=1, how='all') # 통째로 비어있는 열(광통 열) 우선 제거
19 X = X.fillna(X.mean()) # 남은 결측치는 해당 변수의 '평균값'으로 부드럽게 채움
20
21 # 데이터 정규화 (스케일링)
22 scaler = StandardScaler()
23 X_scaled = scaler.fit_transform(X)
24
25 # K-Means 모델 학습 (K=3)
26 k_value = 3
27 kmeans = KMeans(n_clusters=k_value, random_state=42)
28 kmeans_labels = kmeans.fit_predict(X_scaled)
29
30 sil_score = silhouette_score(X_scaled, kmeans_labels)
31 sse = kmeans.inertia_
32
33 print("-" * 40)
34 print(f"🔴 K-Means 군집화 결과 (K={k_value})")
35 print("-" * 40)
36 print(f"▶ 실루엣 점수 (Silhouette Score): {sil_score:.4f}")
37 print(f"▶ SSE (오차제곱합, Inertia): {sse:.4f}")
38 print("-" * 40)
39
40 pca = PCA(n_components=2, random_state=42) # 시각화를 위한 PCA (고차원 -> 2차원)
41 X_pca = pca.fit_transform(X_scaled)
42 plt.figure(figsize=(8, 6))
43
44 # 군집 결과 산점도 시각화
45 plt.scatter(X_pca[:, 0], X_pca[:, 1], c=kmeans_labels, cmap='viridis', s=30, edgecolor='k')
46
47 # 평가 점수를 제외한 깔끔한 그래프 제목 설정
48 plt.title(label=f'K-Means Clustering Result (K={k_value})', fontsize=14, fontweight='bold')
49 plt.xlabel('Principal Component 1 (PC1)')
50 plt.ylabel('Principal Component 2 (PC2)')
51 plt.grid(visible=True, linestyle='--', alpha=0.6)
52 plt.tight_layout()
53 plt.show()
```

12-2. DBSCAN.py

필도기반

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from sklearn.datasets import make_circles
4 from sklearn.cluster import DBSCAN
5 from sklearn.preprocessing import StandardScaler
6 import warnings
7 warnings.filterwarnings('ignore')
8
9 # 1. 시뮬레이션 센서 데이터 생성 (정상: 동심원, 이상치: 무작위 노이즈)
10 X_circles, _ = make_circles(n_samples=500, factor=0.5, noise=0.05, random_state=42)
11 np.random.seed(42)
12 X_noise = np.random.uniform(low=-1.5, high=1.5, size=(30, 2))
13 X = np.vstack([X_circles, X_noise])
14
15 # 2. 데이터 정규화
16 X_scaled = StandardScaler().fit_transform(X)
17
18 # 3. DBSCAN 모델 학습 (eps=0.3으로 넉넉하게 수정!)
19 dbscan = DBSCAN(eps=0.3, min_samples=5)
20 dbscan_labels = dbscan.fit_predict(X_scaled)
21
22 # 4. 결과 출력
23 n_clusters = len(set(dbscan_labels)) - (1 if -1 in dbscan_labels else 0)
24 n_noise = list(dbscan_labels).count(-1)
25
26 print("-" * 40)
27 print(f"▶ 탐지된 정상 궤적(군집) 수: {n_clusters}개")
28 print(f"▶ 탐지된 고장(노이즈) 신호 수: {n_noise}개")
29 print("-" * 40)
30
31 # 5. 초간단 시각화 (색상 자동 할당)
32 plt.figure(figsize=(7, 5))
33 plt.scatter(X_scaled[:, 0], X_scaled[:, 1], c=dbscan_labels, cmap='viridis', edgecolor='k')
34 plt.title(label: 'DBSCAN Simplified Result (eps=0.3)', fontsize=14)
35 plt.show()
```