

머신러닝 프로그래밍

Machine Learning Programming

Lecture 13 : 이상탐지



충북대학교
CHUNGBUK NATIONAL UNIVERSITY



충북대학교
산업인공지능연구센터

이상탐지?

이상탐지(anomaly detection)

정상적인 동작에서 벗어난 데이터포인트, 이벤트를 식별하는 데이터 분석 과정

탐지(Detection) vs 예측(Prediction)

현재 또는 과거
데이터에서 이상을
탐지
Ex. 지금 모터가 이상한 진동을
보인다

vs

미래에 이상이 발생할
가능성을 **예측**
Ex. 모터가 앞으로 3일 이내에 이상
진동을 보일 가능성이 높다

이상탐지?

이상탐지(anomaly detection)의 활용

1

스마트 팩토리 및 제조

설비 고장 예지 및 관리, 제품 품질 관리 및 결함 탐지

2

금융 및 보안

금융 사기탐지, 사이버 보안 및 네트워크 침입 탐지

3

IoT 센서 및 스마트 인프라

스마트 그리드 및 에너지 소비 모니터링

4

의료 및 헬스케어


의료 영상기반 결함 탐지

이상탐지?

시계열 이상탐지(anomaly detection)의 유형


Point Anomaly (점 이상):

- 전체 데이터 분포에서 확연히 벗어난 단일 데이터 포인트.
ex. 평소 10이던 전력 사용량이 갑자기 1000이 된 경우



Contextual Anomaly (맥락적 이상):

- 값 자체는 정상이지만 특정 상황(맥락)에서 이상한 경우.
ex. 한여름에 난방 사용량이 소폭 증가한 경우



Collective Anomaly (집단적 이상):

- 개별 포인트는 정상이지만 그들이 모인 시퀀스 전체가 비정상인 패턴.
ex. 시스템 로그의 특정 순서 반복



이상탐지?

시계열 데이터란?

일정한 시간 간격(Time Interval)을 두고 순차적으로 관측된 데이터 포인트들의 집합

시계열 데이터의 개수에 따라

- 단변량 데이터
- 다변량 데이터

시계열 데이터의 복합적 구조

- **Trend:** 장기적인 증가 또는 감소 추세
- **Seasonality:** 일간, 주간, 월간 반복 패턴
- **Residual (Noise):** 추세와 계절성을 뺀 나머지 영역



이상탐지?

왜 이상 탐지 시스템이 필요할까? - 빅 데이터 시대


넘쳐나는 데이터에 대한 관리, 검증 및 안정화는 필수



정상 데이터 학습
(Normal Data Training)

새로운 데이터 평가
(New Data Evaluation)

활용 가치 및 효과
(Benefits & Value)



이상탐지?

이상탐지의 역사

단일 변수 통계 규칙에서 시계열 맥락(Context)을 이해하는 최신 딥러닝 하이브리드 시스템까지

1. 통계적 기법 (1980s~)

Z-Score, ARIMA, 3-Sigma

초기 이상 탐지는 고정된 임계값(Threshold)과 정규 분포에 의존. 구조가 단순하고 빠르지만, 다변량 데이터나 비선형적인 패턴을 탐지하는 데는 한계 명확.

2. 머신러닝 기법 (2000s~)

Isolation Forest, One-Class SVM

데이터가 방대해지면서 피처(Feature) 간의 비선형적인 관계를 군집화하거나 트리를 분할하여 이상치를 찾기 시작. 고차원 데이터 처리 시작.

3. 딥러닝 기법 (2010s~)

Autoencoder, LSTM, Transformer
특징을 스스로 추출(Representation Learning)하며, 데이터의 '시간적 의존성과 맥락(Context)'을 학습. 복원 오차(Reconstruction Error)를 통해 미세한 시계열 이상 징후를 포착.


최신 트렌드 (Hybrid):

강력한 딥러닝 아키텍처로 맥락을 예측하고, 통계적 기법으로 신뢰 구간을 검증하는 결합 형태로 진화.

이상 탐지?

어떻게 학습할까?

이상 탐지 모델링: 지도 학습의 한계와 실무적 접근법(Representation Learning)



Supervised Learning
(지도 학습)

학습에 사용할
균형 있는 데이터 부족

Unsupervised Learning
(비지도 / 준지도 학습)


풍부한 정상 데이터만으로
학습이 가능

이상탐지?

시계열 이상 탐지 과정

복원 학습 vs 대조 학습 비지도 학습(Unsupervised Learning) 환경에서 모델이 정상 패턴을 이해하는 두 가지 패러다임


복원 학습 (Reconstruction)



Autoencoder 기반

- 정상 시계열 데이터를 좁은 잠재 공간(Latent Space)으로 압축(Encoder)한 뒤, 다시 원래 형태로 복원(Decoder)하도록 학습.
- 정상 데이터의 핵심 특징만 요약하여 기억하는 방식.

대조 학습 (Contrastive Learning)



SimCLR, TS2Vec 기반

- 원본 시계열(Anchor)에 노이즈를 주거나 자른 데이터(Positive)는 잠재 공간에서 서로 가깝게 당기고(Pull), 완전히 다른 시점의 데이터(Negative)는 멀리 밀어냄.

이상탐지?

시계열 이상 탐지 딥러닝 모델

시퀀스 복원 모델

LSTM-AE / VAE

시계열데이터의 순차적(Sequential) 흐름을 기억하여 데이터를 압축하고 다시 복원.

정상 패턴의 흐름을 훈련한 뒤, 새로운 데이터가 들어왔을 때 제대로 복원해내지 못해 '**복원 오차(Reconstruction Error)**'가 급증하는 구간을 이상치로 판별하는 가장 훌륭한 베이스라인 모델.

어텐션 기반 모델

Anomaly Transformer

Self-Attention 메커니즘을 통해 데이터의 **장기 의존성(Long-term Dependency)**을 파악.

각 시점 간의 연관성이 정상 범주와 어떻게 다른지(Association Discrepancy)를 정밀하게 계산하여, 가장 까다로운 **맥락적 이상(Contextual Anomaly)**을 찾아내는데 압도적인 성능을 보임.

그래프 신경망 모델

MTAD-GAT / GDN

다변량 시계열(Multivariate) 환경에서 수십~수백 개 **센서 간의 공간적, 위상적 상호작용**을 그래프(Graph)로 모델링.

개별 센서의 값은 정상이지만, 특정 **센서 변수들 간의 상관관계가 깨지는** 복합적인 시스템 결함(Collective Anomaly)

이상탐지?

실전 임계값(Threshold) 설정 방법론

도출된 어노말리 스코어에서 최적의 이상 판단 기준선을 긋는 3가지 접근법

통계적 분포 기반가장 대중적/빠름

Anomaly score가 정규 분포를 따른다고 가정할 때, 평균에서 표준편차의 N배(주로 **3-Sigma** 기법 적용) 이상 벗어난 값을 이상치로 간주. 데이터 분포 파악이 용이할 때 직관적으로 설정 가능

극단치 이론 (EVT, POT)학술적/동적 임계값

Extreme Value Theory(EVT)와 Peaks-Over-Threshold 기법을 결합하여, 스코어의 극단적인 꼬리(Tail) 분포를 수학적으로 모델링. 데이터의 국소적 변화에 반응하여 동적(Dynamic)으로 임계값을 갱신할 때 자주 쓰이는 최신 연구 방법론.

평가 지표 최적화 (Grid Search)실무적/성능 위주

일부 정답(Label)이 존재하는 Validation Set이 있을 때 사용. 임계값을 조금씩 변경해가며 모델의 Precision(정밀도)과 Recall(재현율)의 조화평균인 F1-Score가 최대가 되는 지점을 역산하여 최적의 컷오프를 찾아냄.

