

시간-주파수 마스크 오토인코더를 위한 시계열 이상 탐지

Yuchen Fang¹, Jiandong Xie², Yan Zhao^{3,*}, Lu Chen⁴, Yunjun Gao⁴, Kai Zheng^{1,*} 1 중국 전
자 과학 기술 대학 2 Huawei Cloud Database Innovation Lab, 중국 3
Aalborg University, 덴마크 4 Zhejiang University,
중국 fyclmiss@gmail.com,
xiejiandong@huawei.com,
yanz@cs.aau.dk, {luchen,gaoyj}@zju.edu.cn, zhengkai@uestc.edu.cn

요약—관측 가능 상태에는 대상 시스템의 작동 상태를 모니터링하기 위해 방대한 양의 시계열 데이터가 수
집됩니다. 이러한 데이터에서 가치를 추출하기 위해서는 이상 탐지가 매우 중요합니다. 기존의 재구성 기반 방
법들은 레이블이 지정되지 않은 데이터에서 우수한 탐지 성능을 보여주었지만, 이상 시점에 대한 학습 편향과
시계열 내 분포 변화와 같은 문제점을 여전히 안고 있습니다. 이러한 문제점을 해결하기 위해, 본 논문에서는
대조 기준을 통해 시계열 데이터의 이상을 탐지하는 간단하면서도 효과적인 시간-주파수 마스크 오토인코더
(TFMAE)를 제안합니다. 구체적으로, TFMAE는 윈도우 기반 시간 마스크 전략과 진폭 기반 주파수 마스크
전략을 각각 적용한 두 개의 트랜스포머 기반 오토인코더를 사용하여 이상 편향 없이 지식을 학습하고, 추출
된 정상 정보를 이용하여 이상을 재구성합니다. 또한, 이중 오토인코더는 대조적 목적 함수를 통해 학습되는
데, 이는 시간-주파수 마스크 오토인코더와의 표현 차이를 최소화하여 이상 징후를 강조하고, 분포 변화의 부
정적인 영향을 완화하는 데 도움을 줍니다. 마지막으로, 과적합을 방지하기 위해 TFMAE는 학습 단계에서 적
대적 학습을 채택합니다. 7개의 데이터셋에 대한 광범위한 실험을 통해 본 모델이 이상 징후 탐지 정확도 측면
에서 최첨단 성능을 능가할 수 있음을 입증했습니다.

하지만 시계열 패턴은 다양한 응용 분야에서 복잡하고 역동적이기 때문에 정확한
시계열 이상 탐지를 제공하는 것은 결코 간단한 작업이 아니며, 이상을 정확하게 정
의하는 일반적인 방법을 찾기가 어렵습니다.

더욱이, 레이블이 지정된 데이터의 부족으로 인해 시계열 이상 탐지를 위한 지도 학습
방법의 발전이 저해되고 있습니다. 비지도 학습 접근 방식은 레이블이 지정된 데이
터 없이도 이상을 탐지할 수 있으며, 이는 주로 밀도 기반 방법(이웃 간의 차이 활용)
과 클러스터링 기반 방법(클러스터 중심과의 거리 활용)에 의존합니다. 시계열 데이터
의 규모가 커지고 데이터 분석에서 탁월한 성능을 보임에 따라, 최근 연구
들은 다양한 딥러닝 모델을 사용하여 복잡한 시간적 상관관계와 다변량 종속성을 갖
는 시계열을 재구성하는 데 집중하고 있습니다. 이러한 모델들은 재구성된 시계열과
원본 시계열 간의 차이에 초점을 맞춥니다. OmniAno[6], Times-Net[7],
TranAD[8]와 같은 혁신적인 모델들은 각각 순환 신경망, 합성곱 신경망, 트랜스포
머 네트워크를 시계열 이상 탐지에 도입했습니다.

색인 용어—시계열 이상 탐지, 시간적-
주파수 분석, 마스크드 오토인코더

I. 서론

시계열은 시간적으로 순서가 정해진 관측값들의 연속체이며, 센서 네트워크, 클
라우드 컴퓨팅, 특히 최근 등장한 관측가능성 개념[1], [2]을 비롯한 시계열 데이터
수집 및 저장 능력의 발전으로 인해 시계열 분석은 학계 및 산업계 연구에서 중요한
과제로 빠르게 부상하고 있다. 이상 탐지는 시계열 분석에서 필수적인 작업으로, 데
이터가 정상적인 데이터 분포를 따르는지 여부를 판단하고, 따르지 않는 부분을 이
상치라고 한다.

이상 징후에 대한 시기적절한 경고는 시스템 유지 관리자가 사전 예방적으로 유지 관
리를 수행할 수 있도록 지원하여 사기 탐지[3], 침입 탐지[4], 에너지 관리[5]와 같은
실제 응용 프로그램에서 지속 가능성과 안전성을 확보할 수 있습니다.

*교신 저자: 정카이, 자오옌. 정카이는 중국 선전 전자과학기술대학교 선전고등연구소 소속
이다.

최근의 개선에도 불구하고 기존의 심층 재구성 기법은 여전히 한계가 있습니다.
기존 방법론은 여전히 다음과 같은 문제점에 직면해 있습니다.

과제 I: 비정상 편향. 딥러닝 모델은 훈련 단계에서 데이터로부터 학습된 지식에
크게 의존하지만, 시계열 데이터에서 정보를 추출하는 것은 복잡한 패턴 때문에 언어
및 이미지 데이터보다 더 어렵습니다[9], [10]. 따라서, 특히 지식과 무관한 비정상 편
향이 존재하는 경우, 고품질 재구성 모델을 학습하는 것은 매우 어렵습니다. 그림 1
의 왼쪽에서 볼 수 있듯이, 대표적인 재구성 모델인 TimesNet[7]은 정상 시계열
은 잘 재구성하지만, 비정상 관측치에 과적합되어 성능 저하를 초래합니다.

이 현상은 흔히 사용되는 시간 모델링 과정에서 정상적인 패턴에 섞여 들어갈 수 있
는 잘못된 비정상적 편향이 포함되면서 발생합니다. 안타깝게도 기존의 많은 재구성
기반 방법들은 이러한 비정상적 편향을 간과하여 최적의 성능을 내지 못합니다.

과제 II: 시계열 분포 변화. 시계열 분포 변화는 중요한 요인으로 작용하여, 훈련
데이터에서 학습된 패턴이 테스트 데이터에는 적합하지 않거나 심지어 잘못된 패턴이
될 수 있으며, 이는 잘못된 시계열 재구성으로 이어집니다. 그림 1의 오른쪽에서 볼
수 있듯이, 테스트 데이터에 대한 누적 점수 곡선은 상승합니다.




그림 1: 왼쪽: TimesNet [7]은 이상 탐지를 수행합니다. 합성 NIPS-TS-Global 데이터셋. 오른쪽: 실제 데이터에 대한 이상치 점수의 누적 분포 함수(CDF). TimesNet용 SMAP 검증 및 테스트 세트.

검증 데이터의 결과보다 더 빠르는데, 이는 다음과 같은 이유 때문입니다. 시계열 분포 변화에 영향을 미치고, 임계값에 대한 일반화 능력이 떨어집니다. 두 가지가 있음에도 불구하고 기존 기술 유형 중 통합 가능한 유형 분포 변화를 완화하기 위한 재구성 기반 방법: 정규화 및 분해. 정적 통계 기반 정규화[11], [12] 및 사전 정의된 매개변수 기반 분해 [9], [13]–[15]는 일반화에 한계를 보입니다. 또한 학습된 통계에 의존하는 방법 [16] 그리고 매개변수 [17], [18]는 여전히 영향에 취약합니다. 유통망의 변화.

본 연구는 시간-주파수 마스크(Temporal-Frequency Masked)라는 혁신적인 모델을 설계하여 위의 문제점들을 해결하는 것을 목표로 합니다. 적대적 대조 목적 함수를 통해 학습된 오토인코더(TFMAE)입니다. 비정상적인 편향의 경우, 시계열 데이터 정제의 중요성을 인식하여, 본 연구에서는 윈도우 기반 시간 마스크 전략을 구현하여 잡음을 제거합니다. 잠재적인 관측 이상 현상(예: 전역적 및 맥락적) 관측 이상치) 변동 계수가 큰 경우, 또한 잠재적인 패턴 이상 현상(예: 추세 및 계절성)을 제거하기 위한 진폭 기반 주파수 마스크 전략을 사용합니다. 진폭이 작은 이상 현상)을 감지합니다. 이러한 전략은 비정상적인 편향 없이 학습하고 재구성하는 데 유용합니다. 학습된 정상 지식과의 불일치. 이를 해결하기 위해 분포 변화 문제를 해결하기 위해, 우리는 먼저 두 개의 트랜스포머 기반 오토인코더를 고안하여 우리의 데이터에 대한 서로 다른 표현을 생성합니다. 시간 및 주파수 마스크 기반 시계열. 그런 다음 최소화하기 위해 새로운 대조 목적 함수가 도입되었습니다. 이러한 표현들 사이의 불일치. 마지막으로, 대조적 불일치는 이상 탐지를 위한 기존 재구성 오류를 대체하며, 이는 불일치와

이상 현상 및 이에 대응하는 정상 복구 이미지 일반적 표현 방식을 뛰어넘는다. ~에서 벗어나다 재구성 패러다임, 대조 기준은 다음과 같은 이점을 제공합니다. 서로 다른 관점의 유사성이 분포에 무관하다는 사실[19]. 또한, 불일치 최소화에서 과적합을 방지하기 위해 적대적 학습이 TFMAE에 통합되었습니다.

우리의 공헌은 다음과 같이 요약할 수 있습니다.

- 잠재적인 비정상 관찰 및 패턴을 제거하기 위해 모델링에 앞서, 윈도우 기반 시간 마스크 전략과 진폭 기반 주파수 마스크 전략을 제시합니다.

- 마스크 전략. 따라서, 정제된 오토인코더 입력값은 관찰 및 패턴 이상 현상에 의해 오도되지 않습니다. 즉, TFMAE는 비정상적인 편향에 강한 모델입니다.
- 저희가 아는 한, 이 연구는 최초의 연구입니다. 이는 재구성 오류를 시간적 오류로 대체합니다. 그리고 주파수 마스크 기반 대조 기준 시계열 이상 탐지, 즉 분포 변화 영향을 받지 않은 모델.
- 우리는 7개의 공개 실제 데이터를 기반으로 광범위한 실험을 수행합니다. 시계열 데이터 세트를 분석하고, 그 결과는 다음과 같은 통찰력을 제공합니다. TFMAE의 효과성과 효율성.

제2절에서는 관련 연구를 살펴본다. 문제 제기 시스템 개요는 3절에서 소개합니다. 그 다음에는... 섹션 IV에서 TFMAE를 제시하고, 이어서 실험을 진행합니다. 결과는 제5절에 제시되어 있습니다. 제6절에서는 본 논문의 결론을 제시합니다.

II. 관련 연구

A. 시계열 이상 탐지 시계열에 관한 수많은 연구가 진행되어 왔다. 이상 탐지. 이상 탐지 방식에 따라 밀도 기반을 포함한 다섯 가지 유형으로 분류할 수 있습니다. 방법론에는 클러스터링 기반 방법, 레이블 기반 방법, 재구성 기반 방법 및 대조 기반 방법이 있습니다. 밀도 기반 방법은 주로 불일치에 초점을 맞춥니다. 관측값과 그 이웃 사이의 관계. 밀도 기반 지역 이상치 요인(LOF) [20] 및 연결성 기반 연결성 이상치 요인(COF) [21]은 두 가지 대표적인 전통적인 방법입니다. 밀도 기반 방법. 심층 표현 학습으로서 DAGMM[22]과 같은 고급 모델이 주목을 받게 되었습니다. MPPCAD [23]는 시간의 자차원 표현을 학습합니다. 본 연구에서는 일련의 데이터를 분석하고 가우시안 혼합 모델을 활용하여 결과를 도출합니다. 밀도를 이용하여 매우 정확한 탐지 결과를 얻습니다. 클러스터링 기반 방법은 관측치와 클러스터 중심 사이의 거리를 활용하여 이상치를 식별합니다. 클러스터링을 고려하면 다음과 같은 고전적인 기법들이 있습니다. 지원 벡터 데이터 설명(SVDD) [24] 및 단일 클래스 서포트 벡터 머신(OC-SVM) [25]은 커널 공간에서 초구와 초평면을 검색합니다. 그 후,

DSVDD [26] 및 THOC [27]는 클러스터를 찾기 위해 제안되었습니다. 이상 탐지를 위한 심층적인 잠재 공간 및 계층 공간. 레이블 기반 방법은 지도 분류를 수행합니다. 훈련 단계 동안. Microsoft [28]는 사용을 선도했습니다. 사람이 생성한 레이블을 사용하여 이상 탐지용 CNN 모델을 훈련합니다. 이 접근 방식을 확장하여 RobustTAD [29]는 다음과 같은 내용을 도입합니다. 레이블과 값에 대한 가중치 할당은 매우 중요합니다. 탐지 성능을 향상시키는 데 도움이 되는 사항입니다. 재구성 기반 방법은 핵심적인 역할을 해왔습니다. 특히 레이블이 지정된 훈련 데이터가 없는 경우 연구에 유용합니다. 이 모델들은 비지도 학습 방식으로 훈련되어 다음을 감지합니다. 원본과 결과 사이의 불일치를 파악하여 이상 현상을 찾아냅니다. 재구성된 시계열. 초기에는 재구성이 ARIMA[30]와 같은 통계적 방법에 의존했습니다.

딤라리의 등장으로 Omni-Ano [6], HIFI [31], Interfusion [32], TFAD [13], VQRAE [33]와 같은 방법들이 생겨났습니다. RDAE[34] 및 TimesNet[7]은 시계열을 재구성합니다.




그림 2: 제안된 TFMAE의 전체 구조. 왼쪽 부분은 시간-주파수 마스크를 포함하고, 가운데 부분은 트랜스포머 기반 오토인코더이며, 오른쪽 부분은 목적 함수를 보여줍니다. DKL은 쿨백-라이블러 발산(Kullback-Leibler divergence)을 의미합니다.

현재 입력으로부터. 또한, 적대적 학습은 다음과 같은 특징을 가지고 있습니다. 견고한 탐지를 위한 재구성 기반 방법에 통합되었습니다. 예를 들면 BeatGAN[35], USAD[36] 등이 있습니다.

DAEMON [37], [38], SA-GAN [39] 및 TranAD [8].

대조 학습 기반 방법은 표현 간의 불일치를 통해 이상 징후를 감지하도록 설계되었습니다.

동일한 입력의 다양한 측면에서 파생됩니다. TimeAu-toAD [40] 및 CTAD [41]은 음성 샘플을 구성합니다.

노이즈를 주입하고 원래의 부정 불일치에 따라 이상 징후를 판단합니다. AnoTran [42]은 이상 징후 탐지에서 분포 변화를 완화하기 위해 사전 표현과 연관 표현 간의 거리를 최소화합니다. 반대로 DCdetec-tor [43]은 사전 지식을 피하기 위해 서로 다른 패치 크기 기반 연관 표현 간의 거리를 최소화합니다.

특히, 기존 접근 방식은 시간적 측면에만 초점을 맞추었습니다. 주파수 특징이 탐지에 있어 중요한 역할을 간과하는 것 비정상적인 패턴.

B. 마스크드 오토인코더

마스크드 언어 모델링의 성공을 바탕으로, BERT에서 제시된 마스크드 오토인코더(MAE)[44] 자기지도형 시각 학습기로서 강력한 성능을 발휘하는 것으로 부상했습니다. 이미지 표현. 구체적으로, MAE는 무작위로 마스크합니다. 이미지 내의 토큰을 사용하여 인코더가 학습할 수 있도록 합니다. 마스크되지 않은 토큰과 마스크된 토큰을 복구하는 디코더.

STMAE[45]는 MAE 패러다임을 비디오로 확장합니다. 모델링을 통해 놀라운 성능을 달성했습니다. MAE는 다음과 같습니다. 비유클리드 기하학을 비롯한 다양한 분야에서 응용 사례를 발견했습니다. 데이터 모델링(GraphMAE [46]) 및 시계열 모델링 (STEP [47]), 기존의 무작위 기반 MAE 방법은 부족합니다. 과제별 적응성. 이에 대한 대응으로 혁신적인 적응이 이루어졌습니다.

MAERec [48]이 도입되었습니다. 더 높은 토큰을 마스크합니다.

견고한 순차적 추천을 위한 구조적 일관성

GPT-ST [49]는 클러스터 간 마스크를 사용합니다.

지식 학습 및 EMAE[50]는 학습된 의미론적 마스크를 사용합니다.

이미지의 일부를 사용하여 빠른 학습을 수행할 수 있습니다. 그러나 이러한 방법에는 다음과 같은 한계가 있습니다.

시계열 이상 탐지에 직접 적용될 수는 없습니다.

III. 서론

1) 시계열 표현: 시계열 S는 수치적 데이터를 나타내는 관측값들의 연속으로 정의됩니다.

센서 또는 기계에서 생성된 값. 형식적으로 $S =$

$\{s_1, \dots, s_t, \dots, s_S\}$, 여기서 $s_t \in \mathbb{R}^N$ 은 N개의 수치로 구성됩니다.

시간 t에서의 값들. 시계열의 길이는 S로 표시됩니다.

$|S|$ 여기서 $S \in \mathbb{R}^{|S| \times N \times N=1}$ 인 특수한 경우, S

는 단변량 시계열입니다. 주어진 S에 대해 다음을 생성할 수 있습니다.

매개변수화된 것을 사용하여 D차원 표현을 합니다.

모델 $G(\cdot, \Theta)$, 여기서 Θ 는 매개변수를 나타냅니다.

2) 문제 정의: 학습된 모델 $G(\cdot, \Theta)$ 가 주어졌을 때, 시계열 $S \in \mathbb{R}^{|S| \times N}$, 시계열 분석의 목적

이상 탐지란 관측값이 이상치인지 여부를 판단하는 것입니다.

해당 계열은 이상 현상을 보인다. 이러한 판단이 내려졌다.

D차원 표현과 레이블 $Y =$ 를 통해

$\{y_1, \dots, y_t, \dots, y_S\} \in \mathbb{R}^{|S|}$, 여기서 $y_t \in \{0, 1\}$ 이고 $y_t=1$ 입니다. t번째 관측값이 이상치임을 나타냅니다.

3) 시스템 개요: 그림 2는 시스템의 아키텍처를 보여줍니다.

당사의 TFMAE는 다음과 같은 구성 요소로 이루어져 있습니다.

• 시간-주파수 마스크. 단변량 또는

다변량 시계열의 경우, TFMAE는 윈도우 기반 시간 마스크 전략과 진폭 기반 전략을 채택합니다.

잠재적인 비정상 관측값 및 패턴을 선택적으로 제거하기 위한 주파수 마스크 전략은 다음과 같은 이점을 제공합니다.

비정상적인 편향을 피하고 서로 다른 두 가지 관점을 도출하십시오.

입력 시계열. 시간 마스크 후,

가려진 관측값은 학습 가능한 매개변수로 대체되고, 가려지지 않은 관측값은 투영됩니다.

각각 고차원 공간. 주파수 이후에

마스크를 통해 마스크된 패턴은 학습 가능한 패턴으로 대체됩니다.

매개변수를 설정한 다음 전체 시계열을 투영합니다.

고차원 공간.

• 트랜스포머 기반 오토인코더. 가려진 패턴과 관측치의 복구를 향상시키기 위해

TFMAE는 효과적인 시간 정보 처리를 위해 널리 사용되는 순차 모델링 프레임워크인 트랜스포머를 통합합니다.

학습. 주파수 마스크 기반 표현의 경우, 복구를 위해 디코더 전용 방식이 사용됩니다.

주파수 혼합으로 인해 패턴이 가려집니다.

시간적 마스크 기반 표현, 마스크되지 않은 부분

초기에 인코더를 통과하여 정상 신호를 학습합니다.

패턴을 찾습니다. 그런 다음 모든 관찰 결과를 입력으로 보냅니다.

가려진 관측값을 복구하는 데 도움이 되는 디코더.

표 I: 표기법 요약.

표기법	설명
$S, S $	입력 시계열 및 그 길이
ω_i, ω	실제 및 예측 이상 레이블
Θ, θ	학습 가능한 매개변수 및 필터
V, μ	변동계수와 평균값
$r(T), r(F), r$	시간적 마스킹, 주파수적 마스킹 및 임계값 계산의 비율
$idx(T), idx(F)$	관찰 및 빈도의 마스크된 지표
$l(T), l(F)$	마스크 처리된 관측치 수 및 빈도
X, X^*, A	주파수 표현, 업데이트된 주파수 표현 및 진폭
α, β, ω	오일러 수, 허수 단위 및 각진동수
Y, Φ, ϵ	마스킹되지 않은 시간적 표현, 마스크된 시간적 표현과 주파수적 표현
$W(F), b(F)$	위치 인코딩 학습 가능한 매개변수 및 주파수 편향
$W(T), b(T)$	투사 학습 가능한 매개변수 및 시간적 편향
W, L, D	투사 부분 시퀀스 길이, 레이어 및 잠재 차원

- 모델 훈련. 학습된 시간 정보를 얻은 후 주파수 마스킹 기반 표현의 경우, 대조 목적 함수는 콜백-라이블러 발산(KLD)을 최소화하는 데 사용됩니다.

시간적 마스킹 기반 표현은 중단됩니다.
주파수 정렬을 보장하는 대조 기능
마스킹 기반 표현을 사용한 후, 적대적 훈련을 적용하여 KLD를 최대화합니다.

시간-주파수 마스킹 기반 표현을 사용하여
주파수 마스킹 기반 표현의 기술기
저지당하는 것. 대립적 훈련은 안전장치 역할을 합니다.
불일치 과적합에 반대합니다.

위 구성 요소에 대한 자세한 내용은 제4절에 나와 있습니다. 또한, 본 논문에서 사용된 표기법은 표 II에 요약되어 있습니다.

IV. 연구 방법론

이제 각 구성 요소에 대한 자세한 내용을 제공하겠습니다.
TFMAE와 이상 탐지를 수행한 후 분석합니다.
TFMAE의 복잡성.

A. 시간-주파수 마스크

- 윈도우 기반 시간 마스킹: 현재 시계열 이상치 분석에는 재구성 패러다임이 널리 사용되고 있습니다. 탐지. 하지만 재구성 기반 방법은 다음과 같은 문제에 직면합니다. 이상 징후로부터 잘못된 정보를 학습할 위험이 있을 때 학습 단계에서 입력 시계열 데이터는 완벽한 상태가 아닙니다. 이는 이상 현상을 잘 회복시키고 정상적인 상태로 되돌리는 데 도움이 될 수 있습니다. 관찰 결과가 좋지 않습니다. 비정상적인 상황을 줄이기 위한 자연스러운 해결책은 다음과 같습니다. 편향은 이상치를 정상 패턴으로 대체하는 것입니다. 이는 다음에서 영감을 받았습니다. 다양한 분야에서 마스크드 오토인코더(MAE)[44]의 성공 필드와 그 고유한 마스킹-재구성 속성을 고려하여, 우리는 새로운 윈도우 기반 시간 마스킹 전략을 설계합니다. MAE에서 무작위 마스킹 전략을 대체할 수 있습니다.



그림 3: 윈도우 기반 시간 마스킹 개요.

잠재적인 비정상 관찰 결과를 가지고 복구합니다.
일반 정보. 윈도우 기반 시간적 세부 정보
마스킹 전략은 아래와 같습니다.
그림 3은 이 마스킹 전략의 파이프라인을 보여줍니다.
이는 처음에 슬라이딩 윈도우를 사용하여 부분 시퀀스를 추출한 다음, 로컬 통계를 측정 기준으로 사용합니다.
마스킹. 시계열에서 윈도우를 슬라이딩하여 추출하는 이유는 다음과 같습니다. 각 관측치의 하위 시퀀스는 계산된 통계입니다.
윈도우 기반 방식은 지역적 시간성을 풍부하게 하고 더욱 견고합니다.
관측값과 비교한 분포 변화에 관하여 [51]. 평균값을 직접 사용하는 것과는 다릅니다.

부분 수열의 경우, 변동 계수가 본 연구에서 채택되었습니다.
상대적인 변동 정도를 반영할 수 있는 전략
로컬 부분 시퀀스[52]. 구체적으로, 관찰이 주어졌을 때
식 1 입력 시계열 S의 특징 n과 그 부분 시퀀스
식 2 W는 슬라이딩 윈도우를 통해 샘플링됩니다.
는 슬라이딩 윈도우의 길이를 나타냅니다. 계수
n번째 부분 수열의 변동은 다음과 같이 계산됩니다.

$$v_t = \frac{1}{N} \sum_{n=1}^N \frac{1}{W} \sum_{k=t}^{t+W-1} \frac{1}{W} \left(\sum_{i=1}^n (s_{t+k} - \mu_n)^2 \right) \quad (1)$$

여기서 v_t 는 변동계수의 합을 나타냅니다.
n번째 부분 시퀀스의 N개 특징, μ_n t 평균을 나타냅니다.
n번째 부분 시퀀스에서 n번째 특징의 값, 그리고 $V \in \mathbb{R}^{|S|}$
모든 관측치의 변동계수를 포함합니다.
윈도우 크기가 커지면 변동계수가 증가합니다.
변동에 따라 미끄러지고 있습니다. 변동 계수가 클수록
이는 데이터가 더 분산되어 있음을 나타내며, 즉 국소적인 하위 시퀀스가 더 비정상적임을 의미합니다. 따라서 우리는 부분집합을 선택합니다.
 $r(T)$ % 변동계수가 큰 관측치
비정상적인 관찰 편향을 줄이기 위한 후보 이상치로 사용됩니다.
더욱이, 우리의 마스킹 전략은 변화에 영향을 받지 않습니다.
데이터의 척도, 왜냐하면 변동계수는
평균값으로 정규화됩니다. 수학적으로, 지수는
가려진 관측값은 다음과 같이 공식화할 수 있습니다.

$$idx(T) = T \text{ opIndex}(V, l(T)) \quad (2)$$

여기서 $l(T) = r(T) \% \times |S|$ 이고 $T \text{ opIndex}(\cdot, l(T))$ 는 다음을 반환합니다.
첫 번째 입력에서 상위 $l(T)$ 값을 갖는 인덱스, 따라서
 $idx(T) \in \mathbb{R}^{|l(T)|}$ 시간 인덱스의 부분 집합입니다. 얻은 후에
마스킹 처리된 관측치의 지표를 얻기 위해 학습 가능한 방법을 사용합니다.
매개변수 기반 벡터 $m(T) \in \mathbb{R}^D$ 를 마스크된 표현으로 사용
그리고 마스크 처리되지 않은 관측값을 변환하기 위한 선형 투영법
더 나은 모델링을 위해 잠재 공간으로 변환합니다. 시간적 마스크가 해제되었습니다.

입력 $U \in \mathbb{R}(|S| \times |T|) \times D$ 및 시간 마스크 입력 $P \in \mathbb{R}(|T|) \times D$ 는 다음과 같이 계산됩니다.

$$u_t = W(T) \cdot s_t + b(T), \quad \text{여기서 } t \in \text{idx}(T)$$
$$p_t = m(T), \quad \text{여기서 } t \in \text{idx}(T)$$

(3)

여기서 $W(T) \in \mathbb{R}^{N \times D}$ 및 $b(T) \in \mathbb{R}^D$ 는 선형 투영의 학습 가능한 매개변수입니다.

FFT 기반 가속. 효율성이 유지된다는 점을 고려할 때 이상 탐지에서 핵심적인 고려 사항으로서, 우리의 윈도우 기반 시간 마스크링 전략은 두 가지 불가피한 문제점을 야기합니다. 루프(내부 루프는 통계 계산용이고 외부 루프는 통계 계산용) (창을 움직이는 데 사용되는 함수 하나 포함)로 인해 계산 시간이 상당히 증가했습니다. 효율성의 중요성을 인식하여, 우리는 변동계수에 대한 대안적인 유도 방법을 탐구해 보십시오. 즉, 예상값과 평균값에 의존하는 방식입니다. 다른 형태는 다음과 같이 간단하게 표현할 수 있습니다.

$$v_t = \frac{\sum_{n=1}^N \mu(2)n + \mu n^2}{\mu n^2}$$

(4)

여기서 $\mu(2)$ 는 부분 수열의 제곱의 평균값을 나타냅니다. 각 윈도우의 평균값을 활용하십시오. 필터 $\theta \in 1W$ 를 S 에 슬라이딩하여 얻을 수 있습니다(즉, 시계열에 대해 1 커널을 사용한 컨볼루션을 적용합니다. 변동계수 계산의 가속도는 다음과 같습니다. 고속 푸리에 변환(FFT)을 통해 얻어짐 Wiener-Khinchin 정리[53]:

$$V = \sum_{n=1}^N v^{-n}, \text{ 여기서 } v^{-n} = \frac{F^{-1}(F(sn^2) \cdot F(\theta)) + (F^{-1}(F(sn) \cdot F(\theta)))^2}{F^{-1}(F(sn) \cdot F(\theta)) \cdot W}$$

(5)

여기서 $v^{-n} \in \mathbb{R}^{|S|}$ 는 n 번째 특징의 변동 계수를 나타내고, 식 (5)는 요소별 덧셈입니다. 다음으로, $F(\cdot)$ 와 $F^{-1}(\cdot)$ 는 FFT와 그 역연산을 나타냅니다. 따라서 두 개의 루프는 FFT 연산으로 대체되며, 이는 병렬 실행 시 $O(|S| \log(|S|))$ 의 복잡도를 갖습니다.

2) 진폭 기반 주파수 마스크링: 우리의 방식은 다음과 같습니다. 윈도우 기반 시간 마스크링은 잠재력을 효과적으로 필터링합니다. 비정상적인 관찰 결과, 다양한 패턴 이상이 지속되고 있습니다. 계절적 이상 및 추세 이상 현상을 포함한 시계열 분석. 이 문제를 해결하기 위해 새로운 주파수 마스크링 전략을 소개합니다. 입력 시계열에 직접 적용하여 완화하는 것을 목표로 합니다. 비정상적인 패턴 편향. 특히, 우리는 빈도 분석을 수행하기로 했습니다. 시간 자체가 아니라 원래 시계열에 마스크링을 적용합니다. 시리즈 후 시간적 마스크링. 이 이중 채널의 설계 이를 통해 시간적 마스크링 후에도 비정상적인 패턴을 유지할 수 있습니다. 주파수 마스크링 후 비정상적인 관찰 결과가 나타났습니다. 의도적인 선택은 대조 학습의 필요성에 뿌리를 두고 있습니다. 이상 징후를 감지하기 위한 서로 다른 표현 방식.

그림 4는 주파수 마스크링 과정을 보여줍니다. 먼저, 잠재적인 비정상 패턴을 마스크링 하기 위해, 시계열은 주파수 기반 표현으로 변환됩니다. 주파수 영역은 패턴 변화에 대한 민감도가 높고 패턴 업데이트가 용이하기 때문에 선택되었습니다[13].



그림 4: 진폭 기반 주파수 마스크링 개요.

주어진 입력 시계열 S 에 대해, 그 주파수 표현은 다음과 같습니다. $X \in \mathbb{C}^{|S|} \times N$ 은 각 특징에 이산 푸리에 변환(DFT)을 적용하여 얻습니다. 수학적으로 주파수는 다음과 같습니다. 스펙트럼 x_n 각주파수 ωn 을 갖는 특징 n 다음과 같이 공식화됩니다:

$$x_n = \sum_{t=1}^{|S|} i^{(sn)} e^{-j\omega n t}$$

(6)

여기서 e 와 j 는 각각 오일러 상수와 허수 단위입니다. 각각. 이전의 주파수 기반 시계열 모델링 이 방법들은 종종 고주파 성분(각도)을 제거합니다. 높은 주파수가 잡음을 의미한다는 가정 하에, i 값이 큰 주파수를 갖는 경우가 많습니다. 그러나 본 논문에서는 다음과 같이 주장합니다. 빈도만으로는 판단 기준으로 삼기에 불충분합니다. 비정상적인 패턴. 첫째, 특정 고빈도 작동, 예를 들어, 서버 클러스터에 로그를 기록하는 것은 보존되어야 합니다. 둘째, 추세 및 형태 이상은 저주파로 나타날 수 있습니다. 시계열 데이터에는 여전히 여러 요소가 존재합니다. 이러한 점을 고려하여 주파수 대신 진폭을 사용합니다. 보다 포괄적인 분석을 가능하게 하는 마스크링 기준 빈도 중요도 평가 시, 다음과 같은 요소를 고려합니다. 존재 기간 및 시간적 크기[29]와 같이, 그림 4의 마스크된 곡선. 입력의 진폭 $A \in \mathbb{C}^{|S|} \times N$ 시계열은 다음과 같이 계산할 수 있습니다.

$$a_n = R2[xn] + J2[xn]$$

(7)

여기서 $R[xn]$ 및 $J[xn]$ 는 실수 부분과 허수 부분을 나타냅니다. 각각의 빈도입니다. 마지막으로 $r(F) \%$ 의 부분집합을 선택합니다. 작은 진폭을 가진 주파수는 마스크 패턴으로 나타납니다. 규모가 더 작고 존속 기간이 더 짧습니다. 수학적으로는, 선택된 주파수의 지수는 다음과 같이 표현될 수 있습니다.

$$\text{idx}(F)_n = \text{TopIndex}(a_n, l(F)) = r(F)$$

(8)

내가 (F) 인 곳 $\% \times |S|$ 및 $\text{idx}(F) \in \mathbb{R}(|F|) \times N$ 시간 영역과 대조적으로. 마스크된 및 마스크되지 않은 표현은 분리될 수 있으며, 주파수는 다음과 같습니다. 시간 영역으로 되돌아간 후 혼합되었습니다. 따라서, 기존의 MAE 패러다임은 일반적으로 다음과 같이 모델링합니다. 마스크를 벗기고 모든 관측을 순차적으로 수행하면 주파수 영역에서 여러 가지 어려움에 직면하게 됩니다. 이러한 문제를 해결하기 위해 우리는 학습 가능한 벡터 $m(F) \in \mathbb{C}^N$ 을 직접 사용하여 대체합니다. 시간 영역으로 변환하기 전에 주파수를 마스크합니다. 따라서 대체된 표현은 다음과 같이 구성될 수 있습니다.

$$x_{\text{in}} = \begin{cases} m(F)_n & [n, i] \in \text{idx}(F) \\ x_n & [n, i] \notin \text{idx}(F) \end{cases}$$

(9)

여기서 $X \in \mathbb{C}^S \times \mathbb{N}$ 은 학습 가능한 것에 대한 정보를 캡슐화합니다. 마스크된 주파수와 마스크되지 않은 원래 주파수. 변환하려면 주파수 표현을 원래의 시간 영역으로 변환 X 에 대해서는 역 이산 푸리에 변환(IDFT)이 사용됩니다. 또한, 선형 투영을 이용하여 변환을 수행합니다. 주파수 마스크 기반 시계열을 잠재 공간으로 변환하여 더 나은 모델링을 구현합니다. 수학적으로 표현하면 $F \in \mathbb{R}^S \times D$ 입니다. 주파수 마스크 후의 결과는 아래와 같습니다.

$$f_t = W(F) \left(\sum_{i=1}^S \left(\frac{e^{j \frac{2\pi}{S} i t}}{S} \right) \right) + b(F) \tag{10}$$

여기서 $W(F) \in \mathbb{R}^{N \times D}$, $b(F) \in \mathbb{R}^D$ 는 학습 가능한 매개변수입니다. 완전히 연결된 네트워크의 일부입니다.




그림 5: 왼쪽: 트랜스포머 기반 디코더 전용 오토인코더 마스크된 주파수를 복구하는 그림으로, ⊕은 요소별 덧셈을 나타냅니다. 오른쪽 그림은 마스크된 관측값을 복원하기 위한 트랜스포머 기반 오토인코더를 보여줍니다. ||는 삽입을 나타냅니다. 가려진 표현을 학습된 가려지지 않은 표현으로 변환합니다.

B. 트랜스포머 기반 오토인코더

1) 주파수 마스크 기반 오토인코더: 이 섹션에서는, 우리는 바닐라 트랜스포머 기반 디코더를 사용하여 복구합니다. 시간적 의존성을 포착하는 데 있어 트랜스포머의 효율성에서 영감을 얻어 마스크된 주파수를 사용합니다[54]. Informer[55], PatchTST[56], AnoTran[42]에 의해 입증되었습니다. 및 TranAD [8] 모델. 주파수 마스크 기반 오토인코더에서 디코더 전용 아키텍처를 채택하기로 한 결정 가려진 주파수와 가려지지 않은 주파수가 혼합되어 발생합니다. IDFT 이후에. 또한, 그림 5의 왼쪽 부분에 나타난 바와 같이, 일반 Transformer는 위치 인코딩을 포함합니다. 모듈과 그 후속 L계층 셀프 어텐션 모듈. 위치 인코딩. 일반적인 패러다임을 따릅니다. 트랜스포머는 절대 순서 정보를 통합합니다. 정현파를 사용하여 표현 F 에 대한 관찰 수렴 속도를 높이기 위한 함수입니다. 구체적으로, t 번째 표현의 i 번째 차원 값은 $f(t)_i$ 로 표시됩니다. 원래 표현 f_i 를 더하여 얻은 것

해당 위치 인코딩 c_i 위치의 세부 사항 인코딩은 다음과 같이 공식화됩니다.

$$f(t)_i = f_i + c_i \quad \text{여기}$$
$$c_i = \begin{cases} \sin(t/10000^{2i/D}) & i \text{ 짝수} \\ \cos(t/10000^{2(i-1)/D}) & i \text{ 홀수} \end{cases} \tag{11}$$

여기서 $F(0) \in \mathbb{R}^S \times D$ 는 인코딩으로 장식된 출력을 나타냅니다. 자기 주의. 그림 5에서 볼 수 있듯이 각 주의 계층은 이 시스템은 내적 셀프 어텐션 메커니즘과 피드포워드 네트워크로 구성됩니다. l 번째 레이어에서 입력 $F(l-1)$ 은 초기에는 다음과 같습니다. 쿼리 $Q(l) \in \mathbb{R}^S \times D$, 키 $K(l) \in \mathbb{R}^S \times D$ 로 투영, 그리고 값 $V(l) \in \mathbb{R}^S \times D$ 는 세 개의 선형 투영을 통해 얻어집니다. 그 다음으로는, 관심도 가중치, 즉 각 요소 간의 상관관계가 있습니다. 관찰값은 곱셈을 통해 계산됩니다. 쿼리 $Q(l)$ 및 키 $K(l)$ 마지막으로, 값 $V(l)$ 은 시간적입니다. 주의력 가중치에 따라 향상됩니다. 수학적으로는, t 번째 관찰에 대한 자기 주의의 표현 l 번째 층은 다음과 같이 표현할 수 있습니다.

$$f(l) = \frac{\sum_{i=1}^S \left(e^{\frac{q(i) \cdot k(i)}{\sqrt{D}}} \right)}{\sum_{i=1}^S \left(e^{\frac{q(i) \cdot k(i)}{\sqrt{D}}} \right)} \tag{12}$$

여기서 $F(l) \in \mathbb{R}^S \times D$ 는 l 번째 셀프 어텐션의 표현을 나타냅니다. 안정적인 학습을 보장하고 셀프 어텐션의 일반화 성능을 향상시키기 위해 잔여 연결을 도입했습니다.

피드포워드 네트워크. 공식은 다음과 같습니다.

$$F^-(l) = \text{LN}(F(l-1)) + F(l-1) \tag{13}$$
$$F(l) = \text{LN}(F^-(l) + \text{MLP}(F^-(l))) \quad \text{여기서 } \text{LN}(\cdot)$$

과 $\text{MLP}(\cdot)$ 는 레이어 정규화를 나타냅니다. 그리고 각각 다층 퍼셉트론입니다. $F^-(l) \in \mathbb{R}^S \times D$ 및 $F(l) \in \mathbb{R}^S \times D$ 는 잔여 연결 이후의 표현입니다. tion 및 피드포워드 네트워크.

2) 시간적 마스크 기반 오토인코더: 이 섹션에서는, 우리는 표현 모델링 과정에 대해 자세히 설명합니다. 시간적 마스크 후. 그림 5의 오른쪽 부분에 나타난 바와 같이, 마스크되지 않은 관측값은 처음에 다음과 같은 과정을 거쳐 처리됩니다. 정상적인 시간 패턴을 학습하기 위한 트랜스포머 기반 인코더. 이후, 모든 관측 데이터가 입력됩니다. 마스크된 관측값을 복구하기 위한 트랜스포머 기반 디코더 학습된 정상 패턴을 통해. 인코더. 디코더만 있는 설계와는 다릅니다. 주파수 영역에서, 마스크되지 않은 시간 입력 U 는 처음에 다음과 같습니다. 인코더에 의해 처리되어 정상적인 시간 패턴을 얻습니다. 구체적으로, U 는 처음에 사인파로 장식됩니다. 위치 인코딩을 거쳐 L-레이어를 통해 모델링되었습니다. 인코더는 시간 정보의 전파를 용이하게 합니다. 컨텍스트에서 현재 상태로. 인코더를 거친 후, 마스크되지 않은 학습된 표현 $U(l) \in \mathbb{R}^S \times D$ 관찰 결과가 얻어집니다. 디코더. 주파수 보기와 유사하게 전체 세트가 표시됩니다. 관찰(즉, 인코딩된 마스크되지 않은 관찰과 학습 가능한 마스크된 관찰) 관찰값은 Transformer 기반 디코더에 사용됩니다. 디코더에 입력되는 정현파 위치 신호

학습 가능한 벡터 기반 마스크 표현에는 위치 정보가 부족하기 때문에, 마스크된 관측값에는 원래 시계열에서의 위치를 기반으로 인코딩이 추가됩니다. 그 후, 마스크된 관측값의 디코레이티드 표현이 마스크되지 않은 관측값의 인코딩된 표현에 삽입됩니다. 그런 다음 두 표현을 디코더에 입력하여 인코더에서 학습된 정규 패턴을 통해 마스크된 관측값을 복원합니다. 마지막으로, L층 디코더를 거쳐 모든 관측값에 대한 표현 $P(L) \in \mathbb{R}^{|S| \times D}$ 를 얻습니다.

C. 모델 훈련

이 섹션에서는 시간적 관점과 주파수적 관점이라는 두 가지 서로 다른 관점의 표현을 사용하여 TFMAE를 학습시키는 적대적 학습 강화 대조 목적 함수를 공식화합니다.

1) 대조 목적 함수: 재구성 오류는 이상 탐지 작업에서 기본적인 손실 함수로 사용되어 왔지만, 시계열 분포 변화라는 지속적인 문제로 인해 효율성이 저해됩니다. 시계열 분포 변화란 훈련 데이터와 비교하여 테스트 데이터의 분포가 변하는 것을 의미하며, 이는 이전에 학습된 패턴으로부터 미지의 데이터를 재구성하는 데 어려움을 초래합니다. 즉, 이상 점수가 높은 관측치가 반드시 비정상적인 것이 아니라 미지의 데이터일 수도 있습니다. 시계열 분포 변화의 부정적인 영향을 완화하기 위해, 본 논문에서는 TFMAE를 훈련하기 위한 새로운 대조 목적 함수를 제안합니다. 이 함수는 원본 시계열과 재구성된 시계열 간의 차이 최소화를 시간-주파수 마스킹 기반 표현과 시간-주파수 마스킹 기반 표현 간의 차이 최소화로 대체합니다. 이는 입력 데이터가 미지의 데이터인 경우에도 동일한 시계열의 시간-주파수 마스킹 기반 표현은 시간-주파수 일관성에 따라 일관성을 유지하기 때문입니다[57]. 또한, 우리의 대조 목적 함수에서는 시간 주파수 마스킹 관점에서 표현의 불일치를 최소화하기 위해 양성 샘플만 사용되며, 이는 양성-음성 쌍을 사용하는 기존의 대조 학습[58]과는 대조적입니다. 훈련 단계에서는 정상-복구된 이상 표현과 원래-비정상 표현 간의 불일치가 일관된 정상 관찰에 비해 감소에 더 저항적이기 때문에 이상이 점진적으로 강조됩니다.

따라서 차이가 큰 관측치는 추론 단계에서 이상치로 감지됩니다. 수학적으로, 대조 목적 함수는 다음과 같이 계산됩니다.

$$L = DKL(P(L), F(L)) + DKL(F(L), P(L))$$
 여기서 $DKL(\cdot, \cdot)$ (14)

은 쿨백-라이블러 발산을 나타내며, 이는 두 표현 사이의 거리를 계산하고 시간-주파수 마스킹 기반 표현 간의 불일치를 반영하는 데 사용됩니다.

2) 적대적 학습: 표 IV에서 볼 수 있듯이, 대조 학습만을 활용하는 것은 과적합 현상(예: 시간 영역에서 비정상 주파수의 표현이 주파수 영역에서 해당 정상 복구 주파수의 표현과 유사해지는 경향)으로 인해 최적의 결과를 얻지 못합니다.

대조 학습은 정상 관측치 간의 차이를 최소화하고 이상치 간의 차이를 최대화하려는 우리의 목표와 상충되는 현상을 초래합니다. 이러한 문제를 해결하기 위해, 우리는 목적 함수에 적대적 메커니즘을 도입하여 대부분의 딥러닝 작업에서 견고성과 일반화 성능을 향상시켰습니다. TFMAE에서 적대적 학습은 정상 표현 간의 유사성을 높이는 동시에 비정상 표현과 그에 대응하는 정상 표현 간의 상당한 차이를 유지하는 것을 목표로 합니다. 수학적으로, 우리의 적대적 대조 함수는 다음과 같이 표현됩니다.

$$L = \text{최소화}_{F(L), P(L)} (DKL(P(L), F(L)) + DKL(F(L), P(L)))$$
 (15)

여기서 max와 min은 시간-주파수 마스킹 기반 표현 간의 차이가 증가 및 감소를 나타냅니다. 훈련 단계에서 비정상 표현과 정상 표현 간의 차이 차이는 점차 커지는데, 이는 비정상 표현의 차이를 줄이기는 어렵고 늘리기는 쉽기 때문입니다. 또한, 시간 마스킹 기반 표현은 원본 정보를 더 많이 보존하므로 적대적 훈련에서 레이블로 사용하기에 더 적합하기 때문에, 시간 및 주파수 마스킹 기반 표현의 그래디언트는 각각 최소화 및 최대화 단계에서 멈춥니다. 그림 8에서 볼 수 있듯이, 적대적 대조 목적 함수는 이상치에서 큰 차이를 출력할 수 있습니다.

D. 이상 탐지 본 대조 설계에서

시간-주파수 마스킹 기반 표현 간의 차이 크기는 이상 발생 가능성과 직접적으로 관련됩니다. 따라서 추론 단계에서 대조 차이를 이상 점수로 사용합니다. 입력 관측치 $st \in \mathbb{R}^N$ 에 대한 점수는 다음과 같이 계산할 수 있습니다: $\|f(L)$

$$\text{점수}(st) = DKL(p_{\text{티}}^{(\text{열})}) + DKL(f(L)_{\text{티}} \| p_{\text{티}}^{(L)})$$
 (16)

궁극적으로 관측값은 이상 점수와 미리 정해진 임계값 δ 를 기준으로 평가됩니다. 즉, 점수가 임계값을 초과하면 이상이 감지됩니다. 감지된 레이블 $Y \in \mathbb{R}^{|S|}$ 는 아래와 같습니다.

$$y_t = \begin{cases} 1 & \text{점수}(st) \geq \delta \\ 0 & \text{점수}(st) < \delta \end{cases}$$
 (17)

E. 복잡도 분석 본 절에서는 원도

우 기반 시간 마스킹, 진폭 기반 주파수 마스킹, 그리고 트랜스포머 기반 오토인코더로 구성된 TFMAE의 복잡도를 분석합니다. 원도우 기반 시간 마스킹의 시간 복잡도는 FFT 연산을 통해 $O(N|S|W)$ 에서 $O(N|S|\log(|S|))$ 로 최적화되었으며, 진폭 기반 주파수 마스킹의 DFT 알고리즘 또한 FFT 연산을 통해 $O(N|S|\log(|S|))$ 의 복잡도로 가속화될 수 있습니다. 따라서, 본 논문에서 제안하는 TFMAE의 시간 복잡도는 트랜스포머의 제공 자기 어텐션으로 인해 $O(LD|S|^2)$ 에 의해 지배되며, 이는 최첨단 방법들과 비교했을 때 동등하거나 그 이상입니다.

표 II: 데이터셋 통계. "AR"은 이상치 비율을 나타냅니다.

데이터 세트	출처	유형	차원	#학습	#검증	#추론	AR(%)	
MSL	NASA 우주	다변수 eBay 서버	55	46653	11664	73729	105984 26497 10.5	
PSM		다변량	25	87841	566724	141681	708420 396000 27.8	
SMD	인터넷 서버	다변량	38	99000	449919	108146	27037 427617 4.2	
가방계 데이터	수처리 다변수		51	40000	10000	50000	40000 10000 50000 12.1	
스맵	NASA 우주	다변량	25					12.8
NIPS-TS-글로벌	인조	단변량						5.0
NIPS-TS-계절별	인조	단변량	11					5.0

V. 실험

TFMAE의 효과성과 효율성을 검증하기 위해, 우리는 7개의 데이터셋에 대해 종합적인 실험을 수행합니다. 다음 여섯 가지 연구 질문에 답하십시오.

- 연구 질문 1: 당사의 TFMAE는 다양한 데이터 세트에서 기준선 대비 우수한 성능을 보여주는가?
- 연구 질문 2: TFMAE 내의 구성 요소(예: 오토인코더)는 이상 탐지 성능에 어떤 영향을 미칩니까?
- 연구 질문 3: 시간 주파수 마스킹은 얼마나 효과적인가? TFMAE에서 설계된 전략은 무엇인가요?
- 연구 질문 4: 다양한 하이퍼파라미터, 특히 시간 주파수 마스킹 비율을 조정하면 어떤 영향을 미칩니까? TFMAE의 성능은 어떻게 됩니까?
- 연구 질문 5: TFMAE는 합리적인 이상치 점수를 출력하는가?
- 연구 질문 6: TFMAE는 이상 탐지에서 얼마나 효율적인가?

A. 실험 장치 구성

1) 벤치마크 데이터셋: 본 논문에서는 7개의 벤치마크 데이터셋을 선정했습니다. 널리 사용되는 시계열 이상 탐지 데이터 세트를 평가하기 위해 TFMAE의 효과. 이 데이터 세트에는 5개가 포함됩니다. 실제 데이터셋 1개와 합성 데이터셋 2개: MSL (Mars Science 실험실 로버) 및 SMAP (토양 수분 능동 수동 위성)은 모두 NASA에서 출시되었습니다[59]. 일련의 사건과 그 안에 있는 이상 경보는 사건 기록부에 의해 기록됩니다. 우주선 모니터링 시스템에서 예상치 못한 이상 현상이 보고되었습니다. PSM (Pooled Server Metrics)은 eBay에서 출시되었으며[60], eBay의 여러 서버 노드에서 수집된 시계열 데이터를 포함합니다. SMD (서버 머신 데이터셋) [6]은 보다 큰 데이터셋이다. 앞서 언급한 사항들을 포함하여 5주간의 일정이 진행됩니다. 인터넷 서버 노드의 시계열. SWaT (Secure Water) 치료)는 지속적인 운영 하에 중요 인프라 시스템의 데이터를 기록합니다[61]. NIPS-TS-Global 및 NIPS-TS-Seasonal은 잘 설계된 규칙[62]에 의해 생성된 합성 데이터 세트와, 전역 관측 이상치를 나타냅니다. 그리고 계절적 이상 현상입니다. 자세한 정보는 다음과 같습니다. 이러한 데이터 세트에 대한 정보는 표 II에 제시되어 있습니다.

2) 측정 지표: 시계열 이상 탐지 성능 비교 성능 평가를 위해 널리 사용되는 세 가지 평가 지표를 사용합니다. 정밀도(P), 재현율(R), F1 점수(F1). 일관성 있음 문헌 설정에서 우리는 점 조정 전략을 적용합니다. 연속적인 이상 징후가 있는 경우 탐지 결과를 얻기 위해 해당 구간에서 단일 관측값이 감지되면 식별됩니다.

3) 기준선: 본 연구에서 제안하는 TF-MAC를 다음 6개 범주 기반의 14개 기준선과 광범위하게 비교합니다.

- 밀도 기반 방법: LOF [20]는 로컬을 계산합니다. 밀도 편차 및 낮은 밀도를 갖는 관측값은 다음과 같습니다.

- 이상 현상. DAGMM [22]은 또한 가우시안을 활용합니다. 혼합 모델을 사용하여 데이터 밀도를 계산합니다.
- 트리 기반 방법: IForest [63]는 선택 시간 복잡도를 갖는 격리 트리를 사용하여 이상 감지를 수행합니다.
- 클러스터링 기반 방법: DSVDD [26]는 심층 네트워크를 사용하여 표현을 도출하고 이상 징후를 감지합니다. 클러스터까지의 거리를 통해. THOC [27]는 확장된 순환 신경망을 통해 계층적 정보를 추출합니다. 이 네트워크는 단일 클래스 목적 함수를 사용하여 모델을 학습시킵니다. 이상 탐지를 위한 클러스터링된 초구에 대하여.
- 재구성 기반 방법: OmniAno [6]는 다음을 활용합니다. 정규화된 흐름은 이상 탐지를 위한 시계열 재구성을 위해 LSTM을 항상시킵니다. TimesNet [7]은 1D를 변환합니다. 시계열을 여러 2D 텐서로 변환한 다음 컨볼루션 백본을 사용하여 시계열을 재구성합니다. GPT4TS [64] 대규모 언어 모델과 시계열 데이터를 결합합니다. 이상 탐지 작업.
- 적대적 재구성 기반 방법: USAD [36] 본 논문에서는 두 개의 디코더를 기반으로 하는 오토인코더를 제안하고 사용합니다. 빠른 훈련을 위한 적대적 방식. BeatGAN [35] 적대적 강화 컨볼루션 모델을 활용하여 감지합니다. 시계열 이상. DAEMON [37]은 두 개의 판별자를 사용하여 오토인코더를 적대적으로 학습한 다음 견고한 재구성 시계열을 도출합니다. TranAD [8] 트랜스포머 프레임워크를 활용하여 시계열을 인코딩합니다. 그런 다음 두 모델에 적대적 학습을 도입합니다. 디코더 기반 모델을 사용하여 견고성을 향상시켰습니다.
- 대조 기반 방법: AnoTran [42]은 시간을 인코딩합니다. 이전 협회 및 시리즈 협회에서 발행한 시리즈, 그런 다음 두 표현 간의 차이를 이용하여 이상을 구별합니다. DCdetector [43]는 이를 활용합니다. 긍정적 대조 학습은 표현에 영향을 미칩니다. 다양한 패치 크기를 사용한 시계열 분석을 통해 이상 징후를 감지합니다.

우리는 기준선에서 최상의 성능을 내는 구성을 활용합니다. 공식 코드를 실행하는 데 사용하는 동일한 컴퓨터에서 실행하기 위해 우리의 모델입니다.

4) 하이퍼파라미터 설정: TFMAE는 다음을 통해 학습됩니다. 초기 학습률이 0.0001인 Adam 최적화기[65] 에포크는 1, 배치 크기는 64로 설정했습니다. 오토인코더에서는 다음과 같이 설정합니다. 트랜스포머 레이어 수는 3개이며, 은닉 기능은 128개입니다. 차원. 윈도우 기반 시간 마스킹 프로세스 동안 슬라이딩 윈도우의 길이는 10으로 설정되어 계산됩니다. 지역 통계적 특징을 고려했습니다. 또한, 각 데이터셋의 특성 때문에 서로 다른 시간-주파수 마스킹 비율을 설정했습니다. 특성. 자세한 설정은 그림 6에서 확인할 수 있습니다. 또한, 임계값 δ 는 $r\%$ 를 감지하여 미리 결정됩니다.

표 III: 5개의 시계열 이상 탐지 데이터 세트에 대한 주요 결과. 정밀도(P), 재현율(R) 및 F1 점수(F1)는 다음과 같습니다. 백분율로 표시됩니다. "평균"은 이 다섯 가지 데이터 세트의 평균값을 나타냅니다. 회색: 최상의 결과, 굵은 글씨: 두 번째로 좋은 결과.

데이터셋		가법적 데이터				PSM				SMD					
모델	장소	피		F1		피		F1		피		F1			
LOF MOD-00	15.37 94.15 26.42	68.77 93.86 79.38 39.52 10.57 15.72													
아이포레	ICDM-08 80.31	81.90 81.09 95.74 85.83 90.51 47.18 72.66 57.21													
스트 DSVDD	ICML-18 91.26 80.49	85.54 72.88 88.99 80.13 56.06 72.56 63.25													
DAGMM ICLR-18	26.19 87.41 40.31	92.07 90.09 91.07 65.39 86.17 74.36													
BeatGAN IJCAI-19	92.46 79.06 85.23	96.58 90.16 96.93 26.77 11.77 60.77 36													
올니아노 KDD-19	71.65 83.76 77.23	95.71 90.09 92.82 72.58 83.67 77.73													
미국 KDD-20	57.76 83.76 68.37	97.63 98.08 97.86 90.96 90.04 90.99													
THOC NeurIPS-20	83.10 83.54 83.32	78.33 88.60 83.15 69.08 77.30 72.96													
대문 ICDE-21		90.86 78.50 84.23 97.57 86.22 91.55 78.08 77.91 77.99													
AnoTran	ICLR-22	83.85 100.0 91.22 96.74 97.73 97.23 90.90 81.20 85.78													
TranAD VLDB-22	94.23 94.36 94.29	97.44 98.19 97.92 74.30 81.65 77.80													
타임스넷 ICLR-23	81.83 97.32 88.90	97.64 98.22 97.93 77.67 81.58 79.58													
DC 검출기 KDD-23	93.25 100.0 96.51	97.40 98.16 97.78 85.37 82.85 84.09													
GPT4TS NeurIPS-23	90.13 95.60 92.79	97.39 94.13 95.73 TFMAE									89.60 81.13 85.16				
		96.77	100.0 98.36 98.06 99.06 98.56 91.41 91.07 91.24												
데이터셋		MSL				스맵				평균					
모델	장소	피		F1		피		F1		피		F1			
LOF MOD-00	63.46 90.05 74.45	79.62 85.26 82.34 53.35 74.78 55.66													
아이포레	ICDM-08 76.95	90.77 83.29 88.60 56.36 68.90 77.76 77.50 76.20													
스트 DSVDD	ICML-18 87.93 86.93	87.43 87.34 58.78 70.27 79.09 77.55 77.32													
DAGMM ICLR-18	90.05 86.93 88.46	87.58 56.31 68.55 72.26 81.38 72.55													
BeatGAN IJCAI-19	OmniAno	91.44 85.42 88.33 93.91 55.41 69.70 90.30 77.53 82.78													
KDD-19	90.82 86.47 88.59 92.34	56.18 69.85 84.62 80.03 81.24													
미국 KDD-20	91.24 94.73 92.96	92.02 65.78 76.71 85.92 86.48 85.38													
THOC NeurIPS-20	90.30 75.99 82.53	90.08 55.50 68.69 82.18 76.19 78.13													
대문 ICDE-21	91.47 87.37 89.37 84.95	56.49 67.86 88.59 77.30 82.20													
아노트란 ICLR-22	91.95 96.50 94.17	94.01 86.72 90.22 91.49 92.43 91.72													
TranAD	VLDB-22 90.72	94.73 92.68 93.12 71.33 80.78 89.96 88.05 88.69													
TimesNet ICLR-23	87.32 85.42 86.36	86.47 65.48 74.53 86.19 85.60 85.46													
DC 검출기 KDD-23	92.08 94.44 93.24	93.18 98.84 95.93 92.26 94.86 93.51													
GPT4TS NeurIPS-23	82.08 85.45 83.73	88.78 64.72 74.86 89.60 84.21 86.45													
TFMAE	92.83 97.59 95.15 94.71	99.19 96.90 94.76 97.38 96.04													

데이터를 이상치로 간주했습니다. 구체적으로, MSL에 대해 $r = 0.9\%$ 로 설정했습니다. PSM은 0.75%, SMAP은 0.45%, SMD는 0.3%, SWaT는 0.3%입니다.

5) 구현 세부 사항: TFMAE 실험 모든 기준선 측정은 하나의 장비를 갖춘 기계에서 수행됩니다.

Intel(R) Xeon(R) Gold 6230R CPU @ 2.10GHz 및 NVIDIA GeForce RTX 3090 GPU 카드와 PyTorch 1.12.1. TFMAE의 소스 코드는 다음에서 확인할 수 있습니다.

<https://github.com/LMissher/TFMAE>. 공정한 비교를 위해, 모든 방법의 임계값은 검증을 통해 계산됩니다. 세트.

B. 성능 비교 (RQ1)

표 III은 시계열 이상치의 성능을 보여줍니다. 5개 데이터셋에서 모든 방법을 사용한 탐지율은 다음과 같이 측정되었습니다. 정밀도, 재현율 및 F1 점수 측면에서 비교했습니다. 공정한 비교를 위해 기준선의 원래 구성을 그대로 유지했습니다. 유일한 조정 사항은 입력 길이를 100으로 고정하는 것입니다. [42]에 따라. 결과적으로 보고된 성능은 기준선은 결과와 비교했을 때 약간의 차이를 보일 수 있습니다. 원문 문헌에서 다음과 같은 주요 결과를 확인할 수 있습니다.

시간적 학습의 장점. 기준선 중에서 고려된 모델들 중에서, DAGMM으로 대표되는 딥러닝 기반 접근 방식은 상당한 이점을 보여줍니다. 고전적인 대응 모델인 LOF와 비교해 보세요. 더욱이, 성능은 다음과 같습니다. 클러스터링 기반 DSVDD 및 THOC는 활용을 통해 고급 시간 모델링 기법은 더 정확한 결과를 가져옵니다.

결과. 이러한 현상은 효과성을 강조합니다.

시간적 의존성 학습.

적대적 학습의 장점. 대조적으로

예제 재구성 기반 방법론, 적대적

재구성 기반 접근 방식(예: TranAD 및 USAD)

효능에 가인하는 뚜렷한 이점을 나타낸다

적대적 훈련의 능력, 즉, 이를 우회하는 능력

비정상적인 패턴의 재구성.

대조 학습의 장점. 표 III에서 볼 수 있듯이, AnoTran과 DCdetector는 대조 학습을 활용합니다.

이중 채널 모델을 통해 얻은 표현에 관하여, 특히 SWaT에서 눈에 띄는 우월성을 보여줍니다.

데이터셋을 재구성 기반 방법과 비교했을 때.

이 현상은 분포 변화에 가인하며, 여기서 테스트에서 동일한 시계열의 다중 시점 표현 전시 근접성을 설정하는 동안 재구성된 시계열은 다음과 같을 수 있습니다. 미지의 테스트 데이터와 상당히 차이가 납니다.

주파수 학습의 장점. Times-Net의 결과는 주파수 영역에서 특징을 활용하면 탐지 성능을 크게 향상시킬 수 있음을 보여줍니다.

시계열의 이상 현상은 시간적 특징만을 고려했을 때와 비교됩니다.

예를 들어 GPT4TS와 같은 방법론이 있습니다. 이는 이상 징후가 단순히 이상 징후만을 나타내는 것이 아니기 때문입니다. 단일 시점뿐만 아니라 패턴과 빈도로도 생성됩니다. 해당 도메인은 패턴 이상에 더 민감합니다.

탁월한 성능을 지속적으로 발휘합니다. 다음을 바탕으로 앞서 언급한 기술들을 바탕으로, 본 논문에서는 새로운 접근법인 TFMAE를 소개합니다.

표 IV: TFMAE 절제술 결과. 정밀도(P), 재현율(R), F1 점수(F1)는 %로 표시됩니다. 굵은 글씨: 본 연구팀 결과.

데이터셋	가법제 데이터		PSM		SMD		MSL P		스텝												
마터법	F1 R (Ladv 제외)		49.93	92.33	64.96	99.41	90.80	94.91	88.63	79.64	83.89	93.03	88.33	89.55	91.17	54.83	68.48	피	F1	피	F1
Lradv 포함 95.73	100.0	97.82	97.44	98.21	97.82	90.23	79.86	84.73	92.07	88.82	90.42	95.22	98.43	96.80							
Fre 제외 FD		90.36	96.22	93.20	97.59	98.47	98.03	91.96	89.36	90.65	93.06	93.18	93.12	91.69	66.02	76.76					
제외 37.40 95.44		53.74	98.72	90.77	94.58																
온도 없음 87.91	96.22	91.88	98.51	95.86	97.17	93.77	87.13	90.33	92.60	87.21	89.83	92.15	65.44	76.53							
TE 없음 94.35 98.52	96.39	97.58	99.01	98.29	90.37	88.44	89.39	92.64	94.31	93.47	94.64	98.66	96.61								
TD 제외 35.21 90.43	50.69	99.45	69.28	81.67	74.56	51.01	60.58	90.43	79.86	84.82	93.31	88.75	90.97								
TFMAE 96.77	100.0	98.36	98.06	99.06	98.56	91.41	91.07	91.24	92.83	97.59	95.15	94.71	99.19	96.90							

표 V: 마스킹 전략의 제거 결과. 정밀도(P), 재현율(R), F1 점수(F1)는 %로 표시됩니다. 굵은 글씨: 본 연구팀의 결과.

데이터셋 메	가법제 데이터				PSM		SMD		MSL		스텝	
트릭(MT)	II	F1			II	F1	II	F1	II	F1	II	F1
제외) 94.25 100.0	97.04 97.48 98.27 97.87 91.51 90.06	90.78 92.88 94.90 93.88 95.10 89.54 92.24										
SMT 포함 95.79	99.10 97.42 97.65 98.45 98.05 91.48 88.01 89.71 92.49 95.40 93.92 94.24 98.26 96.21											
RMT 포함 94.72	99.57 97.09 97.54 98.40 97.97 90.28 88.93 89.60 93.00 90.84 91.91 93.25 99.08 96.08											
MF 없음 95.28	99.06 97.13 97.70 98.61 98.15 91.31 89.21 90.03 92.45 96.29 94.33 94.15 97.52 95.81											
HMF 포함 95.88	98.88 97.35 97.62 98.87 98.25 91.26 85.01 88.09 92.67 95.20 93.92 93.53 98.31 95.86											
RMF 포함 96.08	98.17 96.11 97.72 98.45 98.08 89.92 90.00 89.95 92.50 93.51 93.00 93.69 97.82 95.71											
TFMAE 96.77	100.0 98.36 98.06 99.06 98.56 91.41 91.07 91.24 92.83 97.59 95.15 94.71 99.19 96.90											

처음에 시간 및 주파수 마스킹을 사용하는 접근 방식
오토인코더를 사용하여 오류가 없는 순수한 표현을 얻습니다.
비정상적인 패턴 및 관찰. 이후, 시간 주파수 마스킹 기반의 대조적 객관적
요소를 통합합니다.
이상 탐지 기준으로서의 기능을 수행하고 적대적 공격을 사용합니다.
과적합으로 인한 잠재적인 부작용을 완화하기 위한 훈련.
따라서 표 III에서 알 수 있듯이 TFMAE는 일관되게
모든 데이터 세트에서 최첨단 성능을 달성합니다.

C. 모델 절제 연구 (RQ2)

이 섹션에서는 다섯 가지 데이터셋을 사용하여 실험을 진행합니다.
TFMAE의 7가지 변형을 사용합니다. 이 실험의 목적은 다음과 같습니다.
모델 디자인의 효과를 보여줍니다. 세부 사항
이러한 변형에 대한 설명은 다음과 같습니다.

- "Ladv 제외 ": 이 변형은 적대적 객체를 제외합니다.
훈련 단계 동안.
- "w/ Lradv": 이 버전은 위치를 서로 바꾸는 것입니다.
방정식 15의 F (L) 및 P(L) .
- "주파수 제외": TFMAE는 주파수 관점을 제거합니다.
- "FD 없음": 주파수 디코더가 더 이상 장착되어 있지 않습니다.
- "시간적 관점 제외": TFMAE는 시간적 관점을 제거합니다.
- "TE 없음": 시간 인코더가 더 이상 탑재되지 않습니다.
- "TD 없음": 시간 디코더가 더 이상 탑재되지 않습니다.

표 IV에 제시된 절제 결과에 따르면,
다음과 같은 결과를 도출할 수 있습니다.
대립적 훈련이 가져다주는 이점. 그 결과
"Ladv 없이 " 는 성능이 크게 저하되는 것을 보여주며, 이는 다음을 시사합니다.
적대적 목표의 포함이 TFMAE를 안내한다는 점
보다 정확한 방향으로의 훈련, 즉 적대적 훈련
과적합을 방지하는 데 도움이 될 수 있습니다. 또한 성능은
"w/ Lradv" 는 시간적 마스킹 기반 방식이 더 타당함을 입증합니다.
표현 방식은 더 많은 원본 정보를 저장합니다.
주파수 마스크 오토인코더의 효과 .
"Fre 제외" 실험 결과는 대부분의 시나리오에서 다음과 같은 사실을 보여줍니다.
빈도 관점을 제거하면 상당한 감소가 발생합니다.
성능. 이러한 관찰은 효과성을 강조합니다.

우리의 대조 목적 함수의 성능을 살펴보면, "FE 없음"의 성능이 "Fre 없
음"보다 낮다는 것을 알 수 있습니다.
특정 관점에 맞는 정확한 표현을 도출하는 것이 더 중요하다는 것입니다.
단순히 이러한 관점을 제시하는 것보다 훨씬 더 중요합니다.
시간 마스크드 오토인코더의 효과. 유사 사례
주파수 관점에 있어서 시간적 관점은 필수불가결하다.
우리의 TFMAE는 "Tem 없이"의 성능과 같습니다. 또한,
"TD 없이"에서 나타난 저하된 성능에서 알 수 있듯이,
디코더는 정상적인 상황을 전달하는 데 있어 시간적 관점에서 매우 중요합니다.
시간 정보를 마스킹된 관측값으로 변환합니다.

D. 시간-주파수 마스크에 대한 조사 (RQ3)

이 섹션에서는 우리의 방법의 효과성을 검증하고자 합니다.
제한된 시간-주파수 마스킹 전략은 다음과 같은 목표를 달성하기 위한 것입니다.
이를 위해 TFMAE의 6가지 변형을 설계하고 5개의 시계열 이상 탐지 데이터
셋에 대해 실험을 수행했습니다.
이러한 변형에 대한 세부 정보는 다음과 같습니다.

- "MT 제외": 더 이상 시간적 마스킹 기능을 제공하지 않습니다.
- "SMT 포함": 이 버전은 표준 편차만 사용합니다.
관찰 내용을 숨기기 위해.
- "RMT 포함": 이 버전은 관측값을 무작위로 가립니다.
- "MF 없음": 더 이상 주파수 마스킹 기능을 제공하지 않습니다.
- "HMF 포함": 고주파를 차폐합니다.
- "RMF 포함": 이 변형은 주파수를 무작위로 마스킹합니다.

표 V에 제시된 결과에 따르면 다음과 같습니다.
결과를 도출할 수 있습니다.
윈도우 기반 시간 마스킹의 영향. 결과
"w/ RMT"는 일관되게 우리의 창 기반 방식을 나타냅니다.
시간적 마스킹은 모든 영역에서 무작위 마스킹보다 우수합니다.
데이터셋. 또한, "가계 번역 없음"의 성능은 "가계 번역 있음"과 비슷하거나 오히려
더 우수한 것으로 나타나, 이는 가계 번역이 가계 번역에 유용함을 시사합니다.
성능 향상의 핵심 요소는 "마스킹"에 있는 것이 아닙니다.
그 자체로는 아니지만 "이상 현상 은폐"에서 그렇습니다. 특히 계수는
변형은 "w/"에 비해 우수한 성능을 보여줍니다.
SMT는 데이터 스케일 변화에 덜 민감하기 때문에 사용됩니다.




그림 6: 마스크 전략에 대한 하이퍼파라미터 연구.

진폭 기반 주파수 마스크의 영향. 시간 마스크와 유사하게, 주파수 마스크 제거 ("w/o MF")의 성능은 무작위 마스크("w/ RMF")와 비교했을 때 동등하거나 오히려 더 우수합니다. 또한, 본 마스크 전략의 효과를 더욱 검증하기 위해 진폭 기반 주파수 마스크를 고주파 기반 마스크를 사용하는 변형과 비교했습니다. 표 V에서 볼 수 있듯이, "w/ HMF"는 대부분의 작업에서 TFMAE보다 성능이 떨어지는데, 이는 고주파가 이상치만을 나타내는 것이 아니라 과거 데이터에서 벗어나는 단기적인 시간적 패턴이 이상치일 가능성이 더 높다는 것을 시사합니다.

E. 하이퍼파라미터 민감도 분석 (RQ4)

그림 6과 그림 7은 하이퍼파라미터 변화에 따른 결과를 보여줍니다. 구체적으로, Transformer 레이어 수, 은닉 특징 벡터의 크기, 시간-주파수 마스크 전략의 윈도우 길이, 그리고 시간-주파수 마스크 비율을 탐색 공간에서 [1, 2, 3, 4, 5], [32, 64, 128, 256, 512], [1, 5, 10, 15, 20], 5에서 95까지 10 간격, 그리고 10에서 90까지 10 간격의 값으로 변화시키면서 탐색했습니다. 그림 7에서 볼 수 있듯이, TFMAE의 성능은 레이어 수가 증가함에 따라 처음에는 향상되다가 레이어 수가 3개를 초과하면 감소합니다. 또한, 은닉 특징 벡터의 크기를 128로 설정했을 때 TFMAE가 최적의 성능을 달성합니다. 이는 은닉 특징 벡터의 크기가 너무 클 경우 성능 저하가 발생하기 때문입니다.

특징들이 수렴을 방해할 수 있습니다. 또한, 다음과 같은 그림에서 추가적인 통찰력을 얻을 수 있습니다. 윈도우 길이 W . 이 하이퍼파라미터는 각 관

측에서 고려되는 지역 정보의 양을 조절합니다. 특히, $L=10$ 으로 설정했을 때 최적의 성능을 보이는데, 이는 짧은 부분 시퀀스가 중요한 정보를 간과하는 반면, 긴 부분 시퀀스는 전류 변동의 영향을 줄일 수 있음을 시사합니다.

또한, 원본 값으로 마스크하는 것과 동일한 $L=1$ 의 성능은 절대값이 특히 시계열 분포 변화와 같은 잠재적인 문제 상황에서 비정상적인 관측값을 효과적으로 가리지 못한다는 것을 보여줍니다.

시간적 마스크 비율 $r(T)$ 이 하이퍼파라미터는 마스크할 관측치의 비율을 결정합니다. 그림 6에서 볼 수 있듯이 SWaT, SMD, SMAP에 대한 최적 비율은 다음과 같습니다.




그림 7: 왼쪽: MSL에 대한 TFMAE의 하이퍼파라미터 연구.

오른쪽: SMD에 대한 TFMAE의 하이퍼파라미터 연구.

PSM과 MSL의 마스크 비율은 각각 25%, 5%, 65%, 65%, 55%입니다. SMD 데이터셋에서 5%와 같은 낮은 마스크 비율로 최적의 성능을 달성했음에도 불구하고, SWaT 데이터셋에서는 시간적 마스크 비율을 95%까지 높여도 유사한 결과가 관찰되었습니다. 이는 시계열 데이터가 상당한 시간적 중복성을 보여 결측치 복구가 비교적 용이하기 때문입니다.

주파수 마스크 비율 $r(F)$ 이 하이퍼파라미터는 마스크할 주파수 개수를 결정합니다. 그림 6에서 볼 수 있듯이 SWaT, SMD, SMAP, PSM 및 MSL에 대한 최적 비율은 각각 40%, 20%, 30%, 10%, 40%입니다. 주파수 마스크 비율이 클수록 시간 마스크 비율이 클 때보다 성능이 저하되는 것을 알 수 있습니다. 이러한 차이는 단일 주파수가 단일 관측치보다 더 많은 정보를 담고 있기 때문입니다. 따라서 주파수 마스크 기반 표현은 재구성하기 어려울 수 있으므로 시간 마스크와 함께 사용해야 합니다.

F. 사례 연구 (RQ5)

비정상 편향. TFMAE의 정확한 탐지 결과 생성 능력을 검증하기 위해 NIPS-TS-Seasonal 및 NIPS-TS-Global 데이터셋을 사용한 사례 연구를 수행했습니다. 그림 8에서 볼 수 있듯이, TFMAE와 DCdetector가 생성한 이상 탐지 점수는 일반적으로 구별 가능하며, 이상 징후가 있는 경우를 제외하고는 점수가 작게 유지됩니다. 또한, TFMAE는 계절적 및 지역적 관측 이상 징후를 식별할 수 있는 반면, DCdetector는 식별에 실패합니다. 이러한 차이는 비정상 편향이 모델을 오도할 수 있음을 시사하며, 본 연구에서 제안하는 마스크드 오토인코더는 이러한 문제를 효과적으로 해결합니다.




그림 8: 계절별 및 전지구적 관측 시각화
NIPS-TS-Seasonal 및 NIPS-TS-Global의 이상 현상 데이터 세트. 'DCdet'는 DC 검출기를 나타냅니다. 첫 번째 행에서 빨간색 원은 전력 관측 이상치를 나타내고, 빨간색 상자는... 계절적 이상 현상을 나타냅니다. 두 번째와 세 번째 행에서, 붉은 선은 이상 징후를 감지하는 임계값을 나타냅니다.




그림 9: 왼쪽: SMAP 검증에서 이상 점수의 누적 분포 함수(CDF) 그리고 TimesNet용 테스트 세트. 오른쪽: 이상치 점수의 누적 분포 함수(CDF) TFMAE용 SMAP 검증 및 테스트 세트.

시계열 분포 변화. 견고성 확인을 위해
시계열 데이터가 존재하는 상황에서 우리의 대조 기준 분포 변화에 관해 SMAP을 활용한 사례 연구를 수행했습니다. 데이터 세트. 그림 9에서 볼 수 있듯이 누적 점수는 검증 세트와 테스트 세트에서 TimesNet은 명확한 차이를 보여줍니다. 교대 근무로 인해 발생합니다. 그러나 누적 점수는 다음과 같이 생성됩니다. 검증 세트와 테스트 세트에서의 TFMAE는 항상 유사합니다. 이 비교는 우리의 대조 기준이 타당함을 입증합니다. 시계열 분포 변화를 효과적으로 완화하여 다음과 같은 결과를 가져옵니다. 임계값에서 더 높은 일반화 능력.

G. 모델 효율성 연구 (RQ6)

TFMAE의 효과성과 효율성을 평가하기 위해, 우리는 F1 점수, 학습 속도 및 GPU 메모리 크기를 표시합니다. TFMAE와 대규모 언어 모델 기반 시스템 간의 비교 GPT4TS 및 TranAD를 포함한 최첨단 기준선, AnoTran, TimesNet, DCdetector도 포함됩니다. 또한, 다음과 같은 항목도 포함합니다. 평가에서 TFMAE의 변형으로 "FFT 제외"라고 표기합니다.




그림 10: SMD에서 성능 지표를 비교합니다. 데이터셋, y축은 F1-점수를 %로 나타내고, y축은 속도 x축은 길이, 메모리 사용량의 의 크기로 표시됩니다. 각 방법에 해당하는 원입니다.

평가는 SMD 데이터셋을 기반으로 수행됩니다. 본 논문에서 가장 길고 두 번째로 큰 데이터셋입니다.

- "FFT 미사용": 이 버전은 계산 속도를 높이기 위해 FFT를 사용하지 않습니다. 변동계수 계산.

그림 10에서 볼 수 있듯이 TFMAE는 가장 높은 F1 값을 달성합니다. 점수는 가장 효율적인 GPU 메모리 활용률을 자랑합니다. 훈련 속도 면에서 2위를 차지합니다. TranAD는 탁월한 성능을 보여줍니다. 속도 측면에서는 메모리 사용량이 더 많고 성능이 더 낮습니다. TFMAE와 비교했을 때 TFMAE가 더 우수한 결과를 달성한다는 것을 시사합니다. 속도와 성능 간의 절충점과 탁월한 메모리 활용률을 자랑합니다. 또한, 눈에 띄게 감소된 성능은 다음과 같습니다. FFT를 사용하지 않은 훈련 속도는 그 효과성을 뒷받침합니다. FFT 기반 가속 기술을 사용합니다.

VI. 결론

본 논문에서는 새로운 시간-주파수 모델을 소개합니다. 시계열 이상 탐지를 위한 마스크드 오토인코더(TFMAE) TFMAE는 기존의 재구성 패러다임에서 벗어난 탐지 방식을 사용합니다. TFMAE는 이러한 차이를 활용합니다. 시간-주파수 마스킹 기반 표현을 대체하기 위해 기존의 재구성 오류를 줄이고 시계열 분포 변화의 영향을 완화합니다. 또한, TF-MAE는 윈도우 기반 시간 마스킹 전략을 통합합니다.

그리고 진폭 기반 주파수 마스킹 전략을 사용하기 전에 비정상적인 편향을 줄이기 위한 트랜스포머 기반 오토인코더 시계열 분석. 대조 분석 중 발생할 수 있는 과적합을 방지하기 위해 훈련 과정에서 적대적 목적 함수가 통합됩니다. TFMAE. 7개의 벤치마크 데이터셋에 대한 실험 결과 14에 비해 TFMAE의 우수한 성능을 보여줍니다. 기준선. 향후 연구에서는 TFMAE를 다른 시계열 데이터로 확장할 것입니다. 시계열 예측 및 분류와 같은 작업.

감사의 말씀

본 연구는 중국 국가자연과학기금(NSFC, 과제번호 61972069)의 부분적인 지원을 받아 수행되었습니다. (61836007 및 61832017), 선전시립과학부 기술 연구개발 자금 지원 기초 연구 프로그램 (JCYJ20210324133607021) 및 시 정부 취저우시, 보조금(번호 2022D037, 2023D044) 및 주요 데이터 인텔리전스 및 인지 컴퓨팅 연구소, 선전 룽화구.

참고문헌

[1] J. Li, S. Di, Y. Shen 및 L. Chen, "Fluxev: 사계열 이상 감지를 위한 빠르고 효과적인 비감독 프레임워크", WSDM 2021 회의록, 824-832쪽.

[2] Y. Zhao, L. Deng, X. Chen, C. Guo, B. Yang, T. Kieu, F. Huang, TB Pedersen, K. Zheng 및 CS Jensen, "사계열에 대한 비지도 이상 탐지에 대한 비교 연구: 실험 및 분석", arXiv 사전 인쇄 arXiv:2209.04635, 2022.

[3] Y. Liu, X. Ao, Z. Qin, J. Chi, J. Feng, H. Yang 및 Q. He, "선택 및 고르기: 사기 탐지를 위한 gnn 기반 불균형 학습 접근 방식" WWW, 2021, pp. 3168-3177.

[4] G. Andresini, A. Appice 및 D. Malerba, "네트워크 침입 탐지를 위한 오토인코더 기반 심층 메트릭 학습", 정보 과학, vol. 569, pp. 706-727, 2021.

[5] Y. Himeur, K. Ghanem, A. Alsalemi, F. Bensaali 및 A. Amira, "건물 에너지 소비의 인공지능 기반 이상 감지: 검토, 현재 동향 및 새로운 관점", Applied Energy, vol. 287, p. 116601, 2021.

[6] Y. Su, Y. Zhao, C. Niu, R. Liu, W. Sun 및 D. Pei, "확률적 순환 신경망을 통한 다변량 사계열의 강력한 이상 탐지", SIGKDD 2019 회의록, 2828-2837쪽.

[7] H. Wu, T. Hu, Y. Liu, H. Zhou, J. Wang 및 M. Long, "Timesnet: 일반 사계열 분석을 위한 시간적 2차원 변동 모델링", ICLR 2023 회의록, 1-23쪽.

[8] S. Tuli, G. Casale 및 NR Jennings, "Tranad: 다변량 사계열 데이터의 이상 탐지를 위한 심층 변환 네트워크", VLDB 회의록, 1201-1214쪽, 2022.

[9] Y. Fang, Y. Qin, H. Luo, F. Zhao, B. Xu, L. Zeng 및 C. Wang, "공간-시간과 웨이블릿이 만날 때: 효율적인 스펙트럼 그래프 주의 네트워크를 통한 분리된 교통 예측", ICDE 2023 회의록, 517-529쪽.

[10] Z. Lai, D. Zhang, H. Li, CS Jensen, H. Lu 및 Y. Zhao, "Lightcts: 상한 사계열 예측을 위한 경량 프레임워크", SIGMOD 회의록, 1권, 2호, 1-26쪽, 2023.

[11] T. Kim, J. Kim, Y. Tae, C. Park, J.-H. Choi 및 J. Choo, "분포 변화에 대한 정확한 사계열 예측을 위한 가역 인스턴스 정규화", ICLR 2021 회의록.

[12] J. Lv, Y. Wang, 및 S. Chen, "적응형 다변량 사계열 이상 탐지," 정보 처리 및 관리, 103383쪽, 2023.

[13] C. Zhang, T. Zhou, Q. Wen 및 L. Sun, "Tfad: 시간-주파수 분석을 통한 분해 사계열 이상 탐지 아키텍처", CIKM 2022 회의록, 2497-2507쪽.

[14] Y. Fang, Y. Qin, H. Luo, F. Zhao 및 K. Zheng, "Stwawe+: 분리된 교통 흐름 예측을 위한 장기 추세를 갖춘 다중 스케일 효율적인 스펙트럼 그래프 주의 네트워크", IEEE Transactions on Knowledge and Data Engineering, 2023.

[15] Z. Lai, H. Li, D. Zhang, Y. Zhao, W. Qian 및 CS Jensen, "E2usd: 다변량 사계열을 위한 효율적이고 효과적인 비지도 상태 감지," arXiv 사전 인쇄 arXiv:2402.14041, 2024.

[16] N. Passalis, A. Tefas, J. Kannianen, M. Gabbouj 및 A. Iosifidis, "사계열 예측을 위한 심층 적응 입력 정규화", IEEE 신경망 및 학습 시스템 거래, vol. 31, no. 9, pp. 3760-3765, 2019.

[17] Z. Shao, Z. Zhang, W. Wei, F. Wang, Y. Xu, X. Cao 및 CS Jensen, "교통량 예측을 위한 분리된 동적 공간-시간 그래프 신경망," VLDB 회의록, 2022년 2733-2746쪽.

[18] S. Jiang, T. Syed, X. Zhu, J. Levy, B. Aronchik 및 Y. Sun, "주기적 예측을 위한 자기 주의와 사계열 분해의 연결" CIKM 회의록, 2022, 3202-3211쪽.

[19] Y. Xue, S. Joshi, D. Nguyen 및 B. Mirzasoleiman, "분포 변화에 대한 다중 모델 대조 학습의 견고성 이해", arXiv 사전 인쇄 arXiv:2310.04971, 2023.

[20] MM Breunig, H.-P. Kriegel, RT Ng 및 J. Sander, "Lof: 밀도 기반 로컬 이상치 식별", SIGMOD 2000 회의록, 93-104쪽.

[21] J. Tang, Z. Chen, AW-C. Fu 및 DW Cheung, "낮은 밀도 패턴에 대한 이상치 탐지의 효율성 향상", PAKDD 회의록, 2002, 535-548쪽.

[22] B. Zong, Q. Song, MR Min, W. Cheng, C. Lumezanu, D. Cho 및 H. Chen, "비지도 이상 탐지를 위한 심층 자동 인코딩 가우시안 혼합 모델", ICLR 2018 회의록, 1-19쪽.

[23] T. Yairi, N. Takeishi, T. Oda, Y. Nakajima, N. Nishimura 및 N. Takata, "확률적 클러스터링 및 차원 축소를 기반으로 하는 위성 하우스카핑 데이터에 대한 데이터 기반 건강 모니터링 방법," IEEE 항공우주 및 전자 시스템 거래, vol. 53, no. 3, pp. 1384-1401, 2017.

[24] DM Tax 및 RP Duin, "지원 벡터 데이터 설명", Machine 학습, 제54권, 45-66쪽, 2004년.

[25] Z. Ghafoori, SM Erfani, S. Rajasegarar, JC Bezdek, S. Karunasekera 및 C. Leckie, "단일 클래스 지원 벡터 머신에 대한 효율적인 비지도 매개변수 추정," IEEE transactions on neural networks and learning systems, vol. 29, no. 10, pp. 5057-5070, 2018.

[26] L. Ruff, R. Vandermeulen, N. Goernitz, L. Deecke, SA Siddiqui, A. Binder, E. Muller 및 M. Kloft, "심층 단일 클래스 분류", ICML 2018 회의록, 4393-4402쪽.

[27] L. Shen, Z. Li 및 J. Kwok, "시간적 계층적 단일 클래스 네트워크를 사용한 사계열 이상 탐지" NeurIPS 2020 회의록, 13016-13026쪽.

[28] H. Ren, B. Xu, Y. Wang, C. Yi, C. Huang, X. Kou, T. Xing, M. Yang, J. Tong 및 Q. Zhang, "Microsoft의 사계열 이상 탐지 서비스," SIGKDD 2019 회의록, 3009-3017쪽.

[29] J. Gao, X. Song, Q. Wen, P. Wang, L. Sun 및 H. Xu, "Robustadt: 분해 및 합성 신경망을 통한 견고한 사계열 이상 감지," arXiv 사전 인쇄 arXiv:2002.09545, 2020.

[30] A. Blazquez-García, A. Conde, U. Mori 및 JA Lozano, "사계열 데이터의 이상치/이상 탐지에 대한 검토," ACM Computing Surveys (CSUR), vol. 54, no. 3, pp. 1-33, 2021.

[31] L. Deng, X. Chen, Y. Zhao 및 K. Zheng, "Hifi: 고차 특징 상호 작용이 있는 다변량 사계열에 대한 이상 탐지", DASFAA 회의록, 2021, 641-649쪽.

[32] Z. Li, Y. Zhao, J. Han, Y. Su, R. Jiao, X. Wen 및 D. Pei, "계층적 상호 측정 및 시간적 임베딩을 사용한 다변량 사계열 이상 탐지 및 해석", SIGKDD 2021 회의록, 3220-3230쪽.

[33] T. Kieu, B. Yang, C. Guo, R.-G. Cirstea, Y. Zhao, Y. Song 및 CS Jensen, "강력한 변분 준수한 오토인코더를 이용한 사계열의 이상 탐지", ICDE 2022 학술대회 논문집, 1342-1354쪽.

[34] T. Kieu, B. Yang, C. Guo, CS Jensen, Y. Zhao, F. Huang 및 K. Zheng, "비지도 사계열 이상치 탐지를 위한 견고하고 설명 가능한 오토인코더", ICDE 2022 회의록, 3038-3050쪽.

[35] B. Zhou, S. Liu, B. Hooi, X. Cheng 및 J. Ye, "Beatgan: 작대적으로 생성된 사계열을 사용한 비정상적인 리듬 감지," IJCAI 2019 회의록, 4433-4439쪽.

[36] J. Audibert, P. Michiardi, F. Guyard, S. Marti 및 MA Zuluaga, "Usad: 다변량 사계열에 대한 감독되지 않은 이상 탐지", Proceedings of SIGKDD, 2020, pp. 3395-3404.

[37] X. Chen, L. Deng, F. Huang, C. Zhang, Z. Zhang, Y. Zhao 및 K. Zheng, "Daemon: 다변량 사계열에 대한 비지도 이상 탐지 및 해석," ICDE 2021 회의록, 2225-2230쪽.

[38] X. Chen, L. Deng, Y. Zhao 및 K. Zheng, "비지도 사계열 이상 탐지 및 해석을 위한 작대적 오토인코더", WSDM 2023 회의록, 267-275쪽.

[39] Y. Zhao, X. Chen, L. Deng, T. Kieu, C. Guo, B. Yang, K. Zheng 및 CS Jensen, "크라우드소싱에서 스트리밍 작업 할당을 위한 이상치 감지" WWW 회의록, 2022, pp. 1933-1943.

[40] Y. Jiao, K. Yang, D. Song 및 D. Tao, "Timeautoad: 다변량 사계열에 대한 자체 지도 대조 손실을 사용하는 자율 이상 감지," IEEE 네트워크 과학 및 공학 거래, 9권, 3호, 1604-1619쪽, 2022.

[41] H. Kim, S. Kim, S. Min 및 B. Lee, "대조적 사계열 이상 탐지", IEEE 지식 및 데이터 엔지니어링 거래, pp. 1-14, 2023.

[42] J. Xu, H. Wu, J. Wang 및 M. Long, "Anomaly transformer: 연관 불일치가 있는 사계열 이상 감지", ICLR 2022 회의록, 1-20쪽.

[43] Y. Yang, C. Zhang, T. Zhou, Q. Wen 및 L. Sun, "Dcdetector: 사계열 이상 탐지를 위한 이중 주의 대조 표현 학습", SIGKDD 2023 회의록, 3033-3045쪽.

[44] K. He, X. Chen, S. Xie, Y. Li, P. Dollar 및 R. Girshick, "마스크 오토인코더는 확장 가능한 비전 학습입니다." CVPR 2022 회의록, 16000-16009쪽.

[45] C. Feichtenhofer, Y. Li, K. He 등, "공간-시간 학습기로서의 마스크된 오토인코더", NeurIPS 2022 회의록, 35946-35958쪽.

[46] Z. Hou, X. Liu, Y. Cen, Y. Dong, H. Yang, C. Wang 및 J. Tang, "Graphmae: Self-supervised masked graph autoencoders," SIGKDD 2022 회의록, 594-604쪽.

[47] Z. Shao, Z. Zhang, F. Wang 및 Y. Xu, "다변량 시계열 예측을 위한 사전 훈련 강화 공간-시간 그래프 신경망", SIGKDD 2022 회의록, 1567-1577쪽.

[48] Y. Ye, L. Xia 및 C. Huang, "순차적 추천을 위한 그래프 마스크 오토인코더", SIGIR 2023 회의록, 321-330쪽.

[49] Z. Li, L. Xia, Y. Xu 및 C. Huang, "공간-시간 그래프 신경망의 생성적 사전 훈련" NeurIPS 2023 회의록, 1-18쪽.

[50] Z. Feng 및 S. Zhang, "자기도 학습을 위한 진화된 부분 마스크", CVPR 2023 회의록, 10 386-10 395쪽.

[51] A. Siffer, P.-A. Fouque, A. Termier 및 C. Largouet, "극값 이론을 사용한 스트림의 이상 감지", SIGKDD 2017 회의록, 1067-1075쪽.

[52] P. Castagliola, G. Celano 및 S. Psarakis, "ewma 차트를 사용하여 변동 계수 모니터링", Journal of Quality Technology, vol. 43, no. 3, pp. 249-265, 2011.

[53] N. Wiener, "일반화된 조화 분석," Acta mathematica, vol. 55, no. 1, pp. 117-258, 1930.

[54] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, AN Gomez, . Kaiser, I. Polosukhin, "주의만 있으면 됩니다", Proceedings of NeurIPS, vol. 2017년 30월 30일.

[55] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong 및 W. Zhang, "Informer: 장기 시퀀스 시계열 예측을 위한 효율적인 변환기 그 이상," AAAI 회의록, 35권, 12호, 2021년, 11106-11115쪽.

[56] Y. Nie, NH Nguyen, P. Sinthong 및 J. Kalagnanam, "시계열은 64단어의 가치가 있습니다: 변환기를 사용한 장기 예측", arXiv 사전 인쇄 arXiv:2211.14730, 2022.

[57] X. Zhang, Z. Zhao, T. Tsiligkaridis 및 M. Zitnik, "시간-주파수 일관성을 통한 시계열에 대한 자체 지도 대조 사전 훈련" NeurIPS 2022 회의록, 3988-4003쪽.

[58] P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu 및 D. Krishnan, "지도 대조 학습", Proceedings of NeurIPS, vol. 2020년 33일, 18 661-18 673 페이지.

[59] K. Hundman, V. Constantinou, C. Laporte, I. Colwell 및 T. Soderstrom, "LSTM 및 비모수적 동적 임계값을 사용하여 우주선 이상 감지", SIGKDD 2018 회의록, 387-395쪽.

[60] A. Abdulaal, Z. Liu 및 T. Lancewicki, "비동기 다변량 시계열 이상 탐지 및 위치 파악에 대한 실용적인 접근 방식", SIGKDD 2021 회의록, 2485-2494쪽.

[61] AP Mathur 및 NO Tippenhauer, "Swat: ics 보안에 대한 연구 및 교육을 위한 수처리 테스트베드", 2016 스마트 물 네트워크를 위한 사이버 물리 시스템에 관한 국제 워크숍(CySWater), 2016, 31-36쪽.

[62] K.-H. Lai, D. Zha, J. Xu, Y. Zhao, G. Wang 및 X. Hu, "시계열 이상값 탐지 재검토: 정의 및 벤치마크", Proceedings of NeurIPS, 2021, pp. 1-13.

[63] FT Liu, KM Ting 및 Z.-H. Zhou, "격리된 숲", ICDM 회의록, 2008, 413-422쪽.

[64] T. Zhou, P. Niu, X. Wang, L. Sun 및 R. Jin, "One Fits All: 사전 훈련된 Im을 이용한 일반 시계열 분석의 강력한 기능" NeurIPS 2023 회의록, 1-34쪽.

[65] DP Kingma 및 J. Ba, "Adam: 확률적 최적화를 위한 방법" arXiv 사전 인쇄 arXiv:1412.6980, 2014.